

3D Gaussian Splatting의 Floater 및 Local Minima 해결을 위한 최신 연구 논문 본문 전체 번역집

A Complete Body Translation of 16 Selected 3DGS Papers
(Structured by 5 Core Technical Categories)

번역 및 편집: Antigravity AI 코딩 어시스턴트
대상 자료: 16편 논문 전체 텍스트 수집 및 자동 번역
작성일: 2026년 6월 23일

연구 흐름 소개 및 본문 번역 구성

본 문서는 3D Gaussian Splatting (3DGS)의 주요 난제인 Floater(플로터) 및 Local Minima(국소 최솟값) 문제를 해결하기 위해 다운로드된 16편의 논문 본문 전체를 한국어로 번역한 모음집입니다. 각 논문은 연구의 유사성과 맥락에 맞춰 5가지 핵심 카테고리별로 정렬되어 번역되었으며, 사용자가 원본 논문과 쉽게 대조할 수 있도록 본문 내에 원본 PDF의 페이지 경계 표시(예: [원본 PDF PAGE X])를 삽입하였습니다.

1. Floater = position(xyz) 계열

[논문 01] StableGS 본문 전체 번역

--- 페이지 1 ---
StableGS: 3D 가우스 스플래팅을 위한 플로터 없는 프레임워크
루차오 왕, 첸 렌, 카이민 랴오, 후아 왕, 즈첸, 야오화 탕
무어 스투드 AI
Tangyaohua28@gmail.com
초록
3D GS(3D Gaussian Splatting) 재구성이 어려움을 겪고 있습니다.
기하학을 저하시키는 완고한 "부유물" 인공물에 의해
시각적 충실도. 우리는 근본 원인을 가장 먼저 밝힙니다.
3DGS 최적화 프로세스의 근본적인 충돌
플로터의 불투명도 그라데이션은 블렌딩 시 사라집니다.
색상은 오류를 최소화하는 유사 평형에 도달합니다.
배경을 가짜 로컬 최소값에 가두는 것입니다.
이를 해결하기 위해 우리는 새로운 프레임워크인 StableGS를 제안합니다.
최종 모양 렌더링에서 기하학적 정규화를 분리합니다.
데링. 그 핵심은 두 가지를 생성하는 이중 불투명 아키텍처입니다.
별도의 렌더링 경로: "기하학적 정규화 경로"
구조적 정확성을 위해 강력한 깊이 기반 제약을 견뎌야 하며,
고충실도를 생성하기 위한 "외관 개선 경로"
이 안정적인 기반에 대한 자세한 내용을 확인하세요. 우리는 이것을 보완합니다
기하학적 제약의 시너지 효과 세트: 자체 감독
깊이 일관성 손실 및 외부 기하학적 사전 en-
효율적인 글로벌 규모 최적화 알고리즘을 통해 가능합니다.
여러 벤치마크에 대한 실험에서는 StableGS가
플로터를 제거하고 일반적인 흐림 현상도 해결합니다.
절충하여 최첨단 기하학적 정확도를 달성하고
시각적 품질.
소개
다중 뷰 이미지를 통해 새로운 사실적 뷰를 합성합니다.

연령은 컴퓨터 그래픽과 비전의 핵심 주제입니다. 3DGS (Kerbl et al. 2023)은 다음을 사용하여 중요한 혁신을 이루었습니다. 실시간 달성을 위한 명시적인 가우스 기반 표현 최고 수준의 품질로 렌더링하고 Novel을 크게 발전시킵니다. 합성 보기(NVS). 성공에도 불구하고 3DGS 재구성은 "플로터"라고 알려진 완고한 유물로 인해 어려움을 겪고 있습니다. 품질이 저하되는 잘못된 반투명 가우스 클러스터 기하학적 정확성과 시각적 사실성. 기존 방법은 - 플로터를 완화하고 싶은 유혹이 있지만 종종 심층적인 분석이 부족합니다. 근본 원인을 파악하지 못하여 타겟 솔루션을 제공하지 못합니다. 심층 분석을 통해 플로터의 근본 원인을 밝힙니다. 처음으로: 색상과 색상 사이의 본질적인 갈등 3DGS 파이프라인의 형상 최적화. 우리는 그것을 발견 플로터는 다음과 같은 경우 허위 로컬 최소값에 갇히게 됩니다. 알파 블렌딩된 색상은 의사 평형에 도달합니다. 여러 보기에 걸친 배경. 취소된 이 상태 색상 오류로 인해 불투명도 그라데이션이 사라지고 표준 최적화를 통해 제거할 수 없는 플로터 및 프레임워크의 근본적인 한계를 노출시킵니다. 이러한 최적화 교착 상태를 해결하기 위해 우리는 StableGS를 제안합니다. 기하학적 제약을 도입하는 것은 자연스러운 해결책이지만, 이를 렌더링된 출력에 직접 적용하면 해로움이 발생합니다. 외관 세부 사항. 우리의 핵심 기여인 Dual Opacity GS 모델은 기하학을 분리하여 이러한 절충안을 해결합니다. 최종 모양 렌더링의 정규화. 그것은 두 개의 개별 렌더링을 생성하는 보조 불투명 매개변수 경로: 가혹한 수신을 위한 '기하학적 정규화 경로' 기하학적 제약과 '외관 개선 경로' 충실도가 높은 외관을 위해. 이 디자인은 부정적인 부분을 분리합니다. 정규화의 실질적인 영향을 통해 강력한 전략을 가능하게 함 두 가지 보완적인 깊이 기반 손실을 기반으로 구축되었습니다. 첫째, 자체 감독 깊이 일관성 손실은 내부를 강화합니다. 외부 데이터가 없는 기하학적 무결성 서로 다른 뷰에서 렌더링된 깊이 맵 간의 일관성. 둘째, 까다로운 질감이 약한 영역을 처리하기 위해 단안 깊이 추정으로부터 기하학적 사전을 도입합니다. 우리의 소설과 기술을 통해 대규모 장면에 실행 가능하게 되었습니다. 변환하는 효율적인 글로벌 규모 최적화 알고리즘 다루기 힘든 스케일 정렬 문제를 컴팩트한 것으로 해결했습니다. 요약하자면, 우리의 주요 기여는 다음과 같습니다:

- 플로터의 근본 원인을 최초로 파악합니다.

그래디언트 소실 문제로 듀얼을 제안합니다.

모양과 형상을 분리하는 불투명 아키텍처 에이스. 이 설계는 강력한 정규화 체계를 가능하게 합니다. 자기 감독 일관성과 전 세계적으로 없이 부유물을 효과적으로 제거하기 위해 최적화되었습니다.

시각적 품질에 해를 끼칩니다.

- 광범위한 실험을 통해 StableGS가 그렇지 않다는 사실이 입증되었습니다.

플로터를 제거할 뿐 아니라 일반적인 문제도 해결합니다.

흐림-아티팩트 절충으로 우수한 성능 달성

도전적인 벤치마크.

관련 업무

Novel View Synthesis NVS는 보이지 않는 관점을 추론하는 것을 목표로 합니다.

단안 이미지 컬렉션의 정보입니다. NeRF(밀든홀

외. 2021) MLP 기반 복사장 모델 개척-

볼륨 렌더링을 사용하여 광범위한 후속 조치에 영감을 받았습니다.

검색. NeRF++(Zhang et al. 2020)와 같은 후속 작업,

Mip-NeRF(Barron et al. 2021) 및 Mip-NeRF360(Barron)

외. 2022) 향상된 렌더링 품질, Mip-NeRF360

레이콘 인코딩 및 지원을 통해 앤티앨리어싱을 달성했습니다.

왜곡 손실을 통한 압축 플로터. 한편, DVGO(썬,

arXiv:2503.18458v3 [cs.CV] 2025년 8월 4일

--- 페이지 2 ---

Sun 및 Chen 2022), Instant-NGP(Müller et al. 2022) 및

TensorRF(Chen et al. 2022)는 거의 가까운 수준으로 렌더링을 가속화했습니다.

실시간 속도. 3DGS의 출현(Kerbl et al. 2023)

명시적 3D 가우시안을 사용하여 새로운 패러다임을 확립했습니다.

Mip-NeRF360의 품질과 일치하는 기본 요소를 의미하는 동시에

그 효율성을 도저히 능가할 수 없어 현재의 주요 제품이 되었습니다.

스트림 접근 방식.

3DGS 개선 3DGS(Kerbl et al. 2023) 혁명-

다음은 제외하고 래스터화된 가우시안 렌더링을 통해 NVS를

성능. Mip-Splatting(Yu et al. 2024b) 감소

저역 통과 필터링을 통해 앨리어싱 아티팩트를 제거하는 동시에 치밀화

ABSGS를 통해 전략 개선이 나타났습니다(Ye et al.

2024)(그라디언트 절대 합) 및 GOF(Yu, Sattler 및

Geiger 2024) (결합된 경사 측정법). 기하학적 정규

표준화 접근법에는 2DGS가 포함됩니다(Huang et al. 2024).

2D 표면 및 RaDeGS에 가우스 투영(Zhang

외. 2024) 노멀 맵 제약 조건을 사용합니다. 비록 일부

연구(Huang et al. 2024; Zhang et al. 2024)는 NeRF-를 채택합니다.

플로터 감소를 위한 스타일 왜곡 손실을 보여줍니다.

접근 방식은 3DGS 관련 플로터를 부적절하게 해결합니다.

이상치 불투명도를 잘못 증가시켰습니다. 학습 가능한 서명된 Dis-

GSDF와 같은 SDF(Tance Field) 기반 방법(Yu et al. 2024a)

및 SuGaR(Gu'edon 및 Lepetit 2024)은 플로터를 완화했지만

해상도에 따른 매개변수화 제한 문제로 어려움을 겪었습니다.

확장성. 플로터 문제로 인해 색상 블록 아티팩트가 발생합니다.

렌더링된 이미지로 변환되어 시각적 품질이 저하됩니다. 그러나 아니오

이전 연구에서는 문제의 근본 원인을 체계적으로 조사했습니다.

이 현상은 효과적인 해결책을 제시하지도 않습니다.

고밀도 스테레오 모델 단안의 최근 발전

DUST3R(Wang et al. 2024)과 같은 깊이 추정 및 그
MASt3R(Leroy, Cabon 및 Revaud 2024)과 같은 후속 제품
및 Splatt3R(Smart et al. 2024)은 강력한 지리 정보를 제공했습니다.
미터법 사전. 우리는 뛰어난 성능으로 인해 작업에 DUST3R을 선택했습니다.
정확성이 낮습니다. 동시에 깊이 정규화가 이루어졌습니다.
Gaussian splatting을 향상시키는 일반적인 전략입니다. 되었습니다
퓨샷 NVS의 데이터 희소성을 해결하기 위해 사용됨(Chung,
Oh, and Lee 2024) 및 대규모 캡처(Kerbl et al.
2024). 다른 방법은 직접적으로 이미지를 찍기 전에 깊이를 활용합니다.
예를 들어 방지하기 위해 스피랏을 고정하여 기하학을 증명합니다.
로봇 데이터 세트의 드리프트(Lee et al. 2024) 또는 개발을 통해
더 나은 다중 시점을 위한 편견 없는 깊이 렌더링 기술
일관성(Chen et al. 2024).

방법론

예선

3DGS는 학습 가능한 3D 가우스 타원을 사용하여 장면을 나타냅니다.

고체 $G = \{G_k\}_K$

$k=1$, 여기서 각 Gaussian G_k 는 매개변수입니다.

중심 $\mu_k \in \mathbb{R}^3$, 불투명도 $k \in [0, 1]$, 색상으로 표시

$c_k \in \mathbb{R}^3$, 스케일 $s_k \in \mathbb{R}^3$, 회전 쿼터니언 $q_k \in \mathbb{R}^4$.

공간 지점 $x \in \mathbb{R}^3$ 에서 G_k 의 불투명도는 다음과 같이 지정됩니다.

$$k(x) = k \exp$$

- 1

$$2(x - \mu_k)^T - 1$$

$$k(x - \mu_k)$$

(1)

여기서 k 는 회전에서 파생된 공분산 행렬입니다.

및 스케일 매개변수. 단순화를 위해 c_k 색상을 사용합니다.

구형 고조파가 아닌 직접적으로.

새로운 뷰는 미분 가능한 래스터를 사용하여 렌더링됩니다.

화 파이프라인. 각 카메라 광선 r 에 대해 K_r Gaus-

해당 픽셀과 교차하는 시안은 다음과 같이 정렬됩니다.

깊이. 그러면 최종 색상 $c(r)$ 과 깊이 $d(r)$ 가 계산됩니다.

알파 블렌딩을 통해 복제됨: $c(r) = PK_r$

$$k=1 c_k(xr$$

$$k) k \text{ 및}$$

$$d(r) = PK_r$$

$$k=1 dr$$

$$k(xr$$

$$k) k, \text{ 여기서 } (xr$$

$$k) \text{ 불투명도 조절입니다.}$$

광선을 따른 k 번째 가우스 분포, dr

k 는 깊이,

$$k = Qk - 1$$

$j=1(1 \dots (x_r$
 $j))$ 는 투과율이다. 우리는

($\cdot$)는 렌더링된 출력을 나타냅니다. 모델은 다음과 같이 최적화됩니다.

렌더링된 이미지 C 와

실제 C_{gt} :

$$L3DGS = (1 - \alpha) L1(C, C_{gt}) + \alpha LD-SSIM(C, C_{gt}) \quad (2)$$

여기서 $L1$ 및 $LD-SSIM$ 은 $L1$ 및 $D-SSIM$ 손실입니다.

가우스 스피래팅의 플로터 분석

우리의 심층 연구에 따르면 플로터의 지속성은

잘 훈련된 모델의 오류는 최적화의 중대한 결함에서 비롯됩니다.

Mization 프로세스: 역전파 중 그래디언트가 사라지는 현상.

이는 모델이 완전히 제거하는 것을 불가능하게 만듭니다.

표준 색상 기반 손실만을 사용한 기하학적 오류.

이 메커니즘을 명확하게 설명하기 위해 간단한 분석을 수행합니다.

플로터 클러스터 최적화에 초점을 맞춘 시나리오

해당 실측 색상을 사용하여 M 광선을 통과합니다.

또는 $\{c_{gt}$

$m\}M$

$m=1$. 목표는 $L1$ 색상을 최소화하는 것입니다.

오류. 문제를 단순화하기 위해 나머지 부분은 다음과 같이 가정합니다.

장면은 완벽하게 재구성되었으며, 그 배경은

광선이 통과한 후 관찰되는 바탕색

클러스터는 Ground Truth와 동일합니다. 이론은 동안 -

최적의 조건은 모든 플로터 불투명도 α 가 0인 것입니다.

최적화는 종종 지역 최소값에 갇히게 됩니다. 이에

상태, 알파 블렌드 플로터에서 누적된 $color_{cf}$

클러스터는 주요 특징을 나타냅니다.

색상 차이의 징후가 나타나는 균형"

지상 진실은 모든 M 에서 서로를 거의 상쇄합니다.

보기:오후

$m=1$ 부호($cf - c_{gt}$

$m) \approx 0$. $L1$ 손실의 경우 이 결과는

dition은 축적된 색상의 그래디언션을 직접적으로 유발합니다.

cf 는 0에 접근합니다. 연쇄 법칙에 따르면, 이는

Turn은 두 가지 모두에 대한 그래디언트의 계단식 소멸을 트리거합니다.

불투명도 α 및 색상 c 매개변수. 우리는

다양한 손실 함수에 걸친 이 현상의 일반성,

$L1$ 과 MSE 를 포함합니다.

이러한 그래디언트 소멸 현상은 최적화를 방해합니다.

마이저는 플로터의 불투명도를 효과적으로 줄이지 못했습니다.

가우스, 기하학을 "제거"하는 것이 불가능하게 만듭니다.

캘리. 모델은 다음과 같은 로컬 최소값에 갇히게 됩니다.

기하학적으로 부정확하지만 색상 손실이 매우 낮습니다.

색상 기반에만 의존하는 본질적인 한계

기하학을 최적화하기 위한 손실. 그러나 플로터의 오류

기하학적 차원에서, 즉 깊이는 의미가 있습니다.

할 수 없고 모호하지 않다. 이는 우리가 깊이 있는 내용을 소개하도록 영감을 줍니다.

독립적인 손실 함수를 제공할 수 있는 기반 손실 함수
 잠재적으로 끌어당길 수 있는 더 강력한 기하학적 감독 신호
 이러한 가짜 로컬 최소값을 최적화합니다.
 이중 불투명 GS
 깊이 기반 손실을 도입하는 것은 실행 가능한 경로이지만
 그래디언트 소실 문제 해결, 직접 적용
 표준 3DGS 프레임워크 내에서는 수익 손실로 이어집니다.
 데리링 디테일. The strong gradients from a depth loss, while

--- 페이지 3 ---

플로터와 같은 기하학적 오류를 수정하는 데 효과적입니다.
 감독 신호에서 파생됨(다중 뷰 제약 사항 중 하나)
 또는 외부 사전) 필연적으로 소음과 부정확성을 포함합니다.
 인종. 이러한 불완전하지만 강력한 제약은 환경을 오염시킬 수 있습니다.
 모든 가우스 매개변수로 인해 세부 사항이 부드러워지고
 흐릿한 질감. 또한, 다음과 같은 반투명 물체의 경우
 유리 또는 물, 직접적인 깊이 감독은 심각한 해를 끼칠 수 있습니다.
 렌더링 정밀도.
 이 딜레마를 깨기 위해 우리는 새로운 아키텍처를 제안합니다.
 이중 불투명 가우스 스플래팅 모델. 핵심 목적
 이 디자인의 포즈는 그라데이션 소멸을 해결하는 것이 아닙니다.
 문제를 직접적으로 해결하는 것이 아니라 "방화벽" 메커니즘을 구축하는 것입니다.

깊이 기반 정규화를 효과적으로 견딜 수 있는 애니즘
 최종 모습에서 부작용을 분리하면서
 렌더링. 구체적으로, 추가 학습 가능 항목을 소개합니다.
 보조 불투명 매개변수 α
 $k \in [0, 1]$, 각 가우스에 대해
 G_k . 이제 원래 불투명도 매개변수인 k 가
 기본 기하학의 표현, $\mathbf{p}$
 k 는 다음을 수정하는 데 사용됩니다.
 최종 시각적 투명성을 평가합니다. 이를 바탕으로 우리는 정의합니다.
 두 가지 별개의 불투명도 함수:

- 기하학적 불투명도: $k(x)$, 표준과 동일
 k 만 사용하는 3DGS 정의(식 1).
- 렌더링 불투명도: α

$k(x) =$

$k(x)$ 는 다음과 같습니다.

두 불투명도 매개변수로 채워집니다.

이에 따라 우리 모델은 기능적으로 두 가지를 가지고 있습니다.

분리된 렌더링 경로:

- 기하학적 정규화 경로: 중간체를 렌더링합니다.
 기하학을 사용하여 컬러 맵 C_s 및 깊이 맵 D_s 를 먹었습니다.
 불투명도 $\alpha(x)$. 이 경로의 출력은 독점적으로 제공됩니다.
 후속 깊이 기반의 감독 대상으로
 손실 기능.
- 외관 개선 경로: 최종, 고급 렌더링

품질 색상 맵 C_o 및 깊이 맵 렌더링 사용-
 불투명도 $'(x)$.
 이 디커플링 아키텍처는 깊이를 만드는 핵심입니다.
 기반 손실은 정말 효과적입니다. 우리는 자신있게 힘을 가할 수 있습니다.
 기하학적 정규의 출력에 대한 완전한 깊이 제약 -
 화 경로, D_s . 결과적으로 강한 기울기가 직접적으로 작용합니다.
 기본 기하학적 매개변수를 바탕으로 효과적으로 제거
 플로터 및 전체 형상 수정. 결과
 디테일 손실이나 외관 왜곡은 이 범위 내에 국한됩니다.
 기하학적 경로. 외모 개선 경로 덕분에
 학습 가능한 보조 매개변수 $'$
 k 는 이러한 것로부터 보호됩니다.
 거친 기하학적 그래데이션. 이는 “기하학적”을 기반으로 합니다.
 비계”는 이미 구조가 보장되었습니다.
 기하학적 경로를 학습하고 세밀한 색상 학습에 중점을 둡니다.
 고품질을 달성하는 데 필요한 반투명 효과
 실제 이미지 C_{gt} 와 일치합니다.
 모델의 전반적인 손실 함수는 색상 손실로 구성됩니다.
 L_{color} 및 기하학 손실 $L_{geometry}$:
 $L_{total} = L_{color} + L_{geometry}$ (3)
 색 손실 L_{color} 에는 두 경로 모두에 대한 감독이 포함됩니다.
 $L_{color} = L_{3DGS}(C_o, C_{gt}) + L_1(C_s, C_{gt})$. 첫 번째 용어
 최종 렌더링에 적용되는 기본 모양 손실입니다.
 출력. 두 번째 항 $L_1(C_s, C_{gt})$ 은 보조 손실입니다.
 기본 기하학적 표현을 장려하는 $'$ 로 가중됩니다.
 불투명한 부분을 설명하기 위한 문장(k 가 지배함)
 그림 1: 그림은 두 가지 RadeGS 렌더링 결과를 보여줍니다.
 방 데이터 세트 훈련 세트의 예시 이미지(그림 (a)
 및 (b)) 및 그 뒤뜰린 결과(그림 (c) 및 (d)). 에이
 그림 (a)의 왼쪽 상단에 보이는 플로터가 투영됩니다.
 그림 (d)의 빨간색 상자 영역으로, 해당
 그림 (b)의 빨간색 상자 영역은 정확한 깊이 측정을 표시합니다.
 말. 그림 (b)의 제약 조건을 그림 (d)에 적용하면,
 부유물을 효과적으로 제거할 수 있습니다.
 가능한 한 장면. 결과적으로, 그래데이션
 보조 매개변수 $'$ 에 대해
 k 는 주로 re -에서 나옵니다.
 기하학적 경로로는 완벽하게 모델링할 수 없는 영역,
 반투명 표면과 미세한 구조로. 기하학 용어
 기하학에 적용되는 모든 정규화 용어로 구성됩니다.
 깊이 맵 D . 이에 대해서는 다음 섹션에서 자세히 설명합니다.
 자체 감독 깊이 일관성
 분리된 아키텍처를 기반으로 먼저 다음을 소개합니다.
 자기 감독 기하학적 제약. 현장의 장점을 활용한 것입니다.
 결함이 있는 기하학적 구조를 수정하기 위한 고유한 다중 뷰 일관성
 구조, 특히 부유물은 전-에 의존하지 않고
 내부 데이터. 핵심 아이디어는 깊이 맵이 다음에서 렌더링된다는 것입니다.

i, Ds 보기
 i, 다른 뷰 j로 워프될 때 일치해야 함
 해당 뷰에서 직접 렌더링된 깊이 맵, Ds
 j. 플로터,
 잘못된 깊이 값(일반적으로 평균
 자신의 깊이와 배경)은 이 원칙을 위반합니다.
 이러한 잘못된 깊이 값을 다른 뷰로 워프하면
 올바른 기하학에 대한 큰 불일치로 인해

그림 1에 표시된 것처럼 제거를 위한 강한 기울기 신호입니다.

1. 구체적으로 깊이 일관성 손실 Lconsis를 정의합니다.
 이는 우리의 깊이 맵 D에만 독점적으로 적용됩니다.
 기하학적 정규화 경로. 선택한 이미지 세트의 경우
 쌍 P의 경우 손실은 다음과 같습니다.

Lconsis =

X

(i,j)∈P

$W_{i \rightarrow j}(\mathbf{D}_s$

$i) \mathbf{D}_s$

$j \mid 1 + \mid W_{j \rightarrow i}(\mathbf{D}_s$

$j) \mathbf{D}_s$

나는 스 1

(4)

여기서 $W_{i \rightarrow j}$ 는 미분 가능한 워핑 연산자입니다.
 알려진 카메라 포즈를 사용하여 view_i 에서 j로 점을 재투영합니다.
 손실은 유효하게 투영된 영역에 대해서만 계산됩니다. 받는 사람
 이 손실의 안정성과 효율성을 보장하는 훈련
 P의 쌍은 세 가지 기준을 사용하여 선택됩니다. 1) 숫자
 두 개 사이의 COLMAP에서 공동으로 볼 수 있는 특징점

--- 페이지 4 ---

충분한 중첩을 보장하려면 뷰가 30보다 커야 합니다.

2) 상대 회전 각도는 $16^\circ - 60^\circ$ 로 제한됩니다.

극단적인 기준선을 방지하기 위해 3) 특징의 비율

호모그래피 행렬을 따르는 포인트는 0.8 미만이어야 합니다.

거의 순수한 회전으로 인해 발생하는 퇴화 사례를 억제합니다.

효율적인 전역 최적화를 통한 외부 우선 순위

약하게 기하학적 정확도가 떨어지는 문제를 해결하려면

질감이 있거나 질감이 없는 영역(예: 흰색 벽, 매끄러운

층) 시각적인 특징이 부족하여 다음과 같은 내용을 소개합니다.

단안 깊이 추정의 내부 기하학적 사전

모델 DUST3R. 모든 이미지 쌍(i, j)에 대해 DUST3R 출력

두 개의 연관된 포인트 맵, $X_{1,1}$

i, j 및 $X_{2,1}$

i, j 는 그들의

신뢰도 지도, $C_{1,1}$
 i, j 및 $C_{2,1}$
 나, 제이. 여기, $X_{1,1}$
 i, j 는
 자체 카메라에 있는 이미지 i 의 점에 대한 3D 좌표
 프레임, $X_{2,1}$
 i, j 는 이미지 j 의 점을 나타냅니다.
 내 카메라 프레임. 그러나 결정적인 병목 현상은 다음과 같습니다.
 각 쌍별 예측은 독립적이고 알려지지 않은 변수에 존재합니다.
 확장되어 전역 3D 재구성에 사용할 수 없게 됩니다.
 일관된 글로벌로 깊이 사전 세트를 얻으려면
 scale, 우리는 새롭고 효율적인 글로벌 규모의 옵션을 제안합니다.
 최적의 스케일 팩터를 계산하는 최적화 알고리즘
 모든 이미지 쌍에 대해 $S = \{s_{i,j}, s_{j,i}\} \mid (i,j) \in P$ 입니다. 우리의 최적화
 목표는 두 가지 핵심 구성 요소로 구성됩니다.
 쌍별 포인트 클라우드 정렬 이 목표는
 각 쌍 (i, j) 에 대해 해당 점을 요구합니다.
 구름은 변환된 후 3D 공간에서 정렬됩니다.
 각각의 스케일 팩터와 카메라 포즈, T_i
 그리고 T_j . 정렬 오류는 $L_{\text{pair}}(i, j)$ 로 제공됩니다.

$[C(i, j), C(j, i)] \quad ([s_{i,j} T_i, -s_{j,i} T_j]$

"

엑스 1,1
 나는, $j \times 2,1$
 나, j
 엑스 2,1
 $j, i \times 1,1$
 j, i
 #

, 여기서 de-
 요소별 곱셈과 $C(i, j)$ 에 주목하세요.

$C_{1,1}$
 나는, $j \times 2,1$
 j, i
 $C_{1,1}$
 $i, j + C_{2,1}$
 j, i

.

전체 원시 포인트 클라우드에서 이러한 정렬 오류 최소화
 엄청난 메모리와 메모리로 인해 계산하기가 어렵습니다.
 처리 오버헤드.
 우리의 핵심 기여는 행렬 분해 기반 등가물입니다.
 이러한 높은 수준을 엄격하게 단순화하는 풍부한 변환
 차원 포인트 클라우드 정렬 문제를 낮은 수준으로
 단지 7개의 "등가점"에 대한 차원 최적화입니다.

결과적으로, 우리는 쌍방향 정렬을 효율적으로 표현할 수 있습니다.

$L_{\text{pair-eff}}(i, j) = B_{u,j} \quad (s_{i,j} T_{ixi,j} \quad s_{j,i} T_{jy,j}) r_2$ 로 손실
2,

여기서 $x_{i,j}, y_{i,j} \in \mathbb{R}^{3 \times 7}$ 및 $w_{i,j} \in \mathbb{R}^7$ 은 동일합니다.

원본에서 분해된 포인트 및 해당 가중치

최종 포인트 클라우드.

동등성 증명: 일반적인 가중치 집합 일치의 경우

문제는 다음과 같이 공식화됩니다. $\|J \quad (A_1 Y \quad$

$1 + b_1 \quad A_2 Y \quad$

$2 \quad b_2)\|,$

여기서 $A_1, A_2 \in \mathbb{R}^{3 \times 3}$ 및 $b_1, b_2 \in \mathbb{R}^{3 \times 1}$ 은 임의를 나타냅니다.

3D 아핀 변환, $Y_1, Y_2 \in \mathbb{R}^N \times 3$ 은 소스를 나타냅니다.

및 목표점, $J \in \mathbb{R}^{1 \times N}$ 은 가중치를 나타낸다. 하자

$b = b_1 \quad b_2$, 공식은 동등하게 표현될 수 있습니다

다음과 같이:

$\|J \quad ([A_1, -A_2, b][Y_1, Y_2, 1]^\top)\|$

$= [A_1, \quad A_2, b] [Y_1, Y_2, 1]^\top \text{diag}(J \quad 2)[Y_1, Y_2, 1]$

$\|z\|$

$[A_1, -A_2, b]^\top$

$= [A_1, -A_2, b] V^\top \text{대각선}(\quad 2) V [A_1, -A_2, b]^\top$

여기서 $V^\top \text{diag}(\quad 2) V$ 는 고유값 분해를 구성합니다.

$V \in \mathbb{R}^{7 \times 7}$ 및 $\quad \in \mathbb{R}$ 인 괄호 안의 용어 위치

$\mathbb{R}^7$. 이는 포인트 매칭 형식으로 다시 공식화될 수 있습니다.

$\|w \quad ([A_1, \quad A_2, b][x, y, 1]^\top)\|$, 여기서 $w = \quad V[:7], x =$

$V[:1 \quad 3]/V[:7], y = V[:4 \quad 6]/V[:7], V[:.]$ 는 상관 관계를 나타냄

V 의 응답 열입니다.

Cross-Pair Scale Consistency 통일된 글로벌을 보장하기 위해

규모, 우리는 다음과 관련된 규모를 더욱 제한합니다.

동일한 이미지가 서로 다른 쌍에서 일관되게 유지됩니다. 우리

정규화 용어 $L_{\text{intra}}(i, j) =$ 를 사용하여 이를 구현합니다.

$C(i, a)$

$s_{i,j} \times 1, 1$

$i, j \quad s_{i,a} \times 1, 1$

나, 아

1

, 이는 일탈을 처벌합니다.

신뢰도가 높은 "앵커"에서 쌍의 규모로

쌍". 앵커 쌍 인덱스 $a = \arg \max_k (P \quad C_{1,1}$

$i, k)$ 그렇죠

에 대한 신뢰도가 가장 높은 페어링에 응답합니다.

이미지 나.

이러한 구성 요소를 결합하여 최종 글로벌 규모의 옵션은

Mization 문제는 다음을 효율적으로 해결하기 위해 공식화되었습니다.

컴팩트한 등가점만 사용하는 스케일 팩터 S :

분
에스
 X
 $(i, j) \in P$

$L_{\text{pair-eff}}(i, j) + L_{\text{intra}}(i, j) + L_{\text{intra}}(j, i)$

(5)

실제로 동일한 방법으로 카메라 포즈를 최적화할 수도 있습니다.

SfM(Structure-from-Motion)을 직접 수행하는 방식과

TSDF를 통해 조밀한 MVS 재구성을 달성합니다.

전역적으로 일관된 스케일 팩터 S 를 구한 후,

우리는 신뢰할 수 있는 깊이 사전 세트를 생성할 수 있습니다.

깊이 맵 $d_{i,j} = s_{i,j} \times 1, 1$

i, j [z]의 크기가 올바르게 조정되었습니다. 그러면 우리는

기하학적 사전 손실 L_{prior} 를 정의합니다.

기하학적 정규화 경로의 깊이 맵 D :

$L_{\text{이전}} =$

X

$(i, j) \in P$

$(D(i, j) + D(j, i))$ (6)

여기서 $D(i, j) = 1$

$|d_{i,j}| > 0$

피

$C1, 1$

아이,제이 | D_s

나는 $d_{i,j}$

, $rr \cdot rr$ 0은

L_0 표준이고 합산은 모든 유효한 픽셀 p 에 대한 것입니다. 작성자:

이 손실을 최소화하면서 우리 모델은 올바른 기하학을 학습합니다.

텍스처가 약한 영역에서는 분리된 아키텍처가

이전의 노이즈가 데이터를 오염시키지 않도록 보장합니다.

최종 고품질 외관 렌더링. 마지막으로 우리 총

기하학 손실은 두 정규화의 가중 합입니다.

용어:

기하학 = $\text{consis}L_{\text{consis}} + \text{prior}L_{\text{prior}}$

우리는 전체 프레임워크를 StableGS라고 명명합니다. 듀얼

Opacity GS 모델은 기본 아키텍처 역할을 합니다.

형상과 모양에 대한 분리된 경로를 제공합니다.

이 아키텍처에서는 두 가지 보완적인 요소를 조정합니다.

정규화 전략: 자기 감독 깊이는 다음과 같습니다.

강도 손실은 고유한 구조적 무결성을 강화하는 반면

전역적으로 최적화된 기하학적 사전은 특히 문제를 해결합니다.

길고 질감이 없는 영역. 이러한 체계적인 설계로

StableGS는 표준의 플로터 아티팩트를 제거할 뿐만 아니라

3DGS뿐만 아니라 뛰어난 기하학적 정확성과
도전적인 장면을 재구성할 때 외관 충실도.

실험

실험적 설정

우리의 작업은 차별화 가능한 깊이 렌더링을 기반으로 구현합니다.

RaDeGS(Zhang et al. 2024)에서 Taming-

3DGS 훈련 파이프라인. 모든 실험은 30,000으로 실행됩니다.

--- 페이지 5 ---

건축물 mipnerf360 실내 mipnerf360 실외 블렌더 탱크&템플

PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

3DGS(업데이트) 31.160 0.9255 0.1859 26.348 0.7882 0.2058 29.646 0.9070 0.2387 23.933 0.8562 0.1697

미스플래팅 30.971 0.9242 0.1870 26.384 0.7912 0.2051 29.622 0.9050 0.2431 23.836 0.8531 0.1737

GOF 30.465 0.9178 0.1888 26.566 0.8052 0.1852 29.569 0.9059 0.2427 23.592 0.8530 0.1682

라데GS 30.509 0.9213 0.1887 26.704 0.8119 0.1753 29.530 0.9073 0.2416 23.897 0.8560 0.1673

길들이기-3DGS 31.107 0.9225 0.1926 26.645 0.7997 0.1948 30.031 0.9065 0.2395 24.117 0.8546 0.1732

Lprior가 없는 StableGS 31.548 0.9283 0.1762 26.733 0.8102 0.1716 30.123 0.9111 0.2341 24.165 0.8577

0.1628

3DGS+깊이 31.029 0.9245 0.1861 26.379 0.7875 0.2058 29.976 0.9086 0.2363 24.070 0.8558 0.1668

안정적GS 31.542 0.9281 0.1761 26.738 0.8105 0.1715 30.190 0.9113 0.2347 24.196 0.8590 0.1610

표 1: mipnerf360, Blender 및 Tanks&Temples의 성능 비교. 굵은 글씨는 방법 중 가장 좋은 방법을 나타냅니다.

사전에 깊이가 없습니다.

그림 2: 흐릿한 문제. 카펫의 첫 번째 행 텍스트 세부 사항, 의자 아래의 두 번째 행 잔디, 세 번째 행에 주목하세요.

행 바닥 세부정보(특히 오른쪽 하단 모서리 영역) 우리의 방법은 더 미세한 이미지 세부 정보를 보존합니다.

단일 NVIDIA A100 GPU에서의 반복. 우리는

학습률 및 기타 하이퍼파라미터는

오리지널 3DGS. 제안된 손실에 대해 가중치를 설정합니다.

모든 실험에서 $\text{consis} = 0.05$ 및 $\text{prior} = 0.005$ 입니다.

우리는 세 가지 데이터셋에 대한 방법을 평가합니다: MipNeRF-360

(Barron 외. 2022), 탱크 및 사원(Knapitsch 외. 2017),

및 딥 블렌딩(Hedman et al. 2018). MipNeRF의 경우-

360 데이터 세트를 사용하여 절반 해상도의 이미지를 학습합니다.

측면을 유지하면서 가장 긴 가장자리를 1600픽셀로 확장

비율. 이전 작업(Kerbl et al. 2023)과 일치하여 우리는 다음을 사용합니다.

PSNR, SSIM 및 LPIPS를 이미지 품질 지표로 사용합니다. 우리는-

우리의 방법을 다음을 포함한 몇 가지 강력한 기준선과 비교해 보십시오.

3DGS(Kerbl et al. 2023)가 최신 안정 릴리스로 업데이트되었습니다.

공식 저장소인 Mip-Splatting(Yu et al. 2024b)에서

Taming-3DGS(Mallick et al. 2024), GOF(Yu, Sattler 및

Geiger 2024) 및 RaDeGS. 공정한 비교를 위해 최종

StableGS 및 Taming-3DGS의 가우스 카운트는 다음과 같습니다.

3DGS와 일치하도록 제어됩니다.

비교

결과는 표 1에 제시되어 있으며, 이는 우리의 방법을 보여줍니다.

일반적으로 기존 접근 방식보다 성능이 뛰어납니다. 먼저 비교해보겠습니다

깊이를 사용하지 않는 'StableGS w/oLprior' 변형

기준선에 대한 추정자. MipNeRF-360 실내에서
 장면에서 우리의 방법은
 아마도 이러한 작업이 잘 구조화되어 있기 때문일 것입니다.
 장면을 사용하면 깊이 기반 손실이 특히 효과적입니다.
 tive. 야외 장면의 경우 우리의 방법과 RaDeGS가 모두 보여줍니다.
 StableGS의 성능이 약간 더 좋아 상당한 선두를 달리고 있습니다.
 RaDeGS의 핵심 혁신은 가우시안을 제한하는 반면
 우리의 방법은 다음을 통해 고품질의 결과를 얻습니다.
 깊이 기반 정규화. 블렌더와 탱크 및 온도에 대해
 여러 데이터 세트를 사용하더라도 우리의 방법은 최상의 결과를 얻습니다. 아니-
 표로, 우리의 방법은 훨씬 더 나은 LPIPS 점수를 달성합니다.
 모든 실험에서. 우리는 이것을 개선에 기인합니다
 플로터를 해결하여 얻은 미세한 디테일 렌더링
 문제.
 또한 깊이를 사용하는 방법과 비교합니다.
 사전. 우리의 전체 StableGS 모델은 훨씬 더 뛰어난 성능을 발휘합니다.
 Kerbl et al.에 제시된 '깊이 정규화가 포함된 3DGS'

--- 페이지 6 ---

그림 3: 플로터 문제. 첫 번째 줄 천장과 오른쪽 위 벽 영역, 두 번째 줄의 눈에 띄는 인공물에 주목하세요.
 왼쪽 상단 및 오른쪽 상단 모서리; 그리고 3열 벽면. 우리의 방법은 아티팩트를 크게 줄이고 제거합니다.
 플로터 문제.
 그림 4: 약한 질감의 영역 재구성. 첫 번째 행의 타일 간격과 두 번째 행의 벽 모서리를 관찰합니다.
 깊이 사전을 통합하는 방법만이 이러한 고주파 특성을 성공적으로 복원하며, 우리의 접근 방식은 다음을 달성합니다.
 가장 날카로운 재구성.
 2024), 깊이는 DepthAnything(Yang)에 의해 추정됩니다.
 외. 2024). 우리는 두 가지 모두에 대한 지표 개선이 이루어졌다는 점에 주목합니다.
 '깊이 정규화가 적용된 3DGS'(3DGS 이상)과 우리의 전체
 'StableGS'('StableGS w/oLprior' 이상)는 적당합니다. 이것은
 왜냐하면 깊이 사전은 재구성을 크게 향상시킬 수 있기 때문입니다.
 기능이 약한 지역의 정확도가 향상되었습니다.
 표준 이미지 공간 측정항목에 항상 완전히 반영되는 것은 아닙니다.
 우리는 다음에서 이러한 구체적인 이점을 설명할 것입니다.
 세 가지 관점의 정성적 분석: 흐릿한 문제 해결
 부유물을 제거하고 약한 텍스처를 재구성합니다.
 지역. 우리는 이전의 모든 방법이 예를 통해 보여줄 것입니다.
 od는 흐릿하거나 떠다니는 문제를 겪는 반면, Sta-
 bleGS는 도입 없이 블러를 동시에 제거합니다.
 플로터. 더욱이, 기하학적 사전확률을 통합함으로써, Sta-
 bleGS는 기능이 약한 영역에서 최상의 결과를 제공합니다.
 기존 방법과 비교됩니다.
 흐릿함. 그림 2에서 볼 수 있듯이 원래 3DGS는
 눈에 띄는 흐림. 앨리어싱 해결에도 불구하고 Mip-Splatting
 문제는 흐려짐을 악화시킵니다. Taming-3DGS에도 불구하고
 향상된 치밀화 전략은 여전히 흐림 문제를 겪고 있습니다. 에서
 대조적으로 우리의 StableGS는 가장 선명한 결과를 얻습니다.
 플로터. 그림 3의 모든 기준선은 GOF 치밀화를 사용합니다.

전략을 사용하고 있으며 모두 다양한 정도의 플로터를 보여줍니다.
 결과는 깨끗합니다.
 약한 질감의 영역. 그림 4에서 우리는 ren-
 Mip-Splatting, Taming-3DGS 및

--- 페이지 7 ---

그림 5: 그림 (a)-(d)는 Dual Opacity GS의 두 가지 렌더링 모드를 비교하며 첫 번째 행은 모양을 나타냅니다.
 구체화 경로와 두 번째 행은 기하학적 정규화 경로입니다. 그림 (e)는 표준 3DGS(첫 번째 행)와 3DGS를 대조합니다.
 깊이 정규화(두 번째 행)를 사용하면 직접적인 깊이 통합으로 인해 정밀도가 저하된다는 것을 알 수 있습니다. 그림 (f)는
 주방 데이터세트의 깊이 맵 결과는 Lprior가 없는 StableGS(첫 번째 행)와 StableGS(두 번째 행)를 비교하여
 재구성 충실도에 대한 깊이 사전의 영향.

그러한 지역의 RaDeGS. 구체적인 기여를 입증하기 위해
 깊이 있는 사전 손실과 조밀한 초기화를 고려하여
 또한 비교를 위해 'StableGS w/oLprior' 결과도 보여줍니다.
 아들. StableGS가 최고의 성능을 달성하는 것을 볼 수 있습니다.
 벽과 같은 까다로운 영역에서 가장 날카로운 모서리 생성
 모서리.

절제 연구

우리의 Dual Opacity GS 아키텍처는 광고를 효과적으로 격리합니다.
 깊이 기반 손실의 반대 효과. 그림 5-(b)에 도시된 바와 같이,
 기하학적 정규화가 발생하기 전 깊이의 정확도
 꽃 스파이크의 세부 묘사가 손실된 이미지를 렌더링하는 경로입니다.
 그러나 모양 렌더링 경로에서는 이러한 미세한 디-
 꼬리가 성공적으로 복구되었습니다. 마찬가지로 반투명의 경우
 본질적으로 깊이 손실 문제가 있는 물체,
 그림 5-(d)는 Appearance Rendering Path를 보여줍니다.
 반투명 영역을 올바르게 복원합니다. 대조적으로,
 그림 5-(e)는 깊이 제약을 적용한 결과를 보여준다.
 동일한 케이스의 표준 3DGS에 직접 연결됩니다. 이것은 다음으로 이어진다
 반투명 병의 정밀도가 크게 떨어지고 흐려짐
 그것을 통해 본 배경. 전체 방법은 다음과 같습니다.
 그림 5-(c)는 정확하고 선명한 렌더링을 생성합니다.
 깊이 일관성 손실: 우리는 실험적으로 보여줍니다.
 반투명 물체에 대한 깊이 일관성 손실의 효과
 켄트. 그림 5-(d)에서 볼 수 있듯이 기하학적 정규화
 Path는 유리병을 깊이가 불투명한 고체로 처리합니다.
 기하학적 일관성 제약 조건을 충족하기 위해 매핑합니다. 이
 우리의 방법이 객체의 솔리드를 올바르게 학습했음을 나타냅니다.
 기하학. 그러나 이로 인해 렌더링된 이미지 품질이 저하될 수 있습니다.
 병 뒷면의 흐릿함에서 알 수 있듯이
 그림 5-(c)의 렌더링된 이미지에서. 외관상으로는 르네-
 경로를 지정하면 병이 올바르게 다시 투명해집니다.
 다른 개체는 영향을 받지 않은 상태로 유지됩니다. 이는 다음을 보여줍니다.
 보조 불투명 매개변수 '가 성공적으로 모델링 학습
 반투명 재질의 불투명도.
 Depth Prior Loss : 그림 5-(f)는
 기능이 약한 지역의 깊이 사전 손실. 그것은 분명하다
 사전에 깊이를 도입한 후 잘 관찰되지 않거나 약하게-

질감이 있는 영역이 보다 효과적으로 복구됩니다. 그것은 매우 중요하다
손실이 기하학적 정규에 적용되는 동안
ization Path, 그림 5-(f)에 표시된 깊이 맵은
모양 렌더링 경로. 이는 최적화 방법을 보여줍니다.
기하학적 경로를 적용하는 것은 외관에 긍정적인 영향을 미칩니다.
개선 경로. 우리의 방법은 성공적으로 상관 관계를 활용합니다.
형상을 개선하기 전 깊이의 반사 기능
도전적인 지역에서는 디커플링 메커니즘이
일반적으로 깊이와 관련된 정밀도 손실을 방지합니다.
최종 고품질 출력에 영향을 미치지 않도록 감독합니다.
결론 및 한계
이 논문은 3DGS 훈련의 지역 최소 문제를 다룬다.
우리가 추적하는 지속적인 플로터 아티팩트를 유발하는 ing
그라디언트 소실 현상이 발생합니다. 우리는 StableGS를 제안합니다.
Dual Opacity GS 아키텍처를 중심으로 한 새로운 방법
참. 이 아키텍처는 형상과 모양을 분리합니다.
시너지 세트 적용을 위한 견고한 기반 제공
자기 감독을 포함한 기하학적 제약 조건의 구성
텐시 손실 및 해를 끼치지 않고 전역적으로 최적화된 사전

렌더링 품질. 우리의 방법은 최첨단 성능을 달성합니다.
형성, 피하면서 플로터를 성공적으로 제거
일반적인 흐림-아티팩트 트레이드오프 및 도전에 탁월함
질감이 약한 장면을 촬영합니다. 우리는 또한 몇 가지 한계를 인식합니다.
향후 작업에 대한 반복 및 방향. 우리의 paired 사용
이미지 및 보조 불투명도 매개변수로 메모리 증가
그리고 계산 오버헤드. 게다가 의존도는
깊이 일관성을 위한 충분한 다중 뷰 공동 가시성
손실은 현재 이 방법의 적용 가능성을 소수로 제한합니다.
향후 연구를 위해 남겨두는 새로운 관점 합성 작업-
게이트.

--- 페이지 8 ---

참고자료

배런, J.T.; 밀든홀, B.; 탄치크, M.; 헤드먼, P.; 마틴-
브루알라, R.; 및 Srinivasan, P. P. 2021. Mip-nerf: 멀티스케일
안티 앨리어싱 신경 복사 필드에 대한 표현입니다. 에서
IEEE/CVF 국제 컨퍼런스 진행
컴퓨터 비전, 5855-5864.
배런, J.T.; 밀든홀, B.; 베르빈, D.; 스리니바산, P.P.;
및 Hedman, P. 2022. Mip-nerf 360: 무제한 안티앨리어싱
신경 방사 필드. IEEE/CVF 절차에서
컴퓨터 비전 및 패턴 인식에 관한 회의, 5470-
5479.
첸, A.; 쉬, Z.; 가이거, A.; 유제이; and Su, H. 2022. 10-
sorf: 강력 복사장. 유럽회의에서는
컴퓨터 비전, 333-350. 뛰는 것.

첸, D.; 리, H.; 응, W.; 왕, Y.; 시에, W.; 자이, S.; 왕, N.; 리우, H.; 바오, H.; and Zhang, G. 2024. Pgsr: 평면 기반 효율적이고 충실도가 높은 표면 재구성을 위한 가우스 스피래팅 건설. 시각화 및 컴퓨터에 대한 IEEE 트랜잭션 그래픽.

정제이; 아, J.; and Lee, K.M. 2024. 심층 정규화 몇 장의 이미지에서 3D 가우스 스피래팅을 최적화합니다. IEEE/CVF 컴퓨터 회의 진행 중

비전과 패턴 인식, 811-820.

구에돈, A.; 및 레페티(Lepetit), V. 2024. 슈가: 표면정렬 효율적인 3D 메쉬 재구성을 위한 가우스 스피래팅 고품질 메시 렌더링. 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인정, 5354-5363.

헤드먼, P.; 필립, J.; 가격, T.; 프람, J.-M.; Drettakis, G.; 및 Brostow, G. 2018. 자유 시점을 위한 딥 블렌딩 이미지 기반 렌더링. 그래픽에 대한 ACM 트랜잭션 (ToG), 37(6): 1-15.

황, B.; 유, Z.; 첸, A.; 가이거, A.; 및 Gao, S. 2024. 2d 기하학적으로 정확한 복사장을 위한 가우스 스피래팅. ACM SIGGRAPH 2024 컨퍼런스 논문, 1-11.

커블, B.; 코파나스, G.; Leimkuhler, T.; 및 Drettakis, G. 2023. 실시간 복사장 렌더링을 위한 3D 가우스 스피래팅 데링. ACM 트랜스. 그래프., 42(4): 139-1.

커블, B.; 뮐레만, A.; 코파나스, G.; 위머, M.; 랑방, A.; and Drettakis, G. 2024. 계층적 3D 가우스 표현 매우 큰 데이터 세트의 실시간 렌더링을 위한 표현입니다. ACM 그래픽 거래(ToG), 43(4): 1-15.

크나피치, A.; 박제이; Zhou, Q.-Y.; 및 쿨튼, V. 2017. 탱크 및 사원: 대규모 장면 재구성 벤치마킹 건설. 그래픽에 대한 ACM 트랜잭션(ToG), 36(4): 1-13.

이영수; 최제이; 정다; 윤제이; 류, S.; 마노차, D.; and Jeong, S. 2024. Mode-GS: 단안 깊이 안내 견고한 지상 뷰를 위한 고정된 3D 가우스 스피래팅 장면 렌더링. arXiv 사전 인쇄 arXiv:2410.04646.

리로이, V.; 카본, Y.; 및 Revaud, J. 2024. 접지 이미지 mast3r과 3D 매칭. 유럽회의에서 컴퓨터 비전, 71-91. 뛰는 것.

말릭, S.S.; 고엘, R.; 커블, B.; 스타인버거, M.; 카라스코, F.V.; 및 De La Torre, F. 2024. 3dgs 길들이기: 고품질 자원이 제한된 라디언스 필드. 시그라프 아시아에서 2024 컨퍼런스 논문, 1-11.

밀든홀, B.; 스리니바산, P.P.; 탄치크, M.; 배런, J.T.; 라-마모르티, R.; and Ng, R. 2021. Nerf: 장면 표현 뷰 합성을 위한 신경 방사 필드로 사용됩니다. 커뮤니케이션 ACM, 65(1): 99-106.

Müller, T.; 에반스, A.; 쉬드, C.; 및 Keller, A. 2022. 인스턴트

다중 해상도 해시 인코딩이 포함된 신경 그래픽 프리미티브
ing. 그래픽의 ACM 트랜잭션(TOG), 41(4): 1-15.
스마트, B.; 정, C.; 레이나, I.; 및 Prisacariu, V. A. 2024.

Splatt3r: 보정되지 않은 이미지에서 제로샷 가우스 스플래팅
나이 쌍. arXiv 사전 인쇄 arXiv:2408.13912.

썬, C.; 썬, 엠.; 및 Chen, H.-T. 2022. 직접 복셀 그리드
최적화: 복사장 재검토를 위한 초고속 수렴

건설. IEEE/CVF 회의 진행 중

컴퓨터 비전 및 패턴 인식, 5459-5469.

왕, S.; 리로이, V.; 카본, Y.; Chidlovskii, B.; 그리고 레보,
J. 2024. Dust3r: 기하학적인 3D 비전이 쉬워졌습니다. 진행중-
컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스의 내용과
패턴 인식, 20697-20709.

양, L.; 강비; 황, Z.; 자오, Z.; 쉬, X.; 팡, J.;

및 Zhao, H. 2024. Depth Anything V2. arXiv:2406.09414.

예, Z.; 리, W.; 리우, S.; Qiao, P.; 그리고 도우, Y. 2024. Absgs: 재-
3D 가우스 스플래팅으로 미세한 디테일을 다룹니다. 절차 중
제32차 ACM 국제 멀티미디어 컨퍼런스에서,
1053~1061.

유, M.; 루, T.; 쉬, L.; 장, L.; Xiangli, Y.; 그리고 다이, B.

2024a. Gsdf: 3dgs와 sdf가 만나 향상된 렌더링 및
재건축. arXiv 사전 인쇄 arXiv:2403.16964.

유, Z.; 첸, A.; 황, B.; 새틀러, T.; 및 가이거, A. 2024b.

미프 스플래팅(Mip-splatting): 앨리어싱이 없는 3D 가우스 스플래팅. 진행중-
컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스의 내용과
패턴 인식, 19447-19456.

유, Z.; 새틀러, T.; 및 Geiger, A. 2024. 가우스 불투명도
분야: 무제한의 효율적인 적응형 표면 재구성

장면. ACM 그래픽 트랜잭션(TOG), 43(6): 1-13.

장, B.; 팡, C.; 슈레스타, R.; 리양, Y.; 룡, X.; 그리고

Tan, P. 2024. Rade-gs: 가우스 스플래팅의 깊이 래스터화.
arXiv 사전 인쇄 arXiv:2406.01467.

장, K.; 리글러, G.; 스네이블리, N.; 및 콜튼, V. 2020.

Nerf++: 신경 복사장 분석 및 개선.

arXiv 사전 인쇄 arXiv:2010.07492.

[논문 02] Plug-and-Play PDE Optimization 본문 전체 번역

--- 페이지 1 ---

3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화:

고품질 렌더링 및 재구성

익명의 저자

제출물 ID: 2152

렌더링

타원체

렌더링

타원체

깊이

메쉬

깊이

메쉬

3DGS 3DGS+PDEO

2DGS+PDEO2DGS Ground Truth

그림 1. 3D 가우스의 안정적인 최적화를 가능하게 하고 기존 기능을 향상시키도록 설계된 새로운 플러그 앤 플레이 최적화 프레임워크인 PDEO를 제시합니다.

새로운 뷰 합성 및 표면 재구성과 같은 작업을 위한 3DGS 기반 접근 방식입니다. 우리의 방법은 렌더링과 작업 모두에서 고품질 결과를 달성합니다.

재건축. 더 많은 결과는 첨부된 비디오에서 제공됩니다.

3D GS(3D Gaussian Splatting)는 복사장 재구성에 혁명을 일으켰습니다.

빠른 렌더링으로 고품질의 새로운 뷰 합성을 달성하여

장면을 표현하기 위해 3D 가우스 프리미티브를 도입했습니다. 그러나,

3DGS를 복잡한 장면에 적용하면 흐릿함과 플로터가 발생합니다.

중복되고 모호한 기하학적 구조의 재구성으로 인한

구조. 우리는 이 문제를 Gauss의 불안정한 최적화에 기인한다고 생각합니다.

시안. 이러한 제한을 해결하기 위해 우리는 플러그 앤 플레이 PDE 기반을 제시합니다.

3DGS의 최적화 제약을 극복하는 최적화 방법

새로운 시점 합성, 표면 등 다양한 작업에 대한 기반 접근 방식

재건축. 첫째, 이론적으로 3DGS 최적화를 도출합니다.

절차는 PDE로 모델링될 수 있으며 점성 항을 도입하여 다음을 보장합니다.

안정적인 최적화. 둘째, MPM(Material Point Method)을 사용합니다.

PDE의 안정적인 수치해를 구해 전역적 특성을 향상시킵니다.

그리고 지역적 제약. 또한 효과적인 가우스 치밀화 전략은

세밀한 세부 사항을 보장하기 위해 Egy 및 입자 제약 조건이 도입되었습니다.

광범위한 정성적, 정량적 실험을 통해 우리의 방법이 다음과 같이 확인되었습니다.

최첨단 렌더링 및 재구성 품질을 달성합니다.

CCS 개념: • 컴퓨팅 방법론 → 렌더링; 포인트 기반

모델; 기계 학습 접근 방식 • 컴퓨팅 수학

→ 미분 방정식.

개인 또는 개인을 위해 이 저작물의 전체 또는 일부를 디지털 또는 하드 카피로 만들 수 있는 권한

사본을 만들거나 배포하지 않는 한 강의실 사용은 무료로 허용됩니다.

이익 또는 상업적 이익을 위해 사본에 이 공지와 전체 인용문이 포함되어 있음

첫 페이지에. ACM이 아닌 다른 사람이 소유한 이 저작물의 구성 요소에 대한 저작권

존경받아야 합니다. 신용으로 추상화하는 것이 허용됩니다. 다른 방식으로 복사하거나 다시 게시하려면,

서버에 게시하거나 목록에 재배포하려면 사전 특정 허가 및/또는
수수료. Permissions@acm.org에 권한을 요청하세요.

© 2025 컴퓨팅 기계 협회.

0730-0301/2025/9-ART \$15.00

<https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

추가 핵심 단어 및 문구: 새로운 뷰 합성, 래디언스 필드, 3D

가우스, PDE

ACM 참조 형식:

익명의 저자. 2025. 3D 가우스를 위한 플러그 앤 플레이 PDE 최적화-

ian Splatting: 고품질 렌더링 및 재구성을 향하여. ACM

트랜스. Graph.1, 1(2025년 9월), 15페이지. <https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

nnnnnnnn

1 소개

다중 뷰 이미지에서 3D 장면을 재구성하는 것은 고전적인 방법입니다.

컴퓨터 비전과 컴퓨터 그래픽에 문제가 있습니다. 최근 발전

NeRF(Neural Radiance Fields)에서 [Mildenhall et al. 2021] revo-

암시적 신경 표현을 도입하여 이 작업을 해결했습니다.

최첨단 결과를 달성합니다. 주목할만한 후속 조치는 3D Gauss입니다.

이안 스플래팅(3DGS) [Kerbl et al. 2023], 이는 점점 증가하고 있습니다.

고품질의 실시간 렌더링 성능으로 주목받고 있으며,

명시적인 포인트 기반 표현과 효율적이기 때문입니다.

스플래팅 과정.

복잡한 장면에 적용하면 3DGS는 흐려지고

그림 1에서 검증된 플로터로 인해 렌더링 성능이 저하됨

그리고 재건 품질. 그림 2(a)에서 볼 수 있듯이 3DGS는

큰 가우시안을 사용하여 장면의 공백을 메우려고 합니다.

고주파 세부사항을 정확하게 표현하기 위해

재구성 및 눈에 보이는 흐림. 비록 작은 가우스는

고주파 장면 세부 사항을 캡처하는 데 더 효과적이며 경향이 있습니다.

그림 2(b)에서 볼 수 있듯이 수많은 플로터를 도입합니다. 지역

장면 적용 범위가 제한되어 있으면 새로운 관점에서 플로터를 생성하는 경향이 있습니다.

가우시안은 훈련 보기에 맞춰 최적화되어 있기 때문입니다.

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사. 출판일: 2025년 9월.

arXiv:2509.13938v1 [cs.GR] 2025년 9월 17일

--- 페이지 2 ---

2 • 곧. 제출 ID: 2152

기존 작품 [Ye et al. 2024년; Zhang et al. 2024b] 분할 제안

다음을 사용하여 큰 가우스를 더 많은 수의 작은 가우스로 변환합니다.

효과적인 치밀화 기준. 이러한 방법은 적응형을 사용합니다.

과도한 수의 가우시안으로 장면을 피팅하여 접근합니다.

이는 저장 효율성도 렌더링에도 효과적이지 않습니다.

집중적인 연구를 통해 작은 이유를 알아냈습니다.

가우스는 불안정한 최적화 경향이 있습니다. 에 따르면

그래디언트 계산에서 위치 그래디언트의 크기는 다음과 같습니다.

다른 속성 그래데이션보다 훨씬 높습니다.

가우스 스케일이 작습니다. 결과적으로 3DGS는 이러한 작은 가우시안을 장면에 맞게 조정하여 최적화를 방해합니다. 최적화 프로세스 중 다른 가우스 속성. 이 갑작스러운 위치 변화로 인해 중복되고 모호한 지리적 위치가 발생합니다. 미터법 구조. 안정적인 그래디언트 최적화를 보장하기 위해 기존 그래디언트 최적화 방법은 일반적으로 그래디언트 클립을 강조합니다. 핑 [Pascanu et al. 2013년; Zhang et al. 2019], 정규화 [Ioffe 2015; Santurkaret al. 2018], 체중 감소 [Yong et al. 2020; Zhang et al. 2018]. 그러나 이러한 방법은 본질적으로 경험적입니다. 필연적으로 정보 손실로 이어집니다. 본 논문에서는 3DGS가 원래의 최적화를 우회할 수 있도록 하는 것을 목표로 합니다. 약점을 보완하고 보다 효율적이고 안정적인 최적화를 달성합니다. tion. 위의 관찰을 바탕으로 우리는 다음을 제안합니다. 통찰력: (1) 3DGS 최적화 절차는 다음과 같이 모델링될 수 있습니다. 편미분 방정식(PDE)의 이산화. 이에 공식화하면 3DGS의 속성이 함수로 처리됩니다. 시간의. (2) 유체 시뮬레이션에서 영감을 얻었습니다 [Müller et al. 2003], 우리는 갑작스러운 움직임을 억제하기 위해 PDE에 점성 항을 도입합니다. 변경하고 안정적인 최적화를 달성합니다. 점성 용어는 로컬 평균 속도를 통해 입자를 효과적으로 제한합니다. 입자 운동의 급격한 변화를 방지합니다. 우리는 새로운 플러그 앤 플레이 최적화 프레임워크를 제안합니다. 기존 3DGS 기반 응용 프로그램을 향상시키는 PDEO라고 하는 PDE에 대해 새로운 시점 합성, 표면정밀화 등의 과제를 위한 제안 건설. 목표는 큰 가우스를 더 작은 크기로 조정하는 것입니다. 고주파 세부 사항을 더 잘 포착하고 향상된 렌더링을 위한 작은 가우스의 안정적인 최적화 건설 및 재건 품질. 먼저, 이론적으로 도출해보겠습니다. 3DGS 최적화 절차는 PDE로 모델링될 수 있으며, 안정적인 최적화를 보장하기 위해 점성 용어를 도입합니다. 둘째, 우리는 MPM(Material Point Method)을 사용합니다. [Jiang et al. 2016] ~ PDE를 풀어 전역 및 지역 제약 조건을 모두 적용합니다. 최적화를 위해. 마지막으로 명시적인 입자 제약 조건을 제안합니다. 이에 따라 소규모, 신뢰도가 높은 가우시안을 시행합니다. 입자 가설과 효과적인 가우스 치밀화 세밀한 세부 사항을 보장하는 전략입니다. 광범위한 실험 우리의 PDEO가 최첨단 방법을 개선했음을 입증합니다. 플러그 앤 플레이 오프타이머로서 지속적으로 성능을 향상시킵니다. 새로운 뷰 합성과 표면 재구성 모두에서. 요약하면 주요 기여는 다음과 같습니다.

- 우리는 새로운 플러그 앤 플레이 최적화 프레임워크를 제안합니다.

기존 3DGS 기반 애플리케이션을 향상시키는 PDE 기반 새로운 뷰 합성 및 표면 재구성에 대한 제안입니다.

- 3DGS 최적화 절차를 PDE로 공식화합니다.

안정적인 최적화를 보장하기 위해 점성항을 도입합니다. 가우스. 훈련 보기

소설보기

(아)

(비)

3DGS

3DGS

3DGS+PDEO

3DGS+PDEO

(다)

그림 2. 3D 가우시안 최적화. (a) 대형 3D의 중복 가우스. (b) 작은 3D 가우스의 모호함. (c) 시각화 결과.

2 관련 업무

2.1 새로운 견해 종합

NeRF(Neural Radiance Fields)의 최근 성공 [Mildenhall 외. 2021]은 다음을 달성하는 암시적 장면 표현을 도입합니다. 새로운 뷰 합성으로 높은 렌더링 품질을 제공합니다. 후속 방법 [배런 외. 2022; 필립과 데샹트르 2023; Warburget al. 2023년; Wirthet al. 2023]은 원래 NeRF를 개선하기 위해 제안되었습니다. 에 대한 예를 들어, Mip-NeRF [Barron et al. 2022] 새로운 기능을 제안합니다 개선하기 위해 통합 위치 인코딩 표현 렌더링 품질. 나중에 MipNeRF360[Barron et al. 2022] 연장 이 방법은 비선형 장면을 사용하여 무한한 장면을 구현합니다. 라미터화. 또 다른 연구 분야 [Chen et al. 2023년; Liu et al. 2023년; Somraj 및 Soundararajan 2023] 효율성 개선에 중점을 둡니다. 학습 및 렌더링 가속화를 제안하는 NeRF의 기술 체적 특징을 도입함으로써 [Fridovich-Keil et al. 2022; 유 외. 2021] 또는 희소 해시 기반 그리드 [M ller et al. 2022]. 3D 가우스 스피래팅(3DGS) [Kerbl et al. 2023] 열차 개선- 이방성 3D 가우시안 도입으로 생성 및 렌더링 속도 향상 순방향 래스터화를 지원하는 효율적인 스피래팅 및 비용이 많이 드는 샘플링 및 쿼리의 단점을 방지합니다. 일부 3DGS에 대한 후속 작업은 새로운 기능의 성능을 더욱 향상시킵니다. 합성을 봅니다. 예를 들어, AbsGS [Ye et al. 2024] 그리고 프레스 [장 외. 2024b] 달성하기 위해 3DGS의 치밀화 전략을 강화합니다. 보다 정확한 밀도 조정. GES [Hamdi et al. 2024], 디스크- GS [Quet al. 2024] 및 3D-HGS [Li et al. 2024] 기초를 다듬다 ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 3 ---

3D 가우스 스피래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 3 더 많은 사전 정보를 제공하기 위해 3D 가우스 함수 표현을 사용합니다. 정확하고 상세한 표현. 최근에는 3DGS2[Lan et al. 2025] 3DGS를 위한 2차 수렴 학습 알고리즘을 제안합니다. 훈련 속도가 10배 향상됩니다.

2.2 신경 표면 재구성

표면 제약이 없기 때문에 NeRF는 추출할 수 없습니다. 고품질 표면. NeuS [Wang et al. 2021] Signed를 소개합니다. 장면의 기하학적 표면을 표현하는 거리 필드(SDF) 보다 정확한 결과를 얻기 위해 렌더링 공식을 개선합니다.

결과. 신경란젤로 [Li et al. 2023]은 해시 인코딩을 도입합니다.
 상세한 대규모 장면 재구성을 가능하게 하는 SDF. 바이너리 불투명 그리드 [Reiser et al. 2024] 불연속 불투명 그리드를 사용하여 장면을 표현하여 보다 정확한 표현이 가능합니다.
 그러나 이러한 방법에는 계속해서 상당한 교육이 필요합니다.
 볼륨 렌더링의 높은 계산 비용으로 인해 시간이 걸립니다.
 최근에는 다양한 연구[Chung et al. 2024년; Geiger et al. 2024년; Jianget al. 2016; Zhang et al. 2024a] 3DGS를 표면으로 확장했습니다.
 재건축. 예를 들어, SuGaR [Gordon and Lepetit 2024]은 다음과 같습니다.
 3D 가우스를 장려하는 정규화 용어를 소개합니다.
 표면과 정렬되어 더욱 효과적인 메쉬 추출이 가능해집니다.
 tion. GOF [유 외. 2024b] 레이 트레이싱 기반 볼륨 제안
 비로부터 지오메트리를 직접 추출할 수 있는 렌더링 접근 방식
 제한된 장면. 2DGS [Geiger et al. 2024] 및 RaDeGS [Zhang et al. 2024a] 형상 구성을 적용하여 가우스로 표면을 근사화합니다.
 긴장과 깊이 정보를 통합합니다. 이것들과는 다른
 명시적인 기하학적 제약을 도입하는 방법, 우리의 방법
 PDE 기반 최적화 전략을 사용하여 보다 안정적인 작업을 달성합니다.
 중복되고 모호한 부분을 최적화하고 효과적으로 제거합니다.
 기하학적 구조.

2.3 기울기 최적화

최적화 과정에서 하나의 그라데이션이 발생하는 것은 드문 일이 아닙니다.
 다른 것보다 훨씬 더 큰 것으로 알려진 현상

이는 최적화에서 널리 알려진 문제인 그라데이션 폭발입니다.
 그라데이션 클리핑 [Pascanu et al. 2013] 널리 사용되는 기술이다.
 이는 Gradient에 상한을 적용하여 Gradient를 제한합니다.
 규모가 다릅니다. 후속 연구 [Qian et al. 2021; Zhang et al. 2019]는 이러한 접근 방식을 기반으로 보다 적응력이 뛰어난 기술을 도입했습니다.
 절단 방법. 배치 정규화(BN) [Ioffe 2015; 산투르카르 외. 2018] 속성을 정규화하여 그라디언트를 제한합니다.
 변환을 통해 보다 안정적인 최적화를 촉진합니다.
 마이징 과정. 체중 감소 [Yong et al. 2020; Zhang et al. 2018]
 제약 조건에 안정화 항을 추가하여 손실 함수를 수정합니다.
 그라데이션. 이러한 방법은 합리적인 제약을 부과하지만
 그라디언트에서는 필연적으로 정보 손실이 발생합니다.
 원래 그라데이션. 대조적으로, 우리의 접근 방식은 통치를 수정합니다.
 PDE는 무결성을 유지하면서 기울기를 안정화합니다.

원래 그라데이션 정보.

2.4 재료 포인트 방식

가상 세계의 자연 현상을 시뮬레이션하는 것은 중요한 응용 분야입니다.
 이는 여전히 매우 어려운 일입니다. 머티리얼 포인트 방식
 (MPM) [Sulsky et al. 1995]가 효과적인 것으로 입증되었습니다.
 다양한 고체/유체 짝을 시뮬레이션하기 위한 하이브리드 입자/그리드 방법
 편미분방정식(PDE)의 해법에서 실수, 신흥
 PIC(Particle-in-Cell)와 Fluid Implicit의 일반화로서
 입자(FLIP) 방법 [Jiang et al. 2016]. MPM 방법 결합

라그랑지안 물질 입자 [Bargteil et al. 2006년; 우멘호퍼 외. 2019] 오일러 데카르트 그리드 사용 [Takagi et al. 2012; 톰프-아들 외. 2017], 다음을 사용하여 초기 PDE 문제를 이산화합니다. 물질 입자. 예를 들어, Stomakhin et al. [Stomakhinet al. 2013] MPM을 사용하여 눈을 시뮬레이션하여 설득력 있는 결과를 얻었습니다. 결과. Yue et al. [Yue et al. 2015] MPM이 또한 품과 같은 복잡한 유체를 시뮬레이션하는 데 적합합니다. 이 작품에서는 우리는 3DGS 최적화를 PDE로 모델링하는 PDE-GS를 제안합니다. 3DGS 최적화를 해결하기 위해 MPM을 도입하고 보다 안정적이고 효율적인 최적화를 달성합니다.

3 예비 및 동기 부여

3.1 예비

3.1.1 3D 가우스 스피래팅. 3DGS [Kerbl et al. 2023]은 주변 정보를 캡슐화하는 학습 가능한 3D 가우스 세트 장면을 명시적으로 표현하기 위한 것입니다. 각 3D 가우스 는 중앙 위치 , 불투명도의 학습 가능한 속성으로 매개변수화됨 , 색상 c 및 공분산 행렬 ,

$$\rho(\mathbf{x}) = \exp(-\frac{1}{2}(\mathbf{x} - \mu)^T \Sigma^{-1}(\mathbf{x} - \mu)) \quad (1)$$

여기서 공분산 행렬 는 회전 행렬 로 표시됩니다.

스케일링 행렬 은 = 입니다.

이미지를 렌더링하기 위해 3D 가우시안이 이미지 평면을 스피래팅을 통해 2D 가우시안으로 변환합니다. 작업 [Zwicker et al. 2001]. 그 후, 픽셀의 색상 -블렌딩을 사용하여 정렬된 가우스를 결합하여 계산됩니다.

$$C = \sum_{i \in \mathcal{C}} \alpha_i c_i$$

$$\alpha_i = \frac{\rho_i}{\sum_{j \in \mathcal{C}} \rho_j} \quad (2)$$

여기서 는 2D 가우스에 불투명도를 곱하여 계산됩니다.

ity .

3.1.2 중요 포인트 방식. MPM [Jiang et al. 2016]은 이산적이다.

고체 및 유체 시뮬레이션에 널리 사용되는 PDE 해결 방법

[물러 외. 2003]. MPM은 두 가지 관점을 결합합니다.

시스템: 라그랑지안 설명과 오일러 설명.

라그랑주 설명에서 시스템은 이산적인 시스템으로 간주됩니다.

수많은 독립적인 입자로 구성된 상, 각각 부여됨

고유한 속성을 가지고 있습니다. 대조적으로, 오일러의 설명은 다음을 다룬다.

글로벌 설명을 가능하게 하는 연속체 단계로서의 시스템

입자 운동의.

특히, 입자의 운동 방정식은 시간이 지남에 따라 진화합니다

as: $(\mathbf{x}, \mathbf{v}) =$

, 여기서 는 속도이고 는 위치입니다. 그렇다면 MPM

는 다음과 같이 함수를 분리하는 데 사용됩니다. $(\mathbf{x}, \mathbf{v}) = \mathbf{x} + \mathbf{v} \Delta t$.

3.2 기울기 분석

3DGS는 장면 최적화를 위해 경사하강법을 사용합니다.

이는 고품질 장면 표현을 달성하는 데 필수적입니다.

각 가우스 는 훈련 가능한 속성 세트와 연관되어 있습니다.

$\mathbf{c} = \{c_0, c_1, c_2, c_3, c_4, c_5, c_6, c_7, c_8, c_9, c_{10}, c_{11}, c_{12}, c_{13}, c_{14}, c_{15}\}$, 여기서 c_0 는 중앙 위치를 나타내고, c_1 구면 조화 계수를 나타내고 c_2 는 불투명도를 나타냅니다.

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 4 ---

4 • 곧. 제출 ID: 2152

속성, s 는 스케일 속성을 나타내고, q 는 쿼터니언입니다.

회전 속성을 나타냅니다. 여기서 $\sigma = \text{Sig}(\cdot)$ 는

여기서 $\text{Sig}(\cdot)$ 는 시그모이드 함수를 나타냅니다. $s = \text{특급}(s)$

스케일링 벡터를 나타냅니다. 최적화하는 동안 각 항목이 업데이트됩니다.

속성은 다음과 같이 주어진다.

$$\Delta =$$

$$\mathbf{c} \in \mathbb{R}^{16} \quad (3)$$

여기서 $\mathbf{c}$ 는 학습률을 나타내고 $\mathbf{L}_2$ 는 손실 함수를 나타냅니다.

단순화를 위해 L_2 손실이 있는 단일 픽셀 을 고려합니다. $\mathbf{c} =$

$\|\mathbf{c}\|_2$, 여기서 $\mathbf{c}$ 및 $\mathbf{c}$ 는 렌더링된 색상을 나타내고

각각 픽셀 의 실제 색상입니다. 손실의 기울기

체인 규칙을 사용하여 계산할 수 있습니다.

$$= 2(\mathbf{c} \cdot \mathbf{c})$$

$$\mathbf{c} \in \mathbb{R}^{16} \quad (4)$$

픽셀 과 관련된 시야 광선 을 따라 통합함으로써

정렬된 가우스를 고려하면 방정식은 다음과 같이 확장될 수 있습니다.

$$=$$

$$\sum$$

$$\in$$

$$(\mathbf{c} \cdot \mathbf{c}) \text{ 시그}(\cdot)$$

$$\int$$

$$\mathbf{x} \in \mathbb{R}^3 \quad (\mathbf{x} \cdot \mathbf{x})$$

$$(5)$$

$$\mathbf{c} = \mathbf{c} \cdot \mathbf{c}$$

$$= 1 \quad (1 \cdot 1)$$

$$= 1 \quad (1 \cdot 1)$$

부록 A.1에서 볼 수 있듯이 위치의 크기는

기울기가 다른 매개변수의 기울기보다 훨씬 큼니다.

가우시안의 스케일이 작을 때 그래디언트.

C

S

$(q \cdot \dots,)$ (6)

여기서 는 점근적 동등성을 나타내고, , 은 업데이트를 나타냅니다.

의 방향은 쿼터니언의 정의에 따라 결정됩니다.

4가지 방법

본 논문에서는 새로운 플러그 앤 플레이 최적화 프레임틀을 제안합니다.

PDE를 활용하여 렌더링을 향상시키는 PDEO라는 작업

3DGS 기반 방법의 재구성 품질. 개요

우리의 프레임워크는 그림 3에 나와 있습니다. 섹션 4.1에서는 먼저

3DGS 최적화 절차에 대한 PDE 공식화 및

최적화의 안정성을 높이기 위해 점성 항을 도입했습니다.

둘째, Particle-to-Grid에 의한 PDE를 해결하기 위해 MPM을 사용합니다.

(P2G) 및 섹션 4.2의 G2P(Grid-to-Particle) 전략. 마지막으로,

우리는 소규모, 높은 수준의 성능을 강화하기 위해 명시적인 입자 제약 조건을 제안합니다.

입자 가설에 따른 신뢰도 가우스

섹션 4.3.

4.1 PDE 기반 3DGS 최적화

이 섹션에서는 3DGS에 대한 PDE 공식을 설정합니다.

3DGS 최적화를 제어할 수 있는 최적화 절차

PDE를 명시적으로 수정하여

4.1.1 공식화. PDE에서 시간은 다음의 순서를 나타냅니다.

속성 업데이트 프로세스를 통해 시스템 상태 전환 가능

반복과 유사하게 속성을 변경하여 다음 상태로 이동

3DGS 최적화 단계. 따라서 가우시안의 속성은 다음과 같습니다.

업데이트 프로세스는 시간 의 함수입니다. 오리지널 3DGS의 경우,

최적화 절차는 다음과 같이 표현될 수 있습니다: $+1$

=

+

,

여기서 는 학습률이고 는

은 가우시안의 입장

시간 . 우리는 이산 속도를 정의합니다

가우시안의 시간

로

= $+1$

. 따라서 연속 형태의 속도 방정식은 다음과 같습니다.

=

(7)
그런 다음 방정식의 편미분을 계산합니다.
시간 :

$$\begin{aligned} &= \nabla \\ &= \\ &(\end{aligned}$$

$$\begin{aligned} &)= \\ &\Sigma \end{aligned}$$

$$\in$$

.

(

) (8)
여기서 ∇ 는 위치의 미분 연산자입니다.

,
는 다음을 나타냅니다.
속성 세트 의 속성
= {
, c
,
, s
, q
}. 일차-

시간 도함수와 뉴턴-라이프니츠의 정의
공식에서 최종 운동 방정식은 다음과 같이 정의됩니다.

$$=$$

$$+$$

$$\begin{aligned} & \cdot \nabla \\ & = 2 \\ & 2 \\ & \Sigma \end{aligned}$$

$\in$

$\nabla($

)2 (9)

4.1.2 점성향. 3DGS 최적화와 달리 입자 위치는

업데이트는 유체 시뮬레이션 중에 안정적이고 제어 가능합니다.

점성 용어에 기인합니다 [Müller et al. 2003] 모션 중

방정식.

$$\begin{aligned} & + \cdot \nabla + 1 \\ \nabla & = + \nabla \cdot \nabla \quad (10) \end{aligned}$$

여기서 $\nabla = 0$, 는 시간, 는 밀도, 은 압력, 는 점도,

는 중력 가속도이고 는 유체장의 속도입니다.

입자 위치 의 미분과 같습니다. 즉, =

점성 용어 $\nabla \cdot \nabla$ 는 본질적으로 가속도를 부여합니다.

시스템의 입자를 평균 속도로 향하게 합니다.

주변 환경은 다음과 같이 동일하게 해석될 수 있습니다.

입자의 속도와 평균 속도를 혼합하는 것

주변 입자.

유체 시뮬레이션에서 영감을 얻었습니다 [Müller et al. 2003], 우리는

3DGS 최적화 절차에 대한 점성 용어. 그러므로 우리는

Eq.9를 다음과 같이 다시 작성합니다.

=

$$\begin{aligned} & + \\ & \cdot \nabla \\ & = 2 \\ & 2 \\ & \Sigma \end{aligned}$$

$\in$

$\nabla($

$$)2 + (1 - \alpha) \nabla \cdot \nabla$$

(11)

여기서 α 은 가중치 계수입니다. 기본에 따라 PDE의 원리에 따르면 α 가 0과 같을 때 α 의 에너지는 다음과 같이 감소합니다. α 에 대해 점진적인 방식으로 진행되어 궁극적으로 0에 가까워집니다. 따라서 점도를 도입해도 용액의 용액은 변하지 않습니다. α 는 무한대 경향이 있는 방정식으로, 이는 다음의 이론적 결과입니다. 3DGS 최적화. 이를 위해 이산 솔루션은 다음과 같이 계산될 수 있습니다.

$$+1$$
$$=$$
$$+$$

$$+ 1$$
$$| \quad |$$
$$\Sigma$$
$$\in$$
$$($$

) (12)

여기서 $\mathcal{G}$ 는 Gaussian 의 이웃 집합입니다. ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 5 ---

3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 5

미분 가능

래스터라이저

이미지

프로젝션

가우스

밀도 제어

입자-그리드

입자 속도

그리드-입자

속도장

3D 가우스

입자 속도 복셀 속도

작업 흐름 그래데이션 흐름

입자 제약

그림 3. 제안된 PDEO 개요 3D 가우스는 COLMAP [Schonberger 및 Frahm 2016]에 의해 초기화됩니다. 우리는 3DGS 최적화를 공식화합니다

절차를 편미분 방정식(PDE)으로 적용하고 점도 항을 도입하여 안정적인 최적화를 달성합니다. 구체적으로 우리는 Material Point를 사용합니다.

Particle-to-Grid(P2G) 및 Grid-to-Particle(G2P)을 통해 PDE를 해결하는 방법(MPM)입니다. 속도 필드는 가우시안의 초과 속도를 저장하도록 구성됩니다.

가우시안 운동의 안정성을 보장하기 위해 점차적으로 해제합니다. 또한 소규모, 높은 신뢰도를 강화하기 위해 명시적인 입자

제약 조건을 제안합니다.

입자 가설에 따른 가우스

4.2 MPM 기반 솔루션

이 섹션에서는 3DGS 최적화의 수치 시뮬레이션을 제시합니다.

Eq.12의 이산화 형태에 따른 mization 절차.

방정식을 다음과 같이 근사화할 수 있습니다.

$$+1 \\ = \\ +$$

$$+ 1 \\ | \quad | \\ \Sigma \\ \in \\ ($$

) (13)

이웃을 기반으로 각 3D 가우스의 움직임을 계산한 이후

부르(bour)는 점성 함수를 도입한 후 계산 비용이 많이 듭니다.

용어로, 우리는 3D 가우스를 입자로 취급하고 MPM을 사용하여

이 문제를 해결하세요. 구체적으로 우리는 Particle-to-Grid를 통합합니다.

(P2G) 및 G2P(Grid-to-Particle) 전략을 3DGS 최적화에 적용

추가 기능을 제공하면서 입자 움직임을 억제하는 절차

모션 방정식을 풀기 위한 선택적 모션 안내. 우리는 건설한다

장면 공간을 복셀 그리드로 나누어 속도 필드를 생성합니다. 입자

복셀 그리드에 초과 속도를 저장하여 모션을 업데이트할 수 있으며

복셀 그리드에서 추가 속도를 얻습니다. 그러므로 입자

속도에 대한 로컬 정보를 사용하여 효과적으로 규제됩니다.

필드를 통해 점성 항을 최적화에 도입합니다.

절차.

4.2.1 입자-그리드. P2G 프로세스는 그리드를 구성합니다.

복셀 그리드에 입자의 초과 속도를 저장합니다. 남자로서-

위에서 언급한 가우시안 μ 의 위치는 Δ 에 의해 업데이트됩니다.

$$= \\ /$$

, 손실의 기울기로 계산됩니다. 더 작게-

스케일 가우시안은 위치 돌연변이가 발생하기 쉽습니다.

최적화 절차의 불안정성. 따라서 합리적인 재검토

속도 감소는 최적화 이점이 될 것입니다. 구체적으로,

입자 속도를 감쇠시키기 위해 P2G 프로세스를 사용합니다. Δ

,

동시에 입자의 운동 특성도 보존합니다. 우리 입자의 초과 속도 를 복셀 그리드 에 저장합니다.

$$\begin{aligned} \text{스텝 } &, \\ &+1 \\ &= \\ &+ (1 \quad) \\ &= \\ &+ 1 \\ | & \quad | \\ \Sigma & \\ &\in \\ \Delta & \end{aligned}$$

(14)

여기서 은 = { 에 속합니다.

0, ..., ,
)는 입자 집합입니다.

복셀 그리드 내에 포함된 은 에 저장된 복셀 속도입니다.
 은 가중치 계수입니다. 의 선택을 보여줍니다.

부록 A.2의 전체 기울기에는 영향을 미치지 않습니다.

4.2.2 그리드-입자. 그리드는 입자 속도를 억제할 뿐만 아니라
뿐만 아니라 입자에 대한 추가 모션 안내도 제공합니다.

속도장은 다음의 평균 운동 경향을 나타내기 때문에
복셀 그리드의 입자, 복셀 속도는 다음을 안내하는 데 사용됩니다.
입자의 움직임:

$$\begin{aligned} \Delta & \\ &= \quad \Delta \\ &+ (1 \quad) \\ &, \quad +1 \\ &= \\ &+ \Delta \\ (15) & \end{aligned}$$

여기서 입자 속도는 계수 에 의해 억제되고

Δ
은 업데이트된 속도입니다. 업데이트된 속도는
입자의 위치 최적화 방향이 가장 가능성이 높습니다. 는
서로 다른 입자의 속도가 서로 상호 작용하여
다양한 위치 속성의 급격한 변경을 취소합니다.
에서 추가 속도 안내를 받으면서 방향을 지정합니다.
복셀 속도. 결과적으로 위치 기울기의 변화는
점도 항에 의해 성공적으로 안내됩니다.

4.3 입자 제약

4.3.1 스케일 손실. PDE에서 입자는 척도가 없는 속성입니다. 반대
반대로, 큰 스케일의 가우스 함수는 큰 영역을 차지할 수 있습니다.
이는 PDE 시스템의 가정과 반대되는 공간입니다. 저가-
먼저 3D 가우시안에 대한 크기 제한을 도입합니다.

$$\begin{aligned} &= 1 \\ | & \quad | \\ \Sigma & \end{aligned}$$

∈

(* , 0) (16)

여기서 *는 의 가장 큰 규모를 의미하고, 는 3D 가우시안 세트입니다.

이는 시점 에 표시되며 는 규모의 여백입니다.

이 손실은 대규모의 가우시안을 처벌합니다. 소규모

가우시는 고주파수 세부 정보를 캡처하는 기능을 보장합니다.

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 6 ---

6 • 곧. 제출 ID: 2152

표 1. Mip-NeRF 360의 정량적 결과 [Barron et al. 2022], 탱크&템플스 [Knapitsch et al. 2017] 및 Scanet++ [Yeshwanth et al. 2023] 소설을 위한

합성을 봅니다. 가장 좋은 결과는 굵은 글씨로 강조 표시되어 있습니다. PDEO는 지속적으로 성능을 향상시킵니다.

데이터세트 Mip-NeRF360[Barron et al. 2022] 탱크와 사원[Knapitsch et al. 2017] Scanet++[Yeshwanth et al. 2023]

방법

↑

↑

↑

↓

↓

↓

↑

↓

↑

↑

↑

↓

↓

↑

3DGS	27.77	0.827	0.244	295	163.1	21.63	0.768	0.322	299	44.3	27.83	0.911	0.185	192	74.2
GES	27.71	0.844	0.224	369	106.3	21.59	0.768	0.330	162	64.1	27.86	0.912	0.190	94.1	97.9
AbaGS	27.81	0.850	0.207	804	125.1	21.37	0.755	0.326	340	40.0	27.67	0.907	0.185	121	101.8
밈GS	27.98	0.858	0.213	303	108.5	20.98	0.757	0.326	357	52.1	27.80	0.913	0.177	224	135.2
2DGS	27.42	0.841	0.228	476	42.3	21.02	0.756	0.357	188	21.8	27.91	0.911	0.196	107	36.8
라데GS	28.03	0.866	0.198	536	118.6	20.80	0.750	0.345	239	57.5	27.97	0.911	0.180	165	103.4
MCMC	27.91	0.845	0.186	714	40.4	21.03	0.744	0.318	691	55.7	28.01	0.918	0.182	470.3	52.5
스팩GS	27.96	0.866	0.173	1147	7.9	21.02	0.751	0.322	498	19.7	27.89	0.912	0.195	159	56.1
3DGS+PDEO	27.78	0.831	0.242	186	225.5	21.89	0.768	0.320	125	146.9	27.87	0.911	0.190	66.7	260.0
GES+PDEO	27.99	0.834	0.232	133	166.1	22.08	0.768	0.325	97.0	176.0	27.92	0.911	0.192	53.5	283.0
밈GS+PDEO	28.08	0.870	0.211	137	108.5	22.12	0.761	0.320	79.0	148.5	27.91	0.913	0.169	48.5	254.5
2DGS+PDEO	27.42	0.832	0.273	63.8	94.5	21.03	0.749	0.363	100	64.6	27.93	0.911	0.195	102	81.7
RaDeGS+PDEO	28.16	0.852	0.213	187	171.1	22.61	0.768	0.332	95.1	118.4	28.06	0.911	0.189	65.0	227.9
MCMC+PDEO	28.12	0.833	0.213	198	73.3	22.77	0.780	0.295	210	73.9	28.23	0.919	0.182	212	86.9
스팩GS+PDEO	28.81	0.875	0.173	99.6	65.4	22.16	0.780	0.316	345	28.2	28.10	0.919	0.185	115	66.8

3DGS(랜더)	26.61	0.764	0.318	258	78.8	20.84	0.734	0.380	261	66.1	27.55	0.908	0.202	164.9	92.4
+PDEO(랜더)	27.75	0.825	0.233	89.4	122.3	21.71	0.745	0.361	101	71.5	27.64	0.908	0.199	59.5	138.0
MCMC(랜더)	27.62	0.832	0.203	473	55.6	21.00	0.735	0.333	469	35.8	27.92	0.918	0.187	354	60.7
+PDEO(랜더)	27.85	0.861	0.187	189	85.9	22.64	0.771	0.321	187	54.6	27.98	0.918	0.182	98.7	63.7

표 2. DTU 데이터 세트의 정량적 결과 [Jensen et al. 2014] 표면 재구성. 다양한 방법의 Chamfer Distance 오류를 보고합니다.

가장 좋은 결과는 굵은 글씨로 강조 표시되어 있습니다. PDEO는 지속적으로 성능을 향상시킵니다.

방법 24 37 40 55 63 65 69 83 97 105 106 110 114 118 122 평균

NeRF	1.90	1.60	1.85	0.58	0.81	2.28	1.27	1.47	1.67	2.05	1.07	0.88	1.06	1.15	0.96	1.37
NeuS	1.00	1.37	0.93	0.43	1.10	0.65	0.57	1.48	1.09	0.83	0.52	1.20	0.35	0.49	0.54	0.84
3DGS	1.62	1.25	1.41	1.13	2.57	2.10	1.39	1.97	1.82	1.34	1.41	1.90	1.10	1.14	1.29	1.56
슈가	1.47	1.33	1.13	0.61	2.25	1.71	1.15	1.63	1.62	1.07	0.79	2.45	0.98	0.88	0.79	1.32
GOF	0.50	0.82	0.37	0.37	1.12	0.74	0.73	1.18	1.29	0.68	0.77	0.90	0.42	0.66	0.49	0.74
2DGS	0.60	0.92	0.79	0.37	1.24	1.13	0.87	1.40	1.27	0.86	0.73	1.33	0.44	0.98	0.60	0.90

라데GS 0.46 0.78 0.36 0.39 0.81 0.77 0.76 1.19 1.24 0.63 0.70 0.87 0.36 0.69 0.48 0.70
 3DGS+PDEO 1.48 1.01 1.11 0.59 2.35 1.75 1.07 1.69 1.77 0.97 1.03 1.97 1.13 1.10 1.20 1.34
 2DGS+PDEO 0.59 0.90 0.70 0.39 0.89 0.86 0.82 1.31 1.29 0.74 0.73 1.43 0.44 0.72 0.48 0.82
 RaDeGS+PDEO 0.45 0.77 0.36 0.37 0.73 0.75 0.75 1.18 1.16 0.59 0.67 0.84 0.38 0.68 0.47 0.68

4.3.2 신뢰도 상실. 가우시안은 입자로 설명되므로

PDE에서는 반투명 가우스를 피할 필요가 있습니다. 저가-

먼저, 우리는 높은 신뢰도를 보장하기 위해 신뢰 손실을 제안합니다.

입자 가설을 충족하는 가우스는 다음과 같습니다.

가우시안의 불투명도,

$$= 1$$

| || 1.99 | 2

2 (17)

여기서 $\cdot$ 는 바닥 연산자를 나타내고 $\cdot$ 는 불투명도를 나타냅니다.

4.3.3 가우스 치밀화 가우시안 밀도화(Gaussian Densification)가 사용됩니다.

3DGS는 새로운 가우시안을 복제하고 분할하여 빈 공간을 덮습니다.

기본 장면을 정확하게 표현합니다. 원래 3DGS 평균은

결정하기 위해 뷰 공간 위치의 위치 그래디언션을 에이징합니다.

치밀화를 수행할지 여부. 우리의 접근 방식에서는 속도 필드

복제 및 분할 프로세스를 안내하는 데에도 사용됩니다. 구체적으로,

입자 속도 사이의 코사인 유사성 측정을 계산합니다.

$\triangle$ 및 복셀 속도 $\cdot$ 를 사용하여 치밀화 수행 여부를 결정합니다.

운영. 가우시안에 대한 밀도화 $\cdot$ 는 다음을 만족할 때 수행됩니다.

$\cos(\cdot, \cdot) > \cdot$, 여기서 $\cdot(\cdot)$ 는 코사인 유사성을 나타내고

코사인 임계값을 나타냅니다.

5가지 실험

5.1 실험 설정

데이터 세트. 실험에서 제안된 PDE-GS를 평가했습니다.

다양한 실제 장면을 통해 그 효과를 테스트합니다.

렌더링 및 재구성의 중요성. 새로운 관점 합성을 위해 우리는

다양한 데이터 세트의 17개 장면 사용: Mip-nerf360의 6개 장면

데이터 세트 [Barron et al. 2022], Tanks & Temples 데이터세트의 7개 장면

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사. 출판일: 2025년 9월.

--- 페이지 7 ---

3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 7

표 3. 탱크 및 사원의 정량적 결과 [Knapitsch et al. 2017]

표면 재구성을 위해. 우리는 다양한 방법의 F1 점수를 보고합니다.

가장 좋은 결과는 굵은 글씨로 강조 표시되어 있습니다. RaDeGS+PDEO가 최고의 성과를 달성했습니다.

비교된 모든 방법 중 F1 점수.

방법 2DGS RaDeGS SuGaR RaDeGS+PDEO

헛간 0.387 0.470 0.171 0.588

캐터필러 0.210 0.255 0.129 0.343

법원 0.126 0.100 0.084 0.128

이그나티우스 0.517 0.668 0.351 0.780

회의실 0.250 0.240 0.180 0.610

트럭 0.379 0.462 0.225 0.591

교회 0.054 0.018 0.035 0.078

평균 0.275 0.316 0.168 0.445

[Knapitsch et al. 2017] 및 ScanNet++ 데이터 세트의 4개 장면 [예-Wanthe et al. 2023]. 표면 재구성을 위해 우리는

DTU의 15개 장면에 대한 설명 [Jensen et al. 2014] 외 7개 장면 탱크 및 사원 데이터세트 [Knapitsch et al. 2017]. 이 장면들 경계가 있는 실내 환경과 경계가 없는 실외 환경을 모두 포함하며, 종합적인 평가를 가능하게 합니다.

구현. 고품질 렌더링 및 재구성을 달성하려면

우리의 PDEO는 외부 구조에 쉽게 통합될 수 있습니다.

MipGS와 같은 3DGS 기반 방법이 있다[Yu et al. 2024a] 또는

2DGS [Geiger et al. 2024], 새로운 관점 합성 작업을 위해

그리고 표면 재구성. 일관된 평가를 보장하기 위해 우리는 다음을 사용합니다.

원래 메소드의 기본 매개변수. $\alpha = 0.8$ 로 설정했습니다.

$\beta = 0.8$, $\gamma = 0.2$, $\delta = 120^\circ$, $\epsilon = 0.6$, $\zeta = 0.04$, $\eta = 0.04$ 및 in-

점진적으로 반복하면서 1에서 2.5로 증가합니다. 우리의 모든 실험

단일 V100 GPU에서 수행됩니다.

측정항목. 렌더링 품질을 평가하기 위해 PSNR, SSIM,

및 LPIPS를 사용하여 각 데이터 세트의 성능을 측정합니다. 평가하다

재구성 품질, Chamfer Distance(CD)를 보고합니다.

DTU 데이터 세트 [Jensen et al. 2014] 및 Tanks & F1 점수

사원 데이터세트 [Knapitsch et al. 2017].

5.2 비교

5.2.1 새로운 견해 종합. 우리는 제안된 PDEO를

새로운 시점 합성을 위한 최첨단 3DGS 기반 방법,

3DGS와 비교[Kerbl et al. 2023], GES [Hamdi et al. 2024],

AbsGS [Ye et al. 2024], MipGS [Yu et al. 2024a], 2DGS [Geiger et al.

2024], RaDeGS [Zhang et al. 2024a], 3DGS MCMC 및 SpecGS [양

외. 2024].

정량적 결과를 표 1에 보고합니다. PDEO는 일관되게

PSNR 측면에서 원래 방법의 성능을 향상시킵니다.

SSIM 및 LPIPS. SpecGS+PDEO가 가장 좋은 결과를 얻는 것을 볼 수 있습니다.

성능. 정량적 결과는 그림 4에 나와 있습니다.

PDEO는 아티팩트와 플로터를 크게 줄이면서 동시에

렌더링 품질을 향상시킵니다. 명확한 비교를 위해, 우리는 또한 제공합니다

그림 5에서 가우시안 타원체의 시각화. 전반적으로 제안된

PDEO는 3DGS 기반 방법을 크게 향상시키는 동시에

메모리 효율성을 입증했습니다.

5.2.2 표면 재구성. PDEO는 최신 기술과 통합되어 있습니다.

표면 재구성을 위한 art 3DGS 기반 방법 및 비교

2DGS로 [Geiger et al. 2024], RaDeGS [Zhang et al. 2024a] 및

표 4. Mip-NeRF360 데이터 세트에 대한 절제 연구 [Barron et al. 2022]

새로운 관점 합성을 위해. 우리는 각 구성 요소의 영향을 연구합니다.

Mip-NeRF360의 렌더링 품질과 메모리 사용량에 대한 우리의 방법

데이터 세트 [Barron et al. 2022].

방법 $\uparrow$ $\uparrow$ $\downarrow$ $\downarrow$

기준선 27.71 0.844 0.224 369

P2G 및 G2P 제외 27.51 0.830 0.227 240

우리의 고밀도화 27.96 0.834 0.230 136

스케일 손실 없음 27.75 0.831 0.236 132

신뢰 손실 없음 27.87 0.845 0.219 177

전체 27.99 0.834 0.232 133

전체($\epsilon=0.5$) 27.84 0.835 0.235 151

전체($\epsilon=0.9$) 27.66 0.834 0.233 160

전체($\epsilon=0.5$) 27.69 0.835 0.237 143

전체($\epsilon=0.9$) 27.56 0.833 0.229 207

SuGaR [Gordon 및 Lepetit 2024]. 표 2 및 표에 나타난 바와 같이

3, PDEO는 DTU에서 3DGS 기반 방법을 지속적으로 향상시킵니다.

CD 오류 관련 데이터세트 및 Tanks & Temples 데이터세트

F1 점수로 따지면, RaDeGS+PDEO는 질적으로 더 나은 성과를 거두었습니다.

보다 정확하고 부드러운 기하학으로 재구성합니다.

그림 6에 표시됩니다. 이는 PDEO가 부유물을 제거할 수 있음을 보여줍니다.

재구성 품질을 향상시키기 위해 기하학적 세부 사항을 보존합니다.

5.3 절제 연구

이 섹션에서는 효과를 연구하기 위해 절제 실험을 수행합니다.

PDEO의 각 구성요소의 유효성. 우리는 실험을 수행합니다

Mip-NeRF360 데이터 세트 [Barron et al. 2022] 새로운 시각 합성을 위해.

절제의 정량적 결과는 표 4에 보고되어 있으며

GES [Hamdi et al. 2024]를 기준으로 삼았다.

P2G와 G2P의 효과. 표 4에서는 P2G의 영향을 조사합니다.

그리고 G2P. 이 전략이 없으면 상당한 하락으로 이어집니다.

렌더링 품질이 저하되어 렌더링 품질이 저하됩니다.

우리의 접근 방식은 점도 용어를 최적화에 도입합니다.

P2G 및 G2P 전략을 사용하여 안정적인 절차를 보장합니다.

메모리 사용량을 줄이면서 가우시안을 최적화합니다. 추가-

또한, 정성적 렌더링 결과는 그림 7에 나와 있습니다.

P2G와 G2P가 아티팩트와 플로터를 완화하는 데 도움이 된다는 것을 보여줍니다.

가우스 치밀화의 효과. 표 4에 나타난 바와 같이,

가우스 치밀화 전략은 품질 저하를 초래합니다.

낮은 품질은 전략이 더 많은 것을 달성할 수 있음을 보여줍니다.

장면의 세부 사항에 맞는 정확한 가우스 밀도.

규모 손실과 신뢰도 손실의 영향. 우리는 효과를 분석합니다

규모 손실과 신뢰 손실. 표 4는 유사한 결과를 보여줍니다.

메모리 사용량이 많아지면 성능이 크게 저하됩니다.

규모 손실이나 신뢰도 손실을 제거할 때 품질이 저하됩니다. 그림 7

스케일 손실이 가우시안의 스케일 속성을 제한하는 데 도움이 된다는 증거,

이는 장면 세부 사항을 더 잘 재구성하는 데 도움이 됩니다.

6 결론

장면의 세부 특징을 재구성하려면 최적화가 필요합니다.

수많은 소규모 3D 가우시안을 마이징합니다. 그러나 이러한 3D에

가우시안, 위치 기울기의 감도 크기는 다음과 같습니다.

다른 매개변수 기울기보다 훨씬 높습니다. 는

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 8 ---

8 • 곧. 제출 ID: 2152

다양한 가우스 속성에 대한 불평등한 최적화 처리

그래디언트 크기의 계산에 따르면

3DGS의 불안정한 최적화. 따라서 우리는 PDEO를 제안한다.

3DGS 최적화와

3DGS 최적화를 제어하고 안내하기 위한 PDE 시뮬레이션. 우리의

실험 결과는 항상 효과 있음을 보여줍니다.

렌더링 및 재구성 품질.

한정. 우리의 방법에는 몇 가지 한계가 있습니다. 첫째로,

우리의 방법은 입자 회전을 포함하지 않습니다. 향후 연구는

입자 회전에 대한 공간 복셀 그리드의 영향을 통합합니다.

MPM 시뮬레이션에서 둘째, 복셀을 도입했지만

입자 방향의 최적화를 안내하는 그리드, 우리의 접근 방식

다른 지역에서 3D 가우스안을 안정적으로 재배치하는 데 여전히 어려움을 겪고 있습니다.

포인트 클라우드 초기화에 상당한 차이가 있는 영역으로 분류(예:

초기 포인트 클라우드가 부족한 장면 영역). 어드레싱

이러한 제한은 향후 연구의 유망한 방향을 나타냅니다.

참고자료

Adam W Bargteil, Tolga G Goktekin, James F O'brien 및 John A Strain. 2006. 가

유체 시뮬레이션을 위한 Semi-Lagrangian 윤곽 기법. ACM 거래

그래픽(TOG) 25, 1(2006), 19-38.

Jonathan T Barron, Ben Mildenhall, Dor Verbin, Pratul P Srinivasan 및 Peter Hedman.

2022. Mip-Nerf 360: 무한한 앤티앨리어싱 신경 방사 필드. 절차 중

컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 회의. 5470-5479.

Zhiqin Chen, Thomas Funkhouser, Peter Hedman 및 Andrea Tagliasacchi. 2023.

Mobilenerf: 효율적인 신경장을 위해 다각형 래스터화 파이프라인 활용

모바일 아키텍처에서의 렌더링. IEEE/CVF 회의 진행 중

컴퓨터 비전 및 패턴 인식. 16569~16578.

정재영, 오정택, 이경무. 2024. 깊이 정규화 Op-

Few-Shot 이미지에서 3D 가우스 스플래팅을 위한 타이밍. 절차에서

컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스. 811-820.

Sara Fridovich-Keil, Alex Yu, Matthew Tancik, Qinhong Chen, Benjamin Recht 및

가나자와 양주. 2022. Plenoxels: 신경망이 없는 Radiance Fields. 에서

컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스 진행.

5501-5510.

Andreas Geiger, Shenghua Gao, Anpei Chen, Zehao Yu 및 Binbin Huang. 2024. 2D

기하학적으로 정확한 복사장을 위한 가우스 스플래팅. ACM 시그라프

2024 컨퍼런스 논문(2024).

앙투안 게동(Antoine Gu don)과 뱅상 르페티(Vincent Lepetit). 2024. 설탕: 표면 정렬된 가우스 스플랫-

효율적인 3D 메시 재구성 및 고품질 메시 렌더링을 위한 기술입니다. 에서

컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스 진행.

5354-5363.

압둘라 함디, 루크 멜라스-키리아지, 진지 마이, 귀청 첸, 루오시 리우, 칼 본드릭, 버나드 가넴, 안드레아 베달디. 2024. GES: 일반화 지수 효율적인 래디언스 필드 렌더링을 위한 스플래팅. IEEE/CVF 절차에서 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스. 19812년부터 19822년까지.

세르게이 이오페. 2015. 배치 정규화: 심층 네트워크 훈련 가속화 내부 공변량 이동 감소. arXiv 사전 인쇄 arXiv:1502.03167 (2015).

Rasmus Jensen, Anders Dahl, George Vogiatzis, Engin Tola 및 Henrik Aanæs. 2014. 대규모 다중 시점 입체시 평가. IEEE/CVF 회의 진행 중 컴퓨터 비전 및 패턴 인식에 대한 참조. 406~413.

Chenfanfu Jiang, Craig Schroeder, Joseph Teran, Alexey Stomakhin 및 Andrew Selle. 2016. 연속체 재료 시뮬레이션을 위한 재료 포인트 방법. 1~52.

베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임퀼러, 조지 드레타키스. 2023. 실시간 래디언스 필드 렌더링을 위한 3D 가우스 스플래팅. ACM 거래 그래픽(ToG) 42, 4(2023), 139:1-139:14.

Arno Knapitsch, 박재식, Qian-Yi Zhou, Vladlen Koltun. 2017. 탱크와 사원: 대규모 장면 재구성 벤치마킹. ACM 거래 그래픽(ToG) 36, 4(2017), 1-13.

Lei Lan, Tianjia Shao, Zixuan Lu, Yu Zhang, Chenfanfu Jiang 및 Yin Yang. 2025. 3DGS 2: 2차 수렴에 가까운 3D 가우스 스플래팅. arXiv 사전 인쇄 arXiv:2501.13975 (2025).

Haolin Li, Jinyang Liu, Mario Sznajder 및 Octavia J. Camps. 2024. 3D-HGS: 3D 하프-가우스 스플래팅. arXiv 사전 인쇄 arXiv:2406.02720 (2024).

리 자오슈오, 토마스 뮐러, 알렉스 에반스, 러셀 H 테일러, 마티아스 운버라스, 밍-Yu Liu, Chen-Hsuan Lin. 2023. 신경란젤로: 고충실도 신경 표면 재건. 컴퓨터 비전 및 컴퓨터 비전에 관한 IEEE/CVF 회의 진행 중 패턴 인식. 8456-8465.

Xinhang Liu, Yu-Wing Tai, Chi-Keung Tang. 2023. Clean-NeRF: 재구성 보기 의존적 관찰을 설명하는 NeRF. arXiv 사전 인쇄본 arXiv:2303.14707 (2023).

벤 밀드홀, 프라툴 P 스리니바산, 매튜 탄식, 조나단 T 배런, 라비 라-마모르티(mamoorthi), 렌 응(Ren Ng). 2021. Nerf: 장면을 신경 복사장으로 표현 뷰 합성을 위해. 커뮤니케이터 ACM 65, 1(2021), 99-106.

마티아스 뮐러, 데이비드 샤리파르, 마르쿠스 그로스. 2003. 입자기반유체 대화형 애플리케이션을 위한 시뮬레이션. 2003 ACM SIG 절차에서-컴퓨터 애니메이션에 관한 GRAPH/Eurographics 심포지엄. 인용문, 154-159.

토마스 뮐러, 알렉스 에반스, 크리스토프 쉬드, 알렉산더 J. 켈러. 2022. 인스턴트 다중 해상도 해시 인코딩을 사용하는 신경 그래픽 프리미티브. ACM 트랜잭션 그래픽(TOG) 41, 4(2022), 1-15.

라즈반 파스카누, 토마스 미콜로프, 요슈아 벤지오. 2013. 훈련의 어려움에 대하여 순환 신경망. 기계 학습에 관한 국제 회의에서. 1310년~1318.

줄리안 필립과 발랑탱 데샹트르. 2023. 플로터는 더 이상 없다: 래디언스 필드 그래데이션 향상된 근거리 카메라 훈련을 위한 확장. arXiv 사전 인쇄 arXiv:2305.02756(2023).

Jiang Qian, Yuren Wu, Bojin Zhuang, Shaojun Wang 및 Jing Xiao. 2021. 이해 증분 그래데이션 방법의 그래데이션 클리핑. 국제회의에서 인공지능과 통계. PMLR, 1504-1512.

Haoxuan Qu, Zhuoling Li, Hossein Rahmani, Yujun Cai 및 Jun Liu. 2024. 디스크-GS: 불연속 인식 가우스 스플래팅. arXiv 사전 인쇄 arXiv:2405.15196(2024).

크리스티안 라이저, 스테판 가르빈, 프라톨 스리니바산, 도르 베르빈, 리차드 젤리스키, 벤 밀튼홀, 조나단 배런, 피터 헤드먼, 안드레아스 J. 가이거. 2024. 바이너리 불투명 그리드: 메시 기반 뷰 합성을 위한 정밀한 기하학적 세부 정보 캡처. 그래픽에 대한 ACM 트랜잭션(TOG) 43, 4(2024), 1-14.

Shibani Santurkar, Dimitris Tsipras, Andrew Ilyas 및 Aleksander Madry. 2018. 어떻게 배치 정규화가 최적화에 도움이 됩니까? 신경 정보의 발전 처리 시스템 31(2018).

요하네스 L 손베르거(Johannes L Schonberger)와 얀-마이클 프람(Jan-Michael Frahm). 2016. 움직임으로부터의 구조 재검토.

컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 회의 진행 중. 4104~4113.

Nagabhushan Somraj와 Rajiv Soundararajan. 2023. Vip-Nerf: 사전 가시성 희소 입력 신경 복사 필드. In ACM SIGGRAPH 2023 컨퍼런스 진행. 1~11.

Alexey Stomakhin, Craig Schroeder, Lawrence Chai, Joseph Teran 및 Andrew J. Selle. 2013. 눈 시뮬레이션을 위한 재료 포인트 방법. 그래픽에 대한 ACM 트랜잭션(TOG) 32, 4(2013), 1-10.

데보라 설스키(Deborah Sulsky), 시지안 저우(Shi-Jian Zhou), 하워드 L J. 슈라이어(Howard L J. Schreyer). 1995. A의 출원 고체 역학에 대한 입자 내 방법. 컴퓨터 물리학 커뮤니케이션 87, 1-2(1995), 236-252.

타카기 슈, 스기야마 카즈야스, 이이 사토시, 마츠모토 요이치로. 2012. 리뷰 유체 구조 상호 작용 문제에 대한 전체 오일러 방법. (2012).

조나단 톰슨(Jonathan Tompson), 크리스토퍼 슬라흐터(Kristofer Schlachter), 파블로 스프레크만(Pablo Sprechmann), 켄 펄린(Ken Perlin). 2017. 액-컨볼루션 네트워크를 사용하여 오일러 유체 시뮬레이션을 가속화합니다. 국제에서 머신러닝 컨퍼런스. PMLR, 3424-3433.

벤자민 우멘호퍼, 루카스 프란틀, 닐스 투레이, 블라들렌 쿨톤. 2019. 라-연속 컨볼루션을 사용한 그랜지안 유체 시뮬레이션. 국제회의에서-학습 표현에 대한 내용.

Peng Wang, Lingjie Liu, Yuan Liu, Christian Theobalt, Taku Komura 및 Wenping 왕. 2021. Neus: 볼륨 렌더링을 통한 신경 암시적 표면 학습 다중 뷰 재구성. arXiv 사전 인쇄 arXiv:2106.10689 (2021).

Frederik Warburg, Ethan Weber, Matthew Tancik, Aleksander Holynski 및 Angjoo 가나자와. 2023. Nerfbusters: 우연히 캡처한 유령 유물 제거 너프. 컴퓨터 비전에 관한 IEEE/CVF 국제 컨퍼런스 진행 중. 18120~18130.

Tristan Wirth, Arne Rak, Volker Knauth 및 Dieter W Fellner. 2023. A 후처리 신경 복사장에서 플로터 아티팩트를 자동으로 제거하는 기술. 에서 컴퓨터 그래픽 포럼, Vol. 42. Wiley 온라인 도서관, e14977.

Ziyi Yang, Xinyu Gao, Yang-Tian Sun, Yihua Huang, Xiaoyang Lyu, Wen Zhou, Shao-후이 자오, 샤오주안 치, 샤오강 진. 2024. Spec-gaussian: Anisotropic view-3D 가우스 스피래팅에 대한 종속 모양. 신경 정보의 발전 처리 시스템 37(2024), 61192-61216.

Zongxin Ye, Wenyu Li, Sidun Liu, Peng Qiao 및 Yong Dou. 2024. AbsGS: 회복 중 3D 가우스 스피래팅에 대한 미세한 세부 정보. arXiv 사전 인쇄 arXiv:2404.10484 (2024).

Chandan Yeshwanth, Yueh-Cheng Liu, Matthias Nießner 및 Angela Dai. 2023. 스캔-net++: 3D 실내 장면의 충실도가 높은 데이터 세트입니다. IEEE/CVF 절차에서 컴퓨터 비전에 관한 국제 컨퍼런스. 12-22.

Hongwei Yong, Jianqiang Huang, Xiansheng Hua 및 Lei Zhang. 2020. 그라데이션 중앙화: 심층 신경망을 위한 새로운 최적화 기술입니다. 컴퓨터 내 비전-ECCV 2020: 제16차 유럽 컨퍼런스, 영국 글래스고, 2020년 8월 23~28일, 절차, 파트 I 16. 스프링거, 635-652.

Alex Yu, Ruilong Li, Matthew Tancik, Hao Li, Ren Ng 및 Angjoo Kanazawa. 2021. 신경 복사장(Neural Radiance Field)의 실시간 렌더링을 위한 Plenotrees. 의 절차에서 컴퓨터 비전에 관한 IEEE/CVF 국제 컨퍼런스. 5752-5761.

Zehao Yu, Anpei Chen, Binbin Huang, Torsten Sattler 및 Andreas Geiger. 2024a. 밍 스플래팅(Mip-Splatting): 앨리어싱이 없는 3D 가우스 스플래팅. IEEE/CVF 절차에서 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스. 19447년부터 19456년까지. ACM 트랜스. 그래프., Vol. 1, No. 1, 기사. 출판일: 2025년 9월.

--- 페이지 9 ---

3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 9

Zehao Yu, Torsten Sattler, Andreas J. Geiger. 2024b. 가우스 불투명도 필드: 무한한 장면에서 효율적이고 컴팩트한 표면 재구성. arXiv 사전 인쇄 arXiv:2404.10772 (2024).

Yue Yonghao, Breannan Smith, Christopher Batty, Changxi Zheng 및 Eitan J. Grinspun. 2015. 연속체 품: 전단 의존 유동에 대한 재료 점 방법. ACM 그래픽 트랜잭션(TOG) 34, 5(2015), 1-20.

Baowen Zhang, Chuan Fang, Rakesh Shrestha, Yixun Liang, Xiaoxiao Long 및 Ping 탄. 2024a. RaDe-GS: 가우스 스플래팅의 깊이 래스터화. arXiv 사전 인쇄 arXiv:2406.01467 (2024).

Guodong Zhang, Chaoqi Wang, Bowen Xu 및 Roger Grosse. 2018. 세 가지 메커니즘 체중 감소 정규화. arXiv 사전 인쇄 arXiv:1810.12281 (2018).

Jingzhao Zhang, Tianxing He, Suvrit Sra 및 Ali Jadbabaie. 2019. 왜 그라데이션을 해야 하는가 클리핑은 훈련을 가속화합니다: 적응성에 대한 이론적 정당성. arXiv 사전 인쇄 arXiv:1905.11881 (2019).

Jiahui Zhang, Fangneng Zhan, Muyu Xu, Shijian Lu 및 Eric Xing. 2024b. 프레그: 3D 점진적 주파수 정규화를 사용한 가우스 스플래팅. 절차에서 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스. 21424~21433.

Matthias Zwicker, Hanspeter Pfister, Jeroen Van Baar, Markus Gross. 2001. EWA 볼륨 스플래팅. 절차 시각화, 2001. 29-538. ACM 트랜스. 그래프., Vol. 1, No. 1, 기사. 출판일: 2025년 9월.

--- 페이지 10 ---

10 • 곧. 제출 ID: 2152

GT 3DGS 3DGS+PDEO 사양GS 사양GS+PDEO

그림 4. Mip-NeRF360의 장면에 대한 다양한 방법의 질적 비교 [Barron et al. 2022] 및 Tanks&Temples [Knapitsch et al. 2017] 그리고

Scanet++[Yeshwanth et al. 2023] 새로운 뷰 합성을 위한 데이터세트. PEDO는 렌더링 품질을 향상시키면서 아티팩트와 플로터를 크게 줄입니다.

3DGS 3DGS+PDEO GES GES+PDEOGT

그림 5. 가우스 타원체의 시각화. PEDO는 플로터 가우시안을 제거하고 미세한 기하학적 세부 사항을 복구합니다.

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 11 ---

3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 11

2DGS 2DGS+PDEO RaDe-GSPDEOGT

RaDeGS

그림 6. 탱크와 사원의 장면에 대한 다양한 방법의 질적 비교 [Knapitsch et al. 2017] 표면 재구성을 위한 데이터세트. 페도 재건축의 질을 향상시킵니다.

P2G 및 G2P 없이 전체 확장 손실 없이 전체 신뢰도 손실 없이 전체

그림 7. P2G와 G2P의 제거, 규모 손실 및 신뢰 손실

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 12 ---

12 • 곧. 제출 ID: 2152

부록

A.1 가우스 기울기 감도 분석

3DGS의 속성. 값이 제한된 일부 속성의 경우

범위, 3DGS는 활성화 함수를 적용하여 무한한 범위를 매핑합니다.

제한된 값 범위에 대한 속성입니다. 아래는 일부 비교입니다.

속성 및 해당 렌더링 속성에 사용됨

3DGS:

- 직위: $\mathbf{c} \in \mathbb{R}^3$
- 색상: $\mathbf{c} = (\mathbf{c}_r, \mathbf{c}_g, \mathbf{c}_b)$,
- 불투명도: $\alpha = \text{Sig}(\alpha)$,
- 규모: $\mathbf{s} = (s_x, s_y, s_z)$,
- 회전: $\mathbf{q} \in \mathbb{R}^4$

여기서 $\mathbf{c}$ 는 중심 위치를 나타내고, $\mathbf{c}$ 는 구형을 나타냅니다.

고조파 계수, α 는 불투명도 속성이고, $\mathbf{s}$ 는

scale 속성, $\mathbf{q}$ 는 회전을 나타내는 쿼터니언입니다.

속성. 여기서 $\alpha = \text{Sig}(\alpha)$ 는 불투명도를 나타내며, 여기서 $\text{Sig}(\cdot)$

는 시그모이드 함수를 나타내고, $\mathbf{s} = (s_x, s_y, s_z) \in \mathbb{R}^3$ 은

스케일링 벡터.

뷰라인입니다.

가우시안의 축 평면.

카메라의 이미징 평면.

$(\mathbf{c}_r, \mathbf{c}_g, \mathbf{c}_b)$

$(\mathbf{c}_r, \mathbf{c}_g, \mathbf{c}_b)$

$(\mathbf{c}_r, \mathbf{c}_g)$

$(\mathbf{c}_r, \mathbf{c}_g, \mathbf{c}_b)$

$(\mathbf{c}_r, \mathbf{c}_g, \mathbf{c}_b)$

$(\mathbf{c}_r, \mathbf{c}_g)$

그림 8. 3D 가우시안의 투영 과정. 왼쪽. 카메라의 시선

3D Gaussian.Right의 축 평면에 직교합니다. 상황은

회전 가우시안과 회전 카메라도 동일하므로 회전을 선택합니다.

카메라. 회전 R 후에 뷰 라인은 평면과 직교하지 않습니다.

3DGS를 2D 스플래팅으로 변환합니다. 단순하고 회전되지 않은 3D 가우스의 경우
기본 기능:

$$G(\mathbf{x}) = \frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right),$$

여기서 $\mathbf{c} = (c_1, c_2, c_3)$ 은 샘플링 위치이고 $\mathbf{C} = \begin{pmatrix} s^2 & 0 & 0 \\ 0 & s^2 & 0 \\ 0 & 0 & s^2 \end{pmatrix}$ 은 가우시안 G 의 위치입니다. 우리가 다음 중 하나를 따라 통합하면
점 (c_1, c_2, c_3) 을 통한 좌표축 $(1, 0, 0)$ 과 해당
스폰딩 픽셀은 $\mathbf{c} = (c_1, c_2)$ 입니다. 단순화하기 위해 $\mathbf{c} = (0, 0)$, $(\mathbf{c} = (c_1, c_2, c_3))$. 우리는 다음과 같은 적분 결과를 얻습니다.

$$G(\mathbf{x}) = \frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} G(\mathbf{x}) d\mathbf{x} = 1$$

$$\int$$

$$\left(\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right) \right)$$

$$2 \cdot \frac{1}{s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$+$$

$$\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$2 \cdot \frac{1}{s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$+$$

$$\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$2 \cdot \frac{1}{s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$\left(\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right) \right)$$

$$= \frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$\left(\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right) \right)$$

$$\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$2 \cdot \frac{1}{s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$+$$

$$\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$2 \cdot \frac{1}{s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

$$\left(\frac{1}{2\pi s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right) \right)$$

$$\cdot$$

$$\sqrt{\frac{1}{2\pi s^2}}$$

$$2 \cdot \frac{1}{s^2} \exp\left(-\frac{1}{2s^2}(\mathbf{x} - \mathbf{c})^T \mathbf{C}^{-1}(\mathbf{x} - \mathbf{c})\right)$$

여기서 $\mathbf{v}_1$ 은 다음과 같이 3·3 행렬입니다.

$$\mathbf{v}_1 = \begin{pmatrix} 1 & 2 \cdot s_2 & 1 \\ 0 & 0 & 0 \\ 0 & 1 & 2 \cdot s_2 \\ 0 & 0 & 1 \end{pmatrix}$$

이는 점에서 투영된 픽셀의 2D 스프래iting 기능입니다.

($\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$) 회전이 없는 경우.

그리고 회전 행렬 $\mathbf{R}$ 을 도입하면

점($\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$)을 통과하는 선을 따라 회전된 함수

보는 방향에 평행한 것은 다음의 적분과 동일합니다.

점($\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$)을 통과하는 선을 따라 회전되지 않는 함수
에 의해 회전되었습니다.

그런 다음 통합 축의 방향 벡터를 가정합니다.

회전 후는 $\mathbf{v} = (\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3)$ 입니다. 여기서 $\mathbf{v}_2$

$$\mathbf{v}_1 + \mathbf{v}_2$$

$$\mathbf{v}_2 + \mathbf{v}_3$$

$\mathbf{v}_3 = 1$. 따라서 적분은

회전된 함수의 결과

$$f(\mathbf{v}) =$$

(1, 0, 0)을 따라 적분합니다.

$$f(\mathbf{v}) =$$

$$\int$$

$$f(\mathbf{v}) \cdot \mathbf{v} =$$

$$\int$$

$$((\mathbf{v}_1 \cdot \mathbf{v})^2$$

$$2 \cdot s_2$$

$$1$$

$$+$$

$$(\mathbf{v}_2 \cdot \mathbf{v} + \mathbf{v}_3)^2$$

$$2 \cdot s_2$$

$$2$$

$$+$$

$$(\mathbf{v}_3 \cdot \mathbf{v} + \mathbf{v}_3)^2$$

$$2 \cdot s_2$$

$$3$$

$$)$$

$$,$$

우리는 그것을 단순화

$$\begin{aligned} & \left(\frac{2}{\sqrt{2}} \right. \\ & 2 \cdot s^2 \\ & \left. + \frac{2}{\sqrt{3}} \right) \\ & 2 \cdot s^2 \\ & 3 \\ &) \\ & \cdot \\ & f \end{aligned}$$

$$\begin{aligned} & \left(\frac{2}{\sqrt{2}} \right. \\ & 1 \cdot \frac{2}{\sqrt{2}} \\ & 2 \cdot s^2 \\ & 1 \\ & + \\ & \frac{2}{\sqrt{2}} \\ & 2 \cdot \frac{2}{\sqrt{2}} \\ & 2 \cdot s^2 \\ & 2 \\ & + \\ & \frac{2}{\sqrt{2}} \\ & 3 \cdot \frac{2}{\sqrt{2}} \\ & 2 \cdot s^2 \\ & 3 \\ & + \\ & 2 \cdot \frac{2}{\sqrt{2}} \cdot \frac{2}{\sqrt{2}} \\ & s^2 \\ & 2 \\ & + \\ & 3 \cdot \frac{2}{\sqrt{2}} \cdot \frac{2}{\sqrt{2}} \\ & s^2 \\ & 3 \\ &) \end{aligned}$$

그래서 우리는 두 개의 계수를 소개합니다 $= 2$

$$\begin{aligned} & 1 \\ & 2 \cdot s^2 \\ & 1 \\ & + \frac{2}{\sqrt{2}} \\ & 2 \end{aligned}$$

$$\begin{aligned}
& 2 \cdot s^2 \\
& 2 \\
& + \quad 2 \\
& 3 \\
& 2 \cdot s^2 \\
& 3 \\
& , \text{ 그리고 } (\quad , 2, \quad , 3) = \\
& \quad 2 \cdot \quad , 2 \\
& \quad s^2 \\
& 2 \\
& + \quad 3 \cdot \quad , 3 \\
& \quad s^2 \\
& 3 \\
& :
\end{aligned}$$

$$\begin{aligned}
& (\\
& \quad 2 \\
& \quad , 2 \\
& 2 \cdot s^2 \\
& 2 \\
& + \\
& \quad 2 \\
& \quad , 3 \\
& 2 \cdot s^2 \\
& 3 \\
&) + \\
& \quad (\quad , 2, \quad , 3)^2 \\
& 4 \cdot \\
& \cdot \\
& f \\
& \quad (\quad + \\
& \quad (\quad , 2, \quad , 3) \\
& 2 \quad)^2
\end{aligned}$$

그래서 우리는 얻을 수 있습니다

$$\begin{aligned}
& (\quad) = \quad (\quad) = \\
& (\\
& \quad 2 \\
& \quad , 2 \\
& 2 \cdot s^2 \\
& 2 \\
& + \\
& \quad 2 \\
& \quad , 3 \\
& 2 \cdot s^2 \\
& 3 \\
&) +
\end{aligned}$$

$$\frac{1}{4} \cdot \frac{1}{\sqrt{\pi}}$$

픽셀 에서 의 스플래팅 결과로.
렌더링 그래데이션. 슈퍼렌더링의 에너지 항에 대해
비전을 다음과 같이 작성할 수 있습니다.

$$= \sum$$

$$\left(\frac{1}{\sqrt{\pi}} \cdot \frac{1}{\sqrt{\pi}} \right)^2,$$

여기서 $(\cdot)$ 는 뷰의 Ground Truth이고 $(\cdot)$ 은
다음과 같이 쓸 수 있는 Gaussian splatting의 렌더링 함수:
 $(\cdot) =$
 $\sum$

$$c \cdot \text{Sig}(\cdot) \cdot \left(\frac{1}{\sqrt{\pi}} \right).$$

여기서 c 는 색상이고 $= 1$
 $= 1$ (1)은 의 투과율입니다. 여기서
 $= \text{Sig}(\cdot) \cdot \left(\frac{1}{\sqrt{\pi}} \right)$ 은 불투명합니다. 우리는 찾는다

$$= \sum$$

$$2 \left(\frac{1}{\sqrt{\pi}} \cdot \frac{1}{\sqrt{\pi}} \right) \cdot \sum$$

$$\left(c \cdot \left(\text{Sig}(\cdot) * \left(\frac{1}{\sqrt{\pi}} \right) \right) \right)$$

여기서 도 가우스 지수이고, $\in \{$

,
,
,
,
}는

의 속성. 그래서 우리는 논의만 할 수 있어요
 $\left(\frac{1}{\sqrt{\pi}} \cdot c \cdot \frac{1}{\sqrt{\pi}} \right)$

$$= \left(c \cdot \left(\text{Sig}(\cdot) * \left(\frac{1}{\sqrt{\pi}} \right) \right) \right)$$

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 13 ---

3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 13

다른 속성의 기울기를 비교하려면

따라서 $\frac{\partial \mathbf{c}}{\partial \mathbf{c}} = \mathbf{I}$ 일 때 다음이 성립됩니다.

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)$$

$$=$$

$$\mathbf{c}$$

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)$$

$$= \frac{\mathbf{c} (1 - \text{sig}(\mathbf{c})) \text{sig}(\mathbf{c})}{\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)},$$

$$= \frac{\mathbf{c} \text{sig}(\mathbf{c}) (1 - \text{sig}(\mathbf{c}))}{\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)},$$

$$= \frac{\mathbf{c} \text{sig}(\mathbf{c}) (1 - \text{sig}(\mathbf{c}))}{\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)},$$

여기서 $\text{sig}(\cdot)$ 는 부분도함수를 나타냅니다. 그리고 이 다를 때
에서:

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)$$

$$= 0,$$

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)$$

$$= \frac{\mathbf{c} (1 - \text{Sig}(\mathbf{c})) \text{Sig}(\mathbf{c})}{1}$$

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)$$

$$= - \frac{\mathbf{c} \text{sig}(\mathbf{c}) (1 - \text{sig}(\mathbf{c}))}{1},$$

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)$$

$$= - \frac{\mathbf{c} \text{sig}(\mathbf{c}) (1 - \text{sig}(\mathbf{c}))}{1},$$

$$\text{여디서 } \left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right) =$$

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)^2$$

$$2 \cdot \mathbf{s}^2$$

$$, 2$$

$$+$$

$$\left(\frac{\partial \mathbf{c}}{\partial \mathbf{c}} \right)^3$$

$$\begin{aligned}
& 2 \cdot s_2 \\
& , 3 \\
&) + \\
& (, 2 \quad 2, \quad , 3 \quad 3)^2 \\
& 4 \cdot \\
& \cdot \\
& \sqrt{\cdot}
\end{aligned}$$

따라서 (()) , 및 (()) , 을 무시하면 다음을 찾을 수 있습니다.

같은 그룹에 있는 항목의 나머지 부분은 같은 크기입니다.

적도. Sig() 및 c c 의 경우

c

$$(1 \text{ 시그}()) () 1.$$

따라서 우리는 (()) , 및 (()) , 만 판단할 수 있습니다.

그라디언트.

= 2라고 하면 다음을 얻을 수 있습니다.

$$() , 2 = 1$$

s₂

, 2

·(

$$2 \quad 3 (, 3 \quad 3)$$

s₂

, 3

$$(\quad 2$$

1

s₂

, 1

$$+ \quad 2$$

3

s₂

, 3

$$) (, 2 \quad 2)$$

2

1

s₂

, 1

$$+ \quad 2$$

2

s₂

, 2

$$+ \quad 2$$

3

s₂

, 3

),

여기 s = (). 분명히, 우리는

$$1, (, 3$$

$$3) \quad s , 3 \text{ 및 } 2 + \quad 2 \geq 2$$

$\sqrt{}$

, 그래서 우리는

 $2 \ 3 \ (\ ,3 \ 3)$
 s_2
 $,3$
 2
 1
 s_2
 $,1$
 $+ \ 2$
 2
 s_2
 $,2$
 $+ \ 2$
 3
 s_2
 $,3$
 $2 \ 3$
 $s \ ,3 \ 2$
 1
 s_2
 $,1$
 $+ \ s \ ,3 \ 2$
 2
 s_2
 $,2$
 $+ \ 2$
 3
 $s \ ,3$
 $\leq \ 2 \ 3$
 $2 \ 2 \ 3$
 $s \ ,2$
 $s \ ,2,$

그리고 우리는 $(\ ,2 \ 2) \ s \ ,2$ 를 가지고 있습니다.

 $(\ 2$
 1
 s_2
 $,1$
 $+ \ 2$
 3
 s_2
 $,3$
 $)(\ ,2 \ 2)$
 2
 1
 s_2

$$\begin{aligned}
& + \binom{s-1}{2} \\
& = \frac{(s-1)(s-2)}{2} \\
& = \frac{(s-1)s}{2} - \frac{(s-1)}{2} \\
& = \frac{s(s-1)}{2} - \frac{s-1}{2} \\
& = \frac{(s-1)(s-1+1)}{2} \\
& = \frac{(s-1)s}{2} \\
& = \frac{s(s-1)}{2}
\end{aligned}$$

$$\begin{aligned}
& s_2 \\
& , 2 \\
& - \\
& 2 \quad 2 \quad 3 \quad (\quad , 2 \quad 2) (\quad , 3 \quad 3) (\\
& s_2 \\
& , 3 \quad 2 \\
& 1 \\
& s_2 \\
& , 1 \\
& + \quad 2 \\
& 3) \\
& s_2 \\
& , 2 \quad s_4 \\
& , 3 \quad 2 .
\end{aligned}$$

각 항목을 단계별로 분석합니다. ($\quad , 2 \quad 2$) $s \quad , 2$ 의 경우,

$$\begin{aligned}
& (\quad 2 \\
& 1 \\
& s_2 \\
& , 1 \\
& + \quad 2 \\
& 3 \\
& s_2 \\
& , 3 \\
&) \quad 2 \\
& 2 (\quad , 2 \quad 2) 2 \\
& 2 \quad 2 \quad s_4 \\
& , 2 \\
& \leq \\
& 2 \\
& 2 \\
& 2 \quad s_2 \\
& , 2 \\
& 1,
\end{aligned}$$

마찬가지로 우리는 다음을 얻습니다.

$$\begin{aligned}
& (\quad 2 \\
& 1 \\
& s_2 \\
& , 1 \\
& + \quad 2 \\
& 3 \\
& s_2 \\
& , 3 \\
&) (\quad , 2 \quad 2) 2 \\
& s_2 \\
& , 2 \\
& 1
\end{aligned}$$

세 번째 항목은 약간 더 복잡하므로 다음 단계에서 처리하겠습니다.

두 부분. 먼저 첫 번째 부분을 다루겠습니다.

$1 :=$
 $2 \quad 2$
 $1 \quad 2 \quad 3 \quad (\quad , 2 \quad 2) (\quad , 3 \quad 3)$
 s_2
 $, 1 \quad s_2$
 $, 2 \quad s_2$
 $, 3 \quad 2 .$
참고 $1 =$
 $2 \quad s_2$
 $, 2 \quad s_2$
 $, 3 \quad 2$
 $1 \quad s_2$
 $, 1 \quad 2 \quad 3 \quad (\quad , 2 \quad 2) (\quad , 3 \quad 3)$
 $(\quad s_2$
 $, 2 \quad s_2$
 $, 3 \quad 2$
 $1 + \quad s_2$
 $, 1 \quad s_2$
 $, 3 \quad 2$
 $2 + \quad s_2$
 $, 1 \quad s_2$
 $, 2 \quad 2$
 $3) 2$, 그래서 자연스러운 생각
두 부분으로 나눕니다.

$1 =$
 $2 \quad s_2$
 $, 2 \quad s_2$
 $, 3 \quad 2$
 1
 s_2
 $, 2 \quad s_2$
 $, 3 \quad 2$
 $1 + \quad s_2$
 $, 1 \quad s_2$
 $, 3 \quad 2$
 $2 + \quad s_2$
 $, 1 \quad s_2$
 $, 2 \quad 2$
 3
 $.$
 s_2
 $, 1 \quad 2 \quad 3 \quad (\quad , 2 \quad 2) (\quad , 3 \quad 3)$
 s_2
 $, 2 \quad s_2$
 $, 3 \quad 2$
 $1 + \quad s_2$

$\begin{pmatrix} 1 \\ 3 \end{pmatrix}^T s^2$
 $2 + \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T s^2$
 3
 $\cdot$
 $(\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2) \text{ 및 } (\begin{pmatrix} 3 \\ 3 \end{pmatrix}^T s^2)$ 에 대해 다음을 갖습니다.
 $2 + \begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2$
 1
 $\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2$
 $1 + \begin{pmatrix} 1 \\ 3 \end{pmatrix}^T s^2$
 $2 + \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T s^2$
 3
 $\leq 1,$
 $\begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}^T s^2 (\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2) (\begin{pmatrix} 3 \\ 3 \end{pmatrix}^T s^2)$
 $\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2$
 $1 + \begin{pmatrix} 1 \\ 3 \end{pmatrix}^T s^2$
 $2 + \begin{pmatrix} 1 \\ 2 \end{pmatrix}^T s^2$
 3
 $\leq 1.$
 마찬가지로 두 번째 부분도 다룹니다.
 $2 :=$
 $2 + \begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2$
 $3 (\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2) (\begin{pmatrix} 3 \\ 3 \end{pmatrix}^T s^2)$
 $\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^4$
 $\begin{pmatrix} 3 \\ 3 \end{pmatrix}^T s^2.$
 참고 $2 = 2 + \begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2$
 $3 (\begin{pmatrix} 2 \\ 3 \end{pmatrix}^T s^2)$
 $($
 s^2

$$,3 \quad s \quad ,2 \quad 2$$

1

$$s2$$

$$,1$$

+

$$s2$$

$$,3 \quad 2$$

2

$$s \quad ,2 + \quad s \quad ,2 \quad 2$$

$$3) \quad 2$$

, 그래서 우리는 그것을 두 부분으로 나눕니다:

$$2 = 2 \quad 2 \quad 3 \quad (\quad ,3 \quad 3)$$

$$s2$$

$$,3 \quad s \quad ,2 \quad 2$$

1

$$s2$$

$$,1$$

+

$$s2$$

$$,3 \quad 2$$

2

$$s \quad ,2$$

$$+ \quad s \quad ,2 \quad 2$$

3

.

$$2$$

$$3(\quad ,2 \quad 2)$$

$$s2$$

$$,3 \quad s \quad ,2 \quad 2$$

1

$$s2$$

$$,1$$

+

$$s2$$

$$,3 \quad 2$$

2

$$s \quad ,2$$

$$+ \quad s \quad ,2 \quad 2$$

3

.

그런 다음 우리는 다음을 가집니다:

$$2 \quad 2 \quad 3 \quad (\quad ,3 \quad 30)$$

$$s2$$

$$,3 \quad s \quad ,2 \quad 2$$

1

$$s2$$

$$,1$$

+

s^2

$, 3^2$

2

s^2

+ s^2

3

≤ 1 ,

ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 14 ---

14 • 곧. 제출 ID: 2152

2

3 ($, 2^{20}$)

s^2

$, 3^2 s^2$

1

s^2

$, 1$

+

s^2

$, 3^2$

2

s^2

+ s^2

3

≤ 1 .

따라서 () $, 2 \leq 1$ 이 되고, $2 = 3 = 0$ 이면 () $, 2^1$ 이 됩니다.

동등성의 정의에 따르면 () $, 2^1$. 그리고

의 다른 값과 동일합니다.

따라서 특정 및 에서 다음과 같은 사실을 찾을 수 있습니다.

s^2 ,

(c)

,

(c)

,

(c)

,

(c)

,

특히 회전 속성

쿼터니언 배열은 다음과 같습니다.

다음과 같이 업데이트:

+1

=

+ $\triangle$

이는 가우시안이 자신의 위치를 더 기꺼이 바꿀 것임을 의미합니다.
에너지를 줄이기 위해 대규모 사고가 발생할 가능성이 높습니다.
무작위 드리프트 및 로컬 최소값을 선호합니다. 최적의 달성을 위해
결과적으로 우리는 모든 변수가 상대적으로 일관되게 변경되는 것을 목표로 합니다.
방식. 이를 위해서는 변화를 늦추는 것을 고려하는 것이 당연하다.
3D 가우시안의 위치 속성에서. 구체적으로 우리는
3DGS 최적화 절차를 이산화로 공식화
편미분 방정식(PDE)을 사용하고 점도를 사용합니다.

계수, 공간적 위치가 흡수되고 점차적으로 해제되도록 허용
3D 가우시안의 위치 그래디언트.
그리고 가우스 함수 속성으로 인해 우리는

여기서 ϵ 는 가우스 함수에 대한 신뢰 한계 0.99입니다. 그래서 서로 다른 스케일의 동일한 3D 가우스 $\mathcal{G}_i$ 에 대해 s_i , 우리는

$$\begin{aligned} & \sum_{i=1}^n \left(\frac{1}{c_i} \cdot c_i \cdot \frac{1}{c_i} \right) \\ &= \sum_{i=1}^n \frac{1}{c_i} \\ &\geq \frac{1}{\max_{i=1, \dots, n} c_i} \\ &= \frac{1}{c_{\max}} \end{aligned}$$

그리고 위치 그래데이션
의 $\frac{\partial \phi}{\partial x}$ 은 $(\frac{\partial \phi}{\partial x})_c$ 에 비례합니다.

따라서 우리는 서로 다른 위치 사이의 위치 기울기 관계를 갖습니다.
3D 가우스:

관찰. 3DGS는 복잡한 장면을 3D 세트로 표현합니다. 가우스. 그러나 다양한 3DGS 방법[Geiger et al. 2024년; Yu et al. 2024a]는 블러링과 중복되고 모호한 지리적 재구성으로 인한 플로터 매트릭 구조로 인해 렌더링 및 재구성이 저하됩니다. 품질. 우리는 흐릿함과 불균일성을 다음의 폐색으로 간주합니다.

중복된 큰 가우시안과 작은 가우시안의 모호함,
그림 2와 같이 대형 3D 가우시안은 높은 3D 가우시안을 캡처하지 못합니다.
주파수 세부 정보가 다른 가우시안을 방해하는 경향이 있어
중복성과 새로운 관점에서 흐려짐으로 나타남. 소규모의 경우
3D 가우시안은 불안정한 그라데이션으로 인해 플로터가 나타나는 경향이 있습니다.
가우시안처럼 잘 관찰되지 않는 장면 영역에서
3DGS 중에 관찰된 뷰 쪽으로 위치를 이동하는 경향이 있습니다.
최적화 프로세스로 인해 모호한 기하학적 결과가 발생합니다.
구조.

A.2 공간의 속도 복셀

건물. 우리는 다음을 고려한 손실 함수를 구축하는 것을 목표로 합니다.

공간 위치 $\mathbf{x}$ 에 위치한 입자에 대한 위치 그라데이션 필드:

$$(\mathbf{x}) =$$

그러나 입자의 속성은 알려져 있지 않기 때문에
용어는 직접 계산할 수 없습니다. 더욱이, 운동 동일로서,
3DGS의 기능은 장면 렌더링의 그라데이션을 기반으로 합니다.
결과적으로 서로 다른 색상 속성을 가진 입자는 서로 다른 결과를 나타냅니다.
일반적으로 선형 관계가 결여된 움직임 경향.
따라서 단순히 공간 근처의 입자 속성을 평균화하면
그런 다음 이 평균 속성 세트를 사용하여 계산합니다.
위치 그라데이션은 의미가 없습니다.
우리는 가장 가능성이 높은 것을 나타내기 위해 $\mathbf{v}$ 의 속도 필드를 목표로 합니다.
이 위치에서 가우스 구의 변위. 그러므로 우리는
로컬 평균으로 속도 필드를 구성하고 업데이트하도록 선택합니다.
Eq.31과 같이 $\mathbf{v}$ 의 속도.
이 접근 방식은 수학적으로 의미가 있습니다.
3차원의 점으로 표시되는 3D 가우시안의 위치 그라데이션
공간, $\mathbf{x}$ 근처의 3D 가우시안의 위치 기울기가 점을 형성합니다.
이 속도 필드에는 구름이 있습니다. 우리는 $\mathbf{v}$ 가 중앙에 위치하길 원해요.
이 포인트 클라우드 내에서 가장 큰 클러스터 중 하나입니다.
달성할 수 있음을 의미합니다. 또한, 산술 평균은 다음과 같이 대응할 수 있습니다.
대규모 브라운 운동이 공간에 미치는 영향의 균형을 맞춥니다.
위치 기울기의 급격한 변화로 인해 발생하는 속도 장. 그런 다음
우리는 공간 속도 필드 $\mathbf{v}(\mathbf{x})$ 를 얻습니다.
그라데이션 필드의 총 영향. $\Delta \mathbf{v} =$ 로 필드를 갱신합니다.

1

| |

o

$\in \Delta$

식 31에서. 그래서 우리는 $\Delta \mathbf{v}$ 의 전체 영향을
필드를 모든 단계에 추가하여 다음을 수행합니다.

(

) =

Σ

$\geq$

Δ

(),
여기서 Δ ()은 Δ 이 차지하는 ()의 일부를 의미합니다. 그래서 우리는
(
) = (1

$$\sum$$
$$\geq$$
$$(\quad + 1)$$
$$\rightarrow \Delta$$

따라서 계수 에 관계없이 업데이트된 각 벡터는
필드를 통해 전체 영향에 1의 가중치를 갖습니다.
시공간 밖으로. 동시에 이 벡터의 총 가중치는
그라디언트의 값은 항상 1입니다. 따라서 선택한 가중치에 상관없이
ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

--- 페이지 15 ---
3D 가우스 스플래팅을 위한 플러그 앤 플레이 PDE 최적화: 고품질 렌더링 및 재구성을 향하여 • 15
계수, 이 속도장의 값은 자연스럽게 나타낼 수 있습니다.
그라데이션의 크기.

2007년 2월 20일에 접수됨; 2009년 3월 12일 개정; 2009년 6월 5일 승인
ACM 트랜스. 그래프., Vol. 1, No. 1, 기사 . 출판일: 2025년 9월.

2. Rotation / Scale (Covariance) 계열

[논문 03] Effective Rank Analysis 본문 전체 번역

--- 페이지 1 ---

효과적인 순위 분석 및 정규화

향상된 3D 가우스 스플래팅

형준하¹ 홍수성⁴ 황성원¹ 이재성¹

추재걸^{1*} 김진화^{2,3*}

¹KAIST ²NA VER AI 연구실 ³SNU AIIS ⁴고려대학교

초록

다시점 이미지로부터 3D 재구성은 근본적인 과제 중 하나입니다.

컴퓨터 비전과 그래픽 분야. 최근에는 3DGS(3D Gaussian Splatting)가

고품질의 실시간 렌더링이 가능한 유망 기술로 부상

3D 재구성. 이 방법은 3D 가우스 표현과 타일 기반을 활용합니다.

값비싼 신경장 쿼리를 우회하는 스플래팅 기술. 그럼에도 불구하고

잠재력, 3DGS는 바늘 같은 인공물, 차선책과 같은 문제에 직면합니다.

가우시안이 수렴하여 발생하는 기하학 및 부정확한 법선

하나의 주요 분산을 갖는 이방성 모양. 우리는 효과적인 사용을 제안합니다

3D 가우시안 프리미티브의 형상 통계를 조사하고 식별하기 위한 순위 분석

가우시안은 실제로 유효 순위 1을 사용하여 바늘 모양으로 수렴됩니다.

이 문제를 해결하기 위해 정규화로서 유효 순위를 도입합니다.

가우스의 구조. 우리의 새로운 정규화 방법은 정규화를 향상시킵니다.

바늘 같은 아티팩트를 줄이면서 기하학적 재구성이 가능합니다. 접근 방식

다른 3DGS 변형에 추가 모듈로 통합되어 성능을 향상시킬 수 있습니다.

시각적 충실도를 손상시키지 않으면서 품질을 향상시킵니다. 프로젝트 페이지는 다음에서 확인할 수 있습니다.

<https://junhahyung.github.io/erankgs.github.io/>.

1 소개

여러 이미지에서 3D 모델을 만드는 것은 컴퓨터 비전과 그래픽의 핵심 과제입니다.

NeRF(Neural Radiance Fields)[20]는 놀라운 성능을 보여줌으로써 이 분야에 혁명을 일으켰습니다.

암시적 신경장과 미분 가능한 렌더링 기술을 통해 새로운 뷰 합성 능력을 발휘합니다.

인상적인 3D 재구성 품질에도 불구하고 NeRF의 교육 및 렌더링 프로세스는

기반 방법은 계산 집약적이어서 실시간 애플리케이션에 심각한 문제를 야기합니다.

훈련 및 렌더링 효율성을 향상시키기 위해 베이킹과 같은 다양한 가속 기술을 사용합니다.

셀 [12, 32] 및 그리드 표현 [5, 21]이 도입되었습니다. 이러한 솔루션은

효율성이 어느 정도 향상되더라도 실시간 대화형 시나리오에는 여전히 한계가 있습니다.

최근에는 3DGS(3D Gaussian Splatting)가 유망한 기술로 떠오르고 있습니다.

고품질 결과로 시간을 렌더링합니다. 이 방법은 3D 가우스 표현을 활용하고

비용이 많이 드는 신경장 쿼리 대신 타일 기반 스플래팅 기술을 적용할 수 있습니다.

실제 적용되는 기술. 이는 더 빠른 속도가 필요한 영역에서 새로운 가능성을 열어줍니다.

가상 및 증강 현실, 게임, 실시간 아바타 등의 렌더링.

그러나 그 잠재력에도 불구하고 3DGS는 형상 재구성 측면에서 몇 가지 과제에 직면해 있습니다. 특히 새롭고 극단적인 작업에서 바늘 같은 아티팩트가 있는 노이즈 렌더링 결과를 포함한 훈련 이미지와는 거리가 멀다. 이러한 문제는 3DGS의 원시 기반 특성에서 비롯됩니다. 개별 프리미티브에는 기하학적 제약이 없습니다.

†교신저자

제38차 신경정보처리시스템 컨퍼런스(NeurlPS 2024).

arXiv:2406.11672v3 [cs.CV] 2024년 12월 8일

--- 페이지 2 ---

(아)

(비) (다)

그림 1: (a) DTU의 새로운 뷰 합성 및 일반 재구성에 대한 질적 결과 [14]

데이터세트. (b)와 (c)는 Mip-NeRF360[2]과 DTU에 대한 새로운 뷰 합성 비교를 보여줍니다.

각각 데이터 세트. 상단 행에는 3DGS의 새로운 뷰 렌더링이 표시되고 하단 행에는

효과적인 순위 정규화를 사용한 3DGS 렌더링을 보여줍니다. 순진한 3DGS는 바늘 같은 느낌을 주지만 우리의 정규화 용어는 새로운 관점에서 이러한 아티팩트를 완화합니다.

정확한 기하학적 재구성을 위해서는 밀도장이 집중되어야 한다는 것이 잘 알려져 있습니다.

표면 근처 [30]. 이를 위해 SuGaR[10]과 같은 이전의 노력은 정규화에 중점을 두었습니다.

3D 가우스는 더 평평해집니다. 즉, 다음 중 하나를 사용하여 기본 요소를 이방성 가우스로 정규화합니다.

그 차이는 매우 작습니다. 마찬가지로 2DGS[13]는 3D 가우스 대신 2D 가우스를 사용하여

이 효과.

표면과의 적절한 정렬을 위해서는 가우시안의 평탄도가 필요하지만 우리는 다음과 같이 주장합니다.

평면성만으로는 표면 형상을 정확하게 표현하기에 충분하지 않습니다. 가우스는 또한

하나의 분산이 다른 분산을 지배하는 바늘 모양 또는 고도로 이방성인 것을 피하십시오. 바늘 모양

가우시안은 표면의 무시할 수 있는 부분만 커버하므로 정확한 재구성을 방해합니다.

뾰족한 유물을 생산합니다. 대신, 의미 있는 영역을 다루기 때문에 디스크와 같은 가우시안이 더 좋습니다.

표면 재구성에 효과적으로 기여합니다.

그러나 기존 방법은 디스크형 가우스와 바늘형 가우스를 적절하게 구별하지 못합니다.

둘 다 0에 가깝거나 정확히 0인 하나의 척도를 나타낼 수 있기 때문입니다. 경험적으로 우리는 대부분의 가우스는 이방성 형태로 수렴하여 두 축을 따라 작은 스케일을 갖는 바늘 모양이 됩니다.

적절한 정규화 메커니즘이 없기 때문입니다.

형상 통계(지오메트리가 디스크 모양인지 바늘 모양인지)를 직접 조사하려면

3D 가우스 프리미티브를 학습하고 훈련 중 구조적 변화를 이해하는 방법을 먼저 제안합니다.

가우시안의 공분산 행렬에 대한 효과적인 순위 분석을 수행합니다. 효과적인

정수 순위의 실수 값 및 미분 가능한 확장인 순위 [25]를 사용하여 다음을 수행할 수 있습니다.

가우스 프리미티브의 훈련 역학 및 구조적 변환을 모니터링합니다. 실제로 우리의

분석에 따르면 가우시안의 유효 순위는 유효 순위 1 (erank-1)에 접근합니다.

3DGS 및 SuGaR[10] 및 2DGS[13]와 같은 다른 방법에서 바늘 모양의 모양이 생성됩니다.

또한 구조를 제한하기 위해 정규화 용어로 유효 순위를 사용할 것을 제안합니다.

가우시안의. 오목 로그 항을 사용한 유효 순위의 미분 가능 특성

안정적인 그라디언트를 제공하여 지속적인 최적화 문제에 직접 적용할 수 있습니다. 우리의 새로운 정규화 방법은 바늘 모양을 줄이면서 법선 및 형상 재구성을 향상시킵니다.

2

--- 페이지 3 ---

슈가R3DGS2DGS

기준선기준선 + erankreg.

반복 1만번 14000반복 30000

그림 2: (녹색): 기본 방법인 3DGS[16], SuGaR[10] 및

2DGS[13]는 가우시안 랭크가 형상 재구성을 위해 최적으로 제한되지 않음을 보여줍니다.

(보라색): 정규화 항은 가우시안을 적절하게 제한하여 평면화하고 방지합니다.

바늘 모양으로 수렴됩니다.

특히 새로운 보기 시나리오에서 아티팩트가 발생합니다. 또한, 효과적인 순위 정규화는 다음과 같습니다.

다른 3DGS 변형에 추가 모듈로 적용되어 품질이 향상되었습니다.

우리 작업의 주요 기여는 다음과 같습니다.

- 먼저 효과적인 방법을 사용하여 가우스 원시 구조의 역학을 분석하고 있습니다.

가우시안이 이방성 형태로 수렴한다는 것을 발견하여 최적화 과정에 참여합니다.

하나의 지배적인 분산이 있습니다.

- 우리는 바늘 같은 아티팩트를 완화하는 효과적인 순위 정규화 방법을 제안합니다.

3DGS 렌더링 및 기하학적 재구성이 향상되었습니다.

- 우리의 접근 방식은 다른 3DGS 변형과 통합될 수 있는 추가 모듈입니다.

우리의 방법이 타협하지 않고 3D 형상 재구성을 향상시킨다는 것을 보여줍니다.

시각적 품질.

2 관련 작품

새로운 뷰 합성 NeRF[20]는 새로운 뷰에서 사실적인 렌더링에 혁명을 일으켰습니다.

3D 장면의 신경 암시적 표현을 도입하여 포인트를 파악합니다. 이 접근법은 고주파수를 사용합니다.

위치 인코딩과 미분 가능한 볼륨 렌더링을 통해 전례 없는 현실감을 구현합니다. 강화-

NeRF에 대한 기술은 엔티앨리어싱[1, 3], 무한한 장면 매개변수화[2, 37]와 같은 문제를 해결합니다.

확률론적 과도 모델링을 통해 실제 이미지로부터 훈련[19, 8, 29]을 수행합니다. 더 나아가

3

--- 페이지 4 ---

erank 3errank 2errank 1.65errank 1.25errank 1.08

그림 3: 3D 구와 2D 디스크의 실제 규모 시각화 및 유효 순위.

개선 사항은 하위 텐서를 통합하여 훈련 시간을 줄이고 렌더링 품질을 향상시킵니다.

구성 요소 [5].

다른 연구 노력에서는 다음을 수행하는 대체 암시적 모델을 사용하여 실시간 렌더링을 목표로 했습니다.

MLP에 의존하지 마십시오. 주목할만한 예로는 희소 복셀 그리드[9] 및 다중 해상도 해시 인코딩이 있습니다.

ing [21]. 이러한 발전에도 불구하고 광선 추적 방법은 본질적으로 래스터화보다 느립니다. 받는 사람

이 문제를 해결하기 위해 3DGS[16]는 실시간 고충실도를 위한 포인트 기반 래스터화 기술을 도입했습니다.

합성을 봅니다. EW A V olume Splatting [39]에서 영감을 받은 3DGS는 완전히 차별화 가능한 파이프라인을 사용합니다.

3D 가우시안으로 3D 장면을 표현하고 알려진 카메라 포즈에 볼륨 스플래팅 수행

래스터화를 위해.

표면 재구성 표면 재구성은 컴퓨터 비전 및 그래픽의 중요한 영역입니다.

2D 이미지나 기타 데이터 형식에서 3D 모양과 구조를 재현하는 것을 목표로 합니다. 최근 중

혁신을 통해 NeuS[30]는 볼륨 렌더링 및 부호 있는 거리 함수(SDF)를 활용하여

충실도 재구성. NeuS2 [31]는 훈련 속도를 크게 향상시키고 모델링을 확장합니다.

역동적인 장면을 수용할 수 있습니다. UNISURF [22]는 암시적 표면 모델과 복사장을 통합합니다.

표면 및 볼륨 렌더링 모두. V olSDF [33]는 형상의 함수로 체적 밀도를 모델링합니다.

고품질의 기하학적 재구성을 달성합니다. Neuralangelo[18]는 다중 해상도 해시 그리드를 사용합니다.

세부 구조를 복구하기 위한 신경 표면 렌더링. BakedSDF [34]는 하이브리드 신경망을 도입합니다.

메쉬 추출에 최적화된 볼륨 표면 표현.

3D Gaussian Splatting 최근 3DGS의 발전으로 표면 재구성이 더욱 촉진되었습니다.

tion. NeuSG [6]는 3DGS 및 신경 암시적 모델을 사용하여 표면 세부 사항을 개선합니다. SuGaR [10] 초점 SDF 기반 정규화 및 포아송 재구성을 사용한 메쉬 추출에 대해 설명합니다. 2DGS [13] 붕괴 일관된 뷰 형상 및 상세한 메쉬 재구성을 위해 3D 볼륨을 2D 가우스 디스크로 변환합니다. GaussianShader[15]는 음영 기능을 사용하여 반사 표면의 렌더링 품질을 향상시킵니다. 3D 가우스. GOF [36]는 밀도 추정 및 기하학을 위해 광선-가우스 교차점을 활용합니다. 정규화. GIR [28]은 역 렌더링을 위해 3D 가우스를 사용하여 정확한 추정을 가능하게 합니다. 재료 특성, 조명 및 기하학. 이러한 발전은 다음의 잠재력을 보여줍니다. 고속의 상세하고 다양한 표면 재구성을 위한 3DGS입니다.

3 예선

3.1 3D 가우스 스피래팅

3DGS[16]는 학습 가능한 3D 가우스 프리미티브 세트가 있는 장면을 나타냅니다. $\{G_k | k = 1, \dots, K\}$, 여기서 각 3D Gaussian G_k 는 평균 $\mu_k \in \mathbb{R}^3 \times 1$, 공분산 $\Sigma_k \in \mathbb{R}^3 \times 3$, 점 불투명도 $\alpha_k \in [0, 1]$ 로 구성됩니다. 및 구면 고조파의 뷰 종속 색상 ck . 공분산 행렬 $\Sigma_k = R_k S_k S_k^T$

 kRT $k \leq$

양의 준정부호, 여기서 $S_k = \text{diag}(s_k)$ 는 스케일링 행렬이고, $s_k = (s_{k1}; s_{k2}; s_{k3}) \in \mathbb{R}^{3 \times 1}$ 은 scale 매개변수이고 $R_k \in \mathbb{R}^{3 \times 3}$ 은 쿼터니언으로 매개변수화된 회전 행렬입니다. 3D 가우스 프리미티브는 3D 공간에서 다음과 같이 표현될 수 있습니다.

$$G_k(x) = \frac{1}{2} (x - k)^T \frac{1}{k(x - k)}. \quad (1)$$

그런 다음 기본 요소는 미분 가능한 볼륨 스플래iting을 통해 래스터화됩니다. 구체적으로 3D 가우스는 2D 화면 공간에 투영됨

$k = JW \ k W^T J^T$, 여기서 W 는 월드-카메라 변환이고
 J 는 투영 행렬의 야핀 근사의 야코비안입니다[39]. 공분산과 평균

--- 페이지 5 ---

투영된 가우시안 G2D의

$k(x)$ 는 의 세 번째 열과 행을 제거하여 얻습니다.

케이

단순히 μ_k 를 화면 공간에 투영하는 것뿐입니다. 마지막으로 가우시안은 알파 블렌딩됩니다.

깊이의 순서는 다음과 같습니다.

$$c(\frac{\omega}{\pi}) = \sum_{k=1}^{\infty} KX$$

333

k 1Y

$j=1$

$$(1 - jG2D$$

$$j(u)), (2)$$

여기서 u 는 화면 공간 좌표입니다. 렌더링된 이미지는 광도 손실 L 로 감속됩니다.

NeRF [20]와 유사한 3D 기본 최적화를 위한 것입니다.

가우스는 희박한 SfM 포인트로 초기화되므로 적응형 밀도 제어(ADC)는 다음을 위해 설계되었습니다.

최적화 중 치밀화. 특히 ADC는 다음을 만족하는 가우스를 서브샘플링하고 분할합니다.

조건:

$\forall L$

$\forall n$

2

=

X

$\mathcal{N} \in \mathcal{P}$

$\forall L$

$\forall \text{파이}$

$\forall \text{파이}$

$\forall n$

2

$\forall \cdot, (3)$

여기서 $\mathcal{P}$ 와 $\mathcal{P}_i$ 는 각각 픽셀 인덱스 집합과 i 번째 픽셀을 나타내고 $\mathcal{N}$ 는 미리 정의된 문지방. Eq.의 직관. 3은 아직 잘 재건되지 않은 지역이 넓은 시야를 보인다는 것입니다.

공간 위치 그래데이션. 이는 최적화 프로세스가

가우스는 이러한 영역을 수정하므로 이러한 가우스를 밀도화하면 표현성이 효과적으로 향상될 수 있습니다.

3.2 유효 순위

모두 0이 아닌 실수 값 $M \times N$ 행렬 A 를 생각해 보세요. 특이값 분해(SVD)

A 의 $A = UDV^T$ 로 표현될 수 있습니다. 여기서 U 와 V 는 $M \times M$ 크기의 단위 행렬이고

$N \times N$ 이고, D 는 실수 양수 단수를 포함하는 $M \times N$ 크기의 대각 행렬입니다.

내림차순으로 값:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_L \geq 0, (4)$$

여기서 $L = \min\{M, N\}$. 그러면 특이값 분포는 다음과 같이 정의됩니다.

$$g_i = \lambda_i$$

$$r_i = 1$$

$$, i = 1, 2, \dots, L, (5)$$

여기서 $\mathbf{g} = (g_1, g_2, \dots, g_L)^T$ 이고, $\mathbf{B} \cdot \mathbf{B}$ 는 ℓ_1 -norm을 나타냅니다.

정의 1(유효 순위). 행렬 A 의 유효 순위 [25]는 다음과 같이 간략하게 정의됩니다.

$\text{erank}(A) = \exp\{H(q_1, q_2, \dots, q_L)\}$, 여기서 $H(q_1, q_2, \dots, q_L)$ 는 다음과 같이 주어진 Shannon 엔트로피입니다.

$$H(q_1, q_2, \dots, q_L) =$$

$$LX$$

$$\mathcal{N} = 1$$

$$g_i \log g_i. (6)$$

4 방법

섹션 4.1에서는 가우시안의 기하학적 구조를 검사하기 위한 효과적인 순위 분석을 소개합니다.

3DGS 및 그 변형은 기본 구조를 밝힙니다. 우리의 조사 결과를 바탕으로

효과적인 순위 분석을 위해 섹션 4.2에서 새로운 효과적인 순위 정규화 방법을 제안합니다.

4.1 3차원 가우시안의 효과적인 순위 분석

우리는 개별 3D의 구조적 역학을 조사하기 위해 유효 순위를 분석할 것을 제안합니다.

가우스의 공분산 행렬의 유효 순위를 계산하여 가우스. 공분산

3D Gaussians의 행렬은 $\mathbf{K} = \mathbf{R}\mathbf{k}\mathbf{S}\mathbf{k}^T$ 로 정의됩니다.

$$\mathbf{K} \mathbf{R} \mathbf{T}$$

$\mathbf{k}$ 이고, SVD 이후의 대각 행렬은 다음과 같습니다.

$D = SkST$

k , 다음과 같이 내림차순으로 실제 양수 특이값이 포함됩니다.

s_2

$1 \geq s_2$

$2 \geq s_2$

$3 > 0$, (7)

여기서는 간결함을 위해 sk 의 첨자 k 를 생략합니다.

5

--- 페이지 6 ---

따라서 공분산 행렬 k 를 사용하여 3D Gaussian G_k 의 유효 순위를 도출할 수 있습니다.

엔트로피 항은 $H(G_k) := H(q_1, q_2, q_3) := -P_3$ 입니다.

$i=1$ $q_i \log q_i$,

$q = (q_1, q_2, q_3) =$

s_2

1

에스, 에스2

2

에스, 에스2

3

에스

, 여기서 $S =$

$3 \times$

나는=1

s_2

나, (8)

공분산 행렬 k 를 사용하는 3D 가우스 G_k 의 유효 순위는 다음과 같이 정의됩니다.

$\text{erank}(G_k) := \exp\{H(G_k)\}$. (9)

정수 순위의 미분 가능한 확장인 유효 순위는 기하학적 계산에 적합한 도구입니다.

3D 가우시안 분석은 모든 스케일 매개변수를 공동으로 고려하고 식별할 수 있기 때문에 세 축의 상대적인 스케일. 효과적인 순위의 이점은 다음과 같은 경우에 더욱 분명해집니다.

3D 가우시안의 개별 또는 쌍별 분산만 분석하는 최근 연구와 비교됩니다[15].

이러한 접근 방식은 가우시안의 기하학을 완전히 표현하지 못하며 잠재적으로 평면형 및

바늘 모양의 가우시안이 함께 분류됩니다. 더 나은 이해를 위해 효과적인

그림 3의 구와 2D 디스크의 순위.

우리 접근 방식의 뚜렷한 장점을 통해 바늘 모양의 가우시안과

이는 1에 가까운 유효 순위와 평면 디스크형 가우시안을 갖습니다. 장면을 재구성하려면

정확한 표면을 위해서는 잘 정렬되고 집중되는 평면을 나타내는 가우스가 필요합니다.

표면 [30]. 이상적으로는 $\text{erank}(G_k) \approx 2$ 인 3D 가우스가 선호되지만

얇고 길쭉한 물체와 패턴을 표현하는 데에도 2보다 작은 유효 순위가 필요합니다.

그러나 바늘 모양의 가우스 워더랭크(G_k) ≈ 1 은 다음을 설명하기 때문에 바람직하지 않습니다.

표면의 무시할 수 있는 영역과 새로운 관점에서 퇴화된 결과를 생성합니다.

그림 2의 첫 번째 행(녹색 그래프)은 훈련 중 3DGS에 대한 유효 순위 히스토그램을 보여줍니다.

모델이 수렴함에 따라 $\text{erank}(G_k) \approx 1$ 인 3D 가우스의 수가 증가합니다.

PSNR 및 Chamfer 거리 메트릭의 개선 없이 과적합(메트릭은 다음에서 제공됨)

부록 A.5, 표 5). 이는 대부분의 "평탄한" 가우스(특이값)가 0에 가까움은 실제로는 원판 모양($\text{erank}(G_k) \approx 2$)이 아니라 바늘 모양($\text{erank}(G_k) \approx 1$)입니다. 그것은 또한 3DGS가 자연스럽게 $\text{erank}(G_k) = 2$ 에서 작은 모드를 형성한다는 점은 흥미롭습니다. 정규화를 통해 더욱 강화될 수 있는 선호도입니다. 가우시안에 대해 서로 다른 기하학적 제약 조건이 있음에도 불구하고 SuGaR [10](두 번째 행) 그림 2)와 2DGS[13](그림 2의 세 번째 행)도 비슷한 경향을 보이며 많은 양을 갖는다. 축을 따라 단일 지배적 분산을 갖는 바늘 모양의 가우시안입니다. 모든 가우시안은 2DGS는 정확히 2의 유효 순위로 시작하지만 대부분은 여전히 디스크 모양을 유지하지 못하고 대신 바늘 같은 2D 가우시안이 됩니다.

4.2 최적화

유효 순위의 실제 가치와 차별화 가능한 특성을 통해 정규화로 활용할 수 있습니다. 3D 가우시안에 구조적 제약을 가하는 것이 목표입니다. 구체적으로 우리의 목표는 2 미만의 3D 가우시안의 효과적인 순위를 통해 평면 모양을 촉진하고 가우시안에 불이익을 줍니다. 바늘 모양 인공물을 최소화하기 위해 1에 가까운 유효 순위를 사용합니다. 디스크와 같은 가우시안은 $\text{erank}(G_k) \approx 2$ 가 선호되며, $\text{erank}(G_k) < 2$ 인 모양도 복소수를 표현하는 데 필수적입니다. 기하학. 우리는 기하급수적으로 증가하는 효과적인 순위 정규화 용어를 제안합니다. 유효 순위는 1에 가까워서 이러한 가우시안에게 강력한 불이익을 줍니다.

르랭크 =

X

케이

$$\text{erank} \max(-\log(\text{erank}(G_k) - 1 + \epsilon), 0) + s3, (10)$$

여기서 $\epsilon = 1 \times 10^{-5}$ 는 수치적 안정성을 보장하고 $s3$ 은 G_k 의 가장 작은 척도 매개변수입니다. 는 정규화는 에 추가될 때 가우스 프리미티브의 유효 순위를 효과적으로 제한합니다. 그림 2의 보라색 그래프와 같이 기준선이 됩니다. 또한 정규화도 적용될 예정입니다. 7000회 반복부터 Coarse-to-Fine 학습 패러다임을 고수하여 안정적인 학습이 가능합니다. $\text{erank}(G_k) > 2$ 가우스를 사용한 초기 반복 시. ADC 알고리즘 [4, 36]에 제시된 치밀화 알고리즘의 수정된 버전을 채택합니다. 이는 합산의 노름 대신 노름의 합산을 기반으로 가우스를 밀도화합니다.

6

--- 페이지 7 ---

표 1: DTU 데이터 세트에 대한 모따기 거리 및 PSNR 보고서. +e는 Erank 정규화를 나타냅니다.

방법 24 37 40 55 63 65 69 83 97 105 106 110 114 118 122 Mean Std. PSNR

3DGS 2.14 1.53 2.08 1.68 3.49 2.21 1.43 2.07 2.22 1.75 1.79 2.55 1.53 1.52 1.50 1.96 0.52

32.823DGS+e 0.86 0.77 0.88 0.52 1.29 1.44 0.96 1.30 2.09 0.72 0.87 1.40 0.88 0.94 0.66 1.04 0.39 33.09

슈가R 1.47 1.33 1.13 0.61 2.25 1.71 1.15 1.63 1.62 1.07 0.79 2.45 0.98 0.88 0.79 1.33 0.52 31.59슈가R+e 0.86 0.78 0.89 0.53 1.28 1.45 0.87 1.31 1.60 0.72 0.86 1.45 0.87 0.94 0.66 1.00 0.33 31.76

2DGS 0.48 0.91 0.39 0.39 1.01 0.83 0.81 1.36 1.27 0.76 0.70 1.40 0.40 0.76 0.52 0.80 0.33

32.432DGS+e 0.46 0.86 0.39 0.40 0.96 0.84 0.81 1.29 1.19 0.72 0.70 1.32 0.40 0.75 0.50 0.77 0.30 32.57

GOF 0.50 0.82 0.37 0.37 1.12 0.78 0.73 1.18 1.29 0.71 0.77 0.90 0.44 0.69 0.49 0.74 0.28 32.88GOF+e 0.45 0.66 0.32 0.42 0.97 0.78 0.64 1.13 1.22 0.64 0.62 0.70 0.40 0.53 0.48 0.66 0.26 33.01

표 2: DTU 데이터 세트에 대한 방법의 절제 연구 결과. (a): 고정 치밀화(ADC)

알고리즘, (b): erank 정규화, (c): 부록에서 논의된 선택적 트릭 모음.

방법 24 37 40 55 63 65 69 83 97 105 106 110 114 118 122 평균 PSNR

3DGS 2.14 1.53 2.08 1.68 3.49 2.21 1.43 2.07 2.22 1.75 1.79 2.55 1.53 1.52 1.50 1.96 32.82+a 1.24 0.97

1.09 0.62 1.45 1.55 1.14 1.58 2.31 0.92 1.08 1.72 1.02 1.22 0.97 1.26 32.97+a+b 0.85 0.77 0.88 0.51 1.21

1.45 0.96 1.30 2.09 0.72 0.86 1.45 0.87 0.94 0.66 1.03 33.09+a+b+c 0.45 0.66 0.32 0.42 0.97 0.78 0.64 1.13

1.22 0.64 0.62 0.70 0.40 0.53 0.48 0.66 33.01

방정식. 3(자세한 내용은 부록 A.4 참조). 이 변경 사항은 정규화에 특히 중요합니다.

방법. 디스크형 가우시안은 바늘형 가우시안과 달리 다음과 같이 설정된 분할 기준을 충족하지 못하는 경우가 많습니다.

방정식. 3 축의 분산이 클수록 픽셀당 더 작은 그래디언트 신호가 생성되기 때문입니다. 더욱이, 디스크와 같은 가우시안은 일반적으로 더 많은 픽셀 공간을 차지하므로 정렬되지 않은 신호는 서로 상쇄되는 경향이 있습니다.

밖으로. 대조적으로, 수정된 치밀화 알고리즘은 디스크와 같은 가우시안의 분할을 용이하게 합니다.

특히 바늘 모양의 가우시안에 비해 표면을 재구성하는 뛰어난 능력으로 인해

이 방법은 기준선보다 약 10% 더 적은 가우스를 필요로 합니다[16].

5가지 실험

기준선에 대한 추가 기능으로서의 성능을 비교하여 효과적인 순위 정규화를 평가합니다.

모델. 또한 방법의 다양한 구성 요소의 기여도를 분석합니다.

5.1 구현

정규화 하이퍼파라미터 $\text{erank} = 0.01$ 은 모든 훈련에 사용됩니다. 기타 구성품의 경우

기준선에 속하므로 해당 논문에 설명된 것과 동일한 설정을 사용합니다. 모두

실험은 Tesla V100 GPU에서 수행됩니다. 메시 추출의 경우 잘린 부호 있는 거리

Open3D[38]를 사용한 기능(TSDF) 융합이 사용되며 자세한 내용은 부록 A.3에 나와 있습니다.

5.2 비교

데이터 세트 우리는 DTU [14] 및 Mip-NeRF360 [2] 데이터 세트에서 모델을 평가합니다. DTU 데이터 세트

1600 × 1200의 해상도를 가진 15개의 전방 경계 장면으로 구성됩니다.

표준 [13, 36]에 따라 이미지를 800 × 600의 해상도로 다운샘플링합니다. DTU 데이터 세트는 다음과 같습니다.

형상 재구성(모따기 거리 사용)과 새로운 뷰 합성을 모두 평가하는 데 사용됩니다.

Mip-NeRF360 데이터세트는 다음 해상도의 이미지가 포함된 9개의 실내 및 실외 장면으로 구성됩니다.

1600×1050이며 신규 뷰 합성 평가에만 사용됩니다. 새로운 관점 합성을 위해,

이미지는 훈련 세트와 테스트 세트로 분할되고 전체 이미지 세트는 기하학에 사용됩니다.

재건축. COLMAP [26, 27]은 기준선에 대한 포인트 클라우드를 초기화하는 데 사용됩니다.

기준선 우리의 방법은 추가 용어로 다른 기준선에 적용 가능합니다. 그러므로 우리는 비교한다.

정규화가 있거나 없는 기준선. 우리는 SuGaR, 2DGS, GOF를 기준으로 선택하고,

원본 3DGS와 함께 더 나은 형상 재구성에 초점을 맞춘 작업입니다. 모든

제안된 원본 논문 설정을 사용하여 실험을 수행합니다.

형상 재구성 표 1은 형상 재구성의 정량적 결과를 나타냅니다.

DTU 데이터 세트. 평균 모따기와 함께 각 장면의 모따기 거리를 보고합니다.

7

--- 페이지 8 ---

그림 4: TSDF를 사용하여 재구성된 메시의 시각화. 기준 방법은 종종 정규화 용어는 디스크와 같은 가우시안을 적용하여 이러한 아티팩트와 표면 재구성 개선.

G.T.3DGS 바늘GOF GOF + erank reg.

그림 5: DTU 데이터 세트의 일반 재구성 결과. 바늘 모양의 가우시안은 종종 떠납니다.

빈 구멍이나 투명한 영역으로 인해 빈 구멍 또는 불완전한 재구성이 발생합니다.

배 표면. 효과적인 순위 정규화는 이러한 아티팩트를 크게 완화하여 더 많은 결과를 가져옵니다.

정확한 기하학 재구성.

거리와 평균 PSNR. "+e" 기호는 효과적인 순위 정규화가 추가되었음을 나타냅니다.

(고정 밀도 사용)을 기본 방법으로 변경합니다.

결과는 추가 기능 용어로 강화된 방법이 기준선보다 성능이 우수하다는 것을 보여줍니다. 특히, 3DGS(3DGS+e)에 정규화를 적용하면 기하학이 크게 향상됩니다.

재구성하여 정규화의 효율성을 입증합니다. 이는 우리의 가설을 뒷받침합니다
바늘 모양의 가우시안을 줄이고 그림 2와 같이 평탄도를 달성하면 성능이 향상됩니다.
또한, 그림은 SuGaR이 바늘형 및 비평면형 가우시안을 모두 포함하고 있음을 보여줍니다.
2보다 큰 유효 랭크. 유효 랭크를 통해 평탄도 달성 및 스파이크 제거

정규화를 통해 SuGaR(SuGaR+e)에 대해 상당한 성능 향상을 달성했습니다.
GOF 및 2DGS에는 깊이 왜곡과 같은 잘 설계된 정규화 용어가 이미 포함되어 있습니다.
손실 [13, 2], 가우시안을 표면에 정렬하고 형상 재구성을 향상시킵니다. 게다가,
2DGS는 기본적으로 2D 가우스를 명시적으로 사용하여 본질적으로 평면성을 달성합니다. 그럼에도 불구하고,
우리의 방법은 두 접근 방식 모두에서 가우시안이 바늘로 수렴되는 것을 방지합니다.
GOF의 평탄성)으로 인해 성능이 향상됩니다.
그림 4는 메쉬 재구성 결과를 보여줍니다. 여기서 기본 방법은 종종 빈 구멍을 나타냅니다.
재구성된 메쉬. 우리의 정규화 용어는 디스크와 같은 가우시안을 적용하여 이러한 구멍을 줄이고
표면 재구성에 유리한 것으로 입증되었습니다.
그림 5와 그림 1의 첫 번째 행은 정상적인 재구성 결과를 표시합니다. 그림 5에서 결과 이미지는
GOF의 사진은 뾰족한 인공물과 배의 빈 표면을 보여줍니다. 메쉬 결과와 유사하게,
바늘 모양의 가우시안은 전체 영역을 덮지 못하고 빈 구멍이나 투명한 영역만 남기는 경우가 많습니다.
그 결과 비어 있거나 불완전한 재구성이 발생합니다. 효과적인 순위 정규화는 이러한 문제를 완화합니다.
시끄러운 인공물을 제거하여 기본 형상을 보다 정확하게 재구성합니다.
새로운 뷰 합성 2D 이미지로부터 3D 재구성은 잘못된 문제이므로 가우시안
훈련 뷰에 과적합되는 경향이 있어 바늘 모양으로 수렴되고 뾰족한 아티팩트가 발생합니다.
그림 1 (b), (c) 및 그림 6에 표시된 테스트 뷰. 더 나은 이해를 위해 가우스를 시각화합니다.
빨간색으로 $\text{erank}(\text{Gk}) < 1.02$ (약 20:1 이상의 축척 비율)를 사용합니다. 우리의 방법은
가우시안에 구조적 사전을 적용하여 과적합 및 결과적인 아티팩트를 생성합니다.

8

--- 페이지 9 ---

3DGS 바늘3DGS 3DGS + erank reg.
그림 6: DTU 데이터세트의 정성적 비교. $\text{erank}(\text{Gk}) < 1.02$ 인 가우스가 시각화됩니다.
빨간색으로. 우리의 정규화 용어는 새로운 관점에서 바늘 모양의 아티팩트를 완화합니다.
3DGS(PSNR: 25.1 / 1.4GB)3DGS + erankreg. (PSNR: 25.5 / 1.2GB)
그림 7: Mip-NeRF360 데이터세트의 정성적 비교. 우리의 방법은 얇은 것을 효과적으로 표현합니다.
더 나은 시각적 품질과 컴팩트함을 달성합니다.
또한, 그림 7에서 볼 수 있듯이, 우리의 방법은 다음과 같은 경우에 길쭉한 가우시안을 적응적으로 보존합니다.
필요에 따라 날씬한 구조를 표현할 수 있습니다. 결과는 3DGS가
장면을 표현하기 위해 바늘 모양의 가우시안에 크게 의존하지만 우리의 방법은 사용을 제한합니다.
필요한 경우 새로운 뷰 합성 성능이 향상됩니다.
또한 DTU의 평균 PSNR을 보고하는 표 1에 정량적 결과를 제공합니다.
데이터세트. Mip-NeRF360에 대한 결과는 부록 A.5의 표 3에 보고되어 있습니다. 많은 동안
기하학 정규화 기술은 시각적 품질을 저하시키므로 우리의 방법은 이러한 절충안을 나타내지 않습니다.
실제로 가우시안의 모양을 적절하게 제한하여 약간의 개선을 보여줍니다.
효율성 그림 7과 표 4에서 볼 수 있듯이 3D 재구성에서 디스크형 가우시안의 효율성은
바늘 모양의 가우시안에 비해 메모리 공간이 더 좋습니다. 평균 스토리지 사용량은 다음과 같습니다.
DTU 및 Mip-NeRF360 데이터 세트는 표 4(부록 A.5)에 보고되어 있습니다.

5.3 절제

우리의 방법은 (a) 고정 치밀화(ADC) 알고리즘과 (b)라는 두 가지 주요 구성 요소로 구성됩니다.
효과적인 순위 정규화. 우리는 관찰하기 위해 이러한 구성 요소에 대한 절제 연구를 수행했습니다.

순진한 3DGS 방법에 비해 성능이 향상되었습니다. 표 2는 Chamfer 거리를 보여줍니다. DTU 데이터 세트에서 측정된 PSNR. 결과는 두 구성 요소가 모두 기여한다는 것을 나타냅니다. 형상 재구성 및 새로운 뷰 합성 작업의 성능 향상. 추가적으로, 깊이 왜곡 손실[13, 36]과 같은 기술을 통합하면 최고 성능을 더욱 향상시킬 수 있습니다. 모델(행 +a+b+c). 이러한 기술은 부록 A.2에서 논의됩니다.

6 결론

제한 사항 우리의 정규화 용어는 개별 가우스를 제한하지만 다음 사항을 설명하지 않습니다.

장면의 로컬 및 글로벌 구조. 따라서 우리의 방법을 다음과 결합하는 것이 도움이 될 수 있습니다.

가우시안을 고려하는 깊이 왜곡 손실 [13]과 같은 구조 인식 정규화

9

--- 페이지 10 ---

광선을 따라 집단적으로. 또 다른 제한 사항은 하이퍼파라미터 ϵ_{rank} 를 수동으로 선택하는 것입니다.

선택한 하이퍼파라미터는 평가에 사용된 장면에 적합하지만 그렇지 않을 수도 있습니다.

얇은 물체와 구조물이 많은 극한 장면에 최적입니다.

자금 승인 및 공개

이 작업은 형준하님과 홍수성님이 네이버 AI Lab에서 인턴십을 하면서 진행한 작업입니다. 는

실험에는 NA VER Smart Machine Learning(NSML) 플랫폼[17]이 사용되었습니다. 이

해당 작업은 KAIST-NA VER 하이퍼크리에이티브 AI 센터의 지원을 받았습니다. 이 작업은 부분적으로 지원되었습니다.

정보통신기술진흥원(IITP) 보조금으로

한국정부(과기부) (No.RS-2019-II190075 인공지능대학원과정)

(카이스트)). 이 연구는 한국연구재단(NRF)의 일부 지원을 받았습니다.

한국 정부(MSIT)의 지원을 받는 보조금(No. NRF-2022R1A2B5B02001913).

참고자료

[1] J. T. Barron, B. Mildenhall, M. Tancik, P. Hedman, R. Martin-Brualla 및 P. P. Srinivasan. mip nerf:

앤티앨리어싱 신경 복사 필드에 대한 다중 스케일 표현입니다. IEEE/CVF 절차에서

컴퓨터 비전에 관한 국제 회의, 페이지 5855-5864, 2021.

[2] J. T. Barron, B. Mildenhall, D. Verbin, P. P. Srinivasan 및 P. Hedman. Mip-nerf 360: 무제한

앤티앨리어싱된 신경 방사 필드. 컴퓨터 비전 및 컴퓨터 비전에 관한 IEEE/CVF 회의 진행 중

패턴 인식, 페이지 5470-5479, 2022.

[3] J. T. Barron, B. Mildenhall, D. Verbin, P. P. Srinivasan 및 P. Hedman. Zip-nerf: 앤티앨리어싱 그리드 기반

신경 방사 필드. IEEE/CVF 컴퓨터 비전 국제 컨퍼런스 진행 중,

페이지 19697~19705, 2023.

[4] S. R. Bul , L. Porzi 및 P. Kotschieder. 가우스 스피래팅의 치밀화 수정. arXiv 사전 인쇄

arXiv:2404.06109, 2024.

[5] A. Chen, Z. Xu, A. Geiger, J. Yu 및 H. Su. Tensorf: Tensorial radiance field. 유럽회의에서

컴퓨터 비전, 333~350페이지. 스프링거, 2022년.

[6] H. Chen, C. Li 및 G. H. Lee. Neusg: 3D 가우스 스피래팅을 사용한 신경 암시적 표면 재구성

지도. arXiv 사전 인쇄 arXiv:2312.00846, 2023.

[7] Z. Chen, T. Funkhouser, P. Hedman 및 A. Tagliasacchi. Mobilenerf: 다각형 래스터화 활용

모바일 아키텍처에서 효율적인 신경장 렌더링을 위한 파이프라인입니다. IEEE/CVF 절차에서

컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 16569-16578, 2023.

[8] C. Dudai, M. Alper, H. Bezalet, R. Hanocka, I. Lang 및 H. Averbuch-Elor. Halo-nerf: 학습 기하학-

제약 없는 사진 컬렉션을 탐색하기 위한 안내 의미론. 컴퓨터 그래픽 포럼, 페이지

e15006. 와일리 온라인 도서관, 2024.

[9] S. Fridovich-Keil, A. Yu, M. Tancik, Q. Chen, B. Recht 및 A. Kanazawa. Plenoxels: 래디언스 필드

신경망 없이. 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 진행 중 인식, 페이지 5501-5510, 2022.

[10] A. Gu don 및 V. 레페티. Sugar: 효율적인 3D 메쉬 재구성을 위한 표면 정렬된 가우스 스피래팅 고품질 메시 렌더링. arXiv 사전 인쇄 arXiv:2311.12775, 2023.

[11] P. 헤드먼, J. 필립, T. 프라이스, J.-M. 프람, G. Drettakis, G. Brostow. 자유로운 시점을 위한 딥 블렌딩 이미지 기반 렌더링. ACM 그래픽 트랜잭션(ToG), 37(6):1-15, 2018.

[12] P. Hedman, P. P. Srinivasan, B. Mildenhall, J. T. Barron 및 P. Debevec. 다음을 위한 신경 방사 필드 베이킹 실시간 뷰 합성. IEEE/CVF 컴퓨터 비전 국제 컨퍼런스 진행 중, 페이지 5875-5884, 2021.

[13] B. Huang, Z. Yu, A. Chen, A. Geiger 및 S. Gao. 기하학적으로 정확한 광도를 위한 2D 가우스 스피래팅 필드. arXiv 사전 인쇄 arXiv:2403.17888, 2024.

[14] R. Jensen, A. Dahl, G. Vogiatzis, E. Tola 및 H. Aanæs. 대규모 다시점 입체시 평가. 에서 컴퓨터 비전 및 패턴 인식에 관한 IEEE 회의 간행물, 페이지 406-413, 2014.

[15] 와이. 지양(Jiang), J. 투(J.Tu), Y. Liu, X. Gao, X. Long, W. Wang 및 Y. 엄마. Gaussianshader: 3D 가우스 스피래팅 반사 표면에 대한 음영 처리 기능. arXiv 사전 인쇄 arXiv:2311.17977, 2023.

[16] B. Kerbl, G. Kopanas, T. Leimk hler 및 G. Drettakis. 실시간 래디언스 필드를 위한 3D 가우스 스피래팅 렌더링. 그래픽에 대한 ACM 거래, 42(4):1-14, 2023.

10

--- 페이지 11 ---

[17] 김H., 김M, D. Seo, J. 김, H. 박, S. 박, H. 조, K. 김, Y. 양, Y. 김 외. NsmI: 만나보세요 실제 사례 연구를 포함하는 Mlaas 플랫폼입니다. arXiv 사전 인쇄 arXiv:1810.09957, 2018.

[18] Z. Li, T. M ller, A. Evans, R. H. Taylor, M. Unberath, M.-Y. Liu, 그리고 C.-H. 린. 신경란젤로: 높음 충실도 신경 표면 재구성. 컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스 진행 중 및 패턴 인식, 페이지 8456-8465, 2023.

[19] R. Martin-Brualla, N. Radwan, M. S. Sajjadi, J. T. Barron, A. Dosovitskiy 및 D. Duckworth. 너프 인 야생: 제약 없는 사진 컬렉션을 위한 신경 복사 필드. IEEE/CVF 절차에서 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 7210-7219, 2021.

[20] B. Mildenhall, P. P. Srinivasan, M. Tancik, J. T. Barron, R. Ramamoorthi 및 R. Ng. 너프: 대표 장면을 뷰 합성을 위한 신경 방사 필드로 사용합니다. ACM 커뮤니케이션, 65(1):99-106, 2021.

[21] T. M ller, A. Evans, C. Schied 및 A. Keller. 다중 해상도를 갖춘 즉각적인 신경 그래픽 프리미티브 해시 인코딩. 그래픽에 대한 ACM 트랜잭션(TOG), 41(4):1-15, 2022.

[22] M. Oechsle, S. Peng 및 A. Geiger. Unisurf: 신경 내재적 표면과 복사장 통합 멀티뷰 재구성. IEEE/CVF 컴퓨터 비전 국제 컨퍼런스 진행 중, 페이지 5589~5599, 2021.

[23] C. Reiser, S. Garbin, P. P. Srinivasan, D. Verbin, R. Szeliski, B. Mildenhall, J. T. Barron, P. Hedman 및 A. 가이거. 바이너리 불투명 그리드: 메쉬 기반 뷰 합성을 위한 미세한 기하학적 세부 사항을 캡처합니다. arXiv 사전 인쇄 arXiv:2402.12377, 2024.

[24] C. Reiser, R. Szeliski, D. Verbin, P. Srinivasan, B. Mildenhall, A. Geiger, J. Barron 및 P. Hedman. 머프: 무한한 장면에서 실시간 보기 합성을 위한 메모리 효율적인 복사 필드입니다. ACM 거래 그래픽(TOG), 42(4):1-12, 2023.

[25] O. Roy 및 M. Vetterli. 유효 순위: 유효 차원의 척도입니다. 2007년 15번째 유럽 신호 처리 컨퍼런스, 606~610페이지. IEEE, 2007.

[26] J. L. Sch nberger 및 J.-M. 프람. 모션에서 구조를 재검토했습니다. 컴퓨터 비전 컨퍼런스에서 및 패턴 인식(CVPR), 2016.

[27] J. L. Sch nberger, E. Zheng, M. Pollefeys 및 J.-M. 프람. 구조화되지 않은 픽셀별 보기 선택

멀티뷰 스테레오. 2016년 유럽 컴퓨터 비전 회의(ECCV)에서.

[28] 와이. 시, Y. Wu, C. Wu, X. Liu, C. Zhao, H. Feng, J. Liu, L. Zhang, J. Zhang, B. Zhou 등 Gir: 3d 가우스 재조명 가능한 장면 분해를 위한 역 렌더링. arXiv 사전 인쇄 arXiv:2312.05133, 2023.

[29] J. Sun, X. Chen, Q. Wang, Z. Li, H. Averbuch-Elor, X. Zhou 및 N. Snavely. 신경 3D 재구성 야생. ACM SIGGRAPH 2022 컨퍼런스 회의록, 2022년 1~9페이지.

[30] P. Wang, L. Liu, Y. Liu, C. Theobalt, T. Komura 및 W. Wang. Neus: 신경 암시적 표면 학습 다중 뷰 재구성을 위한 볼륨 렌더링. arXiv 사전 인쇄 arXiv:2106.10689, 2021.

[31] 와이. Wang, Q. Han, M. Habermann, K. Daniilidis, C. Theobalt 및 L. Liu. Neus2: 신경의 빠른 학습 다중 뷰 재구성을 위한 암시적 표면. IEEE/CVF 국제 컨퍼런스 진행 중 컴퓨터 비전, 3295~3306페이지, 2023년.

[32] Z. Wang, T. Shen, M. Nimier-David, N. Sharp, J. Gao, A. Keller, S. Fidler, T. Müller 및 Z. Gojcic. 효율적인 신경 방사 필드 렌더링을 위한 적응형 쉐입니다. arXiv 사전 인쇄 arXiv:2311.10091, 2023.

[33] L. Yariv, J. Gu, Y. 카스텐, 그리고 Y. 리프먼. 신경 암시적 표면의 볼륨 렌더링. 신경 정보 처리 시스템, 34:4805-4815, 2021.

[34] L. Yariv, P. Hedman, C. Reiser, D. Verbin, P. P. Srinivasan, R. Szeliski, J. T. Barron 및 B. Mildenhall. Baked sdf: 실시간 뷰 합성을 위한 신경 sdf 메싱. ACM SIGGRAPH 2023 컨퍼런스에서 절차, 2023년 1~9페이지.

[35] Z. Yu, A. Chen, B. Huang, T. Sattler 및 A. Geiger. 밍 스플래팅(Mip-splatting): 앨리어싱이 없는 3D 가우스 스플래팅. arXiv 사전 인쇄 arXiv:2311.16493, 2023.

[36] Z. Yu, T. Sattler 및 A. Geiger. 가우스 불투명 필드: 효율적이고 컴팩트한 표면 재구성 무한한 장면. arXiv 사전 인쇄 arXiv:2404.10772, 2024.

[37] K. Zhang, G. Riegler, N. Snavely 및 V. 콜튼. Nerf++: 신경 복사장 분석 및 개선. arXiv 사전 인쇄 arXiv:2010.07492, 2020.

[38] Q.-Y. Zhou, J. Park, V. 콜튼. Open3d: 3D 데이터 처리를 위한 최신 라이브러리입니다. arXiv 사전 인쇄 arXiv:1801.09847, 2018.

[39] M. Zwicker, H. Pfister, J. Van Baar 및 M. Gross. Ewa 볼륨 스플래팅. In Proceedings 시각화, 2001. VIS'01., 29~538페이지. IEEE, 2001.

11

--- 페이지 12 ---

A 부록/보충 자료

A.1 광범위한 영향

3D 재구성에 대한 우리 작업의 광범위한 영향은 다양한 분야를 발전시킬 수 있는 잠재력에 있습니다.

가상 및 증강 현실, 의료 영상, 디지털 콘텐츠 제작 등

효율적이고 고품질의 3D 모델 생성. 그러나 다른 첨단 기술과 마찬가지로

잠재적인 위험과 오용 가능성을 제시합니다. 예를 들어, 향상된 3D 재구성 기술

독점 디자인을 디페이크하거나 무단 복제하는 데 악용될 수 있습니다.

윤리적, 법적 문제. 이러한 위험을 완화하기 위해 엄격한 사용 지침을 구현할 것을 제안합니다.

3D 모델의 무결성과 정당한 사용을 보장합니다. 우리는 긍정적인 영향을 극대화하는 것을 목표로 합니다.

잠재적인 부정적인 결과를 최소화하면서 연구를 수행합니다.

A.2 추가 정규화

법선 렌더링을 위해 깊이 왜곡 손실[13]과 같은 다른 정규화 용어를 추가합니다.

[13, 36]에서 제안된 대로 일반적인 정규화. (우리는 이러한 정규화 용어를 다음 용도로 활용하지 않습니다.

Tab의 추가 모듈로 효과적인 순위 정규화를 평가합니다. 1.) 깊이 왜곡 손실,

표면에 스플랫을 집중시키고 플로터 아티팩트를 완화하는 것은 다음과 같이 주어진다.

$L_d = d$

$\times$

나, j

$i \cdot |z_i - z_j|, (11)$

여기서 $i = 1 \dots K$ 이고 z_i 는 가중치의 깊이입니다.

혼합 가중치의 경우 $k=1(1 \dots K)$ 이고 z_i 는 가중치의 깊이입니다.

i -번째 가우스의 교차점, 그리고 i, j 는 특징에 기여하는 가우스에 대한 인덱스입니다.

레이.

노멀 정규화는 스피클렛의 렌더링된 노멀 맵 n 간의 차이를 최소화합니다.

렌더링된 깊이 맵에서 파생된 그래디언트 법선 n

$L_n = |n| - |n|, (12)$

3D 가우시안을 실제 표면과 로컬로 정렬합니다. 효과적인 순위 정규화 이후

장면의 로컬 및 글로벌 구조를 설명하지 않으므로 우리 방법을 결합하는 것이 좋습니다.

이러한 구조 인식 정규화를 사용합니다.

A.3 메쉬 추출

메쉬 추출을 위해 TSDF(Truncate Signed Distance Function) 융합을 활용합니다. 알고리즘
복셀 그리드의 임의의 지점에서 가장 가까운 표면까지의 거리를 인코딩합니다. 거리는 다음과 같습니다.

멀리 있는 지점의 영향을 제한하기 위해 최대값으로 잘렸습니다. 거리 함수의 부호

tion은 점이 개체 내부(음수)인지 외부(양수)인지 여부를 나타냅니다. 다중 TSDF

다양한 관점에서 결합하여 보다 정확하고 완전한 3D 재구성을 생성합니다.

일관되고 포괄적인 3D 모델을 형성합니다. 그런 다음 Marching Cubes 알고리즘이 사용됩니다.

삼각 측량.

A.4 ADC 수정

우리는 [4, 36]에 제시된 치밀화 알고리즘의 수정된 버전을 채택합니다.

Eq.의 합산 노름 대신 노름 합산을 기반으로 한 가우스. 3:

$\times$

나 $\in P$

∂L

$\partial \text{파이}$

$\partial \text{파이}$

$\partial \text{너}$

2

> . (13)

주요 논문에서 논의한 것처럼 이 접근 방식은 디스크와 유사하기 때문에 정규화에 매우 중요합니다.

가우시안은 일반적으로 더 많은 화면 공간을 차지하고 다양한 픽셀로부터 기울기 신호를 수신합니다.

합산되면 취소될 수 있습니다. 수정된 알고리즘은 다음과 같은 가우시안의 효과적인 분할을 보장합니다.

우리의 정규화. 그러나 표면 재구성에서 디스크형 가우시안의 효율성으로 인해

우리의 방법은 기준선에 비해 약 10% 더 적은 가우스를 필요로 합니다[16].

12

--- 페이지 13 ---

표 3: Mip-NeRF 360 [2] 데이터세트의 정량적 결과.

실외 장면 실내 장면

PSNR ↑ SSIM ↑ LPIPS ↓ PSNR ↑ SSIM ↑ LPIPS ↓

모바일-NeRF [7] 21.95 0.470 0.470 - - -

구운SDF [34] 22.47 0.585 0.349 27.06 0.836 0.258
 BOG [23] 23.94 0.680 0.263 27.71 0.873 0.227
 NeRF [20] 21.46 0.458 0.515 26.84 0.790 0.370
 딥 블렌딩 [11] 21.54 0.524 0.364 26.40 0.844 0.261
 인스턴트 NGP [21] 22.90 0.566 0.371 29.15 0.880 0.216
 MERF [24] 23.19 0.616 0.343 27.80 0.855 0.271
 MipNeRF360 [2] 24.47 0.691 0.283 31.72 0.917 0.180
 3DGS [16] 24.64 0.731 0.234 31.13 0.920 0.189
 3DGS+e (당사) 24.93 0.757 0.221 31.16 0.953 0.181

표 4: 모따기 거리, PSNR 및 최적화 시간과 함께 우리 방법의 스토리지 사용량.

데이터 세트 방법 CD ↓ PSNR ↑ 시간 ↓ MB(스토리지) ↓

DTU 3DGS 1.96 32.82 11.2m 113

3DGS+e 1.03 33.09 11.1m 98

Mip-NeRF360 3DGS - 27.52 41m 734

3DGS+e - 27.70 40m 646

A.5 추가적인 정량적 결과

우리는 표 3의 Mip-NeRF360 데이터 세트에 대한 새로운 뷰 합성 결과를 보고합니다. 결과는 다음과 같습니다.

우리의 추가 정규화 용어는 PSNR, SSIM 측면에서 3DGS의 시각적 품질을 향상시킵니다.

그리고 LPIPS. 또한 이 방법은 기존 방법과 비슷하거나 약간 더 나은 성능을 보여줍니다.

느리고 계산 집약적인 렌더링을 갖춘 NeRF 변형입니다.

우리는 표 4에 우리 방법의 훈련 시간을 보고합니다. DTU에서 3DGS에 대한 훈련 시간 [14]

데이터 세트는 장면당 평균 11.2분입니다. 밀도를 높여 효과적인 순위 정규화를 추가합니다.

추가 계산이 감소된 숫자로 보상되므로 수정 시 오버헤드가 발생하지 않습니다.

가우스의 총 훈련 시간은 DTU 데이터 세트의 경우 평균 11.1분, DTU 데이터 세트의 경우 평균 40분입니다.

단일 V100 GPU의 Mip-NeRF360 데이터 세트는 표 4에 보고되어 있습니다.

또한 가우시안 수를 줄이면 장면에 필요한 메모리와 저장 공간이 줄어듭니다.

우리의 방법은 더 간결하지만 측면에서 기존선보다 성능이 뛰어납니다.

모따기 거리와 PSNR.

표 5는 훈련 과정 중 모따기 거리와 PSNR 변화를 보여줍니다.

그림 2에 표시된 기준선. DTU 데이터 세트의 장면 37에 대한 결과가 보고됩니다. 바늘 모양

가우스는 증가하지만 성능이 정체되어 과적합을 나타냅니다. 추가적으로, 다른

유사한 측정항목을 갖는 가우스 구조는 3DGS 및 가우시안의 이질적인 특성을 암시합니다.

그 변형. 또한 보고된 "바늘 수"는 유효 순위가 있는 가우스에 해당합니다.

1.04보다 작습니다. 결과는 우리의 정규화 용어가 숫자를 효과적으로 최소화한다는 것을 시사합니다.

시각적 품질 저하 없이 바늘을 제작할 수 있습니다.

표 6의 DTU 데이터 세트에 장면당 PSNR을 표시합니다. 평균 PSNR은 이미 표시되어 있습니다.

본문의 표 1과 표 2.

A.6 바늘 모양의 가우시안의 원인

우리의 방법론과 직접적인 관련은 없지만, 우리는 수렴에 대한 몇 가지 이유를 조사합니다.

3D 가우스를 하나의 주요 분산을 갖는 이방성 가우스로 변환합니다.

첫째, 확장 연산으로 인해 3D 가우시안의 크기가 제대로 제한되지 않습니다.

Mip에 명시된 대로 최소 크기를 보장하기 위해 화면 공간 Gaussians [16]에 작은 상수를 추가합니다.

13

--- 페이지 14 ---

표 5: 표시된 기준선에 대한 훈련 과정 중 모따기 거리 및 PSNR 변경

DTU 데이터 세트의 장면 37에 대한 그림 2. 바늘 모양의 가우시안은 증가하지만 성능은 정체되고,

과적합을 나타냅니다. 또한 유사한 측정항목을 가진 다양한 가우스 구조가 제안됩니다.

3DGS 및 그 변형에서 가우시안의 이질적인 특성. "바늘 수"를 보고했습니다.

유효 순위가 1.04보다 작은 가우스에 해당합니다.

CD↓ PSNR↑

방법 15k 30k 15k 30k

3DGS 1.5 1.53 27.00 26.98

슈가 1.21 1.23 23.64 23.52

2DGS 0.89 0.88 24.89 24.87

바늘 수 PSNR ↑

0천 15천 30천 30천

3DGS 0 3170 16320 26.93

3DGS+e 0 28 23 27.21

표 6: 각 장면에 대한 PSNR을 보고하는 DTU 데이터 세트의 추가 제거. (a): 고정 치밀화(ADC) 알고리즘, (b): Erank 정규화.

방법 24 37 40 55 63 65 69 83

3DGS 30.45 26.93 29.79 31.92 35.42 31.09 28.34 38.00

+a 30.69 27.14 30.31 32.01 35.93 31.23 28.04 37.95

+a+b 30.90 27.21 30.42 32.23 35.81 31.62 28.41 38.00

방법 97 105 106 110 114 118 122 평균

3DGS 30.20 34.32 35.00 34.65 30.86 37.25 38.07 32.82

+a 30.25 34.30 35.11 34.59 31.10 37.65 38.21 32.97

+a+b 30.27 34.41 35.22 34.69 31.20 37.69 38.23 33.09

스플래팅 [35]. 3DGS의 고유한 암시적 수축 편향과 결합[16, 35]

최적화 프로세스 중 척도 매개변수의 과소평가.

둘째, 긴 축을 따른 치밀화는 긴 축이 있기 때문에 효과적으로 발생하지 않습니다.

분산이 큰 축은 기울기가 더 작습니다. 가우시안이 다음 방향으로 움직일 때

축이 짧을수록 픽셀 값이 갑자기 변경됩니다. 대조적으로, 픽셀 값에는 작은 변화만 있습니다.

더 긴 축을 따라 이동할 때. 구체적으로 σ_{π} 일 때

σ_u 는 가장 긴 방향으로 정렬됩니다.

축에서는 그라데이션 값이 일반적으로 작습니다. 결과적으로 최종 그라디언트의 표준은 종종 떨어지게 됩니다.

치밀화 임계값보다 낮음 ought σ_L

$\sigma_x \ll \sigma_u$, 효과적인 치밀화를 방해합니다. σ_G 를 시각화합니다

σ_x

σ_{π} 에 비례하는 그림 8 (a)의 화살표

σ_u , 더 나은 이해를 위해. 그러므로 스플랫은

더 긴 부분을 따라 분할하기보다는 스케일 매개변수를 조정하는 쪽으로 편향됩니다(그림 8(b)).

바늘 모양의 가우시안으로 수렴됩니다.

셋째, 스케일 매개변수는 분할 후에도 동일하게 유지되므로 치밀화 후에도 바늘이 짧아지지 않습니다.

tion.

이러한 이유를 더 깊이 파고들어 문제를 해결하는 것은 흥미로운 향후 작업이 될 것입니다.

다른 접근법.

A.7 추가적인 정성적 결과

우리는 방법 결과의 일반적인 렌더링을 제시합니다. 그림 9는 장면 122의 결과입니다.

깊이 왜곡과 일반 정규화 손실을 함께 사용합니다. 그림 10은 장면의 결과를 보여줍니다.

55. 그림 11은 우리 방법의 Mip-NeRF360 데이터 세트의 렌더링 결과를 보여줍니다. 우리는 시각화한다 빨간색으로 표시된 유효 순위가 1.02보다 작은 가우시안입니다. 효과적인 순위 정규화는 다음과 같습니다.

현장에 적응하여 바늘 모양의 가우시안 수를 줄이면서 효과적으로 표현합니다.
필요한 지역.

14

--- 페이지 15 ---

(가) (비)

(x)(o)

그림 8: (a): σ_{Gk} 시각화

σ_x 는 화살표로 표시되며 σ_{pi} 에 비례합니다.

σ_{ni} . (b) 스플랫은 편향되어 있다

더 긴 축을 따라 분할하는 대신 축척 매개변수를 조정하는 방향으로 수렴됩니다.

바늘 모양의 가우시안.

그림 9: 심도 왜곡이 포함된 DTU 데이터 세트(장면 122)의 일반 렌더링 결과

그리고 정상적인 정규화 손실.

15

--- 페이지 16 ---

그림 10: 우리 방법의 DTU 데이터 세트(장면 55)의 일반 렌더링 및 시각적 렌더링 결과,
깊이 왜곡과 일반 정규화 손실이 있습니다.

16

--- 페이지 17 ---

그림 11: 우리 방법의 Mip-NeRF360 데이터세트 렌더링 결과. 우리는 가우스를 시각화합니다.

1.02보다 작은 유효 순위는 빨간색입니다. 효과적인 순위 정규화는 현장에 적응하며,

바늘 모양의 가우시안 수를 줄이는 동시에 필요한 영역을 효과적으로 표현합니다.

17

--- 페이지 18 ---

NeurIPS 종이 체크리스트

1. 청구

질문: 초록과 서문의 주요 주장이 내용을 정확하게 반영하고 있습니까?

논문의 기여와 범위는 무엇입니까?

답: [예]

정당성: 초록과 서문에는 논문의 주요 주장과 전반적인 설명이 있습니다.

포함됩니다.

지침:

- NA라는 대답은 초록과 서문에 청구범위가 포함되지 않음을 의미합니다.

종이로 만들었습니다.

- 초록 및/또는 서문에는 주장을 명확하게 명시해야 합니다.

논문의 기여와 중요한 가정 및 제한 사항. A 아니오 또는

이 질문에 대한 NA 답변은 리뷰어가 잘 인식하지 못할 것입니다.

- 주장은 이론 및 실험 결과와 일치해야 하며,

결과가 다른 설정으로 일반화될 것으로 예상할 수 있습니다.

- 열망하는 목표를 동기로 포함하는 것은 괜찮습니다.

종이로는 얻을 수 없습니다.

2. 제한사항

질문: 논문에서 저자가 수행한 작업의 한계를 논의합니까?

답: [예]

정당화: 한계와 논의를 포함합니다.

지침:

- NA라고 대답하면 논문에 제한이 없다는 뜻이고, 아니요라고 대답하면 다음과 같다는 의미입니다.

논문에는 한계가 있지만 논문에서는 이에 대해 논의하지 않습니다.

- 저자는 논문에 별도의 "제한 사항" 섹션을 만드는 것이 좋습니다.
- 논문에서는 강력한 가정과 결과가 얼마나 견고한지 지적해야 합니다.

이러한 가정 위반(예: 독립 가정, 소음 없는 설정, 모델 우물 사양, 국소적으로만 유지되는 점근적 근사). 저자 이러한 가정이 실제로 어떻게 위반될 수 있는지, 그리고 의미는 있을 것입니다.

- 저자는 주장의 범위를 숙고해야 합니다(예: 접근 방식이 다음과 같은 경우).

몇 가지 데이터 세트 또는 몇 번의 실행으로만 테스트되었습니다. 일반적으로 경험적 결과는 종종 명시되어야 하는 암묵적인 가정에 의존합니다.

- 저자는 접근 방식의 성능에 영향을 미치는 요소를 숙고해야 합니다.

예를 들어 얼굴 인식 알고리즘은 이미지 해상도가 낮을 때 성능이 저하될 수 있습니다.

밝기가 낮거나 조명이 어두운 곳에서 이미지가 촬영됩니다. 아니면 음성-텍스트 시스템이 그렇지 않을 수도 있습니다. 처리하지 못하기 때문에 온라인 강의에 자막을 제공하기 위해 안정적으로 사용됩니다.

기술 전문 용어.

- 저자는 제안된 알고리즘의 계산 효율성에 대해 논의해야 합니다.

데이터세트 크기에 따라 확장되는 방식도 설명합니다.

- 해당되는 경우 저자는 접근 방식의 한계에 대해 논의해야 합니다.

개인 정보 보호 및 공정성 문제를 해결합니다.

- 저자는 제한 사항에 대해 완전한 정직성이 악용될 수 있다는 점을 두려워할 수 있습니다.

리뷰어가 거절 사유로 삼을 경우, 리뷰어가 발견하는 더 나쁜 결과가 나올 수도 있습니다.

논문에서 인정되지 않는 한계. 작성자는 최선을 다해야 합니다.

투명성을 위한 개별 행동이 중요하다는 점을 판단하고 인식합니다.

지역사회의 온전함을 보존하는 규범을 개발하는 데 중요한 역할을 합니다. 리뷰어

제한 사항과 관련하여 정직성을 처벌하지 않도록 특별히 지시받을 것입니다.

3. 이론의 가정과 증명

질문: 각 이론적 결과에 대해 논문은 전체 가정 세트를 제공하고 있습니까?

완전한 (그리고 정확한) 증거?

답변: [NA]

18

--- 페이지 19 ---

근거:

지침:

- NA라는 대답은 논문에 이론적 결과가 포함되어 있지 않음을 의미합니다.
- 논문의 모든 정리, 공식 및 증명은 번호를 매기고 교차되어야 합니다.

참조됨.

- 모든 가정은 정리 설명에서 명확하게 기술되거나 참조되어야 합니다.
- 교정쇄는 주요 논문이나 보충 자료에 나타날 수 있지만,

보충 자료에 나타나는 경우, 저자는 짧은 내용을 제공하도록 권장됩니다.

직관을 제공하는 증거 스케치.

- 반대로, 논문의 핵심에 제공된 비공식적 증거는 보완되어야 합니다.

부록이나 보충 자료에 제공된 공식 증명을 통해.

- 증명의 기초가 되는 정리와 정리를 적절하게 참조해야 합니다.

4. 실험 결과 재현성

질문: 논문은 주요 전작을 재현하는 데 필요한 모든 정보를 완전히 공개합니까?

주요 주장 및/또는 결론에 영향을 미치는 정도까지 논문의 실험 결과

(코드와 데이터 제공 여부에 관계없이)

답: [예]

이유: 우리는 하이퍼파라미터와 코드 베이스를 포함한 정보를 완전히 공개합니다.

지침:

- NA라는 대답은 해당 논문에 실험이 포함되어 있지 않음을 의미합니다.
- 논문에 실험이 포함된 경우 이 질문에 대한 '아니오'라는 대답은 인식되지 않습니다.

리뷰어의 의견: 논문을 재현 가능하게 만드는 것이 중요합니다.

코드와 데이터가 제공되는지 여부.

- 기여가 데이터셋 및/또는 모델인 경우 작성자는 취한 단계를 설명해야 합니다.

결과를 재현 가능하거나 검증 가능하게 만듭니다.

- 기여도에 따라 다양한 방법으로 재현성을 달성할 수 있습니다.

예를 들어 기여가 새로운 아키텍처인 경우 아키텍처를 완전히 설명합니다.

충분할 수도 있고, 기여가 특정 모델 및 경험적 평가인 경우에는

다른 사람들이 동일한 모델을 복제할 수 있도록 해야 합니다.

데이터 세트를 제공하거나 모델에 대한 액세스를 제공합니다. 일반적으로 코드와 데이터를 공개하는 경우가 많습니다.

이를 달성하는 좋은 방법 중 하나이지만 세부적인 방법을 통해 재현성을 제공할 수도 있습니다.

결과를 복제하는 방법에 대한 지침, 호스팅 모델에 대한 액세스(예:

대규모 언어 모델), 모델 체크포인트 릴리스 또는 기타 다음과 같은 수단을 사용합니다.

수행된 연구에 적합합니다.

- NeurIPS는 코드 공개를 요구하지 않지만 컨퍼런스에서는 모든 제출이 필요합니다.

재현성을 위한 합리적인 방법을 제공하는 것이 좋습니다.

기여의 성격. 예를 들어

(a) 기여가 주로 새로운 알고리즘인 경우, 논문에서는 어떻게 기여하는지 명확히 해야 합니다.

해당 알고리즘을 재현합니다.

(b) 기여가 주로 새로운 모델 아키텍처인 경우 논문에서는 다음을 설명해야 합니다.

아키텍처를 명확하고 완전하게 만듭니다.

(c) 기여가 새로운 모델(예: 대규모 언어 모델)인 경우 다음이 있어야 합니다.

결과를 재현하기 위해 이 모델에 액세스하는 방법이거나 재현하는 방법이 될 수 있습니다.

모델(예: 오픈 소스 데이터 세트 또는 구성 방법에 대한 지침 포함)

데이터 세트).

(d) 우리는 어떤 경우에는 재현성이 까다로울 수 있다는 것을 알고 있습니다.

저자는 재현성을 제공하는 특정 방법을 설명하는 것을 환영합니다.

비공개 소스 모델의 경우 모델에 대한 액세스가 제한될 수 있습니다.

어떤 방식으로든(예: 등록된 사용자에게), 다른 연구자에게는 가능해야 합니다.

결과를 재현하거나 확인할 수 있는 경로를 갖습니다.

5. 데이터 및 코드에 대한 개방형 액세스

질문: 논문이 충분한 지침을 통해 데이터와 코드에 대한 공개 접근을 제공합니까?

보충 설명에 설명된 대로 주요 실험 결과를 충실하게 재현하기 위한

자료?

19

--- 페이지 20 ---

답: [예]

이유: 우리는 코드를 공개하고 데이터를 공개적으로 사용할 수 있습니다.

지침:

- NA라는 대답은 논문에 코드가 필요한 실험이 포함되어 있지 않음을 의미합니다.
- NeurIPS 코드 및 데이터 제출 지침(<https://nips.cc/>)을 참조하십시오.

자세한 내용은 [public/guides/CodeSubmissionPolicy](https://nips.cc/public/guides/CodeSubmissionPolicy)를 참조하세요.

- 우리는 코드와 데이터의 공개를 장려하지만 이것이 그렇지 않을 수도 있다는 점을 이해합니다.

가능하므로 "아니오"가 허용되는 대답입니다. 단순히 그렇지 않다는 이유로 논문을 거부할 수는 없습니다.

기여에 핵심이 아닌 한 코드 포함(예: 새로운 오픈 소스의 경우)

벤치마크).

- 지침에는 실행하는 데 필요한 정확한 명령과 환경이 포함되어야 합니다.

결과를 재현합니다. NeurIPS 코드 및 데이터 제출 지침(<https://nips.cc/public/guides/CodeSubmissionPolicy>)

자세한 내용을 확인하세요.

- 저자는 데이터 액세스 및 준비에 대한 지침을 제공해야 합니다.

원시 데이터, 전처리된 데이터, 중간 데이터, 생성된 데이터 등에 액세스합니다.

- 저자는 새로운 연구에 대한 모든 실험 결과를 재현하기 위한 스크립트를 제공해야 합니다.

제안된 방법 및 기준선. 실험의 하위 집합만 재현 가능한 경우

스크립트에서 생략된 항목과 그 이유를 명시해야 합니다.

- 제출 시 익명성을 유지하기 위해 저자는 익명화된 내용을 공개해야 합니다.

버전(해당하는 경우).

- 보충 자료에 최대한 많은 정보를 제공합니다(첨부

paper)이 권장되지만 데이터 및 코드에 대한 URL을 포함하는 것은 허용됩니다.

6. 실험 설정/세부 사항

질문: 논문에 모든 훈련 및 테스트 세부 사항(예: 데이터 분할, 하이퍼-프로세스)이 명시되어 있습니까?

매개변수, 선택 방법, 최적화 유형 등)을 이해하는 데 필요합니다.

결과는?

답: [예]

이유: 예, 필요한 모든 세부 정보를 제공합니다.

지침:

- NA라는 대답은 해당 논문에 실험이 포함되어 있지 않음을 의미합니다.
- 실험 설정은 논문의 핵심 부분에 자세하게 제시되어야 합니다.

이는 결과를 평가하고 이해하는 데 필요합니다.

- 전체 세부정보는 코드, 부록 또는 보충 자료로 제공될 수 있습니다.

자료.

7. 실험의 통계적 의의

질문: 종이 보고 오류 막대가 적절하고 올바르게 정의되었거나 기타 적절합니까?

실험의 통계적 중요성에 대한 정보는 무엇입니까?

답: [예]

근거: 결과의 평균 및 표준편차를 제공합니다.

지침:

- NA라는 대답은 해당 논문에 실험이 포함되어 있지 않음을 의미합니다.
- 결과에 오류 막대가 나타나면 저자는 "예"라고 대답해야 합니다.

적어도 뒷받침하는 실험에 대해서는 밀도 간격 또는 통계적 유의성 테스트를 수행합니다.

논문의 주요 주장.

- 오차 막대가 포착하는 가변성 요인이 명확하게 명시되어야 합니다(예:

예를 들어 학습/테스트 분할, 초기화, 일부 매개변수의 무작위 그리기 또는 전체

주어진 실험 조건으로 실행).

- 오차 막대를 계산하는 방법을 설명해야 합니다(단한 형식 공식, 라이브리리 함수 호출, 부트스트랩 등)
- 가정이 제시되어야 합니다(예: 정규 분포 오류).
- 오차 막대가 표준편차인지 표준오차인지 명확해야 합니다.

평균의.

20

--- 페이지 21 ---

- 1-시그마 오류 막대를 보고하는 것은 괜찮지만 이를 명시해야 합니다. 저자는 다음과 같이 해야 합니다. 가설이 다음과 같은 경우 CI가 96%라고 명시하는 것보다 2시그마 오차 막대를 보고하는 것이 좋습니다. 오류의 정규성은 검증되지 않습니다.
- 비대칭 분포의 경우 저자는 표나 표에 표시하지 않도록 주의해야 합니다. 범위를 벗어난 결과를 산출하는 대칭 오차 막대를 나타냅니다(예: 음수 오류율).
- 오류 막대가 표나 도표로 보고되는 경우 저자는 텍스트에서 어떻게 오류가 발생하는지 설명해야 합니다. 그것들은 계산되었으며 본문의 해당 그림이나 표를 참조했습니다.

8. 컴퓨팅 리소스 실험

질문: 각 실험에 대해 논문은 해당 연구에 대한 충분한 정보를 제공합니까?

재현에 필요한 퓨터 리소스(컴퓨팅 작업자 유형, 메모리, 실행 시간)

실험?

답: [예]

근거: GPU와 훈련에 소요되는 시간을 지정합니다.

추억영상.

지침:

- NA라는 대답은 해당 논문에 실험이 포함되어 있지 않음을 의미합니다.
- 문서에는 컴퓨팅 작업자의 유형인 CPU 또는 GPU, 내부 클러스터, 또는 관련 메모리 및 스토리지를 포함한 클라우드 제공업체.
- 논문은 각 개인에게 필요한 컴퓨팅 양을 제공해야 합니다.

실험을 실행하고 총 계산을 추정합니다.

- 논문에서는 전체 연구 프로젝트에 더 많은 컴퓨팅이 필요한지 여부를 공개해야 합니다.

논문에 보고된 실험(예: 예비 또는 실패한 실험)보다

신문에는 나오지 않았습니다.)

9. 윤리강령

질문: 논문에서 수행된 연구는 모든 측면에서 다음과 일치합니까?

NeurIPS 윤리강령 <https://neurips.cc/public/EthicsGuidelines>?

답: [예]

정당성: 네, 저희 논문은 NeurIPS 윤리 강령을 준수합니다.

지침:

- NA라는 대답은 저자가 NeurIPS 윤리 강령을 검토하지 않았음을 의미합니다.
- 저자가 '아니요'라고 답한 경우에는 저자가 필요한 특별한 상황을 설명해야 합니다. 윤리 강령에서 벗어났습니다.
- 저자는 익명성을 유지해야 합니다(예: 특별한 고려사항이 있는 경우).

해당 관할권의 법률이나 규정으로 인해 발생합니다).

10. 더 넓은 영향

질문: 이 논문은 잠재적인 긍정적인 사회적 영향과 부정적인 영향을 모두 논의합니까?

수행된 작업이 사회적으로 미치는 영향은 무엇입니까?

답: [예]

정당성: 부록에서 사회적 영향에 대해 논의합니다.

지침:

- NA라는 대답은 수행된 작업이 사회적 영향을 미치지 않는다는 것을 의미합니다.
- 저자가 NA 또는 No라고 답한 경우, 자신의 저작물에 사회적 영향이 없는 이유를 설명해야 합니다.

영향 또는 논문이 사회적 영향을 다루지 않는 이유.

- 부정적인 사회적 영향의 예로는 잠재적인 악의적이거나 의도하지 않은 사용이 있습니다.

(예: 허위 정보, 가짜 프로필 생성, 감시), 공정성 고려

(예: 특정 사안에 불공정한 영향을 미치는 결정을 내릴 수 있는 기술 배포 그룹), 개인 정보 보호 고려 사항, 보안 고려 사항 등이 있습니다.

21

--- 페이지 22 ---

- 컨퍼런스에서는 많은 논문이 기초 연구일 뿐 묵이지 않을 것으로 예상합니다.

배포는 물론이고 특정 애플리케이션에도 적용됩니다. 그러나 직접 경로가 있는 경우

부정적인 적용이 있으면 저자는 이를 지적해야 합니다. 예를 들어 합법적인 생성 모델의 품질 향상이 다음과 같은 용도로 사용될 수 있음을 지적합니다.

허위 정보를 위한 딥페이크를 생성합니다. 한편, 굳이 지적할 필요는 없다.

신경망을 최적화하기 위한 일반 알고리즘을 사용하면 사람들이 훈련할 수 있다는 것입니다.

Deepfake를 더 빠르게 생성하는 모델.

- 저자는 기술이 다음과 같은 경우 발생할 수 있는 피해를 고려해야 합니다.

의도한 대로 사용하고 올바르게 작동하는 경우 발생할 수 있는 피해

기술이 의도한 대로 사용되고 있지만 잘못된 결과를 낳고 그에 따른 피해를 초래하는 경우

(의도적이든 비의도적이든) 기술의 오용으로 인해 발생합니다.

- 부정적인 사회적 영향이 있는 경우 저자는 가능한 완화 방법에 대해서도 논의할 수 있습니다.

전략(예: 모델의 제한적 출시, 공격 외에 방어 제공,

오용을 모니터링하는 메커니즘, 시스템이 학습하는 방법을 모니터링하는 메커니즘

시간이 지남에 따라 피드백을 제공하여 ML의 효율성과 접근성을 향상시킵니다.

11. 안전장치

질문: 문서에는 책임 있는 행위에 대해 마련된 안전 장치가 설명되어 있습니까?

오용 위험이 높은 데이터 또는 모델 공개(예: 사전 훈련된 언어 모델,

이미지 생성기 또는 스크랩된 데이터 세트)?

답: [예]

정당성: 우리는 부록에서 그러한 정보를 논의합니다.

지침:

- 'NA'라는 대답은 해당 논문에 그러한 위험이 없음을 의미합니다.
- 오용 또는 이중 사용 위험이 높은 출시 모델은 다음과 같이 출시되어야 합니다.

모델의 통제된 사용을 허용하는 데 필요한 안전 장치(예: 요구)

사용자가 모델에 액세스하거나 구현하기 위해 사용 지침이나 제한 사항을 준수하는지

안전 필터.

- 인터넷에서 스크랩된 데이터 세트는 안전 위험을 초래할 수 있습니다. 저자

안전하지 않은 이미지 공개를 어떻게 방지했는지 설명해야 합니다.

- 우리는 효과적인 보호 장치를 제공하는 것이 어렵다는 점을 인식하고 있으며 많은 논문에서 이를 제공하고 있습니다.

이를 요구하지는 않지만 작성자가 이 점을 고려하여 최선을 다할 것을 권장합니다.

믿음의 노력.

12. 기존 자산에 대한 라이선스

질문: 자산(예: 코드, 데이터, 모델)의 작성자 또는 원래 소유자가 다음 작업에 사용됩니까?

해당 논문은 적절하게 출처가 명시되어 있고 명시적으로 언급된 라이선스 및 사용 약관이 있어야 합니다.
제대로 존중받나요?

답: [예]

정당성: 우리는 코드와 모델의 원래 소유자입니다.

지침:

- NA라는 대답은 해당 논문이 기존 자산을 사용하지 않는다는 의미입니다.
- 저자는 코드 패키지 또는 데이터 세트를 생성한 원본 논문을 인용해야 합니다.
- 작성자는 사용된 자산의 버전을 명시하고 가능하면 다음을 포함해야 합니다.

URL.

- 각 자산에는 라이선스 이름(예: CC-BY 4.0)이 포함되어야 합니다.
- 특정 소스(예: 웹사이트)에서 스크랩한 데이터의 경우 저작권 및 약관은 다음과 같습니다.

해당 소스의 서비스가 제공되어야 합니다.

- 자산이 출시된 경우 해당 자산의 라이선스, 저작권 정보 및 사용 약관이

패키지가 제공되어야 합니다. 인기 있는 데이터 세트의 경우 paperswithcode.com/datasets
일부 데이터 세트에 대한 라이선스가 선별되어 있습니다. 라이선스 가이드는
데이터 세트의 라이선스입니다.

- 재패키징된 기존 데이터세트의 경우 원본 라이선스와 다음 라이선스가 모두 필요합니다.

파생 자산(변경된 경우)을 제공해야 합니다.

22

--- 페이지 23 ---

- 이 정보를 온라인에서 사용할 수 없는 경우 저자는 다음 연락처로 문의하는 것이 좋습니다.

자산의 제작자.

13. 새로운 자산

질문: 문서에 소개된 새로운 자산이 잘 문서화되어 있습니까?

자산과 함께 제공됩니까?

답: [예]

근거: 우리는 코드와 모델을 제공합니다.

지침:

- NA라는 대답은 해당 신문이 새로운 자산을 공개하지 않는다는 의미입니다.
- 연구원은 데이터세트/코드/모델의 세부정보를 연구의 일부로 전달해야 합니다.

구조화된 템플릿을 통한 제출. 여기에는 교육, 라이선스,

제한 사항 등

- 논문에서는 다음과 같은 사람들로부터 동의를 얻었는지 여부와 어떻게 얻었는지 논의해야 합니다.

자산이 사용됩니다.

- 제출 시 자산을 식명화하는 것을 잊지 마십시오(해당하는 경우). 다음 중 하나를 수행할 수 있습니다.
식명화된 URL을 생성하거나 식명화된 zip 파일을 포함하세요.

14. 인간 대상을 대상으로 한 클라우드소싱 및 연구

질문: 인간을 대상으로 한 클라우드소싱 실험과 연구에 대해 논문에서는 어떤가요?

해당되는 경우 참가자에게 제공되는 지침의 전체 텍스트와 스크린샷을 포함합니다.

보상에 대한 세부정보(있는 경우)는 무엇입니까?

답변: [NA]

근거:

지침:

- 'NA'라는 대답은 해당 논문이 클라우드소싱이나 연구를 포함하지 않음을 의미합니다.

인간 과목.

- 보충 자료에 이 정보를 포함시키는 것은 괜찮지만, 주요 기여가 논문의 내용이 인간을 대상으로 하는 경우 가능한 한 많은 세부 사항을 기술해야 합니다. 주요 논문에 포함되어 있습니다.

- NeurIPS 윤리강령에 따르면 데이터 수집, 큐레이션, 또는 기타 노동에 대해서는 데이터가 있는 국가의 최저 임금 이상을 지급해야 합니다. 수집가.

15. 인간을 대상으로 한 연구에 대한 기관 검토 위원회(IRB) 승인 또는 이와 동등한 것과

과목

질문: 논문에서는 연구 참가자에게 발생할 수 있는 잠재적인 위험을 설명합니까?

그러한 위험이 피험자에게 공개되었으며, 임상시험심사위원회(IRB)

승인(또는 해당 국가의 요구 사항에 따른 동등한 승인/검토 또는

기관)을 취득하였는가?

답변: [NA]

근거:

지침:

- 'NA'라는 대답은 해당 논문이 클라우드소싱이나 연구를 포함하지 않음을 의미합니다.

인간 과목.

- 연구가 수행되는 국가에 따라 IRB 승인(또는 이에 상응하는 것)

인간 대상 연구에 필요할 수 있습니다. IRB 승인을 받은 경우

이 사실을 논문에 분명히 명시해야 합니다.

- 이에 대한 절차는 기관마다 크게 다를 수 있음을 알고 있습니다.

및 위치, 그리고 우리는 저자가 NeurIPS 윤리강령과

해당 기관에 대한 지침.

- 최초 제출의 경우 익명성을 침해할 수 있는 정보를 포함하지 마십시오(해당하는 경우).

해당) 검토를 수행하는 기관 등.

23

[논문 04] E-3DGS 본문 전체 번역

--- 페이지 1 ---

E-3DGS: 대규모 장면의 이벤트 기반 Novel 뷰 렌더링

3D 가우스 스플래팅 사용

소하이브 자히드^{1,2} 빅토르 루드네프^{1,2} 에디 Ilg¹ 블라디슬라프 골야닉²

¹자울란트 대학교 ²정보학을 위한 MPI, SIC

초록

새로운 뷰 합성 기술이 주로 활용됩니다.

필요성 등의 한계를 계승한 RGB 카메라

충분한 조명, 모션 블러에 대한 민감성 및

엄격한 다이내믹 레인지. 대조적으로, 이벤트 카메라는 다음과 같습니다.

이러한 제한 사항에 훨씬 더 탄력적으로 대처할 수 있었지만

이 영역, 특히 대규모 분야에서는 덜 탐구되었습니다.

설정. 현재 방법론은 주로 전면에 초점을 맞추고 있습니다.

직면 또는 객체 지향(360도 보기) 시나리오. 에 대한

처음으로 이벤트 기반의 3D 가우스를 소개합니다.

새로운 관점 합성. 우리의 방법은 크고

높은 시각적 품질을 갖춘 무한한 장면. 우리는 기여한다

이를 위해 맞춤형된 최초의 실제 및 합성 이벤트 데이터셋

설정. 우리의 방법은 뛰어난 새로운 뷰 동기화를 보여줍니다.

논문이며 지속적으로 기준 EventNeRF보다 뛰어난 성능을 발휘합니다.

주문하는 동안 PSNR(dB)에서 11~25%의 여유가 있습니다.

재구성 및 렌더링 속도가 훨씬 빨라졌습니다.

1. 소개

새로운 관점 종합은 v_i 에 대한 근본적인 접근 방식을 제공합니다.

새로운 관점을 생성하여 복잡한 장면을 시각화합니다.

기존 이미지에서 이는 많은 잠재적인 적용 가능성을 가지고 있습니다.

가상 현실, 영화 제작 및 건축을 포함한

구조적 시각화 [27]. 이에 대한 새로운 대안

일반적인 RGB 센서는 이벤트 카메라입니다.

영감을 받은 시각적 센서 기록 이벤트, 즉 비동기식

밝기 또는 색상 강도의 변화에 대한 픽셀별 신호입니다.

이벤트 스트림은 시간적 해상도가 매우 높으며

본질적으로 희박합니다.

장면이 관찰된다. 작동 원리로 인해 이벤트가 발생합니다.

카메라는 특히 까다로운 작업에서 여러 가지 이점을 제공합니다.

사례: 고속 모션 처리에 탁월하며

지원되는 신호의 다이내믹 레인지가 훨씬 더 높아짐

기존 RGB 카메라보다 측정값이 더 높습니다. 더욱이,

전력 소비가 낮고 다양한 저장 공간이 필요합니다.

캡처된 데이터의 연령 볼륨은 종종 다음보다 작습니다.

동기식 RGB 카메라에 필요한 것 [5, 19].

고속 모션을 처리하는 능력은 매우 중요합니다.

정적 장면, 특히 휴대용 이동의 경우

카메라는 모션의 일반적인 문제를 피하는 데 도움이 됩니다.

흐림. 그러므로 사건을 기반으로 한 소설이 있다는 것은 놀라운 일이 아니다.

뷰 합성이 주목을 받았지만 색상 값은 직접적으로 관찰되지는 않습니다. 특히, 실질적인 내용으로 인해 RGB 기반과 이벤트 기반 형식 간의 차이 접근 방식에는 근본적으로 다른 설계 선택이 필요합니다. 이벤트 기반 신규 시점 합성의 첫 번째 솔루션 문헌에 소개된 sis는 유망한 재원을 보여줍니다. 결과 [12, 25] 및 비이벤트 기반 대안보다 성능이 뛰어남 많은 까다로운 시나리오에서 새로운 뷰 합성을 위해. 그중 EventNeRF [25]는 새로운 관점의 합성을 가능하게 합니다. 와 관련된 이벤트를 가정하여 RGB 공간에 sis를 배치합니다. 세 가지 색상 채널을 입력으로 사용합니다. NeRF 기반 AR로 인해 아키텍처[17]에서는 완전한 단일 개체를 처리할 수 있습니다. 카메라까지 거의 동일한 거리에서 관찰합니다. 그것 또한 훈련 및 렌더링 속도에 제한이 있습니다. 장면을 표현하는 데 사용되는 MLP에는 오랜 훈련이 필요합니다. 매우 제한된 장면 범위 또는 기타 작업만 처리할 수 있습니다. 그렇지 않으면 렌더링 품질이 저하됩니다. 그러므로 품질은 더 큰 장면에서는 합성된 새로운 보기의 품질이 저하됩니다. 새로운 방법인 Event-3DGS(E-3DGS)를 제시합니다. 3D Gaus를 사용하여 이벤트 스트림에서 새로운 뷰 합성을 위해 sians [9]는 다음과 같이 빠른 재구성 및 렌더링을 시연합니다. 무한한 장면 처리도 가능합니다. 기술적인 측면은 이 논문의 배포는 다음과 같습니다.

- E-3DGS를 통해 우리는 새로운 것에 대한 첫 번째 접근 방식을 도입합니다. 컬러 이벤트 카메라에서 합성 보기 이벤트 기반 감독 기능을 갖춘 3D 가우스.
- 절두체 기반 초기화, 적응형 이벤트를 제시합니다.

창, 등방성 3D 가우스 정규화 및 3D 카메라 포즈를 개선하고 그 높은 수준을 보여줍니다. 양질의 결과를 얻을 수 있습니다.

- 마지막으로 새로운 합성 및 실제 이벤트를 소개합니다.

소설을 연구하기 위해 커뮤니티에 대규모 장면에 대한 데이터세트 제공 이 새로운 문제 설정에서 종합을 봅니다. 우리의 실험은 체계적으로 우수한 재검토를 보여줍니다. EventNeRF [25] 및 기타 기준과 비교한 결과입니다. 는 E-3DGS의 소스코드와 데이터세트가 공개되었습니다¹.
1<https://4dqv.mpi-inf.mpg.de/E3DGS/>

1

arXiv:2502.10827v1 [cs.CV] 2025년 2월 15일

--- 페이지 2 ---

2. 관련 업무

2.1. RGB 입력의 새로운 뷰 합성

경직된 장면의 새로운 관점 합성은 주로 손으로 이루어집니다. RGB 입력을 가정하고 있습니다. 이에 대해 널리 사용되는 접근 방식 문제는 좌표 기반 신경 장면 표현을 학습하는 것입니다.

테스트 시 새로운 보기를 렌더링할 수 있는 스테이션입니다. 귀-
 NeRF(Neural Radiance Fields)와 같은 추가 작업 및 그
 직접적인 후속 조치 [17, 27]에서는 암시적 신경 표현을 사용했습니다.
 볼륨 렌더링과 결합된 스테이션. 그들은
 최적화 비용이 많이 드는 다층 퍼셉트론 기반
 (MLP)가 필요하지만 교육 및 평가 속도가 느립니다.
 일단 저장 공간이 상대적으로 적습니다.
 훈련을 받았습니다. 확률론적 광선 샘플링에는 많은 샘플링이 필요합니다.
 정확한 장면 근사치를 얻기 위해 노력하고,
 빈 공간을 통해 광선을 통과시키는 것은 불필요한 과잉을 구성합니다.
 머리. 이러한 접근 방식의 대부분은 단일 개체 또는
 제한된 장면. 최근 기술은 신경 MLP를 가속화합니다.
 기반 표현 또는 광선 샘플링 [20, 24] 또는 피
 복셀 그리드를 사용하는 MLP [2, 4, 26]. 일부 기술 [3]
 방사형 기준 기능을 사용하여 무한한 장면을 지원합니다.
 이를 통해 복셀 그리드의 한계를 극복했습니다.
 기반 방법. 다양한 광선 추적 기반 방법 지원
 대규모 장면과 제어되지 않는 카메라 궤적을 포팅합니다.
 진보적인 NeRF 최적화 덕분입니다 [16, 29]. 인스턴트-
 NGP[20]는 해시 그리드가 있는 신경 기능 볼륨입니다.
 시험 시간에 빠르게 학습하고 평가할 수 있습니다. 그들은 할 수 있다
 또한 다중 규모 훈련 시나리오를 효율적으로 처리합니다.
 유망한 최근 개발은 Ray로부터의 전환입니다.
 3D 도입으로 표시되는 래스터화 추적
 가우스 스피래팅(3DGS) [9]. 이 접근법은
 3D 재구성과 소설을 위한 대안 패러다임
 3D 미분 래스터화를 사용한 합성 보기
 기하학적 기본 요소로서의 가우스. GPU 기술 이후
 ogy와 알고리즘 연구는 여러 차례에 걸쳐 발전해 왔습니다.
 래스터화 애플리케이션을 위한 고성능을 제공하기 위해 수십 년 동안
 응용 프로그램을 통해 3DGS는 훨씬 더 빠르게 훈련하고 다음을 제공합니다.
 NeRF보다 렌더링 처리량이 훨씬 높습니다. 더욱이,
 지오메트리를 명시적으로 나타내기 때문에 쉽게 확장할 수 있습니다.
 특별한 처리 없이 장면 크기가 증가함에 따라
 무한한 장면에 필요합니다. 우리의 접근 방식은 3D를 채택합니다
 가우스 표현과 그 적용을
 이벤트 스트림의 감독. 이는 광고를 상속받습니다.
 뷰 합성을 위한 이벤트 스트림 및 3DGS의 이점.
 2.2. 이벤트 스트림의 새로운 보기 합성
 이벤트 지원 회소 주행 거리 측정 및 동시 현지화
 매핑 접근 방식은 우리 설정과 먼 관련이 있습니다.
 사실적이며 조밀한 렌더링을 허용하지 않기 때문입니다.
 새로운 견해 [7, 10, 13, 22].
 이전에 논의한 바와 같이 이벤트 카메라는 다음과 같은 기능을 나타냅니다.
 조밀하고 새로운 뷰 합성을 위한 RGB 센서의 대안,
 3D 장면 재현 학습에 대한 일부 초기 작업이 수행되었습니다.
 이벤트 스트림에서만 분노가 발생합니다. EventNeRF [25]는

MLP 기반 암시적 3D 훈련을 위한 중요한 프레임워크
 누적된 프레임을 사용한 표현(섹션 2.1 참조)
 컬러 이벤트. 인상적인 결과를 보여주면서도
 균일한 움직임을 갖는 카메라 궤적으로 제한되며
 배경이 일정한 색상이라는 가정(삼각형)
 이벤트가 발생하지 않습니다). E-NeRF [12]는 다음과 같은 또 다른 작업입니다.
 단일 이벤트에 대한 EventNeRF의 훈련 방법론과 유사합니다.
 채널(강도) 이벤트 카메라를 사용하고 Co- 훈련을 허용합니다.
 흐릿한 RGB 조합으로 구성된 3D 표현

이미지 및 회색조 이벤트. Low and의 강력한 E-NeRF
 Lee [14]는 다음과 같은 문제를 줄이기 위한 모델이다.
 통제되지 않은 카메라 움직임. 그들은 내화물을 소개합니다
 이벤트 생성 모델의 기간, 즉
 이벤트 발생 후 픽셀이 비활성화됩니다. 감독-
 이러한 현상은 개별적인 사건 수준에서 발생하며,
 픽셀 내 변화를 처리하기 위해 이벤트 손실을 공식화합니다.
 훈련 중에 최적화된 대비 임계값. 이 모든 것
 방법은 광선 추적을 채택하고 주로 다음에 적용될 수 있습니다.
 360° 객체 중심 데이터세트 또는 전면 궤적.
 우리의 접근 방식은 이전의 이벤트 기반 방법과 다릅니다.
 래스터화가 효율적으로 수행될 수 있음을 보여줍니다.
 광선 추적 대신 이벤트 기반 감독과 결합
 ing. 우리 방법의 주요 설계 선택은 맞춤형입니다.
 3D 가우시안으로. 결과적으로 우리의 방법은 기본 원칙을 상속받습니다.
 빠른 훈련과 in-translation과 같은 3DGS[9]의 장점은 다음과 같습니다.
 참고. EventNeRF [25]와 유사하게 우리의 방법은 다음을 지원합니다.
 색상. 그러나 대조적으로 단일 객체에만 국한되지는 않습니다.
 대규모 장면을 처리할 수 있습니다.

3. 예선

3.1. 3D 가우스

3D Gaussian Splatting [9]은 고품질이며 효율적입니다.

장면 표현. 가우시안은 3D로 정의됩니다.

점 μ_i 를 중심으로 하는 공분산 행렬 Σ_i :

$G_i(x) = \text{특급}$

-1

$2(x - \mu_i)^T \Sigma_i^{-1} (x - \mu_i)$

나는 $(x - \mu_i)$

, (1)

해당 오버레이는 장면 위치 x 의 형상을 모델링합니다.

각 가우시안은 추가로 불투명도 α_i 와 연관됩니다.

뷰 의존적 색상을 모델링하는 구면 고조파.

렌더링 목적으로 평균 μ_i 와 공분산은 다음과 같습니다.

trices Σ_i 는 이미지 좌표로 변환됩니다. 프로-

주입된 행렬 Σ_i'

나는보기를 적용하여 얻을 수 있습니다
 변환 W와 아핀 근사의 야코비안 J
 투영 변환의 모방:

$$i = J W \quad i W T J T. (2)$$

'의 세 번째 행과 열

나는

2D 매트릭스. 방정식 1을 사용하면 다음을 평가할 수 있습니다.

이미지 픽셀과 겹치는 다른 가우시안 i 및

2

--- 페이지 3 ---

그림 1. E-3DGS 방법 개요. 우리는 장면 표현으로 3D Gaussians [9]를 사용하고 초기 노이즈 카메라가 다음과 같다고 가정합니다.

포즈가 가능합니다. 절두체 기반 초기화(섹션 4.2)를 사용하여 장면을 무작위로 초기화한 다음 가우시안과 카메라가 함께 포즈를 취합니다(섹션 4.5). 저주파 구조와 고주파 세부사항 모두의 고품질 재구성을 얻으려면, 우리는 ts1에서 t까지의 큰 이벤트 창과 ts2에서 t까지의 작은 이벤트 창을 사용하는 전략을 제안합니다(Sec. 4.3). 그런 다음 손실 Lrecon을 정의합니다.

(초 4.6) 현재 시간 t(녹색으로 표시)와 이전 시간 ts1(주황색으로 표시) 및 ts2의 모델 렌더링 사이 (빨간색으로 표시), 누적된 수신 이벤트E(ts1, t) 및 E(ts2, t). lossLiso를 사용하여 3D 가우스를 정규화합니다(섹션 4.4). 알파 값을 $\alpha_{i,x} = \sigma_i G'$ 로 얻습니다.

나는(x). 가우스는

그런 다음 깊이에 따라 정렬하고 알파 블렌딩을 수행합니다.

모든 픽셀은 뷰 의존적 요소를 결합하여 수행됩니다.

다음 방정식을 사용하여 ci 색상을 지정합니다.

$$C_x =$$

$$N_X$$

$$N_{\alpha} = 1$$

$$T_{i,x} = \alpha_{i,x} c_i, (3)$$

$$\text{여기서 } T_{i,x} = Q_i - 1$$

$$k=1(1 \quad k,x) \text{는 투과율을 나타냅니다.}$$

3.2. 이벤트 형성 모델

이벤트 카메라는 지속적인 이벤트 스트림을 생성합니다.

$e = (x, p, \quad)$ 로 표시됩니다. 여기서 x는 픽셀 좌표입니다.

이벤트가 시간 t에 트리거되고 $p \in \{-1, +1\}$

이벤트의 극성을 나타내며 증가 또는 감소를 나타냅니다.

미리 정의된 설정에 따라 로그 강도가 감소합니다.

트래픽 임계값 τ . 따라서 삼각함수 사이의 관계는 다음과 같습니다.

이벤트가 발생하고 로그 이미지 강도는 다음과 같습니다.

$$L_x(t) - L_x(t_{\text{이전}}) = p \cdot \Delta, (4)$$

여기서 t_{prev} 는 이전 이벤트가 발생한 시간입니다.

픽셀이 트리거되었습니다. 이 개념은 다음과 같이 일반화될 수 있습니다.

시간 간격 내에서 이벤트 누적을 적용합니다.

(t_1, t_2) $t_1 < t_2$ 픽셀 위치 x에 대해 다음과 같습니다.

$$L_x(t_2) - L_x(t_1) =$$

$$\sum$$

$$1 < t \leq 2$$

pt

데프

= $Ex(t_1, t_2)$, (5)

여기서 t_1, t_2 는 1, 2에 가장 가까운 일련의 이벤트를 색인화합니다.

4. E-3DGS 방법

우리의 목표는 정적 장면의 3D 표현을 배우는 것입니다.

색상 이벤트 스트림만 사용하여 각 픽셀이 관찰됩니다.

다음 중 하나에 해당하는 밝기의 변화를 제공합니다.

Bayer 패턴에 따른 빨간색, 녹색 또는 파란색 채널,

알려진 카메라 내장 $Kt \in \mathbb{R}^{3 \times 3}$ 및 노이즈가 있는 초기화

합리적으로 높은 주파수 시간에서 $Pt \in \mathbb{R}^{3 \times 4}$ 포즈

로 색인된 단계. 3DGS[9]에 이어 우리는

이방성 3D 가우시안의 장면. 우리의 방법론은

가우시안이 없을 때 초기화하는 기술을 소개합니다.

SfM(Structure from Motion) 포인트 클라우드, 적응형 이벤트

3DGS의 프레임 감독 및 포즈 개선 모듈.

우리 방법의 개요는 그림 1에 제공됩니다.

우리의 E-3DGS 방법은 장면에만 국한되지 않습니다.

특정 크기이며 무제한의 환경을 처리할 수 있습니다. 그것

3

--- 페이지 4 ---

배경에 관한 어떠한 가정에도 의존하지 않습니다.

색상, 카메라 동작 유형 또는 속도. 따라서, 그것은 보장한다

다양한 시나리오에서 강력한 성능을 발휘합니다.

4.1. 이벤트 스트림 감독

3D 학습에는 두 가지 주요 접근 방식이 있습니다.

이벤트 스트림의 장면 표현. 일부는

단일 이벤트에 대한 손실 [14]은 Eq. (4). 다른 사람들은

Eq.의 사건 $Ex(t_1, t_2)$ 의 합. (5). 우리는 초를 선택합니다.

3DGS의 래스터화는 효과적인 작업에 매우 적합하므로 두 번째 접근 방식입니다.

개별 픽셀이 아닌 전체 이미지를 효율적으로 렌더링합니다.

다음을 사용하여 가우시안 장면 표현을 최적화하려면

이벤트 데이터를 통해 우리는 두 이벤트 사이의 논리적 동등성을 만들 수 있습니다.

관찰된 이벤트 스트림과 장면 렌더링. 그렇게 하려면,

우리는 Eq.에서 실제 로그 강도 L_x 를 대체합니다. (5)

우리 장면에서 렌더링된 로그 강도 L_x 로,

그리고 사용된 카메라 포즈 P_t 의 시간

각 시간 단계에서 장면을 렌더링합니다. 팔로우-

[25]에서 사용된 접근법을 사용하면 로그 차이는 다음과 같습니다.

포인트 단위로 베이어 필터 F 를 곱하여 다음을 얻습니다.

해당 색상 채널. 마침내 오류를 계산할 수 있습니다

우리 모델의 로그 변화와 AC 사이

이벤트 스트림에서 관찰된 실제 변화를 정의하고

다음과 같은 픽셀당 손실이 발생합니다.

$LX(t_1, t_2) =$

$F(Lx(Pt2) - Lx(Pt1)) - F(Ex(t1, t2))$

1

, (6)

여기서 " "는 픽셀별 곱셈을 나타냅니다.

4.2. 절두체 기반 초기화

원래 3DGS[9]에서는 가우스가 다음과 같이 초기화되었습니다.

입력에 SfM을 적용하여 얻은 포인트 클라우드 생성

이미지. 저자는 또한 초기화를 실험했습니다.

큐브 내의 임의 위치에 있는 가우스. 이 동안

약간의 성능 저하가 있었지만 이를 위해 일했습니다.

장면의 범위에 대한 가정.

SfM을 이벤트 스트림에 직접 적용하는 것이 더 어렵습니다.

RGB 입력[10]보다 길어지고 이 측면을 탐구하는 것은

이 문서의 주요 초점은 아닙니다. 없는 경우

SfM 포인트 클라우드에서는 무작위로 초기화된 가우스를 사용합니다.

이 접근 방식을 무한한 장면으로 확장합니다. 이를 위해,

우리는 지정된 수의 가우스를 초기화합니다(또는-

der of 104)를 각 카메라의 절두체에 넣습니다. 이것은 두 가지를 제공합니다

이점: 1) 초기화된 모든 가우스는 관측값 내에 있습니다.

2) 하나의 느슨한 가정만 필요합니다.

최대 깊이 zfar인 장면에 대해 설명합니다.

4.3. 적응형 이벤트 창

Rudnevet al. [25] EventNeRF에서 다음을 사용하여 시연했습니다.

고정된 이벤트 창 기간으로 인해 차선택이 발생합니다.

건설. 그들은 더 큰 창문이 필수적이라는 것을 알았습니다.

저주파 색상과 구조를 캡처하고 더 작은

이는 더 미세한 고주파수 최적화에 필수적입니다.

세부 사항. 이벤트 창을 무작위로 샘플링하는 동안

지속 시간, 단점은 카메라를 고려하지 않는다는 것입니다

속도 및 이벤트 비율에 따라 샘플링된 창이 일치할 수 있습니다.

이벤트가 너무 많거나 너무 적습니다. 우리의 데이터셋 기능으로는

다양한 카메라 속도를 샘플링하여 개선합니다.

기간이 아닌 이벤트 수입입니다. 받는 사람

이를 달성하기 위해 각 시간 단계마다 무작위로 타르를 샘플링합니다.

[Nmin, Nmax] 범위 내에서 이벤트 수를 가져옵니다.

시간 단계 t가 주어지면 이전 시간 단계 ts를 검색합니다.

이벤트 프레임의 이벤트 수 $E(ts, t)$

원하는 숫자와 거의 같습니다.

Nmax를 결정할 때 우리는 다음과 같은 값을 찾습니다.

디테일과 저주파 구조가 최적, 3DGS

불안정해지는 경향이 있으며 때로는 가우스를 잘라냅니다.

동질적인 지역의 시안. 이는 다음을 통해 완화될 수 있지만

훨씬 더 큰 Nmax를 선택하면 de가 다시 악화됩니다.

꼬리. 따라서 우리는 두 가지를 모두 통합하는 전략을 제안합니다.

작고 큰 창문. 각 t에 대해 더 일찍 두 개를 선택합니다.

시간 단계 ts1 및 ts2. 이벤트 샘플링 범위

둘 다에 대한 개수는 경험적으로 다음과 같이 선택됩니다.

10, N최대]

및 [N최대

300, N최대

30]. 그런 다음 모델에서 프레임을 렌더링합니다.

시간 t , ts_1 및 ts_2 에서 두 개의 동시 손실을 사용합니다.

이벤트 창 $Ex(ts_1, t)$ 및 $Ex(ts_2, t)$.

4.4. 가능한 한 등방성 정규화

3DGS에서 가우시안은 방향에 제약을 받지 않습니다.

이미지 평면에 수직입니다. 이러한 제약이 부족하면

결과적으로 길고 과적합된 가우시안이 생성됩니다. 그리고 동안

훈련 보기에서는 올바르게 보일 수 있습니다.

새로운 관점에서 렌더링될 때 중요한 인공물을 추론합니다.

물체 표면의 플로터 및 왜곡으로 나타납니다.

우리는 또한 다중 뷰 일관성이 부족하고

과적합 경향은 포즈 개선을 불안정하게 만듭니다.

이러한 문제를 완화하기 위해 Gaus-

sian Splatting SLAM [15] 및 SplatTAM [8]을 적용하고

등방성 정규화:

리소 = 1

|지|

X

$g \in G$

S_g S_g

1, (7)

여기서 G 는 이미지에 표시되는 가우스 세트입니다. 방정식. (7)

가우시안이 등방성이 되도록 소프트 제약 조건을 부과합니다.

가능한 한. 우리는 이것이 포즈 개선을 개선하는 데 도움이 된다는 것을 발견했습니다.

플로터를 최소화하고 일반화 가능성을 높입니다.

4.5. 포즈 개선

가장 정확한 결과를 얻기 위해 포즈를 다음과 같이 허용합니다.

개선된 포즈를 모델링하여 최적화 중에 개선됩니다.

P' 로서

$t = \text{페}$

$t P_t$, 여기서 P_e

t 는 오류 수정 변환입니다.

P_e 를 직접 최적화하는 대신

t 를 3×3 행렬로, 다음과 같습니다.

Hempel et al. [6] 우리는 이를 $[r_1 \ r_2 \ T]$ 로 표현합니다.

r_1 과 r_2 는 회전 ma 의 두 회전 벡터를 나타냅니다.

$trix \ R = [r_1 \ r_2 \ r_3]$ 이고 T 는 변환입니다. 그러면 우리는 할 수 있다

4

--- 페이지 5 ---

P_e 를 구하다

그램을 사용한 표현의 t 행렬

슈미트 직교화(보충 II의 세부사항 참조),
따라서 최적화 중에 오류 수정이 보장됩니다.
변환은 항상 유효한 변환 작업을 나타냅니다.
트릭스. 페
t는 항등 변환으로 초기화됩니다. 이후
방정식의 손실 함수. (6) 카메라 포즈에 따라 다릅니다.
글쎄, 그것은 우리가 동일한 손실을 역전파에 사용할 수 있게 해주고
포즈 개선을 위한 그라데이션을 얻습니다.
우리의 목표는 추정된 노이즈 포즈를 개선하는 것입니다.
SLAM을 수행하는 것보다 이 훈련 신호로 충분합니다.
필요합니다. 더욱이, 우리는 포즈가 다음과 같이 달라지는 경향이 있음을 관찰합니다.
주기적인 불투명도 재설정으로 인한 3DGS. 이에 대처하기 위해 우리는
추가적인 포즈 정규화로 소프트 제약을 부과합니다.
이는 행렬 P_e 를 장려합니다.
근처에 머물지 않으려고

단위 행렬 I :

$L_{pose} = P_e$

TS1

$\|I\|_2 + \|P_e\|_2$

TS2

$\|I\|_2 + \|P_e\|_2$

$t = I \mid 2, (8)$

모든 용어에 동일한 가중치가 적용됩니다.

4.6. 최적화

방정식. (6)은 단일 픽셀에 대한 픽셀당 재구성 손실을 정의합니다.
이벤트 프레임. 그러나 순진하게 이러한 픽셀당 평균을 계산합니다.
전체 이미지에 대한 손실로 인해 문제가 발생합니다. 소규모 행사용
창에서 대부분의 픽셀에는 이벤트가 없습니다.
유익하지만 손실의 대부분을 차지하게 됩니다.
이 문제를 해결하기 위해 우리는 손실의 별도 평균을 계산합니다.
이벤트 X_{ev} 가 있는 픽셀과 이벤트 X_{noev} 가 없는 픽셀의 경우.
그런 다음 이러한 평균은 하이퍼파라미터 α 에 의해 조정됩니다.
0.3을 사용하면 완전한 가중 재구성 손실을 얻을 수 있습니다.

레콘(t_s, t) =

$|크노에프스| \cdot$

X

$x \in X_{noevs}$

$LX(t_s, t)$

!

+

+ 1

$|제브| \cdot$

X

$x \in X_{evs}$

$LX(t_s, t)$

!

.

(9)

최종 손실을 얻기 위해 우리는 재원의 가중 합계를 취합니다.

Sec.의 두 이벤트 창에 대한 건설 손실. 4.3

등방성 및 포즈 정규화와 함께:

$$L = L_{\text{recon}}(ts_1, t) + L_{\text{recon}}(ts_2, t)$$

+ iso_{Liso} + $pose_{\text{Lpose}}$

, (10)

여기서 ts_1 , ts_2 및 iso 는 하이퍼 매개변수입니다. 우리의 경험에서는

여기서는 $ts_1 = ts_2 = 0.65$ 를 사용하고 iso 는 초기에 10으로 설정됩니다.

104번의 반복 후에는 1로 감소했습니다.

5. 실험적 평가

5.1. 구현 세부정보

우리는 보충 자료에서 전체 구현 세부 사항을 제공합니다.

정신적 물질. 장면에서 메소드를 실행하는 데는 한 번만 필요합니다.

단일 작업으로 최대 2시간(장면 크기에 따라 다름)

엔비디아 지포스 RTX 3090.

(아)

(비)

그림 2. 무생물이 있는 장면의 두 가지 다른 보기

MPI for Informatics의 멀티뷰 스튜디오에서 조립되었습니다.

5.2. 데이터셋

다음으로 우리가 분석에 제공하는 새로운 이벤트 데이터 세트에 대해 설명합니다.

기존 데이터 세트와 함께 대규모 장면을 분석합니다.

우리는 실험에 사용합니다.

E-3DGS-리얼. 우리의 실제 데이터셋은 연구실 내에서 캡처되었습니다.

디오 환경. 장면은 다양한 물체 세트로 구성됩니다.

그림 2와 같이 프로젝트를 수행했습니다. 우리는 DA VIS346C 색상 이벤트를 사용했습니다.

346 × 260의 해상도로 장면을 캡처하는 카메라입니다.

대비 임계값 설정이 기본값으로 유지되었습니다.

값은 대칭입니다. 우리는 여러 클립을 캡처합니다

장면의 길이는 대략 60~120초이며 다양한 동작이 있습니다.

장면 범위의 특성 및 수준. 포획된

데이터는 2.5의 이벤트 스트림과 RGB 이미지로 구성됩니다.

초당 프레임. 스튜디오에는 115개의 트랙이 갖춰져 있습니다.

벽 전체에 균일하게 분산된 추가 카메라

50FPS로 4K 영상을 캡처합니다. 접근 방식과 유사

Millerdurai 외. EE3D-R의 주석 및 주석(실제)

데이터 세트 [18]에서 우리는 이 카메라를 사용하여

카메라에 장착된 체커보드를 감지하여 포즈를 취함

이벤트 카메라 장비는 다음과 같은 빈도로 추적 데이터를 제공합니다.

최대 50Hz. 일부 타임스탬프에서는 검사기가-

보드는 폐색으로 인해 감지되지 않으며 따라서 50Hz

가장 좋은 경우일 뿐입니다. 외부 카메라의 데이터는 다음과 같습니다.

카메라 포즈 추정과 관련이 있지만 다음과 같이 사용할 수는 없습니다.

관점이 상당히 다르기 때문에 실제 진실은

훈련 보기의 times.

E-3DGS-합성. 합성 데이터 세트를 생성하기 위해 우리는 UnrealEgo [1]의 세 가지 장면을 선택합니다. 우리는 60년대를 렌더링했습니다. 1000FPS의 각 장면 클립. 장면에는 큰 내용이 포함되어 있습니다. 환경을 확장하고 다양한 유형의 표면을 전시합니다. 반사를 포함하여. 우리는 몇 가지 작은 반사율이 높은 물체(예: 금속 막대)로 인해 자연스럽지 못한 현상이 발생합니다. 렌더링에서 ral 앨리어싱이 발생했기 때문에 우리는 이를 diff를 사용하도록 변경했습니다. 퓨즈 재료. Sec의 이벤트 생성 모델. 4는 이러한 충실도가 높은 프레임의 이벤트 데이터를 시뮬레이션하는 데 사용됩니다. 포즈 데이터 1000Hz에 액세스하는 동안 다운샘플링했습니다. 실제 설정을 시뮬레이션하기 위해 50Hz로 설정했습니다. 포즈는 외부에서 캡처한 RGB 이미지로부터 추정됩니다. E-3DGS-합성-하드. 이 데이터 세트는 특별히 설계되었습니다. 핵심 기여를 강조하고 엄격하게 평가하기 위해

5

--- 페이지 6 ---

절제 연구 중 우리의 방법에 대한 설명입니다. 평가하려면 포즈 개선 모듈의 중요성 E-3DGS-Real 데이터 세트에서 정량적으로 평가됩니다. E-3DGS-Synthetic에 인공 소음을 도입합니다. 에서 관찰된 것과 주의 깊게 일치하는 데이터 세트 실제 데이터(자세한 내용은 보충 자료 III 참조) 이를 통해 우리는 포즈 개선 모듈 효과의 성능을 평가합니다. 완벽하게. 소음을 발생시키는 것 외에도 다음 사항도 해결합니다. 카메라 속도 변화 문제. 반면 카메라 속도는 E-3DGS-합성 데이터세트에서는 일반적으로 범위가 좁기 때문에 이는 우리의 기능을 완전히 테스트하지 않습니다. 적응형 이벤트 창. 좀 더 도전적인 장면을 만들기 위해 nario, 우리는 카메라 속도를 정현파로 변화시켰습니다. 최대 속도와 최소 속도 사이에는 100이 있습니다. 수정을 통해 보다 포괄적인 평가가 가능해집니다. 적응형 이벤트 창. TUM-VIE. 이 데이터 세트는 다음의 녹음으로 구성됩니다. Gen4 센서 [11]를 참조하십시오. 전직 RGB 보기 내부적으로 교정된 카메라도 제공됩니다. 캠-시대 외부 요소는 120Hz에서 추적됩니다. 두 가지 기록- Robust E-NeRF[14]에서 사용되었습니다. 우리는 훈련한다 이러한 녹음에 대한 방법, 즉 mocap-1d-trans Robust E-NeRF와 비교하기 위한 mocap-desk2. 그러나 Low and Lee [14]에서도 주장한 바와 같이 이러한 기록은 다음과 같습니다. ings는 새로운 뷰 합성에 적합하지 않습니다. 캡처는 주로 전면을 향하고 있으며 일부는 작습니다. 원으로 또는 좌우로 변위. EventNeRF 데이터세트. EventNeRF [25]는 360°를 제공합니다. 객체 중심 이벤트 데이터를 사용하여 다음을 보여줍니다.

우리의 방법은 또한 객체에 대한 이전 방법보다 성능이 뛰어납니다.
 중심 데이터. 원작의 일관성을 유지하기 위해,
 훈련의 일부인 포즈에 대한 방법을 평가합니다.
 평가 지표에 대한 새로운 관점 대신 궤적
 그들의 것과 비교될 수 있도록. 우리는 syn에 대한 방법을 훈련합니다.
 정량적 비교를 수행하기 위한 주제별 시퀀스. 에서
 이 실험에서는 배경색을 159/255로 설정했습니다.
 원본 논문 [25]을 따릅니다.

5.3. 평가 지표

E-3DGS-Real 데이터세트의 경우 RGB 프레임이 너무 낮습니다.
 품질은 평가 목적으로 사용되므로
 우리는 질적 비교만을 수행합니다. TUM-VIE와 함께,
 Robust E-NeRF [14]에서 제안한 것처럼 이는 쉽지 않습니다.
 톤 매핑이 올바르게 되었습니다. 그러므로 우리는 정량적으로
 합성 데이터 세트로만 평가합니다. 평가를 위해-
 이전의 내용을 유지하면서 합성 데이터에 대한 정보를 제공합니다.
 문헌에서 우리는 다음과 같은 평가 지표를 채택합니다.

- PSNR(최고 신호 대 잡음비);
- 학습된 지각 이미지 패치 유사성(LPIPS) [31];
- 구조적 유사성 지수 측정(SSIM).

5.3.1 색상보정

우리의 방법은 로그 차이만 학습하기 때문에
 절대적인 색상 강도보다 모호함이 있습니다.
 장면의 색상 균형과 조명을 재구성했습니다.
 따라서 색상을 조정해야 하며, 그렇지 않으면 평가가
 지표는 의미가 덜할 것입니다. 예측을 수정했습니다
 다음 방정식을 사용하는 이미지:

엘'

$$c = L' + (E[L] - E[L']), \quad (11)$$

어디서 L'

c는 색상이 보정된 로그 이미지이고

"E[·]"는 기대 연산자입니다. 방정식. (11)은 9월에 적용됩니다.

각 색상 채널에 맞춰 효과적으로 정렬됩니다.

예측된 이미지의 채널별 로그 평균

사실에 근거한 것. 합성 환경에서 우리는 다음과 같습니다.

정확한 대비 임계값을 알 수 있으므로 별도의 준비가 필요하지 않습니다.

이전의 일부 작업에서 수행된 것처럼 이미지의 크기를 수정합니다.

작품 [14, 25]. 실물에 대한 참고 이미지가 부족하기 때문에

데이터 세트에는 평가나 색상 보정이 적용되지 않습니다.

그것에. 그러나 일부 사소한 색상 및 대비 조정은

더 나은 시각화를 위해 수동으로 만들어졌습니다.

5.4. 관련 방법과의 비교

RGB 기반 방법. 우리는 흐릿한 환경에서 Deblur-GS [28]를 훈련시킵니다.

E-3DGS-Real 데이터 세트의 RGB 이미지를 설정합니다.

RGB 입력을 사용하는 참조. 이벤트도 변환해 드립니다

E2VID[23]를 사용하여 이미지로 스트리밍하고 3DGS를 적용합니다(재-

"E2VID + 3DGS"로 지칭됨). 이 방법은 평가됩니다

모든 E-3DGS 데이터세트에 적용됩니다. 두 가지 방법을 모두 훈련하기 위해 우리는 늦게 카메라는 제공되는 개별 시간 간격으로 포즈를 취합니다. 외부 추적 시스템이 필요하기 때문에 포즈 타임스탬프가 프레임 타임스탬프와 일치하지 않습니다. 우리는 RO에 SLERP(Spherical Linear Interpolation)를 사용합니다. 번역을 위한 스테이션 및 선형 보간(LERP) 이미지의 카메라 포즈를 얻으려면 이벤트 기반 방법. 이벤트 기반과의 비교 방법을 사용하여 모든 E-3DGS 데이터 세트에 대해 EventNeRF [25]를 교육합니다. 데이터세트에 맞게 조정하기 위해 카메라 포즈를 정규화합니다. 단위 구 내에서 NeRF++ [30]에 이어 구 외부의 영역을 모델링하는 배경 네트워크 현장 규모는 알 수 없습니다. 게다가, 최대 이벤트 창 길이가 10배로 늘어납니다. 수렴(최대 1초). 우리는 우리의 방법을 훈련하지 않습니다 Robust E-NeRF가 제공하는 합성 데이터 세트 [14] 매우 긴 내화 기간을 위해 설계되었기 때문에 다른 데이터 세트에서는 관찰되지 않습니다. 그러나 우리는 비교 TUM-VIE의 두 시퀀스에 대한 그들의 방법을 우리의 방법으로

그림 3, 즉 mocap-1d-trans 및 mocap-desk2.

5.4.1 관찰

모든 평가 결과는 표 1-2에 보고되어 있으며 무화과. 3~6. 눈에 보이는 것처럼 우리의 방법은 지속적으로 뛰어난 성능을 발휘합니다.

6

--- 페이지 7 ---

그림 3. E-3DGS-Real 데이터세트에 대한 기준선 및 절제 연구에 대한 E-3DGS의 비교. 디블러-GS, E2VID + 3DGS 및 EventNeRF는 흐림, 플로터, 노이즈 등 다양한 문제를 겪고 있습니다. 대조적으로, 우리의 방법은 다음과 같은 명확한 세부 사항을 제공합니다.

조각품 얼굴의 복잡한 구조.

방법 회사 ScienceLab 지하철 평균

↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM

이벤트NeRF [25] 19.59 0.41 0.65 17.22 0.46 0.60 18.71 0.34 0.67 16.80 0.50 0.61

E2VID [23] + 3DGS [9] 9.79 0.37 0.48 11.86 0.38 0.54 9.79 0.40 0.43 10.48 0.38 0.49

E-3DGS(당사) 20.78 0.29 0.72 18.41 0.28 0.73 19.92 0.20 0.74 19.70 0.26 0.73

표 1. E-3DGS-합성 데이터세트에 대한 여러 방법 비교: 모든 경우에 기준선보다 큰 차이로 성능이 뛰어납니다.

또한 E2VID + 3DGS는 PSNR은 낮지만 E2VID의 프레임 재구성으로 인해 EventNeRF보다 더 나은 LPIPS를 달성합니다.

색상 일관성이 좋지 않지만 가장자리 세부 묘사 수준은 적절합니다(그림 6 참조). 녹색과 노란색이 각각 최고와 차선입니다.

장면 이벤트NeRF [25] E-3DGS(당사)

↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM

의자 30.62 0.05 0.94 30.42 0.03 0.95

드럼 27.43 0.07 0.91 31.07 0.03 0.95

무화과나무 31.94 0.05 0.94 34.08 0.02 0.96

햇도그 30.26 0.04 0.94 30.79 0.03 0.96

레고 25.84 0.13 0.89 30.74 0.04 0.94

소재 24.10 0.07 0.94 33.73 0.02 0.97

마이크 31.78 0.03 0.96 35.87 0.02 0.98

평균 28.85 0.06 0.93 32.39 0.03 0.96

표 2. 합성 EventNeRF 데이터세트 비교 우리의

방법은 EventNeRF에 비해 상당한 개선을 보여줍니다.

모든 평가 지표에 걸쳐

합성 데이터와 실제 데이터 모두에 대한 기준선. 이벤트 중-

NeRF 객체 중심 데이터세트에서 우리의 방법은 명확한 우수성을 보여줍니다.

거의 모든 평가 지표에 걸쳐 우선순위를 정합니다. 유일한 예외는-

"의자" 장면에서는 PSNR 점수가 약간 낮습니다.

표 2에 자세히 설명되어 있습니다. 일반적인 성능 이점

그림 4의 질적 결과는 더욱 뒷받침됩니다.

우리의 방법은 더 정확한 재구성을 생성합니다.

마찬가지로 E-3DGS-Synthetic 데이터세트에서는 E-3DGS

EventNeRF와 E2VID+3DGS를 모두 능가합니다.

큰 차이로; 표 1을 참조하십시오. 정성적 결과

그림 3에 강조 표시된 E-3DGS-Real 데이터 세트에 대해

우리 방법의 우수한 성능을 보여줍니다.

GS는 과도한 흐림 문제로 어려움을 겪고 있습니다. EventNeRF는 다음과 같은 문제를 겪고 있습니다.

광선 샘플링 및 메모리 제약으로 인한 노이즈

E2VID+3DGS는 잡음이 있는 가우스 및 플로터를 나타냅니다.

Robust E-NeRF는 더 높은 로컬 대비를 달성하지만

단일 문제로 인해 전체 밝기 일관성 문제로 어려움을 겪고 있습니다.

이벤트 트레이닝; 그림 5를 참조하세요. 우리의 E-3DGS는 일관성을 유지합니다.

장면 전체의 밝기가 약간만 감소합니다.

지역 대조. 몇 개의 구멍을 관찰할 수 있으며

그림의 외부 주변 근처에 플로터가 있습니다. 3과 5. 이들

효과는 물체 가장자리의 경계를 벗어난 영역으로 인해 발생합니다.

왜곡되지 않은 결과로 발생하는 서비스

이벤트 스트림.

5.5. 절제 연구

개인 기여의 효과를 평가하기 위해 우리는

광범위한 정성적 및 정량적 절제 연구. 우리

주로 E-에서 우리 방법의 다양한 변형을 훈련합니다.

3DGS-Real 및 E-3DGS-Synthetic-Hard 데이터 세트, 초점

Liso, Lpose, Pose의 네 가지 주요 구성 요소의 효과에 대해

개선(PR) 및 적응형 이벤트 창(AW).

적응창이 없는 절제 실험의 경우,

7

--- 페이지 8 ---

부품 회사 ScienceLab 지하철 평균

Liso Lpose PR AW ↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM ↑PSNR ↓LPIPS ↑SSIM

20.742 0.404 0.661 18.823 0.414 0.677 18.923 0.436 0.619 19.496 0.418 0.652

20.519 0.434 0.631 18.099 0.454 0.631 19.401 0.475 0.601 19.340 0.454 0.621

20.229 0.539 0.606 17.646 0.587 0.601 18.746 0.620 0.569 18.874 0.582 0.592

20.667 0.427 0.642 18.354 0.440 0.657 18.742 0.440 0.606 19.254 0.436 0.635
 20.845 0.441 0.623 17.792 0.472 0.616 19.475 0.469 0.600 19.371 0.460 0.613
 19.834 0.537 0.583 17.317 0.577 0.571 18.111 0.605 0.532 18.421 0.573 0.562

표 3. E-3DGS-Synthetic-Hard 데이터 세트에 대한 절제 연구. 전반적인 경향은 다음 중 하나가 수행될 때 성능이 저하된다는 것입니다.

구성 요소가 제거되어 전체 성능에 대한 기여를 확인합니다. 특히 AW가 없는 E-3DGS는 지속적으로 2위를 차지하고 있으며,

Liso를 생략하면 종종 3위를 차지하거나 마감됩니다. (PR: 포즈 미세 조정, AW: 적응형 이벤트 창). 녹색, 노란색, 주황색 각각 최고, 두 번째로 좋은 결과, 세 번째로 좋은 결과를 나타냅니다.

그림 4. 합성에 대한 E-3DGS와 EventNeRF의 비교

EventNeRF 데이터 세트. EventNeRF는 드럼 소음으로 어려움을 겪고 있습니다.

Ficus의 시퀀스, 흐릿함, Lego의 배경 아티팩트

및 재료 시퀀스, E-3DGS는 이러한 문제를 잘 처리합니다.

그림 5. E-3DGS와 Robust E-NeRF의 비교

TUM-VIE 데이터 세트. Robust E-NeRF는 더 높은 로컬을 달성하지만

대조적으로, 전체적으로 균일하지 않은 밝기로 인해 어려움을 겪습니다. E-3DGS

비록 일부 경우에도 불구하고 장면 전반에 걸쳐 일관된 밝기를 생성합니다.

세부 손실(예: mocap-desk2 시퀀스의 테이블 텍스처)

최대 대신 최대 시간 간격 Tmax를 사용합니다.

이벤트 Nmax를 사용하여 이벤트 창을 샘플링합니다. 가치

Tmax는 Nmax로부터 계산됩니다. 즉, 평균 이벤트는 다음과 같습니다.

그림 6. E-3DGS와 E-3DGS 기준선 비교

합성 데이터 세트. E2VID + 3DGS는 색상 재현 문제로 어려움을 겪고 있습니다.

구조이지만 가장자리와 구조를 합리적으로 잘 포착합니다.

EventNeRF는 소음과 선명도 부족으로 어려움을 겪고 있습니다. 반대로

Trast의 방식으로 선명한 디테일과 정확한 색상을 구현합니다.

특정 영역의 사소한 문제(예: 의자의 코트 등)

ScienceLab 시퀀스. 줌으로 보는 것이 가장 좋습니다.

창 크기는 거의 비슷합니다.

결과는 표 3 및 그림 1 및 2에 보고되어 있습니다. 3과 6.

Liso를 제거하면 성능이 눈에 띄게 저하됩니다.

하지만 Liso와 Lpose를 함께 제거하면 훨씬 더 많은 결과가 발생합니다.

상당한 감소. 이는 Lpose가 방지하기 때문일 수 있습니다.

불안정한 조건에서 발산을 일으키고, 제거하는 동안

Liso는 과적합으로 인해 불안정성을 유발합니다. 유사한 효과

Liso와 포즈 개선을 결합할 때 발생할 수 있습니다.

6. 결론

E-3DGS의 장점을 효과적으로 결합한 모습을 보여줍니다.

3D 가우스 스플래팅 및 이벤트 기반 감독

대규모의 3차원 재구성과 새로운 시점 합성

장면. 기준선 수량보다 훨씬 뛰어난 성능을 발휘합니다.

규모적으로나 질적으로나 규모면에서나

더 빠리. 이 백서의 범위를 벗어나는 한 가지 측면은 리프트입니다.

카메라 포즈 초기화 요구 사항을 다음을 통해 수행합니다.

외부 프로세스. 우리는 이 작업이 길을 열어준다고 믿습니다.

강력하고 확장 가능한 대규모 장면 재구성 유틸리티를 위한

이벤트 카메라의 장점을 활용하여 세부 사항을 포착합니다.

낮은 조명 및 빠른 움직임과 같은 까다로운 조건.

8

--- 페이지 9 ---

참고자료

- [1] 아카다 히로야스, 왕젠, 시마다 소시, 타카 마사키-하시, 크리스티안 테오발트, 블라디슬라프 골랴닉. an-realego: 강력한 자기중심적 3D 인간 모션을 위한 새로운 데이터세트 캡처. ECCV의 1~17페이지. 스프링거, 2022. 5
- [2] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, 피터 헤드먼(Peter Hedman). Zip-nerf: 엔티앨리어싱 그리드-기반 신경 방사 필드. ICCV, 2023. 2
- [3] Zhang Chen, Zhong Li, Liangchen Song, Lele Chen, Jingyi Yu, Junsong Yuan, Yi Xu. Neurbf: 신경장 대표 적응형 방사형 기초 함수에 대한 분노. ICCV에서는 페이지 4182-4194, 2023. 2
- [4] Fridovich-Keil 및 Yu, Matthew Tancik, Qinhong Chen, 벤자민 레히트(Benjamin Recht), 가나자와 양주(Angjoo Kanazawa). 플레녹셀: Radi-신경망이 없는 엔스 필드. CVPR에서는 2022. 2
- [5] Guillermo Gallego 등. 이벤트 기반 비전: 설문조사. IEEE TPAMI, 44(01):154-180, 2022. 1
- [6] Thorsten Hempel, Ahmed A. Abdelrahman, Ayoub Al-hamadi. 견고하고 제약이 없는 전 범위의 회전을 지향합니다.

머리 자세 추정. IEEE 톱, 33:2377-2387, 2024.

4, 10

- [7] Javier Hidalgo-Carri'o, Guillermo Gallego 및 Davide 스카라무짜. 이벤트 지원 직접 회소 주행 거리 측정. CVPR에서는 2022. 2
- [8] 니킬 키타, 제이 카르하데, 크리슈나 머티 자타발라홀라, Gengshan Yang, Sebastian Scherer, Deva Ramanan 등. 조나단 루이텐. Splatam: 3D 가우스 표시, 추적 및 지도 표시 조밀한 RGB-D 슬램용. CVPR에서는 2024. 4, 11
- [9] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler, 그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅 래디언스 필드 렌더링. ACM TOG, 42(4), 2023. 1, 2, 3, 4, 7, 11, 12
- [10] 김한미, 스테판 루테네거, 앤드루 J. 데이비스. 이벤트를 통한 실시간 3D 재구성 및 6자유도 추적 카메라. ECCV, 2016. 2, 4
- [11] 사이먼 클렌크, 제이슨 추이, 니콜라우스 데멜, 다니엘 크레머. Tum-vie: 텀 스테레오 시각-관성 이벤트 데이터세트. IEEE/RSJ IROS, 페이지 8601-8608. IEEE, 2021.

6

- [12] Simon Klenk, Lukas Koestler, Davide Scaramuzza 및 다니엘 크레머스. E-nerf: 영화의 신경 복사장 이벤트 카메라. IEEE RA-L, 8(3):1587-1594, 2023. 1,

2

- [13] Simone Klenk, Marvin Motzet, Lukas Koestler 및 Daniel 크레머. 심층 이벤트 시각적 주행 거리 측정. 3DV에서, 2024. 2
- [14] 로우 웬페이(Weng Fei Low)와 이김희. 강력한 e-nerf: Nerf 균일하지 않은 모션에서 회박하고 시끄러운 이벤트. ICCV에서는 페이지 18335-18346, 2023. 2, 4, 6
- [15] 마츠키 히데노부, 무라이 리쿠, 폴 H. J. 켈리, 안-J. 데이비슨을 그렸습니다. 가우스 스피래팅 SLAM. 인CVPR, 2024. 4, 11
- [16] Andreas Meuleman, Yu-Lun Liu, Chen Gao, Jia-Bin Huang, 김창일, 김민현, 요하네스 코프. 진전-강력한 뉴 합성을 위해 적극적으로 최적화된 로컬 라디언스 필드 언니. CVPR에서는 2023. 2
- [17] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik, 조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프: 뷰 동기화를 위해 장면을 신경 방사 필드로 표현 논문. ACM 커뮤니케이션, 65(1):99-106, 2021. 1, 2
- [18] 크리스틴 밀러두라이, 아카다 히로야스, 왕지안, 디오고 루비존, 크리스티안 테오발트, 블라디슬라프 골랴닉. 심지어-tego3d: 자기 중심적 이벤트의 3D 인간 모션 캡처 스트림. CVPR에서는 2024. 5
- [19] 크리스틴 밀러두라이(Christen Millerdurai), 디오고 루비존(Diogo Luvizon), 빅토르 루드네프(Viktor Rudnev), Andr e 요나스, 왕 지아이, 크리스티안 테오발트, 블라디슬라프 Golyanik. 상호 작용하는 두 손의 3D 포즈 추정 단안 이벤트 카메라. 3DV에서, 2024. 1
- [20] Thomas M ller, Alex Evans, Christoph Schied 및 Alexan- 켈러. 다중 기능을 갖춘 즉각적인 신경 그래픽 프리미티브 tolution 해시 인코딩. ACM TOG, 41(4):102:1-102:15, 2022. 2
- [21] 그리고리오스 A 파블리오티스. 확률론적 프로세스 및 애플리케이션. 응용수학 텍스트, 60, 2014. 11
- [22] Henri Rebecq, Timo Horstschaef, Guillermo Gallego 및 다비데 스카라무자. Evo: 이벤트에 대한 기하학적 접근 방식 6-dof 기반 실시간 병렬 추적 및 매핑.IEEE RA-L, 2:593-600, 2017. 2
- [23] Henri Rebecq, Ren 'e Ranftl, Vladlen Koltun 및 Davide 스카라무자. 고속 및 HDR(High Dynamic Range) 비디오 이벤트 카메라. IEEE TPAMI, 2019. 6, 7, 12
- [24] Christian Reiser, Songyou Peng, Yiyi Liao 및 Andreas 가이거. Kilonerf: 신경 복사장 속도 향상 수천 개의 작은 mlps. ICCV에서는 2021. 2
- [25] 빅토르 루드네프, 모하메드 엘가리브, 크리스티안 테오발트, 블라디슬라프 골랴닉. Eventnerf: 신경 복사 필드 단색 이벤트 카메라. CVPR에서는 2023. 1, 2, 4, 6, 7, 11, 12
- [26] Cheng Sun, Min Sun 및 Hwann-Tzong Chen. 직접 복셀

그리드 최적화: 복사장을 위한 초고속 수렴

재건축. CVPR, 페이지 5449-5459, 2022. 2

[27] Ayush Tewari et al. 신경 렌더링의 발전. 유로-그래픽, 2022. 1, 2

[28] Chen Wenbo와 Liu Ligang. 더블러-gs: 3d 가우스 스피랏-카메라 동작으로 인해 이미지가 흐릿해졌습니다. I3D, 7(1), 2024. 6, 12

[29] Yuanbo Xiangli, Linning Xu, Xingang Pan, Nanxuan Zhao, Anyi Rao, Christian Theobalt, Bo Dai 및 Dahua Lin.

Bungeenerf: 익스트림을 위한 프로그레시브 신경 방사 필드

다중 규모 장면 렌더링. InECCV, 페이지 106-122, 2022.

2

[30] 카이 장(Kai Zhang), 게르노 리글러(Gernot Riegler), 노아 스네이블리(Noah Snavely), 블라들렌(Vladlen)

콜튼. Nerf++: 신경 방사도 분석 및 개선

필드. arXiv:2010.07492, 2020. 6

[31] 리처드 장, 필립 이슬라, 알렉세이 A 에프로스, 엘리 세흐트만,

그리고 올리버 왕. 딥의 불합리한 효율성

지각 지표로 기능합니다. CVPR에서는 2018. 6

9

--- 페이지 10 ---

E-3DGS: 대규모 장면의 이벤트 기반 Novel 뷰 렌더링

3D 가우스 스피랏팅 사용

보충 자료

이 보충자료는 추가 세부정보와 통찰력을 제공합니다.

주요 주제에서 논의된 방법과 실험에 대해

당. 초에서. 나는 절두체 기반 초기에 대해 자세히 설명합니다.

샘플링 전략과 이를 보장하는 방법을 설명합니다.

장면에 효과적인 가우스 배치. 비서. II 제공

포즈 개선, 특히 사용에 대한 자세한 내용

유효한 트랜스를 유지하기 위한 그램-슈미트 직교화

최적화 중 형성. 초에서. III, 우리는

E-3DGS-Real 데이터 세트의 카메라 포즈 노이즈 및 설명

현실적인 포즈 교란을 시뮬레이션하는 데 사용하는 프로세스

E-3DGS-Synthetic-Hard 데이터 세트의 경우. 비서. IV 개요

조정을 포함한 구현 세부 사항

융합을 향상시키기 위한 독창적인 3DGS 훈련 일정.

비서. V는 우리의 평가를 다루며 우리가 측정한 사항을 강조합니다.

특히 절제의 경우 신뢰할 수 있는 결과를 보장하려면 다음을 수행하십시오.

연구. 마지막으로, 우리는 포괄적인 비교를 제시합니다.

초 추가적인 시각적 결과와 절제를 보여주는 VI

E-3DGS-Real, E-3DGS-Synthetic 및 E-에 대한 연구

3DGS-합성-하드 데이터 세트. 이 실험은 확장됩니다.

주요 논문의 결과에 대해 더 자세히 설명합니다.

다양한 시나리오에서 우리 방법의 효율성.

I. 절두체 기반 초기화

Sec.에 설명된 대로. 주요 논문의 4.2, 우리의 접근 방식
 고정된 수의 가우스를 초기화하는 작업이 포함됩니다.
 N_g 처럼. N_t 개의 카메라 포즈가 있는 경우
 이러한 포즈에 걸쳐 가우시안이 생성되어 N_g/N_t 가우시안이 생성됩니다.
 각 포즈에 대해 초기화 중입니다. 초기화 프로세스
 카메라 절두체 내의 점을 샘플링하는 것으로 시작됩니다.
 정규화된 장치 좌표(NDC). 그러나 대신
 NDC에서 세 좌표(x, y, z)를 모두 균일하게 샘플링하고,
 우리는 깊이(z 축)에 대해 다른 전략을 채택합니다.
 우리는 깊이가 직접 샘플링되었을 때를 관찰합니다.
 NDC, 대부분의 가우시안은 가까운 곳에 매우 가깝게 모여들 것입니다.
 평면(z_{near})으로 인해 장면 커버리지가 좋지 않습니다. 주소
 이를 통해 카메라 좌표에서 깊이를 균일하게 샘플링합니다.
 z_{near} 와 z_{far} 사이. 이를 통해 보다 균일한 분포가 보장됩니다.
 전체 깊이 범위에 걸쳐 가우스를 적용합니다.
 카메라 좌표에서 깊이가 샘플링되면
 NDC로 전환됩니다. 다음으로 x 와 y 좌표는 동일합니다.
 NDC에서 균일하게 주장했습니다. 이제 x, y, z 값을 사용하여
 NDC, 우리는 그것들을 세계 좌표로 다시 투영 취소합니다.
 이 변환은 가우스의 최종 위치를 제공합니다.
 3D 장면의 시안. 다음으로 전체 과정이 반복됩니다
 주어진 포즈와 관련된 각 카메라 절두체에 대해
 P_t , 모든 뷰에서 포괄적인 초기화를 보장합니다.
 따라서 가우스 분포는 효과적으로 다음과 연결됩니다.
 관찰 가능한 장면 영역.

II. 자세 개선과 그램-슈미트 Or- 입체화

초에서. 주요 논문의 4.5에서는 다음과 같은 접근 방식을 소개합니다.
 포즈 세련, 세련된 포즈 P'
 t 는 다음과 같이 모델링됩니다.
 P_t'

$t = P_t$

t P_t, P_e 와 함께

오류 수정 변환이 아닙니다.

P_e 를 직접 최적화하는 것보다

t 를 3×3 행렬로, 우리는

두 개의 회전 벡터 r_1 과 r_2 와 트랜스를 사용하여 이를 표현합니다.

Hempel et al.의 방법에 따라 관계 벡터 T . [6].

이 표현을 통해 우리는 P_e

아직은

최적화 중 유효한 변환 행렬.

회전 행렬의 직교성을 유지하기 위해

그램-슈미트 직교화 tor_1 과 r_2 를 com-

최종 회전 행렬 $R = [r'$

1, r'

2, r'

3]. 과정

다음과 같습니다:

r'

$1 = r_1$

r_1 ,

r'

$2 = r_2 \quad (r'$

$1 \cdot r_2)r'$

1

$r_2 \quad (r'$

$1 \cdot r_2)r'$

$1!$,

r'

$3 = r'$

$1 \times r'$

2, 그리고

페

티 =

||||

r'

$1r'$

$2r'$

$3T$

||||

0 0 0 1

(12)

여기, r'

1은 r_1 의 정규화된 버전이고, r' 은

2는 ob-

r' 에 대한 r_2 의 투영을 빼서 유지됩니다.

1도 아니고-

결과를 나쁘게 만드는 것. 세 번째 벡터 r'

3은 다음과 같이 계산됩니다.

r' 의 외적

1과 r'

2, 결과적인 회전을 보장합니다.

tion 행렬은 직교합니다. 최종 오류 수정 매트릭스

페

그런 다음 t 는 이러한 직교 벡터를 사용하여 구성됩니다.

번역 벡터 T .

이 접근법은 포즈 개선이 다시 이루어지도록 보장합니다.

최적화 프로세스 전반에 걸쳐 유효한 주전원, 기여-

우리 방법의 안정성과 정확성을 중요하게 생각합니다.

III. E-3DGS-합성-의 포즈 교란

하드

Sec.에 설명된 대로. 주요 논문의 5.2에서 우리는 다음을 제공합니다.

E-3DGS-E-3DGS-와 다른 합성-하드 데이터 세트

두 가지 측면에서 합성: 1) 카메라 속도가 매우 빠릅니다.

2) 카메라 외부 장치는 다음과 유사한 소음을 나타냅니다.

실제 데이터에서 관찰된 노이즈의 특성. 받는 사람

E-3DGS-Real 데이터 세트에서 카메라 포즈 노이즈를 정량화하고,

10

--- 페이지 11 ---

(a) E-3DGS-Real 및 E-3DGS-Synthetic-Hard의 회전 오류는 유사한 오류 분포를 보여줍니다.

(b) E-3DGS-Real의 번역 오류에 비해 E-3DGS-Synthetic-Hard에는 더 큰 변환 오류가 적용됩니다.

더 큰 장면 크기와 의미 있는 절제 연구를 위해 충분히 어려운 난이도 수준을 보장합니다.

그림 1. E-3DGS-Real 데이터 세트의 추정된 포즈 오류와 E-3DGS-Real 데이터 세트의 합성으로 발생한 오류의 비교

합성-하드 데이터 세트. 합성 섭동은 Ornstein-Uhlenbeck 프로세스를 사용하여 생성되어 시간 상관 관계를 일치시킵니다.

실제 데이터의 성격과 차이.

우리는 세련된 훈련 카메라 궤적을 다음과 비교합니다.

초기 궤적. 우리의 분석에 따르면 이러한 오류는

시간 상관. 이 관찰과 시험을 바탕으로 -

이러한 오류의 규모에 맞춰 합성 Per-

무작위를 사용하는 E-3DGS-Synthetic 데이터 세트의 교란

부패와 함께 건기, 특히 Ornstein-Uhlenbeck 프로-

cess [21], 이는 섭동의 평균이 0이 되도록 보장합니다.

시간 상관관계를 유지하면서.

합성 섭동의 분산을 보정합니다.

실제 데이터에서 관찰된 회전 오류를 일치시킵니다. 에 대한

번역하면, 우리는 더 높은 수준의 섭동을 적용합니다.

합성 장면은 그 규모가 훨씬 크다는 것을 알 수 있습니다.

실제 데이터. 이 조정을 통해 번역 오류가 발생하지 않도록 보장합니다.

비례적으로 확장되어 비슷한 난이도를 생성합니다.

절제 연구 수준. 소음 패턴은 다음과 같습니다.

그림 1에서 다루었다.

IV. 구현 세부정보

우리의 코드베이스는 3DGS[9]를 기반으로 합니다. 우리는 방법을 훈련합니다

$3 \cdot 10^4$ 반복 대신 $6 \cdot 10^4$ 의 경우

수렴하도록 개선하는 자세를 취합니다. 원본 논문이 수행하는 것

가우시안의 치밀화 및 불투명도 재설정은 다음과 같습니다.

$1.5 \cdot 10^4$ 회 반복. 우리의 경우 불투명도를 다시 수행합니다.

$3 \cdot 10^4$ 까지 설정하고 치밀화는 $5 \cdot 10^4$ 반복까지 설정합니다.

우리의 분석에 따르면 불투명도 재설정 은 다음과 같은 경우에 중요합니다.

플로터를 제거하면 재구성 품질도 저하됩니다.

ity. 따라서 일단 장면이 합리적으로 수렴되면

불투명도 재설정을 중지하고 내기를 위해 장면의 밀도만 높입니다.

재건축.

또한 3DGS는 고정된 임계값 $2 \cdot$

10^{-4} 는 가우스를 분할해야 하는지 여부를 결정합니다.

치밀화를 하고 있다. 우리는 다음과 같이 최적화를 시작합니다.
 같은 값이지만 선형적으로 $4 \cdot 10^{-5}$ 로 줄입니다.
 $4 \cdot 10^4$ 회 반복. 첫째, 이를 통해 우리의 방법은
 더 큰 가우시안과 함께 포즈를 취하여 더 많은 지원을 제공합니다.
 둘째, 더 많은 것을 얻기 위해 이후 단계에서 임계값을 줄입니다.
 상세한 재구성. $N_g = 5 \cdot 10^4$ Gauss-를 초기화합니다.
 우리의 모든 훈련에 시안이 있습니다.
 포즈 개선 실험에서 우리는
 내기를 허용하므로 구형 고조파의 수를 1로 늘립니다.
 포즈 개선 [8, 15]. 완벽한 실험을 위해
 포즈에서는 원래의 3DGS 접근 방식을 따르고 세 가지를 사용합니다.
 구형 고조파. 실험을 제외한 모든 실험에서
 EventNeRF 데이터셋[25]를 사용하여 우리는 일관되게
 창 크기에 대해 $N_{\max}=106$ 이벤트를 사용하십시오. 일련의
 11

--- 페이지 12 ---

후자는 매우 짧고 충분한 이벤트를 포함하지 않습니다.
 이렇게 큰 창에는 $N_{\max}=105$ 를 사용합니다. 기차-
 전체 방법을 수행하는 데는 단일 방법으로 1~2시간이 소요됩니다.
 NVIDIA GeForce RTX 3090(장면 크기에 따라 다름)
 V. 추가 평가 세부 사항(절제)
 결과의 신뢰성을 보장하기 위해 모든 절제 연구는
 평가 지표를 평균하여 4회 실시합니다.
 보다 정확한 통찰력을 제공하고 영향을 최소화하기 위해
 우연의 일치. E-3DGS-Synthetic-Hard 데이터 세트의 경우,
 카메라 포즈가 교란되는 경우 직접 평가는
 학습된 내용 사이의 약간의 불일치로 인해 실현 가능하지 않음
 3D 장면과 실제 정보. 이 문제를 해결하려면 먼저
 가우시안을 고정된 다음 다음을 사용하여 테스트 포즈를 다듬습니다.
 적절한 수렴을 보장하기 위해 작은 학습 속도. 이
 정렬 프로세스를 통해 테스트 뷰가 지면과 일치할 수 있습니다.
 진실을 정확하게 파악하여 정확한 평가가 가능합니다.

6. 추가 비교 및 절제

이 섹션에서는 주요 논문 실험을 확장합니다.
 E-3DGS-Real, E-3DGS-에 대한 추가 결과를 표시하여
 합성 및 E-3DGS-Synthetic-Hard 데이터 세트. 그림 2
 E-3DGS의 성능을 비교하여 보여줍니다.
 Deblur-GS [28], E2VID [23]+3DGS [9] 및 Event-
 E-3DGS-Real 데이터 세트의 NeRF [25]. 이러한 기준
 흐림, 부유물, 소음과 같은 심각한 아티팩트가 나타납니다. 에서
 동일한 수치를 통해 키의 영향도 보여줍니다.
 우리 방법의 구성 요소. Liso를 제거하면 다음과 같은 결과가 발생합니다.
 플로터 및 기타 유물의 양이 늘어났습니다. 모자 그대로-
 조정된 카메라 포즈에는 노이즈가 포함되어 있으며 포즈 개선(PR)은
 정확한 결과를 얻는 데 중요합니다. 따라서 그것 없이는
 모델은 정확한 예측을 생성할 수 없으므로 결과적으로

매우 인공물과 흐릿함. 하지만 없는 모델은 적응형 창(AW)은 다음과 유사한 성능을 보여줍니다. 전체 모델. 아마도 전체적인 통일성 때문인 것 같습니다. 사용된 데이터 세트의 카메라 속도가 감소합니다. 적응형 이벤트 창이 잠재적 영향. 그림 III에서는 E-3DGS를 EventNeRF와 비교합니다[25] E-3DGS 합성 데이터세트의 E2VID [23]+3DGS [9]. 두 기준 모두 성능이 좋지 않습니다. E2VID+3DGS는 가장자리와 일반적인 구조를 파악하는 데 어려움을 겪습니다. 색상 표현 및 EventNeRF 재구성 우리의 방법에 비해 훨씬 더 시끄럽고 흐릿합니다. 에서 대조적으로, 우리의 E-3DGS는 그들을 능가하여 명확하고 정확한 색상 표현으로 선명하고 참신한 시각을 제공합니다. 일부 문제는 여전히 관찰 가능하지만 대부분 감독 수준이 낮습니다. 예를 들어 ScienceLab의 옥상이나 지하철 장면. 마지막으로 그림 IV는 절제 연구 결과를 시각화합니다. E-3DGS-합성-하드 데이터 세트. E-에 비해 3DGS-Synthetic, 이 데이터세트에는 인위적으로 카메라가 추가되었습니다. Sec III에서 설명하는 외부 소음과 급격한 카메라 속도 변화가 상당히 증가했습니다(초 5.2). 동안 이러한 변화로 인해 높은 재구성 품질을 얻을 수 있습니다. 더 어려운 점은 우리의 전체 방법이 여전히 잘 작동하고 성능이 더 뛰어나다는 것입니다. 모든 절제된 모델을 사용 중입니다. E-3DGS-Real과 마찬가지로 제거-Liso를 사용하면 심각한 아티팩트가 발생합니다(예: 첫 번째 보기에서 Company 또는 Subway의 두 번째 보기에서). E-3DGS-Synthetic-Hard 데이터 세트에는 카메라 포즈 노이즈가 있으므로 포즈 구체화(PR)를 사용하는 것이 중요합니다. 흐릿함과 아티팩트가 발생합니다. 적응형 제거 이벤트 창(AW)은 성능 저하로 이어집니다. 예를 들어, 방법 AW가 없는 경우 첫 번째 보기에서 소파에 인공물을 전시합니다. 결과에 없는 회사 서열의 전체 방법. 모두 제거된 점도 주목할 만하다. 모델들은 지하철 시리즈에 대한 두 번째 시각 때문에 어려움을 겪고 있습니다. 그럼에도 불구하고 전체 방법은 더 나은 결과를 얻습니다. sult: 구조가 더 명확하고 더 쉽게 알아볼 수 있습니다. 유물이 적습니다.

12

--- 페이지 13 ---

그림 2. E-3DGS-Real에 대한 기준선 및 절제 연구와 E-3DGS의 비교. 주요 논문인 Deblur-GS에서 관찰된 바와 같이, E2VID + 3DGS 및 EventNeRF는 흐림, 플로터 및 노이즈와 같은 문제를 나타냅니다. 특히, 절제 연구는 다음의 영향을 강조합니다. 주요 구성 요소 제거. Liso를 제거하면 부유물과 유물이 증가합니다. 대조적으로, 적응적 사건이 없는 실험은 Windows(AW)에서는 성능 차이가 거의 없습니다. 이는 이 데이터 세트의 상대적으로 일관된 카메라 속도 때문일 수 있습니다. AW의 잠재적 이점을 줄입니다.

13

--- 페이지 14 ---

그림 III. E-3DGS-합성 데이터세트의 기준선과 E-3DGS의 비교. 본 논문에서 볼 수 있듯이 E2VID + 3DGS 색상 재구성이 좋지 않아 어려움을 겪지만 가장자리와 구조를 합리적으로 잘 포착합니다. EventNeRF는 소음과 정보 부족으로 어려움을 겪고 있습니다.

선명도. 대조적으로, 우리의 방법은 주로 다음과 같이 관찰되지 않는 영역에 국한된 문제로 명확한 세부 사항과 정확한 색상을 제공합니다.

지붕. 줌으로 보는 것이 가장 좋습니다.

14

--- 페이지 15 ---

그림 IV. E-3DGS-Synthetic-Hard 데이터세트에 대한 E-3DGS의 절제 연구. 이 데이터세트의 난이도 증가로 인해 전반적인 E-3DGS-Synthetic에 비해 성능이 저하되지만 전체 방법은 여전히 잘 수행됩니다. 적응형 이벤트가 없는 버전 window(AW)는 전체 방법에 가장 가깝지만 더 많은 아티팩트를 표시합니다. 예를 들어, Company 시퀀스의 첫 번째 열에서 소파는

전체 방법에는 없는 AW 제거 버전의 일부 아티팩트를 보여줍니다. 비슷한 사소한 유물이 다른 곳에서도 보입니다. 는 Subway 시퀀스의 두 번째 열은 모든 버전이 이를 재구성하는 데 어려움을 겪고 있기 때문에 흥미롭습니다. 그럼에도 불구하고 전체 방법은 다음과 같습니다.

다른 것보다 더 나은 구조와 더 적은 인공물.

15

[논문 05] Spec-Gaussian 본문 전체 번역

--- 페이지 1 ---

Spec-Gaussian: 이방성 뷰 종속

3D 가우스 스피래팅의 모양

Ziyi Yang¹ Xinyu Gao¹ Yang-Tian Sun² Yi-Hua Huang² Xiaoyang Lyu²

Wen Zhou³ Shaohui Jiao³ Xiaojuan Qi^{2†} Xiaogang Jin^{1†}

¹절강대학교 ²홍콩대학교 ³ByteDance Inc.

초록

3D 가우스 스피래팅(3D-GS)의 최근 발전은 다음과 같은 이점을 제공할 뿐만 아니라

최신 GPU 래스터화 파이프라인을 통해 실시간 렌더링을 반복했지만

또한 최첨단 렌더링 품질을 달성했습니다. 그럼에도 불구하고, 그 예외에도 불구하고-

표준 데이터셋의 렌더링 품질 및 성능, 3D-GS 자주 사용

반사광 및 이방성 합성물을 정확하게 모델링하는 데 어려움이 있습니다.

넷. 이 문제는 구면 고조파(SH)의 제한된 기능에서 비롯됩니다.

고조파 정보를 나타냅니다. 이러한 어려움을 극복하기 위해 우리는

ASG(이방성 구형 가우스)를 활용하는 접근 방식인 Spec-Gaussian

뷰 종속 모양을 모델링하기 위해 SH 대신 모양 필드

각 3D 가우스. 또한, 우리는 대략적인 훈련을 개발했습니다.

학습 효율성을 높이고 과적합으로 인한 플로터를 제거하는 전략

실제 장면에서 튜닝. 우리의 실험 결과는 우리의 방법이

렌더링 품질 측면에서 기존 접근 방식을 능가합니다. ASG 덕분에 우리는

반사광을 사용하여 장면을 모델링하는 3D-GS의 기능이 크게 향상되었습니다.

3D 가우스인 수를 늘리지 않고 이방성 구성 요소를 포함합니다. 이

개선을 통해 3D GS의 적용 가능성이 확장되어 복잡한 시나리오를 처리할 수 있습니다.

반사면과 이방성 표면이 있습니다. 우리의 코드와 데이터셋은 다음에서 이용 가능합니다.

<https://ingra14m.github.io/Spec-Gaussian-website>.

1 소개

이미지 모음의 고품질 재구성과 사실적인 렌더링은

증강현실/가상현실(AR/VR), 3D 콘텐츠 제작 등 다양한 애플리케이션,

그리고 예술 창작. 고전적인 방법은 메쉬[36] 및 점과 같은 기본 표현을 사용합니다.

[4, 62] 최신 GPU에 최적화된 래스터화 파이프라인을 활용하여 다음을 달성합니다.

실시간 렌더링. 대조적으로, 신경 방사 필드(NeRF)[34, 5, 35]는 신경 암시적을 활용합니다.

연속적인 장면 표현을 제공하고 체적 렌더링을 사용하여 생성하는 표현

렌더링 결과. 이 접근 방식을 사용하면 장면 세부 정보를 더욱 효과적으로 보존할 수 있습니다.

장면 기하학의 재구성.

최근에는 3D Gaussian Splatting(3D-GS)[20]이 주요 기술로 등장하여 상태를 제공합니다.

최고의 품질과 실시간 속도. 이 방법은 다음을 캡처하는 3D 가우스 세트를 최적화합니다.

3D 장면의 모양과 형상을 동시에 제공하여 다음과 같은 연속적인 표현을 제공합니다.

세부 사항을 보존하고 고품질 결과를 생성합니다. 게다가, CUDA 맞춤형 미분변수는

3D 가우스안을 위한 래스터화 파이프라인을 사용하면 고해상도에서도 실시간 렌더링이 가능합니다.

뛰어난 성능에도 불구하고 3D-GS는 장면 내 반사 구성 요소를 모델링하는 데 어려움을 겪습니다.

(그림 1 참조). 이 문제는 주로 저차 구면 고조파(SH)의 제한된 기능에서 비롯됩니다.

[†] 교신저자.

제38차 신경정보처리시스템 컨퍼런스(NeurlPS 2024).

arXiv:2402.15870v2 [cs.CV] 2024년 10월 2일

--- 페이지 2 ---

우리 것 (31.60dB)

3D-GS(25.48dB) 3D-GS(27.04dB) 비계(32.46dB) 우리 것(37.50dB) Ground Truth

그림 1: 우리의 방법은 실시간 렌더링을 달성할 뿐만 아니라

반사광 및 이방성 구성 요소가 포함된 장면을 모델링하는 3D-GS의 기능입니다. 이번 강화의 핵심

성능은 각 3D 가우스의 모양을 모델링하기 위해 ASG 모양 필드를 사용하는 것입니다.

복잡한 장면과 일반 장면 모두의 렌더링 품질이 크게 향상됩니다.

이러한 시나리오에서 고주파수 정보를 캡처합니다. 결과적으로 이는 과제를 제기합니다.

3D-GS는 그림 1과 같이 반사 및 반사 성분이 포함된 장면을 모델링합니다.

이 문제를 해결하기 위해 우리는 Spec-Gaussian이라는 새로운 접근 방식을 도입했습니다.

이방성 및 반사 성분 모델링을 위한 이방성 구형 가우스(ASG) [55]

플로터를 제거하고 학습 효율성을 향상시키는 효과적인 교육 메커니즘, 그리고 앵커 -

가속 및 저장 공간 감소를 위한 기반 3D 가우시안. 구체적으로, 이 방법에는 다음이 포함됩니다.

두 가지 주요 디자인: 1) 대신 ASG 모양 필드를 활용하는 새로운 3D 가우스 표현

SH의 각 3D 가우시안의 모양을 모델링합니다. 주문이 적은 ASG는 효과적으로 모델링할 수 있습니다.

하위 SH가 얻을 수 없는 고주파 정보. 이 새로운 디자인을 통해 3D-GS는 더 많은 작업을 수행할 수 있습니다.

정적 장면에서 이방성 및 반사 구성 요소를 효과적으로 모델링합니다. 2) 거친 훈련

3D-GS에 맞게 특별히 맞춤화된 구성표는 플로터를 제거하고 학습 효율성을 높이도록 설계되었습니다.

이 전략은 초기 단계에서 저해상도 렌더링을 최적화하여 학습 시간을 효과적으로 단축합니다.

3D 가우시안의 수를 늘릴 필요가 없도록 하고 학습을 정규화하는 단계입니다.

부유물을 발생시키는 불필요한 기하학적 구조의 생성을 방지하는 프로세스입니다.

이러한 발전을 결합함으로써 우리의 접근 방식은 반사 하이라이트에 대한 고품질 결과를 렌더링할 수 있습니다.

가우시안의 효율성을 유지하면서 그림 4에 표시된 이방성. 게다가,

포괄적인 실험을 통해 우리의 방법은 3D-GS에 모델링 기능을 부여할 뿐만 아니라

반사 하이라이트뿐만 아니라 일반 벤치마크에서도 최고 수준의 결과를 달성합니다.

요약하면, 우리 작업의 주요 기여는 다음과 같습니다.

- 각 3D 가우스의 뷰 종속 모양을 모델링하는 새로운 ASG 모양 필드, 이를 통해 3D-GS는 반사광 및 이방성 구성 요소가 있는 장면을 효과적으로 표현할 수 있습니다.
 - 훈련을 효과적으로 정규화하여 플로터와 오류를 제거하는 대략적인 훈련 계획
- 실제 장면에서 3D-GS의 학습 효율성을 향상시킵니다.
- 모델의 표현 능력을 평가하기 위해 이방성 데이터셋도 만들어졌습니다.

이방성.

2 관련 업무

2.1 암시적 신경 복사장

신경 렌더링은 비교할 수 없는 뛰어난 성능으로 학계에서 상당한 관심을 끌었습니다.

사실적인 이미지를 생성하는 능력. NeRF [34]와 같은 방법은 다층 퍼셉트론을 활용합니다.

(MLP)를 사용하여 장면의 기하학 및 복사 필드를 모델링합니다. 체적 렌더링 활용

방정식과 MLP 고유의 연속성과 부드러움을 통해 NeRF는 고품질 장면을 구현합니다.

포즈를 취한 이미지 세트를 재구성하여 최신 SOTA(최신 기술) 방법으로 자리매김했습니다.

새로운 관점 합성. 후속 연구에서는 NeRF의 유용성을 다양한 응용 분야로 확장했습니다.

메쉬 재구성 [48, 24, 53, 31], 역 렌더링 [44, 66, 28, 57], 최적화 포함

카메라 매개 변수 [26, 50, 49, 38], 소수 학습 [11, 56, 52] 및 안티 앨리어싱 [2, 1, 3].

그러나 이러한 방법 스트림은 래스터화가 아닌 광선 캐스팅을 사용하여 색상을 결정합니다.

각 픽셀의. 결과적으로 광선을 따라 있는 모든 샘플링 지점에서는 MLP를 쿼리해야 합니다.

렌더링 속도가 상당히 느려지고 훈련 수렴이 길어집니다. 이 제한

대규모 장면 모델링 및 실시간 렌더링에 적용하는 데 상당한 방해가 됩니다.

2

--- 페이지 3 ---

SfM포인트

3D 가우스 밀도화류 의존적 외관 모델링

...ZSH

... ASG

그림 2: Spec-Gaussian의 파이프라인. 최적화 프로세스는 다음에서 파생된 SfM 포인트로 시작됩니다.

COLMAP 또는 무작위로 생성되어 3D 가우스의 초기 상태 역할을 합니다. 문제를 해결하려면

고주파수 정보 모델링에서 저차 SH 및 순수 MLP의 한계를 추가로

뷰 종속 모양을 모델링하기 위해 기능 분리 MLP와 함께 ASG를 사용합니다.

각 3D 가우스의 그런 다음 불투명도가 > 0 인 3D 가우스가 미분 가능 함수를 통해 렌더링됩니다.

가우스 래스터화 파이프라인은 장면의 반사광 하이라이트와 이방성을 효과적으로 캡처합니다.

MLP 기반 NeRF 방법의 학습 시간을 줄이고 렌더링 속도를 향상시키기 위해 후속

이 작업은 다양한 방식으로 NeRF의 효율성을 향상시켰습니다. 구조 기반 기술 [63, 12, 40, 15, 7]

암시적 신경망을 캐싱하거나 증류하여 추론 또는 훈련 효율성을 향상시키려고 노력해 왔습니다.

보다 효율적인 데이터 구조로 표현됩니다. 하이브리드 방법 [27, 45]은 다음과 같이 효율성을 높입니다.

명시적인 복셀 기반 데이터 구조를 통합합니다. 인수분해 방법[5, 16, 8, 14]은 낮은 인수분해 방법을 적용합니다.

장면을 저차원 평면이나 벡터로 분해하기 위한 순위 텐서 가정

더 나은 기하학적 일관성. 연속적인 암시적 표현과 비교하여 수렴은

그리드의 개별 복셀 수가 독립적이므로 훈련 시간이 크게 단축됩니다. 추가적으로,

Instant-NGP [35]는 더 빠른 기능을 위해 해당 CUDA 구현과 함께 해시 그리드를 활용합니다.

쿼리를 통해 신경 복사 필드에 대한 신속한 훈련과 대화형 렌더링이 가능합니다. 스펙-NeRF [32]

가우스인 방향 인코딩을 도입하여 고품질 경반사 모델링을 구현합니다.

더 높은 품질과 더 빠른 렌더링을 달성했음에도 불구하고 이러한 방법은 근본적으로 과도한 작업을 수행하지 못했습니다.

레이 캐스팅과 관련된 상당한 쿼리 오버헤드가 발생합니다. 결과적으로 눈에 띄는 격차가 남아있다.

실시간 렌더링을 달성하기 전에. 이 연구에서 우리는 최근 3D-GS[20]를 기반으로 다음과 같은 점을 제시합니다.

래스터화를 활용하는 기반 렌더링 방법입니다. 레이캐스팅 기반의 방식에 비해

훈련 속도와 렌더링 속도가 모두 크게 향상됩니다.

2.2 포인트 기반 신경 복사장

삼각형 메쉬 기반 방법과 유사한 점 기반 표현은 매우 효율적인 방법을 활용할 수 있습니다.

실시간 렌더링을 달성하기 위한 최신 GPU의 래스터화 파이프라인. 이러한 방법은

엄청난 렌더링 속도와 편집 작업에 적합하며 종종 구멍과

이상치로 인해 렌더링된 이미지에 아티팩트가 발생합니다. 이 문제는 점의 이산적 특성에서 발생합니다.

프리미티브와 결과적으로 렌더링된 이미지에 틈이 생길 수 있습니다.

이러한 불연속성 문제를 해결하기 위해 미분 가능한 점 기반 렌더링 [62, 13, 21, 22]이

복잡한 기하학적 모양을 맞추기 위해 광범위하게 탐구되었습니다. 특히, Zhang et al. [65] 고용하다

미분 가능한 표면 스피클링을 수행하고 RBF(방사형 기초 함수) 커널을 활용하여 계산합니다.

각 픽셀에 대한 각 포인트의 기여도입니다.

최근 3D-GS[20]는 Structure from Motion에서 초기화된 이방성 3D 가우스를 사용했습니다.

(SfM), 3D 장면을 나타냅니다. 혁신적인 치밀화 메커니즘과 CUDA 맞춤형

3D-GS의 미분 가능한 가우스 래스터화 파이프라인은 최첨단 기술을 달성했을 뿐만 아니라

(SOTA) 렌더링 품질도 실시간 렌더링의 한계점을 훨씬 뛰어넘었습니다.

많은 동시 작업으로 3D-GS가 다양한 다운스트림 응용 프로그램으로 빠르게 확장되었습니다.

동적 장면 포함 [30, 58, 59, 17, 23], 텍스트-3D 생성 [25, 46, 9, 61, 10], 아바타

[68, 67, 18, 41, 37], 장면 편집 [54, 6] 및 품질 향상 [33].

일반적으로 사용되는 벤치마크 데이터세트에서 SOTA 결과를 달성했음에도 불구하고 3D-GS는 여전히 어려움을 겪고 있습니다.

반사광 및 반사 구성요소가 있는 모델 장면으로 인해 실제 적용이 제한됩니다.

사실적인 수준의 실시간 렌더링. 본 연구에서는 구형고조파(SH)를 대체하여

3

--- 페이지 4 ---

이방성 구형 가우스(ASG) 모양 필드를 사용하여 3D-GS를 활성화하여 모델링했습니다.
복잡한 반사광 장면을 더욱 효과적으로.

3 방법

우리 방법의 개요는 그림 2에 설명되어 있습니다. 모델에 대한 입력은 일련의 포즈를 취한 이미지입니다.
SfM [42]에서 얻은 희박한 포인트 클라우드와 함께 정적 장면. 우리 방식의 핵심
3D 가우시안의 모양을 모델링할 때 SH를 대체하기 위해 ASG 모양 필드를 사용하는 것입니다(Sec.
3.2). 또한, 플로터를 줄이기 위해 간단하면서도 효과적인 대략적인 학습 전략을 소개합니다.

실제 장면에서(섹션 3.3). 스토리지 오버헤드와 렌더링 속도 압박을 더욱 줄이기 위해
ASG에서 도입한 희소 앵커 가우스를 사용하는 하이브리드 가우스 모델을 결합하여
3D 장면을 모델링하기 위해 신경 가우스 생성(초 3.4)을 촉진합니다.

3.1 예선

3D 가우스 스피래팅. 3D-GS[20]는 이방성 3D 가우시안을 사용하는 포인트 기반 방법이다.
장면을 표현하기 위해 각 3D 가우스는 중심 위치 x , 불투명도 및 3D로 정의됩니다.
공분산 행렬 는 쿼터니언 r 과 스케일링 s 로 분해됩니다. 뷰 의존적
각 3D 가우스의 모양은 처음 세 차수의 구면 고조파를 사용하여 표현됩니다.
(SH). 이 방법은 체적 렌더링이 제공하는 렌더링 세부 정보를 유지할 뿐만 아니라
CUDA 맞춤형 미분 가능 가우스 래스터화를 통해 실시간 렌더링을 달성합니다.
프로세스. [69]에 따르면 3D 가우스는 2D 공분산 행렬 '을 사용하여 2D로 투영될 수 있습니다.
다음과 같이 정의됩니다:

$$' = J V \quad V T J T, (1)$$

여기서 J 는 사영 변환의 아핀 근사의 야코비안이고, V 는
월드 좌표에서 카메라 좌표로 변환되는 뷰 매트릭스. 학습을 용이하게 하기 위해 3D
공분산 행렬 는 두 개의 학습 가능한 구성요소, 즉 쿼터니언 r 로 분해됩니다.
회전 및 스케일링을 나타내는 3D 벡터입니다. 결과 는 다음과 같이 표현됩니다.
회전 행렬 R 과 스케일링 행렬 S 의 조합은 다음과 같습니다.

$$= R S S T R T. (2)$$

그런 다음 이미지 평면의 각 픽셀 색상은 포인트 기반 볼륨 측정을 통해 렌더링됩니다.
렌더링(알파 블렌딩) 기술:

$$C(p) =$$

X

나는 $\in N$

$$T_i \text{ } i c_i, \quad i = i e \quad 1$$

$$2(p \quad i) T P \quad 1(p \quad i), (3)$$

여기서 p 는 픽셀 좌표를 나타내고, T_i 는 $i \quad 1$ 로 정의되는 투과율입니다.

$j=1(1 \quad j)$, c_i 는 다음을 의미합니다.

쿼리된 픽셀과 관련된 정렬된 가우스의 색상, μ_i 는 좌표를 나타냅니다.

2D 이미지 평면에 투영될 때 3D 가우시안의.

이방성 구형 가우스. 이방성 구형 가우스(ASG)[55]가 설계되었습니다.

조명과 음영을 효율적으로 근사화하기 위해 기존 렌더링 파이프라인을 사용합니다. 와는 다르다
구형 가우스(SG), ASG는 이방성 장면을 효과적으로 표현하는 것으로 입증되었습니다.

작은 숫자로. ASG는 SG의 기본 특성을 유지하는 것 외에도

회전 불변성을 가지며 전체 주파수 신호를 나타낼 수 있습니다. ASG 함수는 다음과 같이 정의됩니다.

$$ASG([x, y, z], [\mu], \mu) = S(\mu; z) \cdot e^{-\frac{1}{2}(\mu \cdot x)^2 - \frac{1}{2}(\mu \cdot y)^2} \quad (4)$$

여기서 μ 는 함수 입력으로 사용되는 단위 방향입니다. x, y, z 는 접선에 해당하며,

bi-tangent 및 lobe 축은 각각 서로 직교합니다. $\mu \in R^1$ 및 $\mu \in R^1$ 은

x 축과 y 축에 대한 선명도 매개변수($\mu > 0$ 을 충족함) $\mu \in R^2$ 는 로브 진폭입니다. S 는

$S(\mu; z) = \max(\mu \cdot z, 0)$ 으로 정의된 평활함.

복잡한 이방성이 있는 장면을 모델링하는 ASG의 힘에서 영감을 받아 우리는 다음과 같은 통합을 제안합니다.

ASG를 가우스 스피래팅으로 변환하여 새로운 렌더링 파이프라인을 통해 클래식 모델의 힘에 합류

더 높은 품질. N 개 ASG의 경우 정규 직교 축 x, y, z 를 미리 정의하여 다음과 같이 초기화했습니다.

반구 전체에 균일하게 분포됩니다. 훈련 중에는 나머지 ASG 매개변수를 허용합니다.

μ, μ 는 학습 가능합니다. 모델링을 위해 ASG를 쿼리하기 위한 입력으로 반사 방향 r 을 사용합니다.

뷰 의존적 반사 정보. 각 3D 가우스에 대해 $N = 32$ ASG를 사용합니다.

4

--- 페이지 5 ---

앵커 기반 가우스 스피래팅. 앵커 기반 가우스 스피래팅은 다음과 같이 처음 제안되었습니다.

비계-GS [29]. 3D-GS의 각 엔터티가 전달하는 속성과 달리 각 앵커 가우스만

위치 좌표 $P_v \in R^3$, 로컬 특징 $f_v \in R^{32}$, 변위 계수 $v \in R^3$ 및

k 학습 가능한 오프셋 $O_v \in R^{k \times 3}$. COLMAP [42] 포인트 클라운드를 사용하여 각 앵커 3D를 초기화합니다.

가우스는 신경 가우스 생성을 안내하는 복셀 중심 역할을 합니다. 위치 P_v

앵커 가우스안은 다음과 같이 초기화됩니다.

$P_v =$

P_i

$+ 0.5$

$\cdot$, (5)

여기서 P 는 포인트 클라운드의 위치, μ 는 복셀 크기, $\{ \}$ 는 중복된 앵커 제거를 나타냅니다.

그런 다음 앵커 가우스는 동일한 속성을 갖는 신경 가우스 생성을 안내할 수 있습니다.

바닐라 3D-GS로. 보기 절두체 내의 각 보이는 앵커 가우스에 대해 k 개의 신경을 생성합니다.

가우스를 분석하고 해당 속성을 예측합니다. 신경 가우스의 위치 x 는 다음과 같이 계산됩니다.

$$\{x_0, \dots, x_{k-1}\} = P_v + \{O_0, \dots, O_{k-1}\} \cdot e_{tav}, \quad (6)$$

여기서 P_v 는 k 개의 신경 가우스에 해당하는 앵커 가우스의 위치를 나타냅니다. e_{tav} 는

불투명도 τ 는 작은 MLP를 통해 계산됩니다.

$$\{ \tau_0, \dots, \tau_{k-1} \} = F(\tau_v, \tau_{cv}, \tau_{dcv}), \quad (7)$$

여기서 τ_{cv} 는 앵커 가우스와 카메라 사이의 거리를 나타내고 τ_{dcv} 는 단위입니다.

카메라에서 앵커 가우스안을 가리키는 방향입니다. 각각의 회전 r 과 스케일링 s

신경 가우스는 해당하는 작은 MLP F_r 및 F_s 를 사용하여 유사하게 파생됩니다.

3.2 이방성 뷰 종속 모양

3D 가우스에 대한 ASG 표시 필드입니다. SH가 뷰 종속 장면을 활성화했지만

모델링 시, 저차 SH의 저주파는 복잡한 장면을 모델링하기 어렵게 만듭니다.

반사 하이라이트 및 이방성 효과와 같은 광학 현상. 따라서 사용하는 대신

SH, 우리는 Eq.를 기반으로 ASG 출현 필드 사용을 제안합니다. (4) 각 3D의 외관을 모델링하기 위해

가우스. 그러나 ASG의 도입으로 각 3D 가우스안의 특징 크기가 증가하고,

모델의 저장 오버헤드를 늘립니다. 이 문제를 해결하기 위해 우리는 학습 가능한 소형 MLP μ 를 사용합니다.

각 가우스가 추가 로컬 기능만 전달하는 N 개의 ASG에 대한 매개변수를 예측합니다.

$f \in R^{24}$ 를 MLP에 대한 입력으로 사용:

$$(f) \rightarrow \{ \mu, \mu_i \} N. (8)$$

고주파 정보와 저주파 정보를 더 잘 구별하고 ASG의 피팅을 지원하기 위해
고주파수 반사 색상 세부 사항에 대해 색상 c 를 확산 및 반사 구성 요소로 분해합니다.

$$c = c_d + c_s, (9)$$

여기서 c_d 는 SH의 처음 세 차수를 사용하여 모델링된 확산 색상을 나타내고, c_s 는 반사광을 나타냅니다.
ASG를 통해 계산된 색상입니다. 우리는 외관 모델링에 대한 이러한 포괄적인 접근 방식을 다음과 같이 지칭합니다.
ASG 모양 필드.

ASG는 이론적으로 이방성을 모델링하는 SH의 능력을 향상시키지만 ASG를 직접 사용하여
각 3D 가우스의 반사 색상을 표현하는 것은 이방성을 정확하게 모델링하는 데 여전히 부족합니다.
그림 6에서 볼 수 있듯이 반사 구성 요소. [14]에서 영감을 받아 ASG를 직접 사용하지 않습니다.
색상을 표현하는 대신 ASG를 사용하여 각 3D 가우스의 잠재 기능을 모델링합니다. 이
이방성 정보를 포함하는 잠재 특징은 MLP를 디코딩하는 작은 특징에 공급되어
최종 반사 색상을 결정합니다.

$$(\mathbf{r}, \mathbf{d}, \mathbf{n}, \mathbf{d}) \rightarrow c_s,$$

$$=$$

뉴멕시코

나는=1

$$ASG(\mathbf{r} | [x, y, z], [\mu_i, \mu_i], \mathbf{i}) (10)$$

여기서 $\mathbf{r}$ 는 ASG에서 파생된 잠재 특징이고, L 은 연결 작업을 나타내고, $\mathbf{n}$ 은
위치 인코딩, $\mathbf{d}$ 는 카메라에서 각 3D 가우스를 가리키는 단위 뷰 방향입니다.
 $\mathbf{n}$ 은 각 3D 가우스의 법선이고, $\mathbf{r}$ 은 반사 방향의 단위입니다. 이 전략은 크게
복잡한 광학 현상이 있는 장면을 모델링하는 3D-GS의 능력을 향상시킵니다.
순수 ASG나 순수 MLP는 우리의 접근 방식만큼 효과적으로 이방성 모양 모델링을 달성할 수 있습니다.
5

--- 페이지 6 ---

표 1: 이방성에 대한 정량적 비교

합성 데이터 세트.

데이터 세트 이방성 합성 방법 PSNR↑ SSIM↑ LPIPS↓ FPS Mem Num.(k) 3D-GS 33.82 0.966 0.062 325 47MB
201Scaffold-GS 35.34 0.972 0.052 234 27MB - 앵커 포함 36.76 0.976 0.046 180 25MB - 우리 빛 37.42 0.979
0.044 159 45MB 146 우리 빛 37.70 0.980 0.042 145 57MB 183

훈련 시대

렌더링파이프라인...

w/o 거친 것부터 가는 것까지

w/거친 것에서 미세한 것 그림 3: 거친 것에서 미세한 것 전략을 사용하여,
우리의 접근 방식은 플로터를 제거할 수 있습니다.

GS 수를 늘리지 않고.

정상적인 추정. [19, 43]에 따라 각 가우시안의 가장 짧은 축을 법선으로 사용합니다.
이 접근 방식은 3D 가우시안이 작업 중에 점차적으로 편평해지는 경향이 있다는 관찰에 기초합니다.

최적화 프로세스를 통해 가장 짧은 축이 법선에 대한 합리적인 근사치 역할을 할 수 있습니다.
반사 방향 $\mathbf{r}$ 은 뷰 방향과 로컬 법선 벡터 $\mathbf{n}$ 을 사용하여 다음과 같이 파생될 수 있습니다.

$$\mathbf{r} = 2(\mathbf{w}_o \cdot \mathbf{n}) \cdot \mathbf{n} - \mathbf{w}_o, (11)$$

여기서 $\mathbf{w}_o = \mathbf{d}$ 는 월드 공간의 각 3D 가우스에서 다음을 가리키는 단위 뷰 방향입니다.
카메라. 반사 방향 $\mathbf{r}$ 을 사용하여 ASG를 쿼리하여 잠재 기능을 더 효과적으로 보간할 수 있습니다.
이방성 정보가 포함되어 있습니다. 실험 결과는 비록 이것이 감독되지 않은 정상임에도 불구하고
추정으로는 실제 세계와 일치하는 물리적으로 정확한 법선을 생성할 수 없습니다.

ASG가 고주파수 정보를 맞추는 데 도움이 되도록 상대적으로 정확한 반사 방향을 생성합니다.

3.3 대략적인 훈련

우리는 많은 실제 시나리오에서 3D-GS가 훈련 데이터에 과적합되는 경향이 있다는 것을 관찰했습니다.

새로운 관점에서 이미지를 렌더링할 때 수많은 플로터의 출현. 한 가지 중요한

그 이유는 COLMAP 포인트 클라우드가 너무 희박하기 때문입니다. 잘못된 초기화로 인해

3D-GS는 최적화 중 치밀화를 통해 지나치게 희박한 영역을 보완하여

렌더링 이미지의 플로터. 또한 3D-GS는 각 픽셀에서 GS까지 그래디언트를 누적합니다.

dL

$dx = PdL$

dpi

dpi

dx , 누적량이 임계값을 초과하면 치밀화가 발생합니다.

$g = 0.0002$. 그러나 양수 및 음수 기울기를 사용하면 밀도가 높아져야 하는 GS가 발생할 수 있습니다.

음의 기울기가 크기 때문에 무시됩니다.

따라서 실제 장면에서 플로터의 발생을 완화하기 위해 우리는 대략적인 훈련을 제안합니다.

메커니즘. 먼저 픽셀에서 GS: dL 까지의 그래디언트에 L1 제약 조건을 적용합니다.

$dx = P | dL$

dpi

dpi

dx_{rr1} ,

그래디언트가 아닌 픽셀에서 GS로의 수치적 기여를 누적합니다. 이 아이디어도 비슷해요

동시 작업 [60, 64]. 다음으로 3D-GS의 과도한 성장으로 인한 Overfitting을 방지하기 위해

최적화 초기 단계에서 우리는 3D-GS를 낮은 수준에서 높은 수준으로 점진적으로 훈련하기로 결정했습니다.

실제 장면의 해상도:

$r(i) = \min(r_s + (r_e - r_s) \cdot i / \dots, r_e)$, (12)

여기서 $r(i)$ 는 i 번째 훈련 반복에서의 이미지 해상도이고, r_s 는 시작 이미지 해상도입니다.

는 최종 이미지 해상도(렌더링하려는 전체 해상도)이고 는 임계값 반복입니다.

경험적으로는 5k로 설정되었습니다.

이 훈련 방법을 사용하면 3D-GS가 올바르게 조밀화되고 3D-GS의 과도한 성장을 방지할 수 있습니다.

초기 단계. 또한 초기 단계의 낮은 해상도 훈련으로 인해 이 메커니즘은

훈련 시간을 약 10% 단축합니다. 실험에서는 성능 버전을 제공합니다.

$g = 0.0005$ 이고 라이트 버전은 $g = 0.0006$ 입니다.

3.4 앵커 기반 가우스 스피래팅에 대한 적응

ASG 출현 필드는 3D-GS의 반사광 및 반사광 모델링 능력을 크게 향상시킵니다.

이방성 기능을 사용하면 추가 로컬로 인해 추가 계산 오버헤드가 발생합니다.

각 가우스와 연관된 특징 f . [29]에서 영감을 받아 앵커 기반 가우시안을 사용합니다.

스플래팅을 사용하여 스토리지 오버헤드를 줄이고 렌더링 속도를 높입니다.

ASG로 모델링한 이방성은 공간에서 연속적이므로 더 낮은 차원으로 압축할 수 있습니다.

차원 공간. 앵커 가우시안의 안내 덕분에 앵커 특징 f_v 는 다음과 같습니다.

6

--- 페이지 7 ---

28.83/0.06129.29/0.029 33.00/0.01630.55/0.02729.75/0.034Tri-MipRF3D-GSScaffold-GSGS-ShaderOursGT

그림 4: NeRF 데이터 세트의 시각화. 우리의 방법은 반사광 하이라이트 모델링을 달성했습니다.

빠른 렌더링 속도를 유지하면서 다른 3D-GS 기반 방법은 달성하지 못하는 것입니다.

데이터세트 Mip-NeRF 360 Mip-NeRF 360 실외Mip-NeRF 360 실내방식 | 지표PSNR↑ SSIM↑ LPIPS↓ FPS 메모리 PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

플레녹셀 23.08 0.626 0.463 6.79 2.1GB 21.68 0.513 0.491 24.83 0.766 0.426iNGP 25.59 0.699 0.331 9.43
 48MB 22.75 0.567 0.403 29.14 0.863 0.242Mip-NeRF36027.69 0.792 0.237 0.06 8.6MB 24.47 0.691 0.283
 31.72 0.917 0.1803D-GS 27.79 0.826 0.202 115 748MB 25.02 0.742 0.232 31.25 0.931 0.164Scaffold-GS
 27.98 0.824 0.207 96 203MB 25.07 0.736 0.243 31.61 0.933 0.162
 우리의 앵커 포함28.14 0.824 0.196 70 260MB 24.98 0.735 0.223 32.09 0.935 0.161우리의 빛 28.07 0.834
 0.183 44 684MB 25.09 0.752 0.203 31.80 0.936 0.158우리 28.18 0.835 0.176 33 847MB 25.11 0.754 0.195
 32.01 0.937 0.153

표 2: 실제 데이터 세트의 정량적 비교. PSNR, SSIM, LPIPS를 보고합니다.

(VGG) 각 셀에 best, second best 및 third best로 색상을 지정합니다. 우리의 방법은 최고를 달성했습니다.
 렌더링 품질을 유지하면서 FPS와 저장 메모리 간의 균형을 잘 유지합니다.

N-ASG를 압축하는 데 직접 사용되어 저장 압력을 더욱 줄입니다. 신경의 ASG를 만들기 위해
 가우시안 위치 인식, ASG 매개변수의 압축을 풀기 위해 유닛 뷰 방향을 도입합니다.

결과적으로 Eq.의 ASG 매개변수 예측은 다음과 같습니다. (8)은 다음과 같이 수정됩니다.

$$(f_v, d_{cn}) \rightarrow \{ \mu, \Sigma \}, (13)$$

여기서 d_{cn} 은 카메라에서 각 신경 가우스까지의 단위 뷰 방향을 나타냅니다. 추가적으로,
 MLP를 통해 직접 예측된 신경 가우스 $cd = (f_v)$ 의 확산 부분을 다음과 같이 설정합니다.

확산 구성 요소의 매끄러움을 보장하고 수렴의 어려움을 줄입니다.

3.5 손실

우리는 3D-GS[20]와 동일한 손실 함수를 사용하여 학습 가능한 매개변수와 MLP를 최적화합니다. 는
 전체 감독은 다음과 같이 제공됩니다.

$$L = (1 - \lambda) D\text{-SSIM} + \lambda D\text{-SSIM} L1 + D\text{-SSIM} L2\text{-SSIM}, (14)$$

여기서 $\lambda = 0.2$ 는 실험에서 일관되게 사용됩니다.

4가지 실험

이 섹션에서는 우리 방법의 정량적 결과와 정성적 결과를 모두 제시합니다. 그것을 평가하려면
 효율성을 높이기 위해 이를 다양한 데이터 세트의 여러 가지 최첨단 방법과 비교했습니다. 우리는 색칠한다
 각 셀은 최고, 두 번째로 최고, 세 번째로 최고입니다. 우리의 방법에는 세 가지 버전이 포함되어 있으며 각 버전은 다음을
 기반으로 합니다.

고유한 하이퍼파라미터 설정을 사용하는 다양한 기본 방법을 사용합니다. 퍼포먼스 버전

(우리의 것)은 $\lambda = 0.0005$ 인 3D-GS[20]를 기반으로 합니다. 라이트 버전(Ours-light)도 다음을 기반으로 합니다.

3D-GS는 $\lambda = 0.0006$ 입니다. 미니 버전(앵커 포함 Ours)은 Scaffold-GS를 기반으로 합니다[29].

$\lambda = 0.0006$ 입니다. 우리의 방법은 복잡한 반사광 모델링에서 탁월한 성능을 보여줍니다.

NeRF, NSVF 및 "이방성"에 대한 비교를 통해 입증된 이방성 특징

합성' 데이터세트. 또한 확산 성능을 비교하여 다재다능함을 보여줍니다.

시나리오를 통해 우리 접근 방식의 견고성을 더욱 입증했습니다.

7

--- 페이지 8 ---

표 3: NeRF 합성 데이터 세트에 대한 결과.

NeRF 합성 데이터세트

방법 | 측정항목 PSNR↑ SSIM↑ LPIPS↓ FPS 메모리

iNGP-Base 33.18 0.963 0.045 10 13MB

Mip-NeRF 33.09 0.961 0.043 <1 10MB

트라이-MipRF 33.65 0.963 0.042 5 60MB

3D-GS 33.32 0.969 0.031 315 69MB

GS-셰이더 33.38 0.968 0.030 97 29MB

비계-GS 33.68 0.967 0.034 240 19MB

우리 것-앵커 포함 33.96 0.969 0.032 172 19MB

우리의 빛 34.08 0.970 0.029 148 58MB

우리 것 34.19 0.971 0.028 121 72MB

표 4: NSVF 합성 데이터 세트에 대한 결과.

데이터세트 NSVF 합성

방법 | 측정항목 PSNR↑ SSIM↑ LPIPS↓ FPS 메모리

텐소RF 36.52 0.982 0.026 1.5 65MB

트라이-MipRF 34.58 0.973 0.030 5 60MB

NeuRBF 37.80 0.986 0.019 1 580MB

3D-GS 37.07 0.987 0.015 306 71MB

GS-셰이더 33.85 0.981 0.020 68 33MB

비계-GS 36.43 0.984 0.017 218 17MB

우리 것-앵커 포함 37.71 0.987 0.015 152 16MB

우리의 빛 38.28 0.988 0.013 124 70MB

우리 것 38.40 0.988 0.012 108 89MB

Mip-NeRF 360 3D-GS 비계-GS 우리 GT

그림 5: Mip-NeRF 360 실내 장면 시각화. 우리의 방법은 뛰어난 회수율을 달성합니다

SOTA 방법과 비교한 반사 효과.

4.1 구현 세부 사항

우리는 PyTorch[39]를 사용하여 프레임워크를 구현하고 미분 가능한 가우스 래스터를 수정했습니다.

깊이 시각화를 포함하도록 설정합니다. ASG 출현 필드의 경우 디커플링 MLP 는 다음과 같이 구성됩니다.

3개의 레이어로 구성되며 각 레이어에는 64개의 숨겨진 유닛이 있으며 뷰 방향에 대한 위치 인코딩은 순서대로 이루어집니다.

2. 부유물을 제거하기 위해 실제 장면에만 적용하는 Coarse-to-Fine 훈련에 대해,

4배 다운샘플링된 해상도 rs로 시작합니다. 렌더링 속도를 더욱 높이기 위해 사전 필터링을 수행합니다.

불투명도가 $n > 0$ 인 가우스만 ASG 모양 필드를 통과하도록 허용하고

가우스 래스터화 파이프라인. 모든 실험은 NVIDIA RTX 3090에서 수행되었습니다.

4.2 결과 및 비교

합성 경계 장면. 우리는 NeRF, NSVF 및 "Anisotropic Synthetic" 데이터세트를 다음과 같이 사용했습니다.

합성 장면에 대한 실험 데이터 세트. 우리의 비교는 가장 관련성이 높은 것으로 이루어졌습니다.

3D-GS [20], Scaffold-GS [29], GaussianShader [19] 및 여러 가지를 포함한 최첨단 방법

NSVF [27], TensorRF [5], NeuRBF [8] 및 Tri-MipRF [16]와 같은 NeRF 기반 방법.

그림 4(PSNR 및 LPIPS 포함) 및 탭에 표시된 대로. 3-4, 우리의 방법은 가장 높은 수준을 달성했습니다.

바닐라 3D-GS에 비해 더 적은 가우시안으로 성능을 발휘합니다. 또한, 다음과 같은 문제도 개선되었습니다.

고주파수 반사 하이라이트와 복잡한 이방성을 모델링하는 데 직면한 3D-GS

탭. 1은 가우시안 수가 적고 측정항목이 더 좋습니다. 자세한 내용은 보충 자료를 참조하세요.

현실 세계의 무한한 장면. 실제 시나리오에서 우리 방법의 다양성을 확인하기 위해

반사 하이라이트가 있는 실내 장면이 포함된 Mip360 [2] 데이터 세트를 사용했습니다. 에 표시된 바와 같이

탭. 2, 우리의 방법은 Mip-NeRF 360의 최첨단 방법을 능가합니다. 또한 우리의 방법은

FPS, 스토리지, 렌더링 품질의 균형을 효과적으로 유지합니다. 없이 렌더링 품질을 향상시킵니다.

스토리지를 늘리거나 FPS를 크게 줄입니다. 그림 5와 그림 7에서 볼 수 있듯이, 우리의 방법은

시각적 효과도 크게 향상되었습니다. 야외 장면에서 대량의 부유물을 제거합니다.

실내 장면의 고주파수 반사 하이라이트를 성공적으로 모델링했습니다. 이것은 보여줍니다

우리의 접근 방식은 복잡한 반사 장면을 모델링하는 데 능숙할 뿐만 아니라 효과적으로 개선합니다.

일반적인 시나리오에서의 렌더링 품질.

4.3 절제 연구

ASG 기능은 MLP를 분리합니다. 우리는 핵심 구성 요소를 평가하기 위해 절제 연구를 수행했습니다.

ASG 기능, MLP 분리 및 분리를 포함하는 ASG 출현 필드

8

--- 페이지 9 ---

28.52/0.04130.66/0.035 37.50/0.01833.92/0.02334.95/0.0233D-GS(6-SHScaffold 포함, 4레이어 포함)MLPOurs(ASGOursGT 제외)

28.59/0.099 29.78/0.07728.48/0.09527.99/0.10229.21/0.088

그림 6: ASG 모양 필드의 절제. ASG를 직접 사용하여 색상을 모델링하는 것을 보여줍니다.

이로 인해 이방성 및 반사 하이라이트 모델링이 실패하게 됩니다. ASG 기능을 분리하여 MLP를 통해 복잡한 광학 현상을 현실적으로 모델링할 수 있습니다.

3D-GSScaffoldOurs(c2f 없음)L1 Norm 없음OursGT

0.246/4531k0.286/1600k0.265/5166k0.218/4512k0.180/4447k

그림 7: 대략적인 훈련에 대한 절제. 실험 결과는 우리의 단순하면서도

효과적인 훈련 메커니즘으로 3D 수를 늘리지 않고도 부유물을 효과적으로 제거할 수 있습니다.

Gaussian은 3D-GS 기반 방법에서 널리 퍼져 있는 과적합 문제를 완화합니다.

확산색과 반사색. 그림 6(PSNR 및 LPIPS 포함)에서 볼 수 있듯이 ASG를 직접 사용하여

색상을 출력하면 반사광 및 이방성 구성 요소를 모델링할 수 없게 됩니다. 대조적으로

Scaffold-GS [29]에서와 같이 색상 모델링을 위해 MLP를 직접 사용하여 확산 및 분산을 별도로 모델링합니다.

반사광 색상은 고주파수 정보에 대한 피팅 능력을 향상시킬 수 있습니다. ASG는 더 높은 수준으로 인코딩할 수 있습니다.

주파수 이방성 특징. ASG의 고주파 이방성 인코딩 능력 덕분에

기능을 통해 디커플링 MLP는 복잡한 광학 현상에 적합하여 보다 정확한 렌더링을 가능하게 합니다.

결과. 우리는 또한 고차 SH(6차)와 더 많은 MLP 레이어(4레이어)가 그렇지 않음을 입증했습니다.

3D-GS와 Scaffold-GS가 만족스러운 결과를 얻을 수 있도록 도와주며 ASG의 중요성을 강조합니다.

대략적인 학습부터 미세한 학습까지. 우리는 거친 입자에서 미세한 입자(c2f)의 영향을 평가하기 위해 절제 연구를 수행했습니다.

훈련. 그림 7(LPIPS 및 Gaussian 수 포함)에서 볼 수 있듯이 3D-GS와 Scaffold-GS는 모두

새로운 뷰 합성에서 많은 수의 플로터를 나타냅니다. 효과적인 Coarse-to-Fine 학습

플로터 수를 줄여 3D-GS에서 흔히 발생하는 과적합 문제를 완화합니다.

실제 시나리오. 3D-GS 치밀화에 사용되는 기율기에 L1 제약 조건 적용

플로터와 가우시안의 수를 줄였습니다. 자세한 내용은 보충 자료를 참조하세요.

5 결론

이 연구에서는 3D 가우스 분할에 대한 새로운 접근 방식인 Spec-Gaussian을 소개합니다.

이방성 뷰 종속 모양. ASG의 강력한 역량을 활용하여

방법은 장면을 렌더링할 때 바닐라 3D-GS가 직면한 문제를 효과적으로 극복합니다.

반사 하이라이트 및 이방성. 또한, 우리는 거친 것부터 미세한 것까지의 훈련을 혁신적으로 구현합니다.

실제 장면에서 플로터를 제거하는 메커니즘입니다. 정량적 실험과 정성적 실험 모두

우리의 방법은 3D-GS에 반사 하이라이트를 모델링할 수 있는 기능을 제공할 뿐만 아니라

이방성을 향상시킬 뿐만 아니라 일반 장면에서 3D-GS의 전반적인 렌더링 품질도 향상시킵니다.

제한 사항. 우리의 방법을 사용하면 3D-GS가 복잡한 반사 및 이방성을 모델링할 수 있지만

기능이 있지만 반사를 처리하는 데 여전히 어려움을 겪고 있습니다. 반사광 및 이방성 효과는 주로

반사는 환경과 밀접한 관련이 있는 반면, 재료 특성의 영향을 받습니다.

기하학. 3D-GS에는 명시적인 기하학이 없기 때문에 반사를 구별할 수 없습니다.

Ref-NeRF [47] 및 NeRO [28]에 사용된 것처럼 법선과 같은 제약 조건을 사용하는 재료. 우리

향후 작업에서 3D-GS를 사용한 반사 모델링 솔루션을 탐색할 계획입니다.

9

--- 페이지 10 ---

6 감사의 말씀

반박 기간 동안 도움을 주신 Cornell University의 Chao Wan 학생에게 감사드립니다. 이 작품은 중국 국립자연과학재단(보조금 번호 62036010)의 지원을 받습니다. 양쯔이 ByteDance MMLab에서도 지원되었습니다.

참고자료

- [1] Jonathan T. Barron, Ben Mildenhall, Matthew Tancik, Peter Hedman, Ricardo Martin-Brualla 및 Pratul P. Srinivasan. Mip-nerf: 앤티앨리어싱 신경 방사 필드에 대한 다중 스케일 표현입니다. ICCV, 2021.
- [2] Jonathan T Barron, Ben Mildenhall, Dor Verbin, Pratul P Srinivasan 및 Peter Hedman. mip nerf 360: 무제한 앤티앨리어싱 신경 방사 필드. IEEE/CVF 컴퓨터 회의 진행 중
비전 및 패턴 인식, 페이지 5470-5479, 2022.
- [3] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan 및 Peter Hedman. 우편 너프: 앤티앨리어싱된 그리드 기반 신경 방사 필드. ICCV, 2023.
- [4] Mario Botsch, Alexander Hornung, Matthias Zwicker 및 Leif Kobbelt. 고품질 표면 스피래팅
오늘의 GPU In Proceedings Eurographics/IEEE VGTC 심포지엄 포인트 기반 그래픽, 2005., 페이지 17-141. IEEE, 2005.
- [5] Anpei Chen, Zexiang Xu, Andreas Geiger, Jingyi Yu 및 Hao Su. Tensorf: Tensorial radiance field. 에서
컴퓨터 비전에 관한 유럽 회의, 333~350페이지. 스프링거, 2022년.
- [6] Yiwen Chen, Zilong Chen, Chi Zhang, Feng Wang, Xiaofeng Yang, Yikai Wang, Zhongang Cai, Lei Yang, 류화핑, 린귀성. Gaussianeditor: 가우스 스피래팅을 사용한 신속하고 제어 가능한 3D 편집,
2023.
- [7] Zhiqin Chen, Thomas Funkhouser, Peter Hedman 및 Andrea Tagliasacchi. Mobilenerf: 활용
모바일 아키텍처에서 효율적인 신경장 렌더링을 위한 다각형 래스터화 파이프라인. arXiv 사전 인쇄
arXiv:2208.00277, 2022.
- [8] Zhang Chen, Zhong Li, Liangchen Song, Lele Chen, Jingyi Yu, Junsong Yuan 및 Yi Xu. Neurf: 신경
적응형 방사형 기초 함수를 사용한 필드 표현. IEEE/CVF 국제회의 진행 중
컴퓨터 비전 컨퍼런스, 4182-4194페이지, 2023년.
- [9] Zilong Chen, Feng Wang, Huaping Liu. 가우스 스피래팅을 사용하여 텍스트를 3D로 변환합니다. arXiv 사전 인쇄
arXiv:2309.16585, 2023.
- [10] 정재영, 이수영, 남형진, 이재린, 이경무. 자각몽:
3D 가우스 스피래팅 장면을 도메인 없이 생성합니다. arXiv 사전 인쇄 arXiv:2311.13384, 2023.
- [11] Kangle Deng, Andrew Liu, Jun-Yan Zhu 및 Deva Ramanan. 심층 감독 NeRF: 보기가 적고
무료로 더 빠른 교육을 받을 수 있습니다. 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 진행 중
인정(CVPR), 2022년 6월.
- [12] Stephan J Garbin, Marek Kowalski, Matthew Johnson, Jamie Shotton 및 Julien Valentin. 패스트너프:
200fps의 충실도 높은 신경 렌더링. IEEE/CVF 국제 컨퍼런스 진행 중
컴퓨터 비전, 14346~14355페이지, 2021년.
- [13] 마커스 그로스(Markus Gross)와 한스페터 피스터(Hanspeter Pfister). 포인트 기반 그래픽. 엘스비어, 2011.
- [14] 강한(Kang Han)과 웨이샹(Wei Xiang). 뷰를 위한 멀티스케일 텐서 분해 및 렌더링 방정식 인코딩
합성. IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스, 페이지 4232-4241,
2023.
- [15] Peter Hedman, Pratul P Srinivasan, Ben Mildenhall, Jonathan T Barron 및 Paul Debevec. 베이킹 신경
실시간 뷰 합성을 위한 라디언스 필드. IEEE/CVF 국제 컨퍼런스 진행 중
컴퓨터 비전, 5875~5884페이지, 2021년.
- [16] Wenbo Hu, Yuling Wang, Lin Ma, Bangbang Yang, Lin Gao, Xiao Liu 및 Yuewen Ma. 삼중 miprf:
효율적인 앤티앨리어싱 신경 방사 필드를 위한 Tri-Mip 표현입니다. IEEE/CVF 절차에서
컴퓨터 비전에 관한 국제 회의, 페이지 19774-19783, 2023.
- [17] Yi-Hua Huang, Yang-Tian Sun, Ziyi Yang, Xiaoyang Lyu, Yan-Pei Cao 및 Xiaojuan Qi. Sc-gs: 희소-

편집 가능한 동적 장면을 위한 제어된 가우스 스피래팅. 2023년 1~11페이지.

[18] Yuheng Jiang, Zhehao Shen, Penghao Wang, Zhuo Su, Yu Hong, Yingliang Zhang, Jingyi Yu 및 Lan 쉼. Hifi4g: 컴팩트 가우스 스피래팅을 통한 고성능 인간 성능 렌더링. arXiv 사전 인쇄 arXiv:2312.03461, 2023.

[19] Yingwenqi Jiang, Jiadong Tu, Yuan Liu, Xifeng Gao, Xiaoxiao Long, Wenping Wang 및 Yuexin Ma. Gaussianshader: 반사 표면을 위한 셰이딩 기능을 갖춘 3D 가우스 스피래팅입니다. arXiv 사전 인쇄 arXiv:2311.17977, 2023.

[20] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler 및 George Drettakis. 3D 가우스 스피래팅 실시간 래디언스 필드 렌더링. 그래픽에 대한 ACM 거래, 42(4), 2023년 7월.

[21] 레오니드 케셀만(Leonid Keselman)과 마르시알 헤베르트(Martial Hebert). 대수적 표면을 사용한 대략적인 미분 가능 렌더링. 에서

컴퓨터 비전에 관한 유럽 회의, 596~614페이지. 스프링거, 2022년.

[22] 레오니드 케셀만(Leonid Keselman)과 마르시알 헤베르트(Martial Hebert). 3D 가우스를 사용한 미분 렌더링을 위한 유연한 기술입니다.

arXiv 사전 인쇄 arXiv:2308.14737, 2023.

[23] Zhan Li, Zhang Chen, Zhong Li 및 Yi Xu. 실시간 동적을 위한 시공간 가우스 기능 스피래팅 합성을 봅니다. arXiv 사전 인쇄 arXiv:2312.16812, 2023.

[24] Zhaoshuo Li, Thomas Müller, Alex Evans, Russell H Taylor, Mathias Unberath, Ming-Yu Liu 및 Chen-린 쉬안. Neuralangelo: 충실도가 높은 신경 표면 재구성. IEEE 컴퓨터 회의에서
10

--- 페이지 11 ---

비전 및 패턴 인식(CVPR), 2023.

[25] Yixun Liang, Xin Yang, Jiantao Lin, Haodong Li, Xiaogang Xu 및 Yingcong Chen. 자각몽: 간격 점수 매칭을 통한 충실도 높은 텍스트-3D 생성을 향해, 2023년.

[26] Chen-Hsuan Lin, Wei-Chiu Ma, Antonio Torralba 및 Simon Lucey. Barf: 번들 조정 신경 래디언스 필드. 2021년 IEEE 컴퓨터 비전 국제 컨퍼런스(ICCV)에서.

[27] Lingjie Liu, Jiatao Gu, Kyaw Zaw Lin, Tat-Seng Chua 및 Christian Theobalt. 신경 회소 복셀 필드. 신경 정보 처리 시스템의 발전, 33:15651-15663, 2020.

[28] Yuan Liu, Peng Wang, Cheng Lin, Xiaoxiao Long, Jiepeng Wang, Lingjie Liu, Taku Komura 및 Wenping 왕. Nero: 다중 뷰 이미지에서 반사 개체의 신경 기하학 및 brdf 재구성. 에서
시그라프, 2023.

[29] Tao Lu, Mulin Yu, Linning Xu, Yuanbo Xiangli, Limin Wang, Dahua Lin 및 Bo Dai. 비계-gs:

보기 적응형 렌더링을 위한 구조화된 3D 가우스. arXiv 사전 인쇄 arXiv:2312.00109, 2023.

[30] Jonathon Luiten, Georgios Kopanas, Bastian Leibe 및 Deva Ramanan. 동적 3D 가우스: 추적 지속적인 동적 뷰 합성을 통해. 3DV에서는 2024년.

[31] Xiaoyang Lyu, Yang-Tian Sun, Yi-Hua Huang, Xiuzhe Wu, Ziyi Yang, Yilun Chen, Jiangmiao Pang, 샤오주안 치. 3dgsr: 3D 가우스 스피래팅을 사용한 암시적 표면 재구성. arXiv 사전 인쇄 arXiv:2404.00409, 2024.

[32] Li Ma, Vasu Agrawal, Haithem Turki, 김창일, Chen Gao, Pedro Sander, Michael Zollhfer 및 크리스티안 리처드. Specnerf: 정반사를 위한 가우스 방향 인코딩. 절차에서
컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스, 페이지 21188-21198, 2024.

[33] Dawid Malarz, Weronika Smolak, Jacek Tabor, Sławomir Tadeja 및 Przemysław Spurek. 가우스 너프 기반의 색상과 불투명도를 사용한 스피래팅.

[34] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Barron, Ravi Ramamoorthi 및 Ren 응. Nerf: 장면을 뷰 합성을 위한 신경 복사 필드로 표현합니다. ECCV에서는 2020.

- [35] 토마스 뮐러, 알렉스 에반스, 크리스토프 쉬드, 알렉산더 켈러. 즉각적인 신경 그래픽 프리미티브 다중 해상도 해시 인코딩을 사용합니다. ACM 트랜스. 그래프., 41(4):102:1-102:15, 2022년 7월.
- [36] Jacob Munkberg, Jon Hasselgren, Tianchang Shen, Jun Gao, Wenzheng Chen, Alex Evans, Thomas Müller, 그리고 산자 피들러. 이미지에서 삼각형의 3D 모델, 재질, 조명을 추출합니다. 의 절차에서 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스, 페이지 8280-8290, 2022.
- [37] Haokai Pang, Heming Zhu, Adam Kortylewski, Christian Theobalt 및 Marc Habermann. 애쉬: 애니메이션 가능 효율적이고 사실적인 인간 렌더링을 위한 가우스 스피클렛. 2023.
- [38] 박근홍, Philipp Henzler, Ben Mildenhall, Jonathan T Barron, Ricardo Martin-Brualla. 캠프: 신경 복사장을 위한 카메라 사전 조정. ACM 그래픽 트랜잭션(TOG), 42(6):1-11, 2023.
- [39] Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga 등 Pytorch: 필수적인 스타일, 고성능 심층 학습 도서관. 신경 정보 처리 시스템의 발전, 32, 2019.
- [40] Christian Reiser, Songyou Peng, Yiyi Liao 및 Andreas Geiger. Kilonerf: 신경 방사 속도 향상 수천 개의 작은 mlps가 있는 필드입니다. IEEE/CVF 국제 컴퓨터 컨퍼런스 진행 중 비전, 14335~14345페이지, 2021.
- [41] 사이토 순스케, 가브리엘 슈워츠, 토마스 사이먼, 리준수안, 남길주. 기분 좋은 가우스 코덱 아바타. 2023.
- [42] Johannes L Schonberger 및 Jan-Michael Frahm. 모션에서 구조를 재검토했습니다. 절차에서 컴퓨터 비전 및 패턴 인식에 관한 IEEE 회의, 페이지 4104-4113, 2016.
- [43] Yahao Shi, Yanmin Wu, Chenming Wu, Xing Liu, Chen Zhao, Haocheng Feng, Jingtuo Liu, Liangjun Zhang, Jian Zhang, Bin Zhou 등. Gir: 재조명 가능한 장면 분해를 위한 3D 가우스 역 렌더링. arXiv 사전 인쇄 arXiv:2312.05133, 2023.
- [44] Pratul P. Srinivasan, Boyang Deng, Xiuming Zhang, Matthew Tancik, Ben Mildenhall 및 Jonathan T. Barron. Nerv: 재조명 및 뷰 합성을 위한 신경 방사 및 가시성 필드입니다. CVPR에서는 2021.
- [45] Cheng Sun, Min Sun 및 Hwann-Tzong Chen. 직접 복셀 그리드 최적화: 초고속 수렴 복사장 재구성을 위해. 컴퓨터 비전 및 컴퓨터 비전에 관한 IEEE/CVF 회의 진행 중 패턴 인식, 페이지 5459-5469, 2022.
- [46] Jiaxiang Tang, Jiawei Ren, Hang Zhou, Ziwei Liu 및 Gang Zeng. Dreamgaussian: 생성 가우스 효율적인 3D 콘텐츠 제작을 위한 스피클렛. arXiv 사전 인쇄 arXiv:2309.16653, 2023.
- [47] Dor Verbin, Peter Hedman, Ben Mildenhall, Todd Zickler, Jonathan T. Barron 및 Pratul P. Srinivasan. Ref-NeRF: 신경 방사 필드에 대한 구조화된 뷰 종속 모양입니다. CVPR, 2022.
- [48] Peng Wang, Lingjie Liu, Yuan Liu, Christian Theobalt, Taku Komura 및 Wenping Wang. 노이스: 학습 다중 뷰 재구성을 위한 볼륨 렌더링을 통한 신경 암시적 표면. 신경IPS, 2021.
- [49] Peng Wang, Lingzhe Zhao, Ruijie Ma 및 Peidong Liu. BAD-NeRF: 번들 조정된 디블러 신경망 라디언스 필드. 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스 진행 중 (CVPR), 4170~4179페이지, 2023년 6월.
- [50] Zirui Wang, Shangzhe Wu, Weidi Xie, Min Chen 및 Victor Adrian Prisacariu. NeRF : 신경 복사 알려진 카메라 매개변수가 없는 필드. arXiv 사전 인쇄 arXiv:2102.07064, 2021.
- [51] Suttisak Wizadwongsa, Pakkapon Phongthawee, Jiraphon Yenphraphai 및 Supasorn Suwajanakorn. 넥스: 신경 기반 확장을 통한 실시간 뷰 합성. 컴퓨터 비전 및 패턴에 관한 InIEEE 컨퍼런스 인정(CVPR), 2021.

vasan, Dor Verbin, Jonathan T. Barron, Ben Poole 및 Aleksander Holynski. 재구성: 3D 재구성 확산 우선순위를 사용합니다. arXiv, 2023.

[53] Tong Wu, Jiaqi Wang, Xingang Pan, Xudong Xu, Christian Theobalt, Ziwei Liu 및 Dahua Lin. V 옥서프: V 옥셀 기반의 효율적이고 정확한 신경 표면 재구성. In 국제 학습 컨퍼런스 표현(ICLR), 2023.

[54] Tianyi Xie, Zeshun Zong, Yuxing Qiu, Xuan Li, Yutao Feng, Yin Yang 및 Chenfanfu Jiang. 피가우시안: 생성 역학을 위한 물리학 통합 3D 가우스. arXiv 사전 인쇄 arXiv:2311.12198, 2023.

[55] Kun Xu, Wei-Lun Sun, Zhao Dong, Dan-Yong Zhao, Run-Dong Wu 및 Shi-Min Hu. 이방성 구형 가우스. 그래픽에 대한 ACM 트랜잭션, 32(6):209:1-209:11, 2013.

[56] 양 지아웨이(Jiawei Yang), 마르코 파본(Marco Pavone), 왕 왕(Yue Wang). Freenerf: 무료로 퓨샷 신경 렌더링 개선 주파수 정규화. Proc에서 컴퓨터 비전 및 패턴 인식(CVPR)에 관한 IEEE 컨퍼런스, 2023.

[57] Ziyi Yang, Yanzhen Chen, Xinyu Gao, Yazhen Yuan, Yu Wu, Xiaowei Zhou 및 Xiaogang Jin. 선생님-이르: 고조도 장면에서 그림자 및 조명 제거를 통한 brdf 재구성을 위한 역 렌더링. arXiv 사전 인쇄 arXiv:2310.13030, 2023.

[58] Ziyi Yang, Xinyu Gao, Wen Zhou, Shaohui Jiao, Yuqing Zhang 및 Xiaogang Jin. 변형 가능한 3D 충실도가 높은 단안 동적 장면 재구성을 위한 가우스. IEEE/CVF 절차에서 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 20331-20341, 2024.

[59] Zeyu Yang, Hongye Yang, Zijie Pan, Xiatian Zhu 및 Li Zhang. 실시간으로 사실적인 역동적인 장면 4D 가우스 스피래팅을 사용한 표현 및 렌더링. arXiv 사전 인쇄 arXiv 2310.10642, 2023.

[60] Zongxin Ye, Wenyu Li, Sidun Liu, Peng Qiao 및 Yong Dou. Absgs: 3D의 미세한 디테일 복구 가우스 스피래팅. ACM 멀티미디어 2024, 2024.

[61] Taoran Yi, Jiemin Fang, Junjie Wang, Guanjuan Wu, Lingxi Xie, Xiaopeng Zhang, Wenyu Liu, Qi Tian, 그리고 왕싱강. Gaussiandreamer: 2D와 3D를 연결하여 텍스트에서 3D 가우스로 빠르게 생성 확산 모델. arXiv 사전 인쇄 arXiv:2310.08529, 2023.

[62] Wang Yifan, Felice Serena, Shihao Wu, Cengiz ztireli 및 Olga Sorkine-Hornung. 미분 가능한 표면 포인트 기반 기하학 처리를 위한 스피래팅. ACM 그래픽 트랜잭션(TOG), 38(6):1-14, 2019.

[63] Alex Yu, Ruilong Li, Matthew Tancik, Hao Li, Ren Ng 및 Angjoo Kanazawa. 실시간 Plenotrees 신경 방사 필드의 렌더링. IEEE/CVF 국제 컴퓨터 회의 진행 중 비전, 페이지 5752-5761, 2021.

[64] Zehao Yu, Torsten Sattler 및 Andreas Geiger. 가우스 불투명 필드: 효율적이고 컴팩트한 표면 무한한 장면의 재구성. arXiv 사전 인쇄 arXiv:2404.10772, 2024.

[65] Qiang Zhang, 백승환, Szymon Rusinkiewicz, Felix Heide. 차별화 가능한 포인트 기반 효율적인 뷰 합성을 위한 래디언스 필드. arXiv 사전 인쇄 arXiv:2205.14330, 2022.

[66] Xiuming Zhang, Pratul P Srinivasan, Boyang Deng, Paul Debevec, William T Freeman 및 Jonathan T

배런. Nerfactor: 알려지지 않은 조명 하에서 모양과 반사율의 신경 인수분해. ACM 그래픽 거래(ToG), 40(6):1-18, 2021.

[67] Shunyuan Zheng, Boyao Zhou, Ruizhi Shao, Boning Liu, Shengping Zhang, Liqiang Nie 및 Yebin Liu. Gps-gaussian: 실시간 인간 소셜 뷰 합성을 위한 일반화 가능한 픽셀별 3D 가우스 스피래팅입니다. arXiv, 2023.

[68] 보이치예흐 지엘론카(Wojciech Zielonka), 티무르 바가우트디노프(Timur Bagautdinov), 사이토 순스케(Shunsuke Saito), 미하엘 졸히퍼(Michael Zollhofer), 유스투스 티에스(Justus Thies), 하비에르(Javier) 로메로. 구동 가능한 3D 가우스 아바타. 2023.

[69] Matthias Zwicker, Hanspeter Pfister, Jeroen Van Baar 및 Markus Gross. Ewa 볼륨 스피래팅. 에서 Proceedings Visualization, 2001. VIS'01., 페이지 29-538. IEEE, 2001.

12

--- 페이지 13 ---

A 부록/보충 자료

이 보충 자료는 논문과 함께 더 많은 결과를 제공합니다.

- 섹션 B는 더 많은 절제를 제공합니다.
- 섹션 C는 더 많은 시각화 및 정량적 결과를 포함한 추가 결과를 제공합니다.

완전한 데이터 세트에 대해.

B 추가 절제

이 섹션에서는 방법의 주요 구성 요소에 대한 완전한 정량적 절제를 제시합니다.

먼저 NeRF 합성 장면에서 ASG 모양 필드의 각 구성 요소의 역할을 평가합니다.

탭에 표시된 대로 5. ASG 도입으로 반사 하이라이트 모델링 기능이 향상되었습니다.

3D 가우시안의 수를 줄입니다. 법선 포함이 크게 증가하지 않았습니다.

계산 오버헤드가 발생했지만 렌더링 측정항목과 시각적 품질이 향상되었습니다. 더 중요한 것은, 우리는 바닐라 3D-GS보다 더 적은 수의 가우시안으로 더 나은 렌더링 품질을 달성합니다.

앞으로 더 자세히 탐구될 수 있다.

다음으로 Tab의 Mip360 데이터 세트에 대한 전체 방법을 평가했습니다. 6. 다음 사항에 유의하는 것이 중요합니다.

Mip360 데이터 세트는 실내 장면과 실외 장면으로 구분됩니다. 실내 장면이 더 반사적입니다.

야외 장면에는 많은 수의 플로터가 포함되어 있습니다. 대략적인 접근 방식

자체적으로 상당한 양의 요소를 제거하여 실제 장면에서 3D-GS의 품질을 향상시킵니다.

야외 환경에서의 플로터. ASG 출현 분야가 크게 도입되었지만

렌더링 오버헤드가 증가하여 실내의 반사 하이라이트 모델링이 크게 향상되었습니다.

장면. 거친 메커니즘의 제약 하에서 우리의 완전한 방법은 다음을 결합합니다.

두 가지 장점을 모두 활용하여 최상의 렌더링 품질을 달성합니다. 렌더링 속도를 더욱 향상시키기 위해 우리는 또한 Scaffold-GS를 기반으로 라이트 버전과 미니 버전을 구현합니다. 이러한 버전은 절충안을 제공합니다.

렌더링 품질과 속도 사이에서 필요에 따라 사용할 수 있습니다. Mip360 장면의 품질

우리의 방법이 반사 하이라이트가 있는 장면을 처리할 수 있을 뿐만 아니라

실제 확산 시나리오에서도 강력합니다.

C 추가 비교

이 섹션에서는 실험의 완전한 정량적 결과를 제시합니다. PSNR을 보고합니다.

SSIM, LPIPS(VGG) 및 각 셀에 최고, 두 번째 최고, 세 번째 최고로 색상을 지정합니다.

C.1 NeRF 합성 장면

탭에 표시된 대로. 7-9, 우리의 방법은 거의 모든 분야에서 최고의 렌더링 품질 지표를 보여줍니다.

장면. Tri-MipRF의 실험 설정[16]은 다른 실험 설정과 다르다는 점에 유의하는 것이 중요합니다.

방법. 훈련 세트와 검증 세트를 모두 훈련 데이터로 사용하여 규모를 확장합니다.

모델의 데이터. 훈련 데이터가 훈련 세트로 제한되면 측정항목이 눈에 띄게 감소합니다.

그럼에도 불구하고 실험 결과가 각 장치의 최고 성능을 완전히 반영하도록 하기 위해

실험 환경의 차이로 인해 지표가 크게 떨어지는 것을 방지하기 위해,

우리는 여전히 Tri-MipRF 공식 문서의 측정항목을 제시합니다. 우리의 방법은 더욱 눈에 띄는 성과를 거두었습니다.

드럼, 레고, 선박과 같이 눈에 띄는 정반사 및 이방성이 있는 장면의 측정 기준입니다.

이는 우리의 방법이 전반적인 렌더링 품질을 향상시킬 뿐만 아니라

복잡한 반사 시나리오에서 더욱 중요한 이점을 제공합니다.

C.2 NSVF 합성 장면

NSVF [27] 데이터 세트는 NeRF와 비교하여 더 눈에 띄는 금속 정반사를 특징으로 합니다.

Wineholder, Steamtrain 및 Spaceship 장면에 제시된 바와 같습니다. Tri-

MipRF는 공식 코드를 사용하여 Steam 장면에서 수렴하지 못하므로 다음에 대한 측정항목을 보고하지 않았습니다.

그 시나리오. 탭에 표시된 대로. 10-12에서는 PSNR의 장면별 실험 결과를 제시하며, 보충 자료에는 SSIM 및 LPIPS가 포함되어 있습니다. 실험 결과는 3D-GS[20]를 기반으로 한 다른 방법과 비교하여 우리의 방법은 금속 하이라이트에서 상당한 이점을 갖습니다.

--- 페이지 14 ---

표 5: ASG 모양 필드의 절제.

NeRF 합성 데이터세트

방법 PSNR↑ SSIM↑ LPIPS↓ FPS↑ 수(k)↓

3D-GS 33.32 0.969 0.031 315 295

ASG 제외 34.03 0.969 0.030 175 271

디쿠프 없음-MLP 33.95 0.970 0.030 217 244

법선 없음 34.10 0.971 0.029 139 238

전체(라이트) 34.08 0.970 0.029 148 186

전체 34.19 0.971 0.028 121 237

표 6: 전체 방법에 대한 절제.

데이터세트 MipNeRF 360

방법 PSNR↑ SSIM↑ LPIPS↓ FPS↑ 수(M)↓

3D-GS 27.47 0.812 0.222 115 3.23

ASG 필드 없음 27.61 0.830 0.184 113 3.21

c2f 없음 28.01 0.823 0.203 28 3.56

앵커 포함 28.14 0.824 0.196 70 -

전체(라이트) 28.07 0.834 0.183 44 2.52

완전 28.18 0.835 0.176 33 3.10

Mip-NeRF 360 3D-GS 비계-GS Ours-Norm Ours GT 없음

그림 8: Mip-NeRF 360 야외 장면의 시각화. 우리의 방법은 강력한 플로터를 달성합니다.

거친 훈련에서 미세한 훈련에 의한 제거.

복잡한 전송 시나리오. 추가적으로 SOTA NeRF 기반의

NeRF 기반 방법. 우리의 접근 방식을 통해 3D-GS는 NeRF의 최신 SOTA를 능가하여 다음과 같은 목표를 달성할 수 있습니다.

3D-GS는 실현할 수 없었지만 NeRF는 실현할 수 있었던 고주파 하이라이트 모델링을 통해

그림 14와 같이 진정한 고품질 렌더링이 가능합니다.

3D-GS비계-GS아워스GT

그림 9: 기준선과의 추가 비교. 우리의 방법은 거친 방법으로 강력한 부유물 제거를 달성합니다.

미세한 훈련.

14

--- 페이지 15 ---

반사 하이라이트반사

그림 10: 반사광의 그림

조명과 반사.

GS-Shader 우리의 GT

그림 11: Ref-NeRF 데이터세트의 C비교.

3D-GS비계-GS아워스GT

그림 12: Nex [51] 데이터 세트의 시각화.

의자 드럼 무화과나무 핫도그 레고 재료 마이크 선박 평균.

iNGP-베이스 35.00 26.02 33.51 37.40 36.39 29.78 36.22 31.10 33.18

밍프-NeRF 35.14 25.48 33.29 37.48 35.70 30.71 36.51 30.41 33.09
 트라이-MipRF 36.10 26.59 34.51 38.54 36.15 30.73 37.75 28.78 33.65
 GS 셰이더 35.83 26.36 34.97 37.85 35.87 30.07 35.23 30.82 33.38
 3D-GS 35.36 26.15 34.87 37.72 35.78 30.00 35.36 30.80 33.32
 비계-GS 35.28 26.44 35.21 37.73 35.69 30.65 37.25 31.17 33.68
 앵커 포함 35.57 26.58 35.71 38.12 36.62 30.66 36.81 31.63 33.96
 우리 빛 35.69 26.77 36.03 38.25 36.11 30.84 36.95 31.97 34.08
 당사 35.72 26.92 36.10 38.25 36.46 30.98 37.09 31.97 34.19

표 7: NeRF 데이터 세트의 장면별 PSNR 비교.

의자 드럼 무화과나무 핫도그 레고 재료 마이크 선박 평균.

iNGP-베이스 0.979 0.937 0.981 0.982 0.982 0.951 0.990 0.896 0.963
 밍프-NeRF 0.981 0.932 0.980 0.982 0.978 0.959 0.991 0.882 0.961
 트라이-MipRF 0.985 0.939 0.983 0.984 0.982 0.953 0.992 0.879 0.963
 GS 셰이더 0.987 0.949 0.985 0.985 0.983 0.960 0.991 0.905 0.968
 3D-GS 0.987 0.955 0.987 0.985 0.983 0.960 0.992 0.907 0.969
 비계-GS 0.985 0.950 0.985 0.983 0.980 0.960 0.992 0.898 0.967
 앵커 포함 0.986 0.953 0.987 0.985 0.982 0.962 0.992 0.904 0.969
 우리 빛 0.987 0.955 0.988 0.985 0.981 0.963 0.993 0.905 0.970
 당사 0.987 0.958 0.988 0.985 0.982 0.963 0.993 0.909 0.971

표 8: NeRF 데이터 세트에 대한 장면별 SSIM 비교.

의자 드럼 무화과나무 핫도그 레고 재료 마이크 선박 평균.

iNGP-베이스 0.022 0.071 0.023 0.027 0.017 0.060 0.010 0.132 0.045
 밍프-NeRF 0.021 0.065 0.020 0.027 0.021 0.040 0.009 0.138 0.043
 트라이-MipRF 0.016 0.066 0.020 0.021 0.016 0.052 0.008 0.136 0.042
 GS 셰이더 0.012 0.040 0.013 0.019 0.014 0.033 0.006 0.103 0.030
 3D-GS 0.011 0.037 0.012 0.020 0.016 0.037 0.006 0.106 0.031
 비계-GS 0.013 0.042 0.013 0.023 0.019 0.040 0.008 0.114 0.034

앵커 포함 0.013 0.038 0.012 0.022 0.016 0.037 0.007 0.112 0.032
 우리 빛 0.012 0.035 0.011 0.019 0.017 0.034 0.006 0.101 0.029
 당사 0.011 0.033 0.011 0.018 0.014 0.031 0.006 0.099 0.028

표 9: NeRF 데이터 세트의 장면별 LPIPS(VGG) 비교.

15

--- 페이지 16 ---

3D-GS

우리 것

GT

채우전자 비행기 기록 재떨이 접시 헤드폰 Jupyter Lock

그림 13: "이방성 합성" 데이터 세트의 시각화. 비교를 보여드리겠습니다

8개 장면 모두에서 우리 방법과 3D-GS 사이를 비교합니다. 정성적 실험 결과는 다음과 같습니다.

이방성 장면을 모델링하는 방법의 중요한 장점은 다음과 같습니다.

3D-GS의 렌더링 품질.

3D-GS 스캐폴드-GS GS 셰이더 아워스 GT

그림 14: NSVF 데이터 세트의 시각화. 우리의 방법은 다음과 같은 능력을 크게 향상시킵니다.

다른 GS 기반 방법과 비교하여 금속 재료를 모델링합니다. 동시에, 우리의 방법은 또한

우리의 강력한 피팅 능력을 반영하여 굴절 부품을 모델링하는 능력을 보여줍니다.

방법.

바이크 라이프 팰리스 로봇 스페이스 스팀 토드 와인 평균.

네르프 31.77 31.08 31.76 28.69 34.66 30.84 29.42 28.23 30.81
 NSVF 37.75 34.60 34.05 35.24 39.00 35.13 33.25 32.04 35.13
 텐소RF 39.23 34.51 37.56 38.26 38.60 37.87 34.85 31.32 36.52
 트라이-MipRF 36.98 33.98 36.55 33.49 37.60 - 33.48 29.97 34.58
 뉴RBF 40.71 36.08 38.93 39.13 40.44 38.35 35.73 32.99 37.80
 3D-GS 40.76 33.19 38.89 39.16 36.80 37.67 37.33 32.76 37.07
 비계-GS 39.87 35.00 38.53 37.92 34.36 37.12 36.29 32.32 36.43
 GS 셰이더 37.38 27.36 36.55 37.00 32.61 35.27 34.50 30.16 33.85
 앵커 포함 40.63 35.56 38.95 38.52 39.47 37.98 36.55 34.04 37.71
 우리 빛 41.48 36.11 39.23 39.54 39.89 38.19 37.22 34.59 38.28
 당사 41.67 36.15 39.33 39.65 40.03 38.26 37.43 34.69 38.40

표 10: NSVF 데이터 세트의 장면별 PSNR 비교.

16

--- 페이지 17 ---

바이크 라이프 팰리스 로봇 스페이스 스팀 토드 와인 평균.

네르프 0.970 0.946 0.950 0.960 0.980 0.966 0.920 0.920 0.952
 NSVF 0.991 0.971 0.969 0.988 0.991 0.986 0.968 0.965 0.979
 텐소RF 0.993 0.968 0.979 0.994 0.989 0.991 0.978 0.961 0.982
 트라이-MipRF 0.990 0.962 0.973 0.985 0.986 - 0.968 0.945 0.973
 뉴RBF 0.995 0.977 0.985 0.995 0.993 0.993 0.983 0.972 0.986
 3D-GS 0.994 0.979 0.983 0.994 0.991 0.993 0.985 0.975 0.987
 비계-GS 0.993 0.979 0.981 0.995 0.985 0.992 0.982 0.971 0.984
 GS 셰이더 0.992 0.964 0.979 0.994 0.985 0.990 0.980 0.966 0.981
 앵커 포함 0.994 0.979 0.982 0.994 0.993 0.992 0.984 0.975 0.987
 우리 빛 0.995 0.982 0.984 0.993 0.994 0.994 0.984 0.977 0.988
 당사 0.995 0.982 0.984 0.995 0.994 0.994 0.985 0.978 0.988

표 11: NSVF 데이터 세트에 대한 장면별 SSIM 비교.

바이크 라이프 팰리스 로봇 스페이스 스팀 토드 와인 평균.

텐소RF 0.010 0.048 0.022 0.010 0.020 0.017 0.031 0.051 0.026
 트라이-MipRF 0.012 0.048 0.023 0.019 0.019 - 0.036 0.055 0.030
 뉴RBF 0.006 0.036 0.016 0.009 0.011 0.011 0.025 0.036 0.019
 3D-GS 0.005 0.028 0.017 0.006 0.009 0.007 0.018 0.025 0.015
 비계-GS 0.007 0.030 0.019 0.008 0.019 0.010 0.022 0.021 0.017
 GS 셰이더 0.007 0.051 0.020 0.008 0.016 0.010 0.023 0.029 0.020
 앵커 포함 0.005 0.027 0.018 0.007 0.007 0.008 0.021 0.025 0.015
 우리 빛 0.005 0.024 0.015 0.006 0.007 0.007 0.018 0.022 0.013
 당사 0.004 0.022 0.014 0.005 0.007 0.007 0.017 0.021 0.012

표 12: NSVF 데이터 세트에 대한 장면별 LPIPS(VGG) 비교.

찰주전자 비행기 기록 재떨이 접시 헤드폰 Jupyter Lock 평균.

3D-GS 27.24 26.80 43.81 34.43 29.62 38.72 40.52 29.36 33.81
 비계-GS 30.64 29.14 47.79 35.66 32.12 37.19 40.04 30.13 35.34
 앵커 포함 33.53 31.56 50.35 36.14 32.95 38.48 40.10 30.96 36.76
 우리 빛 34.75 31.01 50.30 37.76 33.03 39.39 41.42 31.68 37.42
 당사 35.24 30.95 50.90 38.03 33.04 40.12 41.47 31.86 37.70

표 13: "비등방성 합성" 데이터 세트에 대한 장면별 PSNR 비교.

채주전자 비행기 기록 재떨이 접시 헤드폰 Jupyter Lock 평균.

3D-GS 0.968 0.946 0.994 0.969 0.947 0.989 0.985 0.932 0.966

비계-GS 0.979 0.965 0.998 0.973 0.967 0.986 0.983 0.924 0.972

앵커 포함 0.985 0.973 0.999 0.974 0.973 0.988 0.984 0.930 0.976

우리 빛 0.987 0.967 0.998 0.984 0.970 0.990 0.987 0.948 0.979

당사 0.988 0.967 0.999 0.985 0.970 0.990 0.987 0.951 0.980

표 14: "이방성 합성" 데이터 세트에 대한 장면별 SSIM 비교.

채주전자 비행기 기록 재떨이 접시 헤드폰 Jupyter Lock 평균.

3D-GS 0.043 0.085 0.019 0.044 0.120 0.015 0.075 0.098 0.062

비계-GS 0.029 0.057 0.006 0.038 0.082 0.021 0.086 0.099 0.052

앵커 포함 0.022 0.042 0.004 0.039 0.067 0.017 0.084 0.093 0.046

우리 빛 0.021 0.052 0.007 0.022 0.079 0.014 0.076 0.080 0.044

당사 0.021 0.051 0.005 0.020 0.077 0.013 0.071 0.075 0.042

표 15: "비등방성 합성" 데이터 세트에 대한 장면별 LPIPS(VGG) 비교.

자전거 꽃들 정원 그루터기 트리힐 방 카운터 부엌 분재

플레녹셀 21.91 20.10 23.49 20.66 22.25 27.59 23.62 23.42 24.67

iNGP 22.17 20.65 25.07 23.47 22.37 29.69 26.69 29.48 30.69

밍-NeRF360 24.37 21.73 26.98 26.40 22.87 31.63 29.55 32.23 33.46

3D-GS 25.63 21.94 27.73 27.02 22.79 31.80 29.12 31.61 32.48

비계-GS 25.61 21.74 27.82 26.79 23.38 32.14 29.62 31.81 32.87

우리 앵커 25.44 21.36 27.97 26.91 23.23 32.27 30.12 32.04 33.91

우리 빛 25.87 21.81 28.06 27.23 22.48 32.11 29.74 32.09 33.26

당사 25.90 21.86 28.07 27.25 22.48 32.11 30.12 32.25 33.54

표 16: Mip-NeRF 360 데이터 세트의 장면별 PSNR 비교.

17

--- 페이지 18 ---

자전거 꽃들 정원 그루터기 트리힐 방 카운터 부엌 분재

플레녹셀 0.496 0.431 0.606 0.523 0.509 0.842 0.759 0.648 0.814

iNGP 0.512 0.486 0.701 0.594 0.542 0.871 0.817 0.858 0.906

밍-NeRF360 0.685 0.583 0.813 0.744 0.632 0.913 0.894 0.920 0.941

3D-GS 0.778 0.623 0.874 0.784 0.651 0.928 0.916 0.933 0.948

비계-GS 0.773 0.609 0.867 0.774 0.657 0.931 0.919 0.931 0.950

우리 앵커 0.775 0.611 0.869 0.775 0.645 0.932 0.920 0.934 0.953

우리 빛 0.795 0.645 0.879 0.795 0.647 0.934 0.920 0.936 0.952

당사 0.797 0.648 0.881 0.797 0.647 0.935 0.923 0.937 0.953

표 17: Mip-NeRF 360 데이터 세트에 대한 SSIM 비교.

자전거 꽃들 정원 그루터기 트리힐 방 카운터 부엌 분재

플레녹셀 0.506 0.521 0.386 0.503 0.540 0.419 0.441 0.447 0.398

iNGP 0.446 0.441 0.257 0.421 0.450 0.261 0.306 0.195 0.205

밍-NeRF360 0.301 0.344 0.170 0.261 0.339 0.211 0.204 0.127 0.176

3D-GS 0.204 0.328 0.103 0.207 0.318 0.191 0.178 0.113 0.173

비계-GS 0.224 0.339 0.112 0.228 0.315 0.182 0.177 0.114 0.174

우리 앵커 0.205 0.292 0.110 0.215 0.293 0.185 0.179 0.115 0.166

우리 빛 0.173 0.279 0.097 0.190 0.275 0.182 0.173 0.111 0.168

당사 0.166 0.263 0.092 0.184 0.269 0.177 0.166 0.108 0.162

표 18: Mip-NeRF 360 데이터세트에 대한 LPIPS 비교.

C.3 이방성 합성 장면

"Anisotropic Synthetic"은 우리가 직접 렌더링한 합성 데이터 세트로, 8개의 장면이 포함되어 있습니다. 중요한 이방성. 우리는 "Anisotropic Synthetic"에 대한 기존 3D-GS 기반 방법 중 일부를 테스트했습니다. 탭에 표시된 대로. 13-15에서 우리의 방법은 렌더링 메트릭에서 매우 중요한 개선을 달성했습니다. 그림 13은 8개 장면 전체에 걸쳐 우리 방법과 3D-GS를 비교한 결과를 보여줍니다. 질적 실험은 또한 우리 방법의 중요한 시각적 이점을 보여줍니다. 우리의 방법은 이방성 부품을 실질적으로 개선하여 전반적인 성능을 향상시킵니다. 렌더링 품질.

C.4 Mip-360 장면

MipNeRF-360 장면에는 5개의 실외 시나리오와 4개의 실내 시나리오가 포함됩니다. 여러 장면이 있는데 분재, 방, 부엌 등 정반사가 풍부합니다. 탭에 표시된 대로. 16-18, 우리의 방법 4개의 실내 장면에서 상당한 이점을 얻었습니다. 이는 우리 방법의 강점을 반영합니다. 정반사 및 이방성 모델링. 야외 장면에서도 우리의 방법으로 렌더링을 달성했습니다. SOTA 방법과 비교할 수 있는 측정항목입니다. 또한, 거친 훈련을 통해 메커니즘을 통해 우리의 방법은 그림 11과 같이 플로터의 수를 크게 줄였으며 결과적으로 시각적 효과가 크게 향상되었습니다.

18

3. Optimization Trajectory / 갇힘 계열

[논문 06] 3DGS as MCMC 본문 전체 번역

--- 페이지 1 ---

3D 가우스 스피래팅

마르코프 체인 몬테카를로

샤키바 케라드만¹, 다니엘 레베인¹, 고팔 샤르마¹,

Weiwei Sun¹, Yang-Che Tseng¹, Hossam Isack², Abhishek Kar²,

안드레아 탈리아사키^{3, 4, 5}, 이광무¹

¹브리티시 컬럼비아 대학교, ²Google Research,

³Google DeepMind, ⁴Simon Fraser University, ⁵University of Toronto

<https://ubc-vision.github.io/3dgs-mcmc>

초록

3D Gaussian Splatting은 최근 신경 렌더링에 인기를 얻고 있지만,

현재 방법은 신중하게 설계된 복제 및 분할 전략에 의존합니다.

품질이 낮은 렌더링으로 이어질 수 있는 가우시안 배치 및

좋은 초기화. 이 작업에서 우리는 3D 가우시안 세트를 무작위로 다시 생각합니다.

물리적 현상을 설명하는 기본 확률 분포에서 추출된 샘플

장면 표현, 즉 MCMC(Markov Chain Monte Carlo)

샘플. 이 보기에서는 3D 가우스 업데이트가 변환될 수 있음을 보여줍니다.

SGLD(Stochastic Gradient Langevin Dynamics) 업데이트를 간단히 소개하면 다음과 같습니다.

소음. 그런 다음 3D Gaussian에서 치밀화 및 가지치기 전략을 다시 작성합니다.

단순히 MCMC 샘플의 결정론적 상태 전환으로 스피래팅하여 제거

프레임워크에서 이러한 휴리스틱을 사용합니다. 이를 위해 가우시안의 '복제'를 수정합니다.

샘플 확률을 대략적으로 유지하는 재위치화 방식으로 전환됩니다. 받는 사람

가우시안의 효율적인 사용을 장려하기 위해 우리는

사용하지 않는 가우스 제거. 다양한 표준 평가 장면에서 다음과 같은 점을 보여줍니다.

우리의 방법은 향상된 렌더링 품질을 제공하고, 수를 쉽게 제어할 수 있습니다.

가우시안 및 초기화에 대한 견고성.

1 소개

NeRF(Neural Radiance Fields)는 이러한 발전의 선두에 서서 다음과 같은 인상적인 결과를 제공했습니다.

신경망을 통한 암묵적 모델링을 통해 결과가 도출되면서 환경은 더욱 진화하고 있습니다.

3D 가우스 스피래팅 도입.

Neural Radiance의 도입으로 신경 렌더링이 크게 발전했습니다.

Fields(NeRF) [28], 그리고 최근에는 3D Gaussian Splatting(3DGS) [19]. 3D 가우스 스피래팅

속도와 효율성 덕분에 큰 인기를 끌었습니다.

NeRF에 필요한 시간의 일부입니다. 당연히 3D Gaussian Splatting에 대한 다양한 확장이 가능합니다.

3D 가우시안을 동적 장면으로 확장하여 [43, 41] 견고하게 만드는 등의 제안이 있었습니다.

앨리어싱 효과[48, 42] 및 생성적 3D 콘텐츠 생성[52, 49, 36].

그러나 다양한 확장에도 불구하고 이러한 방법의 일반적인 단점은 대부분

가우시안 배치를 위해 동일한 초기화 및 치밀화 전략을 사용합니다.
 원래 [19]에서 제안했거나 최근에 제안된 다른 변형 [4]입니다. 특히, 그들은 다음 사항에 의존합니다.
 가우시안 배치를 위해 신중하게 설계된 복제 및 분할 경험적 방법 [19, "적응 밀도" 참조
 제어]. 각 가우시안의 상태에 따라 복제, 분할 또는 가지치기가 수행됩니다.
 3DGS 표현 내에서 가우스 수를 제어하는 기본 방법입니다. 더욱이,
 제38차 신경정보처리시스템 컨퍼런스(NeurlPS 2024).
 arXiv:2404.09591v3 [cs.CV] 2025년 2월 12일

--- 페이지 2 ---

가우시안은 불투명도를 작은 값으로 설정하여 플로터를 제거함으로써 정기적으로 '재설정'됩니다.
 표현. 이 경험적 기반 접근 방식에는 여러 하이퍼파라미터를 신중하게 사용해야 합니다.
 나중에 논문에서 보여주겠지만 일부 장면에서는 실패할 수 있습니다.
 이러한 경험적 방법은 더욱 다양한 문제를 야기합니다. 이는 방법이 좋은 초기에 크게 의존하게 만듭니다.
 특히 실제 장면에 적용할 때 잘 작동하도록 포인트 클라우드를 제공합니다. 그것은 또한 중요하지 않습니다
 하이퍼파라미터만으로 특정 장면에 얼마나 많은 3D 가우스가 사용될지 추정하여
 재구성에 영향을 주지 않고 사전에 계산 및 메모리 예산을 제어하기가 어렵습니다.
 추론 시간 동안의 품질. 동시 작업 [10, 9] 따라서 더 나은 초기화에 중점을 둡니다.

전자를 해결하거나 후자의 문제를 연구하십시오 [4]. 그러나 이러한 최근의 동시 솔루션조차도 여전히
 경험적 방법에 의존하며 항상 일반화가 잘 되는 것은 아닙니다. 어떤 경우에는 이는 차선책으로 이어집니다.
 가우시안 배치로 인해 렌더링 품질이 떨어지고 계산이 낭비됩니다.
 이 문제를 해결하기 위해 우리는 한발 물러서서 3D 가우스 세트를 무작위 샘플로 다시 생각합니다.
 더 구체적으로 말하면 MCMC(Markov Chain Monte Carlo) 샘플로, 기본
 가우시안이 장면을 얼마나 충실하게 재구성하는지에 비례하는 확률 분포입니다.
 이를 고려하여 섹션 3.2에서 기존의 3D Gaussian Splatting 업데이트를 보여줍니다.
 규칙은 Stochastic Gradient Langevin Dynamics 업데이트 [3, 20]와 매우 유사합니다.
 누락된 용어는 샘플 탐색을 촉진하는 노이즈 용어입니다. 따라서 우리는 3D를 재구성합니다.
 Gaussian Splatting을 SGLD 프레임워크인 MCMC 알고리즘으로 자연스럽게 탐색합니다.
 장면 풍경을 충실하게 재현하는 데 효과적인 가우시안 샘플을 제공합니다. 그것은
 우리가 기본 분포를 가정하는 동안 이 분포는 반드시 그럴 필요는 없다는 점에 유의하는 것이 중요합니다.
 가우시안 자체가 이미 이를 표현하고 있으므로 명시적으로 모델링되어야 합니다.
 이러한 관점을 고려할 때, 가우시안의 치밀화 및 가지치기와 관련된 경험적 방법은 다음과 같습니다.
 불투명도를 재설정하는 것은 더 이상 필요하지 않습니다. 3D 가우시안은 단순히 사용된 샘플입니다.
 MCMC의 경우 샘플 위치 탐색은 SGLD 업데이트를 통해 자연스럽게 처리됩니다. 모두
 카디널리티 증가 또는 감소를 포함하여 가우스 집합에 대한 수정이 가능합니다.
 결정론적 상태 전환(가우시안 재배치)으로 재구성되어 샘플을 이동합니다.
 (가우시안 세트)를 다른 샘플(다른 구성을 가진 또 다른 가우시안 세트)로 변환합니다.
 중요한 것은 MCMC 샘플링 체인을 최소한으로 방해하기 위해 두 가지 상태를 확인하는 것입니다.
 이동 전과 후의 확률은 비슷합니다. 이는 훈련 손실 값을 의미합니다.
 내부의 가우시안 수와 같은 조합 속성을 변경해도 변경되지 않습니다.
 표현을 통해 훈련 과정이 불안정해지는 것을 방지합니다. 이 간단한 전략은
 MCMC 프레임워크는 제공되는 것 이상의 고품질 렌더링을 제공하기에 충분합니다.
 기존의 휴리스틱.
 좀 더 자세히 말하자면, 우리는 '죽은' 상태로 이동하는 '복제' 전략을 사용하여 가우시안을 재배포할 것을 제안합니다.
 가우스(불투명도가 낮음)는 다른 '살아 있는' 가우스가 존재하는 곳으로 이동하지만 최소한의 방식으로
 렌더링에 영향을 주어 가우시안의 확률 분포에 영향을 줍니다. 즉, 우리는
 복제된 가우시안의 구성을 복제 전과 동일한 이미지로 렌더링하도록 설정합니다. 동안

복제[4]의 수정은 렌더링이 동일하도록 보장하는 방법으로 최근 제안되었습니다.

가우시안 중심, 우리는 이것이 충분하지 않다는 것을 보여줍니다. 전체 가우시안을 고려해야 합니다. 없이 우리의 신중한 전략 MCMC 샘플링은 차선책 교육을 제공합니다. 마지막으로 효율성을 높이기 위해 Gaussian을 사용하여 L1 정규화를 적용합니다. 가우시안의 범위는 다음과 같이 정의됩니다. 불투명도와 가우시안의 규모를 고려하여 두 가지 모두에 정규화를 적용합니다. 이는 효과적으로 불필요한 경우 '사라지도록' 권장합니다.

우리는 [19](NeRF Synthetic [28], MipNeRF 360 [2],

Tank & Temples [22], Deep Blending [16]) 및 OMMO [27] 데이터 세트

장면 컨텍스트. 우리의 방법을 사용하면 가우시안을 주의 깊게 초기화할 필요가 없습니다. 우리의 방법 가우시안이 무작위로 초기화되거나 초기화되는지 여부에 관계없이 고품질 렌더링을 제공합니다.

모션 포인트의 구조.

요약하자면, 우리의 기여는 다음과 같습니다:

- 3DGS와 MCMC 샘플링 간의 링크를 공개하여 최적화를 더욱 단순화합니다.
- 3D Gaussian Splatting의 경험적 방법을 원칙에 입각한 재배치 전략으로 대체합니다.
- 가우시안의 절약적인 사용을 장려하기 위해 정규화 도구를 도입합니다.
- 초기화에 대한 견고성을 향상합니다.
- 더 높은 렌더링 품질을 제공합니다.

2

--- 페이지 3 ---

2 관련 업무

Neural Radiance Fields를 통한 소설적 관점의 합성. Neural Radiance Fields 도입 이후

(NeRF) [28], 3D 장면을 구축하고 표현하는 데 매우 인기가 높아졌습니다. 핵심

이 방법의 기본 아이디어는 모델링 볼륨의 광도 값을 인코딩하는 신경장을 학습하는 것입니다.

그런 다음 광선을 사용하여 볼륨 렌더링을 통해 렌더링하는 데 사용됩니다. 처음 소개된 이후로,

소수의 뷰를 처리하도록 확장[47], 훈련 없이 새로운 장면으로 일반화[34, 47]

동적 [12] 및 무한한 장면 [2], 대략적인 포즈의 이미지 [39], 훈련 속도 향상 [29, 46],

그리고 심지어 몇 가지 예를 들자면 생의학적 응용[7, 51]에도 적용됩니다. 이러한 확장은 결코

철저한 목록을 작성하고 NeRF가 미친 영향을 보여줍니다. 보다 심층적인 조사를 위해서는 다음을 참조하십시오.

독자는 [13]을 참조하세요.

NeRF 작업 중 우리 작업과 가장 관련이 있는 것은 [20]이며, 이 역시 확률적 그라데이션을 사용합니다.

Langevin Dynamics(SGLD)[3]는 훈련할 가장 유망한 샘플을 식별하고 이를 허용합니다.

더 빠른 훈련 수렴. 우리는 같은 Markov Chain Monte Carlo에 기반을 두고 있지만

(MCMC) 패러다임은 SGLD를 기반으로 하지만 애플리케이션 컨텍스트는 완전히 다릅니다. 그들의 작업에서 SGLD

NeRF 훈련을 가속화하기 위해 일종의 '소프트 마이닝'을 수행하는 데 사용됩니다. 우리의 경우에는 대신

3DGS를 3D 장면을 나타내는 기본 분포의 샘플로 다시 생각합니다.

가우스 스플래팅. 3D GS(3D Gaussian Splatting)[19]는 NeRF에 대한 최근 대안입니다.

볼륨 렌더링 대신 미분 가능한 래스터화를 사용합니다. 간단히 말해서 포인트를 쿼리하는 대신

광선을 따라 가우시안을 저장한 다음 이를 각 뷰로 래스터화하여 이미지를 형성할 수 있습니다. 이

래스터화 작업은 빛을 따라 수백 개의 점을 쿼리하는 대신 매우 효율적입니다.

광선을 사용하여 픽셀을 렌더링하려면 주어진 픽셀과 관련된 (몇 가지) 가우스를 간단히 래스터화할 수 있습니다.

따라서 Gaussian Splatting을 사용하면 1080p 이미지를 초당 130프레임으로 렌더링할 수 있습니다.

연구 커뮤니티를 촉진한 최신 GPU.

당연히 다양한 확장이 즉시 이어졌습니다. 여기에는 제거에 중점을 둔 것들이 포함됩니다.

앨리어싱 효과[48, 42], 반사[44] 또는 동적 장면 캡처[41, 43], 3D 콘텐츠 허용

생성 [36, 52, 49], 제어 가능한 3D 아바타 [23] 및 3D 표현 예측

몇 장의 이미지 [5]. 보다 간결한 표현에 중점을 두어 렌더링에 적합한 방법 모바일 장치에서도 제안되었습니다. 이러한 방법은 적응적으로 가우스를 잘라내거나 클러스터링합니다. 색상을 인코딩하기 위한 구형 고조파 수를 선택하고 [32] 표현 [31]. 이러한 확장 기능은 모두 매우 최근에 나온 것이므로 큰 관심을 받고 있습니다. 커뮤니티 내에서 촉발되었습니다. [5]를 제외하고 이러한 방법의 한 가지 핵심 제한 사항은 공유는 모두 3DGS[19]가 제안한 원래의 적응형 밀도 제어 휴리스틱에 의존한다는 것입니다. 이 작업에서 보여주듯이 이것이 항상 작동하는 것은 아니며 주의가 필요합니다. 초기화 또는 적절한 튜닝. 그럼에도 불구하고 렌더링 결과는 최적일 수 있습니다. 에 대한 추가 연구를 통해 관심 있는 독자에게 최근 설문조사를 안내합니다[6]. 동시 작업. Bulot et al. [4]는 최근 다음 문제를 해결하기 위해 치밀화 전략을 수정하도록 제안했습니다. 가우시안 복제 및 높은 훈련을 받은 위치에서 가우스 밀도를 높이는 문제 오류. 그들의 방법은 복제 문제를 부분적으로 해결하지만 앞으로 보여줄 것만으로는 충분하지 않습니다. 섹션 3.4에서. 그들의 오류 기반 치밀화는 우리의 연구 방향과 직교하며 쉽게 우리의 방법에도 통합되어 향후 작업에 맡깁니다. 다른 작품에서는 방법을 탐구합니다. 보조 NeRF 네트워크[10] 또는 훈련된 밀집 기하학 추정기[9]를 통해 더 잘 초기화됩니다.

[37]과 같은. 우리의 경우 문제의 원인을 해결하고 의존도를 줄였습니다.

초기화 자체.

3 방법

먼저 Gaussian Splatting을 MCMC(Markov Chain Monte Carlo) 샘플링으로 재구성합니다. 그러면 우리는 Stochastic Gradient Langevin을 사용하여 MCMC 프레임워크에서 새로운 업데이트 방정식을 도입합니다. 역학 [3, 20]. 그런 다음 3D Gaussian Splatting [19]의 휴리스틱을 어떻게 접을 수 있는지 논의합니다. 새로운 지역화 계획으로 전환합니다. 마지막으로, 우리가 장려하기 위해 사용하는 L1 정규화에 대해 논의합니다. 가우시안의 효율적인 사용 및 구현 세부 사항.

3

--- 페이지 4 ---

3.1 3D Gaussian Splatting에 대한 간략한 검토

재구성하기 전에 먼저 3D Gaussian Splatting [19]의 완전성을 간략하게 검토합니다. 3D

Gaussian Splatting은 장면을 3D 가우시안 세트에 표현한 다음,

-블렌딩을 통해 원하는 뷰를 얻을 수 있습니다. 이는 볼륨 렌더링을 수행하는 효율적인 방법으로 볼 수 있습니다. NeRF [28]에서. 특히, 픽셀 x 를 렌더링하기 위한 카메라 포즈 $\mathbf{c}$ 의 경우 N 가우스를 다음과 같이 정렬합니다. 카메라와의 거리가 멀어지는 순서대로 정렬하고 씁니다.

$C(x) =$

N_X

$\mathbf{c}_i \cdot \mathbf{x}$

$\mathbf{c}_i \cdot \mathbf{x}$

$\mathbf{c}_i \cdot \mathbf{x}$

$\mathbf{c}_i \cdot \mathbf{x}$

$\mathbf{c}_i \cdot \mathbf{x}$

$\mathbf{c}_i \cdot \mathbf{x}$

여기서 $\mathbf{c}_i$ 는 색상으로 변환되는 구형 고조파로 저장된 각 가우스 색상입니다.

포즈 $\mathbf{c}$ 에 따라 불투명도를 α 로, 중심을 μ 로, 공분산을 Σ 로 표시하면,

$$i(x) = \alpha_i \exp$$

- 1

$$2(x - R(i; j))TR(i; j) - 1(x - R(i; j))$$

, (2)

여기서 R은 카메라 투영 작업입니다.

그런 다음 각 픽셀의 색상 값을 사용하여 가우시안을 훈련하여 손실을 최소화합니다.

$$L_{orig} = (1 - D-SSIM) \cdot L_1 + D-SSIM \cdot LD-SSIM, (3)$$

여기서 L_1 은 $C(x)$ 와 실측 색상 $Cgt(x)$ 사이의 평균 L_1 오류이고 LD-SSIM은 다음과 같습니다.

렌더링된 이미지와 실제 이미지 간의 SSIM(구조적 유사성 지수 메트릭) [38]

여기서 [19]에서 제안한 대로 $D-SSIM=0.2$ 입니다.

3.2 Markov Chain Monte Carlo(MCMC)로 3D 가우스 스플래팅

3D Gaussian Splatting에 대한 기존 접근 방식과 달리 학습 프로세스를 해석하는 것을 제한합니다.

가우시안을 샘플링 프로세스로 배치하고 최적화합니다. 손실 함수를 정의하는 대신

간단히 로컬 최소값을 향한 조치를 취하여 높은 할당을 할당하는 분포 G 를 정의합니다.

훈련 이미지를 충실하게 재구성하는 가우스 컬렉션에 대한 확률입니다. 이 선택

MCMC 프레임워크의 강력한 기능을 활용하여 이 배포판에서 샘플을 추출할 수 있습니다.

매개변수를 개별적으로 변경하는 경우에도 수학적으로 잘 동작하는 방식입니다.

공간. 따라서 원래의 분할 및 가지치기와 유사한 개별 작업을 설계할 수 있습니다.

일반적인 연속성의 가정을 깨지 않고 Gaussian Splatting의 경험적 방법을 사용합니다.

그라디언트 기반 최적화.

이를 달성하기 위해 SGLD(Stochastic Gradient Langevin Dynamics) [40, 3] 방법에서 시작합니다.

이는 최근 새로운 뷰 합성 응용 프로그램에도 적용되는 MCMC 프레임워크입니다.

양이온 [20]. SGLD는 이미 일반적으로 사용되는 것과 유사하므로 이 특별한 선택은 편리합니다.

SGD(확률적 경사하강법) 업데이트 규칙이 있지만 확률적 노이즈가 추가됩니다. 구체적으로 말하면,

3DGS에서 단일 가우스 g 의 업데이트를 고려하고 분할/병합을 잠시 무시합니다.

경험적 방법:

$$g \leftarrow g - lr \cdot \nabla g E[l] - l [L_{total}(g; I)], (4)$$

여기서 lr 은 학습률이고 l 은 훈련 이미지 I 세트에서 샘플링된 이미지입니다.

이제 전자를 일반적인 SGLD 업데이트와 비교해 보세요.

$$g \leftarrow g + a \cdot \nabla g \log P(g) + b \cdot \epsilon, (5)$$

여기서 P 는 샘플링하려는 분포에 대한 데이터 종속 확률 밀도 함수입니다.

from, ϵ 는 탐색을 위한 노이즈 분포입니다. 하이퍼파라미터 a 와 b 는 함께

수렴 속도와 탐색 사이의 균형1 우리는 (4)와

(5). 즉, 손실을 기본 분포의 음의 로그 가능성으로 가짐으로써,

$$G = P \propto \exp(-L_{total}), (6)$$

$lr = a$ 및 $b=0$ 이면 방정식은 동일해집니다. 따라서 표준 Gaussian Splatting은

최적화는 우도 분포에서 샘플링된 가우스를 갖는 것으로 이해될 수 있습니다.

이는 렌더링 품질과 관련이 있습니다. 우리는 최적화에 노이즈를 추가하는 것이 매우 중요하다는 점에 주목합니다.

노이즈를 주입하거나 [35, 30, 8] 교란을 수행하는 전통적인 최적화 방법과 관련된

경사하강법 [17, 18]. 여기서는 확률적 관계를 선호하여 MCMC로 공식화합니다.

(6)에서 제공하는 것과 그것이 가능하게 하는 경험적 방법의 제거에 대해서는 Sec. 3.4.

1일반적인 SGLD 형식에서 b 는 일반적으로 a 와 추가 하이퍼 매개변수의 함수로 표현됩니다.

그러나 우리는 [20]에 따라 일반성을 잃지 않고 이 형식으로 다시 작성합니다.

4

--- 페이지 5 ---

(a) 3DGS에서의 복제 [19]

(b) [4]의 복제

(c) 우리의 방법

그림 1: 다양한 부활 전략 그림 - 래스터화의 1D 예를 보여줍니다.

불투명도가 0.95인 가우스, 4개의 동일한 가우스로 복제하기 전후

서로 다른 전략을 사용하여 함께 래스터화합니다. MCMC에는 기존 방법을 사용할 수 없습니다.

선택한 가우스의 범위를 확장하여 분포 불변성을 크게 위반합니다.

3.3 확률적 경사도 Langevin Dynamics를 사용한 업데이트

SGLD와 기존 3DGS 최적화 사이의 연관성을 밝혀낸 후 (4)를 다음과 같이 다시 작성합니다.

$$\mathbf{g} \leftarrow \mathbf{g} - \eta \cdot \nabla_{\mathbf{g}} \mathcal{L}(\mathbf{g}; \mathbf{I}) + \text{noise} \cdot \epsilon, \quad (7)$$

여기서 η 및 ϵ 는 학습 속도와 탐색 양을 제어하는 하이퍼파라미터입니다.

SGLD에 의해 시행됩니다. 실제로는 원시 그래디언트 $\nabla_{\mathbf{g}} \mathcal{L}(\mathbf{g}; \mathbf{I})$ 대신 다음을 사용합니다.

Adam [21] 및 RMSProp [25]에 대한 기본 매개변수를 사용하는 최적화 프로그램.

식 (7)에서는 잡음 항 ϵ 를 신중하게 설계하는 것이 중요합니다. 잡음 항 ϵ 는 다음과 같아야 합니다.

그래디언트 항 $\nabla_{\mathbf{g}} \mathcal{L}(\mathbf{g}; \mathbf{I})$ 에 의해 '균형'을 이룰 수 있는 방식으로 추가되거나 그렇지 않으면 (7) 다음과 같이 감소됩니다.

무작위 업데이트. 예를 들어, 재구성할 때 가우시안의 범위가 좁아지는 것은 매우 일반적입니다.

선과 가장자리를 표현하는 장면. 추가된 소음으로 인해 가우스가 특정 위치로 이동해야 합니까?

이전 지원 지역 밖에서는 이 무작위 보행이 복구 불가능하게 되어

MCMC 샘플링 체인.

우리는 불투명도, 규모, 색상에 대한 탐색이 중요하지 않다는 점을 추가로 확인했습니다.

이러한 매개변수에 노이즈가 발생합니다. 실제로 우리는 경험적으로 노이즈를 추가하면 약간의 해를 끼칠 수 있다는 것을 발견했습니다.

성능; 섹션 4.1을 참조하세요. 반대로, 3DGS 재구성이 가능하다는 것이 [11]에 의해 나타났습니다.

우주 공간이 탐험되지 않은 채로 남겨질 때 심각한 피해를 입을 수 있습니다. 포인트 누락으로 인해

초기화. 이는 노이즈 기반 탐색이 무작위 및 두 가지 모드에 대한 결과를 향상시킬 가능성을 시사합니다.

누락된 형상으로 인해 어려움을 겪는 초기화 및 SFM 파생 초기화.

마지막으로 단순히 탐색이 아닌 '융합' 품질에 관심이 있기 때문에

가우시안이 잘 행동할 때, 즉 안내할 수 있을 만큼 불투명도가 높을 때 소음 발생

그래디언트요. 따라서 우리는 다음과 같은 가우시안 위치에서만 노이즈 항을 설계합니다.

공분산과 불투명도, 학습 속도에 따라 달라집니다.

$$\epsilon = \eta \cdot \nabla_{\mathbf{g}} \mathcal{L}(\mathbf{g}; \mathbf{I})$$

$$k(t) = \frac{1}{1 + \exp(-t)}$$

여기서 $\eta = [\eta_1, \eta_2, \eta_3]$ 입니다. (8)

여기서 $\eta \sim \mathcal{N}(0, \mathbf{I})$, σ 는 시그모이드 함수, k 와 t 는 샤프를 제어하는 하이퍼파라미터입니다.

시그모이드의 특성은 $k=100$ 및 $t=(0.005)$ 로 설정하여 다음과 같은 날카로운 전환 함수를 만듭니다.

3D Gaussian Splatting의 기본 가지치기 임계값을 중심으로 0에서 1로 이동합니다. [19]

가우시안의 불투명도 값. 간단히 말해서, (8)은 이방성 노이즈로 가우스를 교란시킵니다.

가우시안의 동일한 이방성 프로파일 $\mathbf{C}$ 를 사용하는 반면 시그모이드 항은 다음의 효과를 감소시킵니다.

불투명한 가우시안의 노이즈.

3.4 재배치를 통한 상태 전환으로서의 경험적 접근

MCMC[26, 15]의 점프 및 리샘플링 동작에서 영감을 받아 이제 3D에서 휴리스틱이 어떻게 사용되는지 논의합니다.

Gaussian Splatting은 간단한 상태 전환으로 다시 작성할 수 있습니다. 3D Gaussian Splatting에서 휴리스틱

더 많은 '살아있는' 가우스를 장려하기 위해 가우스 '이동', '분할', '복제', '자르기' 및 '추가'에 사용됩니다.

($\alpha_i \geq 0.005$).2 우리는 하나의 샘플 상태 금에서 다른 샘플 상태로 이동하는 이러한 모든 수정 사항을 설명합니다.

샘플 상태 gnew. 이는 가우시안 수가 변경되는 경우에도 적용됩니다.

2이것은 3D Gaussian Splatting[19]에 사용되는 기본 임계값입니다.

5

--- 페이지 6 ---

더 적은 수의 가우시안을 가진 상태를 단순히 더 많은 가우스를 가진 동일한 상태로 생각하십시오.

가우시안이지만 불투명도가 0인 것, 즉 죽은 가우시안을 사용합니다. 중요한 것은 이러한 종류의 경우

MCMC 프레임워크에 통합되는 결정론적 움직임의 경우, 그렇지 않은 것이 중요합니다.

MCMC 샘플링이 붕괴됩니다. 특히, 우리는 표본의 확률을 보존하는 것을 목표로 합니다.

이동 전후의 상태, 즉 $P(\text{gnew}) = P(\text{gold})$ 로 이동을 간단히 볼 수 있습니다.

동일한 확률로 다른 샘플로 이동합니다. 이제 이를 달성하는 방법을 자세히 설명합니다.

다양한 방법이 있을 수 있지만 우리는 '죽은' 가우스를 이동하는 간단한 전략을 선택합니다($\alpha_i <$

0.005) '라이브' 가우스의 위치로 이동합니다. 그렇게 함으로써 우리는 가우시안의 매개변수를 다음과 같이 설정했습니다.

gnew와 gold가 제공하는 렌더링에 미치는 영향 간의 차이를 최소화합니다. 우리는

부록 A의 정확한 파생과 여기에서 업데이트 방정식을 제공합니다. 일반성을 잃지 않고,

$N - 1$ 개의 가우스 $g_1, \dots, g_{N-1}$ 을 g_N 으로 이동하는 것을 고려해보세요. 그런 다음 이전 가우스 매개변수를 나타냅니다.

오래된 위치자와 새로운 위치자를 사용하여 다음과 같이 씁니다.

μ_{new}

$1, \dots, N = \text{old}$

아니, 오 새로운

$1, \dots, N = 1$

엔

큐

1 - 오래된

엔,

μ_{new}

$1, \dots, N =$

오래된

엔

2

$N \times$

$\mu_{\text{new}} = 1$

$i = 1 \dots N$

$k = 0$

$\mu_{\text{new}} = 1$

케이

$(-1)^k (\text{온뉴}$

아니오) $k+1$

$\sqrt{\mu_{\text{new}}}$

케이 + 1

$1/2$

old

엔.

(9)

언뜻 보기에 우리가 선택한 전략은 3D Gaussian Splat의 '복제'와 유사해 보일 수 있습니다.

ting [19]에서 (9)가 가져오는 차이는 매우 중요합니다. 그림 1에서는 단순화된 1D에 대해 이를 설명합니다.

케이스, 높았을 때

$N=0.95$. 그림과 같이 고전적인 복제와 최근 제안된 '중심 수정'

버전 [4]는 복제가 수행될 때 래스터화된 가우스에서 상당한 차이를 가져옵니다.

이는 (1)에서 구성된 불투명도가 여러 가우시안 모양과 그 부정의 곱이기 때문입니다.

두 가지 기존 전략 모두 그림 1과 같이 선택된 가우스 성장 범위로 이어집니다.

이러한 상태의 유사성 측면에서 크게 다릅니다. 즉, $P(\text{gnew}) = P(\text{gold})$ 입니다. 실제로 이것은 최적이지 아닌 훈련으로 이어집니다.

구현. 우리 방법의 결과는 $P(\text{gnew}) \approx P(\text{gold})$ 이지만 정확하지는 않습니다. 그러므로 우리는 신청합니다

이는 학습 프로세스가 중단되지 않도록 100회 반복마다 이동합니다. 이동할 곳을 선택하려면,

각각의 죽은 가우스에 대해 먼저 다항 샘플링을 통해 이동/순간이동할 대상 가우스를 선택했습니다.

불투명도 값에 비례하는 확률을 갖는 라이브 가우스의 확률입니다. 참고하시기 바랍니다

모든 이동 결정이 완료된 후에만 적용합니다(9). 마지막으로 아담을 의지하여

옵티마이저, 순간 통계도 조정되어야 합니다. 목표에 대한 순간 통계를 재설정합니다.

가우스(복제된 원본)는 고정된 상태를 유지하도록 편향되고 새로운 것의 경우

(출처) 탐구를 장려하기 위해 순간 통계를 유지합니다. '죽었기' 때문이다(출처)

가우스는 (7)의 노이즈 항에 의해 지배되며, 따라서 순간 통계는 다음과 같이 적절합니다.

탐색을 촉진합니다.

3.5 더 적은 수의 가우시안 장려

성능을 향상시키면서 메모리와 컴퓨팅을 효과적으로 활용하려면 다음을 권장합니다.

가우스는 유용하지 않은 위치에서 사라지고 다른 곳에서 '다시 생성'됩니다. 의 존재로서

가우스는 불투명도 α 와 공분산 Σ 에 의해 효과적으로 결정되며 두 가지 모두에 정규화를 적용합니다.

이들 중, 전체 훈련 손실은 다음과 같습니다.

$$L_{\text{total}} = (1 - \alpha) \cdot D\text{-SSIM} \cdot L_1 + \alpha \cdot D\text{-SSIM} \cdot LD\text{-SSIM} + \frac{1}{2} \sum_{i,j} \left(\frac{\|\sigma_{ij}\|_1}{\sigma_{ij}^2} + \frac{\|\sigma_{ij}\|_2}{\sigma_{ij}^2} \right)$$

$\times$

나

$$\|\sigma_{ij}\|_1 + \frac{1}{2} \sum_{i,j} \left(\frac{\|\sigma_{ij}\|_1}{\sigma_{ij}^2} + \frac{\|\sigma_{ij}\|_2}{\sigma_{ij}^2} \right)$$

$\times$

ij

큐

$\text{eig}_j(\Sigma_i)$

1

, (10)

여기서 $\text{eig}_j(\cdot)$ 는 공분산 행렬의 j 번째 고유값을 나타냅니다(원리에 따른 분산).

공분산 행렬의 축), α 및 β 는 초매개변수입니다.

3.6 추가 구현 세부정보

우리는 PyTorch[33]를 사용하여 3DGS[19] 프레임워크 위에 우리 방법을 구현합니다.

가우시안 수가 점차 증가합니다. 다른 작품 [19, 4]에서와 마찬가지로 우리는 숫자를 허용합니다.

가우시안이 점차 증가하여 유용한 위치에 배치됩니다. 우리는 이것을 간단하게 한다

처음에는 선택된 수의 가우시안으로 시작한 다음 더 많은 '죽은' 가우시안을 허용하여

6

--- 페이지 7 ---

표 1: 동일한 수의 가우스를 사용한 정량적 결과 - 우리의 방법이 모든 것보다 성능이 뛰어납니다.

무작위 초기화로 시작하더라도 기준선이 유지되고, 다음과 같은 경우 성능 차이가 큼니다.

3DGS[19]와 비교 - 무작위. 각 열에 대해 최고와 차선책을 강조 표시합니다.

NeRF 합성 [28] MipNeRF 360 [2] 탱크 & 템플 [22] 딥 블렌딩 [16] OMMO [27]

PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓

NeRF [29] 31.01 / - / - 24.85 / 0.66 / 0.43 - 21.18 / 0.78 / 0.34 -

플레녹셀 [46] 31.76 / - / - 23.63 / 0.67 / 0.44 21.08 / 0.72 / 0.38 - -

INGP-빅 [29] 33.18 / - / - 26.75 / 0.75 / 0.30 21.92 / 0.75 / 0.31 - -

MipNeRF [1] 33.09 / - / - 27.60 / 0.81 / 0.25 - 21.54 / 0.78 / 0.37 -

MipNeRF360 [2] - 29.23 / 0.84 / 0.21 22.22 / 0.76 / 0.26 - -

3DGS [19]→[4] 33.32 / - / - 28.69 / 0.87 / 0.22 23.14 / 0.84 / 0.21 - -

3DGS [19] (랜덤) 33.42 / 0.97 / 0.04 27.89 / 0.84 / 0.26 21.93 / 0.79 / 0.27 29.55 / 0.90 / 0.33 28.24 / 0.88 / 0.24

당사(랜덤) 33.80 / 0.97 / 0.04 29.72 / 0.89 / 0.19 24.21 / 0.86 / 0.19 29.71 / 0.90 / 0.32 29.31 / 0.90 / 0.20

3DGS [19] (SfM) - 29.30 / 0.88 / 0.21 23.67 / 0.84 / 0.22 29.64 / 0.90 / 0.32 28.83 / 0.89 / 0.22

당사(SfM) - 29.89 / 0.90 / 0.19 24.29 / 0.86 / 0.19 29.67 / 0.89 / 0.32 29.52 / 0.91 / 0.20

이전에 섹션 3.4에서 자세히 설명한 재배치 전략을 통해 '살아남' 수 있습니다. 구체적으로,

원하는 최대 수에 도달할 때까지 라이브 가우스 수를 5%씩 점진적으로 늘립니다.

가우스가 충족됩니다.

초기화 및 훈련. 일반적으로 무작위로 또는 포인트 클라우드에서 샘플을 초기화합니다.

3DGS[19]에서와 같이 SfM(Structure-from-Motion)으로부터. 무작위 초기화를 위해 3DGS [19]를 따릅니다.

카메라 경계 범위의 3배 내에서 100,000개의 가우스를 균일하게 무작위로 샘플링합니다.

상자. 또한 비교를 위해 동일한 학습률과 학습률 스케줄러를 사용합니다. 에 대한

가우시안의 위치를 알아보기 위해 학습률 $1.6e^{-4}$ 에서 시작하여 기하급수적으로 $1.6e^{-6}$ 으로 감소합니다.

모든 실험에서는 별도로 지정하지 않는 한 $\text{noise}=5 \times 10^5$, $\sigma=0.01$ 및 $\alpha=0.01$ 을 사용합니다. 에 대한

Deep Blending [16]에서는 $\sigma=0.001$ 을 사용합니다. 3DGS [19]에 이어 500회의 준비 반복으로 시작합니다.

그 동안 우리는 Sec에서 재지역화를 수행하지 않습니다. 3.4 가우시안 수를 늘리지도 않습니다.

4가지 실험

우리는 합성 및 실제의 다양한 데이터 세트를 사용합니다. 구체적으로 3DGS[19]에서와 같이 모든 장면을 사용합니다.

NeRF Synthetic [28] 데이터 세트에서 Tank & Temples [22]의 [19]에 사용된 것과 동일한 두 장면

딥 블렌딩 [16] 및 MipNeRF 360 [2]에서 공개적으로 사용 가능한 모든 장면. '꽃'을 사용하지 않습니다.

MipNeRF 360 [2]의 'Treehill' 장면은 공개적으로 사용할 수 없습니다. 우리는 모두를 더 사용합니다

먼 물체가 있는 큰 장면의 경우 [10]과 같은 OMMO [27] 데이터 세트의 장면을 제공합니다.

MipNeRF 360 [2]의 경우 결과가 [19]와 호환되도록 하기 위해 실내 장면을 다운샘플링합니다.

2배, 야외 장면은 4배입니다. OMMO [27] 장면 #01의 경우

이미지 크기를 적당한 수준(1000×750)으로 유지하기 위해 이미지를 4번 반복합니다. 다른 모든 장면에서는 다음을 사용합니다.

원본 이미지 해상도. 주요 논문에서는 평균을 요약하여 결과를 보고합니다.

각 데이터 세트에 대한 통계입니다. 여러 표준편차를 포함한 개별 장면에 대한 결과

실행된 데이터는 부록 B에서 확인할 수 있습니다. 각 데이터세트에 대한 라이선스 정보는 부록 E에서 확인할 수 있습니다.

측정항목. 우리는 세 가지 표준 지표인 PSNR(최고 신호 대 잡음비),

SSIM(구조적 유사성 지수 메트릭) [38] 및 학습된 지각 이미지 패치 유사 -

(LPIPS) [50]. 무작위성을 설명하기 위해 모든 실험을 세 번 실행하고 평균을 냈습니다.

결과.

기준선. 우리는 무작위 및 SfM 포인트 클라우드를 모두 사용하여 기존 3DGS [19]와 비교합니다.

기반 초기화 전략. 우리는 실험에 공식 코드를 사용합니다. 우리는 또한

3DGS의 원래 숫자는 [19]이지만 [4]에서 보고한 대로 LPIPS 점수를 수정합니다. 우리는 또한

각 데이터세트에 대한 최신 기준선을 포함합니다.

4.1 결과

동일한 수의 가우시안으로 성능을 발휘합니다. 가우시안의 수는 직접적인 관련이 있으므로 새로운 뷰 렌더링의 품질에 대해 먼저 다음을 사용하여 기존 기준선과 방법을 비교합니다. 3DGS[19]와 동일한 수의 가우시안. 더 자세하게는 가우시안 개수만 설정하면 됩니다. 원래 3DGS[19]에서 사용되었으며 이를 동안 사용할 최대 가우시안 수로 설정했습니다.

7

--- 페이지 8 ---

탱크와 사원에서 기차 [22] Deep Blending에서 놀이방 [16] MipNeRF 360에서 방 [2] 10에서OMMO [27] 그루터기에서MipNeRF 360 [2]

그림 2: 동일한 수의 가우스를 사용한 정성적 하이라이트 - 다음의 예를 제공합니다.

3DGS의 새로운 관점 렌더링 [19] 및 다양한 데이터 세트의 여러 장면에 대한 접근 방식(

무작위 또는 SFM 초기화). 우리는 삽입 수치의 차이점을 강조합니다. 우리의 방법

하이브리드 MCMC 재구성으로 다양한 지역의 디테일을 충실하게 표현합니다.

휴리스틱 없이 탐색할 수 있습니다. 우리의 결과는 더 높은 품질의 재구성을 제공합니다. 제발 확대하여 세부정보를 확인하세요.

훈련과 추론. 표 1에 정량적 결과를 표시하고 정성적 하이라이트를 표시합니다.

그림 2에서 볼 수 있듯이 우리의 방법은 3DGS[19]보다 더 나은 성능을 제공합니다. 흥미롭게도 우리의 무작위로 초기화되거나 SfM 포인트 클라우드로 초기화되는 방법은

MCMC 공식이 제공하는 탐색 덕분에 성능이 향상되었습니다. 이는 우리의 방법을 허용합니다

초기화 전략에 관계없이 3DGS[19]보다 성능이 뛰어납니다.

그림 3: #Gaussians 변경 - 우리

3DGS[19]의 PSNR을 보고하고

모든 데이터 세트에 대해 평균을 낸 방법(예:

NeRF 합성을 제외).

제한된 예산. 우리는 우리의 효율성을 더욱 검증합니다.

가우스 수에 대한 예산을 제한하여 공식화-

모든 데이터 세트에 대한 sians(NeRF Synthetic [28]을 생략함)

합성 데이터 세트의 성능은 매우 포화 상태입니다.

초기화 시 3DGS [19]에서도 강조 표시됨

실험). 가우시안 수를 제한하려면

기존의 3DGS[19], 우리는 단순히 밀도화를 중지합니다.

제한이 있는 경우 더 많은 포인트를 생성하는 전략

가우시안 수에 도달했습니다. 참고하세요

가지치기 전략으로 인해 치밀화가 재개될 수 있습니다.

이 임계값이 다음과 같은 이후에 일부 가우스가 제거되어야 할까요?

만났다. 이 설정에 대한 실험에서는 다음을 사용하고 있습니다.

3DGS[19]는 기본 매개변수를 사용하며 수행하지 않습니다.

추가 하이퍼 튜닝. 우리는 똑같은 하이퍼파라미터를 사용합니다.

Sec에서와 같이 에테르. 3.6 이 실험에서도 마찬가지입니다. 우리는 보고한다

그림 3에 결과를 요약했습니다. 제한된 예산으로

우리 방법과 3DGS[19] 사이의 격차가 증가합니다.

초기화에 대한 민감도. 우리 방법의 중요한 이점은 탐색을 통해 탐색이 가능하다는 것입니다.

MCMC 샘플링 방식을 사용하여 초기화에 대한 3DGS[19]의 과도한 의존도를 제거합니다. 확인하려면

8

--- 페이지 9 ---

표 3: 절제 연구 - 우리는 다양한 구성요소 없이 정량적 지표를 보고합니다.

방법과 3D Gaussian Splatting의 L1 정규화기[19]를 사용합니다. 우리는 MipNeRF 360을 사용합니다 [2]
데이터 세트 및 무작위 초기화. 모든 구성요소는 최종 렌더링 품질에 영향을 미칩니다.

3DGS [19] 3DGS [19]

전체 포함

우리 것

로리그 포함

우리 것

잡음=0

우리 것

모든 매개변수에 노이즈가 있습니다.

우리 것

전체 방법

PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓
PSNR↑/ SSIM↑/ LPIPS↓

27.89 / 0.84 / 0.26 23.84 / 0.77 / 0.33 23.90 / 0.67 / 0.42 27.41 / 0.83 / 0.26 29.11 / 0.86 / 0.24 29.72 / 0.89 / 0.19

(a) MipNeRF 360의 '자전거' [2]

(b) MipNeRF 360의 'Stump' [2]

(c) OMMO의 '03' [27]

그림 4: 노이즈 항()의 효과 - (왼쪽 절반)이 있는 것과 없는 것의 재구성을 시각화합니다.

(오른쪽 절반) (7)의 잡음 항. 전체 장면 범위를 탐색하려면 노이즈 용어가 필수적입니다.

이는 무작위로 배치하는 3DGS의 기본 초기화 전략[19]에서 벗어납니다.

[19]에 정의된 카메라 범위의 3배 이내의 가우스. 대신 카메라 범위의 1배를 사용합니다.

표 2: 초기화 제거 - 당사의 방법

상관없이 비슷한 성능을 보여줍니다.

초기화 전략, 성능은

원본 3DGS[19]는 크게 다릅니다.

3×카메라 범위 [19] 1×카메라 범위

PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓

3DGS [19] (랜덤) 27.89 / 0.84 / 0.26 22.72 / 0.75 / 0.34

우리 것 (랜덤) 29.72 / 0.89 / 0.19 29.64 / 0.89 / 0.19

우리는 평균에 대한 결과를 요약합니다.

표 2의 MipNeRF 360 [2]의 모든 장면.

표시된 대로, 우리의 방법은 다음에 대한 견고성을 제공합니다.

초기화 전략인 반면, 3DGS[19]는

신중한 초기화가 필요합니다. 이것도 분명하다

섹션 4.1에서 무작위로 결과를 얻었습니다.

초기화는 해당 초기화와 경쟁력을 유지합니다.

SfM 포인트 클라우드로 초기화되었습니다.

절제. 우리는 절제 연구를 추가로 수행합니다.

탭에서. 3. 가우시안의 불투명도와 규모에 정의된 정규화가 도움이 될 수 있는지 평가합니다.

기존 3DGS[19]와 MipNeRF 360[2]을 사용하여 이것이 우리 방법에 얼마나 필수적인지

데이터 세트와 무작위 초기화를 사용하면 효과를 더 쉽게 관찰할 수 있습니다. 우리의 경우

탐색이 장려되는 방법은 총을 쏘는 길 잃은 가우스를 방지하는 데 필수적입니다.

재구성 손실로 인해 잘 업데이트되지 않는 공간(예: 뷰 외부 영역)으로 이동

절두체. 노이즈의 존재는 최고의 성능을 달성하는 데 매우 중요합니다. 노이즈가 없으면 노이즈가 없기 때문입니다.

그림 4에서 설명한 것처럼 장면의 전체 범위를 탐색할 수는 없습니다. 또한 정규화 도구는 다음과 같습니다. 휴리스틱과 호환되지 않기 때문에 기존 3DGS [19]와 함께 사용하면 다소 해로울 수 있습니다. 거기에서 제안했다.

Tab에서도 탐색합니다. 3 다른 매개변수에 노이즈를 추가합니다. (8)의 위치 노이즈 외에도 크기 조정 및 회전에는 $N(0, I)$ 을 적용하고 불투명도에는 $N(0, 0.1 \times I)$ 을 적용하여 기하급수적으로 줄입니다. 각 반복마다 0.9995의 감쇠율을 사용합니다. 이 약간 더 나쁜 성능은 다른 매개변수는 가우스 위치만큼 많은 탐색이 필요하지 않습니다.

Tank & Temples [22]에서는 다음과 같이 노이즈 스케줄러의 설계 선택을 추가로 조사했습니다.

공분산 항과 불투명도 항을 제거합니다. 공분산 항 없이 PSNR을 달성합니다.

23.16의 반면, 공분산 항은 24.21입니다. 불투명도 용어가 없으면 22.47을 달성합니다.

또한 두 용어보다 실적이 더 나쁩니다. 불투명도 용어를 제거하려면 다음이 필요합니다.

noise를 0.05로 설정해야 합니다. 그렇지 않으면 모델이 훈련에 실패합니다($PSNR < 7$).

마지막으로 노이즈 스케줄링이 미치는 영향도 비교합니다. 동일한 지수 스케줄링 사용

우리가 사용하는 3DGS[19]에서와 같이 24.21 PSNR의 최고 성능을 달성하는 반면 선형

스케줄러는 17.64를 제공합니다. 우리는 22.46을 제공하는 [30]에서 제안된 스케줄러와 추가로 비교합니다.

9

--- 페이지 10 ---

표 4: 타이밍 - 다양한 불투명 정규화기(σ) 설정을 사용하여 방법의 타이밍을 보고합니다.

최대 가우스 수는 300,000개입니다. 우리의 방법은 더 빠른 훈련을 제공하면서도 동시에 재건축 품질을 유지합니다.

3DGS [19] 우리 것 ($\sigma=0.01$) 우리 것 ($\sigma=0.001$) 우리 것 ($\sigma=0.01, 300k$)

PSNR 31.7 32.5 32.4 31.8

시간 25분 42분 30분 21분

4.2 계산 시간

우리의 방법은 이전 작업과 동일한 3D Gaussian Splat 표현을 생성하므로 추론 시간은

이는 매우 효율적인 3DGS[19]와 동일하다. 정확한 비교를 위해 저희는

우리의 Gaussian은 1M Gaussian으로 훈련되었으며 단일 최적화 반복 시간을 다시 측정했습니다.

우리의 방법과 원래의 3DGS. 이 경우 우리는 80밀리초가 걸리는 반면 3DGS는 76밀리초가 걸립니다.

밀리초. 즉, 샘플링과 노이즈 추가에 추가되는 시간은 우리의 경우에도 상당하지 않습니다.

PyTorch [33]'storch.multinomial을 사용하여 순진하게 리샘플링을 구현하는 구현입니다.

CUDA 구현을 통해 더욱 가속화될 수 있습니다.

또한 가우시안의 구성(즉, 위치, 크기 및 불투명도)이 중요합니다.

래스터화 속도에 영향을 미치기 때문에 런타임에 크게 영향을 미칩니다(그 중 불투명도

정규화는 속도에 가장 큰 영향을 미칩니다. 따라서 우리는 'Room' 장면의 런타임을 평가합니다.

MipNeRF 360 데이터 세트, 모두 SfM 초기화 및 최대 1.5M 가우스 수 포함

원래의 3DGS 구현. Tab에서 타이밍을 보고합니다. 4. 그림과 같이 우리의 방법은

가장 높은 PSNR을 달성하는 데 시간이 더 오래 걸릴 수 있으며, 유사한 PSNR이 필요할 때 더 빠르게 훈련됩니다. 안

우리 방법[45]을 독립적으로 구현하면 훈련 시간이 20% 감소하고

우리 방법을 사용할 때 필요한 메모리가 65% 감소합니다.

5 결론

본 논문에서는 3D Gaussian Splatting [19] 훈련을 Markov Chain Monte로 재구성했습니다.

Carlo(MCMC)를 사용하고 SGLD(Stochastic Gradient Langevin Dynamics)를 통해 이를 구현합니다. 함으로써

따라서 우리는 포인트 클라우드 초기화의 필요성을 제거하고 휴리스틱 기반을 피할 수 있음을 보여줍니다.

치밀화, 가지치기 및 재설정. 우리는 이 전략이 전체에 걸쳐 잘 일반화된다는 것을 보여줄 뿐만 아니라

다양한 장면에서 원래의 3D Gaussian Splatting [19]보다 성능이 뛰어났지만 처음으로 우리는

이것이 어려운 과제에서 NeRF 백본을 증가하는 3DGS 구현으로 이어진다는 것을 보여줍니다.

MipNeRF3360 [2] 데이터 세트.

감사의 말씀 Charatan et al.에게 감사의 말씀을 전합니다. [5], 다루는 영감으로

배포판으로서의 3DGS 최적화는 그들의 작업에서 영감을 받았습니다. 마찬가지로, 우리는 감사하고 싶습니다

Goliet al. [14], 가우시안에 노이즈를 추가한다는 개념은

위치 널 공간. 또한 Sergio Orts Escolano와 Federico Tombari에게도 감사의 말씀을 전하고 싶습니다.

그들의 피드백. 이 연구는 자연과학과 공학 연구의 일부 지원을 받았습니다.

캐나다 평의회(NSERC) 디스커버리 보조금, NSERC 공동 연구 및 개발

Grant, Google, 캐나다 디지털 연구 연합(Digital Research Alliance of Canada) 및 고급 연구 컴퓨팅(Advanced Research Computing)

브리티시 컬럼비아 대학교 및 SFU 비주얼 컴퓨팅 연구 의장 프로그램.

참고자료

[1] Barron, J.T., Mildenhall, B., Tancik, M., Hedman, P., Martin-Brualla, R., Srinivasan, P.P.:

Mip-nerf: 엔티앨리어싱 신경 방사 필드에 대한 다중 스케일 표현입니다. 에서: Int. 회의 계산. 비스. (2021)

[2] Barron, J.T., Mildenhall, B., Verbin, D., Srinivasan, P.P., Hedman, P.: Mip-nerf 360: 무제한 엔티앨리어싱된 신경 방사 필드. 에서: IEEE 컨퍼런스. 계산. 비스. 패턴 인식 (2022)

[3] Brosse, N., Moulines, E., Durmus, A.: 확률적 그래데이션의 가능성과 함정
량주행 다이내믹스. 에서: 고급 신경 정보. 프로세스. 시스템. (2018)

10

--- 페이지 11 ---

[4] Bul, S.R., Porzi, L., Kotschieder, P.: 가우스 스피래팅의 치밀화 수정. arXiv 사전 인쇄(2024)

[5] Charatan, D., Li, S., Tagliasacchi, A., Sitzmann, V.: pixelplat: 이미지의 3d 가우스 표시 확장 가능한 일반화 가능한 3D 재구성을 위한 쌍입니다. arXiv 사전 인쇄(2023)

[6] Chen, G., Wang, W.: 3D 가우스 스피래팅에 관한 조사. arXiv 사전 인쇄(2024)

[7] 코로나-피게로아, A., Frawley, J., Bond-Taylor, S., Bethapudi, S., Shum, H.P.H., Willcocks, C.G.: Mednerf: 3D 인식 CT 투영을 재구성하기 위한 의료 신경 방사 필드 엑스레이 1회(2022년)

[8] Deng, Z., Huang, J., Kawaguchi, K.: 기울기 노이즈 감소가 성능에 어떻게 도움이 되는지
신경망. In: 빅데이터(빅데이터)에 관한 IEEE 국제 컨퍼런스(2021)

[9] Fan, Z., Cong, W., Wen, K., Wang, K., Zhang, J., Ding, X., Xu, D., Ivanovic, B., Pavone, M., Pavlakos, G., Wang, Z., Wang, Y.: Instantsplat: 무제한 희소 뷰 포즈 없는 가우스
40초 만에 튀기(2024)

[10] Foroutan, Y., Rebain, D., Yi, K.M., Tagliasacchi, A.: 가우스 스피래팅에 sfm 초기화가 필요한가요?
화? arXiv 사전 인쇄(2024)

[11] Foroutan, Y., Rebain, D., Yi, K.M., Tagliasacchi, A.: SFM 포인트 클라우드에 대한 대안 평가
가우스 스피래팅 초기화(2024), <https://arxiv.org/abs/2404.12547>

[12] Gafni, G., Thies, J., Zollhofer, M., Niessner, M.: 단안용 동적 신경 복사장
4D 얼굴 아바타 재구성. <https://arxiv.org/abs/2012.03065> (2020)

[13] Gao, K., Gao, Y., He, H., Lu, D., Xu, L., Li, J.: Nerf: 3D 비전의 신경 복사장, a
종합적인 검토. arXiv 사전 인쇄(2022)

[14] Goli, L., Reading, C., Sellan, S., Jacobson, A., Tagliasacchi, A.: 베이즈 광선: 불확실성
신경 복사장에 대한 정량화. 에서: IEEE 컨퍼런스. 계산. 비스. 패턴 인식 (2024)

[15] Green, P.J.: 가역 점프 마르코프 체인 몬테카를로 계산 및 베이지안 모델

결심. Biometrika 82(4), 711-732 (1995)

[16] Hedman, P., Philip, J., Price, T., Frahm, J.M., Drettakis, G., Brostow, G.: 딥 블렌딩 자유 시점 이미지 기반 렌더링. ACM 트랜스. 그래프. (2018)

[17] Jin, C., Ge, R., Netrapalli, P., Kakade, S.M., Jordan, M.I.: 안장 지점을 탈출하는 방법 효율적으로. 에서: Int. 회의 마하. 배우다. (2017)

[18] Jin, C., Netrapalli, P., Ge, R., Kakade, S.M., Jordan, M.I.: 비볼록 최적화에 대해 기계 학습: 기울기, 확률 및 안장점. ACM 저널(JACM) 68(2), 1-29 (2021)

[19] Kerbl, B., Kopanas, G., Leimkuhler, T., Drettakis, G.: 실시간을 위한 3D 가우스 스피래팅 래디언스 필드 렌더링. 그래픽에 대한 ACM 거래(2023)

[20] Kheradmand, S., Rebain, D., Sharma, G., Isack, H., Kar, A., Tagliasacchi, A., Yi, K.M.: 소프트 마이닝을 통한 신경장 훈련 가속화. 에서: IEEE 컨퍼런스. 계산. 비스. 패턴 인식. (2024)

[21] Kingma, D.P., Ba, J.: Adam: 확률론적 최적화 방법. 에서: Int. 회의 배우다. 대표하다. (2015)

[22] Knapitsch, A., Park, J., Zhou, Q.Y., Koltun, V.: 탱크 및 사원: 대규모 벤치마킹 장면 재구성. ACM 트랜스. 그래프. (2017)

[23] Kocabas, M., Chang, J.H.R., Gabriel, J., Tuzel, O., Ranjan, A.: 포옹: 인간 가우스 표시. arXiv 사전 인쇄(2023)

[24] Kolouri, S., Nadjahi, K., Simsekli, U., Badeau, R., Rohde, G.: 일반화된 얇게 썬 Wasserstein 거리. 에서: 고급 신경 정보. 프로세스. 시스템. (2019)

11

--- 페이지 12 ---

[25] Li, J., Wang, W., Ji, H.: 이미지 재구성을 위한 자기주도 딥러닝: A langevin 몬테카를로 접근법. 이미징 과학에 관한 SIAM 저널(2023)

[26] Lindsey, M., Weare, J., Zhang, A.: 순간 이동 위커가 있는 앙상블 마르코프 체인 몬테 카를로. 불확실성 정량화에 관한 SIAM/ASA 저널(2022)

[27] Lu, C., Yin, F., Chen, X., Liu, W., Chen, T., Yu, G., Fan, J.: 대규모 실외 다중 모드 새로운 뷰 합성 및 암시적 장면 재구성을 위한 데이터셋 및 벤치마크입니다. 에서: Int. 회의 계산. 비스. (2023)

[28] Mildenhall, B., Srinivasan, P.P., Tancik, M., Barron, J.T., Ramamoorthi, R., Ng, R.: Nerf: 뷰 합성을 위한 신경 방사 필드로 장면을 표현합니다. ACM의 통신 (2021)

[29] Muller, T., Evans, A., Schied, C., Keller, A.: 다중 해상도를 갖춘 즉각적인 신경 그래픽 프리미티브 루션 해시 인코딩. 그래픽에 대한 ACM 트랜잭션(2022)

[30] Neelakantan, A., Vilnis, L., Le, Q.V., Sutskever, I., Kaiser, L., Kurach, K., Martens, J.: 추가 그래디언트 노이즈는 매우 깊은 네트워크에 대한 학습을 향상시킵니다. arXiv 사전 인쇄(2015)

[31] Niedermayr, S., Stumpfegger, J., Westermann, R.: 압축된 3d 가우스 스피래팅 신규 시점 합성 가속화(2023)

[32] Papantonakis, P., Kopanas, G., Kerbl, B., Lanvin, A., Drettakis, G.: 기억력 감소-3D 가우스 스피래팅 인쇄. 컴퓨터 그래픽 및 인터랙티브에 관한 ACM 절차 테크닉스(2024)

[33] Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L. 등: Pytorch: 명령형 스타일, 고성능 딥 러닝 도서관. 에서: 고급 신경 정보. 프로세스. 시스템. (2019)

- [34] Rematas, K., Martin-Brualla, R., Ferrari, V.: Sharf: a의 형상 조건 복사 필드 단일보기. 에서: Int. 회의 마하. 배우다. (2021)
- [35] Steijvers, M., Gr nwald, P.: 상황에 맞는 예측을 수행하는 순환 네트워크 작업. In: 인지과학학회 제18차 연례회의의 진행 (1996)
- [36] Tang, J., Ren, J., Zhou, H., Liu, Z., Zeng, G.: Dreamgaussian: 생성적 가우스 스피래팅 효율적인 3D 콘텐츠 제작. arXiv 사전 인쇄(2023)
- [37] Wang, S., Leroy, V., Cabon, Y., Chidlovskii, B., Revaud, J.: Dust3r: 기하학적 3D 비전 제작 쉽다. 에서: CVPR (2024)
- [38] Wang, Z., Bovik, A.C., Sheikh, H.R., Simoncelli, E.P.: 이미지 품질 평가: 오류로부터 구조적 유사성에 대한 가시성. IEEE 트랜스. 이미지 프로세스. (2004)
- [39] Wang, Z., Wu, S., Xie, W., Chen, M., Prisacariu, V.A.: NeRF : 신경 복사장 알려진 카메라 매개 변수가 없습니다. arXiv 사전 인쇄(2021)
- [40] Welling, M., Teh, Y.W.: 확률적 경사 랑주빈 역학을 통한 베이지안 학습. 에서: Int. 회의 마하. 배우다. (2011)
- [41] Wu, G., Yi, T., Fang, J., Xie, L., Zhang, X., Wei, W., Liu, W., Tian, Q., Wang, X.: 4d 가우스 실시간 동적 장면 렌더링을 위한 스피래팅. arXiv 사전 인쇄(2023)
- [42] Yan, Z., Low, W.F., Chen, Y., Lee, G.H.: 엔티앨리어싱을 위한 다중 규모 3D 가우스 스피래팅 렌더링. arXiv 사전 인쇄(2023)
- [43] Yang, Z., Gao, X., Zhou, W., Jiao, S., Zhang, Y., Jin, X.: 변형 가능한 3d 가우스 충실도 단안 동적 장면 재구성. arXiv 사전 인쇄(2023)
- [44] Ye, K., Hou, Q., Zhou, K.: 자연 반사를 사용한 3d 가우스 스피래팅. arXiv 사전 인쇄(2024)

12

--- 페이지 13 ---

- [45] Ye, V., Li, R., Kerr, J., Turkulainen, M., Yi, B., Pan, Z., Seiskari, O., Ye, J., Hu, J., Tancik, M., Kanazawa, A.: gsplat: 가우스 스피래팅을 위한 오픈 소스 라이브러리. arXiv 사전 인쇄(2024)
- [46] Yu, A., Li, R., Tancik, M., Li, H., Ng, R., Kanazawa, A.: 실시간 렌더링을 위한 PlenOctrees 신경 방사 필드. 에서: ICCV (2021)
- [47] Yu, A., Ye, V., Tancik, M., Kanazawa, A.: pixelnerf: 하나 또는 몇 개의 신경 복사장 이미지. 에서: IEEE 컨퍼런스. 계산. 비스. 패턴 인식 (2021)
- [48] Yu, Z., Chen, A., Huang, B., Sattler, T., Geiger, A.: Mip-splatting: Alias-free 3d 가우스 튀는. arXiv 사전 인쇄(2023)
- [49] Yuan, Y., Li, X., Huang, Y., De Mello, S., Nagano, K., Kautz, J., Iqbal, U.: Gavatar: 애니메이션 가능 암시적 메쉬 학습을 갖춘 3D 가우스 아바타. arXiv 사전 인쇄(2023)
- [50] Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O.: 불합리한 효과 지각 지표로서의 심층 기능. 에서: IEEE 컨퍼런스. 계산. 비스. 패턴 인식 (2018)
- [51] Zhong, E.D., Lerer, A., Davis, J.H., Berger, B.: Cryodrgn2: Ab initio 신경 재구성 실제 극저온 이미지에서 얻은 3D 단백질 구조. 에서: Int. 회의 계산. 비스. (2021)
- [52] Zou, Z.X., Yu, Z., Guo, Y.C., Li, Y., Liang, D., Cao, Y.P., Zhang, S.H.: Triplane이 가우스를 만나다 splatting: 변환기를 사용하여 빠르고 일반화 가능한 단일 뷰 3D 재구성. arXiv 사전 인쇄 (2023)

13

--- 페이지 14 ---

부록

복제 전략의 파생

렌더링 결과에 최소한의 영향을 미치기 위해 차이를 최소화하는 전략을 제안합니다.

복제 전과 후의 가우스 래스터화 결과 사이. 단순화를 위해
 가우시안 지수에 대한 아래 첨자를 삭제하고 선택된 가우시안이 다음과 같은 경우만 고려하십시오.
 여러 복사본으로 복제할 수 있습니다. 복제된 가우시안에 대해 $c_{new}=c_{old}$ 를 설정하고 가우시안으로서도 설정합니다.
 3D Gaussian Splatting에서 사용하는 것은 정규화되지 않았으므로 중앙 $C(x)$ 값을 동일하게 설정합니다.
 분할 전후, 즉 $C_{new}(\cdot)=C_{old}(\cdot)$ 입니다. (1)에 $x = \mu$ 를 대입하면 이는 다음을 의미합니다.
 $(1 - \text{온유})N = 1 - \text{오래된}$, (11)
 이는 $N=2$ 인 경우 [4]와 동일합니다.
 그러나 (11)은 [4]에서 이미 언급한 것처럼 래스터화를 유지하는 데 충분하지 않습니다.
 포인트 소스가 아닙니다. 따라서 이러한 가우스의 공분산 Σ 를 변경해야 합니다. 보장하는 한 가지 방법

최소한의 영향은 평균 제곱 오차를 최소화하는 것입니다.
 최소화하다

Z

끝

$C_{new}(x) - C_{old}(x)$

2

$2dx$, (12)

그러나 이를 해결하면 간단한 분석 형식이 없는 복잡한 방정식이 생성됩니다.
 따라서 우리는 통과하는 가우시안의 무작위 1D 슬라이스를 고려하는 대체 솔루션을 선택합니다.
 얇게 썬 Wasserstein 방법에서 영감을 받아 중심을 통과합니다 [24]. 가우시안이 공유한다는 점을 고려하면
 복제 작업 전후의 래스터화 적분은 다음과 동일해야 합니다.
 임의의 슬라이스에 대해 래스터화를 동일하게 유지합니다. 따라서 이 임의의 점을 따라 점을 표시합니다.
 $S(\cdot)$ 를 $x = S(x)$ 로 슬라이스하고 대신 다음과 같이 씁니다.
 최소화하다

Z

끝

$C_{new}(x)dx -$

Z

끝

$C_{old}(x)dx$

2

2

, $\forall S$. (13)

이 방정식에는 간단한 분석 솔루션이 있으며 다음을 달성할 수 있습니다.

R

$\text{Infini } C_{new}(x)dx = R$

(9)의 업데이트 방정식을 포함하여 여러 가지 방법으로 $C_{old}(x)dx$ 를 계산합니다. 이를 고려하여 이제 우리는 어떻게
 우리는 저울을 수정합니다.

일반성을 잃지 않고 단순화하기 위해 복제된 가우스의 평균 μ 를 0으로 간주하겠습니다.

방정식을 더 자세히 살펴보세요. 슬라이스 x 를 따라 있는 점 외에도 '슬라이스'를 추가로 표시해 보겠습니다.

공분산은 $\Sigma = S(\cdot)$ 입니다. 그런 다음 (2)를 (1)에 연결하여 새로운 가우시안에 대해 이제 다음과 같이 쓸 수 있습니다.

$C_{new}(x) =$

NX

$\text{나는}=1$

온유 특급

- x2
 2 new
 $i = 1$
 $j = 1$

1 온유 경험치

- x2
 2 new

,
 =
 NX
 나눈=1
 온유 특급

- x2
 2 new

1 온유 경험치

- x2
 2 new
 나눈=1

.
 (14)
 흥미롭게도 여기서 N-power는 $p < 1$ 에 대해 다음과 같은 사실로 인해 더욱 단순해질 수 있습니다.

$(1 - p)N =$
 NX
 $k = 0$
 엔
 케이

$(1 - p)k(p)k$, (15)
 이를 통해 (14)를 다음과 같이 다시 작성할 수 있습니다.

$C_{new}(x) =$
 NX
 나눈=1
 $i = 1$
 $k = 0$
 나눈 - 1
 케이

$(1 - p)k(1 - p)k + 1 \exp$

- x2

$$2 \text{ new}$$

$$(k+1)$$

$$,$$

$$=$$

$$NX$$

$$나는=1$$

$$i \text{ } 1X$$

$$k=0$$

$$나는 - 1$$

$$케이$$

$$(\text{ } 1)k(new)k+1 \exp$$

$$(k + 1)x2$$

$$2 \text{ new}$$

$$.$$

$$(16)$$

$$14$$

--- 페이지 15 ---

표 5: 동일한 수의 가우스를 사용한 모든 결과 - 우리는 방법의 성능을 보고합니다.
 동일한 수의 가우시안을 사용하는 3DGS [19]. 꼬리표. 1은 이 테이블의 평균 항목을 보고합니다.
 우리의 방법은 전반적으로 3DGS[19]보다 성능이 뛰어납니다. 무작위가 아닌 결과는 포함되지 않습니다.
 이 데이터 세트에는 COLMAP 포인트 클라우드가 포함되어 있지 않으므로 NeRF Synthetic에서 초기화됩니다.
 3DGS [19] (무작위) 3DGS [19] (SfM) 우리 것 (무작위) 우리 것 (SfM)
 PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓ PSNR↑/ SSIM↑/ LPIPS↓
 NeRF 합성 [28]
 마이크 35.35 / 0.99 / 0.01 - 37.29 / 0.99 / 0.01 -
 선박 30.93 / 0.90 / 0.13 - 30.82 / 0.91 / 0.12 -
 레고 35.84 / 0.98 / 0.02 - 36.01 / 0.98 / 0.02 -
 의자 36.17 / 0.99 / 0.02 - 36.51 / 0.99 / 0.02 -
 재료 30.00 / 0.96 / 0.04 - 30.59 / 0.96 / 0.04 -
 핫도그 37.83 / 0.99 / 0.03 - 37.82 / 0.99 / 0.02 -
 드럼 26.22 / 0.95 / 0.04 - 26.29 / 0.95 / 0.04 -
 무화과나무 35.01 / 0.99 / 0.01 - 35.07 / 0.99 / 0.01 -
 평균 33.42 / 0.97 / 0.04 - 33.80 / 0.97 / 0.04 -
 표준 0.0076 / 0.0000 / 0.0000 - 0.0105 / 0.0000 / 0.0000 -
 밍네르프 360 [2]
 카운터 28.09 / 0.88 / 0.30 29.12 / 0.91 / 0.24 29.16 / 0.92 / 0.23 29.51 / 0.92 / 0.22
 그루터기 23.91 / 0.68 / 0.33 26.99 / 0.78 / 0.24 27.67 / 0.82 / 0.20 27.80 / 0.82 / 0.19
 주방 30.54 / 0.92 / 0.16 31.58 / 0.93 / 0.14 32.23 / 0.94 / 0.14 32.27 / 0.94 / 0.14
 자전거 24.57 / 0.70 / 0.33 25.64 / 0.78 / 0.23 26.06 / 0.81 / 0.19 26.15 / 0.81 / 0.18
 분재 30.94 / 0.93 / 0.26 32.32 / 0.95 / 0.24 32.67 / 0.95 / 0.23 32.88 / 0.95 / 0.22
 방 30.04 / 0.90 / 0.32 31.70 / 0.93 / 0.27 32.30 / 0.94 / 0.25 32.48 / 0.94 / 0.25
 정원 27.16 / 0.86 / 0.14 27.73 / 0.87 / 0.12 27.99 / 0.88 / 0.11 28.16 / 0.89 / 0.10
 평균 27.89 / 0.84 / 0.26 29.30 / 0.88 / 0.21 29.72 / 0.89 / 0.19 29.89 / 0.90 / 0.19

표준 0.0524 / 0.0021 / 0.0016 0.0276 / 0.0003 / 0.0003 0.0246 / 0.0001 / 0.0003 0.0154 / 0.0001 / 0.0001
 탱크 &

사원 [22]

기차 21.24 / 0.77 / 0.30 21.94 / 0.81 / 0.25 22.40 / 0.83 / 0.24 22.47 / 0.83 / 0.24

트럭 22.63 / 0.82 / 0.24 25.40 / 0.88 / 0.18 26.02 / 0.89 / 0.14 26.11 / 0.89 / 0.14

평균 21.93 / 0.80 / 0.27 23.67 / 0.84 / 0.22 24.21 / 0.86 / 0.19 24.29 / 0.86 / 0.19

표준 0.0521 / 0.0008 / 0.0007 0.0639 / 0.0004 / 0.0004 0.0729 / 0.0007 / 0.0007 0.0688 / 0.0004 / 0.0008

깊은

블렌딩 [16]

존슨 박사 28.94 / 0.89 / 0.34 29.14 / 0.90 / 0.33 29.05 / 0.89 / 0.33 29.00 / 0.89 / 0.33

놀이방 30.16 / 0.90 / 0.32 30.15 / 0.90 / 0.32 30.37 / 0.90 / 0.31 30.33 / 0.90 / 0.31

평균 29.55 / 0.90 / 0.33 29.64 / 0.90 / 0.32 29.71 / 0.90 / 0.32 29.67 / 0.89 / 0.32

표준 0.0688 / 0.0007 / 0.0010 0.0487 / 0.0003 / 0.0002 0.0556 / 0.0015 / 0.0010 0.0458 / 0.0022 / 0.0022

옴모 [27]

01 25.13 / 0.77 / 0.27 25.64 / 0.79 / 0.25 25.90 / 0.80 / 0.23 25.89 / 0.80 / 0.22

03 25.61 / 0.86 / 0.27 25.80 / 0.87 / 0.26 27.38 / 0.89 / 0.22 27.62 / 0.90 / 0.22

05 27.66 / 0.86 / 0.29 28.37 / 0.87 / 0.28 28.81 / 0.88 / 0.27 28.87 / 0.88 / 0.27

06 27.12 / 0.91 / 0.25 26.79 / 0.91 / 0.25 27.52 / 0.94 / 0.20 27.65 / 0.94 / 0.19

10 29.64 / 0.87 / 0.26 29.99 / 0.89 / 0.23 31.20 / 0.90 / 0.22 31.51 / 0.91 / 0.20

13 31.60 / 0.92 / 0.22 32.75 / 0.94 / 0.18 32.65 / 0.94 / 0.18 33.14 / 0.95 / 0.16

14 30.33 / 0.93 / 0.19 30.87 / 0.94 / 0.17 31.03 / 0.94 / 0.17 31.26 / 0.94 / 0.16

15 28.79 / 0.90 / 0.19 30.46 / 0.93 / 0.16 29.96 / 0.93 / 0.16 30.25 / 0.93 / 0.15

평균 28.24 / 0.88 / 0.24 28.83 / 0.89 / 0.22 29.31 / 0.90 / 0.20 29.52 / 0.91 / 0.20

표준 0.0265 / 0.0006 / 0.0007 0.0299 / 0.0004 / 0.0003 0.0233 / 0.0002 / 0.0001 0.0226 / 0.0001 / 0.0003

마지막으로 다음과 같이

R

$\exp(-ax^2) =$

피

어떤 값 a 에 대한 $1/a$, (16)을

R

$\int_{-\infty}^{\infty} \exp(-ax^2) dx = \sqrt{\pi/a}$

$\int_{-\infty}^{\infty} \exp(-ax^2) dx$ 우리는 쓴다

NX

나는=1

$i = 1 \dots N$

$k=0$

나는 - 1

케이

$(-1)^k (\text{온뉴})^{k+1}$

아르

$2 \dots \text{new}$

$k+1 = \text{오래된 } \sqrt{}$

$2 \dots \text{old. (17)}$

new 에 대해 풀면 우리는 얻는다.

$\text{new} =$

오래된 2

N_X

$n_{\text{is}}=1$

$i \sim 1 \times$

$k=0$

$n_{\text{is}} - 1$

케이

$(-1)^k (\text{온류})^{k+1}$

$\sqrt{}$

케이 + 1

! 2

old. (18)

우리는 임의의 슬라이스 $S(\cdot)$ 에 대해 (18)을 유지하기를 원하므로 간단히 를 로 대체할 수 있습니다. 그런 다음 (9)의 업데이트 방정식을 사용합니다.

15

--- 페이지 16 ---

B 상세 결과

Tab의 모든 장면에 대한 모든 숫자를 보고합니다. 5. 표준편차(std)는 다음을 기준으로 계산됩니다.

세 가지 다른 실행에서 얻은 평균. 여기서 각 평균은 한 장면의 모든 장면에서 계산됩니다.

특정 시드에 대한 데이터 세트입니다.

C 제한사항 및 향후 작업

우리의 방법은

MCMC에 의해 도입된 탐색은 여전히 3DGS[19]와 동일한 제한을 받습니다.

모델링 능력. 예를 들어, [48]에서 해결된 앨리어싱 문제는 우리의 문제일 수도 있습니다.

방법 및 반사 모델링 [44]. 그러나 우리의 방법은 다음과 호환되어야 합니다.

우리의 방법이 더 나은 훈련 프레임워크로 볼 수 있기 때문에 Gaussian Splatting의 발전

가우시안 스피랫(Gaussian Splats)용. 즉, 다른 모든 Gaussian Splatting 방법을 향상시켜야 합니다.

가능합니다.

D 더 넓은 영향

우리의 방법은 3D 재구성의 핵심 문제에 초점을 맞추고 있기 때문에 즉각적인 결과를 얻지는 못합니다.

그러나 사회적 영향은 다운스트림 애플리케이션에 파급력을 미칠 수 있습니다. 왜냐하면

우리의 방법은 초기화에 대한 Gaussian Splatting의 의존도를 줄입니다.

다운스트림 애플리케이션. 예를 들어, 3D 콘텐츠 생성 [36, 52, 49]은 종종 다음과 같은 문제를 겪습니다.

Gaussian Splatting의 휴리스틱을 제거했습니다. 제어 가능한 인간 모델링 [23]을 위해 우리는

방법은 또한 품질을 향상시킬 수 있는 잠재력을 가지고 있습니다. 따라서 우리의 방법은 간접적으로 무엇을 향상시킬 수 있습니까?

생성 방법은 물론 인간 아바타도 사용할 수 있습니다. 두 응용 프로그램 모두 다음과 같은 가능성이 있습니다.

오용될 수 있습니다. 이는 모든 기술의 문제이므로 사용자가 그 의미에 대해 생각해 볼 것을 권장합니다.

우리의 방법을 적용하기 전에.

E 데이터세트 라이선스

우리는 다음 데이터세트를 사용합니다:

- NeRF Synthetic [28]: Creative Commons Attribution 3.0 라이선스에 따라 제공됩니다.

<https://www.matthewtancik.com/nerf>에서 이용 가능합니다.

- Mip-NeRF 360 [2]: 라이선스 조건이 제공되지 않습니다. <https://jonbarron.info/>에서 이용 가능 mipnerf360/.

- OMMO [27]: 라이선스 조건이 제공되지 않습니다. <https://ommo.luchongshan.com/>에서 이용 가능합니다.
- 딥 블렌딩 [16]: 라이선스 조건이 제공되지 않습니다. <http://visual.cs.ucl.ac.uk/pubs/deepblending/>에서 사용 가능합니다.
- 탱크 및 사원 [22]: Creative Commons Attribution-

NonCommercial-ShareAlike 3.0 라이선스 <https://www.tanksandtemples.org/> 라이선스/.

16

[논문 07] SteepGS 본문 전체 번역

--- 페이지 1 ---

arXiv:2505.05587v1 [cs.CV] 2025년 5월 8일

컴팩트한 3D 가우스 스플래팅을 위한 가장 가파른 하강 밀도 제어

Peihao Wang^{1*}, Yuehao Wang^{1*}, Dilin Wang², Sreyas Mohan², Zhiwen Fan¹, Lemeng Wu²,
Ruisi Cai¹, Yu-Ying Yeh², Zhangyang Wang¹, Qiang Liu¹, Rakesh Ranjan²

¹텍사스 대학교 오스틴 캠퍼스, ²Meta Reality Labs

{peihaowang, yuehao, zhiwenfan, ruisi.cai, atlaswang}@utexas.edu,
lqiang@cs.utexas.edu, {wdilin, sreyasmohan, lmwu, yyyeh, rakeshr}@meta.com
vita-group.github.io/SteepGS

경사하강법 밀도화

3DGS SteepGS(당사)

그림 1. 이론적으로 3DGS의 밀도 제어를 조사합니다. 경사하강법을 통한 훈련이 진행됨에 따라 많은 가우스 기본 요소가 덮고 있는 영역을 재구성하지 못하면서 정지 상태가 되는 것으로 관찰되었습니다(예: 표시된 왼쪽 상단 그림의 청록색 얼룩).

와
) . 최적화 이론적 관점(오른쪽 그림 참조)에서 우리는 이러한 기본 요소가 안장점에 갇혀 있음을 보여줍니다.

손실을 추가로 줄이기에는 기울기가 충분하지 않아 매개변수가 국부적으로 최적이지 아닌 손실 환경의 영역입니다. 이 문제를 해결하려면

안장 영역에 위치한 가우시안 포인트를 효율적으로 식별하고 이를 두 개의 자손 스프링으로 분할하여 변위시키는 SteepGS를 소개합니다.

가장 가파른 하강 방향을 따라 새로운 기본 요소가 생성됩니다. 이는 다음을 이스케이프하여 연속적인 그래데이션 기반 업데이트의 효율성을 복원합니다.

안장 영역(예: 왼쪽 상단 그림에서

치밀화 후에 최적화될 수 있습니다). 예 표시된 바와 같이

왼쪽 하단 시각화에서 SteepGS는 미세한 기하학적 세부 사항의 충실도를 유지하면서 보다 간결한 매개변수화를 달성합니다.

초록

3DGS(3D Gaussian Splatter)가 강력한 기술로 등장했습니다.

실시간 고해상도 신규 시점 합성 기술.

장면을 가우시안 프리미티브의 혼합으로 표현함으로써,

3DGS는 GPU 래스터화 파이프라인을 활용하여 효율적인 작업을 수행합니다.

렌더링 및 재구성. 장면 범위를 최적화하려면

3DGS는 치밀화 알고리즘을 사용하여 미세한 세부 사항을 캡처합니다.

추가 포인트를 생성하는 방법입니다. 그러나 이 과정은

종종 중복된 포인트 클라우드로 이어져 과도한 결과를 초래합니다.

메모리 사용량, 느린 성능, 상당한 저장 공간

요구 사항 - 배포에 상당한 어려움을 안겨줍니다.

리소스가 제한된 장치. 이러한 한계를 해결하기 위해 우리는

*동등한 기여.

[†]Meta Reality Labs에서 인턴십 중에 수행한 작업입니다.

신비화를 풀고 구체화하는 이론적 틀을 제안합니다.

3DGS의 밀도 제어를 입증합니다. 우리의 분석에 따르면

분할은 안장 지점을 탈출하는 데 중요합니다. 통해

최적화 이론적인 접근 방식을 통해 우리는 필요한 것을 확립합니다.

치밀화 조건, 최소 수치 결정
 자손 가우스의 섬유, 최적의 매개변수 식별
 방향을 업데이트하고, 노르딕에 대한 분석 솔루션을 제공합니다.
 자손의 불투명도를 악화시킵니다. 이러한 통찰력을 바탕으로 우리는
 가장 가파른 밀도 제어 기능을 통합한 SteepGS를 소개합니다.
 손실을 최소화하면서 원칙을 유지하는 원칙 있는 전략
 컴팩트 포인트 클라우드. SteepGS는 ~50% 감소를 달성했습니다.
 렌더링 품질을 저하시키지 않고 가우시안 포인트에서
 효율성과 확장성을 모두 대폭 향상시켰습니다.

--- 페이지 2 ---

1. 소개

3D GS(3D Gaussian Splatting) [13], 신경망의 후속 모델
 새로운 뷰 합성을 위한 Radiance Fields(NeRF) [20]
 인상적인 뷰 합성 결과를 제공하는 동시에
 대규모 장면을 고해상도로 실시간 렌더링
 루션. NeRF의 체적 표현과 달리 3DGS는
 가우스 혼합으로 3D 장면의 복사장을 나타냅니다.
 위치와 같은 매개변수로 각각 정의되는 시안 프리미티브
 크기, 불투명도 및 모양 [46]. 래스터화(Rasteriza)를 활용하여
 GPU와 통합된 파이프라인을 사용하면 이 접근 방식을 통해 다음과 같은 이점을 얻을 수 있습니다.
 매우 효율적인 렌더링 및 역전파
 장면 재구성 및 뷰 추론을 가속화합니다.
 3DGS의 핵심은 교대 최적화 프로세스입니다.
 이를 통해 복잡한 장면을 정확하게 근사할 수 있습니다.

가우시안 프리미티브를 사용합니다. 미리 계산된 회소로 시작하기
 포인트 클라우드를 초기화로 사용하고 스탠스 간 3DGS 주기를
 dard 그래디언트 기반 광도 오류 최소화 개선
 가우스 매개변수 및 맞춤형 적응형 밀도 밀도
 trol (ADC) 알고리즘 [13]은 가우시안 수를 조정합니다.
 포인트. 치밀화 단계에서 ADC는 다음을 식별합니다.
 고도로 최적화된 포인트 세트를 만들고 각각을 두 개의 오프로 나눕니다.
 스프링, 그에 따라 고유한 매개변수 업데이트 할당
 포괄적인 장면 범위를 보장하는 절대 크기와
 미세한 기하학적 세부 사항을 캡처합니다. 그러나 이번 재건축은
 3DGS의 파이프라인은 종종 지나치게 큰 포인트를 생성합니다.
 클라우드로 인해 메모리 사용량이 증가하고 렌더링 속도가 느려집니다.
 속도와 상당한 디스크 오버헤드를 제공합니다. 이 문제는
 리소스가 제한된 배포에 심각한 병목 현상 발생
 휴대폰, VR 헤드셋 등의 기기.
 사후 가지치기 및 양자화 기반 압축을 수행하는 동안
 이러한 문제를 해결하기 위해 알고리즘이 널리 사용되었습니다.
 렌계 [9, 11, 16, 21, 23-25, 31], 적용되는 경우가 거의 없습니다.
 밀도화를 통해 이 문제를 직접적으로 해결하는 방법
 양이온 과정. 치밀화 단계를 최적화하면 다음과 같은 이점을 얻을 수 있습니다.
 더 빠른 렌더링을 위해 임시로 소형 가우스 포인트 클라우드를 생성합니다.

교육 비용을 절감하는 동시에 교육 비용도 절감할 수 있습니다. 일부 이전 연구에서는 밀도 제어 알을 수정하려고 시도했습니다. 분할 수정과 같은 휴리스틱을 사용하는 gorithm 기준 [3] 또는 샘플링을 통해 새로운 가우스 생성 불투명도 분포 [14]. 그러나 치밀화는 프로세스가 잘 이해되지 않고 결과적으로 기존 솔루션은 매우 제한된 개선만을 달성합니다. 주로 휴리스틱에 의존합니다. 이 논문에서 우리는 이론적으로 밀도 조건을 이해합니다. 비블록 렌즈를 통한 3DGS용 트를 알고리즘 최적화. 우리의 분석은 손실 행동을 특성화합니다. 새로운 행렬을 도입하여 분할한 후 각 행렬의 1차 기울기를 연결하는 분할 행렬 가우스를 해당 헤세로 변환합니다. 우리는 3DGS에서 안장 탈출을 위해서는 분할 작업이 매우 중요합니다. 포인트. 그러나 모든 지점이 치밀화의 이점을 누리는 것은 아닙니다. 특히, 우리는 분할이 단지 연관된 분할 행렬이 양의 반이 아닌 경우 손실 확실한. 이 통찰력은 분할의 중요성을 강조합니다. 밀도 제어 알고리즘에서 더 깊은 최적화를 제공합니다. 기존 기하학을 보완하는 이론적 관점 이해. 이러한 이론적 조사를 바탕으로 우리는 더 나아가 다음과 같은 긍정적인 결론: (i) 각각의 분할 두 자손으로의 가우시안은 다음과 같은 최적화를 달성하기에 충분합니다. 통제된 성장률을 보장하면서 손실 시 잘못된 하강 포인트 수의. (ii) 자손의 규모 가우스는 국소 밀도를 보존하기 위해 절반으로 줄여야 합니다. (iii) 분할 후 손실이 가장 가파르게 감소하기 위해서는 새로운 가우시안은 양수 및 에 해당하는 고유 벡터의 음의 방향 분할 행렬의 최소 고유값입니다. 우리는 이것을 통합합니다 Steepest라고 불리는 원칙에 입각한 분할 전략에 대한 결과 손실률을 최대화하는 밀도 제어(SDC) 산출된 가우시안 수를 최소화하면서 유도 자손. 우리는 가장 가파른 밀도 제어를 추가로 보여줍니다. (SDC)를 효율적으로 구현하고 원활하게 통합할 수 있습니다. 기존 3DGS CUDA 커널에 통합되었습니다. 계산하려면 분할 행렬을 사용하여 다음과 같은 병렬 알고리즘을 제안합니다. 각 가우스에 대해 폐쇄형 헤세 행렬을 활용합니다. 역전파에서 재사용된 그래디언트 정보와 결합됨 tion. 우리는 이것을 향상된 3DGS 기반 재구성이라고 부릅니다. 시스템 SteepGS. 경험적으로 SteepGS는 50% 이상의 높은 렌더링을 유지하면서 가우시안 포인트를 줄입니다. 품질을 향상시켜 메모리 효율성을 크게 향상시키고 렌더링 속도.

2. 관련 업무

2.1. 효율적인 장면 표현

신경 장면 표현의 최근 발전은

변환된 뷰 합성, 신경 복사장

(NeRF) [20]은 사진을 합성하는 방법을 소개했습니다.

연속적인 체적 장면을 최적화하여 사실적인 뷰 제공

희박한 입력 뷰를 사용하여 기능을 수행하지만 높은 효율성을 제공합니다.

추정 비용은 적용을 제한합니다. NeRF를 기반으로 구축,

계산을 줄이기 위해 여러 가지 방법이 시도되었습니다.

예를 들어 다중 해상도 해시를 사용하는 InstantNGP [22]

radiance field를 4D로 모델링하여 인코딩, TensoRF [5]

간단한 하위 인수분해를 사용하는 텐서, 일반화 가능

NeRF [4, 32, 34]는 디코딩 분석에 주의를 기울여

다양한 관점과 Plenoxel [10, 43] 사이의 인용

뷰 의존적 희소 복셀 모델을 사용합니다. 라이트 필드 넷-

작품 [28] 및 표면 기반 렌더링 [17, 27, 41] 및

포인트 기반 렌더링 [1, 40, 42] 또한 상당한 성과를 거두었습니다.

새로운 신경 장면 표현을 제안함으로써 기여

tions 및 미분 가능한 렌더링 기술. 이것들과 달리

3DGS [13]는 다음과 같은 대체 표현을 제공합니다.

학습 가능한 이방성 가우스 커널을 사용한 장면 모델링,

포인트 기반 래스터화를 통해 빠른 렌더링이 가능합니다.

--- 페이지 3 ---

2.2. 컴팩트 3D 가우스 스플래팅

원래의 3D Gaussian Splatting [13] 최적화는 다음과 같은 경향이 있습니다.

중복된 GS가 있는 장면을 표현합니다. 여러 작품이 있는데

증류수를 사용하여 보다 컴팩트한 장면을 얻기 위해 제안되었습니다.

또는 GS 속성에 대한 간결한 표현 [9, 16], 개선된

가지치기 [9, 14] 또는 효율적인 치밀화 [3, 14, 16, 18].

치밀화 접근법 중 Lee et al. [16] 제안하다

사용하는 동안 치밀화하는 동안 학습 가능한 마스킹 전략

컴팩트한 그리드 기반 신경장 및 코드북을 표현

색상과 기하학. 3DGS-MCMC [14]는 밀도를 다시 작성합니다.

MCMC의 결정론적 상태 전이로서의 기능 및 가지치기

샘플. Revising-3DGS [3]는 픽셀 오류 기반을 제안합니다.

치밀화를 위한 밀도 제어. Taming-3DGS [18] 적용

예측 가능한 예산 관리를 통한 점수 기반 밀도화.

대신에 우리의 방법은 부분적인 헤세 정보를 취하여

가장 가파른 밀도 제어를 달성합니다.

2.3. 신경 아키텍처 분할

신경구조 탐색 분야에서 유망한 방향은

작은 시드 네트워크로 시작하여 졸업하는 과정이 포함됩니다.

목표 성능과 사용자를 기반으로 규모를 확장하고 있습니다.

제약. 신경 아키텍처로 알려진 이 접근 방식은

성장 또는 분할은 처음에 Net2Net [7]에 의해 제안되었습니다.

이는 이중화를 통해 네트워크를 성장시키는 개념을 도입했습니다.
 잡음 교란이 있는 뉴런이나 층을 케이팅합니다. 후속 조치
 작품 [6, 8, 33, 39] 네트워크 모듈별 성장 확장
 다양한 응용 프로그램에서 모델 성능을 향상시킵니다.
 가장 관련성이 높은 이전 작업은 아마도 S2D일 것입니다 [30, 36, 38].
 이는 하위 계산을 통해 뉴런 분할 과정을 개선합니다.
 분할할 뉴런 세트 및 분할 기율기 적용
 자손의 최적 업데이트. 그 후 반딧불이 [37]
 근사값에 대한 1차 그라데이션 기반 접근 방식을 도입합니다.
 S2D 분할 행렬을 결합하여 분할 프로세스를 가속화합니다.
 분할 방법을 확장 가능하게 만듭니다. 이론상이지만-
 관련이 있으므로 이러한 방법은 다음에 직접 적용할 수 없습니다.
 3DGS 최적화. 분할 계획에 대한 조사
 3DGS에서는 이러한 격차를 해소하는 것을 목표로 합니다.
 3. 예선: 3D 가우스 스플래팅
 이 섹션에서는 재구성 파이프라인을 간략하게 검토합니다.
 3DGS의 과정에서 필요한 표기법을 소개합니다.
 장면 표현. 3D 가우시안의 핵심 아이디어
 Splatter(3DGS)[13]는 복사장을 근사화하는 것입니다.
 [20] 가우시안 프리미티브의 혼합을 통한 복잡한 장면
 [46]. 공식적으로 다음과 같이 표현되는 한 장면을 고려해보세요.
 매개변수 $\mathcal{G} = \{ (i) \in \mathcal{G} \}$ 을 갖는 n 개의 프리미티브 세트
 $n=1$,
 여기서 $(i) = (p(i), (i), o(i), c(i))$, $p(i) \in \mathbb{R}^3$ 은 다음을 나타냅니다.
 중앙 위치, $(i) \in \mathbb{S}^3 \times \mathbb{S}^3$
 $+$ 는 양의 준확정값입니다.
 공분산 행렬(중중 쿼터니언을 통해 다시 매개변수화됨)
 스케일링 벡터와 $o(i) \in [0, 1]$ 은 다음의 크기를 나타냅니다.
 가우스 함수는 종종 기하학적으로 다음과 같이 해석됩니다.
 불투명도 값. 또한, 각 가우시안 포인트는 연관되어 있습니다.

구형으로 저장되는 색상 속성 $c(i) \in \mathbb{R}^3$ 을 사용합니다.
 ical 고조파 계수를 RGB 값으로 변환
 렌더링 시간에. 장면의 전체 밀도 필드
 $\rho: \mathbb{R}^3 \rightarrow \mathbb{R}$ 은 모든 프리미티브의 조합으로 표현됩니다.
 $\rho(x) = \sum_{i=1}^n \alpha_i \phi(x; (i))$, 여기서 각 가우스 프리미티브
 $(\cdot; (i)): \mathbb{R}^3 \rightarrow \mathbb{R}$ 은 스케일링된 가우스 커널로 기여합니다.
 3D 점 $x \in \mathbb{R}^3$ [46]:
 $\phi(x; (i)) = o(i) N(x; p(i), (i))$. (1)
 여기서 $N(x; p, \Sigma) = \exp(-\frac{1}{2}(x-p)^T \Sigma^{-1}(x-p))$ 는 다음을 나타냅니다.
 정규화되지 않은 가우스 함수.
 래스터화. 화면에 픽셀을 표시하려면 Zwicker
 외. [46]은 볼륨 렌더링 [19]이 실제로 가능하다는 것을 보여줍니다.
 먼저 각 프리미티브를 개별적으로 투영한 다음
 뒤에서 앞으로 -블렌딩을 통해 각 프리미티브를 합성합니다.

공식적으로, 픽셀 위치가 $x \in \mathbb{R}^2$ 이고 세계가 다음과 같다고 가정합니다.

카메라 투영은 $\pi: \mathbb{R}^3 \rightarrow \mathbb{R}^2$ 이며 이는 다음을 포함합니다.

카메라 외부 기능과 내부 기능 모두. 렌더링된 것을 얻으려면

픽셀 x 의 색상, 3DGS는 먼저 뷰에 따라 점을 정렬합니다.

종속 깊이를 적용한 다음 효율적인 래스터화를 채택합니다.

프로세스는 다음과 같이 공식화됩니다.

$$C(x; \theta) =$$

$$n \times$$

$$n = 1$$

$$c_i T_i(x; \theta_i), (2)$$

$$\text{여기서 } T_i = Q_i^{-1}$$

$$j=1(1 \dots (x; \theta_j)), \quad (x; \theta_i) \text{는 다음과 같습니다.}$$

분석 형식:

$$(x; \theta_i) = o(i) N$$

$$x; (p(i)), \quad (i)$$

$$, (3)$$

2D에 투영되는 가우스 프리미티브를 나타냅니다.

아핀 변환을 통한 공간 $\mathbb{R}^3$.

최적화. 3D를 표현하기 위한 매개변수 θ 를 획득하려면

장면, Kerbl et al. [13] 계산된 포인트 클라우드를 사용합니다.

입력이 있는 SfM(Structure-from-Motion) 소프트웨어 [26]에서

이미지를 가우시안 프리미티브의 초기 위치로 사용합니다. Af-

3DGS는 다음을 최소화하여 매개변수 θ 를 최적화합니다.

캡처된 이미지와 이미지 렌더링 간의 측광 오류

동일한 시점에서 θ 로부터 도출되었습니다. 오류가 있다고 가정해보자

함수 $\ell(\cdot; \cdot)$, 총 광도 손실은 다음과 같이 쓸 수 있습니다.

$$L(\theta) = E(\ell(\cdot; \cdot), x) D$$

시간

$$\ell$$

$$C(x; \theta), b_C(x)$$

$$n =$$

$$, (4)$$

여기서 D 는 수집된 모든 항목의 샘플링 분포를 나타냅니다.

픽셀(및 해당 카메라 포즈)이며 $b_C(x)$ 는

해당 실측 픽셀 색상. 특히 3DGS는

손실 함수 $\ell(\cdot; \cdot)$ 로 ℓ_1 거리를 채택합니다. 우리는

이 광도 손실은 기능으로 볼 수 있습니다.

이는 일련의 기본 함수 $\{ \ell(x; \theta_i) \}$ 를 다음과 같이 매핑합니다.

지정된 매개변수 (θ, x) 에 따른 손실 값.

일부 $P \in \mathbb{R}^{2 \times 3}$ 에 대해 아핀 변환 $\pi(x) = Px + b$ 를 가정합니다.

그리고 $b \in \mathbb{R}^2$, 행렬 $\pi \in \mathbb{R}^{3 \times 3}$ 에 적용하면 $\pi = P^{-1} P^T$ 입니다.

2일반성을 잃지 않고 단순성을 위해 SSIM 용어를 무시합니다.

--- 페이지 4 ---

적응형 밀도 제어. 스탠과 함께-

Eq.를 최적화하기 위한 dard 그래디언트 기반 방법. 4, 3DGS

적응형 밀도 제어(ADC) 프로세스를 통합합니다.

보이지 않는 점과 인트로를 동적으로 잘라내는 dure-

기하학적 발견법을 사용하여 새로운 기본 요소를 더 많은 방법으로 유도합니다.

장면을 효과적으로 커버합니다. 우리는 이 밀도를 요약합니다.

양이온 과정이 이 논문의 주요 관심사이기 때문입니다.

(i) ADC는 먼저 큰 ex-

뷰 공간에서 기대되는 그래디언트 노름: $I = \{i \in [n]:$

$E[|\nabla(p(i))|_2] \geq \text{adc}\}$. (ii) I에 있는 작은 점의 경우

scales $I_{\text{clone}} = \{i \in I: \text{Matthew}(i) \leq \text{adc}\}$, ADC는 다음을 고려합니다.

재건축 사례로 간주됩니다. ADC는 2개의 오프를 산출합니다.

I_{clone} 의 각 포인트에 대한 스프링 프리미티브를 복제하여

속성을 조정하고 새로운 자손의 위치를 조정합니다.

그라데이션 방향. (iii) 체구가 큰 분

$I_{\text{split}} = \{i \in I: \text{손}(i) \geq \text{adc}\}$, ADC는 이를 다음과 같이 간주합니다.

과도한 재건축 사례 마찬가지로 3DGS는 두 가지를 생성합니다.

I_{split} 의 각 포인트에 대한 새로운 자손 포인트를 배치하는 동안

상위 밀도에서 추출된 임의의 위치에 있음

기능을 수행하고 저울을 0.8배로 축소합니다.

4. 방법론

기존 ADC의 경험적 성공에도 불구하고

3DGS는 휴리스틱을 고려할 때 종종 중복 포인트를 생성합니다.

그리고 다소 장인적인 분할 기준. 이 섹션에서 우리는

치밀화를 조사하기 위한 이론적 틀 확립

메커니즘. 이를 통해 우리는 세 가지에 대해 긍정적으로 대답합니다.

주요 질문: (i) a의 필요 조건은 무엇입니까?

가우스 프리미티브를 분할할까요? (섹션 4.2) (ii) 어디에서 해야 합니까?

새로운 가우스 자손이 배치됩니까? (섹션 4.3) 및 (iii)

새로운 가우스 포인트의 불투명도를 조정하는 방법은 무엇입니까? (섹션 4.3)

이러한 결과를 결합하여 새로운 밀도 제어를 제안합니다.

하드웨어 효율적인 구현 전략(섹션 4.4)

4.1. 문제 설정

장면이 n Gaussian prim로 표현되었다고 가정합니다.

$= \{ (i) \}_n$ 과 같은 매개변수가 포함된 변수

나는=1이고

총 손실은 Eq.에 정의된 대로 $L()$ 입니다. 4. 우리의 목표는

각 가우스를 $m_i \in \mathbb{N}^+$ 자손으로 분할합니다. 우리는

i 번째 가우스 자손의 매개변수를 다음과 같이 기록해 두세요.

$(i) = \{ (i)$

$j \}_m$

$j=1$, 여기서 (i)

j 는 j 번째 자손입니다. 모피-

그런 다음 각 가우스에 계수 그룹을 할당합니다.

$w(i) = \{w(i)$

$j \in \mathbb{R}^+\}_m$

$j=1$ 로 불투명도를 재조정합니다. 이후
 장면은 합산을 통해 근사화되며,
 분할은 각 ex -를 대체하는 것으로 동등하게 볼 수 있습니다.
 하위 스프링의 조합을 사용하여 로컬로 tant Gaussian:Pmi
 $j=1w(i)$
 $j \quad (;\quad (i)$
 j). 각각의 오래된 Gaus-
 sian은 Pmi가 됩니다
 $j=1w(i)$
 $j \quad (;\quad (i)$
 j) 모든 카메라에 대해
 포즈 $\cdot mi = 1$ 은 분할이 발생하지 않음을 의미하며
 원래 가우스는 변경되지 않은 상태로 유지됩니다.
 모든 새로운 가우스의 매개변수를 $\quad =$ 로 수집합니다.
 $\{ \quad (i)\}n$
 $i=1, w = \{w(i)\}n$ 으로 계수 재가중
 $나는=1,$
 그림 2. 분할 프로세스에 대한 예시적인 표기법. 는
 업데이트 $\quad (i)$
 $j \quad (i)$ 는 먼저 평균을 취하여 분해될 수 있습니다.
 필드 이동 $\mu(i)$ 및 개별 업데이트 적용 $\quad (i)$
 j. 이로써
 분해, $Pw(i)$
 $j \quad (i)$
 $j = 0.$
 약어로. 치밀화 알고리즘이 값을 결정합니다.
 $\{mi\}n$ 동안
 각 단계에서 $i=1, w, \quad$ 입니다. 값을 지정한 후
 w 의 경우 이러한 계수는 불투명도에 흡수됩니다.
 자손의 가치.
 원래 ADC는 다음의 렌즈를 통해 해석될 수 있습니다.
 이 프레임워크: (i) $E[\|\nabla \quad (p(i))\|_2] \geq \quad adc$ 인 경우 $mi = 2$, 또는
 그렇지 않으면 $mi = 1$ 입니다. (ii) $i \in I \text{ clone}$ 이면 $p(i)$
 $j \quad p(i) \propto$
 $\nabla p(i) L$, 그렇지 않으면 $p(i)$
 $j \quad N(p(i), \quad (i)), \quad (i)$
 $j = 0.64 \quad (i),$
 모든 $j \in [mi]$ 에 대해. (iii) 승(i)
 $j = 1$, 두 경우 모두 $\forall j \in [mi]$ 입니다.
 4.2. 치밀화는 언제 도움이 됩니까?
 이 절에서는 이론적으로 다음과 같은 효과를 설명합니다.
 광도계를 검사하여 밀도 제어 알고리즘
 분할 후 손실. 새로 추가된 가우시안 프리미티브로,
 손실은 다음과 같이 평가할 수 있습니다.
 $L(\quad, w) = E(\quad, x) \quad D$
 시간
 ℓ

$C(x; \cdot, w), bC(x)$

나

, (5)

여기서 $C(x; \cdot, w)$ 는 픽셀에 대해 렌더링된 색상을 나타냅니다.

x 식을 통해, 2에는 새로운 매개변수 및 w 가 포함됩니다. 원본

ADC [13]는 이후 손실이 감소할 것이라는 보장이 없습니다.

분열. 나중에 보여주듯이 임의의 점을 밀도화하면 다음과 같은 결과를 얻을 수 있습니다.

심지어 손실도 증가합니다. Bul oet al. [3] 그리고 케라드만드

외. [14] 가우스 자손의 불투명도 값을 조정하여

분할 후 국지적으로 총 밀도를 보존합니다. 이 설정에서는

손실 $L(\cdot, w)$ 는 $L(\cdot)$ 와 거의 동일하게 유지됩니다.

그러나 다음에 설명하겠지만 이러한 보존은

원칙이 반드시 가장 효과적인 접근 방식은 아닙니다. 작성자:

적절한 가우스 프리미티브를 선택하는 것도 가능합니다.

손실을 더욱 줄이기 위해.

이 시점부터 우리는 두 가지 추가 사항을 고려합니다.

실제적인 조건. 먼저, 전체 불투명도를 보장하려면

분할 후 보수적으로 P_{mi} 라는 제약 조건을 적용합니다.

$j=1w(i)$

$i \in [n]$ 마다 $j = 1$ 입니다. 둘째, 우리는 가정한다

자손의 매개변수는 원래의 부모와 가깝습니다.

램미터, 즉 $\{ \cdot(i)$

$j\}$ 미

$j=1$ 은 $\cdot(i)$ 근처에 있습니다.

$rr \cdot(i)$

일부 > 0 에 대해 $j \cdot(i)Bu2 \leq$ 입니다. $\mu(i) =$ 를 정의하겠습니다.

피미

$j=1w(i)$

$j \cdot(i)$

$j \cdot(i)$ 를 i 번째의 평균 변위로

--- 페이지 5 ---

치밀화 후 가우스 및 $\cdot(i)$

$j = \cdot(i)$

$j \cdot(i) \mu(i)$

각 자손에 대해 $\cdot(i)$ 에 추가되는 오프셋을 나타냅니다. 우리

더 나은 설명을 위해 그림 2의 분할 프로세스를 시각화합니다.

우리 표기법의 해석. 분할 과정은 다음과 같이 구성됩니다.

두 단계: 먼저 상위 가우스를 오프셋으로 변환

$\mu(i)$, 둘째, 개별 교대로 자손을 생성합니다.

$\{ \cdot(i)$

$j\}j \in [m]$ 평균이 0입니다.

이러한 모든 설정을 통해 아래에서 첫 번째 주요 내용을 제시합니다.

결과는 분할 후 손실을 분해합니다.

정리 1. $L(\cdot, w)$ 가 3차 경계를 갖는다고 가정합니다.

에 관한 파생물

$$L(\mathbf{w}, \mathbf{w}) = L(\mathbf{w}) + \nabla L(\mathbf{w})^\top \Delta \mathbf{w} + \frac{1}{2} \Delta \mathbf{w}^\top \nabla^2 L(\mathbf{w}) \Delta \mathbf{w}$$

$$L(\mathbf{w})$$

$$+ 1$$

$$2$$

$$n \times$$

$$n = 1$$

$$\text{믹스}$$

$$j = 1$$

$$w(i)$$

$$j = (i)^\top$$

$$j S(i)(\mathbf{w}) = (i)$$

$$j + O(3),$$

$$\text{여기서 } \mu =$$

$$\mu(1)^\top \cdots \mu(n)^\top$$

모든 평균을 연결합니다.

연령 오프셋과 $S(i)(\mathbf{w}) \in \mathbb{R}^{\text{dim}} \times \text{dim}$ 는 다음과 같이 정의됩니다.

$$S(i)(\mathbf{w}) = E(\mathbf{w}, \mathbf{x}) \in \mathbb{D}$$

"

$$\partial \ell$$

$$\partial (x; (i))$$

$$\nabla^2$$

$$(i) = (x; (i))$$

$$\#$$

.

모든 증거는 보충 자료인 Ap-에서 제공됩니다.

pendix C. 정리 1은 다음의 효과를 분리하고 그룹화합니다.

평균 변위와 각각의 개별 오프셋

자손. 파란색으로 강조 표시된 처음 세 용어는 다음과 같습니다.

집합적으로 나타내는 평균 이동 항이라고 합니다.

전체 평균 이동의 영향을 보냈습니다. 변속 이후

모든 자손을 동시에 적용하는 것은 다음과 같습니다.

원래 가우스와 동일한 오프셋, 다음과 관련된 용어

주황색으로 강조 표시된 개별 오프셋은

분할 과정의 본질적인 효과. 우리는 각 용어를 분리합니다.

이 합계 내에서 이를 분할 문자로 참조합니다.

분할의 효과를 완전히 설명하는 istic 함수

단일 가우스 포인트:

$$(i)(\mathbf{w}(i), w(i); \mathbf{w}) = 1$$

$$2$$

$$\text{믹스}$$

$$j = 1$$

$$w(i)$$

$$j = (i)^\top$$

$$j S(i)(\mathbf{w}) = (i)$$

j. (6)

본질적으로 분할 특성 함수는

행렬 $S(i)$ 에 대한 2차 형식입니다. 우리는 참조한다 $S(i)$ 를 분할 행렬로 사용하여 다음을 완전히 제어합니다.

분할 특성 함수의 동작. 정리 1

아래와 같이 두 가지 통찰력을 얻습니다.

치밀화는 안장점을 탈출합니다. RHS를 사용하여 손실을 최소화하기 위한 대체 방법으로 정리 1을 사용할 수 있습니다.

평균 이동 항을 최적화하려면 다음이 필요하지 않습니다.

치밀화는 표준 구배 분해로 달성할 수 있습니다.

항기 3. 그러나 손실 함수는 주목할 가치가 있습니다.

3보다 정확하게는 이는 뉴턴 방법과 일치합니다.

역 헤세 행렬에 의해 사전 조건이 지정됩니다.

그림 3. 가장 가파른 밀도 제어 그림. SDC는

방정식에 대한 최적의 솔루션. 7, 손실에 대해 가장 가파른 하락세를 취함

분할 후. 기하학적으로 두 개의 자손 가우스를

분할의 가장 작은 고유 벡터를 따라 반대 방향

행렬을 만들고 각 가우스의 불투명도를 0.5만큼 줄입니다.

방정식. 4는 매우 불룩하지 않은 대물렌즈로, 수많은 특성을 나타냅니다.

손실 상황에서 불필요한 안장 지점(오른쪽 참조)

그림 1 참조). 그라데이션이 발생하기 쉽습니다.

이러한 안장 지점에 갇혀서 경사도가 감소하는 지점입니다.

항기가 더 이상 개선되지 않습니다. 그러나,

안장 지점의 가우시안 점을 여러 부분으로 조밀화

새로운 용어 - 분할 특성으로 포착

기능 (i) - 나타납니다. 이 용어는 부정적이 될 수 있습니다

손실을 더욱 줄이기 위해. 따라서 치밀화는 다음과 같은 역할을 합니다.

안장점을 탈출하기 위한 효과적인 메커니즘.

분할하면 손실이 언제 감소합니까? 사실, 더 미세한 -

분할 특성을 사용하여 세분화된 분석을 수행할 수 있습니다.

함수 (i). 분할의 전반적인 기여 이후

손실은 2차 함수의 합으로 표현됩니다.

분할 행렬 (i)는 음수가 되어

연관된 분할 행렬이 양수가 아닌 경우에만 손실

준확정. 이는 필요조건이 성립함을 의미한다.

분할을 수행하는 것은 $\min(S(i)) < 0$ 입니다. 여기서 $\min(\cdot)$

지정된 행렬의 가장 작은 고유값을 나타냅니다.

4.3. 최적의 밀도 제어

정리 1을 바탕으로 더욱 강력한 결과를 도출할 수 있습니다.

우리는 다음과 같은 밀도 제어 전략을 찾고자 합니다.

가장 가파른 지점을 달성하면서 최소한의 포인트 수

손실의 하강. 각 단계에서 손실 감소 최대화

낮은 재구성 오류를 적용하고 변환을 가속화합니다.

젠스. 이를 위해 우리는 다음과 같은 제한된 공식을 공식화합니다.

최적화 목표:

최소 $L(\cdot, w)$, s.t.

(i)
j (i)

2
≤ ,
믹스

j=1
w(i)
j = 1, (7)

이는 오프 수의 최적 구성을 추구합니다.
스프링 $m_i \in \mathbb{N}^+$, 재가중 계수 $w(i)$

$j \in \mathbb{R}^+$, 및
새로운 기본요소 { (i)에 대한 매개변수 업데이트
j} 모두에 대해
 $i \in [n], j \in [m_i]$ 손실 하강을 최대화합니다.

--- 페이지 6 ---

Eq. 7은 직접적으로 어렵다. 정리 1은 프로-
대용으로 이상적인 2차 근사를 제공합니다.
가우시안 분할 효과가 완전히 특성화되어 있으므로
분할 특성 함수를 사용하면 충분합니다.
{ (i)에 대해 (i)를 최소화하는 사이더
j}. 결과적으로,
해결책은 간단하고 분석적입니다. 우리의 주요 결과는
아래 제시:

정리 2. Eq. 7에는 두 가지 접힌 부분이 있습니다.

1. 분할 행렬 $S(i)(\cdot)$ 가 양의 준정부호인 경우

$\min(S(i)(\cdot)) \geq 0$ 이면 분할해도

손실. 이 경우 $m_i = 1$ 로 설정하고 분할이 발생하지 않습니다.

2. 그렇지 않고 $\min(S(i)(\cdot)) < 0$ 이면 다음과 같습니다.

분할 전략은 $(i)(\cdot, w(i); \cdot)$ 를 최소화합니다.

??? (i)

모든 $j \in [m_i]$ 에 대해 $j \text{ Bu} \leq 1$:

m^*

나는 = 2, $w(i)^*$

1 = $w(i)^*$

2 = 1

2 ,

(i)*

1 = $\text{vmin}(S(i)(\cdot)), (i)^*$

2 = $\text{vmin}(S(i)(\cdot)),$

여기서 $\text{vmin}(\cdot)$ 은 다음과 연관된 고유벡터를 나타냅니다.

가장 작은 고유값 $\min(\cdot)$.

우리는 정리 2에 설명된 분할 전략을 Steep-

추정 밀도 제어(SDC). 여기에는 네 가지 실질적인 의미가 있습니다.

i) 치밀화에 필요한 조건은 다음과 같습니다.

분할 행렬의 무한정함.

ii) 각 가우스를 두 개의 자손으로 나누는 것으로 충분합니다.

충실하고 더 많은 자손을 생성하는 것은
추가 혜택.

iii) 새로운 프리미티브의 크기는 낮아져야 합니다.
로컬 불투명도를 유지하기 위해 2배로 확장됩니다.

iv) 두 자손의 매개변수는 다음과 같아야 합니다.
긍정적/부정적 방향에 따라 업데이트됩니다.

최소 고유값에 해당하는 고유벡터
분할 행렬.

더 나아가, (i)의 결과는 이미 Sec에 나와 있습니다. 4.2,
포인트 수를 줄이기 위해 필터로 사용할 수 있습니다.

치밀화되다. (ii)에 의한 암시는 공통을 정당화합니다.

기존 ADC 알고리즘에서 "두 개의 하위 스프링" 선택 [13]
적당한 성장률을 보장합니다. 결과 (iii)는

Bul o et al.의 접근법과 대조됩니다. [3] 그리고 케라드만드

외. [14], 새로운 가우시안의 불투명도가 조정되는 곳

렌더링 관련 구성표를 기반으로 합니다. 특히, 둘 다 opac-

이 작업의 조정 방법은 정확하지 않으며

반드시 전체 불투명도를 유지할 필요는 없습니다. 요점 (iv)는 다음과 같습니다.

안장이 아닌 영역으로 포인트를 이동하는 두 가지 업데이트 방향

그림과 같이 정지점에 최적화되었을 때

그림 1의 오른쪽에 있습니다. 우리는 이 분할을 추가로 보여줍니다.

분할 전략이 어떻게 이루어지는지를 시각화한 그림 3의 구성표
지오메트리를 국부적으로 개선합니다.

4.4. 가장 가파른 가우스 스플래팅

이 섹션에서는 3DGS 최적화 알고리즘을 인스턴스화합니다.

SteepGS라고 불리는 밀도 제어 방식으로 SDC를 사용합니다.

SteepGS의 핵심은 분할 행렬을 계산하는 것입니다.

이를 활용하여 포인트를 분할할 시기와 방법을 결정합니다.

부록 A.1의 알고리즘 1은 참조 구현을 제공합니다.

SteepGS에 대한 언급입니다. 우리는 이것이 효율적으로 수행될 수 있음을 보여줍니다.

CUDA 커널에 구현 및 통합되었습니다.

정리 1의 분할 행렬의 형태를 다시 살펴보면,

$\partial \ell / \partial \mathbf{x}_i$ (x; (i))는 (스칼라)의 기울기를 나타냅니다.

i번째 가우스 출력으로 역전파된 손실 ℓ

원시적이고 ∇^2

((i), x)는 다음의 헤세 행렬입니다.

자체 매개변수 (i)에 대한 i번째 가우스입니다. 그것

분할 행렬이 포인트별로 정의된다는 점은 주목할 만합니다.

각 가우스의 헤세 행렬에만 개별적으로 의존합니다.

따라서 분할을 저장하는 데 필요한 총 메모리 공간은

행렬은 $O(n(\dim)^2)$ 입니다. 우리가 단지를 고려할 때

평균 위치 $\{p(i)\}_n$

매개변수는 $i=1$ 이고, 희미한 $\rho = 3$ 입니다.

분할 행렬을 계산하기 위해 기울기가 다음과 같습니다.

$\partial \ell / \partial \mathbf{x}_i$ (x; (i))는 이미 역방향 과정에서 획득되었습니다.

$\nabla L(\mathbf{x}, \mathbf{x})$ 를 계산할 때 전파. 남은

부분, 헤세 행렬 ∇^2

$(x; (i))$ 는 근사화될 수 있습니다.

분석적으로 다음과 같습니다(부록 C.4의 파생 참조).

∇^2

$$(x; (i)) \simeq (i)^\top (i)P^\top (i) - 1P,$$

여기서 $P^\top (i) = 1(x - (p(i)))$, P 는 다음을 나타냅니다.

1 및 (i) $(x; (i))$ 로 주어진 투영 행렬. 는

$S(i)$ 는 병렬로 계산될 수 있으며 중간 결과는

, $()$, $()$ 등은 이전부터 재사용 가능

계산. 최소값 계산의 복잡성

$\dim \times$ 회미 행렬의 고유값 및 고유벡터는 다음과 같습니다.

$O((\text{어두운})^2)$. position 매개변수만 사용하므로

3×3 행렬에 대한 최소 고유값과 고유벡터는 다음과 같습니다.

루트 공식 [29]을 사용하여 계산됩니다. 갈라지긴 하지만

행렬은 2차 정보를 활용합니다.

총 손실의 전체 헤세 행렬에서 ∇^2

L (예:

Hanson et al. [11]) 전체 헤세 행렬에서 교차항을 배제함으로써

∇^2

L [36]. 놀랍게도 문제의 구조는 다음과 같습니다.

안장점의 점별 식별을 위해

분할 행렬을 통해 제공되는 부분 헤세 정보.

5. 실험

이 섹션에서는 실증적으로 유효성을 검증합니다.

우리가 제안한 SteepGS.

5.1. 설정

주요 실험에서는 다양한 밀도로 3DGS를 훈련합니다.

화 방식을 선택하고 최종 포인트 수를 비교합니다.

그리고 새로운 뷰 합성 품질.

데이터 세트. 우리는 방법과 기타 기준을 비교합니다.

세 가지 까다로운 실제 데이터 세트: Mip-NeRF 360

--- 페이지 7 ---

ADReference가 포함된 당사의 3DGS

3DGS MCMC 3DGS 개정

그림 4. 정성적 결과. 우리는 SteepGS를 다른 치밀화 기준과 비교합니다. 각 장면의 첫 번째 행에는 렌더링된 내용이 표시됩니다.

뷰, 두 번째 행은 실제값과 관련된 오류를 시각화합니다. 주요 세부정보는 파란색 상자에 강조표시되어 있습니다.

[2] 실외 장면 3개와 실내 장면 4개 포함, 탱크 및

두 개의 야외 장면이 포함된 Temples [15] 및 딥 블렌딩

[12] 두 개의 실내 장면이 포함되어 있습니다.

기준선. SteepGS를 원래 ADC와 비교합니다

다른 두 가지 치밀화 방식: 3DGS-MCMC

[14] 및 Revising-GS [3]. 우리는 공식 코드베이스를 사용합니다.

3DGS 및 3DGS-MCMC, 개정을 다시 구현하는 동안-

GS는 원본 3DGS의 코드베이스를 기반으로 합니다. 우리는

3DGS-Thres. 원본에서 수정된 기준선
 3DGS ADC는 다음을 충족할 때 훈련이 중지되도록 합니다.
 다른 비교 방법과 동일한 점수를 얻습니다. 둘 다
 3DGS-MCMC 및 Revising-GS에는 최대 한도가 필요합니다.
 가우스 수. 우리는 이 숫자를 숫자로 선택합니다
 Gaussian의 SteepGS 생산량입니다. 이러한 모든 기준에 대해 우리는
 기본 하이퍼 매개변수를 사용합니다.
 구현 세부정보. SteepGS가 구현되었습니다
 공식 3DGS 코드베이스[13]의 코드베이스를 기반으로 합니다.
 우리는 분할을 계산하기 위해 CUDA 커널을 추가로 사용자 정의합니다.
 토크 행렬과 고유 분해. 우리는 따른다
 3DGS의 표준 훈련 파이프라인 및 밀도 수행
 500번째 스텝부터 100스텝마다 제어합니다. 는
 분할 행렬의 가장 작은 고유값에 대한 임계값은 다음과 같습니다.
 $1e^{-6}$ 으로 선택됩니다. 다른 모든 하이퍼 매개변수는
 3DGS의 기본 설정과 동일합니다. 우리의 장면마다
 훈련은 단일 NVIDIA V100 GPU에서 수행됩니다.

5.2. 결과

우리는 PSNR, SSIM [35], LPIPS [44]를 평가 도구로 채택했다.
 뷰 합성 품질에 대한 메트릭을 제공하고 최종 결과를 제시합니다.
 산출된 포인트 수와 훈련 시간을 효율성으로
 측정항목. 꼬리표. 1은 정량적 실험을 제시합니다. 컴-

--- 페이지 8 ---

립네RF360

포인트↓ PSNR↑ SSIM↑ LPIPS↓

3DGS [13] 3.339 29.037 0.872 0.183

3DGS + Thres. [13] 1.632 27.851 0.848 0.227

3DGS-MCMC [14] 1.606 28.149 0.853 0.204

3DGS 개정 [3] 1.606 28.085 0.850 0.212

SteepGS(당사) 1.606 28.734 0.857 0.211

탱크와 사원

포인트↓ PSNR↑ SSIM↑ LPIPS↓

3DGS [13] 1.830 23.743 0.848 0.177

3DGS + Thres. [13] 0.973 22.415 0.812 0.218

3DGS-MCMC [14] 0.957 22.545 0.817 0.204

3DGS 개정 [3] 0.957 22.339 0.811 0.216

SteepGS(당사) 0.958 23.684 0.840 0.194

딥 블렌딩

포인트↓ PSNR↑ SSIM↑ LPIPS↓

3DGS [13] 2.818 29.690 0.904 0.244

3DGS + Thres. [13] 1.326 29.374 0.900 0.250

3DGS-MCMC [14] 1.296 29.439 0.901 0.237

3DGS 개정 [3] 1.296 29.439 0.895 0.245

SteepGS(당사) 1.296 29.963 0.905 0.250

표 1. 3DGS를 포함한 대표적인 기준선과의 비교

[13], 3DGS + Thres. [13] 및 3DGS 개정 [3]. 단위는 "# 포인트"는 백만입니다. 최선의 접근 방식과 차선의 접근 방식 치밀화 개선은 색상으로 표시됩니다. 원래의 적응형 밀도 제어와 비교하여 우리의 방법 Mip에서 비슷한 렌더링 성능을 달성합니다. 가우시안 수를 줄이면서 NeRF 360 데이터 세트 약 50% 정도. 우리의 방법은 3DGS보다 성능이 뛰어납니다. Thres., 3DGS-MCMC 및 3DGS 기준선 수정 두 가지 방법은 동일한 수의 데이터를 생성하도록 훈련되었습니다. 가우스. 마찬가지로 Tank & Temple과 DeepBlend에서도 마찬가지입니다. 데이터 세트를 사용하여 우리의 접근 방식은 약 50% 감소를 달성했습니다. 가우시안 수를 줄이고 심지어 더 높은 PSNR을 달성합니다. DeepBlending 장면의 값. 그림 4는 정성적 결과를 보여준다. 우리의 치밀화 알고리즘과 기본 알고리즘 간의 비교 라인 메소드. 차이점 지도에 나와 있듯이 우리의 방법은 새로운 포인트 수의 절반만 생성합니다. 원래의 치밀화 접근 방식과 비교하여, 경쟁력 있는 렌더링 품질을 제공하고 많은 세부 사항을 보존합니다. 이 결과는 추가 가우시안이 생성되었음을 시사합니다. 원래의 적응형 밀도 제어로는 중복됩니다. 에서 대조적으로, 우리의 방법은 훈련 중 중복성을 완화합니다. 치밀화 절차를 통해 프로세스를 진행합니다. 특히, LightGaussian과 같은 압축 기반 방법과 달리 [9]는 덜 중요한 가우시안을 식별하고 정리합니다. 우리 것

ADC가 포함된 3DGS

6,241포인트

24,657포인트

그림 5. 분할 지점 시각화. 렌더링된 뷰

왼쪽에 존재하며 분할할 해당 포인트는 다음과 같습니다.

오른쪽에 시각화되어 있습니다.

전체 훈련 과정에서 우리의 방법은 다음을 달성합니다.

사후 교육 단계 없이 비용을 절감할 수 있습니다.

5.3. 시각화 및 해석

그림 5에서는 전략에 따라 필터링된 포인트를 시각화합니다.

1,000번째 반복에서의 원래 분할 전략은

각각. 렌더링된 RGB 이미지는 후면이

벤치의 나머지 부분은 기본 모양을 포착하도록 훈련되었습니다.

외관은 여전히 명확한 세부 사항이 부족한 반면 좌석은 여전히 명확한 세부 사항이 부족합니다. 다음과 같이

그림에 묘사된 것처럼 우리의 방법은 효과적으로 집중합니다.

좌석에서 가우스 분할, 다른 영역을 그대로 유지

최적화 프로그램. 대조적으로, 원래의 적응형 밀도 제어

등받이에 분할을 할당하여 대략적인 결과를 얻습니다.

우리 방법보다 분할 지점이 4배 더 많습니다. 이

우리의 접근 방식은 초점을 맞추므로써 효율성을 향상시킨다고 제안합니다.

더 자세한 내용이 필요한 영역을 분할하여 개선합니다.

전반적인 렌더링 성능을 더욱 효율적으로 개선합니다.

6. 결론

이 작업은 3D Gaussian의 비효율성을 해결합니다.
 실시간 초고화질의 선도적인 기술인 Splatting(3DGS)
 해상도 새로운 뷰 합성. 효과적이면서도 밀도가 높습니다.
 양이온 프로세스는 종종 중복 지점을 생성하여
 높은 메모리 사용량, 느린 성능, 증가된 저장 공간
 연립 요구 사항 - 리소스가 제한된 환경에서의 배포 방해
 장치. 이 문제를 해결하기 위해 우리는 이론적 프레임워크를 도입했습니다.
 3DGS의 밀도 제어를 명확하게 하고 최적화하는 작업입니다.
 우리의 분석은 탈출을 위한 분할의 필요성을 강조합니다.
 안정성을 형성하고 치밀화를 위한 최적의 조건을 설정합니다.
 최소한의 자손 가우스를 포함한 양이온
 그리고 해당 매개변수 업데이트. 이러한 통찰력을 바탕으로 우리는
 가장 가파른 밀도 제어를 통합한 SteepGS 제안
 컴팩트한 포인트 클라우드를 유지합니다. SteepGS는 Gaus-
 렌더링 품질을 저하시키지 않고 sian 포인트를 50% 증가시켰습니다.
 실용화를 위한 효율성과 확장성을 향상시킵니다.

--- 페이지 9 ---

감사의 말

PW는 Forrest Iandola, Zhen Wang, Jonathon Luiten,
 도움을 준 Nikolaos Sarafianos와 Amit Kumar
 이번 작품을 준비하는 동안. 어떤 진술이라도,
 의견, 조사 결과, 결론 또는 권장 사항
 이 자료에 표현된 것은 저자의 것이며
 반드시 고용주나 회사의 견해를 반영하는 것은 아닙니다.
 지원 단체.
 참고자료

[1] 카라-알리 알리에프, 아르템 세바스토폴스키, 마리아 콜로스, 드미트리

울리야노프(Ulyanov), 빅터 렘피츠키(Victor Lempitsky). 신경점 기반 그래픽.
 컴퓨터 비전 -ECCV 2020: 16차 유럽 컨퍼런스,
 영국 글래스고, 2020년 8월 23~28일, 절차, XXII부
 16, 696~712페이지. 스프링어, 2020. 2

[2] 조나단 T 배런, 벤 밀든홀, 도르 베르빈, 프라톨 P
 스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한
 앤티앨리어싱된 신경 방사 필드. 절차에서
 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 컨퍼런스
 nition, 페이지 5470-5479, 2022. 7

[3] Samuel Rota Bul o, Lorenzo Porzi, Peter Kotschieder.
 가우스 스플래팅의 치밀화 수정. arXiv 사전 인쇄
 arXiv:2404.06109, 2024. 2, 3, 4, 6, 7, 8, 1

[4] 첸 안페이(Anpei Chen), Zexiang Xu, Fuqiang Zhao, Xiaoshuai Zhang,
 Fanbo Xiang, Jingyi Yu, Hao Su. Mvsnerf: 빠른 장군-
 멀티뷰 스테레오로부터 복사장 재구성이 가능합니다.

IEEE/CVF 국제 회의 진행 중

컴퓨터 비전, 14124~14133페이지, 2021. 2

[5] 안페이 첸(Anpei Chen), Zexiang Xu, 안드레아스 가이거(Andreas Geiger), 징이 유(Jingyi Yu),

- 하오수. Tensorf: Tensorial radiance field. 유럽에서는 컴퓨터 비전에 관한 컨퍼런스, 333~350페이지. 스프링거, 2022. 2
- [6] Cheng Chen, Yichun Yin, Lifeng Shang, Xin Jiang, Yujia Qin, Fengyu Wang, Zhi Wang, Xiao Chen, Zhiyuan Liu 및 Qun 리우. bert2bert: 재사용 가능한 사전 학습된 언어 모델을 지향합니다. arXiv 사전 인쇄 arXiv:2110.07143, 2021. 3
- [7] Tianqi Chen, Ian Goodfellow 및 Jonathon Shlens. 넷투넷: 지식 이전을 통해 학습을 가속화합니다. arXiv 사전 인쇄 arXiv:1511.05641, 2015. 3
- [8] Utku Evci, Bart van Merriënboer, Thomas Unterthiner, 막스 Vladymyrov 및 Fabian Pedregosa. Gradmax: 성장 그래디언트 정보를 사용하는 신경망. arXiv 사전 인쇄 arXiv:2201.05125, 2022. 3
- [9] Zhiwen Fan, Kevin Wang, Kairun Wen, Zehao Zhu, Dejia Xu, 장양 왕. 라이트가우스: 무한한 3D 15배 감소 및 200+ fps의 가우스 압축. arXiv 인쇄 전 arXiv:2311.17245, 2023. 2, 3, 8
- [10] Sara Fridovich-Keil, Alex Yu, Matthew Tancik, Qinzhong 첸, 벤저민 레히트, 가나자와 양주. 플레녹셀: 신경망이 없는 래디언스 필드. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 표창, 페이지 5501-5510, 2022. 2
- [11] Alex Hanson, Allen Tu, Vasu Singla, Mayuka Jayawardhana, 마티아스 즈위커, 톰 골드스타인. Pup 3d-gs: 원칙적 3D 가우스 스피래팅을 위한 불확실성 가지치기. arXiv 사전 인쇄 arXiv:2406.10219, 2024. 2, 6
- [12] 피터 헤드먼, 줄리안 필립, 트루 프라이스, 얀 마이클 프람, 조지 드레타키스, 가브리엘 브로스토우. 딥 블렌딩 자유 시점 이미지 기반 렌더링. ACM 거래 그래픽(ToG), 37(6):1-15, 2018. 7
- [13] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임켈러, 그리고 조지 드레타키스. 실시간 광채를 위한 3D 가우스 스피래팅 필드 렌더링. ACM 트랜스. Graph., 42(4):139-1, 2023. 2, 3, 4, 6, 7, 8
- [14] 샤키바 케라드만드, 다니엘 레베인, 고팔 샤르마, 웨이-웨이 선, Jeff Tseng, Hossam Isack, Abhishek Kar, Andrea 탈리아사치, 이광무. 3D 가우스 스피래팅 마르코프 체인 몬테카를로. arXiv 사전 인쇄 arXiv:2404.09591, 2024. 2, 3, 4, 6, 7, 8, 1
- [15] 아르노 크나피치(Arno Knapitsch), 박재식, 저우첸이(Qian-Yi Zhou), 블라들렌(Vladlen Koltun). 탱크와 사원: 대규모 장면 벤치마킹 재건축. 그래픽에 대한 ACM 트랜잭션(ToG), 36(4): 2017. 7. 1~13
- [16] 이주찬, 노다니엘, 선헥규, 고종환, 그리고 박은병. 컴팩트한 3D 가우스 표현 래디언스 필드. IEEE/CVF 컨퍼런스 진행 중

컴퓨터 비전 및 패턴 인식, 21719페이지 -
21728, 2024. 2, 3, 5

[17] Shichen Liu, Tianye Li, Weikai Chen, Hao Li. 소프트 래스터-
izer: 이미지 기반 3D 추론을 위한 미분 가능한 렌더러입니다.

IEEE/CVF 국제 회의 진행 중

컴퓨터 비전, 7708~7717페이지, 2019. 2

[18] Saswat Subhajyoti Mallick, Rahul Goel, Bernhard Kerbl,
프란시스코 비센테 카라스코(Francisco Vicente Carrasco), 마르쿠스 스타인베르거(Markus Steinberger), 페르-
난도 데 라 토레. Taming 3dgs: 고품질 래디언스 필드
제한된 자원으로. arXiv 사전 인쇄 arXiv:2406.15643 ,
2024. 3

[19] 넬슨 맥스. 직접 볼륨 렌더링을 위한 광학 모델.

시각화 및 컴퓨터 그래픽에 관한 IEEE 거래,

1(2):99-108, 1995. 3

[20] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik,
조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프:
뷰 동기화를 위해 장면을 신경 방사 필드로 표현
논문. ACM 커뮤니케이션, 65(1):99-106, 2021. 2,
3

[21] Wieland Morgenstern, Florian Barthel, Anna Hilsmann 및

피터 아이저트. 자체 기능을 통한 컴팩트한 3D 장면 표현

가우스 그리드를 구성합니다. arXiv 사전 인쇄 arXiv:2312.13299,
2023. 2

[22] Thomas Müller, Alex Evans, Christoph Schied 및 Alexan-

켈러. 다중 해상도를 갖춘 즉각적인 신경 그래픽 프리미티브

솔루션 해시 인코딩. 그래픽(TOG)의 ACM 트랜잭션,

41(4):1~15, 2022. 2

[23] KL Navaneet, Kossar Pourahmadi Meibodi, Soroush Abbasi

Koohpayegani 및 Hamed Pirsiavash. Compact3d: Com-

벡터를 사용하여 가우스 스피레트 래디언스 필드 모델 누르기

양자화. arXiv 사전 인쇄 arXiv:2311.18159, 2023. 2

[24] Simon Niedermayr, Josef Stumpfegger, Rüdiger West-

에르만. 가속을 위한 압축된 3D 가우스 스피레팅

새로운 관점 합성. IEEE/CVF 회의 진행 중

컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지

10349~10358, 2024.

--- 페이지 10 ---

[25] 파나기오티스 파판토나키스, 게오르기오스 코파나스, 베른하르트 케르블,

알렉산드르 랑방, 조지 드레타키스. 메모리를 줄입니다.

3D 가우스 스피레팅의 발자국입니다. 절차

컴퓨터 그래픽 및 인터랙티브 기술에 관한 ACM, 7

(1):1~17, 2024. 2

[26] Johannes L Schonberger 및 Jan-Michael Frahm. 구조-

모션에서 재검토되었습니다. IEEE 회의 진행 중-

컴퓨터 비전 및 패턴 인식에 대한 내용, 4104페이지 -

4113, 2016. 3

[27] Tianchang Shen, Jun Gao, Kangxue Yin, Ming-Yu Liu 및 산자 피들러. 깊은 행진 사면체: 하이브리드 표현 고해상도 3차원 형상 합성을 위한 기술입니다. 진출 신경 정보 처리 시스템, 34:6087-6101, 2021.

2

[28] 빈센트 시츠만, 세몬 레즈치코프, 빌 프리먼, 조쉬 테넨바움, 프레도 듀란드. 라이트 필드 네트워크: 신경망 단일 평가 렌더링을 사용한 장면 표현. 광고-신경 정보 처리 시스템의 vances, 34:19313-19325, 2021. 2

[29] 올리버 K 스미스. 대칭 3×3 행렬의 고유값. ACM 통신문, 4(4):168, 1961. 6, 2

[30] Dilin Wang, Meng Li, Lemeng Wu, Vikas Chandra 및 Qiang 리우. 빠른 속도로 에너지 인식 신경 아키텍처 최적화 가장 가파른 내리막을 나누는 것입니다. arXiv 사전 인쇄 arXiv:1910.03103, 2019. 3

[31] Henan Wang, Hanxin Zhu, Tianyu He, Runsen Feng, Jia-Jun Deng, Jiang Bian 및 Zhibo Chen. 엔드투엔드 속도-왜곡 최적화된 3D 가우스 표현. arXiv 사전 인쇄 arXiv:2406.01597, 2024. 2

[32] Peihao Wang, Xuxi Chen, Tianlong Chen, Subhashini Venugopalan, Zhangyang Wang, 외 여러분. 관심이 너프인 것뿐인가 필요해? arXiv 사전 인쇄 arXiv:2207.13298, 2022. 2

[33] 왕페이하오, 라메스와르 판다, 루카스 토로바 헨나-세데, 필립 그린가드, 레오니드 칼린스키, 로제리오 페리스, 데이비드 다니엘 콕스, 왕장양, 김윤. 배워보세요-효율적인 변압기 훈련을 위해 사전 훈련된 모델을 성장시키고 있습니다. ing. arXiv 사전 인쇄 arXiv:2303.00980, 2023. 3

[34] Qianqian Wang, Zhicheng Wang, Kyle Genova, Pratul P Srinivasan, 하워드 저우, 조나단 T 배런, 리카르도 마틴-브루알라, 노아 스네이블리, 토마스 펑크하우저. 이브르넷: 멀티뷰 이미지 기반 렌더링을 학습합니다. 절차 중 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 표창, 페이지 4690-4699, 2021. 2

[35] Zhou Wang, Alan C Bovik, Hamid R Sheikh 및 Eero P 시몬첼리. 이미지 품질 평가: 오류 가시성부터 구조적 유사성. 이미지 처리에 대한 IEEE 트랜잭션, 13(4):600-612, 2004. 7

[36] Lemeng Wu, Dilin Wang, Qiang Liu. 가장 가파른 분할 성장하는 신경 구조를 위한 하강. 신경의 발전 정보처리시스템, 32, 2019. 3, 6

[37] Lemeng Wu, Bo Liu, Peter Stone 및 Qiang Liu. 반딧불이 신경 구조 하강: 성장을 위한 일반적인 접근 방식

신경망. 신경 정보 처리의 발전 시스템, 33:22373-22383, 2020. 3

[38] Lemeng Wu, Mao Ye, Qi Lei, Jason D Lee 및 Qiang Liu.

가장 가파른 하강 신경 아키텍처 최적화: 탈출

서명된 신경 분할을 통한 국소 최적. arXiv 사전 인쇄

arXiv:2003.10392, 2020. 3

[39] Lemeng Wu, Mengchen Liu, Yinpeng Chen, Dongdong Chen, 시양 다이(Xiyang Dai), 루 위안(Lu Yuan). 전문가들의 잔여 혼합, 2022.

3

[40] Qiangeng Xu, Zexiang Xu, Julien Philip, Sai Bi, Zhixin Shu,

칼얀 순카발리(Kalyan Sunkavalli), 울리히 노이만(Ulrich Neumann). 포인트 너프: 포인트-

기반 신경 방사 필드. IEEE/CVF 절차에서

컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지

5438-5448, 2022. 2

[41] 리오르 야리브, 요니 카스텐, 드로르 모란, 메이라브 갈룬, 마탄

Atzmon, Basri Ronen 및 Yaron Lipman. 다중뷰 신경

기하학과 외관을 풀어 표면을 재구성합니다.

에이스. 신경 정보 처리 시스템의 발전,

33:2492-2502, 2020. 2

[42] Wang Yifan, Felice Serena, Shihao Wu, Cengiz Oztireli 및

올가 소르키네-호농. 미분 가능한 표면 스피래팅

포인트 기반 기하학 처리. ACM 거래

그래픽(TOG), 38(6):1-14, 2019. 2

[43] Alex Yu, Ruilong Li, Matthew Tancik, Hao Li, Ren Ng 및

가나자와 양주. 실시간 렌더링을 위한 Plenocree

신경 방사 필드. IEEE/CVF Inter의 진행에서

전국 컴퓨터 비전 회의, 페이지 5752-5761,

2021. 2

[44] 리처드 장, 필립 이솔라, 알렉세이 A 에프로스, 엘리 세흐트만,

그리고 올리버 왕. 딥의 불합리한 효율성

지각 지표로 기능합니다. CVPR에서는 2018. 7

[45] Zhaoliang Zhang, Tianchen Song, 이용재, Li Yang,

Cheng Peng, Rama Chellappa 및 Deliang Fan. Lp-3dgs:

3D 가우스 스피래팅을 잘라내는 방법을 배웁니다. 서른여덟번째에

신경정보처리시스템에 관한 연례학술대회-

항목. 3, 5

[46] Matthias Zwicker, Hanspeter Pfister, Jeroen Van Baar 및

마커스 그로스. 에와 스피래팅. Visual의 IEEE 트랜잭션

alization and Computer Graphics , 8(3):223-238, 2002. 2,

3

--- 페이지 11 ---

컴팩트한 3D 가우스 스피래팅을 위한 가장 가파른 하강 밀도 제어

보충 자료

가. 시행 세부사항

A.1. 의사코드

우리는 알고리즘 1에서 우리 방법인 SteepGS에 대한 참조 의사코드를 제공합니다. 우리는 알고리즘 1과의 주요 차이점을 강조합니다.

원래 ADC는 주황색입니다. 전체 절차는 두 가지 주요 구성 요소로 구성됩니다. 먼저, 알고리즘은 분할을 추정합니다.

미니 배치 방식으로 즉석에서 행렬을 생성합니다. 둘째, 일정한 간격으로 누적된 분할 행렬을 사용하여 결정합니다. 가우스 점을 분할할지 여부와 결과 자손을 어디에 배치할지 여부입니다. 우리의 알고리즘은 일반적으로 설계되었으며 원래 ADC에서 사용된 그래디언트 기반 전략과 같은 다른 포인트 선택 기준과 통합됩니다. 마지막으로, 우리는 효율성을 위해 의사코드의 모든 for 루프가 병렬로 실행됩니다.

알고리즘 1 가장 가파른 가우스 스플래팅(SteepGS)

입력: 가우스의 초기 점 구름 $\mathcal{G} = \{(\mathbf{g}_i, \mathbf{o}(i))\}_{i=1}^N$

$N_{\text{split}}=1$; 트레이닝 세트 $D(X)$ 와 연관된 손실 함수 $L(\cdot, \cdot)$;

A 단계 크기 $\alpha > 0$; 분할 행렬 임계값 $\text{split} \leq 0$; 총 반복 횟수 T ; 치밀화 간격 T_{split} .

각 훈련 단계에 대해 $t = 1, \dots, T$ do

$t \bmod T_{\text{split}} = 0$ 이면

데이터 포인트 $\mathbf{x} \in D(X)$ 배치를 샘플링하고 손실 함수 $L(\cdot, \mathbf{x})$ 를 계산합니다.

각 가우스 $i = 1, \dots, N$ 하단

표준 경사하강법을 통해 각 가우스 매개변수 $(\mathbf{g}_i, \mathbf{o}(i))$ 를 업데이트합니다.

기울기 누적: $G(i) \leftarrow G(i) + \nabla_{\mathbf{g}_i} L(\mathbf{g}_i, \mathbf{x})$.

분할 행렬을 누적합니다: $S(i) \leftarrow S(i) + \alpha \nabla_{\mathbf{o}(i)} \ell(\mathbf{g}_i, \mathbf{x}) \nabla_{\mathbf{o}(i)}^2 L(\mathbf{g}_i, \mathbf{x})$.

종료

그렇지 않으면

각 가우스 $i = 1, \dots, N$ 하단

평균 기울기 및 분할 행렬을 얻습니다: $G(i) \leftarrow G(i)/T_{\text{split}}$, $S(i) \leftarrow S(i)/T_{\text{split}}$.

분할 행렬에 대해 가장 작은 고유값과 관련 고유벡터를 계산합니다.

$\lambda_i \leftarrow \min(S(i))$, $\mathbf{v}_i \leftarrow \text{vmin}(S(i))$.

$G(i)$ 및 λ_i 에 대한 조건이 분할되면

이 가우스를 두 개의 가우스 자손으로 바꿉니다.

$\mathcal{G} \leftarrow \mathcal{G} \setminus \{(\mathbf{g}_i, \mathbf{o}(i))\} \cup \{(\mathbf{g}_i + \lambda_i \mathbf{v}_i, \mathbf{o}(i)/2), (\mathbf{g}_i - \lambda_i \mathbf{v}_i, \mathbf{o}(i)/2)\}$

종료하면

종료

종료하면

종료

반환

A.2. 변형

증분 예산을 통한 밀도화. 최근의 치밀화 알고리즘[3, 14]에서는 숫자 또는 비율을 고정하는 것으로 나타났습니다.

증분 포인트를 늘리면 보다 컴팩트한 가우스 포인트 클라우드가 생성될 수 있습니다. 이는 전역 제약 조건을 부과하는 것에 해당합니다.

새로운 포인트의 총 개수, P

$i \in [n] \ m_i \leq 2K$, Eq. 7:

최소 $L(\cdot, \mathbf{w})$, s.t.

(i)

$j \in [n] \ (i)$

2

$\leq \cdot$,

믹스

$j=1$

$w(i)$

$j = 1,$

X

$n \in [n]$

$m_i \leq 2K, (8)$

여기서 K 는 증가된 포인트의 최대 개수입니다. 정리 2에 따르면 최대 손실 감소는 다음과 같습니다.

i 번째 가우스 분할은 $(i) * \propto \min(S(i)) / 2$ 로 제공됩니다. 따라서 손실을 극대화하는 최적의 포인트 선택

--- 페이지 12 ---

탱크 및 템플 딥 블렌딩 mip-NeRF 360 실외 mip-NeRF 360 실내

기차 트랙 Dr. Johnson 놀이방 자전거 정원 그루터기 분재 카운터 주방 공간

3DGS 22.091 25.394 29.209 30.172 25.253 27.417 26.705 32.298 29.006 31.628 31.540

가파른GS 21.974 25.395 29.478 30.447 24.890 27.159 26.115 31.911 28.737 31.030 31.401

표 2. 3DGS와 SteepGS의 장면별 PNSR 분석 표.

탱크 및 템플 딥 블렌딩 mip-NeRF 360 실외 mip-NeRF 360 실내

기차 트랙 Dr. Johnson 놀이방 자전거 정원 그루터기 분재 카운터 주방 공간

3DGS 0.813 0.882 0.901 0.907 0.766 0.867 0.908 0.773 0.942 0.928 0.919

가파른GS 0.802 0.879 0.902 0.909 0.734 0.851 0.742 0.938 0.900 0.922 0.915

표 3. 3DGS와 SteepGS의 장면별 SSIM 분석 표.

하강은 전체 가우시안 수에 대해 최소 K 값이 $\min(S(i))$ 인 가우스를 효율적으로 선택하여 수행할 수 있습니다.

음수 $\min(S(i))$ 가 K 를 초과합니다. 즉, $\{i \in [n] : \min(S(i)) < 0\}$ > 케이 .

가장 컴팩트한 분할 전략. 이론적으로 가장 간결한 분할 전략도 존재합니다. 정리 1은 다음과 같이 제안합니다.

최적의 변위 μ 는 표준 음의 기울기 $\nabla L(\cdot)$ 에 해당하며, 이는 일반적인 $O(\cdot)$ 손실 감소를 산출합니다.

고정되지 않은 지점에서. 대조적으로, 분할은 분할 특성 함수의 합산을 도입하며, 각각은 다음에 의해 관리됩니다.

연관된 분할 행렬로 인해 $O(2)$ 차수의 누적 효과가 발생합니다. 이러한 이론적 통찰력은 중요한

의미: 가우스는 기울기가 작은 경우에만 분할되어야 합니다. 그렇지 않으면 분할로 인해 중복된 가우스가 발생합니다.

손실이 거의 개선되지 않습니다. 가장 컴팩트한 분할 조건은 다음과 같이 공식화될 수 있습니다.

$G(i)rr \leq \text{grad}$ 및 $\min(S(i)) < \text{분할}, \forall i \in [n]$,

여기서 $\text{grad} > 0$ 은 선택된 하이퍼 매개변수입니다. 이 결론은 원래 ADC 전략과 모순되는 것처럼 보일 수 있지만

ADC는 기대값의 표준이 아닌 $E[|G(i)|]$ 를 추정하여 실제로 기울기의 분산을 검사한다고 주장합니다.

즉, $E[|G(i)|]$. 따라서 우리의 조건은 원래 접근 방식과 모순되지 않고 오히려 더 많은 것을 제공함으로써 이를 보완합니다.

원칙적인 기준.

A.3. 고유분해

우리 실험에서는 가장 가파른 분할 하강에 대해 위치 매개변수만 고려합니다. 이는 다음을 단순화합니다.

분할 행렬의 고유 분해는 대칭 3×3 행렬로 제한됩니다. 우리는 [29]의 방법을 따를 수 있습니다.

고유값을 계산합니다. 대칭 3×3 행렬 A 의 특성 방정식은 다음과 같습니다.

$$\det(\lambda I - A) = \lambda^3 - \text{tr}(A)\lambda^2 + \dots$$

2

$\text{tr}(A^2) - \text{tr}^2(A)$

$$\det(A) = 0.$$

A 에 대한 아핀 변경은 표현을 상당히 단순화하고 삼각법 솔루션으로 직접 연결됩니다. $A = pB + qI$ 인 경우,

그러면 A 와 B 는 동일한 고유벡터를 가지며 $\lambda = p + q$ 가 A 의 고유값인 경우에만 λ 는 B 의 고유값입니다.

$q = \text{tr}(A)$ 라고 하자

3 및 $p =$

tr

$(A - qI)^2$

6

1/2

, $\det(B) = 3 \cos^3 \theta - 3 \cos \theta = 0$ 을 유도합니다. $\cos \theta = 2 \cos^3 \theta$ 를 대체하고 $\cos^3 \theta = 4 \cos \theta$ $3 \cos \theta$ 항등식을 사용하여 일부 대수적 단순화를 수행하면 $\cos^3 \theta = \det(B)$ 를 얻을 수 있습니다.

2. 따라서 뿌리는

특성방정식은 다음과 같이 주어진다:

 $\cos \theta = 2 \cos^3 \theta$

1

3 아르코스

데트(B)

2

+ 2k

3

, $k = 0, 1, 2$.A가 실수이고 대칭인 경우 $\det(B)$ 도 실수이고 절댓값이 2보다 크지 않습니다.

B. 추가 실험 결과

측정항목 분석. 표 2, 3, 4 및 5는 PSNR, SSIM, LPIPS 및 수에 대한 분석 수치 평가를 제공합니다.

우리의 방법과 원래의 적응형 밀도 제어에 대한 포인트 수입입니다. 결과는 우리의 방법이 달성되었음을 보여줍니다

모든 장면에서 원래의 밀도화와 비슷한 성능을 발휘합니다. 특히, Playroom과 Dr. Johnson에서는

장면에서 우리의 방법은 포인트 수의 절반만 활용하면서 원래 적응형 밀도 제어보다 성능이 뛰어납니다.

--- 페이지 13 ---

탱크 및 템플 딥 블렌딩 mip-NeRF 360 실외 mip-NeRF 360 실내

기차 트랙 Dr. Johnson 놀이방 자전거 정원 그루터기 분재 카운터 주방 공간

3DGS 0.207 0.147 0.244 0.244 0.210 0.107 0.215 0.203 0.200 0.126 0.219

가파른GS 0.230 0.160 0.251 0.250 0.268 0.142 0.271 0.211 0.217 0.137 0.233

표 4. 3DGS와 SteepGS의 장면별 LPIPS 분석 표.

탱크 및 템플 딥 블렌딩 mip-NeRF 360 실외 mip-NeRF 360 실내

기차 트랙 Dr. Johnson 놀이방 자전거 정원 그루터기 분재 카운터 주방 공간

3DGS 1088197 2572172 3316036 2320830 6074705 5845401 4863462 1260017 1195896 1807771

1550152

가파른GS 530476 1387065 1485567 1107604 2900640 2195185 3175021 746163 591508 922717 710212

표 5. 3DGS와 SteepGS를 통해 밀도화된 포인트 수에 대한 분석 표.

3DGS ADC (4.9M) 우리 것 (3.1M) 우리 것 (3.5M)

그림 6. 추가 작업 후 방법의 시각적 품질이 향상되었습니다.

가우스 분할의 단계.

자전거 정원 그루터기

3DGS 25.25 27.42 26.70

우리 24.89 27.16 26.11

우리 (추가 단계) 25.23 27.38 26.65

표 6. 평가된 방법의 향상된 성능

추가 단계의 가우스 분할 후 PSNR.

더 많은 시각화. 그림 7은 4개 장면에서 치밀화를 위해 선택된 점을 시각화합니다. 우리의 방법이 관찰될 수 있다

흐릿하게 재구성되지 않은 영역이 있는 영역에 집중하여 더 적은 수의 포인트를 선택합니다. 이에 비해 원래 적응형은

밀도 제어는 고주파 세부 사항에 대해 더 많은 밀도를 수행하므로 렌더링을 효과적으로 향상시킬 가능성이 적습니다. 품질. 이러한 결과는 우리의 방법이 다음 영역으로 치밀화를 유도하여 계산 리소스를 절약한다는 것을 입증합니다. 렌더링 손실이 가장 급격하게 감소합니다.

더 많은 지표와 비교 방법. 본문의 비교 방법 외에도 두 가지 기준을 더 테스트합니다.

컴팩트-3DGS[16] 및 LP-3DGS[45]. 훈련을 위한 GPU의 경과 시간, 평균 및 최고 GPU 메모리도 포함됩니다.

훈련에 사용하고 FPS4를 추가 측정항목으로 렌더링합니다. 표 7은 MipNeRF360에서 평가된 비교 결과를 제시합니다.

Temple&Tanks 및 Deep Blending 데이터 세트. Compact-3DGS와 LP-3DGS는 최종 결과에서 더 적은 점수를 산출하지만,

우리의 방법은 PSNR에서 더 나은 측정 항목을 달성하고 GPU의 훈련 시간을 크게 줄입니다. 게다가 우리의 방법은 GPU 메모리 사용량을 지속적으로 줄이고 원래 3DGS ADC에 비해 렌더링 FPS를 향상시킵니다.

새로 비교된 두 가지 방법과 동등합니다.

성능이 향상되었습니다. 독자들은 우리의 방법이 그에 더 가까운 성능을 얻을 수 있는지 궁금할 것입니다.

원래 3DGS ADC의. 주요 실험에서는 공정한 비교를 보장하기 위해 ADC의 하이퍼 매개변수를 재사용했습니다.

그러나 우리는 일부 MipNeRF360에서 치밀화 반복을 25K로 확장하고 전체 훈련 단계를 40K로 확장한다는 것을 발견했습니다.

장면을 사용하면 우리 방법이 더 나은 성능을 달성하고 렌더링된 이미지에서 관찰되는 흐릿함을 더욱 완화할 수 있습니다.

참고로, 표 6은 더 많은 치밀화 반복을 통한 성능 향상을 보여줍니다. 그림 6은 감소된 것을 보여줍니다.

그러르기 장면의 흐릿함.

4FPS 측정이 일관되지 않을 수 있다는 점을 관찰했으며 표에 보고된 값은 참고용으로 간주되어야 합니다.

--- 페이지 14 ---

ADC가 포함된 3DGS

11,917포인트 56,525포인트

7,706점 26,079포인트

9,860점 2,932점.

7,824포인트 26,223포인트

그림 7. 분할 지점의 추가 시각화. 제안한 방법과 원래의 ADC로 분할된 포인트 수를 비교합니다.

다. 이론

C.1. 표기법 및 설정

우선 표기법과 문제 설정을 더욱 엄격하게 다시 소개합니다. 우리는 각 가우스를 다음과 같이 추상화합니다.

함수 $(x; (i)) : \mathbb{R}^3 \rightarrow \mathbb{O}$ 여기서 $(i) \in \mathbb{N}$ 는 평균, 공분산, 밀도, SH 계수를 캡슐화하는 매개변수입니다.

$(x; (i)) \in \mathbb{X}$ 는 각각 카메라 변환과 2D 픽셀 좌표를 나타내며 출력에는 밀도와

공간 O의 RGB 색상. 더 나아가 입력 공간에 확률 측정값 $D(X)$ 를 할당합니다. 우리는 $\mathbb{O}$ -블렌딩과

단일 함수로서의 광도 손실 $\ell(\cdot) : P(\mathbb{O}) \rightarrow \mathbb{R}$, 여기서 $P(\mathbb{O})$ 는 전체 출력 공간을 나타냅니다.

요소는 출력 공간 O에 있습니다. 장면에 n 개의 가우스가 있다고 가정하면 모든 매개변수를 $\theta = \{(i)\}_n$ 로 나타냅니다.

$n=1$

약어로 총 손실 함수는 다음과 같이 표현될 수 있습니다.

$$L(\theta) = \mathbb{E}_{x \sim D(X)} [\ell((x; (1)), \dots, (x; (n)))]. \quad (9)$$

이제 우리의 목표는 각 가우스를 m_i 자손으로 분할하는 것입니다. i 번째 가우스 자손의 매개변수를 다음과 같이 나타냅니다.

$$(i) = \{(i)$$

$$j\}_{m_i}$$

$$j=1, \text{ 여기서 } (i)$$

j 는 i 번째 가우스 분포의 j 번째 자식이고 이를 재가중 계수 그룹에 할당합니다.

$$w(i) = \{w(i)$$

$$j\}_{m_i}$$

$j=1$ 은 원래 가우스를 다음과 같이 과도하게 매개변수화합니다.

```

j=1w(i)
j (x; (i)
j ) 그런 식으로Pmi
j=1w(i)
j = 1마다
i ∈ [n] 모든 새로운 가우스의 매개변수를 = { (i)}n으로 수집합니다.
i=1, w = {w(i)}n으로 계수 재가중
i=1, for

```

--- 페이지 15 ---

립네RF360

포인트↓ PSNR↑ SSIM↑ LPIPS↓ GPU 경과↓ 평균 GPU 메모리↓ 최대 GPU 메모리↓ FPS↑
 3DGS 3.339M 29.037 0.872 0.183 1550.925초 10.262GB 12.110GB 179
 LP-3DGS 1.303M 28.640 0.865 0.198 1177.648초 10.027GB 12.458GB 350
 Compact-3DGS 1.310M 28.504 0.856 0.208 4063.203초 7.274GB 9.044GB 98
 SteepGS(당사) 1.606M 28.734 0.857 0.211 1051.276초 7.597GB 8.957GB 252
 탱크와 사원

포인트↓ PSNR↑ SSIM↑ LPIPS↓ GPU 경과↓ 평균 GPU 메모리↓ 최대 GPU 메모리↓ FPS↑
 3DGS 1.830M 23.743 0.848 0.177 803.542초 5.193GB 6.241GB 248
 LP-3DGS 0.671M 23.424 0.839 0.197 1021.806초 5.045GB 6.489GB 150
 Compact-3DGS 0.836M 23.319 0.835 0.200 1255.748초 3.802GB 4.774GB 357
 SteepGS(당사) 0.958M 23.684 0.840 0.194 539.048초 4.701GB 5.607GB 343

딥 블렌딩

포인트↓ PSNR↑ SSIM↑ LPIPS↓ GPU 경과↓ 평균 GPU 메모리↓ 최대 GPU 메모리↓ FPS↑
 3DGS 2.818M 29.690 0.904 0.244 1429.878초 8.668GB 10.218GB 187
 LP-3DGS 0.861M 29.764 0.906 0.249 1697.793초 8.354GB 10.115GB 134
 Compact-3DGS 1.054M 29.896 0.905 0.255 1861.897초 6.332GB 8.026GB 312
 SteepGS(당사) 1.296M 29.963 0.905 0.250 956.536초 5.928GB 9.506GB 280

표 7. MipNeRF360, Tank & Temple 및 Deep Blending 데이터 세트에 대한 LP-3DGS [45] 및 Compact-3DGS [16] 기준선과 비교.

추가 지표: 훈련을 위한 GPU 경과 시간, 평균 및 최고 GPU 메모리 사용량, FPS가 포함됩니다.

속기. 새로 추가된 가우시안을 사용하면 증가된 손실 함수는 다음과 같습니다.

$L(\mathbf{w}, \mathbf{w}) = E_{\mathbf{x}} D(\mathbf{X})$

ℓ

m1X

j=1

w(1)

j (x; (1)

j), ...,

mnX

j=1

w(n)

j (x; (n)

j)

. (10)

C.2. 주요 결과

정리 증명 1. $\mu(i)$ 를 $\mu(i)$ 의 평균 변위로 정의합니다. $\mu(i) = (P\mu_i$

$j=1$ $w(i)$

j $\mu(i)$

j $\mu(i)/$ 및 $\mu(i)$

$j =$

$\mu(i)$

j 번째 자손에 대한 $\mu(i)$ 에 추가되는 오프셋인 j $\mu(i)/$ $\mu(i)$. 다음은 분명합니다.

믹스

$j=1$

$w(i)$

j $\mu(i)$

$j =$

믹스

$j=1$

$w(i)$

j

$\mu(i)$

j $\mu(i)$

$\mu(i)$

!

$= 1$

믹스

$j=1$

$w(i)$

j $\mu(i)$

$j - 1$

믹스

$j=1$

$w(i)$

j $\mu(i)$

믹스

$j=1$

$w(i)$

$j \mu(i)$

$= 1$

믹스

$j=1$

$w(i)$

$j(i)$

$j-1$

$(i) \quad \mu(i) = 0. \quad (11)$

또한 (i)

$j = \mu(i) + (i)$

j 및 (i)

j 는 다음과 같이 쓸 수 있습니다: (i)

$j = (i) + (i)$

$j = (i) + ((i) + (i))$

j). 우리는

보조 함수: $L((i), (i), w(i))$:

$L((i), (i), w(i)) = E_{x \in D(X)}$

ℓ

$(x; (1)), \dots,$

믹스

$j=1$

$w(i)$

$j(x; (i)$

$j), \dots, (x; (n))$

, (12)

--- 페이지 16 ---

이는 i 번째 가우스 (i) 를 (i) 로만 분할합니다. Lemma 6에 따르면 다음과 같습니다.

$(L(\cdot, w) - L(\cdot)) =$

nX

나는=1

$L((i), (i), w(i)) - L(\cdot)$

$+ 2$

2

X

나는,나는' $\in [n]$

나는 =나'

$\mu(i) \top \partial 2$

$(i) (i') L(\cdot) (i') + O(3). \quad (13)$

Lemma 7에 따르면 다음과 같습니다.

$L((i), (i), w(i)) - L(\cdot) = \partial (i) L(\cdot) \top (i) + 2$

$2 \mu(i) \top \partial 2$

$(i) (i) L(\cdot) (i) \quad (14)$

$+ 2$

2

믹스

$j=1$

$w(i)$

$j \quad (i)^\top$

$j \, S(i)(\quad) \, (i)$

$j + O(\quad 3). \, (15)$

=라고 하자

$\mu(1) \cdots \mu(n)$

모든 가우스의 평균 변위를 연결합니다. 방정식을 결합. 13 및 식. 14, 우리는 할 수 있다

결론:

$(L(\quad , w) \quad L(\quad)) =$

nX

나는=1

$\partial \quad (i) \, L(\quad)^\top \quad (i) + \quad 2$

$2 \, \mu(i)^\top \partial 2$

$(i) \, (i) \, L(\quad) \, (i) + \quad 2$

2

믹스

$j=1$

$w(i)$

$j \quad (i)^\top$

$j \, S(i)(\quad) \, (i)$

j

$+ \quad 2$

2

X

나는,나는' $\in [n]$

나는 =나'

$\mu(i)^\top \partial 2$

$(i) \, (i') \, L(\quad) \, (i') + O(\quad 3)$

=

nX

나는=1

$\partial \quad (i) \, L(\quad)^\top \quad (i) + \quad 2$

2

X

나는,나는' $\in [n]$

$\mu(i)^\top \partial 2$

$(i) \, (i') \, L(\quad) \, (i')$

$+ \quad 2$

2

믹스

$j=1$

$w(i)$

$$\begin{aligned}
& j \quad (i)^\top \\
& j \, S(i)(\quad) \, (i) \\
& j + O(\quad 3) \\
& = \quad \nabla \, L(\quad)^\top \quad + \quad 2 \\
& 2 \, \mu^\top \nabla 2L(\quad) \, \mu + \quad 2 \\
& 2 \\
& \text{믹스}
\end{aligned}$$

$$\begin{aligned}
& j=1 \\
& w(i) \\
& j \quad (i)^\top \\
& j \, S(i)(\quad) \, (i) \\
& j + O(\quad 3), \\
& \text{원하는대로.}
\end{aligned}$$

정리 증명 2. 표준 변형 특성화에 따르면 다음과 같은 하한이 있습니다.

$$\begin{aligned}
& (i)(\quad (i), w(i); \quad) := \quad 2 \\
& 2
\end{aligned}$$

$$\begin{aligned}
& \text{믹스} \\
& j=1 \\
& w(i) \\
& j \quad (i)^\top \\
& j \, S(i)(\quad) \, (i) \\
& j \geq \quad 2 \\
& 2
\end{aligned}$$

$$\begin{aligned}
& \text{믹스} \\
& j=1 \\
& w(i) \\
& j \quad \min(S(i)(\quad)) = \quad 2 \\
& 2 \quad \min(S(i)(\quad)), \\
& \text{MAT} \quad (i) \text{의 적용을 받음}
\end{aligned}$$

$j \, Bu \leq 1$. (i) 인 경우에만 등식이 성립합니다.

j 는 $S(i)(\quad)$ 의 가장 작은 고유벡터와 같습니다.

따라서 $\min(S(i)(\quad)) \geq 0$ 이면 손실이 감소하지 않습니다. 그렇지 않으면 간단히 $m_i = 2$, $w(i)$ 를 선택할 수 있습니다.

$$1 = w(i)$$

$$2 = 1/2,$$

$$(i)$$

$$1 = \text{vmin}(S(i)(\quad)) \text{ 및 } (i)$$

$$2 = \quad \text{vmin}(S(i)(\quad)) \text{ 이 하한을 달성합니다.}$$

C.3. 보조 결과

정리 3. 모든 $i \in [n]$ 에 대해 $L(\quad)$ 에 대해 다음 등식이 유지됩니다.

$$\textcircled{a} \quad (i) \, L(\quad) = E \quad , x \in D(X)$$

시간

$$\textcircled{a} \quad (i) \, \ell$$

$$(x; \quad (1)), \cdots, \quad (x; \quad (n))$$

$$\nabla \quad (x; \quad (i))$$

나

$$\partial^2$$

$$(i) \quad (i) L(\cdot) = T(i)(\cdot) + S(i)(\cdot),$$

$$\partial^2$$

$$(i) \quad (i') L(\cdot) = E_{\cdot, x} D(X)$$

시간

$$\partial^2$$

$$(i) \quad (i') \ell$$

$$(x; (1)), \dots, (x; (n))$$

$$\nabla (x; (i)) \nabla (x; (i')) \top$$

나

$$, \forall i' \in [n], i' = i,$$

$$\text{여기서 } T(i)(\cdot) = E_{\cdot, x} D(X)$$

시간

$$\partial^2$$

$$(i) \quad (i) \ell$$

$$(x; (1)), \dots, (x; (n))$$

$$\nabla (x; (i)) \nabla (x; (i)) \top$$

나

.

--- 페이지 17 ---

증거. $L(\cdot)$ 의 기울기는 간단한 연쇄 법칙을 통해 증명됩니다. 그리고

$$\partial^2$$

$$(i) \quad (i') L(\cdot) = \partial (i') [\partial (i) L(\cdot)]$$

$$= E_{\cdot, x} D(X)$$

시간

$$\partial^2$$

$$(i) \quad (i') \ell$$

$$(x; (1)), \dots, (x; (n))$$

$$\nabla (x; (i)) \nabla (x; (i')) \top$$

나

$$+ E_{\cdot, x} D(X)$$

시간

$$\partial (i) \ell$$

$$(x; (1)), \dots, (x; (n))$$

$$\partial (i') \nabla (x; (i))$$

나

.

$i = i'$ 일 때, $\partial_{\mathbf{x}} (i') \nabla^2 \mathbf{L}(\mathbf{x}; (i)) = \nabla^2 \mathbf{L}(\mathbf{x}; (i))$, 이후로는:

$$(i) \quad \mathbf{L}(\mathbf{x}) = \mathbf{T}(i)(\mathbf{x}) + \mathbf{S}(i)(\mathbf{x}).$$

그렇지 않으면 $\partial_{\mathbf{x}} (i') \nabla^2 \mathbf{L}(\mathbf{x}; (i)) = 0$ 이므로 다음과 같습니다.

$$(i) \quad (i') \mathbf{L}(\mathbf{x}) = \mathbf{L}(\mathbf{x}) - \mathbf{D}(\mathbf{x})$$

시간

$$(i) \quad (i') \ell$$

$$(\mathbf{x}; (1)), \dots, (\mathbf{x}; (n))$$

$$\nabla \mathbf{L}(\mathbf{x}; (i)) \nabla \mathbf{L}(\mathbf{x}; (i'))^\top$$

나

,

모두 원하는대로.

정리 4. $\mathbf{L}(\mathbf{x}, \mathbf{w})$ 에 대해 다음 등식이 성립합니다.

$$\partial_{\mathbf{x}} (i)$$

j

$$\mathbf{L}(\mathbf{x}, \mathbf{w})$$

$$= 0$$

$$= \mathbf{w}(i)$$

$$\partial_{\mathbf{x}} (i) \mathbf{L}(\mathbf{x}), \forall i \in [n], j \in [m_i], (16)$$

$$\partial_{\mathbf{x}}^2$$

$$(i)$$

$$\mathbf{j} \quad (i)$$

j

$$\mathbf{L}(\mathbf{x}, \mathbf{w})$$

$$= 0$$

$$= \mathbf{w}(i)$$

$$\mathbf{j} \mathbf{S}(i)(\mathbf{x}) + \mathbf{w}(i)^2$$

$$\mathbf{j} \mathbf{T}(i)(\mathbf{x}), \forall i \in [n], j \in [m_i], (17)$$

$$\partial_{\mathbf{x}}^2$$

$$(i)$$

$$\mathbf{j} \quad (i)$$

j'

$$\mathbf{L}(\mathbf{x}, \mathbf{w})$$

$$= 0$$

$$= \mathbf{w}(i)$$

$$\mathbf{j} \mathbf{S}(i)$$

$$\mathbf{j}' \mathbf{T}(i)(\mathbf{x}), \forall i \in [n], j, j' \in [m_i], j = j', (18)$$

$$\partial_{\mathbf{x}}^2$$

$$(i)$$

$$\mathbf{j}, (i')$$

j'
 $L(\cdot, w)$

$=0$
 $=w(i)$
 $jw(i')$
 $j' \geq 2$
 $(i) \quad (i') L(\cdot), \forall i, i' \in [n], i = i', j \in [mi], j' \in [mi'], (19)$

여기서 $T(i)(\cdot) = E_{\cdot, x} D(X)$

시간

≥ 2

$(i) \quad (i) \ell$

$(x; (1)), \dots, (x; (n))$

$\nabla (x; (i)) \nabla (x; (i))^\top$

나

에 정의된 바와 같다

보조정리 3.

증거. Let $e_{\cdot} (x; (i)) = P m_i$

$j=1w(i)$

$j \quad (x; (i))$

j) 그리고 $L(\cdot, w)$ 를 다음과 같이 표현할 수 있습니다.

$L(\cdot, w) = E_{\cdot, x} D(X)$

시간

ℓ

$e_{\cdot} (x; (1)), \dots, e_{\cdot} (x; (n))$

나는

. (20)

$L(\cdot, w)$ 의 도함수를 얻기 위해 체인 규칙을 활용합니다. 모든 $i \in [n], j \in [mi]$ 에 대해:

$\geq (i)$

j

$L(\cdot, w) = \geq (i)$

j

$E_{\cdot, x} D(X)$

시간

ℓ

$e_{\cdot} (x; (1)), \dots, e_{\cdot} (x; (n))$

나는

$=_{\cdot, x} D(X)$

시간

$\geq (i)$

j

ℓ

$$e(x; (1)), \dots, e(x; (n))$$

나는

$$= \sum_j x_j D(X)$$

시간

$$\partial(i) \ell$$

$$e(x; (1)), \dots, e(x; (n))$$

$$\partial(i)$$

j

$$e(x; (i))$$

나

$$= w(i)$$

$$\sum_j x_j D(X)$$

시간

$$\partial(i) \ell$$

$$e(x; (1)), \dots, e(x; (n))$$

$$\nabla(x; (i)$$

j)

나

$$. (21)$$

$$= 0 \text{이므로 } (i)$$

$$j = (i) \text{ 및 } e(x; (i)) = P_{mi}$$

$$j=1w(i)$$

$$j(x; (i)) = (x;). \text{ 따라서 우리는 Eq.를 더욱 단순화할 수 있습니다.}$$

21 다음과 같이:

$$\partial(i)$$

j

$$L(, w)$$

$$= 0$$

$$= w(i)$$

$$\sum_j x_j D(X)$$

시간

$$\partial(i) \ell$$

$$e(x; (1)), \dots, e(x; (n))$$

$$\nabla(x; (i)$$

j)

나

$$= 0$$

$$= w(i)$$

$$\sum_j x_j D(X)$$

시간

$\partial \quad (i) \ell$

$(x; \quad (1)), \cdots, \quad (x; \quad (n))$

$\nabla \quad (x; \quad (i))$

나

$= w(i)$

$j \partial \quad (i) L(\quad),$

--- 페이지 18 ---

마지막 단계는 Lemma 3입니다.

다음으로 2차 도함수를 유도합니다. Eq. (i') 측면에서 21

일부 $i' \in [n], j' \in [mi']$ 에 대해 j' , 그리고

체인 규칙:

∂^2

(i)

$j \quad (i')$

j'

$L(\quad, w) = \partial \quad (i')$

j'

$w(i)$

$j \quad, x \quad D(X)$

시간

$\partial \quad (i) \ell$

$e \quad (x; \quad (1)), \cdots, e \quad (x; \quad (n))$

$\nabla \quad (x; \quad (i)$

$j)$

나

$= w(i)$

$j \quad, x \quad D(X)$

∂^2

$(i) \quad (i') \ell$

$e \quad (x; \quad (1)), \cdots, e \quad (x; \quad (n))$

$\nabla \quad (x; \quad (i)$

$j) \partial \quad (i')$

j'

$e \quad (x; \quad (i')) \top$

$+ \text{승}(i)$

$j \quad, x \quad D(X)$

$\partial \quad (i) \ell$

$e \quad (x; \quad (1)), \cdots, e \quad (x; \quad (n))$

$\partial \quad (i')$

j'

$\nabla \quad (x; \quad (i)$

$j)$

$= w(i)$

$jw(i')$

$j' \in \mathcal{X} \cap D(X)$

시간

∂^2

$(i) \quad (i') \ell$

$e \quad (x; \quad (1)), \cdots, e \quad (x; \quad (n))$

$\nabla \quad (x; \quad (i)$

$j) \nabla \quad (x; \quad (i')$

$j')^\top$

나

$+ \text{승}(i)$

$j \in \mathcal{X} \cap D(X)$

$\partial \quad (i) \ell$

$e \quad (x; \quad (1)), \cdots, e \quad (x; \quad (n))$

$\partial \quad (i')$

j'

$\nabla \quad (x; \quad (i)$

$j)$

.

이제 우리는 세 가지 시나리오를 논의합니다.

1. $i = i'$ 이고 $j = j'$ 일 때, $\partial \quad (i')$

j'

$\nabla \quad (x; \quad (i)$

$j) = \nabla^2 \quad (x; \quad (i)$

$j)$, 그리고 나서

∂^2

(i)

$j \quad (i)$

j

$L(\quad, w) = w(i)^2$

$j \in \mathcal{X} \cap D(X)$

시간

∂^2

(i) (i) ℓ

$e(x; (1)), \dots, e(x; (n))$

$\nabla(x; (i)$

$j) \nabla(x; (i)$

$j) \top$

나

+ 승(i)

$j, x \in D(X)$

시간

$\partial(i) \ell$

$e(x; (1)), \dots, e(x; (n))$

$\nabla^2(x; (i)$

$j)$

나

(22)

2. $i = i'$ 이고 $j = j'$ 일 때, $\partial(i')$

j'

$\nabla(x; (i)$

$j) = 0$ 이므로

∂^2

(i)

$j(i)$

j'

$L(\cdot, w) = w(i)$

j 승(i)

$j' \in \cdot, x \in D(X)$

시간

∂^2

(i) (i) ℓ

$e(x; (1)), \dots, e(x; (n))$

$\nabla(x; (i)$

$j) \nabla(x; (i)$

$j') \top$

나

(23)

3. $i = i'$, $\partial(i')$ 일 때

j'

$\nabla(x; (i)$

$j) = 0$, 이후

$$\begin{aligned} & \partial^2 \\ & (i) \\ & j \quad (i') \\ & j' \\ & L(\quad, w) = w(i) \\ & jw(i') \\ & j' \in \quad, x \in D(X) \\ & \text{시간} \\ & \partial^2 \\ & (i) \quad (i') \ell \end{aligned}$$

$$e \quad (x; \quad (1)), \cdots, e \quad (x; \quad (n))$$

$$\begin{aligned} & \nabla \quad (x; \quad (i) \\ & j) \nabla \quad (x; \quad (i') \\ & j') \top \\ & \text{나} \\ & (24) \\ & \text{이 사실을 다시 사용하면: } (i) \\ & j = \quad (i) \text{ 및 } e \quad (x; \quad (i)) = Pmi \\ & j=1w(i) \\ & = 0 \text{ 일 때 } j \quad (x; \quad (i)) = \quad (x; \quad (i)), \text{ Eq. 22는 다음과 같습니다:} \end{aligned}$$

$$\begin{aligned} & \partial^2 \\ & (i) \\ & j \quad (i) \\ & j \\ & L(\quad, w) \end{aligned}$$

$$\begin{aligned} & = 0 \\ & = w(i)^2 \\ & j \quad, x \in D(X) \\ & \text{시간} \\ & \partial^2 \\ & (i) \quad (i) \ell \end{aligned}$$

$$(x; \quad (1)), \cdots, \quad (x; \quad (n))$$

$$\begin{aligned} & \nabla \quad (x; \quad (i)) \nabla \quad (x; \quad (i)) \top \\ & \text{나} \\ & + \text{승}(i) \\ & j \quad, x \in D(X) \\ & \text{시간} \\ & \partial \quad (i) \ell \end{aligned}$$

$$(x; \quad (1)), \cdots, \quad (x; \quad (n))$$

$$\nabla^2 \quad (x; \quad (i))$$

나
 $= w(i)^2$
 $j \ T(i)(\) + w(i)$
 $jS(i)(\),$
 방정식. 23은 다음과 같이 단순화할 수 있습니다.

∂^2
 (i)
 $j \ (i)$
 j'
 $L(\ , w)$

$= 0$
 $= w(i)$
 $j_{\text{승}}(i)$
 $j' \in \mathcal{E}, x \in D(X)$
 시간

∂^2
 $(i) \ (i) \ell$

$(x; (1)), \dots, (x; (n))$

$\nabla \ (x; (i)) \nabla \ (x; (i)) \top$

나
 $= w(i)$
 $j_{\text{승}}(i)$
 $j' \ T(i)(\),$
 그리고 Lemma 3, Eq. 24는 다음과 같이 변합니다.

∂^2
 (i)
 $j \ (i')$
 j'
 $L(\ , w)$

$= 0$
 $= w(i)$
 $jw(i')$
 $j' \in \mathcal{E}, x \in D(X)$
 시간

∂^2
 $(i) \ (i') \ell$

$(x; (1)), \dots, (x; (n))$

$\nabla \ (x; (i)) \nabla \ (x; (i')) \top$

나
 $= w(i)$
 $jw(i')$

$j' \geq 2$
 (i)
 $j = (i')$
 j'
 $L(\cdot)$,
 모두 원하는대로.

--- 페이지 19 ---

정리 5. 임의의 $i \in [n]$ 에 대해 $\mathcal{L}_i = 0$ 에서 $L(\cdot(i), \cdot(i), w(i))$ 에 대해 다음 등식이 유지됩니다.

$\mathcal{L}_i(i)$
 j
 $L(\cdot(i), \cdot(i), w(i))$

$= 0$
 $= w(i)$
 $j \geq (i) L(\cdot), \forall j \in [mi], (25)$

$\mathcal{L}_i$
 (i)
 $j = (i)$
 j
 $L(\cdot(i), \cdot(i), w(i))$

$= 0$
 $= w(i)$
 $j S(i)(\cdot) + w(i)^2$
 $j T(i)(\cdot), \forall j \in [mi], (26)$

$\mathcal{L}_i$
 (i)
 $j = (i)$
 j'
 $L(\cdot(i), \cdot(i), w(i))$

$= 0$
 $= w(i)$
 $j \leq (i)$
 $j' T(i)(\cdot), \forall j, j' \in [mi], j = j', (27)$
 여기서 $T(i)(\cdot) = E_{\cdot, x} D(X)$

시간

$\mathcal{L}_i$
 (i) (i) ℓ

$(x; (1)), \dots, (x; (n))$

$\nabla (x; (i)) \nabla (x; (i))^\top$
 나

에 정의된 바와 같다
 보조정리 3.

증거. 증명은 Lemma 4와 동일합니다. 완전성을 위해 세부 사항을 설명합니다. Let $e_{j=1}^{w(i)}(x; (i)) = P_{mi}$

$j=1$
 $w(i)$
 $(x; (i))$

$j)$

그리고 $L((\lambda_i), (i), w(i))$ 를 다음과 같이 표현할 수 있습니다.

$$L((\lambda_i), (i), w(i)) = E_{x \in D(X)}$$

시간

ℓ

$$(x; (1)), \dots, e_{j=1}^{w(i)}(x; (i)), \dots, (x; (n))$$

나는

. (28)

연쇄 법칙에 따르면, 모든 $j \in [mi]$ 에 대해:

$$\partial_{j=1}^{w(i)}$$

j

$$L((\lambda_i), (i), w(i)) = \partial_{j=1}^{w(i)}$$

j

$$E_{x \in D(X)}$$

시간

ℓ

$$(x; (1)), \dots, e_{j=1}^{w(i)}(x; (i)), \dots, (x; (n))$$

나는

$$= E_{x \in D(X)}$$

시간

$$\partial_{j=1}^{w(i)} \ell$$

$$(x; (1)), \dots, e_{j=1}^{w(i)}(x; (i)), \dots, (x; (n))$$

$$\partial_{j=1}^{w(i)}$$

j

$$e_{j=1}^{w(i)}(x; (i))$$

나

$$= w(i)$$

$$j \in D(X)$$

시간

$$\partial_{j=1}^{w(i)} \ell$$

$$(x; (1)), \dots, e_{j=1}^{w(i)}(x; (i)), \dots, (x; (n))$$

$$\nabla_{j=1}^{w(i)}$$

$j)$

나

. (29)

(i)라는 사실을 이용하여

$$j = (i) \text{ 및 } e_{j=1}^{w(i)}(x; (i)) = P_{mi}$$

$$j=1$$

$= 0$ 일 때 j $(x; (i)) = (x; (i))$, Eq. 29는 다시 쓸 수 있습니다
다음과 같이:

$$\begin{aligned} & \partial (i) \\ & j \\ & L(\backslash i), (i), w(i)) \end{aligned}$$

$$\begin{aligned} & = 0 \\ & = w(i) \\ & j, x \in D(X) \\ & \text{시간} \\ & \partial (i) \ell \end{aligned}$$

$$(x; (1)), \dots, e (x; (i)), \dots, (x; (n))$$

$$\begin{aligned} & \nabla (x; (i) \\ & j) \\ & \text{나} \\ & = 0 \\ & = w(i) \\ & j, x \in D(X) \\ & \text{시간} \\ & \partial (i) \ell \end{aligned}$$

$$(x; (1)), \dots, (x; (i)), \dots, (x; (n))$$

$$\begin{aligned} & \nabla (x; (i)) \\ & \text{나} \\ & = w(i) \end{aligned}$$

$j \partial (i) L(\quad)$,
마지막 단계는 Lemma 3입니다.
다음으로 2차 도함수를 유도합니다. Eq. (i) 측면에서 29
일부 $j' \in [m_i]$ 에 대해 j' , 그리고 체인에 의해
규칙:

$$\begin{aligned} & \partial^2 \\ & (i) \\ & j (i) \\ & j' \\ & L(\backslash i), (i), w(i)) = \partial (i) \\ & j' \\ & w(i) \\ & j, x \in D(X) \\ & \text{시간} \\ & \partial (i) \ell \end{aligned}$$

$$\dots, e (x; (i)), \dots$$

$$\nabla (x; (i))$$

$j)$
 나
 $= w(i)$
 $j, x \in D(X)$

∂^2
 $(i) \quad (i) \ell$

$\cdots, e \quad (x; \quad (i)), \cdots$

$\nabla \quad (x; \quad (i)$
 $j) \partial \quad (i)$
 j'
 $e \quad (x; \quad (i')) \top$

$+ \text{승}(i)$
 $j, x \in D(X)$

$\partial \quad (i) \ell$

$\cdots, e \quad (x; \quad (i)), \cdots$

$\partial \quad (i)$
 j'
 $\nabla \quad (x; \quad (i)$
 $j)$

$= w(i)$
 $j \text{승}(i)$
 $j' \in E, x \in D(X)$
 시간
 ∂^2
 $(i) \quad (i) \ell$

$\cdots, e \quad (x; \quad (i)), \cdots$

$\nabla \quad (x; \quad (i)$
 $j) \nabla \quad (x; \quad (i)$
 $j') \top$
 나
 $+ \text{승}(i)$
 $j, x \in D(X)$

$\partial \quad (i) \ell$

$\cdots, e \quad (x; \quad (i)), \cdots$

$\vartheta(i)$

j'

$\nabla(x; (i)$

$j)$

.

이제 우리는 두 가지 시나리오를 고려합니다.

1. $j = j'$ 일 때, $\vartheta(i)$

j'

$\nabla(x; (i)$

$j) = \nabla^2(x; (i)$

$j)$, 그리고 나서

ϑ^2

(i)

$j(i)$

j

$L(\backslash i, (i), w(i))$

$= 0$

$= w(i)^2$

$j, x \in D(X)$

시간

ϑ^2

$(i) \in \ell$

$\dots, e(x; (i)), \dots$

$\nabla(x; (i)$

$j) \nabla(x; (i)$

$j) \top$

나

$+ \text{승}(i)$

$j, x \in D(X)$

시간

$\vartheta(i) \in \ell$

$\dots, e(x; (i)), \dots$

$\nabla^2(x; (i)$

$j)$

나

(30)

--- 페이지 20 ---

2. $j = j'$ 일 때, $\vartheta(i)$

j'

$\nabla(x; (i)$

$j) = 0$ 이므로

∂^2

(i)

$j \quad (i)$

j'

$L(\quad(i), \quad(i), w(i))$

$=0$

$= w(i)$

$j \text{ 승}(i)$

$j' \in \mathbb{R}, x \in D(X)$

시간

∂^2

(i) (i) ℓ

$\cdots, e \quad (x; \quad(i)), \cdots$

$\nabla \quad (x; \quad(i))$

$j) \nabla \quad (x; \quad(i))$

$j')^\top$

나

(31)

이 사실을 다시 사용하면: (i)

$j = \quad(i)$ 및 $e \quad (x; \quad(i)) = Pmi$

$j=1w(i)$

$= 0$ 일 때 $j \quad (x; \quad(i)) = \quad (x; \quad(i))$, Eq. 30은 다음과 같습니다:

∂^2

(i)

$j \quad (i)$

j

$L(\quad(i), \quad(i), w(i)) = w(i)^2$

$j \in \mathbb{R}, x \in D(X)$

시간

∂^2

(i) (i) ℓ

$\cdots, \quad (x; \quad(i)), \cdots$

$\nabla \quad (x; \quad(i)) \nabla \quad (x; \quad(i))^\top$

나

$+ \text{승}(i)$

$j \in \mathbb{R}, x \in D(X)$

시간

$\partial \quad (i) \ell$

$\cdots, \quad (x; \quad(i)), \cdots$

$$\nabla^2 \quad (x; \quad (i))$$

나

$$= w(i)^2$$

$$j \, T(i)(\quad) + w(i)$$

$$jS(i)(\quad),$$

그리고 방정식. 31은 다음과 같이 단순화할 수 있습니다.

$$\vartheta^2$$

(i)

$$j \quad (i)$$

$$j'$$

$$L(\quad \backslash i), \quad (i), w(i)) = w(i)$$

$$j\text{승}(i)$$

$$j' \in \quad , x \in D(X)$$

시간

$$\vartheta^2$$

$$(i) \quad (i) \, \ell$$

$$\cdots, \quad (x; \quad (i)), \cdots$$

$$\nabla \quad (x; \quad (i)) \nabla \quad (x; \quad (i))^\top$$

나

$$= w(i)$$

$$j\text{승}(i)$$

$$j' \, T(i)(\quad),$$

둘 다 원하는대로.

정리 6. $L(\quad , w)$ 가 $\quad$ 에 대해 제한된 3차 도함수를 갖는다고 가정하면 다음과 같습니다.

$$(L(\quad , w) \quad L(\quad)) =$$

$$nX$$

$$\text{나는}=1$$

$$L(\quad \backslash i), \quad (i), w(i)) \quad L(\quad)$$

$$+ \quad 2$$

$$2$$

$$X$$

$$\text{나는}, \text{나는}' \in [n]$$

$$\text{나는} = \text{나}'$$

$$\mu(i)^\top \vartheta^2$$

$$(i) \quad (i') \, L(\quad) \quad (i') + O(\quad 3),$$

여기서 $L(\quad \backslash i), \quad (i), w(i))$ 및 (i) 는 정리 1에 정의된 바와 같습니다.

증거. 보조 기능을 정의합니다:

$$F(\quad) = (L(\quad , w) \quad L(\quad))$$

$$nX$$

$$\text{나는}=1$$

$$L(\quad \backslash i), \quad (i), w(i)) \quad L(\quad)$$

$F(\cdot)$ 도 유계 3차 도함수를 갖는다는 점에 유의하세요. 따라서 Taylor 전개에 따르면 다음과 같습니다.

$$F(\mathbf{x}) = F(\mathbf{0}) + \mathbf{d}^T \mathbf{x}$$

$$+ \frac{1}{2} \mathbf{x}^T \mathbf{d}^2 \mathbf{x}$$

$$+ \frac{1}{6} \mathbf{x}^T \mathbf{d}^3 \mathbf{x}$$

$$+ O(\|\mathbf{x}\|^4).$$

$$(32)$$

경로 도함수를 통해 F 의 1차 도함수를 계산합니다.

디

$$\mathbf{d}^T (\mathbf{L}(\mathbf{x}, \mathbf{w}) - \mathbf{L}(\mathbf{0})) =$$

$$\mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

그리고 모든 $i \in [n]$ 에 대해:

디

디

$$\mathbf{L}(\mathbf{x}(\mathbf{i}), \mathbf{w}(\mathbf{i}), \mathbf{w}(\mathbf{i})) - \mathbf{L}(\mathbf{0})$$

$$=$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

$$= \mathbf{d}^T \mathbf{L}'(\mathbf{0}) \mathbf{x}$$

제이, (34)

--- 페이지 21 ---

Lemma 4 및 Lemma 5에 따르면, $\vartheta(i)$

$$\sum_j L(\mathbf{v}_i, \mathbf{v}_i, w(i))$$

$$= 0$$

$$= \vartheta(i)$$

$$\sum_j L(\mathbf{v}_i, w)$$

$$= 0$$

, 따라서 Eq. 33 및 34:

$$\frac{d}{dt} F(0) =$$

$n \times$

나는=1

믹스

$j=1$

$\vartheta(i)$

j

$$L(\mathbf{v}_i, w)^\top \mathbf{v}_i$$

j

$n \times$

나는=1

믹스

$j=1$

$\vartheta(i)$

j

$$L(\mathbf{v}_i, \mathbf{v}_i, w(i))^\top \mathbf{v}_i$$

j

$$= 0$$

$$= 0. \quad (35)$$

경로 도함수를 통해 2차 도함수를 계산할 수도 있습니다.

d^2

$$d^2 (L(\mathbf{v}_i, w) - L(\mathbf{v}_i)) = d$$

d

$n \times$

나는=1

믹스

$j=1$

$a(i)$

j

$L(\cdot, w)^T(i)$

j

$=$

$n \times$

$n \times 1$

$n \times$

$n \times 1$

믹스

$j=1$

믹스

$j'=1$

$(i)^T$

$j \neq 2$

(i)

$j(i')$

j'

$L(\cdot, w)$

$d(i')$

j'

디

$=$

$n \times$

$n \times 1$

$n \times$

$n \times 1$

믹스

$j=1$

믹스

$j'=1$

$(i)^T$

$j \neq 2$

(i)

$j(i')$

j'

$L(\cdot, w)(i')$

$j', (36)$

그리고 모든 $i \in [n]$ 에 대해서도 마찬가지로,

d_2

d_2

$L(\langle i \rangle, (i), w(i)) = L(\cdot)$

$=$ 디

디

믹스

$$j=1$$

$$\vartheta \quad (i)$$

$$j$$

$$L(\langle i \rangle, \quad (i), w(i)) \top \quad (i)$$

$$j$$

$$=$$

$$\text{믹스}$$

$$j=1$$

$$\text{믹스}$$

$$j'=1$$

$$(i) \top$$

$$j \vartheta 2$$

$$(i)$$

$$j \quad (i)$$

$$j'$$

$$L(\langle i \rangle, \quad (i), w(i))$$

$$d \quad (i)$$

$$j'$$

$$\text{디}$$

$$=$$

$$\text{믹스}$$

$$j=1$$

$$\text{믹스}$$

$$j'=1$$

$$(i) \top$$

$$j \vartheta 2$$

$$(i)$$

$$j \quad (i)$$

$$j'$$

$$L(\langle i \rangle, \quad (i), w(i)) \quad (i)$$

$$j' \text{ . (37)}$$

$$\text{Lemma 4 및 Lemma 5, } \vartheta 2$$

$$(i)$$

$$j \quad (i)$$

$$j'$$

$$L(\langle i \rangle, \quad (i), w(i))$$

$$=0$$

$$= \vartheta 2$$

$$(i)$$

$$j \quad (i)$$

$$j'$$

$$L(\quad , w)$$

$$=0$$

임의의 $i \in [n]$ 및 j 에 대해 $j' \in [mi]$, 따라서
Eq.의 모든 항을 취소할 수 있습니다. 37 작성자:

d_2

$d_2 F(0) =$

X

$\text{나는, 나는} \in [n]$

믹스

$j=1$

믹스

$j'=1$

$(i)^\top$

$j \neq 2$

(i)

$j = (i')$

j'

$L(\cdot, w) = (i')$

$j' =$

nX

$\text{나는}=1$

믹스

$j=1$

믹스

$j'=1$

$(i)^\top$

$j \neq 2$

(i)

$j = (i)$

j'

$L(\langle i \rangle, (i), w(i)) = (i)$

j'

$=0$

$=$

nX

$\text{나는}=1$

믹스

$j=1$

믹스

$j'=1$

$(i)^\top$

j

$\neq 2$

(i)

$j \quad (i)$
 j'
 $L(\quad , w) \quad \partial^2$
 (i)
 $j \quad (i)$
 j'
 $L(\quad (i), \quad (i), w(i))$

 (i)
 j'

$=0$
 $+$

 X
 $\text{나는} = \text{나}'$
 믹스
 $j=1$
 믹스
 $j'=1$
 $(i)^\top$
 $j \partial^2$
 (i)
 $j \quad (i')$
 j'
 $L(\quad , w) \quad (i')$
 j'

$=0$
 $=$
 X
 $\text{나는} = \text{나}'$
 믹스
 $j=1$
 믹스
 $j'=1$
 $w(i)$
 $jw(i')$
 $j' \quad (i)^\top$
 $j \partial^2$
 (i)
 $j \quad (i')$
 j'

$L(\cdot)(i')$
 j'
 $=$
 $\times$
 $\text{나는} = \text{나}'$
 믹스
 $j=1$
 믹스
 $j'=1$
 $\mu(i) \top \partial 2$
 (i)
 $j(i')$
 j'
 $L(\cdot)(i'), (38)$

여기서 Eq.를 사용합니다. Lemma 4의 마지막 두 번째 동일성은 19이며 다음 사실을 사용합니다. Pmi

$j=1w(i)$
 $j(i)$
 $j = \mu(i)$ 를 사용하여 마지막 값을 얻습니다.
 평등. 방정식을 병합합니다. 32, 35, 38, 원하는 대로 결과를 얻습니다.

--- 페이지 22 ---

정리 7. $L(\cdot, w)$ 가 $\mathcal{E}$ 에 대해 제한된 3차 도함수를 갖는다고 가정하면 다음과 같습니다.

$$L(\cdot)(i), (i), w(i)) \quad L(\cdot) = \partial(i) L(\cdot) \top (i) + \quad 2$$

$$2 \mu(i) \top \partial 2$$

$$(i) (i) L(\cdot) (i)$$

$$+ \quad 2$$

$$2$$

믹스

$$j=1$$

$$w(i)$$

$$j(i) \top$$

$$j S(i)(\cdot) (i)$$

$$j + O(\quad 3).$$

증거. 라고 하자

(나)

$$= \{ (i), \dots, (i) \} \mid$$

(나)

$\mid = \text{미}$. 이것은 i 번째 가우스를 매개변수를 사용하여 m_i 자손으로 분할하는 것입니다.

원래 것과 동일하거나 $= 0$ 으로 둡니다. (i) 를 로 바꾸면

(나)

, 그것은 다음과 같이 주장합니다:

$$L(\cdot)(i),$$

(나)

$$, w(i) = \quad , x \quad D(X)$$

ℓ

$(x; (1)), \dots,$

믹스

$j=1$

$w(i)$

$j \quad (x; (i)), \dots, \quad (x; (n))$

$= \int_{\mathcal{X}} D(X)$

시간

ℓ

$(x; (1)), \dots, \quad (x; (i)), \dots, \quad (x; (n))$

나는

$= L(\quad),$

그리고

$\vartheta(i)$

j

$L(\quad(i),$

(나)

$, w(i) = \vartheta(i)$

j

$L(\quad(i), \quad(i), w(i))$

$=0$

테일러 전개에 의해,

$L(\quad(i), \quad(i), w(i)) \quad L(\quad) = L(\quad(i), \quad(i), w(i)) \quad L(\quad(i),$

(나)

$, \text{승}(i))$

$=$

믹스

$j=1$

$L(\quad(i), \quad(i), w(i))$

$\top$

$=0$

$(\quad(i)$

$j \quad (i))$

$+$

$\times$

$j, j' \in [mi]$

$(\quad(i)$

$j \quad (i)) \top \vartheta(i)$

$j \quad (i)$

$$\begin{aligned}
& j' \\
& L(\langle i \rangle, \langle i \rangle, w(i)) \\
& = 0 \\
& (\langle i \rangle) \\
& j' \langle i \rangle + O(3). \\
& \text{Lemma 5 및 3:} \\
& L(\langle i \rangle, \langle i \rangle, w(i)) = L(\langle \rangle) \\
& = \\
& \text{믹스} \\
& j=1 \\
& w(i) \\
& j \partial \langle i \rangle L(\langle \rangle)^\top \langle i \rangle \\
& j + 2 \\
& 2 \\
& \text{믹스} \\
& j=1 \\
& \langle i \rangle^\top \\
& j
\end{aligned}$$

$$\begin{aligned}
& w(i) \\
& j S(i) \langle \rangle + w(i)^2 \\
& j T(i) \langle \rangle
\end{aligned}$$

$$\begin{aligned}
& \langle i \rangle \\
& j \\
& + 2 \\
& 2 \\
& X \\
& j, j' \in [m], j = j' \\
& w(i) \\
& j \text{승}(i) \\
& j' \langle i \rangle^\top \\
& j T(i) \langle \rangle \langle i \rangle \\
& j' + O(3) \\
& = \\
& \text{믹스} \\
& j=1 \\
& w(i) \\
& j \partial \langle i \rangle L(\langle \rangle)^\top \langle i \rangle \\
& j + 2 \\
& 2 \\
& \text{믹스} \\
& j=1 \\
& w(i) \\
& j \langle i \rangle^\top \\
& j S(i) \langle \rangle \langle i \rangle
\end{aligned}$$

j
 $+ \frac{1}{2}$
 $\frac{1}{2}$
 $\times$
 $j, j' \in [m_i]$
 $w(i)$
 $j_{\text{승}}(i)$
 $j' - (i) \top$
 $j \top (i) (\quad) (i)$
 $j + O(\frac{1}{3})$
 $= \frac{1}{2} (i) L(\quad) \top (i) + \frac{1}{2}$
 $\frac{1}{2}$
 믹스
 $j=1$
 $w(i)$
 $j - (i) \top$
 $j S(i) (\quad) (i)$
 $j + \mu(i) \top$
 $T(i) (\quad) (i) + O(\frac{1}{3})$
 $= \frac{1}{2} (i) L(\quad) \top (i) + \frac{1}{2}$
 $\frac{1}{2} (i) \top$
 $S(i) (\quad) + T(i) (\quad)$

(i)
 $+ \frac{1}{2}$
 $\frac{1}{2}$
 믹스
 $j=1$
 $w(i)$
 j

$(i) \top$
 $j S(i) (\quad) (i)$
 $j - \mu(i) \top S(i) (\quad) (i)$

$+ O(\frac{1}{3})$
 $= \frac{1}{2} (i) L(\quad) \top (i) + \frac{1}{2}$
 $\frac{1}{2} (i) \top$
 $\frac{1}{2}$
 $(i) (i) L(\quad) (i) + \frac{1}{2}$
 $\frac{1}{2}$
 믹스
 $j=1$
 $w(i)$
 j

$(i) \top$

$$\sum_j S(i)(\) (i) \\ \sum_j \mu(i) \top S(i)(\) (i)$$

$$+ O(\ 3).$$

--- 페이지 23 ---

마지막으로 다음을 보여줌으로써 증명을 마무리합니다.

믹스

$$j=1$$

$$w(i)$$

$$j$$

$$\begin{aligned} & (i) \top \\ & \sum_j S(i)(\) (i) \\ & \sum_j \mu(i) \top S(i)(\) (i) \end{aligned}$$

$$=$$

믹스

$$j=1$$

$$w(i)$$

$$j \ (i) \top$$

$$\sum_j S(i)(\) (i)$$

$$\sum_j + \ (i) \top S(i)(\) (i) \ 2$$

믹스

$$j=1$$

$$w(i)$$

$$j \ (i)$$

$$j$$

$$\top$$

$$S(i)(\) (i)$$

$$=$$

믹스

$$j=1$$

$$w(i)$$

$$j$$

$$(\ (i)$$

$$\sum_j \mu(i) \top S(i)(\) (i)$$

$$\sum_j \mu(i))$$

$$=$$

믹스

$$j=1$$

$w(i)$

$j \quad (i)^\top$

$j \, S(i) \quad (i)$

$j.$

C.4. 가우스의 헤세 행렬 도출

초에서, 4.4에서 우리는 SteepGS가 $(x; \quad)$ 에 대한 헤시안 행렬 계산을 필요로 한다는 점을 논의했습니다. 우리는 다음을 만듭니다

단순화: (i) 가장 가파른 하강을 계산할 때 위치 매개변수만 최적화 변수로 간주합니다.

방향. (ii) 다른 변수는 평균 매개변수에 종속성을 가질 수 있지만, 예를 들어 투영 행렬과

뷰 종속 RGB 색상을 사용하면 쉽게 파생되도록 이러한 종속성을 해제합니다. 이제 3D 가우스 포인트가 있다고 가정해 보겠습니다.

매개변수 $\quad = (p, \quad, o)$ 를 사용하면 불투명도 o 와 유사하게 처리할 수 있으므로 RGB 색상을 생략합니다. 아핀을 고려하면 변환 $\quad : p \mapsto Pp + b$, $P \in \mathbb{R}^{2 \times 3}$ 및 $b \in \mathbb{R}^2$, 그러면 $(x; \quad)$ 는 다음과 같이 표현될 수 있습니다.

$$(x; \quad) = o \exp$$

-1

$$2(x \quad Pp \quad b)^\top (P \quad P^\top) \quad 1(x \quad Pp \quad b)$$

$$= o \, N(x; Pp + b, P \quad P^\top).$$

기울기는 다음과 같이 파생될 수 있습니다.

$$\nabla_p \quad (x; \quad) = o \, N(x; Pp + b, P \quad P^\top) \nabla_p$$

-1

$$2(x \quad Pp \quad b)^\top (P \quad P^\top) \quad 1(x \quad Pp \quad b)$$

$$= o \, N(x; Pp + b, P \quad P^\top) P^\top (P \quad P^\top) \quad 1(x \quad Pp \quad b).$$

이제 Hessian 행렬을 다음과 같이 계산할 수 있습니다.

$$\nabla^2$$

$$p \quad (x; \quad) = P^\top (P \quad P^\top) \quad 1(x \quad Pp + b) \nabla_p$$

시간

$$o \, N(x; Pp + b, P \quad P^\top)$$

나 $^\top$

$$o \, N(x; Pp + b, P \quad P^\top) (P \quad P^\top) \quad 1P$$

$$= o \, N(x; Pp + b, P \quad P^\top) P^\top (P \quad P^\top) \quad 1(x \quad Pp \quad b) (x \quad Pp \quad b)^\top (P \quad P^\top) \quad 1P$$

$$o \, N(x; Pp + b, P \quad P^\top) P^\top (P \quad P^\top) \quad 1P$$

$$= \quad (x; \quad)$$

$$P^\top (P \quad P^\top) \quad 1(x \quad Pp \quad b) (x \quad Pp \quad b)^\top (P \quad P^\top) \quad 1P \quad P^\top (P \quad P^\top) \quad 1P$$

원하는대로.

[논문 08] FASR 본문 전체 번역

--- 페이지 1 ---

주파수 적응 선명도 정규화

3D 가우스 스플래팅 일반화 개선을 위한

윤영식

연세대

bbangsik@yonsei.ac.kr

구동준

UNIST

djku1020@unist.ac.kr

어영정

연세대

yj.uh@yonsei.ac.kr

초록

3D Gaussian Splatting(3DGS)이 대부분의 분야에서 탁월함에도 불구하고

구성, 새로운 관점에 대한 일반화가 부족합니다.

이는 몇 번의 샷 시나리오에 과적합되기 때문에

드문 관찰. 우리는 3DGS 최적화를 다시 살펴봅니다.

머신러닝 관점, 새로운 관점 합성 프레이밍

보이지 않는 관점에 대한 일반화 문제로서의 sis

탐구되지 않은 방향. 주파수 적응형을 제안합니다

FASR(선명도 정규화)은

3DGS 훈련 목표를 통해 3DGS가 다음을 수행하도록 안내합니다.

더 나은 일반화 솔루션을 향해 나아가고 있습니다. 비록

선명도 인식 최소화(SAM)도 마찬가지로

일반화를 개선하기 위한 손실 환경의 선명도

분류 모델을 3DGS에 직접 적용

작업 간의 불일치로 인해 차선책입니다.

특히, 이는 고주파수 역해제를 재구성하는 것을 방해합니다.

과도한 정규화로 인해 꼬리가 줄어들면서

강도는 과소한 선명도를 가져옵니다. 주소

이를 위해 이미지의 로컬 주파수를 반영하여

정규화 가중치와 주변 반경

국소 선명도를 추정합니다. 플로터 아트를 방지합니다.

사실을 새로운 관점으로 분석하고 세밀한 세부 사항을 재구성합니다.

SAM은 지나치게 부드러운 경향이 있습니다. 다양한 데이터 세트에 걸쳐

구성을 통해 우리의 방법은 지속적으로 넓은 범위를 개선합니다.

기준선의 범위. 코드는 <https://bbangsik13.github.io/FASR>에서 확인할 수 있습니다.

[//bbangsik13.github.io/FASR](https://bbangsik13.github.io/FASR).

1. 소개

다시점 2D 이미지에서 3D 장면을 재구성하는 것은

오랫동안 관심의 문제였습니다. 3D 가우스

Splatting(3DGS)[23]은 다음에서 사진처럼 사실적인 충실도를 달성합니다.

실시간 렌더링을 통한 새로운 뷰 합성. 그러나,

조밀하게 캡처된 입력 뷰가 필요하며, 이는 비용이 많이 듭니다.

획득. 희소 보기 설정에서는 종종 훈련에 과적합됩니다.

새로운 관점에 대한 일반화가 부적절함

해결되지 않은 세부 사항과 떠다니는 아티팩트가 있습니다. 개선하기 위해

+ 당사 : $.00927 \pm .00002$

+ 당사 : $.03078 \pm .00017$

3DGS: $.00660 \pm .00002$

3DGS: $.03338 \pm .00034$

평균 오류 열차 ↓

평균 오류 테스트 ↓

그림 1. 개요. 우리가 제안한 최적화 알고리즘은 다음과 같습니다.

일반화를 증명합니다. 렌더링된 8개의 훈련 뷰가 주어지면

Blender 합성 데이터세트의 thelegoscene[41], 우리의 방법

보간된 새로운 관점에서 낮은 평균 오류 [44]를 유지합니다.

반면 3DGS는 과적합을 나타냅니다. 플롯은 수단이자 표준이다

10회 이상의 편차.

일반화, 이전 접근 방식은 다양한 채택

깊이로부터 기하학적 사전 통합과 같은 전략

흐름 추정기 [8, 66], 밀집된 상관 관계 활용

spondence 예측 모델 [20]. 비록 이러한 방법은

효율성을 보여주지만 3DGS 최적화는 충분히 이루어지지 않았습니다.

일반화가 가능한 머신러닝 문제로 모색됨

새로운 관점을 갖는 것이 중요하다.

본 논문에서는 최적화 알고리즘을 제안한다.

새로운 관점에서 품질을 향상시키는 3DGS 변형, 즉

일반화(그림 1). 우리의 동기는

손실 환경에서 평평한 최소값을 향한 모델입니다.

더 나은 일반화를 촉진하는 것으로 널리 알려져 있습니다. 마찬가지로-

그림 2에 표시된 것처럼 날카로운 최소값 1은 큰 간격을 나타냅니다.

훈련 손실과 테스트 손실 사이에 있는 반면, 플랫폼 최소값은 많은 양을 보여줍니다.

1간결함을 위해 "로컬"을 생략합니다.

arXiv:2511.17918v1 [cs.CV] 2025년 11월 22일

--- 페이지 2 ---

더 작은 간격은 더 나은 일반화를 나타냅니다. 예를 들어,

플로터는 훈련 보기에서는 보이지 않지만 매우 중요하게 나타납니다.

새로운 관점에서; 즉, 가우스는 열차에 과적합됩니다.

조희수. 이 큰 일반화 격차는 날카로운 의미를 의미합니다.

최소, 즉 약간의 변화에도 손실이 극적으로 변합니다.

모델 매개변수의 섭동2.

선명도 인식 최소화(SAM) [12]

추구한다는 것을 이론적, 경험적으로 보여줍니다.

더 평평한 최소값은 분류의 일반화를 향상시킵니다.

네트워크에서 평평한 최소값을 달성하는 것이 항상 그런 것은 아닙니다.

재구성 작업에서 더 나은 일반화를 보장합니다.

정확한 재구성을 위해서는 선명도가 중요합니다.

지역마다 다릅니다. 특히, 모델 매개변수

본질적으로 고주파 세부 사항(예: 가장자리)을 나타냅니다.

급격한 손실 환경을 유도합니다. 우물의 작은 변화에도 피팅된 가우스는 손실에 급격한 변화를 일으킵니다. 반대로 trast, 저주파 영역을 나타내는 매개변수의 경우, 손실은 보다 점진적으로 변하여 평평한 최소값을 선호합니다. 에서 이런 의미에서 모든 가우시안에 대해 균일한 최소값을 찾는 것은 문제입니다. 레마틱; 고주파수 영역의 선명도가 바람직합니다. 정확한 재구성, 저주파 재에서의 더 평평한 최소값 더 나은 일반화를 위해서는 gions가 바람직합니다. 이를 위해 우리는 주파수 적응형 선명도(Frequency-Adaptive Sharpness)를 제안합니다. 정규화(FASR)는 다음과 같은 최적화 알고리즘입니다. 주변 반경이 모두 로컬 선명도를 결정합니다. 계산에 사용되며 정규화 가중치는 다음과 같습니다. 지역 주파수에 반비례하도록 설정하여 선명도를 유지하면서 더 평평한 손실 환경을 유지합니다. 세부적인 내용이 필요합니다. 향상되었음을 보여드립니다. 우리의 방법은 이전 방법을 보완하므로 전반적인 성능 향상을 제공합니다. 우리의 기여는 다음과 같이 중요합니다:

- 우리가 아는 한, 우리는 첫 번째 재미를 제공합니다.

손실 간의 관계에 대한 근본적인 조사 새로운 관점 합성의 풍경과 일반화.

- 결과적으로 우리는 다음에 대한 최적화 알고리즘을 제안합니다.

주파수 적응형으로 SAM을 재구성하여 3DGS 방식으로 SAM의 한계를 극복했습니다. 고주파수 세부 사항을 매끄럽게 만듭니다.

- 우리의 방법은 광범위한 개선에 다재다능합니다.

다양한 데이터 세트에 대한 기본 방법.

2. 관련 업무

2.1. 스파스 뷰 재구성

매우 희박한 입력으로 장면을 재구성하는 것은 여전히 제한된 감독으로 인해 종종 근본적인 문제가 발생합니다. 2카메라 섭동은 가우스 외부 매개변수로 해석될 수 있습니다. 영원한 섭동, 예를 들어 모든 가우시안의 평행 이동은 다음과 같습니다. 카메라를 움직인다. 3그림은 Keskar et al.에서 재현되었습니다. [24]. 경험적으로 보여진 것처럼 Izmailov et al. [18], 테스트 손실 환경은 다음과 같이 이동하는 경향이 있습니다. 열차 손실 상황, Liu et al. [37]은 손실 환경이 데이터 세트의 불균형 수준에 따라 다릅니다.

균일 최소값

샤프 최소

열차 손실 테스트 손실

작은 일반화 격차

큰 일반화 격차

매개변수

손실

그림 2. 플랫 및 샤프의 개념적 1D 손실 환경

최소3. 플랫 최소값은 날카로운 최소값보다 일반화하는 것이 더 좋습니다.

훈련 뷰에 과대적합된 모델로 인해 결과가 불충분함
보이지 않는 관점의 일반화. 초기 노력은 다음을 추구했습니다.
NeRF(신경 복사 장) [41] 경향을 통합하여
추가적인 정규화 또는 보조 단서. 예를 들어,
이러한 연구[9, 44, 54, 60]는 기하학 또는 깊이를 소개합니다.
완화하기 위한 기반 제약 및 빈도 정규화
최소 뷰 최적화의 제약이 부족한 특성.
이러한 접근 방식은 효율성을 입증하지만
NeRF의 느린 훈련 및 렌더링 프로세스를 계승합니다.
최근 연구에서는 3D Gaussian Splat을 사용하는 것으로 전환되었습니다.
ting (3DGS) [23], 실시간 렌더링 효율성을 목표로 합니다.
이러한 연구[8, 20, 31, 58, 66, 68]는 유사하게 레버리지를 활용합니다.
깊이 [6, 46], 대응 [30]과 같은 내부 사전
또는 흐름 [49], 다른 하나는 앙상블과 같은 레귤레이션에 중점을 둡니다.
일반화 [45, 63, 65]. 우리와 핵심 통찰력을 공유
Sparfels[21] 방법은 최악의 손실을 최소화하는 것을 목표로 합니다.
견고성을 위해; 그러나 가우스를 동결함으로써 그렇게 합니다.
sian은 상한값을 사용하여 목표를 근사화하는 것을 의미합니다.
경계, 이는 색상 분산 정규화로 단순화됩니다.
각 광선을 따라. 이 프록시는 효과적으로 개선되지만
자세한 내용은 색상이 일치하는 플로터를 간과할 수 있습니다. 대조적으로,
우리의 방법은 다시 최악의 손실을 직접 최적화합니다.
모든 가우스 매개변수를 분석하여 이를 날카로운 것으로 해석합니다.
네스 정규화.

중요한 것은 우리의 최적화 알고리즘이 보완된다는 것입니다.
tary: 표현을 변경하거나 사전을 추가하는 대신,
우리는 기본적으로 3DGS가 일반적인 방향으로 수렴하도록 안내합니다.
제한이 적은 최소 감독에서의 솔루션.

2.2. 평탄성과 일반화

손실 환경의 평탄성 사이의 관계
모델 일반화가 광범위하게 조사되었습니다.
사전 연구에서. Keskar et al. [24]는 수렴하는 것을 보여줍니다.
날카로운 최소값은 일반화에 좋지 않은 결과를 가져오는 반면 Jiang은
외. [22]는 선명도가 가장 상관 관계가 있음을 식별합니다.
일반화의 지시자. 후속작 [7, 18] 악마-
훈련 궤적을 따라 매개변수를 평균화한다고 전락했습니다.
더 나은 일반화를 통해 더 평평한 최소값을 얻을 수 있습니다.
평균화 전략을 넘어 Sharpness-Aware Mini-
mization (SAM) [12]은 명시적으로 추정하고 감소시킵니다.
선명도, 영감을 주는 후속 작업 [2, 34, 42, 51]
그 제제를 분석하고 개선합니다. 게다가 일부
작품은 예상 선명도의 정확성을 분석했습니다.
일반화의 척도로. 그 날카로움을 보여주네

--- 페이지 3 ---

매개변수 재조정으로 변경[10], 그리고 적절한

선명도 추정은 다양한 훈련 세션에 따라 다릅니다.
 tups와 작업[3]은 서로의 상관관계를 방해합니다.
 선명도와 일반화. 이에 따라 최근 작품
 정규화 및 불변 공식을 응용 프로그램에 도입합니다.
 선명도를 적절하게 추정하여 보다 안정적인 링크를 가능하게 합니다.
 선명도와 일반화 사이 [16, 19, 26, 28, 53].
 반면에 일부 작품에서는 반례를 보고합니다.
 더 날카로운 모델이 일반화되는 경우가 많아 더 평평하다는 것을 나타냅니다.
 최소값이 항상 일반화를 위한 최적의 전략은 아닙니다.
 tion [4, 10, 56].
 이러한 관점을 바탕으로 우리는 손실 토지를 다시 살펴봅니다.
 재구성 작업의 맥락에서 풍경 선명도.
 우리는 최적의 선명도가 균일하지 않다고 가정합니다.
 그러나 신호의 로컬 주파수에 따라 달라집니다. 더-
 더 나아가, 국부적 선명도를 추정하기 위한 반경은
 지역 주파수에 따라 다릅니다. 따라서 추구하는 대신
 보편적으로 균일한 최소값을 사용하여 주파수를 도입합니다.
 적절하게 정규화하는 적응형 최적화 전략
 재구성 작업을 위한 선명도를 제공하여 날카로운 최소값을 허용합니다.
 고주파 세부 정보에 도움이 되는 곳은 없습니다.

2.3. 섭동을 이용한 재구성

래디언스에 무작위 섭동이 도입되었습니다.
 두 가지 주요 목적을 위한 현장 훈련.
 일반적인 개선을 목표로 하는 우리의 접근 방식과는 달리
 화, 일부 연구에서는 불확실성에 대한 섭동을 사용합니다.
 결정론적 접근법에 의존하기보다는 정량화를 통해
 설교. NeRF의 확률론적 또는 베이지안 공식은 다음과 같습니다.
 명시적으로 모델링된 휘도 또는 밀도 분포 [29,
 48]. 후속 작업으로 인해 훈련된 모델의 추정이 방해받습니다.
 인식론적 불확실성 [15]. 비슷한 아이디어가 예전에도 있었습니다.
 가우시안 매개변수가 샘플링되는 3DGS 경향
 이미지와 보정을 모두 렌더링하기 위해 학습된 분포를 사용합니다.
 브레이티드 불확실성 맵 [1].
 일부 연구[13, 25, 36]는 주입을 통해 견고성을 달성합니다.
 가우스 매개변수 또는 쿼리 위치에 무작위 노이즈를 추가합니다.
 이는 무작위로 선택하는 것으로 해석될 수 있습니다.
 인근 반경의 측정기. 그럼에도 불구하고 이것은 실행되었습니다-
 동 교란은 찾기 위한 비효율적인 프록시 역할을 합니다.
 최악의 손실을 초래하고 예상치 못한 결과가 발생할 수도 있습니다.
 사실(섹션 C에 자세한 내용이 나와 있습니다). 이에 비해 우리의 방법은
 그라디언트 방향을 따라 매개변수를 적대적으로 교란합니다.
 해당 반경 내에서 최악의 손실을 계산합니다.

3. 방법

먼저 SAM [12](Sec. 3.1)에 대한 예비 정보를 제공합니다. 그런 다음,
 SAM을 3DGS에 적용하는 방법을 살펴봅니다(초 3.2). 마지막으로,
 초 3.3은 주파수 적응 선명도 정규성을 나타냅니다.
 화.

3.1. 예비: 선명도 인식 최소화

선명도 인식 최소화(SAM)[12]는 최적화입니다.

격려함으로써 일반화를 향상시키는 방법

손실 환경의 평평한 영역에 있는 솔루션입니다. 함께

매개변수 지점에서 경험적 손실을 최소화하여,

SAM은 다음 지역 내에서 손실 선명도를 추정합니다.

반경 . 그런 다음 최적화는 두 가지를 공동으로 최소화합니다.

경험적 손실과 추정된 선명도:

LSAM

손실 선명도

$z \} \{$

최대

$\|r\|_2 \leq$

$L(w + \eta) - L(w) +$

경험적 손실

$z \} \{$

$\eta(w)$

= 최대

$\|r\|_2 \leq$

$L(w + \eta)$

$\{z\}$

최악의 손실

, (1)

이는 최악의 손실에 해당합니다. 실제로는

손실에 대한 1차 테일러 전개를 통해 근사화됨

현재 매개변수를 중심으로 기능하여 PA를 교란시킵니다.

크기 η 를 갖는 경사 방향의 램미터:

$\eta(w) = \arg \max$

$\|r\|_2 \leq$

$L(w + \eta) - L(w) - \eta \cdot \nabla L(w)$

$\|\nabla L(w)\|_2 \leq$

.(2)

그런 다음 Stochastic을 통해 모델 매개변수웨어가 업데이트되었습니다.

경사 하강법(SGD) [43] 단계, 경사 합성

추정된 지역 최대값 $w + \eta(w)$ 에 적용:

$w \leftarrow w + \eta \cdot \nabla L(w) | w + \eta(w),$

여기서 η 는 학습률입니다. 직관을 지원

그림 2, 이 방법은 강화를 통해 일반화를 향상시킵니다.

다음에서 파생된 선명도를 기반으로 한 일반화 경계

PAC-베이지안 프레임워크 [11, 39, 47]:

정리 1. 데이터에서 훈련 세트 S 를 사용하여 $n > 0$ 인 경우

분포 D ,

$L_D(w) \leq$ 최대

$\|r\|_2 \leq$

$L_S(w + \eta) + h(\|w\|_2$

$2/\epsilon^2)$,

여기서 $h: \mathbb{R}^+ \rightarrow \mathbb{R}^+$ 는 엄격하게 증가하는 함수입니다(아래에서).

$L_D(w)$ 에 대한 일부 기술 조건.

실제로 α 는 하이퍼파라미터입니다.

선명도는 정규화로 해석될 수 있습니다.

WSAM(Weighted SAM) [61]과 같은 용어:

$L_{WSAM} = L(w) +$

$\frac{1}{2} \|\nabla L(w)\|_2^2$ [최대

$\frac{1}{2} \|\nabla L(w)\|_2^2 \leq$

$L(w + \frac{\alpha}{2} \nabla L(w)) - L(w)$

$= \frac{1}{2} \|\nabla L(w)\|_2^2$

$\frac{1}{2} \|\nabla L(w)\|_2^2 +$

최대 $\frac{1}{2} \|\nabla L(w)\|_2^2$

$\frac{1}{2} \|\nabla L(w)\|_2^2 \leq$

$L(w + \frac{\alpha}{2} \nabla L(w))$.

(3)

가중치 하이퍼파라미터 α 가 0으로 설정되면 날카로운-

ness 항은 사라지고 최적화는 em을 최소화합니다.

prical 손실만 발생합니다. $\alpha = 0.5$ 일 때 WSAM은 다음과 같습니다.

SAM(식(1)), $0.5 < \alpha < 1$ 의 경우 선명도 항

--- 페이지 4 ---

알고리즘 13DGS에 SAM 적용

입력: 다중 뷰 이미지 $\{I_v\}$, 여기서 카메라 $v \in V$

출력: 최적화 $G = (\theta, q, s, \sigma, Y_{DC}, Y_{AC})$

1: while Gnot 수렴 do

2: $L \leftarrow \text{Loss}(\text{Render}(G, v), \{I_v\})$ // 손실을 얻습니다.

3: 모든 $\theta \in G_{\text{do}}$ 에 대해

4: $\theta \leftarrow \theta +$

∇L

∇L 에 2

// 상승 단계

5: 끝

6: $G \leftarrow (G \mid \theta \in G)$ // 지역 최대

7: $L \leftarrow \text{Loss}(\text{Render}(G, v), \{I_v\})$ // 손실을 얻습니다.

8: $G \leftarrow G$ 아담(∇G

L) // 하강 단계

9: 끝나다

강조된다. 따라서 확장된 정리 1에서,

최대 $\|\nabla L\|_2 \leq \|\nabla L(w + \frac{\alpha}{2} \nabla L(w))\|_2 = L_{WSAM}$

5가 L_{WSAM} 이 됨

에스, 그리고

기능이 수정되었습니다.

Foret et al. [12] 및 Yue et al. [61] 전체 이론에 대해

rem 진술과 증명.

3.2. 3DGS에 SAM 적용

G_i 를 다음과 같이 정의된 i 번째 가우스라고 하자. $G_i =$

$(\theta_i, q_i, s_i, \sigma_i, Y_{DC}, Y_{AC})$

나, Y_{AC}
 i), 여기서 μ, q, s , 및 Y_{repr} -
평균, 회전, 크기, 불투명도 및 구형 Har-를 보냈습니다.
각각 Y_{DC} 및 Y_{AC} 를 사용하는 모닉스(SH) 계수
SH의 DC 및 AC 조건에 해당합니다.
3DGS [23] 파이프라인과 마찬가지로 3D 가우시안을 렌더링합니다.
 $G = (G_i)N$
카메라 뷰에서 $i=1$ 이고 손실을 계산합니다.
L(알고리즘 1.2). 이 손실의 기울기는 PA를 안내합니다.
rammeter를 로컬 최대값으로 설정합니다(알고리즘 1.3-6). 유사한
그런 다음 SAM 파이프라인에 대한 손실을 평가합니다.
cal 최대값을 사용하고 이 그래디언트를 사용하여 원본을 업데이트합니다.
Adam 옵티마이저[27](알고리즘 1.7-8)를 통한 매개변수.
그러나 이러한 직접적인 적용은 종종 하위 선택으로 이어집니다.
Sec에 표시된 성능 저하. 4.2.1. 클래스와는 달리
sification 작업, 재구성 작업에서는 곡률
풍경은 이미지 빈도와 높은 상관관계가 있습니다.
고주파수 영역의 손실에는 날카로운 최소값이 필요합니다.
정확한 재구성으로 교란에 민감합니다.
반면 저주파 영역에는 평평한 최소값이 필요합니다.
그리고 그들에게 덜 민감합니다. 이런 센세이션의 차이로 인해
sitivity, 고정된 는 문제가 있습니다. 구체적으로, 높은
주파수 영역에서는 부정확한 선명도 추정으로 이어집니다.
큰 1차 근사 오류(Eq.
2). 반대로 저주파 영역에서는 섭동이 발생합니다.
의미가 너무 약해서 개선이 제한됩니다.
샘. 게다가 SAM은 추정된 선명도에 페널티를 줍니다.
고정 정규화 가중치 $= 0.5$. 과한 처벌을 가하는군요
날카롭게 유지되어야 하는 고주파수 영역
세부 사항을 보존하십시오. 동시에, 낮은 수준의 처벌을 과소화합니다.
주파수 영역, 일반적인 개선이 충분히 이루어지지 않음
화.
렌더링된 이미지
GT 이미지축척 지도
손실가우시안당 별도의 선명도(초 3.3.1)
주파수 적응형 섭동 크기(초 3.3.2)
렌더링된 이미지
LossFrequency-adaptivesharpness 가중치(초 3.3.3)
선명도
RGB 손실최종 손실고주파
저주파
약간 동요매우 동요
혼란
업데이트
GT 이미지축척도
그림 3. 제안된 방법의 개요.

주요 가설.이 직관을 바탕으로 우리는 가설을 세웁니다.

각 가우스에 대해 최적의 이웃 반경

정규화 가중치 는 이미지와 상관관계에 따라 달라집니다.

WSAM 확장을 효과적으로 강화하는 주파수

정리 1의 일반화 버전입니다.

3.3. 주파수 적응 선명도 정규화

SAM의 한계를 해결하기 위해 주파수를 도입합니다.

적응형 선명도 정규화(FASR). 그림과 같이

그림 3에서 우리는 먼저 각 가우스의 국부적 선명도를 추정합니다.

sian 속성을 독립적으로 사용합니다(섹션 3.3.1). 그런 다음 조정합니다.

섭동 크기와 정규화 가중치

각 가우스 속성 4(초 3.3.2 및 3.3.3)

viewv에서 미리 계산된 축척 맵 v , 이는 역으로

로컬 주파수에 비례합니다(섹션 E에 자세히 설명되어 있음).

3.3.1. 가우시안별로 별도의 선명도

신경망과 달리 3DGS는 명시적 모델입니다.

각 픽셀의 로컬 주파수를 다음과 연관시킬 수 있습니다.

해당 가우스. 주파수 적응을 적용하려면

ity, 우리는 per-Gaussian에 대한 그래디언트를 계산하는 것으로 시작합니다.

attribute $i \in G$ 전체 매개변수가 아닌 개별적으로

설정합니다. 따라서 알고리즘 1.4는 다음과 같습니다.

$i \leftarrow i +$

∇i_L

∇i_{Lrr2}

.(4)

이 단계는 로컬 샤프를 추정하는 이점이 있습니다.

각 가우스 속성의 특성은 독립적입니다. 구체적으로,

선명도의 1차 근사 오류를 완화합니다.

큰 그래디언트 가우시안에 의한 것입니다.

3.3.2. 주파수 적응 섭동 크기

한 단계 더 나아가서 섭동 크기를 조정합니다.

로컬 이미지 주파수에 따라. 구체적으로,

각 가우시안, 최적 스케일 맵의 값을 쿼리합니다.

2D 카메라의 투영된 중심 좌표(x, y)에

plane, $i \leftarrow v(x, y)$. 이 값은 2D에서 얻어지기 때문에

이미지 공간에서 렌더링된 깊이를 동일하게 곱합니다.

위치, $d_i \leftarrow D v(x, y)$, 초점 거리로 나눕니다.

4우리는 이 적응성을 평균 μ_i , 회전 q_i 및 스케일 i 에 적용합니다.

이는 가우시안의 기하학적 속성입니다.

--- 페이지 5 ---

표 1. 정량적 비교. 우리의 방법은 전반적으로 기준선을 향상시킵니다.

방법 LLFF(3개 보기) MipNeRF-360(12개 보기)

PSNR↑SSIM↑LPIPS↓PSNR↓SSIM↓LPIPS↓

3DGS [ACM ToG'23] 19.810±.339.6790±.0078.2145±.006518.903±.179.5499±.0036.3734±.0042

+ 당사20.783±.300.7197±.0032.1965±.003419.303±.185.5622±.0051.3552±.0047

CoR-GS [ECCV'24] 20.185±.142.7015±.0040.2029±.003519.515±.243.5733±.0049.3741±.0066

+ 당사20.862±.154.7283±.0042.1932±.003019.805±.233.5833±.0058.3681±.0069
 DropGaussian [CVPR'25] 20.461±.212.7070±.0045.2064±.004719.514±.199.5722±.0042.3657±.0036
 + 당사20.853±.227.7295±.0045.1969±.004019.625±.254.5750±.0053.3627±.0051
 NexusGS [CVPR'25] 21.048±.049.7382±.0008.1776±.000918.506±.098.5222±.0031.3587±.0021
 + 당사21.348±.078.7511±.0012.1714±.001118.736±.103.5316±.0034.3522±.0024
 SE-GS [ICCV'25] 20.725±.217.7203±.0049.1861±.005819.931±.288.5930±.0063.3702±.0054
 + 당사21.141±.223.7403±.0042.1803±.003820.135±.232.5960±.0059.3644±.0052

f 를 가우스 평균 μ_i 에 맞게 조정하고 i 를 스케일링하면
 카메라베어에서 더 멀리 위치한 가우시안은
 3D 공간에서 더 강하게 터졌습니다. 그러면 결과값은
 결정하기 위해 미리 정의된 이웃 반경을 곱합니다.
 내 마지막 섭동을 따라서 Eq. (4)
 알고리즘 1.4는 다음과 같습니다.

$$i \leftarrow i + i$$

디

f

∇i_L

∇i_{Lrr2}

.(5)

결과적으로, 섭동 크기는 다음에 적응합니다.

해당 가우스의 주파수. 이 적응-

tion은 샤프의 1차 근사 오류를 완화합니다.

고주파수 영역 및 섭동의 가우스 분포

저주파 영역에서 강하게 나타납니다. 결과적으로, 추정-

선명도가 더 적절하므로 세대가 향상됩니다.

일반화.

3.3.3. 주파수 적응형 선명도 가중치

마지막으로 정규화 가중치를 다음과 같이 조정합니다.

주파수가 정의되는 각 가우스의 주파수

Sec과 동일합니다. 3.3.2. 식에서. (3) 최종 기울기는 다음과 같습니다.

원래 지점에서 그라디언트의 가중치 조합

교란된 지점의 기울기는 다음과 같습니다.

∇i

$L \leftarrow 1 - 2 i$

$1 - i$

$\nabla i_L + i$

$1 - i$

∇i

L.(6)

여기서 $i \leftarrow 0.95 - i / \max$, 여기서 $\max$ 는 최대 가능 값입니다.

LoG 커널의 규모는 0.95로 결정됩니다.

피적으로. 그런 다음 원래 지점에서 매개변수를 업데이트합니다.

이 가중치 그라데이션을 사용합니다(알고리즘 1.8).

결과적으로 선명도 페널티는 높은 영역에서 감소합니다.

주파수 영역을 적용하면서 미세한 디테일을 유지합니다.

저주파 영역에서 더 강한 페널티를 통해 더 나은 결과를 얻을 수 있습니다.

정규화.

4. 실험

데이터 세트. 우리는 LLFF [40]에 대한 방법을 평가하고

MipNeRF-360 [5], 이전 연구 [45, 63, 66,

68], 여기서 입력 해상도는 $8\times$ 다운샘플링되고 3

LLFF 및 MipNeRF-360에 대해 12개의 입력 보기가 분할됩니다.

각각.

구현. 공개적으로 사용 가능한 것을 선택합니다.

3DGS[23]와 그 후속 조치는 기준선으로 작동합니다. 구체적으로-

당연히 우리는 최첨단 NexusGS[66]를 선택했습니다.

기초 모델과 CoR-GS [63], DropGaus를 활용합니다.

sian [45] 및 SE-GS [65]는 그렇지 않습니다.

측정항목. PSNR, SSIM [55] 및 LPIPS [64]를 사용합니다.

LPIPS가 다음과 같이 계산되는 평가 지표로 사용됩니다.

VGG 네트워크 [50]. 또한 평균 오류를 사용합니다.

(A VGE)[44]는 PSNR, SSIM의 기하평균이며,

그리고 LPIPS. 3DGS의 무작위성을 고려하여 우리는

덕트는 LLFF 데이터세트에서 10번 실행되고 LLFF 데이터세트에서 5번 실행됩니다.

MipNeRF-360 데이터 세트.

4.1. 재건 품질

탭에 표시된대로. 1, 우리의 방법은 다음과 같은 면에서 분명한 이득을 얻습니다.

모든 지표, 데이터 세트 및 기준선. 중요한 것은, 이것들은-

아키텍처 변경 없이 증명이 달성됩니다.

또는 추가 사전확률이 있지만 최적화 전략을 사용하는 경우에만 가능합니다.

egy. 그림 4는 시각적 비교를 보여줍니다. 우리의 방법 적용

기하학적인 수정을 통해 지속적으로 기준선을 개선합니다.

새로운 관점에서 부정확성과 떠다니는 아티팩트를 줄입니다.

포인트. 이 결과는 우리가 제안한 최적화가

알고리즘은 현재의 알고리즘과 완벽하게 통합될 수 있습니다.

미래의 3DGS 기반 프레임워크로 보완적 제공

개선.

--- 페이지 6 ---

그림 4. 정성적 비교. 재구성 품질을 비교하려면 빨간색 상자 안의 삽입물을 확대하세요.

4.2. 분석

4.2.1. 절제 연구

SAM[12]을 3DGS에 직접 적용하면 성능이 저하됩니다.

형식. 이 순진한 접근 방식은 가우시안을 크게 교란시킵니다.

그라데이션이 크면 재구성이 흐릿해집니다.

(그림 5, 두 번째 열). 게다가, 그것은 첫 번째를 증가시킵니다.

선명도 추정의 차수 근사 오류, 방해물

SAM의 최적화 과정을 살펴봅니다(표 2, 네 번째 행).

가우시안별로 선명도를 분리하고 각 가우스를 처리합니다.

별도로. 따라서 이 문제를 완화하여 다음과 같은 개선을 가져옵니다.

일부 측정항목(탭 2, 다섯 번째 행)에 포함되어 있지만 결과는

흐릿하게 유지됩니다(그림 5, 세 번째 열). 주파수 적응형

선명도 가중치는 고주파수에서 선명도를 유지합니다.

세부 사항. 한편, 주파수 적응 섭동 magnitude는 적응적으로 조정하여 보다 충실한 추정을 가능하게 합니다. 섭동 규모를 정의합니다. 두 가지 구성 요소 중 하나를 적용하면 개별적으로는 성능 향상을 보여줍니다(표 2, 여섯 번째). 및 일곱 번째 행). 그러나 두 구성 요소 중 하나를 제거하면 성능이 저하됩니다(그림 5, 네 번째 및 다섯 번째 열). 두 가지를 모두 사용하면 더 나은 일반화가 달성되고 균형을 이룰 수 있습니다. 트윈 선명도 감소 및 세부 사항 보존(그림 5, 여섯 번째 열; 탭. 2, 여덟 번째 줄).

4.2.2. 손실 환경 시각화

우리 방법의 수렴 동작을 분석하기 위해 재건축 손실 상황과 그에 따른 결과를 시각화합니다. 최적 최적화 궤적. 우리는 먼저 3DGS를 훈련시킵니다. 5,000번의 반복. 그 후, 우리는 다음을 위한 훈련을 계속합니다. 치밀화 프로세스를 통한 추가 5,000회 반복 3DGS 최적화, SAM 및 우리가 제안한 방법. 시각화를 위해 우리는

고차원 매개변수 궤적을 매개변수가 포함된 주성분 분석을 사용한 2D 평면 두 궤적 모두에서 에테르를 얻습니다.

--- 페이지 7 ---

그림 5. 절제 연구. FAP 및 FAS는 주파수 적응 섭동 크기 및 주파수 적응 선명도 가중치를 나타냅니다. 각각. "3DGS", "SAM" 및 "FAS 및 FAP 없음"은 부정확한 형상을 생성합니다(빨간색 상자). "Ours Full"을 제외한 모든 항목이 흐릿한 결과를 표시합니다. (노란색 상자).

표 2. 절제 연구. 우리는 10개 이상의 평균 결과를 보고합니다. 달린다. 공간 제약으로 인해 표준편차는 생략됩니다. SSG, FAP 및 FAS는 가우스별, 주파수별 별도의 선명도를 나타냅니다. Quency 적응형 섭동 크기 및 주파수 적응형 선명도 가중치. 구성요소 LLFF(3개 보기)

	SAM	SSG	FAP	FAS	PSNR↑	SSIM↑	LPIPS↓
1	19.810	.6790	.2145				
2	20.198	.6958	.2095				
3	20.390	.6977	.2174				
4	20.570	.6980	.2142				
5	20.560	.7116	.2023				
6	20.783	.7197	.1965				

SAM은 3DGS보다 더 평평한 최소값으로 수렴됩니다. 도 6a에서, 로컬 최대값과 최소값 사이의 손실 범위는 다음과 같습니다. $2.37\times$, 측정된 선명도 max 는 $1.49\times$ 더 작습니다. SAM은 또한 3DGS보다 낮은 0.0129의 테스트 손실을 달성합니다. 일반화 격차를 0.0985에서 0.0809로 줄였습니다. 그러나 우리의 방법은 다음보다 덜 평평한 최소값으로 수렴됩니다. 샘. 그림 6b에서 볼 수 있듯이 국부적 손실 범위와 측정값은

확실한 선명도는 1.11배 더 작고 1.01배입니다.
 각각 3DGS보다 작습니다. 흥미롭게도 우리의 방법은
 3DGS보다 낮은 0.0141의 테스트 손실을 달성합니다.
 일반화 격차를 0.0805로 줄여 성능이 뛰어납니다.
 일반화의 SAM.
 이러한 결과는 선명도가 엄격하게 일치하지 않음을 시사합니다.
 일반화와 관련되어 우리의 가설을 뒷받침합니다.
 고주파 픽셀의 선명도가 보존되어야 합니다.
 이는 다음과 같은 우리의 연구 결과(그림 5, 두 번째 열)와 일치합니다.
 SAM은 고주파수 세부 사항에 과도한 페널티를 적용하는 경향이 있습니다.
 결과가 흐릿해집니다.

4.2.3. 공유성 수준에 따른 성능 개선

우리 방법의 개선은 더욱 실질적입니다
 더 적은 수의 훈련 보기가 관찰된 지역에서. 팔로우-
 CoMapGS [20]를 사용하여 우리는 다음을 사용하여 공유 가능성 맵을 계산합니다.
 MAST3R [30]. 탭에 표시된대로. 3, 개선
 기준선 3DGS에 대한 우리의 방법은 점진적으로 증가합니다.
 공동성이 감소하기 때문입니다. 이 행동은 우리의

범위 = $7.1e-5$

범위 = $6.4e-5$

최대 = $2.81e-3$

범위 = $7.1e-5$

최대 = $2.81e-3$

최대 = $2.77e-3$

범위 = $3.0e-5$

최대 = $1.88e-3$

0.0083 0.0888

0.0091 0.0900

(a) 3DGS 대 SAM

(b) 3DGS와 우리의 것

0.0044

0.0044 0.1029

0.1029

그림 6. 손실 환경 시각화. 우리는 변환을 비교합니다.
 3DGS, SAM, Ours의 젠더 행동. 시각화하기 때문에-
 원활한 손실 환경을 생성하고 확대된 데이터를 제공합니다.
 수렴 지점 근처를 봅니다. 우리는 선명도를 다음과 같이 측정합니다.
 헤세 행렬의 최대 고유값 $\max [38, 57]$.

표 3. LLFF 데이터 세트의 공동 가시성 수준별 성능.

우리의 방법은 뷰 희소성이 높을수록 더 큰 개선을 보여줍니다.

공개성 수준 A VGE↓

3DGS + 우리의 것

공동가시성 3 0.0483 ± 0.0093 0.0417 ± 0.0080 -0.0066 ± 0.0043

공동가시성 2 0.0757 ± 0.0156 0.0644 ± 0.0137 -0.0114 ± 0.0067

공동가시성 1 0.0948 ± 0.0256 0.0806 ± 0.0232 -0.0142 ± 0.0074

우리의 방법이 일반화를 향상시킨다는 가설, 특히

일반적으로 제약이 적은 지역에서 발생합니다.

4.3. 신청

4.3.1. FASR의 계산 비용 절감

SAM과 후속 작업의 주요 한계는 다음과 같습니다.
그들은 각 단계에서 손실 기울기를 두 번 계산합니다.
훈련 시간을 2배로 늘립니다. 다행히 신청은
지난 몇 번의 훈련 에포크에 대한 SAM은 성능을 향상시킵니다.
전체 애플리케이션 [67]과 유사합니다. 이 발견을 바탕으로 -
ing, 우리는 전체의 마지막 12.5% 동안 우리의 방법을 적용합니다.
Ours-L로 표시되는 반복입니다. 탭에 표시된대로. 4, 우리 것-

--- 페이지 8 ---

표 4. 후기 훈련 단계에서 FASR 적용 효율적인
훈련, 우리는 이후 반복 중에 우리의 방법을 적용합니다.
우리-L처럼. 우리는 지표(및 3DGS와 관련된 변경 사항)를 보고합니다.
RTX A5000에서 10회 이상 삭제되었습니다. 표준편차
간결함을 위해 설명은 생략되었습니다. 굵은 글씨는 최고의 성능을 나타냅니다.

그리고 밀줄은 두 번째로 좋은 것을 나타냅니다.

방법 LLFF (3 보기)

A VGE↓시간(초)↓

3DGS .111185.7

3DGS + 아워스.0979(-.0132)237.(2.77×)

3DGS + 아워스-L .1016 (-.0095)98.2 (1.15×)

표 5. 온라인 동적 3D 가우스에 FASR 적용. 우리의
이 방법은 시간적 희박성이 있는 동적 시나리오에서 효과적입니다.
특히 mTV를 줄임으로써 시간적 일관성이 향상되었습니다.

방법 신경망 3D 비디오

PSNR↑SSIM↑mTV↓

윤 외. [SIGGRAPH'25] 32.542 .9486 .1109

+ 우리32.622 .9497 .0989

L은 A VGE에서 3DGS를 0.0095 향상시켰습니다.

(0.0037만큼) 전체 우리보다 적습니다. 게다가,

기준 3DGS, 우리의 훈련 시간은 2.77배 증가합니다.

Ours-L은 이를 1.15배만 증가시켜 더욱 효율적으로 만듭니다.

Ours-L의 성능 저하는 다음과 같은 이유로 발생합니다.

3DGS는 학습 가능한 매개변수 수를 적응적으로 조정합니다.

치밀화를 통해 전달됩니다. 이는 신경망과의 주요 차이점입니다.

네트워크. 이로 인해 초기 훈련 반복이 영향력을 가지게 됩니다.

Zhou et al.과는 다른 결과를 이끌어낸다. [67].

4.3.2. 시간적 희소성의 일반화 개선

또한 우리는 방법을 동적 장면으로 확장합니다.

멀티뷰 카메라로 촬영한 Neural 3D Video

데이터 세트 [33]. 구체적으로 우리는 다음과 같은 환경에서 실험을 수행합니다.

라인 구성 [14, 17, 32, 59], 여기서 관측값은 다음과 같습니다.

공간적으로는 조밀하지만 시간적으로는 희박합니다. 즉,

순차적으로 처리된 프레임의 현재 프레임에만 액세스합니다.

비디오 스트림. 우리는 우리의 방법을 Yun et al.에 적용했습니다. [62]

3DGSStream [52] 백본을 사용합니다. 그들의 프로토타입에 따라 col, 우리는 높은 수준의 첫 번째 프레임 3D 가우스를 선택합니다. 초기화를 위한 PSNR을 추정하고 마스크된 총계를 계산합니다. 시간적 일관성을 측정하기 위한 변동(mTV)입니다. 우리의 방법은 시간적 일관성과 시각적인 측면을 향상시킵니다. 기준선과 비교한 품질(표 5) 이는 다음을 보여줍니다. 우리의 접근 방식은 공간적 측면뿐만 아니라 일반화를 향상시킵니다. 영역뿐만 아니라 시간 영역에서도 마찬가지입니다. 게다가 윤 외. [62]는 시간적 지터링의 원인 중 하나가 다음과 같다고 주장합니다. 학습 데이터 세트에 불가피한 노이즈가 있습니다. SAM이 ro-를 보여주기 때문에 시끄러운 훈련 데이터의 흉상, 우리의 발견은 이것과 일치합니다 설명.

그림 7. FreeNeRF와의 정성적 비교. 확대해주세요
재건 품질을 비교하기 위해 빨간색 상자의 삽입물에 표시됩니다.

표 6. FreeNeRF와의 정량적 비교. 우리의 앱-
Proach는 NeRF 기준선을 향상시킵니다.

방법 LLFF (3 보기)

PSNR↑SSIM↑LPIPS↓

FreeNeRF [CVPR'23] 19.523 .6063 .3103

+ 우리 것19.584 .6182 .2983

4.3.3. NeRF에 직관 적용

우리의 방법이 암시적 표현을 위해 직접적으로 설계되지 않았음에도 불구하고 단일 매개변수 때문에 NeRF[41]와 같은 분노

모든 픽셀에 영향을 미치므로 직관을 다음에 적용할 수도 있습니다.

대략적인 절차에서 학습하는 기준선 [36, 60].

구체적으로, 우리는 강한 섭동 크기를 설정하고

NeRF 매개변수가 낮은 값을 학습할 때 정규화 가중치

주파수 성분을 제거하고 이 값을 점차적으로 감소시킵니다.

모델이 고주파수 세부정보를 학습하므로

우리는 이 접근 방식을 FreeNeRF [60] 및 악마에 적용했습니다.

새로운 뷰 동기화에서 시각적 품질을 모두 향상시킨다고 설명합니다.

논문(그림 7)과 정량적 결과(표 6). 비록

NeRF 기준선에 대한 개선은 다음보다 작습니다.

표현의 불일치로 인해 3DGS 기준선에서

분노, 이러한 추가 이득은 여전히 우리의 직관을 뒷받침합니다

다양한 표현에 걸친 다양성.

5. 결론

이 연구에서 우리는 첫 번째 기본 조사를 제시합니다.

손실 환경과 일반화를 소설과 연결하는 방법

뷰 합성을 통해 3D Gaus-의 품질을 향상시킵니다.

sian Splatting [23], 특히 희소 뷰 재구성에서

tion. 우리는 주파수 적응형 샤프니스 레귤러를 제안합니다.

FASR(최적화 알고리즘)은 다음을 다시 공식화하는 최적화 알고리즘입니다.

선명도 인식 최소화(SAM) [12] 주파수-

적응 방식. 이 재구성은 한계를 극복합니다.

재구성 작업에서 SAM을 사용하여 일반화를 달성합니다.

미세한 디테일 재구성도 가능합니다. FASR은 쉽게

다양한 기준선에 걸쳐 적용 가능하며 더 구체적일 수 있습니다.
NeRF 기반 모델과 동적 장면을 주제로 삼았습니다.

거의 희박한 시나리오. 우리는 이 작품이
선명도 사이의 연관성을 탐구하는 연구 커뮤니티
재건 분야의 일반화.

--- 페이지 9 ---

참고자료

- [1] 루카 사반트 아이라(Luca Savant Aira), 디에고 발세시아(Diego Valsesia), 엔리코 마글리(Enrico Magli). 모드-
가우스 스피래팅에 대한 불확실성 제거.IEEE 트랜잭션
신경망 및 학습 시스템, 36(6):11657-
11663, 2025. 3
- [2] 막심 안드리우셴코(Maksym Andriushchenko)와 니콜라스 플라마리온(Nicolas Flammarion). 향해
선명도 인식 최소화를 이해합니다. 진행중-
제39차 머신러닝 국제학술회의 내용 -
ing, 639~668페이지. PMLR, 2022. 2
- [3] 막심 안드리우셴코, 프란체스코 크로체, 막시밀리안
M uller, Matthias Hein, Nicolas Flammarion. 현대적인
선명도와 일반화의 관계를 살펴보세요.
tion. 제40차 국제회의의 진행 중
기계 학습, 840~902페이지. PMLR, 2023. 3
- [4] 막심 안드리우셴코, 프란체스코 크로체, 막시밀리안
M uller, Matthias Hein, Nicolas Flammarion. 현대적인
선명도와 일반화의 관계를 살펴보세요.
tion. 제40차 국제회의의 진행 중
기계 학습, 840~902페이지. PMLR, 2023. 3
- [5] 조나단 T. 배런, 벤 밀든홀, 도르 베르빈, 프라톨 P.
스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한
앤티앨리어싱된 신경 방사 필드. 의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
Recognition(CVPR), 페이지 5470-5479, 2022. 5
- [6] Shariq Farooq Bhat, Reiner Birkel, Diana Wofk, Peter Wonka,
그리고 Matthias M uller. ZoeDepth: COM에 의한 제로샷 전송
비닝 상대 및 미터법 깊이, 2023. 2
- [7] 차준범, 천상혁, 이경재, 한철
조, 박승현, 이윤성, 박성래.
Swad: 균일한 최소값을 찾아 도메인 일반화. 에서
신경 정보 처리 시스템의 발전, 페이지
22405~22418. Curran Associates, Inc., 2021. 2
- [8] Dongrui Dai와 Yuxiang Xing. Eap-gs: 효율적인 증강-
몇 장의 장면에서 3D 가우스 스피래팅을 위한 포인트클라우드 기술
재건축. IEEE/CVF 컨퍼런스 진행 중
컴퓨터 비전 및 패턴 인식(CVPR) 페이지
16498-16507, 2025. 1, 2
- [9] Kangle Deng, Andrew Liu, Jun-Yan Zhu 및 Deva Ra-
마난. 깊이 감독 너프: 보기가 적고 훈련 속도가 빨라집니다.

무료로 합니다. IEEE/CVF 컨퍼런스 진행 중
컴퓨터 비전 및 패턴 인식(CVPR) 페이지
12882-12891, 2022. 2

[10] Laurent Dinh, Razvan Pascanu, Samy Bengio 및 Yoshua
벤지오. 날카로운 최소값은 깊은 망에 대해 일반화할 수 있습니다. 인프로-
제34차 국제기계학회 학술대회 참가
학습, 1019~1028페이지. PMLR, 2017. 3

[11] Gintare Karolina Dziugaite 및 Daniel M. Roy. 컴퓨팅-
깊은(확률론적)에 대한 비공공 일반화 범위 지정
훈련보다 더 많은 매개변수를 가진 신경망
데이터. 유엔에 관한 제33차 연례회의 진행 중
인공지능(UAI)의 확실성, 2017. 3

[12] 피에르 포레, 아리엘 클라이너, 호세인 모바히, 베남
네이샤부르. 효율적으로 선명도를 인식하여 최소화
일반화 개선. 에 관한 국제회의
학습표현, 2021. 2, 3, 4, 6, 8

[13] Qiankun Gao, Jiarui Meng, Chengxiang Wen, Jie Chen 및
장 지안. Hicom: 동적 계층적 일관성 모션
3D 가우스 스피래팅을 사용한 스트리밍 가능한 장면. 에서
신경 정보 처리 시스템의 발전, 페이지
80609~80633. 커란어소시에이츠(Curran Associates, Inc.), 2024. 3

[14] Sharath Girish, Tianye Li, Amrita Mazumdar, Abhinav Shri-
바스타바, David Luebke, Shalini De Mello. 여왕: 관-
스트리밍을 위한 동적 가우스의 효율적인 인코딩
무료 시청 비디오. 신경 정보의 진보
처리 시스템, 페이지 43435-43467. 커란 어소시에이츠,
주식회사, 2024. 8

[15] 릴리 골리, 코디 리딩, 실비아 셀'안, 알렉 제이콥슨,
그리고 안드레아 탈리아사키. 베이즈 광선: 불확실성 측정
신경 복사장에 대한 정보. 다음의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
인정(CVPR), 20061~20070페이지, 2024. 3

[16] Moritz Haas, Jin Xu, Volkan Cevher 및 Leena Chen-
nuru Vankadara. p2: 효과적인 선명도 인식 최소화-
이를 위해서는 계층별 섭동 스케일링이 필요합니다. 사전에
신경 정보 처리 시스템, 38888페이지 -
38959. Curran Associates, Inc., 2024. 3

[17] Qiang Hu, Zihan Zheng, Houqiang Zhong, Sihua Fu, Li
송, 장샤오윤, 자이광타오, 왕옌핑.
4dgc: 효율적인 속도 인식 4d 가우스 압축
스트리밍 가능한 무료 시점 비디오. 의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
Recognition (CVPR), 페이지 875-885, 2025. 8

[18] 파벨 이즈마일로프, 드미트리 포도프리킨, 티무르 가리포프, 드미트리
Vetrov, 앤드루 고든 월슨. 평균 가중치
더 넓은 최적화와 더 나은 일반화로 이어집니다. 진행중-

인공물의 불확실성에 관한 제34차 연례 회의의 내용은 다음과 같습니다.

cial Intelligence (UAI), 2018. 2

[19] 장청재, 이성윤, 프랭크 박, 영균
아노. 재매개변수화 불변 선명도 측정 기반
정보 기하학에 관한 신경 정보의 발전
처리 시스템, 35:27893-27905, 2022. 3

[20] 장영균과 Eduardo P'erez-Pellitero. 회사소개:
희소 소셜에 대한 공개성 맵 기반 가우스 스피래팅
합성을 봅니다. 컴퓨터 비전 회보
및 패턴 인식 회의(CVPR), 26779페이지 -
26788, 2025. 1, 2, 7

[21] Shubhendu Jena, Amine Ouasfi, Mae Younes 및 Adnane
부카이마. 스파펠(Sparfels): 희소한 것에서 빠른 재구성
포즈를 취하지 않은 이미지. IEEE/CVF InProceedings of the IEEE/CVF In-
ICCV(국제 컴퓨터 비전 회의), 페이지
27476~27487, 2025. 2

[22] 이딩 장, 베남 네이샤부르, 호세인 모바히, 딜립
크리슈난, 새미 벤지오. 환상적인 일반화 방법
확실하고 어디서 찾을 수 있는지. 에서국제 컨퍼런스
학습표현에 관하여, 2020. 2

[23] 베른하르트 커블, 게오르기오스 코파나스, 토마스 라임쿠엘러,
그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅
래디언스 필드 렌더링.ACM Trans. 그래프., 42(4), 2023.
1, 2, 4, 5, 8

[24] Nitish Shirish Keskar, Dheevatsa Mudigere, Jorge Nocedal,
미하일 스멜얀스키(Mikhail Smelyanskiy), 핑 탁 피터 탕(Ping Tak Peter Tang). 크게-
딥러닝을 위한 배치 훈련: 일반화 격차 및
날카로운 최소값. InInternational Conference on Learning Rep-
원망, 2017. 2

--- 페이지 10 ---

[25] 샤키바 케라드만드, 다니엘 레베인, 고팔 샤르마, 웨이-
웨이 순, 양체 첵, 호삼 이삭, 아비섹 카르,
안드레아 탈리아사키, 이광무. 3d 가우스 표시
마르코프 체인 몬테카를로처럼요. 신경망의 InAdvances
정보 처리 시스템, 페이지 80965-80986. 현재-
Associates, Inc. 운영, 2024. 3

[26] 김민영, 달리, Shell X Hu, Timothy
호스페달레스. Fisher SAM: 정보 기하학과 날카로운-
네스 인식 최소화. 39차 회의에서
기계 학습에 관한 국제 컨퍼런스, 11148페이지 -
11161. PMLR, 2022. 3

[27] Diederik P. Kingma 및 지미 바. 아담: 방법
확률론적 최적화를 위해. 에 관한 국제회의
학습표현, 2015. 4

[28] 권정민, 김정섭, 박현서,
최권예요. Asam: 적응형 선명도 인식 최소화-

심층 신경망의 규모 불변 학습을 위한 방법입니다. 에서

제38차 Ma-M 국제회의의 진행사항

중국 학습, 5905~5914페이지. PMLR, 2021. 3

[29] 이시백, 강경수, 하성보, 현우

유. 베이지안 너프: 거래량에 따른 불확실성 정량화

신경 암시적 필드의 밀도. IEEE 로봇 공학 및 Au-

Tomation Letters, 10(3):2144-2151, 2025. 3

[30] 빈센트 르로이(Vincent Leroy), 요한 카봉(Yohann Cabon), 제롬 레보(Jerome Revaud). 지상-

mast3r을 사용하여 3D 이미지 매칭을 수행합니다. 인컴퓨터 비전

- ECCV 2024, 페이지 71-91, Cham, 2025. Springer Nature

스위스. 2, 7

[31] Jiahe Li, Jiawei Zhang, Xiao Bai, Jin Zheng, Xin Ning, Jun

저우, 린 구. Dngaussian: 희소 뷰 3D 최적화

글로벌-로컬 깊이 정규화를 통한 가우스 래디언스 필드

tion. IEEE/CVF 통신 회의 진행 중

퓨터 비전 및 패턴 인식(CVPR), 20775페이지 -

20785, 2024. 2

[32] Lingzhi Li, Zhen Shen, Zhongshu Wang, Li Shen 및 Ping

탄. 3D 비디오 합성을 위한 스트리밍 래디언스 필드. ~ 안에

신경 정보 처리 시스템의 발전, 페이지

13485~13498. Curran Associates, Inc., 2022. 8

[33] Tianye Li, Mira Slavcheva, Michael Zollh fer, Simon Green,

크리스토프 라스너, 김창일, 태너 슈미트, 스티븐

러브그로브, 마이클 괴셀, 리차드 뉴컴, 그리고

조양 Lv. 멀티뷰에서 신경망 3D 비디오 합성

비디오. IEEE/CVF 통신 회의 진행 중

퓨터 비전 및 패턴 인식(CVPR), 5521페이지 -

5531, 2022. 8

[34] Tao Li, Pan Zhou, Zhengbao He, Xinwen Cheng 및 Xiaolin

황. 친숙한 선명도 인식 최소화. 진행중-

컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스의 내용과

패턴 인식(CVPR), 페이지 5631-5640, 2024. 2

[35] 토니 린데버그. 일반화의 척도 선택 속성

규모 공간 관심 지점 감지기. Journal of Mathematical

이미징 및 비전, 46(2):177-210, 2013. 13

[36] 셀레나 링, 멀린 니미에-데이비드, 알렉 제이콥슨,

니콜라스 샤프. 신경장에 대한 확률론적 사전 조건화

최적화. ACM Trans. 그래프., 44(4), 2025. 3, 8

[37] Yahao Liu, Qin Wang, Lixin Duan 및 Wen Li. 균형 잡힌

불균형 회귀에 대한 선명도 인식 최소화. 에서

IEEE/CVF 국제 컨퍼런스 진행

컴퓨터 비전(ICCV), 페이지 6242-6251, 2025. 2

[38] Haocheng Luo, Tuan Truong, Tung Pham, Mehrtash Ha-

란디, 딘퐁, 쯡레. 명시적 고유값

정규화는 선명도 인식 최소화를 향상시킵니다. 에서

신경정보에 관한 제38차 연례회의

가공시스템, 2024. 7

[39] 데이비드 A. 맥알레스터. 일부 팩베이즈 정리. 에서

제11차 연례회의의 진행사항

추정 학습 이론, 230-234페이지, 뉴욕, 뉴욕,

미국, 1998. 컴퓨터 기계 협회. 3

[40] 벤 밀든홀, 프라툴 P. 스리니바산, 로드리고 오르티즈-카운,

니마 카데미 칼란타리(Nima Khademi Kalantari), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng)

아비셰크 카르. 국소광장융합:실용적 시각동기화

규범적인 샘플링 지침을 갖춘 논문.ACM Trans.

그래프., 38(4), 2019. 5

[41] 벤 Mildenhall, Pratul P. Srinivasan, Matthew Tancik,

조나단 T. 배런(Jonathan T. Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프:

뷰 동기화를 위해 장면을 신경 방사 필드로 표현

논문. InComputer Vision - ECCV 2020, 페이지 405-421,

참, 2020. 스프링거 국제 출판. 1, 2, 8

[42] 막시밀리안 물러, 티파니 블라르, 데이비드 롤닉,

마티아스 하인. 정규화 레이어는 선명도가 뛰어납니다.

최소화 요구를 인식합니다. 신경 정보의 InAdvances-

처리 시스템, 페이지 69228-69252. 쿠란 아소-

(주)시아테스, 2023. 2

[43] 와이. Nesterov. 볼록 프로그래밍을 해결하는 방법

수렴률 문제 $o(1/k^2)$, 1983. 3

[44] 마이클 니마이어, 조나단 T. 배런, 벤 밀든홀,

메디 S. M. 사자디(Mehdi S. M. Sajjadi), 안드레아스 가이거(Andreas Geiger), 노하 라드완(Noha Radwan)

Regnerf: 뷰 동기화를 위한 신경 복사 필드 정규화

희박한 입력에서 나온 논문. IEEE/CVF 회의록

컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스

(CVPR), 페이지 5480-5490, 2022. 1, 2, 5

[45] 박현우, 류건, 김원준. 드롭가우스-

sian: 희소 뷰 가우스를 위한 구조적 정규화

튀는. IEEE/CVF 컨퍼런스 진행 중

컴퓨터 비전 및 패턴 인식(CVPR), 페이지

21600~21609, 2025. 2, 5

[46] Ren 'e Ranftl, Alexey Bochkovskiy 및 Vladlen Koltun. Vi-

조밀한 예측을 위한 이온 변환기. 다음의 절차에서

IEEE/CVF 컴퓨터 비전 국제 컨퍼런스

(ICCV), 페이지 12179-12188, 2021. 2

[47] 존 쇼테일러(John Shawe-Taylor)와 로버트 C. 윌리엄슨(Robert C. Williamson). 팩 분석-

베이지안 추정자의 누나. 10차 회의록에서

컴퓨터 학습 이론에 관한 연례 회의, 페이지

2-9, 뉴욕, 뉴욕, 미국, 1997. 컴퓨팅 협회

기계. 3

[48] Jianxiong Shen, Adria Ruiz, Antonio Agudo 및 Francesc

모레노노게르. 확률론적 신경 방사 필드: Quanti-

암시적 3D 표현의 불확실성을 해소합니다. 2021년에는

3D Vision(3DV)에 관한 국제 회의, 페이지 972-981,

2021. 3

[49] Xiaoyu Shi, Zhaoyang Huang, Dasong Li, Manyuan Zhang,

Ka Chun Cheung, Simon See, Hongwei Qin, Jifeng Dai 및 리 홍성. Flowformer++: Masked Cost Volume Autoencoder-
광학 흐름 추정을 사전 훈련하기 위한 코딩. 진행중-
컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스의 내용과
패턴 인식(CVPR), 1599~1610페이지, 2023. 2, 13

--- 페이지 11 ---

[50] Karen Simonyan과 Andrew Zisserman. 매우 깊은 대화-
대규모 이미지 인식을 위한 루멘탈 네트워크. 인인-
학습 표현에 관한 국제 회의, 2015.

5

[51] 하오순(Hao Sun), 리셴(Li Shen), Qihuang Zhong, Liang Ding, Shixiang
Chen, Jingwei Sun, Jing Li, Guangzhong Sun 및 Dacheng
타오. Adamasam: 선명도 인식 최소화 강화
심층 신경 학습을 위한 적응형 학습 속도 및 추진력
ral 네트워크. 신경망, 169:506-519, 2024. 2

[52] Jiakai Sun, Han Jiao, Guangyuan Li, Zhanjie Zhang, 레이
자오, 웨이싱. 3dstream: 즉석 교육
사실적인 무료 스트리밍의 효율적인 스트리밍을 위한 3D 가우스
관점 영상. IEEE/CVF 회의 진행 중-
컴퓨터 비전 및 패턴 인식(CVPR)에 대한
페이지 20675-20685, 2024. 8

[53] 츠츠크 유스케, 사토 잇세이, 스기야마 마사시. 그것도 아니고-
Malized Flat Minima: 척도 불변 정의 탐색
pac-bayesian 분석을 사용한 신경망의 평면 최소값
언니. InInternational Conference on Machine Learning, 페이지
9636-9647. PMLR, 2020. 3

[54] Guangcong Wang, Zhaoxi Chen, Chen Change Loy 및 Zi-
웨이 리우. Sparsenerf: 퓨샷을 위한 증류 깊이 순위
새로운 관점 합성. IEEE/CVF InProceedings of the IEEE/CVF In-
ICCV(국제 컴퓨터 비전 회의), 페이지
9065-9076, 2023. 2

[55] Zhou Wang, A.C. Bovik, H.R. Sheikh 및 E.P. 시몬첼리.
이미지 품질 평가: 오류 가시성부터 구조적까지
유사성.IEEE 이미지 처리 트랜잭션, 13(4):
600-612, 2004. 5

[56] Kaiyue Wen, Zhiyuan Li, Tengyu Ma. 선명도 최소
이미화 알고리즘은 선명도를 최소화할 뿐만 아니라
더 나은 일반화를 달성합니다. 신경 정보의 발전-
처리 시스템, 36:1024-1035, 2023. 3

[57] Kaiyue Wen, Tengyu Ma 및 Zhiyuan Li. 얼마나 날카로움-
인식 최소화는 선명도를 최소화합니까? 인더
제11차 학습에 관한 국제회의 대표자-
2023. 7.

[58] Xu Xu, Longguang Wang, Minglin Chen, Sheng Ao, Li

리, 울란 구오. Dropoutgs: 가우스를 삭제합니다.
더 나은 스파스 뷰 렌더링. Com의 진행 과정에서
퓨터 비전 및 패턴 인식 컨퍼런스(CVPR),
701~710페이지, 2025. 2

[59] 진보얀(Jinbo Yan), 평루이(Rui Peng), 왕즈옌(Zhiyan Wang), 루양탕(Luyang Tang), 지아유(Jiayu)
Yang, Jie Liang, Jiahao Wu 및 Ronggang Wang. 인스턴트
가우스 스트림: 빠르고 일반화 가능한 다이 스트리밍
가우스 스플래팅을 통한 나뭇 장면 재구성. 인프로-
컴퓨터 비전에 관한 IEEE/CVF 회의의 결과
및 패턴 인식(CVPR), 페이지 16520-16531, 2025.

8

[60] 양 지아웨이(Jiawei Yang), 마르코 파보네(Marco Pavone), 왕 왕(Yue Wang). Freenerf: 난-
자유 주파수 조정을 통한 퓨샷 신경 렌더링 입증
일반화. IEEE/CVF 컨퍼런스 진행 중
컴퓨터 비전 및 패턴 인식(CVPR) 페이지
8254-8263, 2023. 2, 8

[61] Yun Yue, Jiadi Jiang, Zhiling Ye, Ning Gao, Yongchao Liu,
그리고 커 장. 선명도 인식 최소화 재검토:
정규화 용어로서 가중치 선명도. 진행 중
지식디스에 관한 제29차 ACM SIGKDD 컨퍼런스
표지 및 데이터 마이닝, 3185-3194페이지, New York, NY,
미국, 2023. 컴퓨팅 기계 협회. 3, 4

[62] 윤영식, 배정민, 손현승, 김서하,
이하현, 방건, 어영정. 보상-
온라인 다이에 대한 시공간적으로 일관성이 없는 관찰을 하고 있습니다.
Namic 3D 가우스 스플래팅. 특별 행사 진행 중
컴퓨터 그래픽 및 인터랙티브 기술에 관한 관심 그룹 -
niques Conference Conference Papers, 뉴욕, 뉴욕, 미국,
2025. 컴퓨터기계협회. 8, 13

[63] 장자웨이(Jiawei Zhang), 리자헤(Jiahe Li), 유샤오한(Xiaohan Yu), 황레이(Lei Huang), 린구(Lin Gu), 진(Jin)
정, 샤오바이. Cor-gs: Sparse-view 3d 가우스 스플랫-
공동 정규화를 통해 조정합니다. 인컴퓨터 비전 - ECCV 2024,
페이지 335-352, Cham, 2025. Springer Nature Switzerland.
2, 5

[64] Richard Zhang, Phillip Isola, Alexei A. Efros, Eli Shecht-
남자, 그리고 올리버 왕. 불합리한 효율성
지각 지표로서의 심층 기능. 의 절차에서
컴퓨터 비전 및 패턴 인식에 관한 IEEE 컨퍼런스
tion (CVPR), 2018. 5

[65] Chen Zhao, Xuan Wang, Tong Zhang, Saqib Javed 및
마티유 잘츠만. 자기 양상블 가우스 스플래팅
몇 장의 새로운 뷰 합성. 의 절차에서
IEEE/CVF 컴퓨터 비전 국제 컨퍼런스
(ICCV), 페이지 4940-4950, 2025. 2, 5

[66] Yulong Zheng, Zicheng Jiang, He Shengfeng, Yandu Sun,
Junyu Dong, Huaidong Zhang 및 Yong Du. 넥서스:

3D 가우스에서 에피플라 깊이 사전을 사용한 희소 뷰 합성
시안 스플래팅. 컴퓨터 비전 회보
및 패턴 인식 회의(CVPR), 26800페이지 -
26809, 2025. 1, 2, 5
[67] Zhanpeng Zhou, Mingze Wang, Yuchen Mao, Binrui Li,
그리고 준치 안. 선명도 인식 최소화를 효율적으로 수행
훈련 후반에 더 평평한 최소값을 선택합니다. 13번째 In-
학습 표현에 관한 국제 회의, 2025.
7, 8, 13
[68] Zehao Zhu, Zhiwen Fan, Yifan Jiang 및 Zhangyang Wang.
Fsgs: 가우스를 이용한 실시간 퓨샷 뷰 합성
튀는. InComputer Vision - ECCV 2024, 페이지 145-163,
참, 2025. 스프링거 네이처 스위스. 2, 5

--- 페이지 12 ---
2e-2 5e-2 1e-1 2e-1 5e-1 1e0
섭동 규모
0.10
0.12
0.14AVGE
뜻
평균
± 표준
최고
1e-4 2e-4 5e-4 1e-3 2e-3 5e-3
섭동 규모
0.108
0.110
0.112AVGE
회전
평균
±표준
최고
5e-2 1e-1 2e-1 5e-1 1e0 2e0 5e0
섭동 규모
0.110
0.115AVGE
규모
평균
±표준
최고
2e-6 5e-6 1e-5 2e-5 5e-5 1e-4
섭동 규모
0.108
0.110
0.112AVGE
불투명도

평균

±표준

최고

5e-3 1e-2 2e-2 5e-2 1e-1 2e-1

섭동 규모

0.1075

0.1100

0.1125A VGE

SHDC

평균

±표준

최고

2e-4 5e-4 1e-3 2e-3 5e-3 1e-2

섭동 규모

0.108

0.110

0.112AVGE

SHAC

평균

±표준

최고

그림 8. 각 매개변수가 LLFF 데이터세트에서 개별적으로 교란되는 하이퍼파라미터 그리드 검색. 플롯은 수단이고 10회 실행에 대한 표준 편차. 최고의 하이퍼파라미터 값에 별표를 표시합니다.

A. 하이퍼파라미터 검색

반경 의 최적 이웃 선택, 즉

섭동 규모는 여전히 어려운 문제로 남아 있습니다.

SAM 기반 방법. 우리의 방법은 다음과 같이 확장되지만

로컬 이미지 주파수 자체를 고려한 각 가우스

핵심 하이퍼파라미터로 남아 있습니다. SAM과 유사하게 우리는 먼저

그리드 검색은 섭동에 따른 최적의 섭동 크기를 검색합니다.

그림 8과 같이 각 매개변수를 개별적으로 지정합니다.

모든 매개변수를 동시에 교란할 때 최적의 는

일반적으로 이 값보다 작습니다.

매개변수가 독립적이지 않고 무-

실제로 서로 영향을 미칩니다. 그러므로 우리는 후보자를 선택합니다.

개별적으로 발견된 및 더 작은 값을 포함하며,

그런 다음 동시 섭동으로 그리드 검색을 수행합니다.

최종 하이퍼파라미터를 결정합니다.

B. 각 가우스 아티뷰트의 기여

각 가우스 속성의 기여도를 분석하려면

전반적인 성능을 고려하여 다음 중 하나를 제외하고 방법을 적용합니다.

단일 속성 또는 하나를 제외한 모든 속성에 순차적으로 적용됩니다.

그럼에도 불구하고 모든 속성은 성과에 긍정적으로 기여합니다.

형태에서는 가우스 평균이 지배적인 기여자입니다.

성능 향상(표 7). 이 발견은 다음을 시사합니다.

모든 속성을 동시에 교란하는 대신

가우시안 평균에 대한 우리의 방법은 다음과 같습니다.

단순화된 접근 방식으로 하이퍼파라미터를 크게 줄입니다.

상당한 비중을 유지하면서 검색이 복잡해집니다.

성능 개선에 대한 내용입니다.

C. 무작위 섭동과의 비교

Sec.에서 우리의 주장을 뒷받침합니다. 2.3, 우리는 다음과 같은 내용을 보여줍니다.

가우스 매개변수에 무작위 섭동을 적용하는 협약

훈련 중 터. 도 9에 도시된 바와 같이, 무작위 교란-

표 7. 각 가우시안의 기여도에 대한 절제 연구

속성. 가우스 평균은

성능 개선.

방법 LLFF (3 보기)

PSNR↑SSIM↑LPIPS↓

3DGS + 우리 20.783±.300.7197±.0032.1965±.0034

평균 없음 20.053±.228.6903±.0051.2102±.0040

회전 없음 20.656±.241.7175±.0046.1976±.0040

눈금 없음 20.641±.235.7171±.0049.1987±.0035

불투명도 없음 20.628±.218.7175±.0044.1977±.0033

SHDC 없음 20.594±.242.7152±.0052.1972±.0036

SHAC 없음 20.599±.205.7169±.0041.1973±.0034

평균 20.561±.268.7147±.0046.1975±.0037

회전 포함 19.854±.168.6828±.0029.2110±.0024

스케일 포함 20.036±.222.6871±.0048.2093±.0037

불투명도 포함 19.888±.188.6803±.0045.2124±.0033

SHDC 포함 19.990±.202.6867±.0048.2115±.0034

SHAC 포함 19.914±.186.6827±.0042.2114±.0033

3DGS 19.810±.339.6790±.0078.2145±.0065

종종 예상치 못한 아티팩트가 발생하여 생산량이 더 작아집니다.

우리보다 성능이 향상되었습니다(표 8).

또한, 찾는 것의 중요성을 보여주기 위해

적대적인 섭동에 의한 지역 최대값을 비교합니다.

매개변수를 무작위로 샘플링하는 변형을 사용하는 방법

인근 반경 내에 있습니다. 탭에 표시된대로. 8,

무작위 섭동의 개선은 우리보다 작습니다.

그라디언트 d_i 가 적대적으로 교란됨을 나타냅니다.

효과적인 선명도 정규화를 위해서는 반응이 필수적입니다.

--- 페이지 13 ---

그림 9. 무작위 섭동과

우리의 방법. 무작위 교란은 종종 예상치 못한 결과를 가져옵니다.

유물.

방법 LLFF (3 보기)

PSNR↑SSIM↑LPIPS↓

3DGS 19.810±.339.6790±.0078.2145±.0065

RP 포함 20.174±.207.6987±.0040.2009±.0032

AP 없음 20.263±.289.6990±.0031.2056±.0027

3DGS + 우리 20.783±.300.7197±.0032.1965±.0034

표 8. 무작위 섭동과 섭동의 정량적 비교

적의 혼란. RP와 AP는 무작위 교란을 나타냅니다.

가우스 매개변수 및 적대적 섭동에 대한

적극적으로

D. 후기 적용 분석

우리는 우리의 신청시기에 대한 자세한 연구를 제공합니다

방법. 초에서. 4.3.1, 우리는 Zhou et al. [67], 적용

우리의 방법은 전체 훈련의 마지막 12.5% 동안에만 수행됩니다.

반복. 이를 확장하여 영향을 추가로 분석합니다.

적용 기간을 다양하게 하여 시작점을 정합니다.

총 반복의 10% 증가입니다. 도 10에 도시된 바와 같이,

우리의 방법을 완전히 적용하면 최고의 성능을 얻을 수 있습니다.

적용 단계가 늦어질수록 성능이 저하됩니다.

훈련 과정에서.

E. 로컬 이미지 주파수 추정을 위한 LoG.

입력의 각 픽셀에서 로컬 주파수를 계산합니다.

blob de-에서 영감을 받은 다중 규모 분석을 사용한 이미지

LoG(Laplacian of Gaussian)를 사용한 검출 [35]. 에 대한

회색조 이미지에서 절대 LoG 응답을 계산합니다.

각 후보 척도. 우리는 각 지점에서 최적의 규모를 포착합니다.

픽셀의 응답이 처음으로 크게 증가한 것을 발견합니다.

임계값을 초과하는 곡선. 최적의 규모는

그러한 상승에 앞서 가장 작은 것; 그렇지 않으면 우리는-

최대 후보자 척도에 서명하십시오. 이 프로세스의 결과는 다음과 같습니다.

viewv에서 최적의 스케일 맵 $v \in \mathbb{R}^{H \times W}$, with Hand

W는 각각 이미지의 높이와 너비를 나타냅니다.

로컬 주파수는 선택한 값에 반비례합니다.

0 2000 4000 6000 8000 10000

반복 시작

0.0950

0.0975

0.1000

0.1025

0.1050

0.1075

0.1100AVGE

평균

±표준

최고

그림 10. 적용 단계에 대한 절제 연구. 우리 악마-

응용 프로그램을 변경하여 얻은 성능 향상을 설명합니다.

총 훈련 반복의 10% 단위로 적용 기간

tions.

규모.

F. 구현 세부 사항

3DGS를 제외한 모든 방법에 대해 공식 저장소를 사용합니다.

이토리. 공식 3DGS는 sparse를 타겟으로 하지 않기 때문에

재구성을 보고 CoR을 참조하여 리팩토링합니다.
 GS와 DropGaussian. NexusGS는 광통신을 제공하지 않습니다.
 MipNeRF-360에 대한 흐름; Flow를 사용하여 흐름을 계산합니다.
 이전++ [49]. 기준선이 정규화를 활용하는 경우,
 FASR의 기울기를 계산한 후 역전파합니다.
 변형 과정에 우리의 방법을 적용할 때,
 변형된 가우스에 대한 FASR 기울기를 계산하고
 이를 다시 변형 네트워크로 전파합니다. 업데이트한다
 Yun et al.의 잔차 지도. [62] 상승 단계 중
 그리고 하강 단계 동안의 가우스. 각 데이터 세트에 대해
 다음을 제외하고 모든 기준선에 대해 동일한 및 값을 사용합니다.
 NexusGS에서는 0.1×에 사용된 값으로 설정했습니다.
 더 조밀한 픽셀당 가우스를 사용하기 때문에 다른 기준선이 됩니다.
 G. 추가 결과
 Tab에서 각 장면의 정량적 결과를 보고합니다. 9.
 우리의 방법은 대부분의 경우 기준선보다 성능이 뛰어납니다.

--- 페이지 14 ---

표 9. LLFF 및 MipNeRF-360 데이터세트에 대한 장면별 정량적 결과. 우리는 각 장면의 VGE(낮을수록 좋음)를 보고합니다.
 방법 LLFF (3 보기)

양치류 꽃 요새 뿔 앞 난초 방 trex

3DGS .0950±.01790.1147±.00180.0885±.00390.1276±.00240.1362±.00170.1769±.00190.0753±.00160.074
 9±.00210

+ 당사.0765±.00080.1066±.00140.0781±.00530.1044±.00280.1170±.00130.1605±.00190.0686±.00190.071
 2±.00710

CoR-GS .0806±.00080.1088±.00290.0754±.00160.1205±.00120.1427±.00310.1735±.00200.0723±.00130.06
 99±.00440

+ 당사.0724±.00090.1014±.00220.0683±.00190.1075±.00200.1326±.00240.1603±.00100.0695±.00100.061
 4±.00340

드롭가우스 .0791±.00120.1056±.00210.0796±.00420.1186±.00270.1284±.00190.1650±.00160.0715±.00150.
 0687±.00190

+ 당사.0717±.00100.1048±.00170.0784±.00340.1101±.00340.1176±.00140.1536±.00170.0701±.00200.065
 7±.00260

NexusGS .0893±.00030.0981±.00020.0498±.00030.0909±.00050.1072±.00030.1383±.00060.0755±.00060.0
 810±.00050

+ 당사.0848±.00050.0989±.00060.0475±.00090.0897±.00070.0993±.00060.1354±.00040.0696±.00030.074
 1±.00060

SE-GS .0720±.00040.1052±.00180.0662±.00130.1104±.00180.1392±.00230.1707±.01440.0635±.00220.059
 6±.00180

+ 당사.0675±.00060.0992±.00160.0661±.00820.1028±.00160.1310±.00160.1546±.00170.0629±.00120.056
 4±.00080

방법 MipNeRF-360 (12 보기)

자전거 분재 카운터 정원 부엌 방 그루터기

3DGS .1763±.00400.1408±.00400.1464±.00250.1302±.00190.1052±.00160.1078±.00110.2347±.00280

+ 당사.1714±.00120.1285±.00240.1350±.00110.1240±.00130.1017±.00160.1021±.00460.2253±.00640

CoR-GS .1734±.00340.1262±.00250.1310±.00120.1297±.00370.1054±.00360.0931±.00230.2214±.00770

+ 당사.1733±.00170.1131±.00230.1229±.00060.1287±.00290.1044±.00320.0993±.00440.2073±.00950
드롭가우스 .1646±.00110.1301±.00210.1356±.00140.1243±.00110.0979±.00270.1026±.00500.2187±.00410
+ 당사.1613±.00310.1286±.00070.1309±.00100.1218±.00200.1027±.00210.1003±.00440.2171±.01180
NexusGS .1818±.00100.1308±.00190.1563±.00130.1249±.00030.0941±.00070.1506±.00380.2352±.00240
+ 당사.1739±.00100.1278±.00060.1531±.00160.1243±.00040.0921±.00090.1421±.00450.2299±.00210
SE-GS .1624±.00350.1179±.00300.1251±.00370.1207±.00160.1107±.00370.0875±.00380.2014±.00830
+ 당사.1599±.00690.1105±.00300.1217±.00170.1179±.00250.1092±.00350.0973±.00090.1941±.00480

[논문 09] 3DGS-LM 본문 전체 번역

--- 페이지 1 ---

3DGS-LM: Levenberg-Marquardt를 사용한 더 빠른 가우스 스플래팅 최적화

Lukas Höllein¹ Aljazez Bozic² Michael Zollhöfer² Matthias Nießner¹

¹원현 공과대학 ²Meta

<https://lukashoel.github.io/3DGS-LM/>

300 400 500 600 700 800

시간(초)

21.4

21.6

21.8

22.0

22.2

22.4

22.6PSNR(db)

109s

87년대

53초

3DGS + 우리 것

3DGS

DISTWAR + 우리의 것

디스워

길들이기-3DGS + 우리의 것

길들이기-3DGS

3DGS, 692s, 18.78 PSNR

3DGS+Ours, 692s, 22.10 PSNR

실측 이미지

3DGS, 657s, 21.51 PSNR

3DGS+Ours, 657s, 24.12 PSNR

실측 이미지

그림 1. 우리의 방법은 ADAM 최적화 프로그램을 맞춤형으로 대체하여 3D GS(3D Gaussian Splatting) [23] 재구성을 가속화합니다.

Levenberg-Marquardt. 왼쪽: 동일한 초기화에서 시작하여 우리의 방법이 Tanks&Temples TRAIN 장면에서 더 빠르게 수렴됩니다.

오른쪽: 동일한 시간이 지나면 우리의 방법은 더 높은 품질의 렌더링을 생성합니다(예: 더 나은 밝기 및 대비).

초록

재작업을 가속화하는 새로운 방법인 3DGS-LM을 제시합니다.

대체하여 3D Gaussian Splatter(3DGS) 구축

맞춤형 Levenberg-Marquardt를 갖춘 ADAM 최적화 프로그램

(LM). 기존 방법은 다음을 수행하여 최적화 시간을 단축합니다.

가우시안 수를 늘리거나 품질을 개선하여

미분 가능한 래스터라이저의 구현. 그러나 그들은

Gaussian 매개변수에 맞추기 위해 여전히 ADAM 최적화 프로그램에 의존합니다.

수천 번의 반복을 통해 한 장면을 완성하는 데 시간이 걸릴 수 있습니다.

최대 1시간. 이를 위해 옵티마이저를 다음과 같이 변경합니다.

3DGS 미분변수와 함께 실행되는 LM

래스터라이저. 효율적인 GPU 병렬화를 위해 우리는
 중간 기울기에 대한 데이터 구조 캐싱
 야코비안 벡터 곱을 효율적으로 계산할 수 있는 방법이 없습니다.
 맞춤형 CUDA 커널. 모든 LM 반복에서 우리는 다음을 계산합니다.
 이를 사용하여 여러 이미지 하위 집합의 방향을 업데이트합니다.
 커널을 가중 평균으로 결합합니다. 전반적으로,
 우리의 방법은 원래의 3DGS보다 20% 더 빠르며 관찰은
 동일한 재구성 품질을 유지합니다. 우리의 최적화는
 또한 3DGS를 가속화하는 다른 방법에 대해 불가지론적입니다.
 바닐라 3DGS에 비해 훨씬 더 빠른 속도 향상이 가능합니다.

1. 소개

NVS(Novel View Synthesis)는 다음을 렌더링하는 작업입니다.
 다음과 같이 일련의 이미지가 주어졌을 때 새로운 관점에서 본 장면
 넣어. NVS는 가상 현실 애플리케이션에 사용될 수 있습니다.
 사실적인 물입을 달성하고 자유롭게 탐험할 수 있습니다.
 실제 장면. 이를 용이하게 하기 위해 다양한 3D 장면을 표현합니다.
 기술이 개발되었습니다 [2, 3, 23, 33, 35, 42]. 중
 즉, 3DGS [23] (3D Gaussian-Splatting)은 포인트 기반입니다.
 장면을 3D 세트로 매개변수화하는 표현
 가우스. 실시간 렌더링과 고품질을 제공합니다.
 이미지 합성, 포즈 세트에서 최적화되는 동안
 미분 가능한 래스터라이저를 통한 이미지.
 3DGS는 포즈가 지정된 입력 이미지 세트에서 최적화됩니다.
 현장을 촘촘하게 담아냅니다. 최적화가 필요할 수 있습니다
 고해상도 실제 장면에 수렴하는 데 최대 1시간
 이미지가 많은 데이터 세트 [49]. 다시 하는 것이 바람직하다.
 더 빠른 사용을 가능하게 하는 최적화 런타임을 유도합니다.
 다운스트림 애플리케이션을 위한 재구성. 존재한다-
 방법을 사용하면 최적화를 개선하여 이 런타임을 줄일 수 있습니다.
 다양한 축을 따라 크기 조정. 첫째, 방법은
 타일 기반의 미분 가능한 래스터라이저의 렌더링 속도
 또는 최적화를 위해 특별히 맞춤화된 역방향 패스입니다.
 경사하강법을 이용한 미세화 [12, 15, 32, 48]. 예를 들어
 충분하다, Durvasula et al. [12] 워프 감소를 사용합니다.

1

arXiv:2409.12892v2 [cs.CV] 2025년 8월 21일

--- 페이지 2 ---

렌더링 그라디언트의 더 효율적인 합, Mallick 등
 알. [32]는 역전파를 위해 스플랫 병렬화를 활용합니다.
 둘째, 3DGS에서는 가우시안의 수가 점차 증가합니다.
 최적화 과정에서 성장하는 것을 밀도라고 합니다.
 tion. 최근에는 GS-MCMC[25], Taming-3DGS[32], Mini-
 Splatting [14] 및 Revising-3DGS [5]는 새로운 밀도를 제안합니다.
 필요한 가우스 수를 줄이는 방식
 현장을 대표하는 시안들. 이로써 최적화가 이루어집니다

더 적은 수의 가우시안이 필요하므로 더 안정적이고 더 빠릅니다.
 모든 반복에서 최적화되고 렌더링됩니다.
 이러한 개선에도 불구하고 최적화에는 여전히 시간이 걸립니다.
 수천 번의 경사도 감소가 필요한 상당한 리소스
 수렴하는 향기 반복. 이를 위해 우리는 감소시키는 것을 목표로 합니다.
 기본 최적화를 개선하여 런타임을 개선합니다.
 3DGS 재구성 중입니다. 좀 더 구체적으로 제안하자면
 널리 사용되는 ADAM [26] 최적화 프로그램을
 맞춤형 Levenberg-Marquardt(LM) [34]. LM은 알려진 바에 따르면
 대략적으로 반복 횟수를 대폭 줄입니다.
 정규 방정식을 풀어 2차 업데이트를 수행합니다.
 (표 4). 이를 통해 3DGS 정찰을 가속화할 수 있습니다.
 평균 20% 이상 증가합니다(그림 1 왼쪽). 구체적으로,
 우리는 매우 효율적인 GPU 병렬화 방식을 제안합니다
 선조건 적용 공액 기울기(PCG) 알고리즘의 경우
 각각의 값을 얻기 위해 내부 LM 루프 내에서
 업데이트 방향. 이를 위해 미분변수를 확장합니다.
 계산하는 맞춤형 CUDA 커널을 갖춘 3DGS 래스터라이저
 야코비안 벡터 곱. 우리가 제안한 캐싱 데이터 구조는
 중간 기울기에 대한 실제(그림 3)를 사용하면 다음과 같은 작업을 수행할 수 있습니다.
 데이터 병렬 방식으로 이러한 계산을 빠르고 효율적으로 구성합니다.
 패션. 캐싱을 고해상도 이미지로 확장하기 위해
 데이터 세트를 사용하여 여러 IM에서 업데이트 방향을 계산합니다.
 연령 부분 집합을 추출하고 이를 가중 평균으로 결합합니다. 오버-
 모두 이를 통해 재구성 시간을 20% 향상할 수 있습니다.
 최첨단 3DGS 기준선과 비교하여
 동일한 재구성 품질을 제공합니다(그림 1 오른쪽).
 요약하자면, 우리의 기여는 다음과 같습니다:
 • 우리는 다음을 기반으로 맞춤형 3DGS 최적화를 제안합니다.
 재구성 시간을 향상시키는 Levenberg-Marquardt
 20% 정도 증가했으며 다른 3DGS 가속에는 불가능적입니다.
 방법.
 • 매우 효율적인 GPU 병렬화 방식을 제안합니다.
 맞춤형 CUDA 커널의 3DGS용 PCG 알고리즘
 효율적인 작업을 용이하게 하기 위해 캐싱 데이터 구조를 갖춘 널
 야코비안 벡터 곱.

2. 관련 업무

2.1. 소셜-관-합성

소셜-보기-합성은 최근 몇 년 동안 널리 연구되고 있습니다.
 [2, 3, 19, 23, 33, 35, 42]. NeRF [33]는 높은 광-성능을 달성합니다.
 미분 가능한 볼륨을 통한 사실적인 영상 합성 결과
 미터법 렌더링. 명시적인 표현과 결합되었습니다.
 최적화 런타임을 가속화하는 방법 [7, 16, 35, 41, 47].
 3D 가우스 스피래팅(3DGS)[23]은 이 아이디어를 다음과 같이 확장합니다.
 장면을 3D 가우시안 세트로 표현합니다.
 2D 스피래트로 래스터화된 다음 픽셀 열로 블렌딩됩니다.
 또는. 이 접근 방식은 다음과 같은 능력으로 인해 인기를 얻었습니다.
 고품질 이미지를 실시간으로 렌더링합니다. 창립 이래,

3DGS는 여러 축을 따라 개선되었습니다. 최근 방법 증가하거나 정규화하여 이미지 품질을 향상시킵니다. 프리미티브의 용량 [18, 20, 22, 31, 50]. 기타 증가 렌더링 효율성 [36, 40], 더 나은 표면 재구성을 얻습니다. 지침 [17, 21], 메모리 요구 사항 감소 [37], 대규모 재구성이 가능합니다 [24, 53]. 우리도 비슷해요- 장면 표현으로 3DGS를 채택하고 다음에 중점을 둡니다. 장면별 최적화 런타임을 개선합니다.

2.2. 가우스 스플래팅 최적화 속도 향상

3DGS 장면 재구성을 얻는 것이 더 빨라질 수 있습니다. 여러 가지 방법으로 먹었습니다. 한 줄의 작업으로 숫자가 줄어듭니다. 치밀화 휴리스틱을 변경하여 가우시안의 범위를 확장합니다. [5, 14, 25, 30-32]. 다른 방법은 스퍼스 뷰 검토에 중점을 둡니다. 사전 데이터로 신경망을 구축하고 훈련합니다. 단일 순방향 패스로 가우스를 출력합니다 [6, 8, 9, 13, 29, 46, 54]. 대조적으로, 우리는 밀집된 뷰와 당 뷰에 중점을 둡니다. 장면 최적화 설정, 즉 회소에만 국한되지 않습니다. 재구성을 봅니다. 가장 관련성이 높은 방법은 개선 방법입니다. 기본 미분 가능 래스터의 구현 - izer. [12, 48]에서 경사하강법 역방향 패스는 다음과 같습니다. 워크 감소를 통해 가속되는 반면 [32]는 병렬화 패턴과 [15]는 렌더링을 가속화합니다. 에서 대조적으로, 우리는 경사하강법을 완전히 대체합니다. 새롭고 맞춤형 GPU 병렬을 통해 LM으로 마이징

렐리제이션 계획. 우리는 우리가 호환 가능함을 보여줍니다. 기존 방법을 사용하면 런타임이 더욱 단축됩니다. 옵티마이저를 장면 초기화에 연결하면 됩니다.

2.3. 3D 재구성 작업을 위한 최적화 도구

NeRF 및 3DGS는 일반적으로 Stochas에 최적화되어 있습니다. ADAM과 같은 SGD(tic Gradient Descent) 최적화 프로그램 [26] 수천 번의 반복 동안. 그에 비해 많은 작품이 RGB-D 융합은 Gauss-Newton(또는 Levenberg-Marquardt) 알고리즘은 3D 정찰을 위한 목표를 최적화합니다. 건설 작업 [10, 11, 43, 44, 55, 56]. 그렇게 함으로써 이러한 방법은 크기 순서대로 빠르게 수렴될 수 있습니다. SGD보다 반복 횟수가 적습니다. 이에 동기를 부여하여 우리는 Levenberg를 채택하여 3DGS 최적화를 가속화합니다. Marquardt 알고리즘을 최적화 도구로 사용합니다. Rasmusonet al. [39] 재구성을 위해 Gauss-Newton 알고리즘을 구현했습니다. 조밀한 복셀 그리드를 기반으로 하는 저해상도 NeRF를 사용합니다. 에서 대조적으로, 우리는 명시적인 가우스 프리미티브를 활용합니다. 고효율 야코비안 벡터 곱을 수행하는 3DGS 데이터 병렬 방식으로. 이를 통해 우리는 상태를 달성할 수 있습니다. 최첨단 렌더링 품질과 동시에 상당한 속도 향상 ADAM 기반 방법과 비교하여 최적화됩니다.

--- 페이지 3 ---

SfM 포인트 &
포즈를 취한 이미지
초기화:

3DGS + 아담

미세 조정:

3DGS + 우리 것

초기 3D

가우스

(밀도화)

최종 3D

가우스

(수렴)

정규 방정식을 풀다

이미지 배치에

가중 평균

업데이트 적용

라인 검색

5~10회 반복

그림 2. 방법 개요. 3DGS 최적화를 가속화합니다

두 단계로 구성하여. 먼저 원본 ADAM을 사용합니다.

초기화에 도달하기 위한 최적화 및 밀도화 방식

모든 가우스에 대해. 둘째, Levenberg-Marquardt를 사용합니다.

최적화를 완료하는 알고리즘입니다.

3. 방법

우리의 파이프라인은 그림 2에 시각화되어 있습니다. 먼저,

포즈를 취한 일련의 가우시안을 초기화합니다.

다음을 실행하여 연령과 해당 SfM 포인트 클라우드를 입력으로 사용합니다.

표준 3DGS 최적화(초 3.1). 이 단계에서는

가우스는 치밀화되었지만 수렴되지 않은 상태로 유지됩니다. 이후-

와드에서는 새로운 최적화 도구를 사용하여 최적화를 마무리합니다.

구체적으로, 우리는 목표 제곱합을 다음과 같이 최적화합니다.

Levenberg-Marquardt(LM) [34] 알고리즘(초 3.2),

이는 효율적인 CUDA 커널에서 구현됩니다(Sec. 3.3).

이 2단계 접근 방식은 최적화 작업을 가속화합니다.

1차 최적화 프로그램만 사용하도록 비교되었습니다.

3.1. 가우스 스플래팅 검토

3D Gaussian Splatter(3DGS)[23]는 장면을 세트로 모델링합니다.

3D 가우시안의 각각은 위치에 의해 매개변수화됩니다.

위치, 회전, 크기 조절 및 불투명도. 뷰 의존적

색상은 다음의 구형 고조파 계수로 모델링됩니다.

der 3. 주어진 뷰에서 장면의 이미지를 렌더링하려면-

즉, 모든 가우시안은 먼저 2D 가우스로 투영됩니다.

타일 기반 미분 래스터라이저를 사용하여 표시합니다. 그 후,

픽셀 색상 c 를 얻기 위해 광선을 따라 -블렌딩됩니다.

$c =$

X

$n \in N$

$c_i = i T_i, T_i =$

$i = 1 \dots Y$

$j = 1$

$(1 \dots j) (1)$

여기서 c_i 는 광선을 따라 i 번째 표시의 색상이고, i 는 다음과 같습니다.

2D 가우스를 곱한 값을 평가하여 제공됩니다.

불투명도, T_i 는 투과율입니다. 모든 가우시안 p_a 에 맞게

레이미터 $x \in RM$ 으로 이미지 관찰, 렌더링

ADAM [26] 최적화 프로그램을 사용하면 손실이 최소화됩니다.

$L(x) = 1$

엔

NX

$n = 1$

$(1 |c_i - C_i| + 2(1 - SSIM(c_i, C_i))) (2)$

여기서 $1 = 0.8$, $2 = 0.2$, C_i 는 하나의 실측 진실입니다.

픽셀. 일반적으로 3DGS는 샘플링을 통해 배치 크기 1을 사용합니다.

업데이트 단계마다 임의의 이미지. 가우스는 초기-

SfM 포인트로부터 초기화되고 그 수는 점차적으로 증가합니다.

최적화 전반부 동안 성장했습니다.

치밀화라고 알려져 있다[23].

3.2. 3DGS를 위한 Levenberg-Marquardt 최적화

Gauss 최적화를 위해 LM 알고리즘을 사용합니다.

렌더링 손실을 다음의 합으로 다시 공식화하여

사각형 에너지 함수:

전자(x) =

NX

$n = 1$

π

$1 |c_i - C_i|$

2

$+$

π

$2(1 - SSIM(c_i, C_i))$

2

(3)

두 개의 별도 잔차 r_{ab} 이 있는 경우

$n =$

π

$1 |c_i - C_i|$

그리고 r_{SSIM}

$n =$

π

색상 채널당 $2(1 - SSIM(c_i, C_i))$

각 픽셀. 우리는 각 손실 항의 제곱근을 취하여

방정식을 변환하십시오. (2) LM 알고리즘에 필요한 형식으로 변환합니다.

즉, 동일한 목표를 사용하지만 다른 목표를 사용합니다.

최적화 프로그램. ADAM과 달리 LM 알고리즘에는 다음이 필요합니다.
 모든 업데이트 단계에 대한 대규모 배치 크기(이상적으로는 모든 이미지)
 안정적인 수렴을 달성하기 위해 [34]. 실제로 우리는
 안정적인 업데이트를 보장하기 위해 모든 이미지의 하위 집합이 충분히 큼니다.
 단계(자세한 내용은 섹션 3.3 참조).
 우리 작업의 모든 반복에서 업데이트 방향 얻기
 우리는 모든 업데이트 방향 $\in \text{RM}$ 을 얻는 시간을 정합니다.
 M 가우스 매개변수는 정규 방정식을 풀어서:
 $(J^T J + \text{regdiag}(J^T J)) = J^T F(x)$ (4)
 여기서 $F(x)=[r_{abs}$
 $1, \dots, \text{토끼}$
 N, rSSIM
 $1, \dots, \text{rSSIM}$
 $N] \in \mathbb{R}^{2N}$ 은
 Eq.에 해당하는 잔차 벡터. (3) 그리고 $J \in \mathbb{R}^{2N \times M}$
 대응하는 야코비 행렬.
 일반적인 조밀한 캡처 설정에서 우리는 100만 단위 이상으로 최적화합니다.
 가우시안 사자는 수백 개의 고해상도 이미지를 가지고 있습니다.
 연령 [4, 19, 27]. J가 희소 행렬(각 행
 다음과 같은 가우시안에 대해 0이 아닌 값만 포함합니다.
 해당 픽셀의 색상에 대한 찬사) 따라서 불가능합니다.
 메모리에서 J를 구체화합니다. 대신에 우리는 사전에
 조건부 공액 기울기(PCG) 알고리즘을 사용하여 문제를 해결합니다.
 방정식. (4) 매트릭스가 없는 방식으로. 우리는 맞춤형 PCG를 구현합니다.
 톰 CUDA 커널, Sec. 자세한 내용은 3.3을 참조하세요.
 솔루션을 얻은 후 매개변수 업데이트 적용
 α , 최적의 스케일링 계수 $\in \mathbb{R}$ 을 찾기 위해 선형 검색을 실행합니다.
 가우스 매개변수를 업데이트하려면:
 분

$$E(x_k + \frac{\alpha}{3} \Delta x_k) \quad (5)$$

--- 페이지 4 ---

실제로 우리는 모든 항목의 30% 하위 집합에 대해 라인 검색을 실행합니다.
 에 대한 합리적인 추정치를 얻기에 충분한 이미지,
 하지만 더 적은 수의 렌더링 패스가 필요합니다. 그 후, 업데이트합니다
 가우스 매개변수는 $x_{k+1} = x_k + \alpha \Delta x_k$ 입니다. 유사하다
 CERES [1]에서 LM을 구현하면 규정을 조정합니다.
 다음을 기반으로 매 반복 후의 정렬 강도 $\text{reg} \in \mathbb{R}$
 업데이트 단계의 품질. 구체적으로 계산해 보면

$$= \|F(x)\|^2 - \|F(x + \frac{\alpha}{3} \Delta x_k)\|^2$$

$$\|F(x)\|^2 - \|J \Delta x_k + F(x)\|^2 \quad (6)$$

$$> 1e^{-5}$$
인 경우에만 업데이트를 유지합니다. 이 경우 다시
 정규화 강도를 $\text{reg} *= 1 - (2 - 1)^3$ 으로 추론합니다. 기타-
 그렇지 않으면 업데이트를 되돌리고 reg 를 두 배로 늘립니다.
 3.3. PCG를 위한 효율적인 병렬화 방식

PCG 알고리즘은 최소 제곱에 대한 솔루션을 얻습니다.

방정식의 문제. (4) 여러 번 반복합니다. 우리는 알-

최대 $n_{\text{iters}}=8$ 반복에 대한 gorithm을 구현하고 다음을 사용하여 구현합니다.

맞춤형 CUDA 커널. 이를 알고리즘 1에 요약합니다.

알고리즘 1: 우리는 맞춤형 PCG 알고리즘을 실행합니다.

모든 LM 반복에서 톰 CUDA 커널(파란색).

입력: 가우스 및 카메라 G, F, reg

출력: 업데이트 방향

1 $b, C = \text{buildCache}(G, F) // b = J^T F$

2 $C = \text{sortCacheByGaussians}(C)$

3 $M^{-1} = 1/\text{diag} J^T J(G, C)$

4 $x_0 = M^{-1} b$

5 $u_0 = \text{applyJ}(\text{sortX}(x_0), G, C) // u_0 = J x_0$

6 $g_0 = \text{적용J}(u_0, G, C) // g_0 = J^T u_0$

7 $r_0 = b - (g_0 + \text{reg} M x_0)$

8 $z_0 = M^{-1} r_0$

9 $p_0 = z_0$

10 $i = 0 \sim n_{\text{iters}}$ do

11 $u_i = \text{applyJ}(\text{sortX}(p_i), G, C) // u_i = J p_i$

12 $g_i = \text{적용J}(u_i, G, C) // g_i = J^T u_i$

13 $g_i += \text{reg} M p_i$

14 $p_i = r_i$

난 지

태평양 표준시

나는 기

15 $x_{i+1} = x_i + p_i$

16 $r_{i+1} = r_i - J p_i$

17 $z_{i+1} = M^{-1} r_{i+1}$

18 $p_i =$

R^T

$i+1 z_{i+1}$

R^T

난 지

19 $p_{i+1} = z_{i+1} + p_i$

20 if $\|r_{i+1}\|_2 < 0.01 \|b\|_2$ 이면

21 휴식

22 끝이면

23 종료

24 리턴 x_{i+1}

모든 PCG 반복에서 대부분의 작업이 소비됩니다.

행렬-벡터 곱 $g_i = J^T J p_i$ 를 계산하여 계산합니다. 우리

먼저 $u_i = J p_i$ 를 계산한 다음 $g_i = J^T u_i$ 를 계산하여 계산합니다.

J 의 0이 아닌 값을 계산하려면 역전파가 필요합니다.

-블렌딩을 통해 잔차로부터 게이팅(Eq. (1))

가우스 매개변수에 대한 표시 투영 단계. 는

3DGS[23]의 타일 기반 래스터라이저가 이 계산을 수행합니다.

픽셀당 병렬화를 사용합니다. 즉, 모든 스레드는

하나의 광선을 처리하고 이 모든 표시를 따라 뒤로 물러납니다.
레이 히트. 우리는 이 병렬화가 너무 느리다는 것을 발견했습니다.
효율적인 PCG 구현. 그 이유는 반복 때문이다.
광선 행진: PCG 반복마다 u_i 에 대해 한 번 수행합니다.
그리고 g_i 에 한 번. 결과적으로 동일한 중간체
-혼합 상태(즉, T_s , ∂c

$$\partial$$

$$, \partial c$$

$$\partial c_s$$

모든 표시가 나올 때마다

광선)은 여러 번(최대 18회) 다시 계산됩니다.

캐시 중심 병렬화 우리는 변화를 제안합니다

스플랫당 픽셀당 병렬화(요약:

그림 3). 즉, 하나의 스레드가 하나의 광선의 모든 잔여물을 처리합니다.

한 번에. J 의 각 항목은 잔차의 기울기입니다.

r ($L1$ 또는 $SSIM$ 항 중 하나)을 가우스 매개변수로 변환

x_i . 개념적으로 이는 세 단계로 계산될 수 있습니다.

$$\partial r$$

$$\partial x_i$$

$$= \partial r$$

$$\partial c$$

$$\partial c$$

$$\partial$$

$$\partial$$

$$\partial x_i$$

$$(7)$$

어디 ∂r

∂c 는 잔차에서 렌까지의 기울기를 나타냅니다.

색상, ∂c

∂ 색상에서 투영된 표시까지

$$\partial$$

$$\partial x_i$$

스플랫에서 가우스 매개변수까지. 첫 번째와

방정식의 마지막 요소. (7)은 독립적으로 계산될 수 있습니다

각각의 잔여 및 표시는 각각 효율적입니다.

가상 병렬화. 마찬가지로 ∂c 를 계산할 수 있습니다.

∂ 실제로

계속해서, 우리가 T_s 와 ∂c 에 접근할 수 있다면

$$\partial$$

. 루프 대신-

광선을 따라 모든 스피켓을 여러 번 살펴보고 이를 캐시합니다.

수량은 한 번입니다(그림 3 왼쪽). u_i 나 g_i 를 계산할 때,

그런 다음 캐시에서 이 값을 읽습니다(그림 3 오른쪽). 이 알-

모든 픽셀의 모든 스피켓에 대해 병렬화를 수행하도록 합니다.

런타임을 자동으로 가속화합니다. 캐시 크기가 제어됩니다.

각 PCG 반복에서 처리하는 이미지(광선) 수에 따라

그리고 최종 색상에 기여하는 스플랫 수
 각 광선. 우리는 효율적인 서브샘플링 방식을 제안합니다.
 캐시 크기를 사용 가능한 예산으로 제한합니다.
 3DGS는 구조적 유사성 지수 측정을 사용합니다.
 (SSIM)을 최적화 중 손실 항으로 사용합니다(식(2)). SSIM에서는
 모든 픽셀의 지역적 이웃은 다음과 같이 복잡해집니다.
 최종 픽셀당 점수를 얻기 위한 가우스 커널 [45] 우리
 σ 를 계산하다
 역전파를 통해 SSIM 잔차에 대한 σ
 픽셀당 점수를 중앙 픽셀에 적용합니다(기여도 무시).
 지역 이웃의 다른 픽셀에 적용). 이를 통해
 우리는 광선을 서로 독립적으로 유지하여
 효율적인 병렬화를 위해 우리는 다음과 같이 구현합니다
 Zhao et al.의 파생. [52].
 PCG를 CUDA 커널로 매핑 우리는 모든 그래픽을 캐시합니다.
 디엔트 σ
 σ 는 buildCache 작업을 사용합니다. 팔로우-
 미분 가능한 래스터라이저의 구현을
 3DGS[23]는 픽셀당 병렬화 및 계산을 사용합니다.
 그라디언트 업데이트 $b = \frac{1}{4} \nabla F$ 를 지연시킵니다. 병합된 읽기의 경우
 4

--- 페이지 5 ---

빌드 캐시: 픽셀당 병렬화
 캐시 정렬
 가우시안에 의한
 픽셀
 가우스
 픽셀당 합계
 그라디언트 캐시,
 벡터 값
 가우스 당 /
 픽셀
 읽기 / 쓰기
 작동
 스레드당:
 역전파
 가우스
 속성
 레이
 가우스당 합계
 PCG: 픽셀당 스플랫당 병렬화
 컬러 투 스플랫
 그라데이션
 가우스

그림 3. 병렬화 전략 및 캐싱 방식. 우리는 효율적인 CUDA 커널을 사용하여 PCG 알고리즘을 구현합니다.
 야코비안 벡터 곱을 계산하기 위한 그라디언트 캐시. 왼쪽: PCG가 시작되기 전에 픽셀당 그라디언트 캐시를 생성합니다.

3DGS의 병렬화 [23]. 그런 다음 통합된 읽기 액세스를 보장하기 위해 캐시를 가우시안별로 정렬합니다. 오른쪽: 캐시가 분리됨

광선을 따라 스피켓을 표시하므로 PCG 동안 $u = Jp$ 및 $g = JT u$ 를 계산할 때 스피켓당 픽셀별로 병렬화할 수 있습니다.

쓰기 액세스를 수행하려면 먼저 pix 로 정렬된 캐시를 저장합니다.

els(그림 3 왼쪽). 그 후, Gaussian us 를 기준으로 다시 정렬합니다.

sortCacheByGaussians 커널을 사용합니다. 우리는

Jacobi 선조건자 $M^{-1} = 1/\text{diag}(JT J)$ 및 계산

한 번은 픽셀당 스피켓당 병렬화를 사용했습니다.

diagJTJ 커널. 내부 PCG 루프에는 두 개의 커널이 포함됩니다.

이는 우리의 새로운 병렬화 체계에 의해 가속화됩니다.

먼저 ApplyJ는 $u = Jp$ 를 계산합니다. 이를 다음과 같이 구현합니다.

픽셀당 합계 집계. 이후 JT커널로 신청하세요.

푸테스 $g = JT u$. 이 가우스당 합계는 효율적으로 집계될 수 있습니다.

워프 감소를 사용하여 집계됩니다. 우리는 나머지를 계산합니다

PyTorch에서 직접 알고리즘 1의 벡터-벡터 항을 사용할 수 있습니다[38].

자세한 내용은 보충 자료를 참조하십시오.

이미지 서브샘플링 방식 우리의 캐시는 다음을 추가로 소비합니다.

선택적 GPU 메모리. 밀도가 높은 고해상도 이미지의 경우

재구성 설정, 광선 수 및 캐시

크기가 너무 커질 수 있습니다. 이를 위해 이미지를 분할합니다.

일괄적으로 정규방정식을 독립적으로 풀고,

다음 방정식. (4). 이를 통해 캐시를 다음에 대해서만 저장할 수 있습니다.

한 번에 한 배치씩. 구체적으로 nb 배치의 경우 nb 를 얻습니다.

벡터를 업데이트하고 가중 평균으로 결합합니다.

=

nbX

$na=1$

$M_i = iP_n$

$k=1Mk$

(8)

여기서는 PCG 선조건자의 역함수를 사용합니다.

$M_i = \text{diag}(JT$

$i J_i)$ 를 가중치로 한다. 우리는 유연한

가중치 도출을 위한 정신적 자료. 이것들

가중치는 업데이트 벡터의 중요성 균형을 맞춥니다.

각 가우스 매개변수가 얼마나 많은지에 따라 배치됩니다.

각 이미지의 렌더링된 색상에 기여합니다.

이 서브샘플링 방식을 사용하면 캐시 크기를 제어할 수 있습니다.

배치의 이미지 수에 비례합니다. 실제로 우리는

배치 크기는 25~70개 이미지, 최대 $nb=4$ 배치 선택

LM 반복당. 우리는 무작위로 이미지를 선택하거나

또는 장면이 부드러운 궤적을 따라 캡처된 경우

모든 배치에서 장면 커버리지를 극대화하는 스트라이드 패션.

3.4. 2단계의 3DGS 최적화

우리 파이프라인은 두 번째 단계에서 LM 옵티마이저를 활용합니다.

3DGS 최적화(그림 2 참조). 그 전에 우리는

Gaus-의 초기화를 얻기 위한 ADAM 최적화 프로그램
 시안 매개변수. 이를 LM 운영과 비교합니다.
 얻은 가우스 초기화에 대한 직접 최적화
 SfM 포인트 클라우드([23]에 따름). 그림 4는 다음을 보여줍니다.
 더 나은 초기화된 가우스를 위해 LM이 더 빠르게 수렴합니다.
 결국 순수한 ADAM을 이깁니다. 대조적으로, 그것을 이중으로 실행하면
 바로 SfM 초기화에서는 속도가 느려집니다. 이것은 보여줍니다
 우리와 같은 준2차 솔버는 잘 알려져 있습니다.
 초기화에 더 민감해집니다. 즉, 그라데이션
 하강은 처음에는 빠르게 진행되지만,
 최종 가우스 매개변수로 수렴하는 데 더 많은 시간이 걸립니다. 는
 LM 최적화의 추가 컴퓨팅 오버헤드는 다음과 같습니다.
 특히 더 빨리 수렴하는 데 도움이 됩니다. 이는 동기를 부여합니다
 방법을 두 단계로 나누겠습니다. 또한 이를 통해 우리는 다음과 같은 작업을 수행할 수 있습니다.
 사용하기 전에 가우스의 치밀화를 완료하십시오.
 구현을 단순화하는 LM 최적화 프로그램.

4. 결과

기준선 우리는 LM 최적화 프로그램을 ADAM과 비교합니다.
 3DGS의 여러 참조 구현. 이것은 보여줍니다,
 우리 방법이 다른 런타임 개선 사항과 호환된다는 점
 말. 즉, 옵티마이저를 교체하고
 다른 모든 것을 유지하십시오. 구체적으로 비교해보면
 원본 3DGS [23], 재구현된 "gsplat" [48]
 DISTW AR [12]. 또한 Taming과 비교합니다.
 3DGS[32]는 "예산" 접근 방식을 활용하여
 런타임 측면에서 가장 빠른 기준선. 우리는 모든 기준을 실행합니다
 기본 하이퍼파라미터를 사용하여 30K 반복을 수행합니다.

5

--- 페이지 6 ---

0 200 400 600 800 1000 1200

시간(초)

22시 50분

22.75

23.00

23.25

23시 50분

23.75

24.00

24.25PSNR(db)

디스워

DISTWAR + Ours(8000초기 반복)

DISTWAR + Ours(6000초기 반복)

DISTWAR + Ours(4000초기 반복)

DISTWAR + Ours(2000 초기 반복)

DISTWAR + Ours(초기화 0회)

그림 4. 초기화 반복 비교. 우리의 첫 번째

단계에서는 K iter에 대한 경사하강법을 사용하여 가우스를 초기화합니다.

LM 옵티마이저로 미세 조정하기 전에 $K = 6000$ 이후

또는 $K = 8000$ 반복인 경우, 우리의 방법은 기본 방법보다 빠르게 수렴됩니다.

라인. 반복 횟수가 적을수록 순수 LM은 속도가 느려지므로

우리의 2단계 접근 방식이 중요합니다. 예 보고된 결과

치밀화가 없는 MipNeRF360 [33]의 정원 장면.

데이터 세트/메트릭 우리는 런타임 개선을 벤치마킹했습니다.

세 가지 확립된 데이터 세트에 대한 설명: Tanks&Temples [27],

딥 블렌딩 [19] 및 MipNeRF360 [4]. 이러한 데이터 세트

경계가 있는 실내 및 실외를 포괄하는 총 13개의 장면을 포함합니다.

제한된 실외 환경. 우리는 모든 장면에 모두 적합합니다.

훈련/테스트를 사용하여 동일한 NVIDIA A100 GPU에서 방법

원래 3DGS [23] 간행물에서 제안된 대로 분할됩니다. 받는 사람

재구성의 품질을 측정하고 최고점을 보고합니다.

신호 대 잡음비(PSNR), 구조적 유사성(SSIM),

및 지각 유사성(LPIPS) [51]은 모든 테스트에 걸쳐 평균화되었습니다.

이미지. 또한 최적화 런타임을 보고합니다.

그리고 소비된 GPU 메모리의 최대량.

구현 세부 사항 주요 결과를 위해 다음을 실행합니다.

기본 하이퍼파라미터를 사용한 20K 반복의 첫 번째 단계

각각의 기준선의 에테르. 치밀화는 com-

15,000번의 반복 후에 소모되었습니다. 그 후에는 실행만 하면 됩니다.

수렴할 각각 8개의 PCG 반복을 포함하는 5개의 LM 반복

모든 장면. 이는 최적화 프로그램의 효율성을 보여줍니다.

데이터세트마다 이미지 해상도가 다르기 때문에

우리는 배치 크기와 배치 수를 선택합니다.

캐싱에 사용되는 메모리는 비슷합니다. 25를 선택합니다

MipNeRF360의 경우 4개 배치 이미지 [4], 3개 이미지 25개

딥 블렌딩을 위한 배치[19], 3개의 배치에 70개의 이미지

탱크 및 사원용 [27]. 우리는 값 범위를 제한합니다.

안정적인 업데이트를 위한 reg. Deep에 대해 $[1e^{-4}, 1e^{-2}]$ 에서 정의합니다.

Blending [19] 및 Tanks&Temples [27] 및 그 간격

MipNeRF360 [4]의 경우 $[1e^{-4}, 1e^{-2}]$.

4.1. 기준선과의 비교

우리는 주요 정량적 결과를 Tab으로 보고합니다. 1. 우리 LM

모든 기본 구현에 최적화 프로그램을 추가할 수 있으며

최적화 런타임을 평균 20% 가속화합니다.

재구성은 모든 지표에서 유사한 품질을 보여줍니다.

및 데이터세트를 통해 우리의 방법이 유사한 결과에 도달했음을 강조합니다.

lar 로컬 최소값, 더 빠릅니다. 우리는 또한 장면별로 제공합니다

이러한 결과를 보충 자료로 분석합니다.

평균적으로 우리의 방법은 53GB의 GPU 메모리를 소비합니다.

모든 데이터 세트에서. 대조적으로, 기준선은 추가 항목을 사용하지 않습니다.

캐시가 필요하며 6~11GB의 메모리만 필요합니다. 이

우리 접근 방식의 런타임-메모리 균형을 보여줍니다.

그림 5의 테스트 세트에서 샘플 이미지를 시각화합니다.

실내 및 실외 시나리오 모두, 같은 금액이 지나면
최적화 런타임에서는 우리의 방법이 이미 수렴되었습니다.
반면 기준선은 여전히 더 오래 실행되어야 합니다. 그 결과,
기준선에는 여전히 최적이지 아닌 가우스가 포함되어 있습니다.
렌더링된 이미지에 눈에 보이는 아티팩트가 발생합니다. 비교하면,
렌더링된 이미지는 실제와 더 유사합니다.
더욱 정확한 밝기/대비 및 질감 디테일을 제공합니다.

4.2. 절제

L1/SSIM 목표가 중요합니까? 우리는 같은 것을 활용합니다
원래 3DGS im에서와 같이 LM 최적화 프로그램의 목표
보완, 즉 L1 및 SSIM 손실 조건(식(2)).

LM 에너지 항은 제곱항으로 정의되므로

이러한 손실 항의 제곱근 공식을 ar에 채택합니다.

동일한 목표를 달성합니다(식(3)). 우리는 이것을 비교한다

L2 손실만으로 가우스 피팅을 선택하는 것에 대한 선택,

즉 제곱근을 취할 필요가 없습니다. 구체적으로 우리는

LM의 달성된 품질과 런타임을 다음과 비교하십시오.

L2 손실과 L1 및 SSIM 손실 모두에 대한 ADAM.

탭에서 볼 수 있듯이, 2, 더 빠른 수렴을 달성합니다.

두 경우 모두 비슷한 품질입니다. 그러나 달성된

LM과 ADAM만 사용하면 품질이 떨어집니다.

L2 손실. 이는 L1의 중요성을 강조하며,

SSIM 손실 조건과 이를 우리 방법에 채택한 이유

음. 우리는 보충 자료에서 다음과 같은 계산을 보여줍니다.

더 단순한 L2 잔차 대신 이러한 손실 항을 적용하면

CUDA 커널의 효율성에 부정적인 영향을 미치지 않습니다.

배치당 몇 개의 이미지가 필요합니까? 핵심은-

우리 모델의 매개변수는

배치 및 모든 LM에 대해 선택할 배치 수

(섹션 3.3). 이는 한 반복의 실행 시간을 제어합니다.

우리의 최적화 프로그램이 소비하는 GPU 메모리의 양.

Tab에서 서로 다른 수의 이미지를 비교합니다. 3에

LM it당 단일 배치의 NeRF-합성 [33] 데이터 세트-

즉, $n_b = 1$ 입니다. 전체 데이터세트 사용(이미지 100개)

최고의 결과를 만들어냅니다. IM 수를 줄입니다.

일괄적으로 숙성하면 품질이 약간 나빠질 뿐이지만

또한 더 빠른 수렴을 제공하고 GPU 메모리를 줄입니다.

이미지 40개에 대해 선형적으로 15GB까지 소비됩니다. 이

서브샘플링 이미지가 부정적이지 않음을 보여줍니다.

우리 작업에서 LM 최적화 프로그램의 수렴에 영향을 미칩니다.

우리는 멀티뷰 ADAM보다 나은가요? 우리의 방법은

기준선보다 반복 횟수가 적습니다. 구체적으로 우리는

초기 이후에는 5~10번의 추가 LM 반복만 필요합니다.

--- 페이지 7 ---

방법 MipNeRF-360 [4] 탱크 및 사원 [27] 딥 블렌딩 [19]

SSIM↑ PSNR↑ LPIPS↓ 시간(초) SSIM↑ PSNR↑ LPIPS↓ 시간(초) SSIM↑ PSNR↑ LPIPS↓ 시간(초)

3DGS [23] 0.813 27.40 0.218 1271 0.844 23.68 0.178 736 0.900 29.51 0.247 1222

+ 당사 0.813 27.39 0.221 972 0.845 23.73 0.182 663 0.903 29.72 0.247 951

DISTW AR [12] 0.813 27.42 0.217 966 0.844 23.67 0.178 601 0.899 29.47 0.247 841

+ 당사 0.814 27.42 0.221 764 0.844 23.67 0.183 537 0.902 29.60 0.248 672

gsplat [48] 0.814 27.42 0.217 1064 0.846 23.50 0.179 646 0.904 29.52 0.247 919

+ 당사 0.814 27.42 0.221 818 0.844 23.68 0.183 414 0.902 29.58 0.249 716

길들이기-3DGS [32] 0.793 27.14 0.260 566 0.833 23.76 0.209 366 0.900 29.84 0.274 447

+ 당사 0.791 27.13 0.260 453 0.832 23.72 0.209 310 0.901 29.91 0.275 347

표 1. 우리의 방법과 기준선의 정량적 비교. 기준선에 방법을 추가하면 최적화 시간이 단축됩니다.

동일한 품질을 달성하면서 평균적으로 20% 정도 향상되었습니다. 우리는 우리의 방법을 다른 축과 함께 런타임을 향상시키는 다른 방법과 결합할 수 있습니다.

이는 우리의 방법이 직교 개선을 제공한다는 것을 보여줍니다. 즉, LM 최적화 프로그램을 기존의 많은 방법에 연결할 수 있습니다.

3DGS [23] 814년대 이후 3DGS + 794년대 이후의 Ground-Truth 이미지

Taming-3DGS [32] 328초 이후 Taming-3DGS + 324초 이후의 Ground-Truth 이미지

gsplat [48] 453초 이후 gsplat + 447초 이후 Ground-Truth 이미지

DISTW AR [12] 978년대 이후 DISTW AR + 971년대 이후의 Ground-Truth 이미지

그림 5. 우리의 방법과 기준선의 정성적 비교. 유사한 최적화 시간 후에 렌더링된 테스트 이미지를 비교합니다. 모두 아티팩트가 적고 밝기/대비가 더 정확한 이미지를 표시하는 LM 최적화 프로그램을 사용하면 기준선이 더 빠르게 수렴됩니다.

반면 ADAM은 또 다른 10K 반복을 위해 실행됩니다.

기본 배치 크기(이미지 수)를 늘립니다.

동일한 수의 다중 보기 제약 조건이 적용되는 라인

각 업데이트 단계에 대해 관찰됩니다. 그러나 다음과 같이

탭에서 볼 수 있습니다. 4, 달성된 품질이 더 나쁩니다.

동일한 횟수의 반복 후 ADAM. 달릴 때

더 많은 반복을 위해 ADAM은 결국 유사한 것으로 수렴됩니다.

품질은 좋지만 시간이 더 필요합니다. 이는 효율성을 강조합니다.

우리의 최적화 프로그램: 정규 방정식을 풀기 때문에

방정식. (3) 한 번의 LM 반복으로 더 높은 품질의 업데이트 단계가 생성됩니다.

그래디언트 방향만 사용하는 ADAM보다

4.3. 런타임 분석

우리는 여러 환경에 걸쳐 LM 최적화 프로그램의 런타임을 분석합니다.

그림 6의 여러 반복. 런타임은 해결 방법에 의해 지배됩니다.

Eq. (4) PCG를 사용하여 캐시를 구축합니다(초 3.3).

캐시 정렬, 선택한 이미지 렌더링 및

라인 검색(Eq. (5))은 비교적 빠릅니다. PCG 중에는

applyJ와 applyJT 커널을 최대 9번 실행합니다.

스플랫당 픽셀당 병렬화. 그에 비해 우리는

buildCache 커널을 한 번, 픽셀당 병렬화합니다.

약간만 더 빠릅니다. 이는 우리 회사의 장점을 보여줍니다.

7

--- 페이지 8 ---

방법 SSIM↑ PSNR↑ LPIPS↓ 시간(초)

3DGS [23] (L1/SSIM) 0.862 27.23 0.108 1573

3DGS + 당사(L1/SSIM) 0.863 27.29 0.110 1175

3DGS [23] (L2) 0.854 27.31 0.117 1528

3DGS + 우리 것 (L2) 0.857 27.48 0.114 1131

표 2. 목적의 절제. L1/SSIM을 사용하여 비교합니다.

L2 손실에 대한 손실. 두 가지 모두에 대해 3DGS[23]는 다음과 같이 최적화되었습니다.

ADAM과 우리의 결합으로 우리는

L1/SSIM 목표. 두 경우 모두 우리의 방법은 분석을 가속화합니다.

융합. MipNeRF360[4]의 GARDEN 장면 결과.

배치 크기 SSIM↑ PSNR↑ LPIPS↓ 시간(초) 메모리(Gb)

100 0.969 33.77 0.030 242 32.5

80 0.969 33.73 0.031 233 29.8

60 0.968 33.69 0.031 223 22.6

40 0.967 33.51 0.032 212 15.4

표 3. 배치 크기 제거. LM당 더 적은 수의 이미지 선택

반복은 런타임을 줄이고 GPU 메모리 소비를 줄입니다.

품질에 약간 영향을 미칩니다. 이는 이미지 하위 샘플링을 보여줍니다.

pling(Sec. 3.3)은 우리 작업에서 LM과 호환됩니다. 결과 ob-
3DGS[23] 및 nb=1로 초기화한 후 유지됩니다.

2 4 6 8 10

LM 반복

0

5

10

15

20

25시간(초)

PCG

캐시 구축

캐시 정렬

라인 검색

이미지 렌더링

그림 6. 런타임 분석. LM 최적화 프로그램의 한 번의 반복

PCG를 해결하고 캐시를 구축하는 것이 지배적입니다. 측정됨

치밀화 후 Mip-NeRF360 [4]의 GARDEN 장면.

제안된 병렬화 방식: 동일한 야코비안 벡터

제품이 훨씬 빠르게 실행됩니다. 우리는 또한 자세한 프로필을 제공합니다.

보충 자료에서 커널 분석을 수행합니다.

4.4. 제한 사항

ADAM을 LM 방식으로 대체함으로써 우리는

3DGS 수렴 속도는 모두 평균 20% 향상됩니다.

데이터 세트 및 기준선. 그러나 몇 가지 단점이 남아 있습니다.

첫째, 우리의 접근 방식은 기본 메모리보다 더 많은 GPU 메모리가 필요합니다.

그래디언트 캐시(초 3.3)로 인해 발생합니다. 에 따라

이미지의 수와 해상도에 따라 광고가 필요할 수 있습니다.

방법 반복 배치 크기 시간(초) PSNR ↑

3DGS [23] 10,000 1 1222 29.51
 3DGS [23] 50 75 962 29.54
 3DGS [23] 130 75 1193 29.68
 + 우리 5 75 951 29.72
 DISTW AR [12] 10,000 1 841 29.47
 DISTW AR [12] 50 75 681 29.49
 DISTW AR [12] 130 75 814 29.58
 + 우리 5 75 672 29.60
 gsplat [48] 10,000 1 919 29.52
 gsplat [48] 50 75 724 29.53
 gsplat [48] 130 75 892 29.56
 + 우리 5 75 716 29.58
 길들이기-3DGS [32] 10,000 1 447 29.84
 길들이기-3DGS [32] 50 75 328 29.86
 길들이기-3DGS [32] 130 75 391 29.91
 + 우리 5 75 347 29.91

표 4. 다중 뷰 제약 분석 우리는 더 높은 것을 얻습니다
 LM 최적화의 품질 업데이트 단계가 더 적어서 필요하지 않음
 수렴하는 반복. 일괄적으로 동일한 수의 이미지를 사용하여
 ADAM을 사용하는 기준선에는 여전히 더 많은 반복과 런타임이 필요합니다.
 비슷한 품질에 도달합니다. 결과는 DeepBlending[19]에서 평균화되었습니다.
 우리의 방법을 실행하기 위해 캐시 부분의 추가 CPU 오프로드
 더 작은 GPU. Mallick et al. [32] 다음과 같이 할 수 있다.
 그런 다음 기울기 ∂c 를 저장하여 캐시 크기를 줄입니다.

만

광선을 따라 32번째 스피랫마다 -블렌딩을 다시 수행
 이 로컬 창에서. 둘째, 우리의 2단계 접근 방식은
 치밀화는 ADAM에 달려 있습니다. 3DGS [23]는 밀도를 높입니다.
 가우스는 최대 140배까지 가능하며 쉽게 전송할 수 없습니다.
 5-10 LM 반복으로 세분화됩니다. 대신에 하나
 최근 대안을 탐색하고 통합할 수 있습니다[5, 25, 30].

5. 결론

속도를 높이는 방법인 3DGS-LM을 제시했습니다.
 3D Gaussian-Splatting [23]을 대체하여 재구성
 맞춤형 Levenberg-Marquardt를 사용한 ADAM 최적화 프로그램
 (LM) (섹션 3.2). 우리는 데이터 병렬화를 통해 이를 보여줍니다.
 우리는 정규 방정식을 효율적으로 풀 수 있는 방식을 사용합니다.
 사용자 정의 CUDA 커널의 PCG(초 3.3)에서 근무
 2단계 접근 방식(섹션 3.4), 이는 20% 런타임으로 이어집니다.
 기준선 대비 가속도. 우리는 추가로 시연합니다
 우리의 접근 방식은 다른 방법에 불가지론적입니다 [12, 32, 48],
 이는 최적화 런타임을 더욱 향상시킵니다. 즉, 우리는
 우리가 제안한 최적화 프로그램을 더 빠른 최적화 도구와 쉽게 결합할 수 있습니다.
 3DGS 방법. 전반적으로 우리는 더 빠른 능력이 있다고 믿습니다.
 우리의 방법을 사용한 3DGS 재구성은 더욱 발전할 것입니다
 [28]과 같은 연구 방법을 사용하여 3DGS를 더욱 실용적으로 만듭니다.
 다양한 실제 응용 프로그램에 걸쳐.

8

--- 페이지 9 ---

6. 감사의 말씀

이 프로젝트는 Meta 후원 연구의 자금을 지원받았습니다.

합의. 또한, 해당 프로젝트는 다음과 같은 지원을 받았습니다.

ERC 시작 보조금 Scan2CAD(804724)도

독일연구재단(DFG) 연구

단원 "비주얼 컴퓨팅의 학습 및 시뮬레이션".

유용한 토론을 해주신 Justin Johnson에게 감사드립니다.

비슷한 방향의 이전 프로젝트에서 Peter는

이미지 하위 샘플에 대한 유용한 토론을 위한 Kocsis

플링. 또한 영상 음성 해설을 해주신 Angela Dai에게도 감사드립니다.

참고자료

[1] Sameer Agarwal, Keir Mierle 및 Ceres Solver 팀.

세레스 솔버, 2023. 4

[2] 카라-알리 알리에프, 아르템 세바스토폴스키, 마리아 콜로스, 드미트리
울리야노프(Ulyanov), 빅터 렘피츠키(Victor Lempitsky). 신경점 기반 그래프 -
ics. 컴퓨터 비전 -ECCV 2020: 제16회 유럽 연합
컨퍼런스, 영국 글래스고, 2020년 8월 23~28일, 절차,

XXII 16부, 696~712페이지. 스프링어, 2020. 1, 2

[3] 조나단 T 배런, 벤 밀든홀, 매튜 탄식, 피터
Hedman, Ricardo Martin-Brualla 및 Pratul P Srinivasan.

Mip-nerf: 엔티앨리어싱 중립을 위한 다중 스케일 표현
ral 래디언스 필드. IEEE/CVF 간 진행에서
컴퓨터 비전에 관한 전국 회의, 5855~5864페이지,
2021. 1, 2

[4] 조나단 T 배런, 벤 밀든홀, 도르 베르빈, 프라툴 P
스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한
엔티앨리어싱된 신경 방사 필드. 의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
인식, 페이지 5470-5479, 2022. 3, 6, 7, 8, 14, 15, 16

[5] Samuel Rota Bul o, Lorenzo Porzi, Peter Kotschieder.
가우스 스피래팅의 치밀화 수정. 유럽연합
컴퓨터비전 컨퍼런스, 2024. 2, 8

[6] David Charatan, Sizhe Lester Li, Andrea Tagliasacchi 및
빈센트 시츠만. pixelplat: 이미지의 3D 가우스 표시
확장 가능한 일반화 가능한 3D 재구성을 위한 쌍입니다. 프로에서는
컴퓨터 비전에 관한 IEEE/CVF 회의의 결과
및 패턴 인식, 페이지 19457-19467, 2024. 2

[7] 안페이 첸(Anpei Chen), Zexiang Xu, 안드레아스 가이거(Andreas Geiger), 징이 유(Jingyi Yu),
하오수. Tensorf: Tensorial radiance field. 인유럽 콘-
컴퓨터 비전에 대한 참고 자료, 333~350페이지. 스프링거, 2022년.
2

[8] Anpei Chen, Haofei Xu, Stefano Esposito, Siyu Tang 및
안드레아스 가이거. Lara: 효율적인 대규모 베이스라인 래디언스

필드. 2024년 컴퓨터 비전에 관한 유럽 회의에서.

2

[9] Yuedong Chen, Hao-fei Xu, Chuanxia Zheng, Bohan Zhuang,

Marc Pollefeys, Andreas Geiger, Tat-Jen Cham 및 Jianfei

카이. Mvsplat: 스파스에서 효율적인 3D 가우스 스플래팅

멀티뷰 이미지. 컴퓨터 vi에 관한 유럽 회의

시온, 2024. 2

[10] 안젤라 다이, Matthias Nießner, Michael Zollh ofer, Shahram

이자디, 크리스티안 테오발트. Bundlefusion: 실시간

측석 표면을 사용하여 전 세계적으로 일관된 3D 재구성

재통합. 그래픽에 대한 ACM 트랜잭션(ToG), 36(4):

2017년 2월 1일

[11] 재커리 드비토(Zachary DeVito), 마이클 마라, 마이클 졸(Michael Zollh), 길버트(Gilbert)

번스타인, 조나단 레이건-켈리, 크리스티안 테오발트, 팻

한라한, 매튜 피셔, 마티아스 니스너. 선택: A

비선형 최소 제곱 최적화를 위한 도메인별 언어

그래픽과 이미징의 규모화. ACM 거래

그래픽(TOG), 36(5):1-27, 2017. 2

[12] Sankeerth Durvasula, Adrian Zhao, 판 첸, Ruofan

리양(Liang), 파완 쿠마르 산자야(Pawan Kumar Sanjaya), 난디타 비자이쿠마르(Nandita Vijaykumar).

Distwar: 래스터 기반 렌더링에서 빠르게 차별화 가능한 렌더링

데링 파이프라인. arXiv 사전 인쇄 arXiv:2401.05345, 2023. 1,

2, 5, 7, 8, 14, 15

[13] Zhiwen Fan, Wenyan Cong, Kairun Wen, Kevin Wang,

Jian Zhang, Xinghao Ding, Danfei Xu, 보리스 이바노비치,

Marco Pavone, Georgios Pavlakos 등. Instantsplat: Un-

40초 안에 제한된 희소 뷰 포즈 없는 가우스 스플래팅-

onds. arXiv 사전 인쇄 arXiv:2403.20309, 2024. 2

[14] Guangchi Fang과 Bing Wang. 미니 스플래팅: 표현-

제한된 수의 가우스를 사용하여 장면을 촬영합니다. 유로-

컴퓨터 비전에 관한 콩 컨퍼런스, 2024. 2

[15] Guofeng Feng, Siyan Chen, Rong Fu, Zimu Liao, Yi Wang,

Tao Liu, Boni Hu, Linning Xu, Zhilin Pei, Hengjie Li 등

Flashgs: 대규모 및 대규모 작업을 위한 효율적인 3D 가우스 스플래팅

고해상도 렌더링. 컴퓨터 진행 중

비전 및 패턴 인식 컨퍼런스, 26652페이지 -

26662, 2025. 1, 2

[16] Sara Fridovich-Keil, Alex Yu, Matthew Tancik, Qinhong

첸, 벤저민 레히트, 가나자와 양주. 플레녹셀:

신경망이 없는 래디언스 필드. 의 절차에서

컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스

인정(CVPR), 페이지 5501-5510, 2022. 2

[17] Antoine Gu'edon과 Vincent Lepetit. 설탕: 표면-

효율적인 3D 메시 재구성을 위한 정렬된 가우스 스플래팅

및 고품질 메시 렌더링이 가능합니다. 의 절차에서

컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스

인식, 페이지 5354-5363, 2024. 2

[18] 압둘라 함디, 루크 멜라스-키리아지, 진지 마이, 귀청 Qian, Ruoshi Liu, Carl V Ondrick, Bernard Ghanem 및 안드레아 베달디. Ges: 일반화된 지수 스플래팅

효율적인 래디언스 필드 렌더링을 위한 것입니다. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 19812-19822, 2024. 2

[19] 피터 헤드먼, 줄리앙 필립, 트루 프라이스, 안 마이클 프람, 조지 드레타키스, 가브리엘 브로스토우. 딥 블렌딩 자유 시점 이미지 기반 렌더링. ACM 거래 그래픽(ToG), 37(6):1-15, 2018. 2, 3, 6, 7, 8, 15, 16

[20] 안 헬드, 르노 반데겐, 압둘라 함디, 아드리안 들리에주, 안소니 치오파, 실비오 지안콜라, 안드레아 베달디, 버나드 가넴(Bernard Ghanem), 마크 반 드로젠브로크(Marc Van Droogenbroeck). 3D 콘 vex splatting: 3D 부드러운 컨버전을 사용한 Radiance 필드 렌더링 짜증나. IEEE/CVF 통신 회의 진행 중 퓨터 비전 및 패턴 인식(CVPR), 2025. 2

[21] Binbin Huang, Zehao Yu, Anpei Chen, Andreas Geiger 및 가오 성화. 기하학적으로 정확한 계산을 위한 2D 가우스 스플래팅 속도 복사 필드. SIGGRAPH 2024 컨퍼런스 논문에서. 컴퓨터기계협회, 2024. 2

[22] 황이화(Yi-Hua Huang), 린밍시안(Ming-Xian Lin), 순양티안(Yang-Tian Sun), 양쯔이(Ziyi Yang), Xiaoyang Lyu, Yan-Pei Cao, Xiaojuan Qi. 변형 가능 9

--- 페이지 10 ---

방사형 커널 스플래팅. 컴퓨터 진행 중 비전 및 패턴 인식 컨퍼런스, 21513페이지 - 21523, 2025. 2

[23] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler, 그리고 조지 드레타키스. 실시간 3D 가우스 스플래팅 래디언스 필드 렌더링. 그래픽의 ACM 트랜잭션, 42 (4), 2023. 1, 2, 3, 4, 5, 6, 7, 8, 12, 14, 15

[24] 베른하르트 커블, 안드레아스 뮐레만, 게오르기오스 코파나스, 마이클 위머, 알렉상드르 랑방, 조지 드레타키스. 실시간 렌더링을 위한 계층적 3D 가우스 표현 매우 큰 데이터 세트를 삭제합니다. 그래프의 ACM 트랜잭션- ics, 43(4), 2024. 2

[25] 샤키바 케라드만드, 다니엘 레베인, 고팔 샤르마, 웨이-wei Sun, Jeff Tseng, Hossam Isack, Abhishek Kar, 안드레아 탈리아사치, 이광무. 3d 가우스 마르코프 체인 몬테카를로처럼 튀는 것. arXiv 사전 인쇄 arXiv:2404.09591, 2024. 2, 8

[26] 디데릭 P 킹마. Adam: 확률론적 최적화 방법 마이징. arXiv 사전 인쇄 arXiv:1412.6980, 2014. 2, 3

[27] 아르노 크나피치(Arno Knapitsch), 박재식, 저우첸이(Qian-Yi Zhou), 블라들렌(Vladlen Koltun. 탱크와 사원: 대규모 장면 벤치마킹

- 재건축. 그래픽에 대한 ACM 트랜잭션(ToG), 36 (4):1~13, 2017. 3, 6, 7, 15, 16
- [28] 레이란, 티엔지아 샤오, 지쉬안 루, 유 장, 첸판푸 장, 음양. 3dgs2: 거의 2차 수렴 3D 가우스 스피래팅을 수행합니다. arXiv 사전 인쇄 arXiv:2501.13975, 2025. 8
- [29] Tianqi Liu, Guangcong Wang, Shoukang Hu, Liao Shen, Xinyi Ye, Yuhang Zang, Zhiguo Cao, Wei Li 및 Ziwei 리우. Mvsgaussian: 빠르게 일반화 가능한 가우스 스피래팅 재-멀티뷰 스테레오로 구성. 유럽회의 컴퓨터비전, 2024. 2
- [30] 타오 루, 안킷 디만, R 스리나스, 엠레 아르슬란, 안젤라 Xing, Yuanbo Xiangli, R Venkatesh Babu 및 Srinath Sridha. Turbo-gs: 고속 3D 가우스 피팅 가속화 품질 광채 필드. arXiv 사전 인쇄 arXiv:2412.13547, 2024. 2, 8
- [31] Tao Lu, Mulin Yu, Linning Xu, Yuanbo Xiangli, Limin 왕(Wang), 다화린(Dahua Lin), 보다이(Bo Dai). Scaffold-gs: 구조화된 3D 뷰 적응형 렌더링을 위한 가우스. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 20654-20664, 2024. 2
- [32] Saswat Subhajyoti Mallick, Rahul Goel, Bernhard Kerbl, 마르쿠스 스타인베르거(Markus Steinberger), 프란시스코 비센테 카라스코(Francisco Vicente Carrasco), 페르난도 데 라 토레. Taming 3dgs: 고품질 광채 자원이 제한된 분야. SIGGRAPH Asia 2024 Con-에서 참조 논문, 뉴욕, 뉴욕, 미국, 2024. 협회 컴퓨팅 기계. 1, 2, 5, 7, 8, 14, 16
- [33] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik, 조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프: 뷰 동기화를 위해 장면을 신경 방사 필드로 표현 논문. ACM 커뮤니케이션, 65(1):99-106, 2021. 1, 2, 6
- [34] Jorge J Mor'e. levenberg-marquardt 알고리즘: 구현-정신과 이론. 수치 분석: 절차 6월 28일부터 7월 1일까지 던디에서 2년마다 개최되는 컨퍼런스 1977년, 105~116페이지. 스프링어, 2006. 2, 3
- [35] Thomas Müller, Alex Evans, Christoph Schied 및 Alexander Keller. 다중 기능을 갖춘 즉각적인 신경 그래픽 프리미티브 tisation 해시 인코딩. 그래픽의 ACM 트랜잭션 (TOG), 41(4):1-15, 2022. 1, 2
- [36] 마이클 니마이어, 파비안 만하르트, 마리-줄리 라코토사오나, 마이클 오크슬, 다니엘 덕워스, 라마 고슬라, 타데노 케이스케, 존 베이츠, 도미닉 캐저, 페데리코 톰바리. Radsplat: Radiance 필드 기반 가우스 스피래팅-900+ fps의 강력한 실시간 렌더링을 위한 것입니다. 내부-3D Vision 2025 컨퍼런스, 2025. 2

- [37] 파나기오티스 파판토나키스, 게오르기오스 코파나스, 베른하르트 커블, 알렉상드르 랑방, 조지 드레타키스. 감소 3D 가우스 스피래팅의 메모리 공간. 절차 컴퓨터 그래픽 및 인터랙티브 기술에 관한 ACM의 niques, 7(1):1-17, 2024. 2
- [38] 아담 패스케(Adam Paszke), 샘 그로스(Sam Gross), 프란시스코 마사(Francisco Massa), 아담 레러(Adam Lerer), 제임스 브래드버리, 그레고리 채넌, 트레버 킬린, 제밍 Lin, Natalia Gimelshein, Luca Antiga 등. Pytorch: 제가-Perative 스타일의 고성능 딥러닝 라이브러리입니다. 광고-신경 정보 처리 시스템의 발전, 32, 2019. 5
- [39] Sverker Rasmuson, Erik Sintorn 및 Ulf Assarsson. 성능: 성능이 뛰어나고 명시적인 래디언스 필드. 컴퓨터의 프론티어 과학, 4:871808, 2022. 2
- [40] Kerui Ren, Lihan Jiang, Tao Lu, Mulin Yu, Linning Xu, 장카이니(Zhangkai Ni), 보다이(Bo Dai). Octree-gs: 일관성을 향하여 로드 구조의 3D 가우스를 사용한 실시간 렌더링. arXiv 사전 인쇄 arXiv:2403.17898, 2024. 2
- [41] Cheng Sun, Min Sun 및 Hwann-Tzong Chen. 직접 복셀 그리드 최적화: 복사장을 위한 초고속 수렴 재건축. IEEE/CVF 회의 진행 중 컴퓨터 비전 및 패턴 인식, 5459페이지 - 5469, 2022. 2
- [42] A. Tewari, J. Thies, B. Mildenhall, P. Srinivasan, E. Tretschk, W. Yifan, C. Lassner, V. 시츠만, R. 마틴-브루알라, S. Lombardi, T. Simon, C. Theobalt, M. Nießner, J. T. Barron, G. Wetzstein, M. Zollhofer 및 V. Golyanik. 진출 신경 렌더링. 컴퓨터 그래픽 포럼(EG STAR 2022), 2022. 1, 2
- [43] Justus Thies, Michael Zollhofer, Matthias Nießner, Levi Val-Gaerts, Marc Stamminger 및 Christian Theobalt. 진짜-얼굴 재연을 위한 시간 표현 전송. ACM 트랜스. Graph., 34(6):183-1, 2015. 2
- [44] Justus Thies, Michael Zollhofer, Marc Stamminger, 크리스티안 테오발트, 마티아스 니스너. Face2face: 실시간 RGB 비디오의 얼굴 캡처 및 재연. 진행중-컴퓨터 비전 및 패턴에 관한 IEEE 회의의 내용 인정(CVPR), 2016. 2
- [45] Zhou Wang, Alan C Bovik, Hamid R Sheikh 및 Eero P Simoncelli. 이미지 품질 평가: 오류 가시성부터 구조적 유사성. 이미지 처리에 대한 IEEE 트랜잭션, 13(4):600-612, 2004. 4
- [46] Hao-fei Xu, Songyou Peng, Fang-jinhua Wang, Hermann 블룸, 다니엘 바라스, 안드레아스 가이거, 마크 폴리페이스. Depthslat: 가우스 스피래팅과 깊이를 연결합니다. 에서 컴퓨터 비전 및 패턴 인식 논문 컨퍼런스, 페이지 16453-16463, 2025. 2

10

--- 페이지 11 ---

- [47] Qiangeng Xu, Zexiang Xu, Julien Philip, Sai Bi, Zhixin Shu, 칼안 순카발리, 올리히 노이만. 포인트-nerf: 포인트 기반 신경 방사 필드. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 표창, 페이지 5438-5448, 2022. 2
- [48] Vickie Ye, Ruilong Li, 저스틴 커, Matias Turkulainen, 브렌트 이, Zhuoyang Pan, Otto Seiskari, Jianbo Ye, Jeffrey Hu, Matthew Tancik, Angjoo Kanazawa. gsplat: 안 Gaussian splatting을 위한 오픈 소스 라이브러리입니다. arXiv 사전 인쇄 arXiv:2409.06765, 2024. 1, 2, 5, 7, 8, 14, 16
- [49] Chandan Yeshwanth, Yueh-Cheng Liu, Matthias Nießner, 그리고 안젤라 다이. Scannet++: 고품질 3D 데이터 세트 문 장면. IEEE/CVF 국제회의의 진행 중 컴퓨터 비전 컨퍼런스, 2023년 12~22페이지. 1
- [50] Zehao Yu, Anpei Chen, Binbin Huang, Torsten Sattler 및 안드레아스 가이거. Mip-splatting: Alias-free 3d gaussian splatting. IEEE/CVF 통신 회의의 진행 중 퓨터 비전 및 패턴 인식(CVPR), 19447페이지 - 19456, 2024. 2
- [51] 리처드 장, 필립 이솔라, 알렉세이 A 에프로스, 엘리 세흐트만, 그리고 올리버 왕. 딥의 불합리한 효율성 지각 지표로 기능합니다. CVPR에서는 2018. 6
- [52] Hang Zhao, Orazio Gallo, Iuri Frosio 및 Jan Kautz. 손실 신경망을 이용한 이미지 복원 기능. IEEE 컴퓨터 이미징에 관한 거래, 3(1):47-57, 2016. 4
- [53] 자오허쉬, 웅하오양, 루다오한, 리양, 리진양, Aurojit Panda 및 Saining Xie. 3D 가우스 확장 시 스플래팅 훈련. 컴퓨터 Vi에 관한 유럽 회의에서 시온, 14~36페이지. 스프링거, 2025. 2
- [54] Chen Ziwen, Hao Tan, Kai Zhang, Sai Bi, Fujun Luan, Yi-콩홍(cong Hong), 리푸신(Li Fuxin), Zexiang Xu. Long-lrm: 롱-넓은 범위를 위한 시퀀스 대규모 재구성 모델 가우스 스플랫. IEEE/CVF Interna- 컴퓨터 비전 컨퍼런스, 2025. 2
- [55] Michael Zollhöfer, Matthias Nießner, Shahram Izadi, 크리스토프 레만, 크리스토퍼 잭, 매튜 피셔, Chenglei Wu, 앤드류 피츠기번, 찰스 루프, 크리스찬 Theobalt, et al. 실시간 비강체 재구성 RGB-D 카메라. 그래픽에 대한 ACM 트랜잭션(ToG), 33(4): 2014. 2. 1~12
- [56] Michael Zollhöfer, Angela Dai, Matthias Innmann, Chenglei Wu, 마크 스태밍거, 크리스티안 테오발트, 마티아스

니에스너. 체적 서명에 대한 음영 기반 개선
거리 함수. 그래픽 기반 ACM 트랜잭션(ToG),
34(4):1~14, 2015. 2

11

--- 페이지 12 ---

3DGS-LM: Levenberg-Marquardt를 사용한 더 빠른 가우스 스피래팅 최적화
보충 자료

A. CUDA 커널 디자인에 대한 자세한 내용

우리는 다음을 계산하는 데 필요한 CUDA 커널을 소개합니다.

초의 PCG 알고리즘. 3.3. 이 섹션에서는 다음과 같은 광고를 제공합니다.

추가 구현 세부정보

A.1. 병렬화 패턴

우리는 픽셀당 스피래팅당 병렬화 패턴을 구현합니다.

후속 항목을 읽어 CUDA 커널에서 tern

후속 스레드의 그래디언트 캐시에서. 이것은

완벽하게 통합된 캐시 값을 읽으므로 최소값

작업으로 인한 오버헤드를 최소화합니다. 그라데이션

캐시는 가우스를 기준으로 정렬됩니다. 즉, 하위

Quent 항목은 이것을 본 다른 광선(픽셀)을 나타냅니다.

투영된 가우스(표시). 일반적으로 하나의 스레드는 한-

각 픽셀에 해당하는 모든 잔차를 처리합니다. 즉,

많은 계산이 색상 채널 전반에 걸쳐 공유되며

그러므로 결합.

A.2. buildCache 및 applyJT 설계

buildCache에 필요한 계산 및

PCG의 applyJT 단계(알고리즘 1 참조)는 다음과 같이 분할됩니다.

세 개의 커널. 이는 3DGS의 원래 디자인을 따릅니다.

미분 가능한 래스터라이저 [23]. 두 경우 모두에서 우리는 다음을 계산합니다.

$g = JT u$ 형식의 야코비안 벡터 곱

$J \in \mathbb{R}^N \times M$ 은 N 잔차와 M 으로 구성된 야코비안 행렬입니다.

가우스 매개변수 및 $u \in \mathbb{R}^N$ 은 입력 벡터입니다. 는

출력 벡터의 k 번째 요소는 다음과 같이 계산됩니다.

$g_k =$

$N \times$

$n_k = 0$

∂r_i

∂x_k

$u_i = \partial y_k$

∂x_k

$N \times$

$n_k = 0$

∂r_i

∂y_k

UI (9)

여기서 r_i 는 i 번째 잔차이고 x_k 는 k 번째 가우스 p_a 입니다.

평가자. 즉, g_k 는 다음의 모든 잔차에 대한 합입니다.

k번째 가우스 매개변수입니다. 연쇄 법칙에 따르면,
그라디언트 ∂r_i 를 분할하는 것이 가능합니다.

∂x_k

$= \partial r_i$

∂y_k

∂y_k

∂x_k

. 우리는 할 수 있다

이를 사용하여 세 개의 작은 커널로 계산을 분할합니다.

nels, 첫 번째만 전체 합계를 계산하면 됩니다.

잔차:PN

나는=0

∂r_i

∂y_k

ui. 이 금액이 주요 병목 현상입니다.

커널 구현, 구현이 필요하기 때문에

원자적으로(즉, 여러 스레드가 동일한 출력에 쓰기

위치). 그런 다음 다른 커널은 남은 값만 계산합니다.

가우시안을 통해 병렬화하여 단계를 수행합니다. 조금 남용한다

표기법을 사용하고 2D 평균, 색상 및 불투명도를 y_k 로 표시합니다.

k번째 투영된 가우스의 속성입니다. 즉,

첫 번째 커널은 이들 각각에 대한 편도함수를 합산합니다.

별도의 벡터에 있는 속성. 다음에서는

점미사 p_1, p_2, p_3 은 해당 커널의 세 가지 커널을 나타냅니다.

각각의 작업(여기서 p_1 은 다음을 계산하는 커널을 나타냄)

잔차에 대한 합계를 계산합니다).

buildCache p_1 은 원래 픽셀당 캐시를 활용합니다.

ApplyJT p_1 커널은 병렬화를 사용하는 반면

그라디언트 캐시와 우리가 제안한 스플랫당 픽셀당 병렬

레리제이션 패턴. 그라디언트 캐시는 Gaus-

즉, 후속 항목은 다른 광선에 해당합니다.

같은 스플랫. 이를 통해 효율적으로 구현을 수행할 수 있습니다.

먼저 분할된 워프 감소를 수행하여 합산한 다음

워프당 하나의omicAdd 문만 발행합니다.

A.3. applyJ 및 diagJTJ 설계

대조적으로, applyJ 및 diagJTJ 계산은 다음을 수행할 수 있습니다.

더 작은 커널로 분할되지 않습니다. 구체적으로,

applyJ 커널은 $p \in \mathbb{R}^M$ 으로 $u = Jp$ 를 계산합니다. k번째

출력 벡터의 요소는 다음과 같이 계산됩니다.

영국 =

MX

나는=0

∂r_k

∂x_i

파이 =

NX

나는=0

∂r_k

∂O_i

∂O_i

∂x_i

파이 (10)

즉, u_k 는 다음의 모든 가우스 속성에 대한 합입니다.

k 번째 잔차. 마찬가지로 $\text{diag}(J_T)$ 커널은 다음을 계산합니다.

$M = \text{diag}(J_T) \in \mathbb{R}^{M \times M}$. 출력의 k 번째 요소

벡터는 다음과 같이 계산됩니다.

마크 =

N_X

나는=0

(∂r_i

∂x_k

) 2 =

N_X

나는=0

(∂r_i

∂y_k

∂y_k

∂x_k

) 2 (11)

두 경우 모두 그래디언트의 일부를 이동할 수 없습니다.

금액 외의 금액입니다. 결과적으로, 둘 다 적용됩니다.

$\text{diag}(J_T)$ 는 하나의 커널로 구현됩니다.

스레드는 최종 편도함수를 직접 계산하여

모든 가우스 속성. 이렇게 하면 숫자가 약간 증가합니다.

필요한 레지스터 수 및 런타임과 비교

apply_J 커널(탭 5 참조). $\text{Diag}(J_T)$ 커널은

apply_J p1과 동일한 분할 워프 감소 사용

제공된 편도함수를 효율적으로 합산하기 위한 것입니다.

Apply_J 커널은 먼저 모든 가우스에 대해 요약합니다.

각 스레드 내에서 개별적으로 공물을 제공합니다. 그러면 우리는 단지 발행

스레드당 각 잔여에 대해 하나의 omicAdd 문.

Apply_J 커널에서는 입력 벡터 p 가 다음과 같아야 합니다.

가우시안별로 정렬되어 읽기가 합쳐졌습니다.

즉, $p = [x_a$

$1, \dots, x_z$

$1, \dots, x_a$

남, ..., x_z

$M]_T$, 여기서 x_a

k 는

k 번째 가우스의 a 번째 매개변수에 해당하는 값

시안. 전체적으로 각 가우스는 59개의 매개변수로 구성됩니다.

위치, 회전, 배율 조정 및 불투명도의 경우 11개, 위치, 회전, 크기 조정 및 불투명도의 경우 48개

3차의 모든 구형 고조파 계수.

trast, 다른 모든 커널에서는 출력 벡터를 정렬해야 합니다.

속성별로 쓰기를 통합합니다. 즉:

$q = [x_a$

$1, \dots, x_a$

$\text{남}, \dots, x_z$

$1, \dots, x_z$

M]T. 우리는 q 의 구조를 사용합니다

알고리즘 1의 다른 모든 벡터-벡터 계산의 경우

12

--- 페이지 13 ---

음. ApplyJ 커널을 호출할 때마다 먼저

q 를 p 의 레이아웃으로 재구성하는 sortX 커널을 호출합니다.

A.4. 잔여 픽셀 가중치의 사전 계산

우리는 잔차의 제공근 공식을 채택합니다.

에너지 공식화 (식 (3) 참조). 우리는 효율적으로 사전 계산합니다.

편도함수에 대한 제공근의 기여도

방정식의 (9), 식. (10) 및 식. (11). 다음에서 우리는

i 번째 잔차의 부분 도함수를 다음으로 나눕니다.

k 번째 가우스 속성은 두 단계로 나뉩니다.

a_{ri}

a_{xk}

$= a_{ri}$

a_{ci}

a_{ci}

a_{xk}

(12)

여기서 a_{ri}

a_{ci}

잔여 픽셀에서 렌더링된 픽셀로 이동

색상 및 a_{ci}

a_{xk}

픽셀 색상에서 가우시안 속성까지.

우리는 L1 및 SSIM 손실 조건을 채택하고

제공근, 항 a_{ri}

a_{ci}

그에 따라 계산해야 합니다.

대조적으로, L2 손실을 사용할 때는 사소한 형태를 취합니다.

a_{ri} 의

a_{ci}

$= 1$. 다음에서는 단순화할 수 있음을 보여줍니다.

a_{ri} 의 계산

a_{xk}

a_{ri} 를 미리 계산하여 커널에서

a_{ci}

.

g 의 k 번째 요소는 다음과 같이 계산됩니다.

$g_k = (J^T J p)_k =$

$N \times$

$\text{나는} = 0$

∂r_i

∂x_k

$M \times$

$j = 0$

∂r_i

∂x_j

피제이 (13)

Eq. (12)를 식으로 (13), ∂r_i 를 제외합니다.

∂c_i

:

$g_k =$

$N \times$

$\text{나는} = 0$

$(\partial r_i$

∂c_i

$)^2 \partial c_i$

∂x_k

$M \times$

$j = 0$

∂c_i

∂x_j

피제이 (14)

조건 ∂c_i

∂x_k

동일한 픽셀의 잔차에 대해 동일합니다.

L1 또는 SSIM에 해당하는 색상 채널

손실 조건. 컴퓨팅 ∂c_i 를 피하려면

∂x_k

두 번 (그리고

따라서 모든 커널의 그리드 크기를 두 배로 늘립니다. 대신

두 손실 조건의 기여도를 요약합니다.

$(\partial r_i$

∂c_i

$)^2 = (\partial r_1$

나

∂c_i

$)^2 + (\partial r_2$

나

∂c_i

$)^2$ (15)

여기서 r_1

i 는 i 번째 L1 잔차에 해당하고 r_2 는

내가 나한테-

SSIM 잔차. 추가적으로 우리는 곱셈을 구현합니다.

(∂r_i 의 양이온

∂c_i

)2 식에서. (14) 요소별 벡터 생성

uct (로 표시) of $u = [PM$

$j=0$

∂c_0

∂x_j

$p_j \dots$ 오후

$j=0$

∂c_N

∂x_j

$p_j]$

그리고 $\nabla r = [(\partial r_0$

∂c_0

)2...(∂r_N

∂c_N

)2]:

$g_k =$

NX

나는=0

∂c_i

∂x_k

($u \nabla r)_i$ (16)

이렇게 하면 통합되지 않은 추가 전역 메모리 읽기가 방지됩니다.

CUDA 커널에서는 ∇r 입니다. 대신에 우리는 $u \nabla r$ 을 계산합니다

ApplyJ 커널 이후와 이전에 별도의 작업

JT를 신청하세요. 이는 또한 커널을 단순화합니다.

∂c_i 만 계산하면 됩니다.

∂x_k

∂r_i 대신

∂x_k

. 그러므로,

L1 및 SSIM 잔여 사용으로 인한 런타임 오버헤드만

L2 잔차에 대한 항은 ∇r 의 계산입니다. 어떻게-

이는 역전파를 사용하여 효율적으로 계산할 수 있습니다.

(autograd)이므로 병목 현상이 발생하지 않습니다.

B. 이미지 서브샘플링 가중치 도출

우리는 이미지의 크기를 줄이기 위해 이미지 배치를 서브샘플링합니다.

그래디언트 캐시(섹션 3.3 참조) 업데이트를 결합하려면

여러 배치의 벡터를 사용하여 가중치를 계산합니다.

Eq.에 자세히 설명된 대로 의미합니다. (8). 이 가중 평균은 근사치입니다.

정규 방정식(Eq. (4))에 "참" 해를 구합니다.

이는 이미지 서브샘플링에 의존하지 않습니다(대신

사용 가능한 모든 훈련 이미지를 사용합니다). 서브샘플링할 때

연령에 따라 총 잔차 수를 더 작은 크기로 나눕니다.

덩어리. 다음에서는 두 가지 경우를 고려한다.

청크(1과 2로 표시)가 있지만 모든 청크에도 동일하게 적용됩니다.
 청크의 수. 우리는 정규 방정식을 다시 작성합니다(-
 아웃 서브샘플링) 다음과 같이 청크 표기법을 사용합니다.

JT
 1JT
 2
 J1
 J2

=

JT
 1JT
 2

F1(엑스)
 F2(x)

(17)

여기서는 추가 LM 정규화 용어를 삭제합니다.
 명확성을 높이고 야코비안 벡터와 잔차 벡터를 분리하여 나눕니다.
 청크에 따라 행렬/벡터를 평가합니다. 해결책
 정규방정식은 다음과 같이 구해진다:

= (JT
 1 J1 + JT
 2 J2) 1(JT
 1 F1(x) + JT
 2 F2(x)) (18)

대조적으로, 이미지를 서브샘플링할 때 우리는 다음을 해결합니다.
 Mal 방정식을 별도로 계산하고 두 가지 해를 얻습니다.

1 = (JT
 1J1) 1JT
 1 F1(x) (19)
 2 = (JT
 2 J2) 1JT
 2 F2(x) (20)

우리는 방정식을 다시 쓸 수 있습니다. (18) 1, 2의 가중 평균:

= K 1(JT
 1 J1)(JT
 1 J1) 1(JT
 1 F1(x)) (21)
 +K 1(JT
 2 J2)(JT
 2 J2) 1(JT
 2 F2(x)) (22)
 = w1 1 + w2 2 (23)

여기서 $K = (JT$

$1 J1 + JT$

$2 J2)$, $w1 = K \quad 1(JT$

$1 J1)$, $w2 =$

$K \quad 1(JT$

$2 J2)$. 이러한 가중치를 계산하려면 다음이 필요합니다.

K 를 리얼화하고 반전시킵니다. 이는 메모리에 담기에는 너무 비용이 많이 듭니다.

이를 위해 실제 가중치 $w1$ 과 $w2$ 를 근사화합니다.

$\sim w1 = \text{diag}(w1)$ 및 $\sim w2 = \text{diag}(w2)$ 입니다. 이 직접

우리가 Eq.에서 사용하는 가중 평균으로 이어집니다. (8).

13

--- 페이지 14 ---

커널 런타임(ms) ↓ 컴퓨팅 처리량(%) ↑ 메모리 처리량(%) ↑ 레지스터 수 ↓

빌드캐시 p1 31.32 78.56 78.56 64

빌드캐시 p2 0.53 17.43 87.94 58

빌드캐시 p3 4.12 4.54 73.45 74

sortCacheByGaussians 5.04 61.17 61.17 18

diagJTJ 41.60 71.13 71.13 90

정렬X 4.45 15.15 60.30 36

적용J 10.98 86.32 86.32 80

적용JT p1 3.93 75.79 75.79 34

적용JT p2 0.37 18.83 89.69 40

적용JT p3 3.20 4.75 78.48 48

표 5. CUDA 커널의 프로파일러 분석 그라디언트 캐시 구축/리조트를 위해 RTX3090 GPU에서 측정된 결과를 제공합니다.

MipNerf360 [4] "정원" 장면에서 하나의 이미지 배치 크기로 하나의 PCG 반복을 실행합니다.

C. 상세한 런타임 분석

우리는 실행을 통해 CUDA 커널에 대한 추가 분석을 제공합니다.

NVIDIA Nsight 컴퓨팅 프로파일러를 만드는 중입니다. 우리는 프로-Tab에서 결과를 확인하세요. 5는 RTX3090 GPU에서 측정되었습니다.

그라디언트 캐시 구축/리조트 및 하나의 PCG 실행

배치를 사용한 MipNerf360 [4] "정원" 장면 반복

이미지 하나의 크기입니다. 점미사 p1, p2, p3을 추가합니다.

우리가 해당 사양을 구현하는 데 사용하는 세 가지 커널에 신호를 보냅니다.

작동합니다(부록 A 참조).

buildCache의 런타임과

applyJT 커널은 우리 프로의 장점을 드러냅니다.

스플랫당 픽셀당 병렬화 패턴을 제시했습니다. 둘 다

동일한 야코비안 벡터 곱을 계산하지만

buildCache 커널은 픽셀당 병렬화에 의존합니다.

원본 3DGS 래스터라이저의 패턴[23]. 그러나 우리는

그라디언트 캐시를 사용하여 결과를 4.8배 더 빠르게 계산합니다.

applyJT 커널. 우리는 또한 계산과

메모리 처리량과 두 가지 모두의 레지스터 수

커널은 거의 비슷합니다. 이는 우리 커널이

보완은 똑같이 효율적입니다. 즉, 고유한 요소가 없습니다.

우리가 제안한 GPU 병렬화 방식의 단점.

D. 장면별 결과

우리는 주요 수량에 대한 장면별 분석을 제공합니다.

모든 데이터 세트의 모든 기준선에 대한 결과입니다. 비교

3DGS[23]에 대한 ison은 Tab에 있습니다. 6. 비교

DISTW AR [12]에 대한 내용은 Tab에 있습니다. 7. 비교

gsplat [48]에 대한 내용은 Tab에 있습니다. 8. 비교

Taming-3DGS [32]는 Tab에 있습니다. 9. 우리의 방법은 다음과 같이 구성됩니다.

모든 장면에서 최적화 런타임의 텐트 가속,

동일한 품질을 달성하면서.

14

--- 페이지 15 ---

메소드 장면 MipNeRF-360 [4]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

3DGS [23] 트리힐 0.631 22.44 0.330 1130

+ 우리 트리힐 0.633 22.57 0.334 836

3DGS [23] 카운터 0.905 28.96 0.202 1178

+ 우리 카운터 0.904 28.89 0.206 927

3DGS [23] 그루터기 0.769 26.56 0.217 1234

+ 우리 그루터기 0.774 26.67 0.218 895

3DGS [23] 분재 0.939 31.99 0.206 1034

+ 우리 분재 0.938 31.84 0.208 794

3DGS [23] 자전거 0.764 25.20 0.212 1563

+ 우리 자전거 0.765 25.30 0.218 1141

3DGS [23] 주방 0.925 31.37 0.128 1389

+ 우리 주방 0.924 31.21 0.128 1156

3DGS [23] 꽃 0.602 21.49 0.340 1132

+ 우리꽃 0.600 21.52 0.344 819

3DGS [23] 방 0.917 31.36 0.221 1210

+ 우리방 0.916 31.10 0.224 1004

3DGS [23] 정원 0.862 27.23 0.109 1573

+ 우리 정원 0.863 27.30 0.110 1175

메소드 씬 딥 블렌딩 [19]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

3DGS [23] 놀이방 0.901 29.90 0.247 1085

+ 우리 놀이방 0.905 30.24 0.246 861

3DGS [23] drjohnson 0.898 29.12 0.246 1359

+ 우리 drjohnson 0.901 29.23 0.248 1040

메소드 장면 탱크 및 사원 [27]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

3DGS [23] 열차 0.811 21.95 0.209 636

+ 우리 열차 0.811 22.07 0.214 579

3DGS [23] 트랙 0.877 25.40 0.148 837

+ 우리 트랙 0.876 25.36 0.151 747

표 6. 우리의 방법과 기반의 정량적 비교

라인. 우리는 모든 지표에 대한 장면별 분석을 보여줍니다.

3DGS [23] 기준선.

메소드 장면 MipNeRF-360 [4]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

DISTW AR [12]트리힐 0.633 22.47 0.327 898

+ 우리 트리힐 0.635 22.54 0.332 669

DISTW AR [12]카운터 0.905 29.00 0.203 790

+ 우리 카운터 0.904 28.91 0.205 687

DISTW AR [12]그루터기 0.771 26.60 0.216 1017

+ 우리 그루터기 0.773 26.70 0.217 760

DISTW AR [12]분재 0.939 32.13 0.206 677

+ 우리 분재 0.938 31.92 0.208 578

DISTW AR [12]자전거 0.763 25.19 0.212 1333

+ 우리 자전거 0.764 25.26 0.218 971

DISTW AR [12]주방 0.925 31.31 0.127 957

+ 우리집 주방 0.924 31.14 0.128 838

DISTW AR [12]꽃 0.602 21.45 0.340 884

+ 우리꽃 0.596 21.48 0.348 671

DISTW AR [12]실 0.916 31.41 0.221 803

+ 우리방 0.916 31.40 0.224 680

DISTW AR [12]정원 0.862 27.23 0.109 1338

+ 우리 정원 0.861 27.32 0.112 1023

메소드 씬 딥 블렌딩 [19]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

DISTW AR [12]놀이방 0.900 29.81 0.247 729

+ 우리놀이방 0.905 30.24 0.246 586

DISTW AR [12]drjohnson 0.898 29.13 0.247 953

+ 우리 drjohnson 0.901 29.13 0.249 758

메소드 장면 탱크 및 사원 [27]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

DISTW AR [12]열차 0.812 22.05 0.209 504

+ 우리 열차 0.810 22.10 0.216 440

DISTW AR [12]트럭 0.877 25.29 0.148 698

+ 우리 트럭 0.877 25.28 0.150 635

표 7. 우리의 방법과 기반의 정량적 비교

라인. 우리는 모든 지표에 대한 장면별 분석을 보여줍니다.

DISTW AR [12] 기준선.

15

--- 페이지 16 ---

메소드 장면 MipNeRF-360 [4]

SSIM↑ PSNR↑ LPIPS↓ 시간(초)

gsplat [48] 트리힐 0.634 22.44 0.324 973

+ 우리 트리힐 0.635 22.54 0.332 701

gsplat [48] 카운터 0.908 28.99 0.201 903

+ 우리 카운터 0.904 28.91 0.205 762

gsplat [48] 그루터기 0.769 26.53 0.218 1097

+ 우리 그루터기 0.774 26.70 0.217 793

gsplat [48] 분재 0.937 31.95 0.208 783
 + 우리 분재 0.938 31.92 0.208 646
 gsplat [48] 자전거 0.765 25.21 0.206 1398
 + 우리 자전거 0.765 25.26 0.218 988
 gsplat [48] 주방 0.926 31.17 0.128 1086
 + 우리집 주방 0.924 31.14 0.128 921
 gsplat [48] 꽃 0.600 21.53 0.338 965

 + 우리꽃 0.601 21.48 0.348 709
 gsplat [48] 방 0.920 31.48 0.219 913
 + 우리방 0.916 31.39 0.224 753
 gsplat [48] 정원 0.869 27.48 0.105 1462
 + 우리 정원 0.861 27.32 0.112 1085
 메소드 씬 딥 블렌딩 [19]
 SSIM↑ PSNR↑ LPIPS↓ 시간(초)
 gsplat [48] 놀이방 0.907 29.89 0.248 799
 + 우리 놀이방 0.904 30.90 0.247 626
 gsplat [48] drjohnson 0.901 29.16 0.244 1040
 + 우리 drjohnson 0.901 29.07 0.251 805
 메소드 장면 탱크 및 사원 [27]
 SSIM↑ PSNR↑ LPIPS↓ 시간(초)
 gsplat [48] 열차 0.811 21.64 0.209 558
 + 우리 열차 0.809 22.09 0.216 381
 gsplat [48] 트럭 0.880 25.35 0.149 735
 + 우리 트럭 0.877 25.28 0.150 447
 표 8. 우리의 방법과 기반의 정량적 비교
 라인. 우리는 모든 지표에 대한 장면별 분석을 보여줍니다.
 gsplat [48] 기준선.
 메소드 장면 MipNeRF-360 [4]
 SSIM↑ PSNR↑ LPIPS↓ 시간(초) #G(M)
 테이밍 [32] 트리힐 0.625 23.00 0.385 479 0.78
 + 우리 트리힐 0.623 23.03 0.332 381 0.78
 길들이기 [32] 카운터 0.896 28.59 0.223 646 0.31
 + 우리 카운터 0.894 28.51 0.205 537 0.31
 길들이기 [32] 그루터기 0.734 25.96 0.292 405 0.48
 + 우리 그루터기 0.733 25.98 0.217 315 0.48
 길들이기 [32] 분재 0.934 31.73 0.221 634 0.41
 + 우리 분재 0.932 31.64 0.208 504 0.41
 길들이기 [32] 자전거 0.716 24.78 0.295 485 0.81
 + 우리 자전거 0.709 24.75 0.218 376 0.81
 길들이기 [32] 부엌 0.918 30.85 0.141 722 0.48
 + 우리 주방 0.918 30.84 0.128 597 0.48
 [32] 길들이기 꽃 0.554 21.00 0.407 465 0.57
 + 우리꽃 0.549 20.99 0.348 365 0.57
 길들이기 [32] 방 0.906 31.12 0.251 621 0.22
 + 우리방 0.906 31.21 0.224 521 0.22
 길들이기 [32] 정원 0.852 27.24 0.128 638 1.90

+ 우리 정원 0.852 27.25 0.112 483 1.90

메소드 씬 딥 블렌딩 [19]

SSIM↑ PSNR↑ LPIPS↓ 시간(초) #G(M)

길들이기 [32] 놀이방 0.900 30.29 0.278 419 0.18

+ 우리 놀이방 0.902 30.41 0.280 324 0.18

길들이기 [32] drjohnson 0.899 29.38 0.269 475 0.40

+ 우리 drjohnson 0.899 29.40 0.271 370 0.40

메소드 장면 탱크 및 사원 [27]

SSIM↑ PSNR↑ LPIPS↓ 시간(초) #G(M)

[32] 길들이기 열차 0.815 22.18 0.205 411 0.36

+ 우리 열차 0.802 22.28 0.241 328 0.36

[32] 길들이기 트랙 0.879 25.40 0.146 514 0.27

+ 우리 트랙 0.862 25.16 0.178 292 0.27

표 9. 우리의 방법과 기반의 정량적 비교

라인. 우리는 모든 지표에 대한 장면별 분석을 보여줍니다.

Taming-3DGS [32] 기준선. 추가적으로, 우리는 숫자를 포함합니다

de를 사용하여 얻은 수백만 개의 가우스(#G(M))

"예산"에 대한 오류 하이퍼파라미터.

16

4. Sparse-View & Geometry Ambiguity 계열

[논문 10] DRGS 본문 전체 번역

--- 페이지 1 ---

Few-Shot 이미지에서 3D 가우스 스플래팅을 위한 깊이 정규화된 최적화

정재영¹ 오정택² 이경무^{1,2}

¹서울대학교 ASRI ECE학과

²IPAI, ASRI, 서울대학교, 서울, 한국

{robot0321, 오제트곳, 경무}@snu.ac.kr

초록

본 논문에서는 Gaussian을 최적화하는 방법을 제시한다.

피하면서 제한된 수의 이미지로 튀기십시오.

과적합. 숫자를 조합하여 3D 장면을 표현합니다.

다양한 가우시안 스플랫(Gaussian splats)은 뛰어난 시각적 품질을 제공합니다.

그러나 이는 훈련 뷰에만 과적합되는 경향이 있습니다.

적은 수의 이미지를 사용할 수 있습니다. 이 문제를 해결하려면-

고소, 기하학 가이드로 조밀한 깊이 맵을 소개합니다.

과적합을 완화합니다. 우리는 다음을 사용하여 깊이 맵을 얻었습니다.

사전 훈련된 단안 깊이 추정 모델 및 정렬

희소한 COLMAP 특징 포인트를 사용하여 스케일 및 오프셋.

조정된 깊이는 색상 기반 최적화에 도움이 됩니다.

3D 가우스 스플래팅, 떠다니는 아티팩트 완화 및

기하학적 제약을 확실히 준수합니다. 우리는

다양한 NeRF-LLFF 데이터 세트에 대해 제안된 방법

몇 개의 이미지. 우리의 접근 방식은 강력함을 보여줍니다.

기하학에만 의존하는 원래 방법과 비교

이미지에.

1. 소개

영상을 통해 3차원 공간을 재구성하는 것은

오랫동안 컴퓨터 비전 분야의 도전이었습니다. 다시

센트의 발전은 사실적인 가능성을 보여줍니다.

새로운 견해 종합 [3, 31], 재구성에 대한 연구에 불을 붙였습니다.

이미지에서부터 완전한 3D 공간을 구성합니다. 운전한 사람

컴퓨터 그래픽 기술의 발전과 산업화

특히 가상 현실과 같은 분야에서 그렇습니다. [14]

및 모바일[11], 고품질 및 모바일 달성을 위한 연구

고속 실시간 렌더링이 진행되었습니다. 중

최근 주목할만한 발전, 3D Gaussian Splatting

(3DGS) [23]은 높은 조합으로 돋보입니다.

품질, 빠른 재구성 속도, 실제 지원

시간 렌더링. 3DGS는 가우스 감쇠 구형을 사용합니다.
 불투명도를 기본 요소로 사용하는 ical harmonic splats [12, 38]
 장면의 모든 부분을 표현합니다. 이는 표시가 일치하도록 안내합니다.
 에 제약 조건을 부과하여 일관된 지오메트리를 구성합니다.
 동시에 여러 이미지를 만족시키는 표시.
 장면에 대한 작은 표시를 모으는 접근 방식
 우리의 3DGS
 우리의 3DGS
 그림 1. 몇 번의 샷에서 깊이 정규화의 효율성
 설정 제한된 수의 가우시안 스플랫을 최적화합니다.
 형상 지침을 통해 과적합을 방지하는 이미지
 이미지에서 추정. 참고로 저희는 2개만 사용했습니다.
 이 3D 장면을 만들기 위한 이미지입니다.
 복잡한 디테일을 표현할 수 있는 기능을 제공하지만
 지역적 특성으로 인해 과적합되기 쉽습니다. 3DGS [24]
 다중 뷰 색상에 따라 독립적인 표시를 최적화합니다.
 글로벌 구조가 없는 감독. 따라서 AB에서는
 제공할 수 있는 충분한 양의 이미지
 전역 기하학적 단서에는 예방 조치가 없습니다.
 과적합. 이 문제는 다음과 같이 더욱 두드러집니다.
 3D 장면을 최적화하는 데 사용되는 이미지 수가 적습니다.
 소수의 제한된 기하학적 정보
 이미지는 로컬 반대 방향으로 잘못된 수렴을 초래합니다.
 최적의 결과로 인해 최적화가 실패하거나 떠다니는 아티팩트가 발생합니다.
 그림 1에 표시된 것처럼. 그럼에도 불구하고 재구성 기능은
 제한된 수의 이미지로 3D 장면을 구성하는 것이 중요합니다.
 실제적인 적용을 위한 cial을 통해 우리는 다음과 같은 문제를 해결해야 합니다.
 몇 번의 최적화 문제.

1

arXiv:2311.13398v3 [cs.CV] 2024년 1월 4일

--- 페이지 2 ---

한 가지 직관적인 해결책은 추가 기술을 보완하는 것입니다.
 깊이와 같은 측정 단서. 수많은 3D 재구성에서
 컨텍스트 [6]에서 깊이는 재구성에 엄청난 가치가 있음이 입증되었습니다.
 직접적인 기하학적 정보를 제공하여 3D 장면을 구성합니다.
 tion. 이러한 견고한 기하학적 단서를 얻으려면 깊이 센서가 필요합니다.
 RGB 카메라와 정렬된 카메라가 사용됩니다. 비록 이러한
 장치는 최소한의 오류로 조밀한 깊이 맵을 제공합니다.
 그러한 장비의 필요성은 또한 실행에 장애가 됩니다.
 응용 프로그램.

따라서 우리는 외부로 조정하여 조밀한 깊이 맵을 얻습니다.
 희박한 깊이를 갖는 깊이 추정 네트워크 삽입
 유명한 SfM(Structure-from-Motion)의 지도,
 카메라 매개변수와 3D 기능을 계산합니다.
 동시에 포인트를 줍니다. 3DGS는 특히 SfM을 사용합니다.

COLMAP [41], 그러한 정보를 획득합니다. 그러나 SfM은 또한 사용 가능한 3D에서도 눈에 띄는 부족에 직면했습니다. 이미지 수가 적을 때의 특징. 희박한 포인트 클라우드의 특성상 등록이 불가능합니다. 모든 가우스 스피랫(Gaussian splats)을 형식화합니다. 그러므로 추론하는 방법은 조밀한 깊이 맵이 필수적입니다. ex-하는 방법 중 하나 단안을 활용하여 이미지에서 밀도가 높은 깊이를 추출합니다. 깊이 추정 모델. 이러한 모델은 다음을 수행할 수 있지만 Principal을 기반으로 개별 이미지에서 조밀한 깊이 맵을 생성합니다. 또는 데이터에서 얻은 데이터는 상대적인 깊이만 생성합니다. 규모의 모호성 때문입니다. 규모의 모호함은 다중 뷰 이미지에서 중요한 기하학 충돌이 필요합니다. 독립적인 충돌을 방지하기 위해 규모를 조정합니다. 추론된 깊이. 우리는 이것이 피팅을 통해 수행될 수 있음을 보여줍니다. COLMAP [41]에서 다음으로의 무료 출력인 희소 깊이 추정된 조밀한 깊이 맵. 본 논문에서는 3차원을 표현하는 방법을 제안한다. 소수의 RGB 이미지를 활용한 장면 사전 훈련된 단안 깊이로부터의 사전 정보 타이밍 모델 [5] 및 부드러움 제약 조건. 우리는 적응한다 희소 깊이에 대한 추정 깊이의 스케일 및 오프셋 COLMAP 포인트로 스케일 모호함을 해결합니다. 우리는 색상 기반 작업을 지원하기 위해 기하학 가이드로 깊이를 조정했습니다. 타이밍화, 떠다니는 아티팩트 감소 및 형상 만족-조건을 시도해 보세요. 우리는 수정된 깊이조차도 도움이 된다는 것을 관찰했습니다. 그럼에도 불구하고 장면을 기하학적으로 최적의 솔루션으로 안내합니다. 거칠기. 우리는 다음을 통합하여 과적합 문제를 방지합니다. 최적화 프로세스를 통해 조기 중지 전략을 평가합니다. 깊이 가이드 손실이 증가하기 시작하면 중지됩니다. 게다가, 더 많은 안정성을 얻으려면 부드러움 제약 조건을 적용합니다. 인접한 3D 포인트의 깊이가 비슷한지 확인합니다. 우리 3DGS를 기준으로 삼아 성능 비교 NeRF-LLFF [30] 데이터 세트의 방법 중 하나입니다. 확인한다 우리의 전략은 측면에서만 아니라 그럴듯한 결과로 이어진다는 것을 RGB 신규 시점 합성뿐만 아니라 3D 기하학 재구성도 가능합니다. 건설. 추가 실험을 통해 우리는 깊이 및 초기점과 같은 기하학 단서의 영향 가우스 스피래팅에 대해. 그들은 직원에게 큰 영향을 미칩니다. 가우스 스피래팅의 최적화. 요약하자면, 우리가 기여한 내용은 다음과 같습니다.

- 우리는 깊이 기반 Gaussian Splatting 최적화를 제안합니다.

장면을 최적화할 수 있는 전략 몇 개의 이미지를 사용하여 과적합 문제를 완화합니다. 우리 악마-추정된 깊이조차도 SfM의 결과인 희소 포인트 클라우드 파이프라인은 기하학적 정규화에 중요한 역할을 할 수 있습니다. tion.

- 새로운 조기 정지 전략을 제시합니다: 열차를 정지-깊이 기반 손실이 감소할 때 프로세스를 수행합니다. 우리 철저한 분석을 통해 각 전략의 영향력을 설명합니다.

아 절제 연구.

- 우리는 부드러움 항의 채택을 보여줍니다. 깊이 맵은 모델이 올바른 지리를 찾도록 지시합니다. 측량법. 종합적인 실험 결과 향상된 것으로 나타났습니다. 원활한 포함으로 인한 성능 네스 용어.

2. 관련 업무

모션으로부터의 새로운 뷰 합성 구조(SfM) [46] 및 다중 뷰 스테레오(MVS)[45]는 여러 이미지를 이용해 3차원 구조를 구축하는 오랫동안 컴퓨터 비전 분야에서 연구되어 왔습니다. 필드. 지속적인 개발 중 COLMAP [41] 널리 사용되는 대표적인 도구이다. COLMAP이 수행하는 카메라 포즈 교정 및 희박한 3D 키포인트 찾기 다중 시점 이미지의 에피폴라 제약 조건 [22]을 사용합니다. 보다 조밀하고 사실적인 재구성을 위해 딥러닝-ing 기반의 3차원 재구성 기술은 주로 공부했습니다. [21, 31, 51] 그 중 신경복사장 (NeRF)[31]은 신경망을 이용한 대표적인 방법이다.

표현 방법으로서의 네트워크. NeRF는 현실감을 창조합니다 3D 공간 표현으로 MLP 네트워크를 사용하는 3D 장면 및 볼륨 렌더링을 통해 많은 후속 논문을 작성했습니다. 3D 재구성 연구. [3, 4, 18, 44, 47, 54] 특히-NeRF의 느린 속도를 극복하기 위해 많은 노력이 지속적으로 이루어지고 있습니다. 명시적 기술을 활용하여 실시간 렌더링을 달성하기 위해 계속 노력하고 있습니다. 희소 복셀과 같은 표현[16, 27, 43, 56], 특집 포인트 클라우드[52], 텐서[10], 폴리곤[11]. 이러한 대표 센세이션에는 독립적으로 작동하는 로컬 요소가 있습니다. 그래서 빠른 렌더링과 최적화 속도를 보여줍니다. 기반 이 아이디어에 따라 Multi-Level과 같은 다양한 표현이 가능해졌습니다. 계층 구조 [32, 33], 무한 네트워크 [19, 39], 삼중 비행기 [9]가 시도되었습니다. 그 중 3D 가우시안 splatting [23]은 다음을 통해 빠르고 효율적인 방법을 제시했습니다. 시간이 많이 걸리는 볼륨 대신 알파 블렌딩 래스터화 ume 렌더링. 수백만 달러를 사용하여 3D 장면을 최적화합니다. 불투명도가 있는 가우스 감쇠 구형 고조파 쉽고 빠른 3D 재구성을 보여주는 프리미티브 고품질.

2

--- 페이지 3 ---

스페이스 뷰
구조

에서
모션
포인트 클라우드

초기화
가우스 스피래팅

조정

독창적인 3D 가우스 스피래팅(Depth-Regularized) 최적화

그림 2. 개요. 우리는 에서 얻은 포인트 클라우드로 조정된 조밀한 깊이 맵을 사용하여 3D 가우스 스피래팅[23]을 최적화합니다.

콜맵 [41]. 3D 장면의 기하학적 구조를 조절하기 위해 깊이 맵을 통합함으로써 우리 모델은 다음을 사용하여 장면을 성공적으로 재구성했습니다.

제한된 수의 이미지.

퓨샷 3D 재구성 이미지에선 다음과 같은 내용이 포함되어 있으므로

3D 장면에 대한 부분적인 정보만, 3D 재구성

건설에는 많은 수의 다중 뷰 이미지가 필요합니다.

COLMAP은 여러 항목 간에 일치하는 특징점을 업로드합니다.

여러 이미지를 3D 공간에 배치하므로 더 많은 이미지가 사용됩니다.

보다 안정적인 3D 포인트와 카메라 포즈를 얻을 수 있습니다.

얻었습니다.[17, 41] NeRF는 또한 색상과 지리를 최적화합니다.

대형 픽셀 색상을 기반으로 한 3D 장면의 측정

고품질 장면을 얻기 위한 이미지 수. [48, 57]

그러나 많은 이미지에 대한 요구 사항으로 인해 실습이 방해를 받았습니다.

응용, 3D 재구성 활용에 대한 연구 촉발

이미지 수가 몇 개만 있습니다. 많은 소수의 3D 재촬영

건설 연구는 깊이를 활용하여 귀중한 지리 정보를 제공합니다.

3D 장면을 만들기 위한 측정 큐. 깊이는 감소에 도움이 됩니다.

색상 합의를 통해 기하학을 추론하려는 노력

표면 평활도 제어를 도입하여 여러 이미지를

변형 [25, 35]에서 얻은 희박한 깊이를 감속합니다.

COLMAP [13, 49]에서 얻은 조밀한 깊이를 사용하여

추가 센서 [2, 7, 15] 또는 추정된 밀도 활용

사전 훈련된 네트워크의 깊이. [34, 37, 40] 이 스테르드-

즉, 신경의 전역성을 기반으로 기하학을 정규화합니다.

ral 네트워크이므로 대표자에게 적용하기가 어렵습니다.

희박한 복셀[16]이나 특징과 같은 큰 지역성을 가진 이온

포인트 [52]. 대신 연결을 시도했습니다.

전체 변수를 통해 3D 공간의 로컬 요소 간

(TV) 손실 [16, 53, 59], 그러나 철저한 Hy-
에 따라 달라지는 전체 변동의 매개변수 조정
장면과 위치. 3D 가우스 스플래팅 [23]이 생성됩니다.
이미지 개수가 적은 떠다니는 인공물
지역성이 강함. 희소한 COLMAP 기능 포인트는 다음과 같습니다.
Gaussian splat 하위 프로세스에서 얻을 수 있는 것은 무료입니다.
추가적인 정보 없이도 얻을 수 있는 깊이 가이드
Mation [40], 그러나 다음에서 얻은 희소 포인트의 수는 다음과 같습니다.
소수의 이미지가 너무 작아서 안내할 수 없습니다.
지역성이 강한 모든 가우스 스플랫. 우리는 거친 기어를 사용합니다.
사전 훈련된 깊이를 통한 최적화를 위한 측량법 가이드
추정 모델 [5, 29, 58]. 비록 그들이 가지고 있지 않더라도
정확하고 세부적인 깊이에 대한 대략적인 가이드를 제공합니다.
최적화에 크게 기여하는 스플랫 위치
몇 번의 샷 상황에서도 안정성을 유지하고 떠다니는 현상을 방지하는 데 도움이 됩니다.
임의의 위치에서 발생하는 인공물.

3. 방법

우리의 방법은 작은 세트에서 최적화를 촉진합니다

이미지 수 $\{i\}_{k=1}^K$

$i=0, l_i \in [0, 1]^{H \times W \times 3}$. 전처리로서 -

ing, 우리는 SfM(예: COLMAP[41]) 파이프라인을 실행하고

카메라 포즈 $R_i \in \mathbb{R}^{3 \times 3}$, $t_i \in \mathbb{R}^3$, 내장 매개변수

$K_i \in \mathbb{R}^{3 \times 3}$, 포인트 클라우드 $P \in \mathbb{R}^n \times 3$. 그 정보들로-

각 픽에 대한 희소 깊이 맵을 쉽게 얻을 수 있습니다.

3

--- 페이지 4 ---

이미지, 보이는 모든 지점을 픽셀 공간으로 투영하여:

$p = \text{포모그}[R_i t_i], (1)$

및 $D_{\text{sparse}, i} = p_z \in [0, 1]^{H \times W}$. (2)

우리의 접근 방식은 3DGS[23]를 기반으로 합니다. 그들은

색상이 포함된 렌더링된 이미지를 기반으로 한 가우스 표시

손실 L_{color} 및 D-SSIM 손실 $L_{\text{D-SSIM}}$. 3DGS 이전

최적화를 통해 우리는 다음을 사용하여 각 이미지에 대한 깊이 맵을 추정합니다.

깊이 추정 네트워크를 만들고 희소 깊이 맵에 맞춥니다.

섹션 3.1). Gaussian 세트에서 깊이를 렌더링합니다.

색상 래스터화 프로세스를 활용한 스플래팅 및 추가

이전에 조밀한 깊이를 사용한 깊이 제약(섹션 3.2).

우리는 사이의 부드러움을 위해 추가 제약 조건을 추가합니다.

인접 픽셀의 깊이(섹션 3.3) 및 최적화 개선

몇 장 촬영 설정에 대한 옵션 옵션(섹션 3.4)

3.1. Dense Depth Prior 준비

스플랫을 그럴듯한 기하학으로 유도하는 것을 목표로,

우리는 다음과 같은 이유로 전역 기하학 정보를 제공해야 합니다.

가우시안 스플랫(Gaussian splats)의 지역성. 밀도 깊이는 다음 중 하나입니다.

이전에는 유망한 기하학이 있었지만 도전 과제가 있습니다.

그것을 건설하고 있습니다. SfM 포인트의 밀도는 다음에 따라 달라집니다.

이미지 수가 너무 많아서 유효한 포인트 수가 너무 많습니다.

몇 장의 샷 설정에서 조밀한 깊이를 직접 추정하려면 작습니다.

(예를 들어 19개 이미지의 SfM 재구성은

평균 0.04%의 유효 픽셀을 갖는 희소 깊이 맵. [40])

최신 깊이 완성 모델도 완성에 실패

상당한 정보 격차로 인해 깊이가 뭉뚱합니다.

깊이를 미리 설계할 때 주의해야 할 사항은 다음과 같습니다.

거친 깊이라도 스플랫을 안내하는 데 크게 도움이 됩니다.

그리고 강한 얼룩으로 인한 인공물을 제거합니다.

잘못된 기하학. 그러므로 우리는 최첨단 기술을 사용합니다.

단안 깊이 추정 모델 및 스케일 매칭

최적화를 위해 거칠고 조밀한 깊이 가이드를 제공합니다. 에서

열차 이미지 I, 단안 깊이 추정 모델 F

밀도가 높은 깊이 Ddense를 출력합니다.

$D_{dense} = s \cdot F(I) + t.$ (3)

추정된 조밀 깊이의 스케일 모호성을 해결하기 위해

Ddense, 추정 깊이의 스케일 s와 오프셋 t를 조정합니다.

SfM 깊이를 희소화하려면 Dsparse:

$s^*, t^* = \arg \min$

s, t

X

$p \in D_{sparse}$

$w(p) \cdot D_{sparse}(p) \quad D_{dense}(p; s, t)$

2

,

(4)

여기서 $w \in [0, 1]$ 은 다음을 나타내는 정규화된 가중치입니다.

역수로 계산된 각 특징점의 책임

SfM의 재투영 오류입니다. 마지막으로 광고를 사용합니다.

정의된 밀도 깊이 D^*

밀도 $= s^* \cdot F(I) + t^*$ 를 정규화합니다.

가우스 스플래팅의 최적화 손실.

3.2. 래스터화를 통한 깊이 렌더링

3D 가우스 스플래팅은 래스터화 파이프라인을 활용합니다. [1]

단절되고 구조화되지 않은 스플랫 레버를 렌더링하려면 -

GPU의 병렬 아키텍처를 기반으로 합니다. 차이점을 기반으로

발효 가능한 포인트 기반 렌더링 기술 [26, 50, 55],

-를 통해 표시를 래스터화하여 이미지를 렌더링합니다.

블렌딩. 포인트 기반 접근 방식은 유사한 방정식을 활용합니다.

NeRF 스타일 볼륨 렌더링으로 픽셀 색상 래스터화

해당 픽셀을 덮는 정렬된 포인트로,

$C =$

X

나는 $\in N$

$C_i = i T_i$ (5)

여기서 $T_i =$

$i = 1 \dots Y$

$j = 1$

$(1 \dots j)$,

C 는 픽셀 색상, c 는 스피클렛 색상, 여기서 ρ 는 학습된 불투명도에 2D 가우스의 공분산을 곱한 값 시안. 이 제형은 불투명한 스피클렛의 색상을 우선시합니다. 카메라에 더 가깝게 배치되어 사진에 큰 영향을 미칩니다. 최종 결과 C . 심도 구현에서 영감을 얻었습니다.

NeRF는 래스터화 파이프라인을 활용하여

가우시안 스피클렛의 깊이 맵,

$D_i =$

X

$N \in \mathbb{N}$

$D_i = i T_i$, (6)

여기서 D 는 렌더링된 깊이이고 $d_i = (R_i p_i + T_i) z$ 는

카메라의 각 스피클렛 깊이. 방정식. (6)은

Eqn에서 계산된 ρ_i 와 T_i 의 직접 활용. (5), 시실-

최소한의 계산으로 빠른 깊이 렌더링 반복

로드. 마지막으로 렌더링된 깊이를 추정된 깊이로 안내합니다.

L_1 거리를 이용한 조밀한 깊이,

깊이 =

$D = D^*$

밀도가 높은

1 (7)

3.3. 감독되지 않은 평활도 제약 조건

각각 독립적으로 추정된 깊이가 적합했음에도 불구하고

COLMAP 지점과 관련하여 충돌이 자주 발생합니다. 우리는-

지오메트리를 원활하게 하기 위해 감독되지 않은 제약 조건을 도입합니다.

갈등을 정규화하기 위해 [20]에서 영감을 얻었습니다. 이 콘 -

변형은 유사한 3D 위치에 있는 포인트가 시뮬레이션을 가짐을 의미합니다.

이미지 평면의 일라 깊이. Canny Edge를 활용합니다.

감지기 [8]를 마스크로 사용하여 규칙적으로

깊이에 상당한 차이가 있는 영역을 지정합니다.

경계. 깊이 d_i 와 인접한 깊이 d_j 에 대해 우리는

그들 사이의 차이를 정규화하십시오.

$L_{smooth} =$

X

$D_j \in \text{adj}(D_i)$

$1 \text{개}(D_i, D_j) \cdot$

$D_i - D_j$

2

(8)

여기서 1ne은 둘 다인지 여부를 나타내는 표시 함수입니다.

깊이는 가장자리에 있지 않습니다.

4

--- 페이지 5 ---

PSNR↑ SSIM↑ LPIPS↓

2뷰 3뷰 4뷰 5뷰 2뷰 3뷰 4뷰 5뷰 2뷰 3뷰 4뷰 5뷰

NeRF-LLFF[31]

양치류

3DGS 13.03 14.29 16.73 18.59 0.336 0.408 0.517 0.603 0.476 0.389 0.296 0.217

당사 17.59 19.13 19.91 20.55 0.516 0.588 0.616 0.642 0.286 0.232 0.203 0.167

오라클 18.18 20.30 20.78 21.81 0.524 0.636 0.654 0.701 0.278 0.201 0.185 0.157

꽃

3DGS 14.90 17.75 19.71 21.39 0.351 0.508 0.605 0.671 0.406 0.257 0.190 0.146

당사 15.92 17.80 19.15 20.45 0.395 0.445 0.538 0.576 0.414 0.376 0.323 0.293

오라클 19.71 22.16 23.26 24.65 0.570 0.673 0.714 0.760 0.250 0.163 0.128 0.097

요새

3DGS 13.87 15.98 19.26 19.98 0.363 0.492 0.609 0.631 0.389 0.283 0.201 0.191

당사 19.80 21.85 23.07 23.72 0.567 0.655 0.724 0.740 0.232 0.191 0.162 0.144

오라클 23.07 24.51 26.39 26.73 0.654 0.728 0.787 0.797 0.159 0.130 0.100 0.093

별

3DGS 11.43 12.48 13.76 14.75 0.264 0.339 0.433 0.498 0.531 0.464 0.395 0.350

당사 15.91 16.22 18.09 18.39 0.420 0.466 0.527 0.565 0.362 0.349 0.306 0.296

오라클 18.56 20.08 20.88 22.52 0.568 0.644 0.668 0.725 0.259 0.212 0.199 0.168

나뭇잎

3DGS 12.33 12.36 12.49 12.26 0.260 0.275 0.298 0.297 0.412 0.397 0.397 0.401

당사 13.04 13.63 13.97 14.13 0.235 0.270 0.283 0.297 0.460 0.445 0.440 0.438

오라클 13.52 14.23 14.78 14.85 0.287 0.353 0.377 0.397 0.380 0.348 0.341 0.356

난초

3DGS 11.78 13.94 15.41 16.08 0.182 0.320 0.416 0.460 0.426 0.310 0.245 0.219

당사 12.88 14.71 15.40 16.13 0.216 0.297 0.343 0.391 0.462 0.383 0.366 0.352

오라클 14.89 16.45 17.42 18.45 0.365 0.471 0.525 0.576 0.303 0.237 0.200 0.174

방

3DGS 10.18 11.51 11.59 12.21 0.404 0.494 0.510 0.552 0.606 0.559 0.556 0.515

당사 17.21 18.11 18.87 19.63 0.668 0.719 0.732 0.757 0.352 0.360 0.326 0.295

오라클 20.66 22.31 23.80 24.59 0.758 0.801 0.839 0.864 0.217 0.188 0.160 0.156

트렉스

3DGS 10.72 11.72 13.11 14.14 0.322 0.417 0.492 0.548 0.520 0.446 0.394 0.351

당사 14.90 15.90 16.75 17.37 0.480 0.537 0.567 0.625 0.358 0.362 0.348 0.305

오라클 17.76 19.58 20.84 22.83 0.591 0.669 0.714 0.786 0.284 0.226 0.192 0.134

평균

3DGS 12.25 13.75 15.26 16.17 0.306 0.407 0.485 0.533 0.471 0.388 0.334 0.299

당사 15.94 17.17 18.15 18.74 0.439 0.497 0.541 0.571 0.365 0.337 0.309 0.288

오라클 18.29 19.95 21.02 22.05 0.539 0.622 0.660 0.701 0.266 0.213 0.188 0.167

표 1. NeRF-LLFF[30] 데이터세트의 정량적 결과. oracle을 제외한 최고의 성능은**bolded**입니다.

우리는 다음을 통합하여 최종 손실 조건을 결론짓습니다.

Eqn의 깊이 손실. (7) 매끄러움 손실 및 매끄러움-
Eqn의 네스 손실. (8) 자체 하이퍼파라미터 사용
깊이 및 매끄러움:

$$L = (1 - \text{ssim})L_{\text{color}} + \text{ssim}L_{\text{LD-SSIM}} \\ + \text{깊이}L_{\text{깊이}} + \text{매끄러움}L_{\text{매끄러움}}$$

(9)

여기서 앞의 두 손실 항 L_{color} , LD-SSIM은 다음과 같습니다.

원래의 3D 가우스 스플래팅 손실에 응답합니다. [23]

3.4. Few-Shot 학습을 위한 수정

원본에서 두 가지 최적화 기술을 수정합니다.

제한된 이미지로 3D 장면을 만들 수 있는 종이입니다. 기술은-
3DGS에 사용된 나이키는 다음과 같은 가정 하에 설계되었습니다.

잠재적으로 상당한 수의 이미지를 활용하는 것
몇 번의 샷 설정에서 수렴을 방해합니다. 반복을 통해-
실제 실험을 통해 이를 확인하고 기술을 수정합니다.
몇 장 촬영 설정에 맞게 조정하십시오. 첫째로, 우리는 최대 de-를 설정했습니다.

구면 고조파(SH)의 값을 1로 설정합니다. 이렇게 하면 과적합을 방지할 수 있습니다.

높은 원인이 되는 구면 고조파 계수의 계산

정보가 부족해서 자주 발생합니다. 둘째, 우리는

깊이 손실을 기반으로 조기 중지 정책을 구현합니다. 우리

Eqn을 구성합니다. (9) 주로 색 손실에 의해 유발되고,

깊이 손실과 부드러움 손실을 다음과 같이 사용합니다.

지도 요인. 따라서 점차적으로 과적합이 발생하게 됩니다.

색상 손실이 가장 큰 영향을 미칩니다. 우리는 mov-를 사용합니다.

스플랫이 표시될 때 최적화를 중단하기 위해 평균 깊이 손실을 적용합니다.

깊이 가이드에서 벗어나기 시작합니다. 마지막으로, 우리는

주기적인 재설정 프로세스. 불투명도를 재설정하는 것을 관찰합니다.

모든 표시의 는 되돌릴 수 없고 해로운 결과를 초래합니다.

Quences. 제한된 정보로 인해 정보가 부족합니다.

스플랫의 불투명도를 복원할 수 없기 때문에

모든 표시가 제거되었거나 갇혀 있던 narios

예상치 못한 결과와 최적화를 유발하는 로컬 최적화

실패. 앞서 언급한 기술의 결과로,

퓨샷 학습으로 안정적인 최적화를 달성합니다.

4. 실험

4.1. 실험 설정

데이터 세트. NeRF-LLFF에 대한 방법을 평가합니다 [30]

데이터세트. NeRF-LLFF에는 전방을 향한 8개의 장면이 포함되어 있습니다.

카메라를 사용하여 각 장면의 이미지를 기차로 나눕니다.

그리고 테스트 세트. 우리는 캠의 이미지 외부 가장자리를 사용합니다.

볼록 선체 알고리즘을 기반으로 한 열차 세트로서의 시대 그룹 -

전방을 향한 카메라 분포로 인해 리듬 [36].

각 실험마다 k-shot으로 장면을 최적화합니다.

(k=2,3,4,5) 열차 세트에서 무작위로 선택된 이미지와

동일한 테스트 세트에서 평가합니다. 무작위로 선택된 10개를 사용합니다.

씨앗을 뿌리고 10번의 실험 평균을 보고합니다.

5

--- 페이지 6 ---

- (iv) 뿔 (iii) 요새 (ii) 방 (i) 양치류
- 5뷰 2뷰 5뷰 2뷰 5뷰 2뷰 5뷰 2뷰
- (가) GT
- (b) 3DGS[23](RGB)
- (c) 3DGS [23] (깊이)
- (d) 당사(RGB)
- (e) 우리 것(깊이)

그림 3. NeRF-LLFF [30] 데이터 세트의 정성적 비교. 3D 가우스 스플래팅(3DGS) [23] 간의 차이를 시각화합니다. 2뷰 및 5뷰 설정 모두에서 우리의 방법을 살펴보겠습니다. 주로 색상 손실로 인해 3DGS는 원하는 형상을 달성하는 데 어려움을 겪었습니다. 우리의 접근 방식은 깊이 안내를 통해 그럴듯한 기하학적 구조를 일관되게 확립하여 우수한 재구성 결과를 가져옵니다.

6

--- 페이지 7 ---

- (아)
- (비)
- (다)
- (디)

그림 4. 잘린 패치의 세부정보. (a) 입력 화면 (b) 3DGS [23] (c) 당사의 것 (d) Ground Truth. 우리의 방법은 다음과 같은 결과를 낳습니다. 3DGS[23]와 비교한 주변 재구성 결과

추가적인 기하학적 단서. 우리의 방법은 안정적인 기하학적 구조를 확립합니다. 시도해 보세요. 재구성 품질에서 3DGS를 능가합니다.

구현 세부정보 공정한 비교를 위해 옵션이 다르기 때문에 통일된 좌표를 사용하는 것이 필수적입니다. 각 장면에서 평가 값을 표준화합니다. 우리 장면의 전체 이미지를 처리하여 이를 달성합니다. COLMAP을 통해 일관된 카메라 포즈를 얻고, 특징 포인트, 각 k-shot ex와 관련된 특징 포인트 선택 주변. 기차 세트에서 k개의 카메라를 선택하고 적어도 3개 이상에서 보이는 특징점을 추출합니다. k 카메라 중. 우리는 이러한 특징점을 깊이 가이드로 사용합니다. Eqn의 Dsparse. (4) 및 Gaussian splat의 초기점

팅 최적화. 기준선(3DGS)에서는 동일한 것을 사용합니다. k개의 카메라 포즈와 동일한 필터링된 초기 지점, 보고서-원본과 마찬가지로 30,000번의 반복으로 평가값을 계산합니다. 설정. 오라클의 경우, 우리는 효율성을 설명하는 것을 목표로 합니다. 정확한 깊이. 우리는 최적화를 통해 pseudo-GT 깊이를 생성합니다. 기차와 테스트의 전체 이미지를 촬영합니다. 우리는 교체한다 pseudo-GT 깊이를 사용하여 우리 방법에서 추정된 깊이 그리고 그 결과를 오라클로 보고합니다. 마지막으로 우리는 Eqn에 설명된 미분 가능 깊이 래스터라이저. (6) 기반

쿠다.

4.2. 실험 결과

우리의 방법인 3DGS의 비교 결과를 제시합니다.
 표 1의 NeRF-LLFF 장면에 대한 Oracle 및 Oracle.
 방법과 장면, 사용되는 IM 수가 감소합니다.
 나이가 들수록 시각적 품질이 지속적으로 저하됩니다. 우리의 방법

일반적으로 3DGS에 비해 우수한 결과를 보여줍니다.
 특히 이미지 수가 제한되어 있는 경우에는 더욱 그렇습니다. 그림 3
 3DGS와 우리 방법의 차이점을 시각화합니다.

방법 2-뷰 5-뷰

PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

조정 없음 7.86 0.319 0.740 10.01 0.346 0.761 (3.1절)

w/o L 깊이 11.49 0.344 0.533 12.97 0.506 0.418 (3.2절)

w/o L smooth 포함 14.75 0.415 0.391 17.79 0.561 0.297 (3.3절)

조기 정지 없음 13.99 0.345 0.433 17.28 0.494 0.333 (3.4절)

당사 15.91 0.420 0.362 18.39 0.565 0.296

표 2. 절제. 우리는 각 엘에 대한 절제 연구를 설명합니다.

제안된 방법의 구현. 실험도 선보입니다

Dense 대신 COLMAP의 희박한 깊이로 감독

깊이. 보고된 값은 Horns에서 평가됩니다.

초기화 2개 보기 5개 보기

포인트 PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

COLMAP from 19.80 0.567 0.232 23.72 0.740 0.144 sparse-view (당사)

비투영 16.39 0.457 0.281 19.15 0.569 0.222 from D*dense

COLMAP 21.18 0.681 0.200 24.09 0.778 0.127 전면에서

표 3. 초기화 방법 비교 우리는

제안된 방법의 각 요소에 대한 절제 연구. 우리

또한 희박한 깊이를 감독하는 실험을 제시합니다.

충충한 깊이 대신 COLMAP. 보고된 값은 평가되었습니다.

요새에서 uated.

깊이 맵은 3DGS의 기하학적 오류를 강조합니다.

소수 사건. 예를 들어, the Fern의 2뷰에서는

시뮬레이션에 비해 완전히 잘못된 형상을 표시합니다.

RGB의 일리티. 2뷰 시나리오와 같은 열악한 조건에서는

3DGS는 종종 적절한 형상을 형성하지 못합니다. 대조적으로,

우리의 방법은 그럴듯한 기하학을 형성하는 동시에

매력적인 이미지. 우리는 그림에 추가 예를 제시합니다.

4. 잘린 패치는 우리의 방법이

심층적인 지도를 통해 더 나은 결과를 얻습니다. 따라서 우리는

깊이에 의해 제공되는 기하학적 단서가

Gaussian의 재구성에 상당히 유익합니다.

특히 이미지 수가 제한되어 있는 경우에는 튀는 현상이 발생합니다.

이는 놀라운 성능을 통해 다시 확인됩니다.

정확한 기하학을 사용하는 오라클의. 전-

오라클의 풍부한 이미지는 오라클의 효율성을 입증합니다.

그림 5와 같이 정확한 깊이를 제공합니다. 풍부한 정보는

pseudo-GT 깊이가 제공하는 옵션을 통해 다음을 생성할 수 있습니다.

제한된 인원으로도 상세하고 신뢰할 수 있는 결과를 얻을 수 있습니다.

이미지.

주목해야 할 중요한 관찰은 실질적인 재검토입니다.

사전 훈련된 단안 깊이에 대한 우리의 접근 방식

추정 모델. 우리는 사전 훈련된 모델을 활용합니다.

ZoeDepth [5] 실내 데이터 세트 NYU Depth에 대해 훈련됨

v2 [42] 및 도시 데이터 세트 KITTI [28]. 결과적으로 우리 모델은

실내 장면에서 상대적으로 더 높은 성능을 보고합니다.

(Fortress, Room, Fern) 및 비교적 나쁜 결과

7

--- 페이지 8 ---

그림 5. 의사 GT 깊이를 활용한 결과 예(oracle) 정확한 깊이로 인해 고품질 3D 재구성이 가능합니다.

제한된 수의 이미지. RGB와 깊이 모두에서 미세한 디테일을 인지할 수 있습니다.

자연스러운 장면(난초, 꽃)용. 나뭇잎에 주목하세요

COLMAP에 대한 과제를 제시하며 일반적으로

성공적인 가우스 스플래팅 훈련.

4.3. 절제

우리는 생산의 각 구성 요소에 대한 절제 연구를 제시합니다.

표 2에 제시된 방법. 첫 번째와 두 번째 행은

절대 깊이 안내의 필요성을 설명합니다. 없이

섹션 3.1의 조정 과정, Dense Depth Ddense

단안 심도 추정의 척도가 잘못되었습니다.

모델. 깊이가 카메라 본질과 잘못 정렬되었습니다.

COLMAP의 sic 매개변수를 사용하여 완전한 교육으로 이어짐

실패. 우리는 또한 단독으로 최적화 실패를 관찰했습니다.

깊이가 없는 감독되지 않은 부드러운 제약 조건 활용

섹션 3.2에 감독이 도입되었습니다. 의 적용

절대 기하학이 없는 부드러움 제약

비전은 기준선에 비해 더 나쁜 결과를 산출합니다. 는

표 2의 세 번째와 네 번째 행은

추가 기술을 통한 성능 향상. 와

깊이 감시 D^*

조밀하고 부드러움 제약 조건

3.3절은 기업의 성과 향상에 기여한다.

추가적인 기하학적 단서를 제공합니다. 특히, 조기 정지

섹션 3.4에 소개된 메커니즘은 다음에서 중추적인 역할을 합니다.

우리의 접근 방식 내에서 성능 저하를 방지합니다.

깊이 손실을 활용하여

규정된 지오메트리 가이드의 표시가 효과적으로 정지됩니다.

잠재적인 과적합 사례를 발생시킵니다.

Table 3에서는 두 기업 간의 성능을 비교하였다.

다양한 가우스 스플래팅 초기화. 두 번째 행

포인트 클라우드 프로를 활용했을 때의 결과를 보여줍니다.

밀도가 높은 깊이 D 를 투영하지 않음으로써 유도됨*

초기화만큼 조밀함

포인트. un-를 통해 생성된 수많은 초기 포인트

투영이 효과적으로 병합되거나 정리되지 않아
 Sparse COLMAP ini에 비해 성능이 낮습니다.
 초기화. 그에 비해 세 번째 결과는
 행은 모든 COLMAP 포인트를 활용한다고 가정합니다. 고용-
 에서는 달성할 수 없는 다수의 유리한 초기 지점을 확보합니다.
 k 이미지는 다음을 통해 성과 향상에 기여합니다.
 조밀한 깊이 조정 및 초기화.
 5. 한계와 향후 과제
 우리의 접근 방식은 Gaussian의 타당성을 입증했습니다.
 깊이를 통한 몇 번의 샷 설정으로 스피래팅 최적화
 안내하고 있지만 한계가 있습니다. 첫째, 의존도가 크다.
 단안 심도 추정 성능에 관한
 추정 모델. 게다가 이 모델의 깊이 추정은
 학습된 데이터 작업에 따라 성능이 달라질 수 있습니다.
 결과적으로 Gaus-의 성능에 영향을 미칩니다.
 시안 스피래팅 최적화. 게다가 피팅에 의존하여
 COLMAP 지점에 대한 추정 깊이는 종속성을 의미합니다.
 COLMAP의 성능이 저하되어 불가능해집니다.
 질감이 없는 평원이나 까다로운 표면을 다루는 경우
 COLMAP이 실패할 수 있습니다. 최적화 작업은 향후 작업으로 남겨둡니다.
 오히려 상호의존적인 추정 깊이에 의한 3D 장면의 생성
 COLMAP 포인트보다 또한 정기적인 방법을 모색하고 있습니다.
 다양한 데이터세트에 걸쳐 지오메트리를 조정합니다.
 하늘과 같은 깊이 추정은 어려울 수 있습니다.
 미래의 일을 위한 또 다른 길.

6. 결론

이 연구에서는 심도 정규화된 최적화(Depth-Regularized Optimization)를 소개합니다.
 Few-Shot 이미지의 3D Gaussian Splatting을 위한 모델
 작은 숫자로 3D Gaussian splatting을 학습하기 위한 것
 이미지. 우리 모델은 깊이를 사용하여 스피래팅을 정규화합니다.
 그러한 기하학적 안내의 효과를 입증합니다.
 에이스. 조밀한 깊이 안내를 얻기 위해 우리는 단일 장치를 활용합니다.
 깊이 추정 모델을 기반으로 깊이 척도를 조정합니다.
 SfM 포인트에. 우리는 프로의 효율성을 조사했습니다.
 깊이 손실, 감독되지 않은 부드러운 제약, 초기
 NeRF-LLFF 데이터세트의 정지 기술. 우리의 방법은-
 몇 장의 샷 설정에서 3D 가우스 스피래팅을 수행합니다.
 그럴듯한 기하학을 먹는 것. 마지막으로 우리는 다음을 통해 시연했습니다.
 깊이와 초기화를 개선한 추가 실험
 포인트를 사용하면 Gauss의 성능이 크게 향상됩니다.
 sian splatting 기반 3D 재구성.

8

--- 페이지 9 ---

참고자료

[1] Tomas Akenine-Möller, Eric Haines 및 Naty Hoffman.
 실시간 렌더링. CRC프레스, 2019. 4

- [2] Dejan Azinovi 'c, Ricardo Martin-Brualla, Dan B Goldman, 마티아스 니스너(Matthias Nießner), 유스투스 티에스(Justus Thies). 신경 RGB-D 표면 재건축. IEEE/CVF 컨퍼런스 진행 중 컴퓨터비전 및 패턴인식에 관한 논문, 2022. 3
- [3] 조나단 T 배런, 벤 밀든홀, 매튜 탄식, 피터 Hedman, Ricardo Martin-Brualla 및 Pratul P Srinivasan. Mip-nerf: 엔티앨리어싱 중립을 위한 다중 스케일 표현 ral 래디언스 필드. IEEE/CVF Interna- 컴퓨터 비전 컨퍼런스, 2021. 1, 2
- [4] 조나단 T 배런, 벤 밀든홀, 도르 베르빈, 프라툴 P 스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한 엔티앨리어싱된 신경 방사 필드. 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인정, 2022. 2
- [5] Shariq Farooq Bhat, Reiner Birkel, Diana Wofk, 피터 Wonka, Matthias Müller. ZoeDepth: 제로샷 트랜스-상대 깊이와 미터법 깊이를 결합하여 결정합니다. arXiv 사전 인쇄 arXiv:2302.12288, 2023. 2, 3, 7
- [6] Wenjing Bian, Zirui Wang, Kejie Li, Jiawang Bian 및 Vic-Adrian Prisacariu에게. 너프 없음: 신경 복사 최적화 포즈가 없는 필드. 2023. 2
- [7] Hongrui Cai, Wanquan Feng, Xuetao Feng, Yan Wang 및 장주용. 동적 신경 표면 재구성 단안 RGB-D 카메라를 사용한 장면. 신경의 발전 정보처리시스템, 2022. 3
- [8] 존 캐니. 가장자리 감지에 대한 계산적 접근 방식입니다. 패턴 분석 및 기계 지능에 관한 IEEE 거래 젠젠, 1986. 4
- [9] Eric R Chan, Connor Z Lin, Matthew A Chan, Koki Nagano, Boxiao Pan, Shalini De Mello, 오라치오 갈로, 레오니다스 J Guibas, Jonathan Tremblay, Sameh Khamis 등 효율적-고대 기하학을 인식하는 3D 생성적 적대 네트워크. 에서 CVPR, 2022. 2
- [10] 안페이 첸(Anpei Chen), Zexiang Xu, 안드레아스 가이거(Andreas Geiger), 징이 유(Jingyi Yu), 하오수. Tensorf: Tensorial radiance field. ECCV, 2022. 2
- [11] Zhiqin Chen, Thomas Funkhouser, Peter Hedman 및 안드레아 탈리아사키. Mobilenerf: 폴리곤 ras 활용하기 효율적인 신경장 렌더링을 위한 최적화 파이프라인 담즙 아키텍처. CVPR에서는 2023. 1, 2
- [12] Roger A Crawfis와 Nelson Max. 3D용 텍스처 표시 스칼라 및 벡터 필드 시각화. 절차에서 시각적-화'93, 1993. 1
- [13] Kangle Deng, Andrew Liu, Jun-Yan Zhu 및 Deva Ra-마난. 깊이 감독 너프: 보기가 적고 훈련 속도가 빨라집니다. 무료로 합니다. IEEE/CVF 회의 진행 중

컴퓨터비전 및 패턴인식, 2022. 3

[14] Nianchen Deng, Zhenyi He, Jiannan Ye, Budmonde Duinkharjav, Praneeth Chakravarthula, Xubo Yang 및 Qi 일요일. Fov-nerf: 가상을 위한 Foveated 신경 복사 필드 현실. 시각화 및 컴퓨터에 대한 IEEE 거래 그래픽, 2022. 1

[15] Arnab Dey, Yassine Ahmine, Andrew I Comport. mip-nerf rgb-d: 깊이 지원 빠른 신경 복사장. arXiv 사전 인쇄 arXiv:2205.09351, 2022. 3

[16] Sara Fridovich-Keil, Alex Yu, Matthew Tancik, Qinhong 첸, 벤저민 레히트, 가나자와 양주. 플레녹셀: 신경망이 없는 래디언스 필드. CVPR에서는 2022. 2, 3

[17] 후루카와 야스타카, Carlos Hern 'andez, 외. 멀티뷰 스테레오: 튜토리얼. 컴퓨터의 기초 및 동향® 그래픽과 비전, 2015. 3

[18] Kyle Gao, Yina Gao, Hongjie He, Dening Lu, Linlin Xu 및 조나단 리. Nerf: 3D 비전의 신경 방사 필드, 종합적인 검토. arXiv 사전 인쇄 arXiv:2210.00379, 2022. 2

[19] 스테판 J 가빈, 마렉 코왈스키, 매튜 존슨, 제이미 쇼튼, 줄리앙 발렌틴. Fastnerf: 충실도가 높은 신경망 200fps로 렌더링합니다. ICCV에서는 2021. 2

[20] 클레망 고다르, 오이신 맥 아오다, 가브리엘 J 브라더스 견인. 왼쪽을 이용한 감독되지 않은 단안 깊이 추정 올바른 일관성. IEEE 회의 진행 중 컴퓨터비전과 패턴인식에 관한 연구, 2017. 4

[21] Xian-Feng Han, Hamid Laga, Mohammed Bennamoun. 이미지 기반 3D 객체 재구성: 최첨단 및 딥러닝 시대의 트렌드. 파미, 2019. 2

[22] Richard Hartley와 Andrew Zisserman. 다중 뷰 지역-컴퓨터 비전의 측량법. 케임브리지 대학 출판부, 2003. 2

[23] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler, 그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅 래디언스 필드 렌더링. TOG, 2023. 1, 2, 3, 4, 5, 6, 7

[24] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler, 그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅 래디언스 필드 렌더링. 그래픽에 대한 ACM 트랜잭션, 2023. 1

[25] 김미정, 서성욱, 한보형. 정보: 소수의 신경 볼륨 렌더링을 위한 광선 엔트로피 최소화 데링. IEEE/CVF 회의 진행 중 컴퓨터비전 및 패턴인식, 2022. 3

[26] 게오르기오스 코파나스(Georgios Kopanas), 줄리앙 필립(Julien Philip), 토마스 라임크 uhler, 조지 드레타키스. Per-를 사용한 포인트 기반 신경 렌더링 뷰 최적화. 컴퓨터 그래픽 포럼에서, 2021. 4

[27] Lingjie Liu, Jiatao Gu, Kyaw Zaw Lin, Tat-Seng Chua 및 크리스티안 테오발트. 신경 회소 복셀 필드. 닙스, 2020.

2

[28] 모리츠 멘체와 안드레아스 가이거. 객체 장면 흐름

자율주행차. IEEE 컨퍼런스 진행 중

컴퓨터비전과 패턴인식에 관한 연구, 2015. 7

[29] Alican Mertan, Damien Jade Duff, Gozde Unal. 싱글 이미지 깊이 추정: 개요. 디지털 신호 프로-

2022. 3 종료

[30] 벤 밀든홀, 프라툴 P. 스리니바산, 로드리고 오르티즈-카운, 니마 카데미 칼란타리(Nima Khademi Kalantari), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng) 아비셰크 카르. 국소광장융합: 실용시각합성
규정적인 샘플링 지침을 따르는 sis.ACM 거래
그래픽(TOG), 2019. 2, 5, 6

[31] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik, 조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프:

9

--- 페이지 10 ---

뷰 동기화를 위해 장면을 신경 방사 필드로 표현

논문. ACM 커뮤니케이션, 2021. 1, 2, 5

[32] Thomas Müller, Fabrice Rousselle, Jan Novák 및 Alexander Keller. 경로 추적을 위한 실시간 신경 복사 캐싱
ing. arXiv 사전 인쇄 arXiv:2106.12372, 2021. 2

[33] Thomas Müller, Alex Evans, Christoph Schied 및 Alexander Keller. 다중 해상도를 갖춘 즉각적인 신경 그래픽 프리미티브
솔루션 해시 인코딩. TOG, 2022. 2

[34] 토마스 네프, 파스칼 슈타들바우어, 마티아스 파저, 안드레아스 Kurz, Joerg H Mueller, Chakravarty R Alla Chaitanya, Anton Kaplanyan, Markus Steinberger. 도네르프: 향해
다음을 사용하여 소형 신경 방사 필드의 실시간 렌더링
깊이 있는 오라클 네트워크. 컴퓨터 그래픽 포럼, 2021.

3

[35] 마이클 니마이어, 조나단 T 배런, 벤 밀든홀, Mehdi SM Sajjadi, Andreas Geiger 및 Noha Radwan. 등록-
nerf: 뷰 합성을 위한 신경 복사 필드 정규화
희박한 입력에서. IEEE/CVF 회의 진행 중
컴퓨터 비전 및 패턴 인식에 대한 참조 자료, 2022.

3

[36] Franco P Preparata 및 Michael I Shamos. 전산
기하학: 소개. Springer 과학 및 비즈니스 Me-
다이어, 2012. 5

[37] Malte Prinzler, Otmar Hilliges 및 Justus Thies. 식당:
깊이 인식 이미지 기반 신경 방사 필드. 프로에서는
컴퓨터 비전에 관한 IEEE/CVF 회의의 결과
및 패턴인식, 2023. 3

- [38] 마이클 리드. 현대 수학 물리학의 방법: 기능 분석. 엘스비어, 2012. 1
- [39] Christian Reiser, Songyou Peng, Yiyi Liao 및 Andreas Gaijer. Kilonerf: 신경 복사장 속도 향상 수천 개의 작은 mlps. ICCV에서는 2021. 2
- [40] 바바라 로슬(Barbara Roessle), 조나단 T 배런(Jonathan T Barron), 벤 밀든홀(Ben Mildenhall), Pratul P Srinivasan, Matthias Nießner. 밀도가 높은 깊이 또는 희소 입력 보기의 신경 복사 필드에 대한 것입니다. 에서 컴퓨터 비디오에 관한 IEEE/CVF 컨퍼런스 진행 시온과 패턴인식, 2022. 3, 4
- [41] Johannes L Schonberger 및 Jan-Michael Frahm. 구조-모션에서 재검토되었습니다. CVPR, 2016. 2, 3
- [42] Nathan Silberman, Derek Hoiem, Pushmeet Kohli 및 Rob Fergus. 실내 분할 및 지원 추론 rgb-d 이미지. 컴퓨터 비전 -ECCV 2012: 제12회 유로-컴퓨터 비전에 관한 회의, 이탈리아 피렌체, 10월 2012년 7월 13일, 절차, 파트 V 12, 2012. 7
- [43] Cheng Sun, Min Sun 및 Hwann-Tzong Chen. 직접 복셀 그리드 최적화: 복사장을 위한 초고속 수렴 재건축. CVPR에서는 2022. 2
- [44] Ayush Tewari, Justus Thies, Ben Mildenhall, Pratul Srinivasan, 에드가 트레치크, 왕이판, 크리스토프 라스너, 빈센트 시츠만, 리카르도 마틴-브루알라, 스티븐 롬바르디, 외. 신경 렌더링의 발전. 컴퓨터 그래픽 분야 포럼, 2022. 2
- [45] 카를로 토마시(Carlo Tomasi)와 카나데 타케오(Takeo Kanade). 모양과 움직임 정사법 하의 이미지 스트림: 인수분해 방법. 국제컴퓨터비전저널, 1992. 2
- [46] 시몬 울만. 모의 구조 해석 tion. 런던 왕립학회의 회보. 시리즈 B. 생명과학과, 1979. 2
- [47] 펑왕(Peng Wang), 류링지에(Lingjie Liu), 류위안(Yuan Liu), 크리스티안 테오발트(Christian Theobalt), 타쿠(Taku Goma), 왕웬핑. Neus: 신경 암묵적 학습 다중 뷰 재구성을 위한 볼륨 렌더링별 표면. arXiv 사전 인쇄 arXiv:2106.10689, 2021. 2
- [48] Zirui Wang, Shangzhe Wu, Weidi Xie, Min Chen 및 빅터 아드리안 프리사카리우. Nerf-: 신경 복사장 알려진 카메라 매개 변수가 없습니다. arXiv 사전 인쇄 arXiv:2102.07064, 2021. 3
- [49] Yi Wei, Shaohui Liu, Yongming Rao, Wang Zhao, Jiwen Lu, 그리고 주 지에. Nerfingmvs: 신경 최적화 안내 실내 멀티뷰 스테레오를 위한 래디언스 필드. 절차 중 컴퓨터 Vi에 관한 IEEE/CVF 국제 컨퍼런스의 시온, 2021. 3
- [50] 올리비아 와일즈, 조지아 기옥사리, 리차드 스젤리스키, 저스틴 존슨. Synsin: sin-에서 엔드투엔드 뷰 합성

글 이미지. IEEE/CVF 회의 진행 중

컴퓨터비전과 패턴인식, 2020. 4

[51] 시에 이헨, 타키카와 토와키, 사이토 쉐스케, 또는 리타니, Shiqin Yan, Numair Khan, Federico Tombari, James Tompson, Vincent Sitzmann 및 Srinath Sridhar. 신경장 비주얼 컴퓨팅 그 이상. 컴퓨터 그래픽 포럼, 2022. 2

[52] Qiangeng Xu, Zexiang Xu, Julien Philip, Sai Bi, Zhixin Shu, 칼얀 순카발리(Kalyan Sunkavalli), 울리히 노이만(Ulrich Neumann). 포인트 너프: 포인트-기반 신경 방사 필드. CVPR에서는 2022. 2, 3

[53] Chen Yang, Peihao Li, Zanwei Zhou, Shanxin Yuan, Bing-Bing Liu, Xiaokang Yang, Weichao Qiu 및 Wei Shen. 네르-ivs: 형상을 통한 자유 뷰 합성을 위한 신경 복사 필드 에트리 비계. IEEE/CVF 컨퍼런스 진행 중 컴퓨터 비전 및 패턴 인식, 2023. 3

[54] Lior Yariv, Jiatao Gu, Yoni Kasten 및 Yaron Lipman. 불-신경 암시적 표면의 ume 렌더링. Neu-의 발전 라정보처리시스템, 2021. 2

[55] 왕이판(Wang Yifan), 펠리체 세레나(Felice Serena), 우시하오(Shihao Wu), Cengiz Oztireli 및 올라 소르키네-호농. 미분 가능한 표면 스피래팅 포인트 기반 기하학 처리. ACM 거래 그래픽(TOG), 2019. 4

[56] Alex Yu, Ruilong Li, Matthew Tancik, Hao Li, Ren Ng 및 가나자와 양주. 실시간 렌더링을 위한 Plenocree 신경 방사 필드. ICCV에서는 2021. 2

[57] 카이 장, 게르노 리글러, 노아 스네이블리, 블라들렌 콜튼. Nerf++: 신경 방사도 분석 및 개선 필드. arXiv 사전 인쇄 arXiv:2010.07492, 2020. 3

[58] Wenliang Zhao, Yongming Rao, Zuyan Liu, Benlin Liu, Jie Zhou, Jiwen Lu. 텍스트와 이미지의 차이를 최대한 활용 시각적 인식을 위한 융합 모델. arXiv 사전 인쇄 arXiv:2303.02153, 2023. 3

[59] Chao Zhou, Hong Zhang, Xiaoyong Shen 및 Jiaya Jia. 안-스테레오 매칭의 지도 학습. 의 절차에서 IEEE 컴퓨터 비전 국제 컨퍼런스, 2017. 3

10

[논문 11] DNGaussian 본문 전체 번역

--- 페이지 1 ---

DNGaussian: 최소 뷰 3D 가우스 래디언스 필드 최적화

글로벌-로컬 깊이 정규화

Jiahe Li¹, Jiawei Zhang¹, Xiao Bai^{1*}, Jin Zheng¹, Xin Ning², Jun Zhou³, Lin Gu^{4,5}

¹컴퓨터 과학 및 공학부 국가 핵심 연구실

복잡하고 중요한 소프트웨어 환경, Beihang University Jiangxi Research Institute

²중국과학원 반도체연구소

³그리피스대학교 정보통신기술대학원

⁴RIKEN AIP ⁵도쿄대학

그림 1. 최첨단 FreeNeRF [53] 및 SparseNeRF [42]와 훈련을 위해 세 가지 뷰를 활용하는 DNGaussian 비교.

DNGaussian은 25배의 놀라운 감소로 비교적 높은 품질의 합성 뷰와 뛰어난 디테일을 제공함으로써 두각을 나타냅니다.

가장 빠르고 유일한 실시간 렌더링 속도인 300을 달성하면서 훈련 중에 시간을 절약하고 메모리 오버헤드를 크게 낮춥니다.

FPS. 가우시안의 포인트 클라우드는 우리의 방법을 통해 학습된 상세하고 설명 가능한 공간 표현을 보여줍니다.

초록

Radiance 필드는 인상적인 성능을 보여주었습니다.

희박한 입력 보기에서 새로운 보기를 종합하는 능력,

그러나 일반적인 방법은 높은 훈련 비용과

추론 속도가 느립니다. 이 논문에서는 DNGaus를 소개합니다.

3D Gauss를 기반으로 한 깊이 정규화된 프레임워크인 sian

실시간 고품질을 제공하는 sian radiance field

저렴한 비용으로 몇 장의 새로운 뷰 합성. 우리의 동기

매우 효율적인 표현과 놀라움에서 비롯됩니다.

그럼에도 불구하고 최근 3D Gaussian Splatting의 품질은 좋지 않습니다.

뷰를 입력할 때 형상 저하가 발생합니다.

감소. 가우스 복사장에서 우리는 이것을 발견합니다

주로 측면에 늘어난 장면 형상의 저하

가우스 프리미티브의 위치 지정은 다음과 같이 완화될 수 있습니다.

깊이 제약. 결과적으로 우리는 Hard와

*교신저자: Xiao Bai(baixiao@buaa.edu.cn).

정확한 장면 위치를 복원하기 위한 소프트 깊이 정규화

거친 단안 심도 감독 하에 측정하는 동안

세밀한 색상 외관을 유지합니다. 더 나아가

세부적인 지오메트리 재형성을 개선하고 Global-

국소 깊이 정규화(Local Depth Normalization)로 작은 부분에 대한 초점 강화

국부적인 깊이 변화. LLFF, DTU에 대한 광범위한 실험,

그리고 Blender 데이터 세트는 DNGaussian이 더 뛰어나다는 것을 보여줍니다.

최첨단 방법을 형성하여 비교 가능하거나

대폭 감소된 메모리 비용으로 더 나은 결과를 얻습니다. a25x

훈련 시간 감소, 렌더링 속도 3000배 이상 빨라짐

속도. 코드는 <https://github.com/에서> 확인할 수 있습니다.

Fictionarry/DNGaussian .

1. 소개

희박한 입력을 사용한 새로운 뷰 합성은 문제를 야기합니다.

래디언스 필드용. 신경 방사선의 최근 발전

필드(NeRF)는 사실적 재구성에 뛰어났습니다.

arXiv:2403.06912v3 [cs.CV] 2024년 3월 24일

--- 페이지 2 ---

그림 2. 3D Gaussian Splatting [18]은 다음과 같은 가능성을 보여줍니다.
회소 입력 뷰에서 일부 세부 정보(녹색 상자)를 구성합니다.
그럼에도 불구하고 감소된 입력 조화수는 크게 저하됩니다.
형상 및 재구성 실패의 원인이 됩니다(주황색 상자). 앵글 후-
플라이 깊이 정규화를 통해 DNGaussian은 성공적으로 AC를 복구했습니다.
기하학을 선별하고 고품질의 새로운 관점을 합성합니다.
단 몇 가지만으로 눈에 띄는 외관과 정확한 기하학
입력 보기 [5, 16, 27, 35, 36, 42, 49, 53, 55]. 그러나,
대부분의 스파스 뷰 NeRF는 저프로세스로 구현됩니다.
처리 속도와 상당한 메모리 소비로 인해
높은 시간과 계산 비용으로 인해
실용적인 응용 프로그램. 일부 방법 [36, 38, 49]
그리드 기반 백본으로 더 빠른 추론 속도 달성
[13, 26, 37], 그들은 종종 트레이드오프로 인해 어려움을 겪습니다.
교육 비용이 높거나 렌더링 품질이 저하됩니다.
최근에는 3D Gaussian Splatting[18]이 도입되었습니다.
구조화되지 않은 3D 가우스 복사장(radiance field)
놀라운 성공을 달성하기 위한 3D 가우스 프리미티브 세트
신속하고 고품질이며 저렴한 비용으로 새로운 뷰 동기화가 가능합니다.
논문은 색상 밀도가 높은 입력 뷰에서 학습된 경우입니다. 심지어

희박한 입력만으로도 여전히 부분적으로 서피스를 유지할 수 있습니다.
명확하고 상세한 내용을 재구성하는 능력을 높이 평가합니다.
칼 기능. 그럼에도 불구하고 시야 제약이 줄어들었습니다.
장면 기하학의 상당 부분을 통합합니다.
바로 학습되어 새로운 관점 합성에 실패하고,
그림 2에 설명된 대로. 귀의 성공에서 영감을 얻었습니다.
더 깊이 정규화 된 회소 뷰 NeRF [36, 42], 이 pa-
사전 훈련된 깊이 정보를 추출하여 탐구합니다.
가우스 필드를 수정하기 위한 단안 깊이 추정기
잘못 배운 기하학의 깊이 Nor-를 소개합니다.
정규화된 회소 뷰 3D 가우스 광도
더 높은 품질과 효율성을 추구하는 Fields(DNGaussian)
퓨샷(Few-Shot)의 새로운 뷰 합성을 위한 능력.
비슷한 형태의 깊이 렌더링을 공유함에도 불구하고
3D 가우스 복사 필드에 대한 깊이 정규화가 다릅니다.
NeRF가 채택한 것보다 훨씬 더 많습니다. 첫째, 기존의
NeRF에 대한 깊이 정규화 전략은 일반적으로
전체 모델을 정규화하기 위해 깊이를 사용합니다.
광고하는 가우시안 필드의 잠재적인 기하학적 충돌
품질에 역으로 영향을 미칩니다. 특히 이 관행은
오히려 부드러운 단안 깊이에 맞는 가우시안 형태
복잡한 색상 외관보다 손실이 발생합니다.
세부 사항과 흐릿한 외관. 그것을 고려하면

장면 기하학의 기초는 가우스의 위치에 있습니다.
 모양보다는 시안 프리미티브를 사용하여 모양을 고정합니다.
 매개변수를 지정하고 Hard 및 Soft Depth Regular를 제안합니다.
 이동을 촉진하여 공간적 재구성을 가능하게 하는 화
 원시인 중에서. 정규화 과정에서 우리는
 두 가지 유형의 깊이를 렌더링하여 독립적으로 조정하는 포즈
 가우시안의 중심과 불투명도를 변경하지 않고
 형태를 갖추므로 피팅 사이의 균형을 유지합니다.
 복잡한 색상 표현과 부드럽고 거친 깊이.
 게다가 가우스 복사장은 더 민감합니다.
 NeRF에 비해 작은 깊이 오류가 발생할 수 있습니다.
 결과적으로 프리미티브의 시끄러운 배포와 재실패가 발생합니다.
 복잡한 질감을 지닌 기온. 기존 규모 불변 깊이
 손실은 종종 깊이 맵을 고정된 규모로 정렬하는 것을 선택합니다.
 작은 손실을 간과하게 됩니다. 이 문제를 해결하려면
 Global-Local Depth Normalization을 소개합니다.
 깊이 손실 함수를 사용하여 학습을 장려합니다.
 스케일 불변 방식으로 작은 로컬 깊이 변화. 와 함께
 로컬 및 글로벌 규모 정규화에서 우리의 방법은
 유지하면서 작은 로컬 오류에 다시 초점을 맞추는 손실 기능
 절대적인 규모로 지식을 보유하고,
 깊이 정규화를 위한 꼬리 형상 재형성 프로세스.
 제안된 두 가지 기술을 통합한 DNGaussian
 경쟁력 있는 품질과 우수한 견해를 종합합니다.
 여러 분야의 최신 방법과 비교한 세부 사항
 LLFF, Blender 및 DTU 데이터 세트에 대한 스파스 뷰 설정.
 이러한 장점은 훨씬 더 낮은 가격으로 더욱 강화됩니다.
 메모리 비용, 훈련 시간 25배 감소 등
 렌더링 속도가 3000배 더 빨라졌습니다. 실험도
 복잡한 문제를 해결할 수 있는 우리 방법의 보편적인 능력을 보여줍니다.
 장면, 넓은 시야, 다양한 자료.
 우리의 주요 기여는 다음과 같습니다:

- 하드 및 소프트 깊이 정규화를 통해
 3D Gaussian Radiance Field의 기하학
 거친-를 가능하게 하는 가우시안의 움직임
 타협하지 않고 깊이 정규화된 공간 재구성
 세밀한 색상 성능.
- 정규화하는 전역-로컬 깊이 정규화
 작은 영역에 다시 초점을 맞추기 위한 로컬 규모의 깊이 패치
 국부적인 깊이 변화로 인해 재구성이 향상됩니다.
 3D Gaussian radiance field의 세부 표현.
- 빠르고 고품질의 소수를 위한 DNGaussian 프레임워크
 위의 두 가지를 결합한 샷 소셜 뷰 합성
 다양한 기술을 통해 경쟁력 있는 품질을 달성합니다.
 최신 방법과 비교한 다양한 벤치마크
 ods, 훨씬 낮은 비용으로 세부 사항을 캡처하는 데 탁월합니다.
 훈련 비용 및 실시간 렌더링.

우리가 아는 한, 우리는 첫 번째 시도입니다.
 깊이 정규화 문제를 분석하고 해결합니다.
 거친 깊이 큐에서 3D 가우스 스플래팅. 우리는 희망한다
 이 논문은 광채 최적화를 위한 더 많은 아이디어에 영감을 줄 수 있습니다
 제한된 상황의 필드.

--- 페이지 3 ---

2. 관련 업무

새로운 관점 합성을 위한 래디언스 필드. 참신한 견해
 합성은 동일한 대상에 대해 보이지 않는 관점을 생성하는 것을 목표로 합니다.
 또는 주어진 이미지 세트의 장면 [1, 60]. 신경 래디언스
 Fields(NeRF) [25]는 대규모 MLP를 사용하여 3D 장면을 표현합니다.
 볼륨 렌더링을 통해 렌더링합니다. 그러나 그 속도는
 훈련과 추론 모두 느립니다. 다음은-
 증명은 주로 더 높은 품질 [2, 3] 또는 효율성을 추구합니다.
 [6, 12, 15, 21, 26, 37, 54] 그러나 두 가지를 모두 달성하기는 어렵습니다.
 가장 최근의 구조화되지 않은 복사장[7, 18, 52] 활용
 장면을 표현하기 위해 기본 요소 세트를 만듭니다. 그 중 3D
 Gaussian Splatting [18]은 다음과 같은 집합으로 복사 필드를 나타냅니다.
 이방성 3D 가우스 및 미분 가능한 렌더링
 튜브. 이 접근 방식은 빠르고 신속하게 큰 성공을 거두었습니다.
 복잡한 실제 장면을 위한 고품질 재구성. 동안
 이 방법은 조밀한 입력 보기에 탁월하며 다음과 같은 목표를 달성했습니다.
 다양한 3D 작업 성공[23, 39, 47], 재구성
 스파스 뷰 입력의 경우 아직 해결되지 않은 문제로 남아 있습니다. 또한,
 IM에 대한 추가 제약 조건을 어떻게 적용할지와 같은 문제가 있습니다.
 증명은 아직 해결되지 않았으며 논의할 가치가 있습니다.
 퓨샷 소실관 종합. 몇 장의 참신한 견해
 합성은 단지 세트로부터 새로운 견해를 생성하는 것을 목표로 합니다.
 희박한 입력 뷰. 많은 작품이 문제를 해결합니다.
 NeRF에 지정된 정규화 전략을 도입하여
 [11, 19, 27, 53]. 일부 사전 훈련된 방법은
 생성 모델에 서명하고 대규모 데이터 세트에서 훈련합니다. [5,
 9, 20, 55, 62], 다른 사람들[16, 49]은 사전 훈련된 모드를 사용합니다.
 훈련 과정을 정규화하기 위한 일종의 손실입니다.
 잘 배운 지식. 심층 증류 [11, 31, 36, 42]
 희소 보기 신경장을 위한 강력한 기술이기도 합니다.
 그러나 강력하지만 느린 백본으로 인해 제한됩니다.
 또는 복잡한 사전 훈련 모델, 이러한 방법의 대부분
 훈련과 추론 모두에 비용이 많이 듭니다. 비록 일부
 방법 [36, 38, 49]은 추론 효율성을 향상시켰습니다.
 그리드 기반 백본을 통해 그들은 또한 절충안을 겪습니다.
 교육 비용이 높거나 품질이 낮은 경우 등이 있습니다. 최근에는
 일부 작업 [22, 28, 32]은 제로샷 참신한 뷰 합성을 가능하게 합니다.
 확산 모델 이전에 입력이 하나라도 있는 경우가 있지만
 복잡한 장면을 처리하기 어렵고 효율성도 떨어집니다.
 희소 뷰 신경 필드의 깊이 감독.로서
 많은 3D 비전 작업의 고전적인 단서 [41, 43, 44, 46, 58, 61],

깊이 정보는 회소 정보를 감독하는 데 널리 사용되었습니다.
 신경장을 봅시다. 첫 번째 그룹 [11, 31]은 ac를 추출하는 것입니다.
 신뢰할 수 있는 포인트 클라우드에서 선별하지만 희박한 깊이 값,
 두 번째 [14, 36, 40, 42, 56]는 심층적 지식을 증류합니다.
 현재의 강력한 단안 깊이 추정기 [29, 30]에서.
 포인트 클라우드가 희박하고 사용할 수 없다는 점을 고려하면
 희박한 시야의 경우가 많으므로 단안 깊이가 장점을 보여줍니다.
 우리 작업에 대한 밀도와 견고성을 갖추었습니다. 문제를 해결하기 위해
 단안 깊이의 척도 모호함과 오류, 일부 사전
 많은 작업과 동시 회소 뷰 3DGS 방법이 있습니다.
 다양한 규모 불변 손실이 도입되었습니다 [10, 36, 50, 56, 63]
 깊이 순위 손실 [42, 51]을 포함하지만 모두
 우리에게 최적이지 않습니다. 첫째, 유연한 가우시안이 더 좋습니다.
 잘못된 깊이 단서에 민감하므로 추가 디자인이 필요함
 정규화. 또한 이러한 손실은 깊이를 특정 기준에 맞춰 조정합니다.
 작은 로컬 깊이를 무시할 수 있는 고정된 전역 규모를 유지합니다.
 변화. 이러한 간과로 인해 시끄러운 원시적 장애가 발생할 수 있습니다.
 특히 복잡한 텍스처가 있는 영역에서 분포가 발생합니다. Be-
 측면에서 우리는 세부 사항을 보존할 수 있는 HDN 손실[57]을 발견했습니다.
 단안 깊이 추정. 그럼에도 불구하고, 그것은 또한 비-
 다중 규모 패치에 대한 의존도가 높기 때문에 적합합니다.
 장거리 오류가 발생하고 기하학적 정확도가 저하됩니다.

3. 방법

3.1. 3D Gaussian Splatting을 위한 예비

대표. 3D 가우스 스플래팅 [18]은 3D를 나타냅니다.
 3D 가우시안 세트에 정보를 제공합니다. 픽셀을 계산합니다.
 3D 가우스 프리미티브 세트가 포함된 현명한 색상 C , 보기
 포즈 P , 중앙 o 와 관련된 카메라 매개변수입니다.
 구체적으로 가우스 프리미티브는 다음과 같이 설명할 수 있습니다.
 중심 $\mu \in \mathbb{R}^3$, 배율 인수 $s \in \mathbb{R}^3$ 및 회전
 쿼터니언 $q \in \mathbb{R}^4$. i 번째 프리미티브의 기본 기능
 G_i 는 다음과 같은 형태입니다.

$$G_i(x) = \frac{1}{2\pi(x - \mu)^T(x - \mu)} \exp(-\frac{1}{2}(x - \mu)^T(x - \mu))$$

나는 $(x - \mu)$, (1)

공분산 행렬 는 다음으로부터 계산될 수 있습니다.
 스케일 s 와 회전 q . 렌더링 목적으로 Gaus-
 시안 프리미티브는 또한 불투명도 값 $\alpha \in \mathbb{R}$ 을 유지하며
 K 차원 색상 특징 $f \in \mathbb{R}^K$. 그러면 $i =$
 $\{ \mu_i, s_i, q_i, \alpha_i, f_i \}$ 는 i 번째 가우스에 대한 매개변수입니다.
 표현. 3D Gaussian Splatting은 포인트 기반을 활용합니다.
 N 을 혼합하여 픽셀 x_p 의 색상 C 를 계산하는 렌더링
 픽셀과 겹치는 정렬된 가우스:

$$C(x_p) = \sum_{i \in N} \alpha_i G_i(x_p) C_i$$

나는 $\in N$

$$c_i = \mathbf{e}_i$$

$$i = 1 \dots Y$$

$$j = 1$$

$$(1 - e^{-j}), (2)$$

여기서 c_i 는 기능 f 의 디코딩된 색상입니다.

NeRF의 광선 샘플링 전략과 다른 점은

분산된 N Gaussian은 잘 최적화된 Ras에 의해 수집됩니다.

XP에 따른 terizer, 카메라 매개변수, 뷰 포즈

P 및 사전 정의된 역할 세트. 그리고 렌더링 불투명도

N 프리미티브의 e 는 와 투영된 값으로 계산됩니다.

이미지 평면의 2D 가우스 G_{proj} :

$$e_i = \mathbf{e}_i G_{proj}$$

나 (XP). (3)

그런 다음 NeRF와 유사하게 픽셀 단위로 표현할 수 있습니다.

깊이 D 와 카메라 중심까지의 거리 o :

$$D(x_p) =$$

$$X$$

$$N \in \mathbb{N}$$

$$\| \mathbf{e}_i - \mathbf{o} \|_2 \times e_i$$

$$i = 1 \dots Y$$

$$j = 1$$

$$(1 - e^{-j}). (4)$$

최적화. 3D Gaussian Splatting은 공간을 최적화합니다.

경사하강법을 통한 모든 가우스에 대한 매개변수

색상 감독. 최적화 과정에서

베틱할 가장 활동적인 기본 요소를 식별하고 복제합니다.

복잡한 텍스처를 표현하는 동시에 재처리를 제거합니다.

--- 페이지 4 ---

그림 3. DNGaussian의 프레임워크. 우리의 프레임워크는 무작위 초기화로 시작하며 Color Supervision으로 구성됩니다.

모듈 및 깊이 정규화 모듈. Color Supervision의 최적화 프로세스는 주로 3D Gaussian Splatting을 상속합니다.

[18] Neural Color Renderer는 제외됩니다. 깊이 정규화에서는 입력 뷰에 대해 Hard Depth와 Soft Depth를 렌더링합니다.

제안된 Global-Local Depth Normalization을 사용하여 사전 생성된 단안 깊이 맵의 손실을 별도로 계산합니다.

마지막으로,

출력 가우스 필드는 효율적이고 고품질의 새로운 뷰 합성을 가능하게 합니다.

불필요한 기본 요소. 이 작업에서 우리는 이러한 최적화를 상속받습니다.

색상 감독을 위한 전략.

초기화. 더 나은 기하학에서 시작하려면 다음 방법을 사용하십시오.

COLMAP의 포인트 클라우드 활용을 제안합니다 [33, 34]

또는 다른 SfM을 사용하여 가우스를 초기화합니다. 대신에-

희박한 상황에서 포인트 클라우드의 불안정성을 해결하고,

우리는 임의의 가우시안 세트로 메소드를 초기화합니다.

3.2. 가우스에 대한 깊이 정규화

유사한 깊이 계산을 공유함에도 불구하고 기존 깊이

NeRF에 대한 정규화는 3D Gaussian Ra로 전환할 수 없습니다.

엄청난 차이로 인한 다이안스 필드. 첫째, 목표 설정

추가 시간이 지나면 색상과 깊이 사이의 충돌이 발생합니다.
 평가자. 또한 연속형에 대한 이전 정규화
 NeRF는 밀도에만 초점을 맞추므로 거의 작동하지 않습니다.
 이산적이고 유연한 가우스 프리미티브에 대해서는 잘 알고 있습니다.
 모양 동결. 3D 가우스 라디언스 필드는 4개의
 직접적으로 영향을 미칠 수 있는 최적화 가능한 매개변수 $\{ \mu, s, q, \sigma \}$
 NeRF보다 더 복잡한 깊이입니다. 이후
 모노 깊이는 훨씬 부드럽고 맞추기 쉽습니다.
 색상에 대해 모든 매개변수 깊이 정규화를 적용합니다.
 이전 sparse-view에서 널리 사용되었던 타이어 모델
 신경장[10, 14, 42, 51, 56]은 PA-
 대상 깊이 맵에 과적합되어 흐릿해지는 원인이 되는 측정기
 외관. 따라서 이러한 매개변수는 서로 다르게 처리되어야 합니다.
 엔터티. 장면 기하학은 주로 다음과 같이 표현되므로
 가우시안 프리미티브의 위치 분포를 고려합니다.
 중심 μ 와 불투명도 σ 를 가장 중요한 매개변수로 사용합니다.

정규화하십시오. 왜냐하면 그들은 위치 자체를 별도로 나타내기 때문입니다.
 그리고 지위의 점유. 게다가,
 색상 재구성에 부정적인 영향을 미치므로
 깊이 정규화에서 스케일링 s 및 회전 q .
 하드 깊이 정규화. 공간재활용을 위해서는
 가우시안 필드의 형성을 위해 먼저 Hard를 제안합니다.
 움직임을 장려하는 깊이 정규화
 표면을 구성할 것으로 예상되는 가장 가까운 가우스
 그러나 종종 소음과 인공물이 발생합니다. 사건을 고려하여
 여러 가우스를 혼합하여 지정된 깊이를 렌더링합니다.
 sians를 누적 곱 e 로 재가중하여 우리는 다음과 같은 결과를 얻었습니다.
 일반적으로 모든 가우시안에 큰 불투명도 값 σ 를 적용합니다. 그런 다음,
 우리는 주로 가장 가까운 것으로 구성된 "하드 깊이"를 렌더링합니다.
 카메라 중심 o 및 가로질러 촬영된 광선의 가우스
 픽셀 x_p :

다하드(x_p) =

$\sum$

$\mu_i \in N$

$(1 - \sigma_i) \mu_i \text{Gproj}$

$\| \mu_i(x_p) - \mu_i(o) \|^2$. (5)

이제 중심 μ 만 최적화되었으므로 가우시안은
 잘못된 위치는 감소로 인해 정규화되는 것을 피할 수 없습니다.
 불투명도를 높이거나 모양을 변경하여 중심을 변경합니다.
 μ 움직여라. 정규화는 유사성에 의해 구현됩니다.
 하드 깊이를 장려하기 위해 대상 이미지 영역 P 에서의 손실
 단안 깊이 e_D 에 가까운 D_{hard} :
 $R_{hard}(P) = L_{similar}(D_{hard}(P), e_D(P))$. (6)
 소프트 깊이 정규화. "하드"에 대해서만 정규화
 깊이"는 불투명도 옵션이 없기 때문에 충분하지 않습니다.
 마이징. 우리는 또한 실제의 정확성을 보장할 것으로 기대합니다.

"부드러운 깊이"로 렌더링됩니다. 그렇지 않으면 표면이 반투명하고 속이 비어있습니다. 이런 관점에서- 따라서 우리는 추가로 가우스 중심 μ (표시됨)를 고정합니다. 중심 이동으로 인한 부정적인 영향을 피하기 위해 1/4)에 의해 튜닝을 위한 Soft Depth Regularization을 제안합니다.

불투명도 :

$D_{\text{soft}}(x_p) =$

$\times$

$\sum_{i \in N}$

$\| \frac{1}{4} \mathbf{i} - \mathbf{o} \|^2 \times e^{-i}$

$i \in 1 \dots Y$

$j=1$

$(1 - e^{-j})$,

$R_{\text{soft}}(P) = L_{\text{similar}}(D_{\text{soft}}(P), eD(P)).$

(7)

--- 페이지 5 ---

하드 및 소프트 깊이 정규화를 모두 사용하면 가장 가까운 가우스를 적절한 위치에 유지하도록 제한 불투명도가 높아서 완전한 표면을 구성합니다.

3.3. 글로벌-로컬 깊이 정규화

이전의 심도 감독 신경장은 일반적으로 깊이 맵의 소스 스케일에 대한 깊이 손실[10, 14, 36, 42, 56]. 이러한 유형의 정렬은 다음을 통해 모든 손실을 측정합니다.

넓은 지역의 통계에 기초한 고정 규모. 그 결과, 특히 작은 오류를 간과할 수 있습니다.

색상 조정과 같은 다양한 목적을 다룰 때

구조 또는 광범위한 깊이 변화. 이 간과

이전 NeRF 기반 작업에서는 그다지 중요하지 않을 수 있지만 가우스 복사장에서 더 큰 문제가 발생할 수 있습니다.

가우시안 래디언스 필드에서 작은 심도 보정

오류는 주로 다음 사항에 의존하기 때문에 더 어렵습니다.

가우시안 프리미티브의 움직임, 일어나는 과정

학습률이 약간 낮습니다. 또한, 프리미티브가 없다면

깊이 정규화 중에 위치가 수정되었습니다.

플로트 소음이 발생하여 특히 고장의 원인이 됩니다.

수많은 사람들이 모이는 세밀한 모습을 지닌 지역

그림 4에 표시된 대로 기본 요소입니다.

국소 깊이 정규화. 이 문제를 해결하기 위해 우리는

손실 함수를 도입하여 작은 오류에 다시 초점을 맞춥니다.

패치별 로컬 정규화를 수행합니다. 구체적으로는 컷

전체 깊이 맵을 작은 패치로 나누고 정규화합니다.

예측 깊이와 단안 깊이의 패치 P

평균값은 0이고 표준편차는 1에 가깝습니다.

$DLN(x) = D(x) - \text{평균}(D(P))$

$\text{std}(D(P)) + \epsilon$, s.t. $x \in P$, (8)

여기서 ϵ 는 수치 안정성 값입니다. 그 이후로 모든

패치가 로컬 규모로 정규화되었으며 손실이 발생했습니다.
 내부에서 계산할 수 있습니다. 나중에 Local Depth를 적용합니다.
 하드 및 소프트 깊이 정규화
 기하학 재형성에 도움이 됩니다.
 전역 깊이 정규화. 집중하는 것과는 달리
 지역적 손실이 적기 때문에 글로벌 관점에서 학습해야 합니다.
 전체적인 모양. 글로벌 규모의 부족함을 채우기 위해 우리는
 깊이 정규화에 전역 깊이 정규화를 추가합니다.

tion. 이를 통해 깊이 손실이 글로벌 규모를 인식하게 됩니다.
 지역 관련성을 유지하면서. 현지와 비슷하고,
 우리는 패치별 정규화를 적용하여 깊이를 해방합니다.
 소스 규모를 조정하고 지역적 변화에 초점을 맞춥니다. 유일한 차이점은-
 여기서는 전체의 전역 표준 편차를 사용합니다.

패치의 이미지 깊이 D_I 를 대체할 이미지 I 의 이미지 깊이 D_I :

$$DGN(x) = D(x) - \text{평균}(D(P))$$

표준(D_I),

성 $x \in P, P \subseteq I$.

(9)

또한 패치별 정규화를 통해 다음과 같은 문제도 피할 수 있습니다.
 운전에 의한 단안 깊이의 장거리 오류
 비슷한 효과를 제공하는 지역적으로 상대적인 깊이를 학습합니다.
 심도 등급 증류로 효과적입니다 [42, 51]. 그러나 다르게는
 그림 4. 고정된 글로벌 규모는 작은 것에 거의 관심을 기울이지 않습니다.
 L1 손실에서도 깊이 오류가 발생하여 시끄러운 프리미티브가 발생합니다.
 새로운 보기(노란색 상자)에서 오류가 발생합니다. 우리의 글로벌-로컬
 깊이 정규화는 로컬 스케일을 통해 작은 오류에 다시 초점을 맞추고
 보다 정확한 모양(녹색 상자)을 재구성하는 데 도움이 됩니다.
 기하학 재형성 목적을 위해 모델을 권장합니다.
 무시하기보다는 절대적인 깊이 변화를 배우는 것입니다.

3.4. 교육 세부정보

손실 함수 손실 함수는 세 부분으로 구성됩니다.
 색상 재구성 손실 L_{color} , 하드 깊이 정규화
 R_{hard} 및 Soft 깊이 정규화 R_{soft} . 3D에 이어
 Gaussian Splatting, 색상 재구성 손실은 다음과 같습니다.
 L1 재구성 손실 국가 및 D-SSIM 용어
 렌더링 이미지 I 및 지상 진실 I^* :

$$L_{color} = L1(I, I^*) + \lambda D-SSIM(I, I^*). \quad (10)$$

깊이 정규화 R_{hard} 와 R_{soft} 는 모두 낮은 수준을 포함합니다.
 cal 과 글로벌 용어는 두 종류의 깊이와 별도로 사용됩니다.
 정규화. 우리는 유사한 것을 측정하기 위해 L2 손실을 취합니다.
 ity. 두 정규화는 모두 다음과 같은 형식입니다.

$$RT = L2(DGN(T, eDGN) + \lambda L2(DLN(T, eDLN)), \quad (11)$$

여기서 T 는 hard(하드) 또는 Soft(소프트) t 를 나타냅니다. 실제로 우리는
 제약 조건을 완화하기 위해 L2 손실에 대한 오류 허용 오차를 설정합니다. 는

전체 손실 함수는 다음과 같이 공식화됩니다.

$$L = L_{color} + R_{hard} + R_{soft} \quad (12)$$

신경 컬러 렌더러. 3D 가우스 스플래팅 매장

구면 고조파를 통해 색상을 표현하지만, 과도하게 사용하기 쉽습니다.

스파스 뷰에만 적합합니다. 이 문제를 완화하기 위해 우리는

신경망 컬러 렌더러로서의 그리드 인코더 및 MLP

각 프리미티브의 색상을 예측합니다(그림 3). 추론하는 동안-

따라서 우리는 중간 결과를 저장하고 단지

가속을 위해 뷰 방향을 병합하는 마지막 MLP 레이어입니다.

4. 실험

4.1. 설정

데이터 세트. 우리는 세 가지 데이터 세트에 대한 실험을 수행합니다.

NeRF Blender 합성 데이터세트(Blender) [25], DTU

데이터 세트 [17] 및 LLFF 데이터 세트 [24]. 우리는 세트를 따릅니다-

동일한 분할을 사용하여 이전 작품 [27, 42, 53]에서 사용된 ting

3가지 보기에서 모델을 훈련하고 테스트하기 위한 DTU 및 LLFF

다른 이미지 세트에. 뒤에서 나는 소리를 없애려면-

대상 물체에 지면과 초점을 맞춘 다음 동일한 방법을 적용합니다.

--- 페이지 6 ---

LLFF DT설정 PSNR↑ LPIPS↓ SSIM↑ A VGE↓ PSNR↑ LPIPS↓ SSIM↑ A VGE↓

SRF [8] 12.34 0.591 0.250 0.313 15.32 0.304 0.671 0.171

PixelNeRF [55] 7.93 0.682 0.272 0.461 16.82 0.270 0.695 0.147

MVSNeRF [5]

DTU 교육을 받았습니다.

17.25 0.356 0.557 0.171 18.63 0.197 0.769 0.113

SRF 피트 [8] 17.07 0.529 0.436 0.203 15.68 0.281 0.698 0.162

PixelNeRF ft [55] 16.17 0.512 0.438 0.217 18.95 0.269 0.710 0.125

MVSNeRF 피트 [5]

DTU 교육을 받았습니다.

장면별 미세 조정 17.88 0.327 0.584 0.157 18.54 0.197 0.769 0.113

Mip-NeRF [2] 14.62 0.495 0.351 0.246 8.68 0.353 0.571 0.323

다이어트NeRF [16] 14.94 0.496 0.370 0.240 11.85 0.314 0.633 0.243

RegNeRF [27] 19.08 0.336 0.587 0.149 18.89 0.190 0.745 0.112

프리네르프 [53] 19.63 0.308 0.612 0.134 19.92 0.182 0.787 0.098

SparseNeRF [42]

장면별로 최적화됨

19.86 0.328 0.624 0.127 19.55 0.201 0.769 0.102

3DGS [18] 15.52 0.405 0.408 0.209 10.99 0.313 0.585 0.252

3DGS⁺ 16.46 0.401 0.440 0.192 14.74 0.249 0.672 0.169

DN가우시안(우리의 것)

장면별로 최적화됨

19.12 0.294 0.591 0.132 18.91 0.176 0.790 0.102

⁺DNgaussian과 동일한 하이퍼파라미터 및 신경 색상 렌더러를 사용합니다.

표 1. 3개 입력 뷰에 대한 LLFF 및 DTU의 정량적 비교. 최고, 2위, 3위 항목은 빨간색으로 표시됩니다.

각각 주황색, 노란색. 특히 가우시안 기반의 방법은 무의미한 보이지 않는 부분에 배경색을 직접적으로 표현하는 방식이다.

특히 PSNR에서는 측정항목이 낮아질 수 있습니다.

방법 PSNR↑ SSIM↑ LPIPS↓

네르프 [25] 14.934 0.687 0.318

NeRF(단순화) [16] 20.092 0.822 0.179

다이어트NeRF [16] 23.147 0.866 0.109

DietNeRF + 피트 [16] 23.591 0.874 0.097

프리네르프 [53] 24.259 0.883 0.098

SparseNeRF [42] 22.410 0.861 0.119

3DGS [18] 22.226 0.858 0.114

DN가우스(당사) 24.305 0.886 0.088

표 2. 8입력 블렌더의 정량적 비교

조회수, 최고, 2위, 3위 항목이 표시됩니다.

각각 빨간색, 주황색, 노란색으로 표시됩니다.

평가 시 DTU에 대한 이전 작업[27]과 같은 객체 마스크입니다.

Blender의 경우 DietNeRF [16] 및 FreeNeRF [53]를 따릅니다.

동일한 8개의 보기로 훈련하고 25개의 보이지 않는 이미지를 테스트합니다.

기준선, 다운샘플링 속도 8, 4 및

2는 LLFF, DTU, Blender에 적용됩니다. 사전에 이어

회소 보기 설정을 사용하면 카메라 포즈가 다음과 같이 가정됩니다.

교정이나 다른 방법을 통해 알 수 있습니다.

평가 지표. 우리는 PSNR, SSIM [45] 및

재구성 성능을 평가하기 위한 LPIPS [59] 점수

양적으로. 또한 평균오차(A VGE) [27]

$MSE = 10 \cdot PSNR/10, \sqrt{\cdot}$ 의 기하 평균으로 보고됩니다.

1 - SSIM 및 LPIPS.

기준선. 이전의 회소 뷰 신경장에 이어

[16, 27, 42, 53], 우리는 현재 SOTA 방법인 SRF [8]를 사용합니다.

PixelNeRF [55], MVNeRF [5], Mip-NeRF [2], DietNeRF

[16], RegNeRF [27], FreeNeRF [53] 및 SparseNeRF [42]

우리의 기준으로. 대부분의 NeRF 기반 방법에 대해 우리는 다음을 수행합니다.

해당하는 최상의 정량적 결과를 정확하게 보고합니다.

비교 논문을 발표했습니다. 원시 3D의 결과

Gaussian Splatting(3DGS)[18]도 보고되었습니다.

구현. 우리는 공식 Py-

Torch 3D Gaussian Splatting 코드베이스. 우리는 모델을 훈련합니다

모든 데이터 세트에 대해 6,000번의 반복과 소프트 깊이 등록이 포함되어 있습니다.

안정성을 위해 1,000회 반복 후에 정규화가 적용됩니다. 우리

모든 실험에 대해 손실 함수에서 $\lambda = 0.1$, $\beta = 0.95$ 로 설정합니다.

신경 렌더러는 해시 인코더[26]로 구성됩니다.

16~512 해상도 범위의 16레벨 및 최대 크기

219의 숨겨진 딤이 64인 5레이어 MLP입니다.

DPT [29]를 사용하여 모든 입력에 대한 단안 깊이 맵 예측

조회수. 3DGS와 DNGaussian의 모델은 무작위로 생성됩니다.

균일한 분포로 초기화되었습니다.

4.2. 비교

LLFF. 질적 결과와 시각화

3개 입력 보기의 LLFF 데이터 세트가 표 1에 보고됩니다.

그림 5. 특히 NeRF 기반 기준선 이후 내부에서 보이지 않는 영역에 색상을 보간합니다. 이산 가우스 복사 필드가 di- 이 빈 공간에 검정색 배경을 바로 노출시키고, 3DGS 기반 방법은 본질적으로 약점을 가지고 있습니다. 이러한 무의미하고 보이지 않는 AR로부터 재구성 측정항목을 예아. 그럼에도 불구하고 우리의 접근 방식은 여전히 모든 기반을 능가합니다. LPIPS 점수에서 라인을 유지하고 유사한 PSNR을 달성합니다. SSIM 및 평균 오류가 가장 좋은 방법입니다. 둘 다에서 정량적, 정성적 결과를 보면 우리는 DNGaussian은 더욱 미세한 디테일과 정밀한 형상을 예측합니다. 시도해 보세요. FreeNeRF는 부족한 부드러운 뷰를 합성하는 경향이 있습니다. 고주파수 세부 사항도 있고 형상도 정확하지 않습니다. 깊이 감독된 SparseNeRF 및 우리의 DNGaus- 시안. 동일한 깊이 맵으로 정규화되었지만 SparseN- eRF는 세부 사항 및 형상 완성도가 더 약합니다. 네스. DNGaussian은 또한 두 가지 측면 모두에서 큰 개선을 이루었습니다. 잘 조정된 3DGS와 비교한 연령 기하학 품질. DTU. DTU 3뷰 설정의 정량적 결과 표 1에 보고된 내용은 우리의 방법이 가장 좋은 결과를 달성했음을 보여줍니다. LPIPS 및 SSIM에서는 평균 오류에서 두 번째로 좋습니다.

--- 페이지 7 ---

그림 5. LLFF.3DGS [18]의 정성적 비교는 희박한 입력에서 정확하고 새로운 뷰를 합성하지 못합니다. 렌더링 뷰 FreeNeRF [53] 및 SparseNeRF [42]의 결과는 모두 부드럽지만 너무 많은 세부 정보가 손실되었습니다. FreeNeRF는 다음에서 잘못된 기하학을 더 학습합니다. 완전한 장면. 우리의 방법은 보다 완전한 전경 기하학을 학습하고 미세한 세부 묘사로 고품질의 새로운 뷰를 렌더링합니다. 그림 6. DTU의 정성적 비교. 우리의 방법은 탁월합니다. 어려운 영역의 기하학과 렌더링 품질 모두에서. 그러나 우리는 PSNR에서 더 낮은 점수를 얻었습니다. 스케일 변화와 노이즈 페색으로 인해 장면의 질감이 없는 보드와 배경. 에서 그림 6에서 정성적 예를 보면 다음과 같은 것을 알 수 있습니다. 우리의 방법은 보다 정확하고 완전한 기하학을 학습할 수 있습니다. FreeNeRF와 심도 감독 둘 다와 비교해 보세요. SparseNeRF는 다양한 색상에서도 고품질 디테일을 생성합니다. 가상의 봉제 및 반사 영역. 블렌더. 주변 뷰를 통해 피팅 능력을 테스트하려면, 우리는 8인치 미만의 Blender 데이터 세트를 평가합니다. 견해를 넣어라. 점수는 표 2에 보고되어 있습니다. 일부 데이터는 FreeNeRF [53] 및 DietNeRF [16]에서 제공됩니다. 우리의 방법은 모든 PSNR, SSIM 및 그림 7. 블렌더의 정성적 비교. 결과 주변 경관으로부터 강력한 피팅 능력을 보여주며, 상세하고 복잡한 장면을 재구성합니다. LPIPS. 그림 7의 정성적 결과를 보면 다음과 같다.

우리의 방법이 올바른 기하학적 구조로 뷰를 합성한다는 것을 보았습니다.
바닐라 3DGS에 비해 플로터가 적고 플로터 수가 적습니다.
2차에 비해 세부적으로 좋은 성능을 보여줍니다.
최고의 FreeNeRF. 결과는 DNGaussian이
LLFF와 같은 기대되는 장면을 처리할 수 있을 뿐만 아니라
DTU뿐만 아니라 복잡한 객체의 전체 재구성
투명하고 반사되는 소재로
능률. 우리는 효율성에 대한 연구를 추가로 수행합니다.
RTX 3090 Ti GPU를 사용한 LLFF 3뷰 설정 탐색
현재 SOTA 기준선 [42, 53]의 성능
24GB/12GB의 제한된 GPU 메모리 및 훈련 시간

--- 페이지 8 ---

방법 FPS 시간 GPU MemPSNR↑ LPIPS↓ SSIM↑

FreeNeRF [53]9×10 2 2.3시간 4×48GB 19.63 0.308 0.6122.3시간 24GB 19.71 0.322 0.6031.0시간 24GB 19.66 0.357 0.574

SparseNeRF [42]9×10 2 1.5시간 32GB 19.86 0.328 0.6241.5시간 12GB 19.95 0.334 0.5980.5시간 12GB 19.94 0.341 0.585

당사 300 3.5분 2GB 19.12 0.294 0.591

표 3. 제한된 리소스를 사용한 효율성 비교. 우리의
방법은 효율적인 훈련과 가장 빠른 실시간 렌더링을 달성합니다.

경쟁력 있는 고품질의 참신한 견해를 종합하면서.

정규화 정규화 PSNR↑ LPIPS↓ SSIM↑AP 하드 소프트 로컬 글로벌

18.14 0.354 0.538

17.90 0.351 0.525

18.31 0.339 0.552

18.68 0.331 0.565

18.55 0.324 0.562

19.12 0.294 0.591

표 4. 절제 연구. 우리는 LLFF에 대한 방법을 제거합니다.

3뷰 설정. 결과는 우리가 기여한 효과를 보여줍니다.

그림 8. 깊이 정규화의 시각화 결과.

우리의 하드 깊이 정규화는 높은 수준의 깊이를 크게 향상시킵니다.

주파수는 세부적이지만 빈 공간을 유발합니다. 이 단점은 해결될 수 있다

Soft Depth를 통해 미세한 디테일을 합성합니다. 우리는 깊이를 취합니다

조밀한 견해를 비교를 위한 근거 진실로 삼습니다.

표 3에 표시된 대로 1.0h/0.5h입니다. 각 항목의 맨 위 행은

그룹은 해당 그룹의 기본 설정을 나타냅니다.

훈련 시간은 다음과 같이 측정됩니다.

단일 GPU에서 동일한 횟수의 반복이 수행됩니다. 둘 다 동안

FreeNeRF 및 SparseNeRF는 엄격한 재검토 하에서 성능이 저하됩니다.

소스 제한으로 인해 우리의 방법은 다음과 같은 측면에서 큰 이점을 보여줍니다.

25배의 놀라운 가속을 달성하는 효율성

훈련 시간과 FPS에서 3000× 이상, 합성하는 동안-

경쟁력 있는 품질의 새로운 견해를 가지고 있습니다. 필요성을 고려하여

장면별 최적화와 신속한 시각화를 위해 우리의 높은

효율성은 실제 응용 분야에서 상당한 가치를 갖습니다.

4.3. 절제 연구

우리는 LLFF 3-뷰 설정에서 우리의 방법을 제거합니다. 는
정량적 결과는 표 4 및 5에 보고되어 있습니다.

깊이 정규화. 우리는 하드 및 소프트 깊이를 제거합니다.

일반 전체 매개변수(AP) L2 재구성을 사용한 정규화

건설 손실 기간. 효과를 더 잘 별도로 설명하기 위해

두 가지 유형의 깊이 중 모양의 영향을 제외합니다.

동결하면 상황과의 비교를 더욱 시각화할 수 있습니다.

그림 8에서는 모양이 동결된 경우에만 가능합니다.

일반 깊이 정규화는 효과적으로 재구성할 수 없습니다.

이는 우리 방법의 필요성을 증명하는 장면 기하학입니다.

정성적, 정량적 결과 모두 우리의

그림 9. 형상 동결의 시각화 결과. 합성은-

형태가 동결되지 않은 크기의 참신한 뷰는 흐릿한 영역으로 채워지고,

이는 주로 다음에서 학습한 지나치게 부드러운 지오메트리로 인해 발생합니다.

단안 깊이(왼쪽 하단).

PSNR↑ LPIPS↓ SSIM↑ A VGE↓ 설정

형상 동결 없음 17.96 0.363 0.547 0.160

중양 동결 없음 18.87 0.300 0.584 0.140

전체 19.12 0.294 0.591 0.132

표 5. 매개변수 동결에 대한 절제 연구. 결과

매개변수 동결 전략의 필요성을 입증합니다.

형상 품질 및 고주파수 세부 사항에 영향을 미칩니다.

글로벌-로컬 깊이 정규화. 그 결과에서 우리는

전역 정규화를 추가해야만 가능하다는 것을 알 수 있습니다.

또한 주로 로컬 패치로 인해 피팅에 도움이 됩니다.

현명한 손실 계산. 현지인 참석 후-

Malization, 렌더링 품질은 특히 De-에서 향상됩니다.

꼬리. 이러한 개선 사항은 적용할 때 훨씬 더 분명해집니다.

모든 매개변수보다 우리가 제안한 정규화를 적용했습니다.

해당 필드에 적합하지 않은 정규화입니다. 결과

우리의 디자인과 일치하고 우리의 효율성을 보여줍니다.

글로벌-로컬 깊이 정규화.

매개변수 동결. 우리의 효과를 설명하기 위해

매개변수 고정 전략을 사용하면 모양 고정도 제거됩니다.

소프트 깊이 계산에서 정규화 및 중심 동결

ulation. 결과를 표 5 및 도 9에 나타내었다.

시각화는 깊이 색상의 문제를 보여줍니다.

Sec.3.2의 충돌. 센터 동결이 없는 상황에서는,

일부 기본 요소는 예상치 못한 곳으로 이동하여 상호 작용할 수 있습니다.

깊이 손실을 감수해야 품질이 저하됩니다. 작성자:

제한된 매개변수 동결을 도입하여 우리는 성공했습니다.

문제를 완전히 완화하고 최상의 결과를 얻으십시오.

5. 결론

이 논문은 다음과 같은 DNGaussian 프레임워크를 제시합니다.

3DGS를 몇 번의 새로운 뷰 합성 작업으로 유도합니다.

깊이 정규화. 공간의 제약으로 인해 우리는
보충 자료에서 더 많은 논의를 해보세요.
감사의 말씀. 이 작품에서 우리는 다음의 지원을 받습니다:
중국국립자연과학재단 62276016,
62372029. Lin Gu는 JST Moonshot R&D의 지원을 받습니다.
승인 번호 JPMJMS2011 일본.

--- 페이지 9 ---

DNGaussian: 희소 뷰 3D 가우스 래디언스 필드 최적화

글로벌-로컬 깊이 정규화

보충 자료

개요

보충 문서에서는 먼저 추가 정보를 보고합니다.

Sec에서 연구합니다. 우리가 제안한 깊이 정규화 중 A는 neu-
ral 컬러 렌더러 및 이전 방법의 성능

빠른 그리드 기반 백본에 대한 ods. 그런 다음, 우리는
우리의 구현 및 데이터 세트 설정에 대한 세부 사항은 다음과 같습니다.

초의 실험. 나. 마지막으로 한계점과 한계점을 논의한다.

Sec에서 우리 방법의 향후 작업. 다.

가. 추가 결과

A.1. 깊이 정규화에 대한 절제 연구

로컬 및 글로벌 깊이의 역할을 더 잘 설명하기 위해

정규화, 추가 절제 연구를 수행하고

L2 손실 함수를 L1으로 대체하여 감소를 방지합니다.

작은 손실. 정량적 시각화 결과는 다음과 같습니다.

표 6과 그림 10에 나와 있습니다. 비교에서 우리는

설명하기 위해 글로벌 및 로컬을 적절하게 적용합니다.

각각의 강점과 약점: 1) 전 세계적으로

또한 모델을 개별적으로 지원하여 이상의 내용을 학습할 수도 있습니다.

모든 장면에서 우리가 경험한 것처럼 사소한 오류를 최적화하는 데 약합니다.

Sec.3.3에서 논의됩니다. 2) 지역은 혼자 설 수 없다

절대적인 규모는 부족하지만 풍부한 정보를 제공합니다.

국부적인 깊이 변화에 대한 메이션. 3) 두 가지 기술을 결합하여

물론, 글로벌-로컬 깊이 정규화는 동시에 가능합니다.

글로벌 규모와 소규모에 대한 지식을 모두 습득합니다.

로컬 오류와 최고를 달성합니다. 특히, 다르기 때문에-

이 연구에서는 손실 유형을 사용했으며 점수는 다음과 같이 다양합니다.

주요 논문에 보고된 내용입니다. 그럼에도 불구하고 우리의 방법은

특히 LPIPS와 SSIM에서 여전히 좋은 성능을 발휘합니다.

깊이 정규화의 견고성을 보여줍니다.

PSNR↑ LPIPS↓ SSIM↑ A VGE↓ 설정

글로벌만 18.32 0.309 0.579 0.144

로컬만 17.17 0.338 0.523 0.167

전체 18.67 0.291 0.595 0.137

표 6. 깊이 정규화에 대한 추가 절제 연구

tion. 제안된 두 가지 깊이 정규화를 모두 결합하면

Global-Local Depth Normalization은 최고의 품질을 달성합니다.

A.2. 신경 컬러 렌더러에 대한 절제 연구

본 연구에서는 3D의 구면고조파(SH)를 대체한다.

표현하기 위한 뉴럴 컬러 렌더러를 사용한 가우스 스피클레팅

방향 변형 색상. 기능을 더 잘 설명하기 위해

이 모듈의 원래 SH 함수와 비교합니다.

3번의 훈련이 포함된 LLFF 데이터 세트에서 다양한 학위

그림 10. 제안된 두 가지 깊이 정규화의 시각화.

입력 뷰와 합성 소설의 색상 및 깊이 맵

보기는 (a)와 (b)에 표시됩니다. 글로벌은 글로벌을 제공합니다

그러나 전체 장면에 대한 시야는 소규모 지역을 처리하는 데 약합니다.

흐릿하고 잘못된 모양을 유발하는 오류(흰색 상자)

(노란색 상자). 그에 비해 지역적인 것은 지역적인 것에 더 민감하다.

깊이 변화. 두 가지를 결합함으로써 우리의 방법은 다음과 같이 학습할 수 있습니다.

보다 정확한 장면 기하학. 더 나은 시각화를 위해 확대하세요.

그림 11. 제안된 두 가지 깊이 정규화의 시각화.

희박한 상황에서 SH는 일관되지 않은 색상을 생성할 수 있습니다.

과적합으로 인해 보이지 않는 뷰(노란색 화살표).

신경 컬러 렌더러에 의해 믿어집니다.

PSNR↑ LPIPS↓ SSIM↑ A VGE↓ FPS 설정

SH 정도=2 17.06 0.333 0.549 0.167 340

SH 정도=3 17.11 0.328 0.560 0.164 300

신경 렌더러 19.12 0.294 0.591 0.132 300

표 7. 신경 컬러 렌더러에 대한 절제 연구. 우리의 신경

컬러 렌더러는 렌더링 품질을 성공적으로 향상시키는 동시에

똑같이 빠른 추론 속도를 유지합니다.

조희수. 결과는 표 7과 그림 11에 나와 있습니다. SH

희소 뷰 상황에서는 함수가 과적합되기 쉽고

뷰를 변경하는 동안 이상한 색상이 나타납니다. 이

각 프리미티브의 독립성으로 인해 발생할 수 있습니다.

지역적 일관성 부족으로 이어진다. 소개한 후

뉴럴 컬러 렌더러를 사용하면 문제가 완화되었습니다. 작성자:

중간 결과를 저장하고 최신 결과만 계산

두 개의 MLP 레이어를 사용하면 빠른 렌더링 속도를 유지할 수 있습니다

SH에도 경쟁력이 있다.

--- 페이지 10 ---

백본 전략 PSNR↑ LPIPS↓ SSIM↑ 시간↓ VM 비용↓ FPS↑

밈-NeRF [2]

없음 14.62 0.495 0.351 2.2h

≥32GB 0.09FreeNeRF 19.63 0.308 0.612 2.3h

SparseNeRF 19.86 0.328 0.624 1.5h

인스턴트-NGP [26]

없음 17.19 0.483 0.469 3.8분

3GB 3FreeNeRF 15.30 0.516 0.369 4.2분

SparseNeRF 17.19 0.478 0.476 7.5분

텐소RF [6]

없음 16.16 0.454 0.443 4.1분

8GB 5FreeNeRF 15.78 0.466 0.430 4.5분

SparseNeRF 16.11 0.465 0.443 8.9분

3DGS [18]

없음 16.46 0.401 0.440 2.7분

2GB 280FreeNeRF 16.55 0.399 0.472 2.7분

SparseNeRF 16.80 0.374 0.504 2.9분

3DGS [18] 우리 것 19.12 0.294 0.591 3.5분 2GB 300

표 8. 서로 다른 백본을 사용한 SOTA 전략 FreeNeRF [53] 및 SparseNeRF [42] 비교 모두를 위한 최고의 결과와 각 백본에는 굵은 글씨와 밑줄이 표시되어 있습니다. FreeNeRF와 SparseNeRF는 암시적 Mip-NeRF [2]에서 잘 수행되지만, 우리 작업에서는 현재의 빠른 백본인 Instant-NGP [26], TensorRF [6] 및 3DGS [18]를 사용하여 품질을 약하게 향상시킬 수 있습니다.

그림 12. Fast로 전송될 때 암시적 기반 SOTA 방법 SparseNeRF(S)[42] 및 FreeNeRF(F)[53]의 시각화 백본 Instant-NGP(iNGP) [26], TensorRF [6] 및 3D Gaussian Splatting (3DGS) [18]. 깊이 기반 SparseNeRF로 인해 흐려짐

모든 빠른 백본에서 렌더링하는 반면 FreeNeRF는 품질 개선에 미치는 영향이 적습니다. 대신, 우리의 DNGaussian은 최고의 결과를 얻었습니다.

가장 효율적인 3DGS 백본의 품질은 우리 방법의 필요성을 보여줍니다.

A.3. 이전 전략의 이전

이 섹션에서는 다음을 설명하기 위해 실험을 수행합니다.

효율적인 DNGaussian이 필요합니다. 실제로,

FreeNeRF [53] 및 SparseN과 같은 일부 기존 방법

eRF [42]는 주로 백업으로 인해 효율성이 낮습니다.

전략 자체보다는 빠대입니다. 그러나 그들은 단지

일부 암시적 백본에 대해서는 이미 효과적인 것으로 입증되었습니다.

느리고 비용이 많이 듭니다. 그들이 할 수 있는지 확인하려면-

더 높은 효율성을 달성하기 위해 더 빠른 백본으로 직접 전송

우리는 두 개의 빠른 그리드에서 이 두 가지 방법을 구현합니다.

Instant-NGP [26] 및 TensorRF [6] 기반. 또, 우리는 이런 일을 합니다

3D Gaussian Splatting(3DGS) [18] 백본에 있습니다. 그런 다음,

우리는 LLFF 3-view 설정에서 이러한 구현을 테스트합니다.

결과를 표 8 및 도 12에 나타내었다.

훈련 시간(Time), GPU 메모리 비용을 보고합니다.

(VM 비용) 및 각 항목에 대한 추론 FPS입니다.

구현 세부정보 우리는 CUDA 구현을 활용합니다

2개의 그리드 기반 백본을 위한 Ray Marching 1

더 빠른 속도와 더 낮은 비용. 3DGS 백본은 다음을 사용합니다.

우리의 방법과 동일한 신경 컬러 렌더러입니다. 우리는

단일 생성을 위한 SparseNeRF의 원래 구현

모든 입력 뷰에 대한 형식적 깊이 맵을 생성하고 해당 로컬을 전송합니다.

이러한 새로운 백본에 대한 심층 순위 증류

동일한 하이퍼파라미터 FreeNeRF의 경우 세 가지 이후

빠른 백본에는 주파수 기반 위치가 포함되어 있지 않습니다.

인코딩을 수행할 때 빈도 정규화를 적용합니다.

대안으로 그리드 기반 위치 인코딩.

1<https://github.com/ashawkey/torch-ngp>

--- 페이지 11 ---

그리드 기반 백본 비교. 비록 이러한 두 가지 방법은 원래의 암시적 Mip에서 잘 수행됩니다. NeRF는 Instant-NGP와 TensorRF 모두에서 약합니다. SparseNeRF는 단안에서 깊이 순위를 추출합니다. 그러나 정규화를 위한 깊이 맵은 더 많은 흐림을 유발합니다. 이는 더 강력한 공간 기억 능력으로 인해 발생할 수 있습니다. 기억하기 쉽도록 명시적인 그리드로부터 리즈 소음. FreeNeRF는 이 두 가지 모두에서 더 나쁜 성능을 발휘합니다. 두 개의 백본은 서로 다른 표현으로 인해 발생할 수 있습니다. 위치 인코딩에 대한 설명입니다. TensorRF에서는 이 두 가지 모두 전략은 성과를 향상시키지 못합니다. 한 가지 이유는 TensorRF는 별도의 작업 없이 명시적 그리드를 직접 활용합니다. 밀도 값을 저장하는 신경 디코더는 더 어렵습니다. 정규화하는 컬트. 3DGS에서의 비교. 비교에서는 3DGS 백본은 빠른 FPS와 낮은 예상 훈련 비용. 그러나 SparseNeRF와 FreeNeRF는 강력하고 효율적인 이 기능을 효과적으로 정규화할 수 없습니다. 백본. 주파수 위치 인코딩이 부족하기 때문에 FreeNeRF는 대략적인 전략과 유사하며 약간의 개선만 가져올 뿐입니다. 시각화부터 그림 12의 SparseNeRF가 충분하지 않음을 확인할 수 있습니다. 3DGS의 3D 가우스 복사장에 적합합니다. 깊이 순위를 유지하고 색상 감도를 기다립니다. 상세한 형상을 개선하는 최적화 프로세스입니다. 컴-이 두 가지 방법을 결합하여 우리의 DNGaussian은 다음을 달성합니다. 훈련을 조금만 늘려도 훨씬 더 나은 품질을 얻을 수 있습니다. 시간. 학습된 기하학에서 노이즈가 적은 우리의 방법 또한 더 빠른 추론 속도를 달성합니다. 결론. 실험은 이전 방법이 암시적 백본에 대한 ods는 적어도 쉽게는 거의 불가능합니다. 방법은 현재의 빠른 백본으로 전환하는 것입니다. 또한 그들은 그렇지 않습니다 3D Gaussian Radiance Field에 적합합니다. 그런 자리에-우리의 DNGaussian은 다음과 같은 측면에서 상당한 가치를 보여줍니다. 고품질, 저비용의 소수 촬영을 위한 효율적인 방법 새로운 관점 합성.

A.4. 그리드 기반 방법과의 비교

그리드 기반을 활용한 작품[36, 38, 49]이 있다. 훈련 효율성을 향상시키는 백본. DaRF 이후 [36]은 최소 9개의 데이터가 포함된 또 다른 두 개의 데이터 세트에서 평가됩니다. VGOS [38] 및 DiffusioNeRF [49]가 사용하는 동안 뷰를 넣습니다. 측정항목을 측정하는 방법은 다양합니다. 주요 논문의 기준으로 삼지 마십시오. 여기에 우리가 나열합니다

표 9의 VGOS 및 DiffusioNeRF의 점수

비교를 위한 LLFF 3뷰 설정입니다. VGOS의 경우, 우리는 단지 측정 방법이 정의된 점수를 보고합니다.

RegNeRF [27] 및 FreeNeRF [53]와 완전히 동일합니다.

DiffusioNeRF의 결과는 업데이트된 것에서 얻습니다.

arXiv 2에 대한 논문. 비교에서 우리의 방법은

LPIPS, SSIM,

2<https://arxiv.org/abs/2302.12231>

그림 13. 블렌더 데이터세트의 정성적 비교

8개의 입력 보기. FreeNeRF [53]는 다음을 통해 정확한 기하학을 학습합니다.

그러나 고주파 신호를 마스킹하는 데는 흐릿한 디코드 문제가 발생합니다.

꼬리는 트레이드 오프입니다. 대조적으로, 우리의 방법은 명시적으로

고주파 콘텐츠의 학습을 제한합니다. 또한 귀속됨

3D 가우스 신경장에 대한 우리의 방법은 다음에서 더 잘 수행됩니다.

세밀한 세부 사항.

방법 PSNR↑ LPIPS↓ SSIM↑ A VGE↓

VGOS [38] 19.35 0.432 - -

확산NeRF [49] 19.79 0.338 0.568 0.136

당사 19.12 0.294 0.591 0.132

표 9. 그리드 기반 퓨샷 NeRF와의 비교

3개의 훈련 보기가 있는 LLFF. 우리의 방법은 그리드 기반보다 성능이 뛰어납니다.

방법 VGOS [38] 및 DiffusioNeRF [38].

그리고 VGE. 실제로 우리의 방법은 효율성 측면에서도 최고를 달성합니다.

훨씬 낮은 비용과 더 빠른 추론으로 효율성을 높였습니다.

A.5. 추가 시각화

우리는 실험을 통해 더 많은 렌더링 결과를 제공합니다. 는

3가지 학습 보기가 있는 DTU 및 LLFF의 예는 다음과 같습니다.

그림 14와 15에 나와 있습니다. 우리는 또한 더 많은 수량을 보여주었습니다.

Blender 8 뷰 설정의 적정 비교

그림 13의 SOTA 방법 FreeNeRF [53]. 추가 결과

우리의 보충 비디오에서 찾을 수 있습니다.

나. 세부사항

B.1. 구현

사전 훈련된 깊이 모델. 이 작업에서 우리는

깊이를 예측하기 위한 사전 훈련된 DPT [29, 30] 추정기

NeRF 기반에서 널리 사용되는 맵

작품 [4, 10, 42, 48]. 특히, 우리는 다음과 같은 유형을 사용합니다.

--- 페이지 12 ---

그림 14. DTU 데이터 세트에 대한 3개의 입력 뷰가 있는 DNGaussian의 합성된 새로운 뷰 결과의 예.

그림 15. LLFF 데이터 세트에 대한 3개의 입력 뷰가 있는 DNGaussian의 합성된 새로운 뷰 결과의 예.

--- 페이지 13 ---

유형 PSNR↑ LPIPS↓ SSIM↑ A VGE↓

LLFF

dpthybrid384* 19.12 0.294 0.591 0.132

dptlarge384 19.03 0.297 0.590 0.135

DTU

dpthybrid384 18.86 0.179 0.784 0.106

dptlarge384* 18.91 0.176 0.790 0.102

표 10. 다양한 사전 훈련된 깊이 모델의 영향

우리는 사전 훈련된 깊이 모델을 다른 유형으로 대체합니다.
동일한 하이퍼파라미터를 유지하면서 LLFF 및 DTU 설정.
결과는 우리의 방법이 다른 단안에도 강력하다는 것을 보여줍니다
깊이 추정기. *는 각 데이터 세트의 기본 유형을 나타냅니다.
LLFF 데이터 세트의 경우 dpt hybrid 384, dpt Large 384
순수에 대해 더 나은 성능을 발휘하는 DTU 및 Blender의 경우
흰색 또는 검정색 배경. 실제로 성능 격차가
다양한 유형의 깊이 모드를 적용할 때 우리의 방법
표 10에 나타난 바와 같이 약간의 차이가 있습니다.
패치 크기. 우리의 구현에서는 무작위로 샘플링합니다.
패치 기반에 대해 사전 정의된 범위의 패치 크기
글로벌-로컬 깊이 정규화. 이 범위는 다음과 같이 설정됩니다.
LLFF 및 Blender의 경우 [5, 17], DTU의 경우 더 큰 [17, 51]
개체는 작지만 많은 부분을 차지하기 때문에
이미지의. 정규화의 유연성으로 인해 우리는
각 장면에 대해 이 값을 별도로 조정할 필요가 없습니다.
측정항목. 이전 방법 [27, 53]에 따라 우리는
scikit-image 3에서 com-으로의 "구조적 유사성" API
SSIM 점수를 입력하고 구현을 사용합니다.
LPIPS 점수를 계산하기 위해 사전 훈련된 VGG 모델입니다.
카메라 포즈. 기존 작품 [16, 27, 42, 53]에 이어,
우리는 모든 카메라 포즈가 이미 알려져 있다고 가정합니다. 실제로는
LLFF와 Blender의 경우 주어진 포즈를 사용합니다.
데이터 세트. DTU의 경우 COLMAP [33, 34]를 사용하여 다음을 계산합니다.
주어진 모든 뷰에 따라 카메라가 늦게 포즈를 취한 다음
결과에서 대상 희소 뷰를 샘플링합니다.

B.2. 데이터세트

LLFF. LLFF 데이터 세트[24]에는 8개의 전방 방향이 포함되어 있습니다.
총 장면. [27, 42, 53]에 이어, 우리는 매 8-

테스트를 위한 새로운 보기로 이미지를 만듭니다. 입력 뷰
나머지 보기 전체에서 균등하게 샘플링됩니다. 이미지는
8x를 378x504 해상도로 다운샘플링했습니다. 실제로,
원본 이미지의 왜곡을 무시합니다.
DTU. DTU 데이터세트[17]는 124개의 객체 중심으로 구성됩니다.

고정 카메라 세트로 촬영한 장면. 우리는 [27,
42, 53] 15개 장면에서 직접 모델을 평가합니다.
8, 21, 30, 31, 34, 38, 40, 41, 45, 55, 63, 82, 103, 의 스캔 ID
110, 114. 각 스캔에서 다음과 같은 이미지가 나타납니다.
25, 22, 28의 ID가 3-의 입력 뷰로 사용됩니다.
보기 설정. 테스트 세트는 ID가 1인 이미지로 구성됩니다.
2장, 9장, 10장, 11장, 12장, 14장, 15장, 23장, 24장, 26장, 27장, 29장, 30장, 31장, 32장, 33장,
3<https://scikit-image.org/docs/stable/api/skimetrics.html>
평가를 위해 34, 35, 41, 42, 43, 45, 46 및 47을 참고하세요. 이미지
4배로 다운샘플링됩니다. 특히 왜곡되지 않은 방식을 사용합니다.
COLMAP의 이미지를 사용하여 부정적인 영향을 제거합니다.

지워지지 않은 렌즈 왜곡.

블렌더. 우리는 [16, 53]에 사용된 데이터 분할을 따릅니다.

블렌더 데이터 세트 [11]. 8개의 입력 보기는 다음에서 선택됩니다.

ID가 26, 86, 2, 55, 75, 93, 16, 73인 학습 이미지

8. 25개의 테스트 뷰는 테스트에서 균등하게 샘플링됩니다.

평가용 이미지. 모든 이미지는 2배로 다운샘플링되어

실험 중에는 400×400.

C. 논의 및 제한 사항

우리의 DNGaussian은 거친 단안 깊이를 활용하여

입력이 부족한 상황에서 장면 형상을 표준화합니다.

전망, 그리고 외관에 상당한 개선을 달성합니다.

품질. 그러나 우리의 방법에는 여전히 다음과 같은 한계가 있습니다.

아래와 같이. 향후 작업에서 이러한 문제가 해결될 수 있기를 바랍니다.

더 많은 입력 보기. 단 3개의 입력 뷰 외에 우리는

또한 입력 수가 증가했을 때의 성능도 조사했습니다.

다음과 같이 LLFF 데이터세트에서 조회수는 6과 9로 증가합니다.

Table 11. 실험에서

조회수 증가, 기준 성능

또한 개선됩니다. 우리의 DNGaussian은 여전히 품질을 향상시킬 수 있습니다.

6개의 입력 뷰로 합성된 신규 뷰의 정확성. 어떻게-

입력 조회수가 너무 많아지면 제대로 작동하지 않습니다.

9개로 늘어나서 거의 충분한 양을 제공할 수 있습니다.

색상 제약. 깊이의 오류로 인해 발생할 수 있습니다.

최적화 프로세스에 부정적인 영향을 미치는 지도입니다. 는

우리 작업의 다음 단계는 불확실성을 활용하는 것입니다.

신뢰할 수 없는 감독을 필터링하기 위해 단안 깊이를 사용합니다.

조회 방법 PSNR↑ LPIPS↓ SSIM↑ A VGE↓

3

3DGS 15.52 0.405 0.408 0.209

3DGS[†] 16.46 0.401 0.440 0.192

DN가우시안 19.12 0.294 0.591 0.132

6

3DGS 20.63 0.226 0.699 0.108

3DGS[†] 21.09 0.229 0.699 0.103

DN가우시안 22.18 0.198 0.755 0.088

9

3DGS 20.44 0.230 0.697 0.108

3DGS[†] 23.21 0.176 0.785 0.076

DN가우시안 23.17 0.180 0.788 0.077

표 11. LLFF의 3, 6, 9 입력 뷰 비교

데이터세트. [†]는 동일한 하이퍼파라미터가 적용되었음을 나타냅니다.

DNGaussian과 같은 신경 컬러 렌더러.

단색 비행기. 가우시안의 이방성 형태

프리미티브로 인해 단색 평면을 표현하기가 어렵습니다.

입력 뷰가 희박한 상황에서. 첫째, 원시인

해당 지역의 색상과 깊이로 제한하기가 어렵습니다.

광선과 같은 소음과 빈 공간이 발생할 수 있습니다.

또한, 유사한 방식으로 다른 지역으로 자유롭게 이동할 수 있기 때문에 색상이 다양할수록 치밀화 작업이 더 활성화될 수 있습니다. 자주 발생하고 소음이 발생합니다. 이 문제는 광고를 통해 해결되기를 바랍니다. 추가 기하학 이전.

--- 페이지 14 ---

반사광 영역. 우리의 방법은 일부를 처리할 수 있지만 특히 깊이 감독에 의존하여 반사 영역을 Local Depth Normalization에서 일관되지 않은 적용은 이 지역의 성과는 3DGS에 여전히 어려운 과제입니다. 이 문제를 완전히 해결하려면 더 많은 사양이 필요할 수 있습니다. 시설 디자인. 구멍과 균열. 우리 Gaus-의 스플래팅 기술은 sian Splatting [18] 백본은 기존 기본 요소를 직접 병합합니다. 보간 없이 픽셀 수준의 색상을 렌더링하는 것이 좋습니다. 그러나 모든 픽셀이 겹쳐질 수는 없기 때문에 투영된 프리미티브, 두 가우스 사이의 빈 공간-

시안 프리미티브는 다음과 같은 경우 빈 공간과 균열을 일으킬 수 있습니다. 카메라 포즈가 변경됩니다. 예를 들어, 일부 빈 공간은 다음과 같습니다. 그림 14의 스캔 40에서 볼 수 있습니다. 이 작업에서 우리는 다음을 해결하려고 합니다. 이 문제는 고주파수에 더 많은 관심을 기울임으로써 발생합니다. 세부 사항을 파악하고 이에 따라 기본 사항의 밀도화를 장려합니다. 이러한 빈 공간을 채우기 위한 노력입니다. 앞으로도 우리는 이것을 믿습니다. 개선을 통해 문제를 근본적으로 해결할 수 있습니다. 표현 자체의.

참고자료

- [1] 샤이 아비단과 암논 샤슈아. 소셜적 견해 종합 텐서 공간. IEEE 컴퓨터 학회 회의 진행 중 컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지 1034~1040. IEEE, 1997. 3
- [2] 조나단 T 배런, 벤 밀든홀, 매튜 탄식, 피터 Hedman, Ricardo Martin-Brualla 및 Pratul P Srinivasan. Mip-nerf: 엔티앨리어싱 중립을 위한 다중 스케일 표현 ral 래디언스 필드. IEEE/CVF Inter의 진행에서 컴퓨터 비전에 관한 전국 회의, 5855-5864페이지, 2021. 3, 6, 2
- [3] 조나단 T 배런, 벤 밀든홀, 도르 베르빈, 프라툴 P 스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한 엔티앨리어싱된 신경 방사 필드. 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 5470-5479, 2022. 3
- [4] Wenjing Bian, Zirui Wang, Kejie Li, Jia-Wang Bian 및 빅터 아드리안 프리사카리우. 너프 없음: 중립 최적화 사전 포즈가 없는 ral 래디언스 필드. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 4160-4169, 2023. 3

- [5] 첸 안페이(Anpei Chen), Zexiang Xu, Fuqiang Zhao, Xiaoshuai Zhang, Fanbo Xiang, Jingyi Yu, Hao Su. Mvsnerf: 빠른 장군-멀티뷰 스테레오로부터 복사장 재구성이 가능합니다. IEEE/CVF 국제 컨퍼런스 진행 중 컴퓨터 비전, 페이지 14124-14133, 2021. 2, 3, 6
- [6] 안페이 첸(Anpei Chen), Zexiang Xu, 안드레아스 가이거(Andreas Geiger), 징이 유(Jingyi Yu), 하오수. Tensorf: Tensorial radiance field. 컴퓨터에서 비전 -ECCV 2022: 제17차 유럽 회의, 텔아비브, is-라엘, 2022년 10월 23~27일, 절차, XXXII부, 페이지 333-350. 스프링어, 2022. 3, 2
- [7] Zhang Chen, Zhong Li, Liangchen Song, Lele Chen, Jingyi Yu, Junsong Yuan, Yi Xu. Neurbf: 신경장 표현 적응형 방사형 기초 기능을 사용한 문장. 진행중-IEEE/CVF 국제 회의의 내용 퓨터 비전(puter Vision), 4182~4194페이지, 2023. 3
- [8] Julian Chibane, Aayush Bansal, Verica Lazova 및 Gerard 폰스몰. 스테레오 라디언스 필드(srf): 학습 보기 동기화 새로운 장면에 대한 희박한 견해에 대한 논문. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 7911-7920, 2021. 6
- [9] Wenyan Cong, Hanxue Liang, Peihao Wang, Zhiwen Fan, Tianlong Chen, Mukund Varma, Yi Wang, Zhangyang 왕. LLM 강화와 유사한 너프 강화: 일반화 가능 전문가의 의견이 혼합된 너프 트랜스포머. 진행중-IEEE/CVF 국제 회의의 내용 퓨터 비전(puter Vision), 3193~3204페이지, 2023. 3
- [10] Congyue Deng, Chiyu Jiang, Charles R Qi, Xinchun Yan, Yin Zhou, Leonidas Guibas, Dragomir Anguelov 등 Nerdi: 언어 기반 차이를 사용한 단일 뷰 너프 합성 일반적인 이미지 우선순위로서의 융합. 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 20637-20647, 2023. 3, 4, 5
- [11] Kangle Deng, Andrew Liu, Jun-Yan Zhu 및 Deva Ramanan. 깊이 감독 너프: 보기가 적고 훈련 속도가 빨라집니다. 무료로 합니다. IEEE/CVF 컨퍼런스 진행 중 컴퓨터 비전 및 패턴 인식, 12882페이지 - 12891, 2022. 3, 5
- [12] Sara Fridovich-Keil, Alex Yu, Matthew Tancik, Qinhong 첸, 벤저민 레히트, 가나자와 양주. 플레녹셀: 신경망이 없는 라디언스 필드. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 5501-5510, 2022. 3
- [13] Sara Fridovich-Keil, Giacomo Meanti, Frederik Rahbæk 워버그(Warburg), 벤자민 레히트(Benjamin Recht), 가나자와 양주(Angjoo Kanazawa). K-평면: 공간, 시간 및 외관의 명시적인 복사장. 에서 컴퓨터 비디오에 관한 IEEE/CVF 컨퍼런스 진행

- 시온 및 패턴 인식, 12479~12488페이지, 2023. 2
- [14] Shoukang Hu, Kaichen Zhou, Kaiyu Li, Longhui Yu, Lan-Qing Hong, Tianyang Hu, Zhenguo Li, 김희 이 외
류쯔웨이. Consistenerf: 신경 복사장 강화
스파스 뷰 합성을 위한 3D 일관성.arXiv 사전 인쇄
arXiv:2305.11031, 2023. 3, 4, 5
- [15] Wenbo Hu, Yuling Wang, Lin Ma, Bangbang Yang, Lin Gao, Xiao Liu, Yuewen Ma. Tri-miprf: Tri-mip 표현
효율적인 앤티앨리어싱 신경 방사 필드를 위한 방법입니다. 에서
IEEE/CVF 국제 컨퍼런스 진행
컴퓨터 비전, 19774~19783페이지, 2023. 3
- [16] Ajay Jain, Matthew Tancik, Pieter Abbeel. 너프 적용
다이어트 중: 의미상 일관된 퓨샷 뷰 합성.
IEEE/CVF 국제 컨퍼런스 진행 중
컴퓨터 비전, 페이지 5885-5894, 2021. 2, 3, 6, 7, 5
- [17] Rasmus Jensen, Anders Dahl, George Vogiatis, Engin Tola, 그리고 헨리크 아나이스(Henrik Aanæs). 대규모 다시점 입체시 평가
유에이션. 컴퓨터에 관한 IEEE 회의 진행 중
시각 및 패턴 인식, 406~413페이지, 2014. 5
- [18] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler,
그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅
라디언스 필드 렌더링. 그래픽에 대한 ACM 트랜잭션
(ToG), 42(4):1-14, 2023. 2, 3, 4, 6, 7
- [19] 김미정, 서성욱, 한보형. 정보:
소수의 신경 볼륨 렌더링을 위한 광선 엔트로피 최소화
- 페이지 15 ---
- 데링. IEEE/CVF 회의 진행 중
컴퓨터 비전 및 패턴 인식, 12912페이지 -
12921, 2022. 3
- [20] Jon 'a's Kulh'aneek, Erik Derner, Torsten Sattler 및 Robert
바부스카. Viewformer: 몇 가지의 너프 없는 신경 렌더링
트랜스포머를 사용한 이미지. 유럽회의에서
컴퓨터비전(ECCV), 2022. 3
- [21] Lingjie Liu, Jiatao Gu, Kyaw Zaw Lin, Tat-Seng Chua 및
크리스티안 테오발트. 신경 회소 복셀 필드. 발전
신경 정보 처리 시스템, 33:15651-15663,
2020. 3
- [22] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tok-
마코프, 세르게이 자카로프, 칼 V 온드릭. 0-1-3:
하나의 이미지를 3D 객체로 제로샷합니다. 절차에서
IEEE/CVF 컴퓨터 비전 국제 컨퍼런스,
페이지 9298-9309, 2023. 3
- [23] 요나톤 루이텐, 게오르기오스 코파나스, 바스티안 레이베,
데바 라마난. 동적 3D 가우스: 추적
지속적인 동적 뷰 합성을 통해. arXiv 사전 인쇄
arXiv:2308.09713, 2023. 3
- [24] 벤 Mildenhall, Pratul P Srinivasan, Rodrigo Ortiz-Cayon,

- 니마 카데미 칼란타리(Nima Khademi Kalantari), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng)
아비셰크 카르. 국소광장융합: 실용시각동기화
규범적인 샘플링 지침을 갖춘 논문. ACM트랜잭-
그래픽 관련 정보(TOG), 38(4):1-14, 2019. 5
- [25] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik,
조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프:
뷰 동기화를 위해 장면을 신경 방사 필드로 표현
논문. ACM 커뮤니케이션, 65(1):99-106, 2021. 3,
5, 6
- [26] Thomas Müller, Alex Evans, Christoph Schied 및 Alexan-
켈러. 다중 기능을 갖춘 즉각적인 신경 그래픽 프리미티브
tiresolution 해시 인코딩. 그래픽에 대한 ACM 트랜잭션
(TOG), 41(4):1-15, 2022. 2, 3, 6
- [27] 마이클 니마이어, 조나단 T 배런, 벤 밀든홀,
Mehdi SM Sajjadi, Andreas Geiger 및 Noha Radwan. 등록-
nerf: 뷰 합성을 위한 신경 복사 필드 정규화
희박한 입력에서. IEEE/CVF 회의 진행 중
컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지
5480-5490, 2022. 2, 3, 5, 6
- [28] Guocheng Qian, Jinjie Mai, Abdullah Hamdi, Jian Ren,
Aliaksandr Siarohin, Bing Li, Hsin-Ying Lee, Ivan Sko-
Rokhodov, Peter Wonka, Sergey Tulyakov 등 매직123:
하나의 이미지에서 두 가지를 모두 사용하여 고품질 3D 객체 생성
2D 및 3D 확산 이전.arXiv 사전 인쇄 arXiv:2306.17843,
2023. 3
- [29] Ren 'e Ranftl, Alexey Bochkovskiy 및 Vladlen Koltun. Vi-
조밀한 예측을 위한 이온 변환기. ICCV, 2021. 3, 6
- [30] Ren 'e Ranftl, Katrin Lasinger, David Hafner, Konrad
신들러, 블라들렌 콜튼. 견고한 단안을 향하여
- 깊이 추정: 제로 샷 교차 데이터 세트에 대한 데이터 세트 혼합
양도. 패턴 분석 및 MA에 관한 IEEE 거래
차인 인텔리전스, 44(3), 2022. 3
- [31] 바바라 로슬(Barbara Roessle), 조나단 T 배런(Jonathan T Barron), 벤 밀든홀(Ben Mildenhall),
Pratul P Srinivasan, Matthias Nießner. 밀도가 높은 깊이
또는 희소 입력 보기의 신경 복사 필드에 대한 것입니다. 에서
컴퓨터 비디오에 관한 IEEE/CVF 컨퍼런스 진행
시온 및 패턴 인식, 페이지 12892-12901, 2022. 3
- [32] Kyle Sargent, Zizhang Li, Tanmay Shah, Charles Herrmann,
유홍성, 장윤지, 에릭 라이언 찬, 드미트리 라-
총, Li Fei-Fei, Deqing Sun 등. Zeronvs: 제로샷
하나의 실제 이미지로 360도 뷰를 합성합니다. arXiv
사전 인쇄 arXiv:2310.17994, 2023. 3
- [33] Johannes Lutz Schödl onberger 및 Jan-Michael Frahm.
동작에서 구조를 재검토했습니다. Com 회의에서
퓨터 비전 및 패턴 인식(CVPR), 2016. 4, 5
- [34] Johannes Lutz Schödl onberger, Enliang Zheng, Marc Pollefeys,

- 그리고 Jan-Michael Frahm. Un-에 대한 픽셀별 보기 선택 구조화된 멀티뷰 스테레오. 유럽회의에서 컴퓨터비전(ECCV), 2016. 4, 5
- [35] 서승현, 장연진, 광노준. 플립-erf: 몇 장의 새로운 뷰 합성을 위한 반전된 반사 광선 언니. IEEE/CVF 국제 컨퍼런스 진행 중-컴퓨터 비전에 대한 내용, 22883~22893페이지, 2023. 2
- [36] 송지운, 박성훈, 안홍규, 조석주, 광민섭, 조성진, 김승룡. 다르프: 단안을 사용하여 희박한 입력에서 복사장 강화 깊이적응, 2023. 2, 3, 5
- [37] Cheng Sun, Min Sun 및 Hwann-Tzong Chen. 직접 복셀 그리드 최적화: 복사장을 위한 초고속 수렴 재건축. IEEE/CVF 컨퍼런스 진행 중 컴퓨터 비전 및 패턴 인식, 5459페이지 - 5469, 2022. 2, 3
- [38] Jiakai Sun, Zhanjie Zhang, Jiafu Chen, Guangyuan Li, 보옌지(Boyan Ji), 레이자오(Lei Zhao), 웨이싱(Wei Xing). Vgos: Voxel 그리드 최적화 희소 입력으로부터 뷰 합성을 위한 크기화. 진행중-제32차 국제합동회의의 내용 인공지능, IJCAI-23, 1414~1422페이지. 내부-인공지능기구 공동회의-2023년. 메인 트랙. 2, 3
- [39] Jiaxiang Tang, Jiawei Ren, Hang Zhou, Ziwei Liu 및 Gang 정. Dreamgaussian: 효율성을 위한 생성 가우스 스피클렛팅 고대 3D 콘텐츠 제작. arXiv 사전 인쇄 arXiv:2309.16653, 2023. 3
- [40] 미카엘라 안젤리나 우이, 리카르도 마틴-브루알라, 레오니다스 기바스(Guibas), 케 리(Ke Li). Scade: 공간 조각의 너프 모호성을 인식하는 깊이 추정을 사용합니다. 의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 16518-16527, 2023. 3
- [41] Chen Wang, Xiang Wang, Jiawei Zhang, Liang Zhang, Xiao Bai, Xin Ning, Jun Zhou 및 Edwin Hancock. 불확실-증거 기반 스테레오 매칭을 위한 오염 추정 딥러닝. 패턴 인식, 124:108498, 2022. 3
- [42] Guangcong Wang, Zhaoxi Chen, Chen Change Loy 및 Zi-웨이 리우. Sparsenerf: 퓨샷을 위한 증류 깊이 순위 새로운 관점 합성. IEEE/CVF 절차에서 컴퓨터 비전에 관한 국제 회의(ICCV) , 페이지 9065-9076, 2023. 1, 2, 3, 4, 5, 6, 7, 8
- [43] Xiang Wang, Chen Wang, Bing Liu, Xiaoqing Zhou, Liang 장, 진 정, 샤오 바이. 멀티뷰 스테레오 딥러닝 시대: 종합적인 검토. 디스플레이, 70: 102102, 2021. 3
- [44] Xiang Wang, Haonan Luo, Zihang Wang, Jin Zheng 및 샤오바이. 다중 뷰 스테레오 네트워크를 위한 강력한 교육

시끄러운 라벨이 있습니다. 디스플레이, 81:102604, 2024. 3

--- 페이지 16 ---

[45] Zhou Wang, Alan C Bovik, Hamid R Sheikh 및 Eero P Simoncelli. 이미지 품질 평가: 오류 가시성부터 구조적 유사성. 이미지 처리에 대한 IEEE 트랜잭션, 13(4):600-612, 2004. 6

[46] 왕자항(Zihang Wang), 하오난뤄(Haonan Luo), 왕샹(Xiang Wang), 진정(Jin Zheng), 신(Xin)닝, 샤오바이. 비교학습 기반의 비수퍼-다단계 자가 훈련 전략을 갖춘 다중 뷰 스테레오egy. 디스플레이, 페이지 102672, 2024. 3

[47] 우 관준(Guanjun Wu), 이타오란(Taoran Yi), 팡 지에민(Jiemin Fang), 링시 시에(Lingxi Xie), 샤오펑(Xiaopeng)

Zhang, Wei Wei, Wenyu Liu, Qi Tian 및 Xinggang Wang.

실시간 동적 장면 렌더링을 위한 4D 가우스 스피래팅.

arXiv 사전 인쇄 arXiv:2310.08528, 2023. 3

[48] Zijin Wu, Xingyi Li, Juwen Peng, Hao Lu, Zhiguo Cao 및 웨이카이 종. Dof-nerf: 심도와 신경 방사선의 만남에이스 필드. 제30회 ACM International 회의 진행 중 멀티미디어 회의, 페이지 1718-1729, 2022. 3

[49] Jamie Wynn 및 Daniyar Turmukhambetov. 확산기:

노이즈 제거 확산으로 신경 방사 필드 정규화

시온 모델. IEEE/CVF 컨퍼런스 진행 중

컴퓨터 비전 및 패턴 인식, 4180페이지 - 4189, 2023. 2, 3

[50] Haolin Xiong, Sairisheek Muttukuru, Rishi Upadhyay, Pradyumna Chari와 Achuta Kadambi. Sparsegs: 실제-가우스 스피래팅을 사용한 시간 360° 스파스 뷰 합성.

arXiv 사전 인쇄 arXiv:2312.00206, 2023. 3

[51] DeJia Xu, Yifan Jiang, Peihao Wang, Zhiwen Fan, Yi Wang, 그리고 왕장양. Neurallift-360: 야생에서 들어올리기 2D 사진을 360도 뷰의 3D 개체로 변환합니다. 다음의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 4479-4489, 2023. 3, 4, 5

[52] Qiangeng Xu, Zexiang Xu, Julien Philip, Sai Bi, Zhixin 슈, 칼얀 순카발리, 울리히 노이만. 포인트 너프: 포인트 기반 신경 방사 필드. 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 5438-5448, 2022. 3

[53] 양 지아웨이(Jiawei Yang), 마르코 파보네(Marco Pavone), 왕 왕(Yue Wang). Freenerf: 난-자유 주파수 조정을 통한 퓨샷 신경 렌더링 입증 일반화. IEEE/CVF 컨퍼런스 진행 중 컴퓨터 비전 및 패턴 인식, 8254페이지 - 8263, 2023. 1, 2, 3, 5, 6, 7, 8

[54] Alex Yu, Ruilong Li, Matthew Tancik, Hao Li, Ren Ng, 그리고 가나자와 양주. 실시간 렌더링을 위한 Plenotree 신경 방사 필드. IEEE/CVF 절차에서

- 컴퓨터 비전에 관한 국제 컨퍼런스, 5752페이지 - 5761, 2021. 3
- [55] Alex Yu, Vickie Ye, Matthew Tancik 및 Angjoo Kanazawa. pixelnerf: 하나 또는 몇 개의 이미지에서 얻은 신경 복사장. IEEE/CVF 컴퓨터 회의 진행 중
비전 및 패턴 인식, 4578-4587페이지, 2021. 2, 3, 6
- [56] Zehao Yu, Songyou Peng, Michael Niemeyer, Torsten Sattler, 안드레아스 가이거. Monosdf: 모노큐 탐색
신경 암시적 표면 재구성을 위한 기하학적 단서
tion. 신경 정보 처리 시스템의 발전, 35:25018-25032, 2022. 3, 4, 5
- [57] Chi Zhang, Wei Yin, Billz Wang, Gang Yu, Bin Fu, 그리고 춘화쎈. 견고성을 위한 계층적 정규화
단안 깊이 추정. 신경 정보의 발전 - 처리 시스템, 35:14128-14139, 2022. 3
- [58] 장자웨이, 왕상, 샤오바이, 왕첸, 레이 Huang, Yimin Chen, Lin Gu, Jun Zhou, Tatsuya Harada 및 에드윈 R 한콕. 도메인 일반화 스테레오 재검토
기능 일관성 관점에서 네트워크를 일치시킵니다. IEEE/CVF 컴퓨터 회의 진행 중
비전 및 패턴 인식, 페이지 13001-13011, 2022. 3
- [59] 리처드 장, 필립 이솔라, 알렉세이 A 에프로스, 엘리 세흐트-남자, 그리고 올리버 왕. 불합리한 효율성
지각 지표로서의 심층 기능. 절차에서
컴퓨터 비전 및 패턴 인식에 관한 IEEE 컨퍼런스
섹션, 586~595페이지, 2018. 6
- [60] Tinghui Zhou, Shubham Tulsiani, Weilun Sun, Jitendra Malik, Alexei A Efros 등이 있습니다. 외관 흐름별로 합성을 봅니다.
컴퓨터 비전 -ECCV 2016: 제14회 유럽 회의-
ence, 네덜란드 암스테르담, 2016년 10월 11~14일,
절차, 파트 IV 14, 페이지 286-301. 스프링어, 2016. 3
- [61] Xiaoqing Zhou, Xiang Wang, Jin Zheng 및 Xiao Bai. 효율적인 다중 뷰 스테레오를 위한 적응형 공간 희소화
매칭. Acta Electronica Sinica , 51(11):3079-3091, 2023. 3
- [62] Zhizhuo Zhou 및 Shubham Tulsiani. 스파스퓨전: 디스-3D 재구성을 위한 뷰 조건 확산 경작. 에서
CVPR, 2023. 3
- [63] Zehao Zhu, Zhiwen Fan, Yifan Jiang 및 Zhangyang Wang. Fsgs: 가우스를 이용한 실시간 퓨샷 뷰 합성
튀는. arXiv 사전 인쇄 arXiv:2312.00451, 2023. 3

[논문 12] SparseGS 본문 전체 번역

--- 페이지 1 ---

SparseGS: 3D 가우스 스플래팅을 사용한 스파스 뷰 합성

Haolin Xiong^{1,3,†,*}, Sairisheek Muttukuru^{1,*}, Hanyuan Xiao^{2,3}, Rishi Upadhyay¹

프라디움나 차리¹ 야지에 자오^{2,3} 아추타 카담비¹

¹캘리포니아대학교 로스앤젤레스 ²서던캘리포니아대학교

³USC 창의기술연구소

그림 1. 3DGS[12]의 품질은 특히 무한한 장면에서 입력 뷰 수가 감소함에 따라 저하됩니다. SparseGS 빠른 훈련과 실시간 렌더링을 유지하면서 희소 입력 설정에서 새로운 뷰 합성 품질을 크게 향상시킵니다.

초록

3D GS(3D Gaussian Splatting)가 최근 활성화되었습니다.

새로운 시각을 위한 무한한 3D 장면의 실시간 렌더링

합성. 그러나 이 기술에는 조밀한 훈련이 필요합니다.

3D 형상을 정확하게 재구성하기 위해 뷰를 생성합니다. 제한된

입력 뷰 수가 많아지면 재구성 성능이 크게 저하됩니다.

품질이 저하되어 "플로터"와 같은 아티팩트가 발생합니다.

보이지 않는 시점에서의 "배경 붕괴". 이 작품에서는

효율적인 훈련 파이프라인인 SparseGS를 소개합니다.

시나리오에서 3DGS의 한계를 해결하기 위해 서명되었습니다.

희박한 훈련 보기. SparseGS는 깊이 사전을 통합합니다.

새로운 깊이 렌더링 기술 및 가지치기 휴리스틱

보이지 않는 관점과 함께 플로터 아티팩트를 완화하기 위해

배경 붕괴를 완화하기 위한 정규화 모듈입니다.

Mip-NeRF360, LLFF 및

DTU 데이터 세트는 SparseGS가 높은 성능을 달성했음을 보여줍니다.

무제한 및 순방향 모두에서 품질 재구성

12개와 3개의 입력 이미지만으로 시나리오에 직면하고,

각각 빠른 훈련과 실시간을 유지하면서

렌더링 능력.

* 동등 기여.

† 교신저자. {xiongh@ucla.edu}

1. 소개

2D 이미지에서 3D 표현을 학습하는 과제

오랫동안 관심을 받아온 분야였지만,

효율성과 충실도 사이의 균형은 여전히 중요합니다.

꾸준한 도전. NeRF(신경 복사 장)

고품질 렌더링에 탁월하며 효과적으로 표현합니다.

뷰 보간 시 이방성 효과로 인해 어려움을 겪습니다.

학습 시간이 길고, 뷰가 희박한 경우 흐릿함

입력으로 제공됩니다. 최근 3D Gaus-

3DGS(sian Splatting)는 훈련 시간을 크게 줄였습니다.

보다 간결하고 명시적인 3D 표현을 도입하여 비용을 절감합니다.

실시간 렌더링 파이프라인과 결합됩니다. 그러나,

3DGS는 여전히 고유한 AM으로 인한 아티팩트 때문에 어려움을 겪고 있습니다.

희박한 입력으로 인한 3D에서 2D 투영의 복잡성

조희수.

"플로터"(고밀도 플롯)와 같은 3DGS의 아티팩트
 잘못 배치된 가우시안으로 인한 영역) 및 "배경
 붕괴"(가우시안이 통합에서 잘못 배치되어 발생)
 깊이를 직선화하여 배경 가우스가 나타납니다.
 전경에서) 그보다 더 두드러지는 경향이 있습니다.
 NeRF에서. 이러한 문제는 다음과 같은 경우 더욱 악화됩니다.
 훈련 세트에는 다음과 같은 장면 적용 범위가 부족합니다.
 다중 뷰 무한한 장면 [2](360도라고 함)
 이 문서의 나머지 부분에 나오는 장면). 3DGS의 확장, 예:
 [14, 49]와 같이 깊이 사전을 다음과 같이 통합하려고 시도했습니다.
 기하학 감독이나 정규화 도구를 사용했지만 여전히 실패했습니다.
 arXiv:2312.00206v3 [cs.CV] 2025년 3월 26일

--- 페이지 2 ---

특히 무한한 플로터 문제를 해결합니다.
 장면. 우리는 동일한 알파를 순진하게 적용하는 것을 관찰합니다.
 렌더링 깊이에 대한 혼합 방정식으로 인해 그라데이션이 발생할 수 있음
 잘못된 가우스로 전파되어 부정적인 영향을 미침
 품질. 또한,
 훈련 뷰는 과적합 문제를 완화하지 않습니다.
 따라서 배경 붕괴 문제를 해결하지 못했습니다.
 회소 입력 설정.
 우리의 목표는 360도 각도로 정확하게 재구성하는 것입니다.
 12개의 입력 이미지를 사용하여 제한된 3D 장면을 생성합니다. 받는 사람
 앞서 언급한 "플로터" 및 "배경 열"을 해결합니다.
 3DGS 표현의 '실패' 문제에 대해 세 가지를 소개합니다.
 핵심 모듈. 먼저, 우리는 두 가지 새로운 깊이 렌더링을 제안합니다.
 기술(소프트맥스 스케일링 깊이 및 모드 선택)

깊이) 널리 사용되는 알파 블렌딩 깊이를 넘어서는
 플로터를 보다 효과적으로 관리할 수 있습니다. 다음으로, 우리는
 레버로 배경 붕괴를 해결하도록 설계된 모듈-
 2D 생성 확산 이전 [16, 26] 및 깊이 노화
 워핑 [22, 44]. 마지막으로 명시적인 na 를 활용합니다.
 직접적인 장면을 허용하는 3DGS 표현의 특성
 조작을 통해 플로터 가지치기 절차를 제시합니다.
 원하지 않는 가우스를 식별하고 제거합니다. 결합,
 우리 파이프라인은 최첨단(SOTA) 성능을 달성했습니다.
 회소 입력 신규 뷰 합성(NVS) 문제에서는 그렇지 않습니다.
 전방을 향한 데이터세트에서만 가능하지만 360도 비방향 데이터세트에서도 가능합니다.
 제한된 장면, 최신 몇 장의 기술이 적용되는 시나리오
 niques [14, 24, 40]는 효과적으로 처리하는 데 어려움을 겪고 있습니다.
 요약하면 우리의 기여는 다음과 같습니다.
 1. 훈련을 위한 새로운 프레임워크인 SparseGS를 제안합니다.
 일관되고 강력한 3D 가우스 표현
 제한된 입력, 희박한 SOTA 방법보다 성능이 뛰어남
 합성을 봅니다.

2. SparseGS는 다음을 도입하여 "플로터" 문제를 해결합니다.
모드 선택 및 소프트맥스 스케일링 깊이 렌더링
기술.

3. SparseGS는 보이지 않는 관점 정규화를 도입합니다.
정규화를 통해 과적합을 완화하는 모듈
기존과는 다른 관점에서 3DGS 교육을 진행하고 있습니다.
견해를 넣어라. 경험적으로 모듈은 "배경"을 줄입니다.
최소 입력 설정에서 축소".

4. SparseGS는 또한 명시적 및 적응형 옵션을 도입합니다.
바람직하지 않은 떠다니는 아티팩트를 추가로 제거하는 레이더
3DGS.

2. 관련 업무

우리는 특히 3D 장면의 신경 표현에 중점을 둡니다.
제공되는 세부 수준을 고려한 래디언스 필드
그리고 새로운 뷰 합성의 확장성 또한, 우리는
렌더링 품질 향상을 목표로 한 plore 관련 작업
최소 보기 이미지만 있는 경우 아티팩트를 해결합니다.
입력으로 제공됩니다.
래디언스 필드. 3D로 제공되는 신경 복사장(NeRF)
장면 표현은 [20]에 의해 처음 소개되었습니다. NeRF
자연스럽게 나타나는 밀도와 색상의 연속적인 장을 학습합니다.
고차원 외관 특징을 다른 방식으로 보간합니다.
발효 가능한 방법. 체적 렌더링 방정식은 다음과 같습니다.

$C =$

NX

$\alpha_i = 1$

티시시치, (1)

$\alpha_i = (1 - \exp(-\alpha_i \cdot \rho_i)), T_i =$

$\alpha_i \cdot 1Y$

$j=1$

$(1 - \alpha_i), (2)$

여기서 C 는 광선을 따라 집계된 색상이고 T_i 는 투과 색상입니다.

광선을 따라 샘플링된 점 i 의 투과율, α_i 는 밀도입니다.

ρ_i 는 α_i 이고 c_i 는 i 의 색입니다. 전직의 난폭한 그룹

긴장 작업은 더 어려운 데이터 세트를 도입합니다 [13, 21],

훈련 속도[23] 또는 품질[1]을 개선하고 NeRF를 적용합니다.

다른 작업에 [42, 47]. 그 중 Mip-NeRF [1]

렌더링을 통해 NeRF에 멀티스케일링 개념을 도입했습니다.

광선보다는 원추형 절두체를 사용합니다. 그 결과, Mip-

NeRF는 지속적으로 높은 수준에서 멀티스케일링 렌더링을 수행할 수 있습니다.

훈련 뷰와는 다른 초점 거리의 품질. mip-

NeRF 360 [2]은 특히 다음과 같은 Mip-NeRF를 추적했습니다.

360° 무한한 장면 표현의 병목 현상을 주도했습니다.

이 작업에서 우리는 미래 지향적인 장면과

까다로운 최소 보기 입력으로 360° 무한한 장면 제공

작업.

3D Gaussian Splatter(3DGS)[12]는 다음과 같은 점을 도입했습니다.

다음은 달성하는 기반의 차별화 가능한 3D 표현
 Petitive 렌더링 품질, 훈련 시간 및 실시간
 고해상도로 렌더링합니다. 볼륨이 있는 포인트(또는
 표시)는 위치, 회전, 배율 조정에 따라 매개변수화됩니다.
 볼투명도 및 구면 고조파 계수 세트
 뷰에 따른 색상. 특히 스피클렛의 기하학적 구조는
 다음과 같이 구성된 전체 3D 공분산 행렬로 정의됩니다.
 스케일링 행렬과 회전 행렬을 사용합니다. 미분 가능한
 설정을 통해 간단한 색상 감도로 교육 가능
 NeRF로서. 3DGS는 NeRF의 대표 확장성을 향상시킵니다.
 NeRF가 대규모 장면을 인코딩할 수 없는 분노
 MLP의 매개변수 수는 제한되어 있습니다. 게다가 3D
 가우스 표현은 암시적 표현이 아닌 명시적입니다.
 NeRF의 표현을 통해 보다 직접적인
 편집과 해석이 더 쉬워졌습니다. 우리는 이 제안을 활용합니다.
 개인정보를 식별하고 직접 삭제하는 기술을 보유하고 있습니다.
 플로터.

최근 작품은 3D Gaussian Splatting을 기반으로 구축되었습니다.
 텍스트를 포함한 다양한 다운스트림 작업을 수행합니다.
 3D 생성 [38, 46], 동적 장면 표현 [17,
 43], 인간에게 생명을 불어넣는 것 [50].
 몇 장의 단편소설 보기 종합. 소설의 문제
 몇몇 이미지의 뷰 합성이 상당한 성과를 거두었습니다.
 많은 뷰 합성 기술에 관심이 있을 수 있습니다.
 실제 사용에 비해 조회수가 엄청나게 높습니다.
 초기 기술 [34, 39, 48]은 다중 평면 이미지를 활용합니다.
 (MPI)는 서로 다른 하위 이미지로 이미지를 나타냅니다.

--- 페이지 3 ---

그림 2. 우리가 제안한 파이프라인은 깊이 사전, 확산 제약, 플로터 가지치기 기술을 통합하여 소수를 개선합니다.
 새로운 시각 합성 성능을 촬영했습니다. 훈련하는 동안 우리는 소프트맥스 깊이를 렌더링하고 Pearson 상관 관계를
 사용하여 정렬하도록 권장합니다.
 dpt로(섹션 3.2). 또한 절차(초 3.3.1)를 사용하여 새로운 보기를 생성하고 점수 증류 샘플링 손실을 통합합니다. 에
 미리 설정된 간격으로 Sec.에 설명된 고급 플로터 제거 절차에 따라 플로터를 정리합니다. 3.4.
 깊이, 새로운 관점에서 깊이와 색상을 다시 렌더링합니다.
 전통적인 변환을 사용합니다. 최신 기술
 NeRF 프레임워크 위에 구축되었으며 다음과 같은 문제를 해결하는 경향이 있습니다.
 두 가지 방법 중 하나로 문제를 해결합니다. 첫 번째 방법 세트
 뷰 간의 변화에 대한 제약을 도입합니다. 안
 이러한 유형의 방법의 초기 예는 DietNeRF[8]입니다.
 이는 높은 수준의 의미를 보장하기 위해 제약 조건을 추가했습니다.
 tic 기능은 이후 다양한 관점에서 동일하게 유지되었습니다.
 그들은 같은 물건을 담고 있었습니다. 또 다른 예는 Reg-
 색상과 깊이 일관성을 모두 적용하는 NeRF [24]
 새로운 관점에서 출력 손실. 두 번째 세트의 메타-
 ods는 소설에 깊이 사전을 추가하여 문제에 접근합니다.

출력을 정규화하는 뷰입니다. SparseNeRF [40]은 이에 속합니다.
 카테고리별 지정하고 사전 훈련된 깊이 추정 모델을 사용하여
 의사 지상 진실 깊이 맵을 얻은 다음 다음에 사용됩니다.
 로컬 깊이 순위 손실. 추가로 깊이를 적용합니다.
 렌더링된 깊이 맵을 장려하기 위한 부드러움 손실
 조각조각 매끄럽게. DSNeRF [3]도 추가 깊이를 사용합니다.
 감독하지만 Structure-From-Motion의 출력을 사용합니다.
 대신 Motion(SFM) 파이프라인(일반적으로 COLMAP [32])
 사전 훈련된 모델의 위의 기술 외에도
 Neo 360 [7]은 3면을 사용하여 제한된 장면을 표현합니다.
 더 효율적으로. [14]는 희소 뷰 3DGS 재구성을 다룹니다.
 깊이 정규화 및 단안 깊이 에스를 사용한 구조-
 타이밍. 동시 작업[49]은 더 발전된 기능을 도입합니다.
 3DGS에 맞춰진 치밀화 전략과 시뮬레이션을 활용합니다.
 ilar 제로 샷 깊이 추정기 [27, 28]. 최선을 다해
 지식 [7, 49]은 다음을 실행하는 유일한 기준 방법입니다.
 360° 소수의 새로운 시각 동기화 문제를 명시적으로 해결합니다.
 논문.

3. 방법

개요. 우리의 방법은 세 가지 핵심 구성 요소로 구성됩니다.
 뷰 편의성을 향상시키기 위해 응집력 있게 작동하도록 설계된 장치
 새로운 뷰 합성의 지속성 및 깊이 정확도:
 깊이 상관 손실, 보이지 않는 관점 정규화
 (UVR) 모듈 및 플로터 가지치기 작업을 수행합니다. 다음에서-
 Lowing 섹션에서는 먼저 세 가지 임대 방법에 대해 논의합니다.
 3DGS 장면에서 심도를 낮추고 패치 기반
 깊이 손실. 그런 다음 UVR 모듈을 두 개로 분해합니다.
 부분: SDS(Score Distillation Sampling) 손실 및 깊이
 뷰를 정규화하기 위해 설계된 워핑 손실
 각각 훈련 카메라에 먼 지점과 가까운 지점을 지정합니다.
 마지막으로 플로터 가지치기 절차를 소개합니다.
 깊이를 활용하여 잘못 배치된 가우스를 식별하고 제거합니다.
 (“플로터”). 그림 2는 다음의 상위 수준 아키텍처를 보여줍니다.
 우리 파이프라인.

3.1. 모드 선택 및 소프트웨어 스케일링 깊이 Ren- 데링

알파 블렌딩은 NeRF에서 널리 사용되는 기술입니다[20]
 깊이 맵을 렌더링하기 위한 것입니다. 같은 방법을 적용하면
 픽셀(x, y)에서의 알파 블렌딩 깊이인 3DGS는 다음과 같이 나타냅니다.

달파

x, y 는 다음과 같이 계산됩니다.

달파

$x, y =$

$N \times$

나는=1

티아이디 (3)

여기서 T_i 는 i 번째 가우스에 대한 누적 투과율입니다.

sian, i 는 알파 합성 가중치, d_i 는 깊이
가우스의. 이 렌더링 접근 방식에서는 깊이 값이
하나의 픽셀은 해당하는 모든 가우스의 영향을 받습니다.
스폰딩 레이. 결과적으로 모델은 전송을 조정할 수 있습니다.

--- 페이지 4 ---

그림 3. 세 가지 종류의 깊이에 대한 시연. 는
가중치 w_i 는 적용 후 가중치와 함께 상단에 표시됩니다.
Softmax는 아래 w_s 로 표시됩니다. 비록 단일 가우스-
sian은 가장 높은 가중치를 가질 수 있고, 근처의 다른 낮은 가중치 Gaus-
sian은 여전히 깊이 계산에 영향을 미칩니다. 소프트맥스를 적용하여
스케일링, 깊이 축적은 가우시안 쪽으로 편향됩니다.
더 높은 가중치. 깊이 피어슨 상관관계는 다음과 같은 가능성이 적습니다.
플로터의 불투명도를 조작하여 실제 깊이를 왜곡합니다. 작성자:
훈련이 끝나면 우리 모델은 저중량 Gaus-
sian을 올바른 깊이의 단일 가우스 포인트로 변환하여
모든 깊이 변화가 정렬됩니다.
대신에 잘못 배치된 가우스의 미터스 값
위치를 변경하여 2D 깊이 맵을 표시합니다.
잘못된 각도에도 불구하고 훈련 각도에서 정확합니다.
근본적인 3D 기하학. 그래서 우리는 두 가지 다른 것을 소개합니다
나중에 사용되는 3DGS에서 깊이를 렌더링하는 방법
섹션.
모드 선택. 모드 선택에서 가우스의 깊이는-
가장 큰 기여를 하는 sian $w_i = T_i$ i 는
해당 픽셀의 깊이. 모드에서 선택한 픽셀 깊이는
다음과 같이 작성됩니다:
d모드
$$x, y = \text{darg max}_i(w_i). \quad (4)$$

직관적으로 모드에서 선택한 깊이는 가장 높은 것을 선택합니다.
불투명도 가우시안, 알파 블렌딩 깊이는
가상 광선을 따라 모든 가우스를 계산합니다.
카메라. 가지치기 작업을 구축하기 위한 중요한 통찰력은
tor는 dmode와 d_{α} 가 이상적으로 동일해야 한다는 것입니다. 반대
그림 3의 왼쪽에 있는 장난감 설정을 살펴보세요. 이 시나리오에서는
dmode는 두 번째 가우스의 깊이에 해당합니다.
왼쪽은 w_i 가 가장 높기 때문입니다. 그런데 달파가 나타나요
낮은 영향으로 인해 이 가우시안보다 약간 뒤떨어집니다.
더 깊은 깊이를 가진 가중치 가우스. 이러한 불일치는
실제 깊이에 대해 모호함을 만듭니다. 우리는 이것을 해석한다
3DGS의 불확실성을 측정하는 모호성
특정 지점을 지정하고 이를 활용하여 가지치기 작업자를 안내합니다.
나중에 소개함.
소프트맥스 스케일링. 모드를 사용하여 깊이를 렌더링하면서
에 기여하는 가장 중요한 가우스를 식별합니다.
깊이, $\arg \max$ 연산자는 동안 기울기를 제한합니다.
높은 가우시안으로만 역전파 흐름
그렇죠. 이 접근법은 Gaussian이 다음과 같은 경우 문제가 될 수 있습니다.

보는 사람에게 가까울수록 반투명합니다.
 가우스는 0이 아니어야 합니다. 이를 극복하기 위해서는
 제한 사항이 있으므로 Mod에 Softmax-scaling을 추가로 도입합니다.
 알파 블렌딩을 강화합니다:

dsoftmax

$x, y = \log$

PN

$i=1 \dots N$ $w_i d_i$

PN

$i=1 \dots N$ w_i

!

, (5)

여기서 매개변수를 사용하면 소프트맥스를 변조할 수 있습니다.

온도에 따라 원하는 증폭을 선택합니다.

가중치가 높은 가우시안. 참고 사항:

임

$\rightarrow 0$

dsoftmax

$x, y = \log(\alpha)$

x, y , (6)

임

$\rightarrow \vee$

dsoftmax

$x, y = \log(d_{\text{mode}})$

x, y , (7)

소프트맥스 스케일링 추가 기능을 사용하면 다음과 같은 근사값을 얻을 수 있습니다.

가우스에 그래디언트를 전파하는 동안 모드 깊이

시안 모드를 꺼주세요.

3.2. 패치 기반 깊이 상관 손실

사전을 사용하여 의사 지상 진실 깊이 맵을 계산합니다.

훈련 뷰에 대한 훈련된 깊이 추정 모델.

우리는 Marigold 단안 깊이 추정기[11]를 선택합니다.

사전 훈련된 깊이 추정 모델 [18, 27, 28,

35] 작동할 수 있습니다. 우리는 이 사전 훈련된 깊이를 참조합니다.

dpt로 모델을 지정하세요.

단안 추정 모델은 상대적인 예측을 하기 때문에

깊이, 알파 블렌딩, 소프트맥스 스케일링 및 모드-

선택 깊이는 COLMAP에 고정되어 직접 적용됩니다.

평균 제곱 오차(MSE)와 같은 L2 손실은 다음과 같습니다.

효과가 없습니다. 한 가지 옵션은 규모 및 이동 매개변수를 추정하는 것입니다.

미터법 공간에서 두 개의 깊이 맵을 정렬하는 데 사용됩니다. 그러나,

이 변환은 전체에서 일정하다고 보장되지 않습니다.

모든 픽셀과 순진한 정렬로 인해 추가 문제가 발생할 수 있습니다.

원치 않는 왜곡. 대신에 Pearson 상관관계를 채택합니다.

유사성 지표를 계산하기 위해 이미지 패치 전반에 걸쳐

깊이 맵 사이. 이 접근 방식은 시뮬레이션에서 파생됩니다.

이전에 제안된 깊이 순위 손실과 같은 직관
작업 [40]은 둘 다 상대적인 깊이를 활용하여 다음을 확인합니다.
글로벌 깊이를 유지합니다. 하지만 순위를 비교하기보다는
반복당 두 개의 선택된 픽셀을 비교합니다.
전체 패치를 통해 모델이 더 큰 부분에 영향을 미칠 수 있습니다.
이미지를 보고 더 많은 지역 구조를 알아보세요. 배-
아들 상관 계수는 동시에 패치를 권장합니다.
두 깊이 맵의 위치는 높은 상호 상관 관계를 가지며,

--- 페이지 5 ---

깊이 값 범위의 변화에 관계없이. 각 반복에서-
따라서 우리는 겹치지 않는 N개의 패치를 무작위로 샘플링하여
깊이 상관 손실을 다음과 같이 계산합니다.
깊이 = 1
엔
NX
나
1 - PCC(psoftmax
나, pdpt
나) (8)
여기서 psoftmax
나는 $\in$ RS2
dsoftmaxand의 i번째 패치를 나타냅니다.
PPT
나는 $\in$ RS2
dpt의 i번째 패치를 나타내며 패치 크기는 S입니다.
경험적으로 1/100로 선택된 하이퍼 매개변수입니다.
이미지 해상도. 또한 글로벌 Pearson 심도
깊이 불연속성을 방지하기 위해 손실을 적용해야 합니다.
패치 가장자리에 나타납니다. 직관적으로 이 손실은 정렬에 작용합니다.
가우시안 표현의 소프트맥스 스케일링 깊이 맵
불일치 문제를 피하면서 dpt를 사용하여 tation
규모와 변화.

3.3. 보이지 않는 관점 정규화(UVR)

이 섹션에서는 두 가지 정규화 방법을 제안합니다.
새로운 관점에서 재건을 개선합니다.

- 1). SDS(Score Distillation Sampling) 손실: 이 손실 레버는
관점에서 훈련을 안내하기 위해 대형 비전 모델 [30]을 사용합니다.
원래 훈련 카메라에서 멀리 떨어진 지점,
렌더링이 더욱 자연스럽게 보이도록 합니다.
- 2). 깊이 뒤틀림 손실: 이 손실은 단안을 활용합니다.
훈련 이미지를 가까운 각도로 워프하기 위한 추정 깊이,
추가 의사 훈련 카메라를 효과적으로 생성
재투영된 뷰에서.

3.3.1 점수 증류 샘플링 손실

그림 4. SDS 손실로 인한 이점을 보여줍니다. 동안
장면 구조는 잘 보존되어 있으며 두 장면 모두 고주파 노이즈가 있습니다.

기하학과 질감이 크게 감소합니다(빨간색 상자).
 sparse-view 설정에서는 잘 구성된 가우시안이
 입력 관점에서 긴장된 부분은 종종 작은 조각으로 나타납니다.
 다른 샘플링된 관점에서 렌더링된 사고. 이것은-
 고소는 잘못 배치된 가우스 또는 느슨하게 제한된 제약으로 인해 발생합니다.
 고차원적인 색상 표현. 간단하게 부드럽게-
 라플라시안 스무딩(Laplacian Smoothing)과 같은 기술을 사용하면 손실이 발생합니다.
 세부적으로 선명도. 최근 확산 모드에서 영감을 얻었습니다.
 els [5, 9, 25, 26, 31, 45] 및 점수 증류 샘플링
 (SDS) [38] 제로샷 3D 재구성을 위한 [6, 15, 16, 36],
 우리는 개선하기 전에 미리 훈련된 2D 확산을 사용할 것을 제안합니다.
 3DGS 재구성. 사전 확산이 예상됩니다.
 의미 있는 이미지 세부정보 보존(분포 내 모델링)
 확산 모델에 따라) 비사실적인 AR을 제거하면서
 티팩트(확산 모델로 모델링된 분포 외).
 구체적으로 우리는 샘플을 실행하는 전략을 구현합니다.
 장면 중심 주변의 돔 시점은 다음에서 추정됩니다.
 입력 카메라. 그런 다음 샘플링된 뷰의 렌더링은 -
 포인트는 확산 모델에 의해 인코딩 및 디코딩됩니다.
 예측된 소음은 SDS를 통해 감속됩니다.
 손실은 다음과 같이 공식화됩니다.

나는 = N ($\sqrt{\frac{1}{N} \sum_{i=1}^N \|I_i - I\|^2}$), (9)

$$LSDS = \nabla G E[(\frac{1}{N} \sum_{i=1}^N \|I_i - I\|^2)^\alpha] + \lambda \|p - p_0\|^2$$
 , (10)
 여기서 G는 가우스 표현의 매개변수를 나타냅니다.
 문장에서 α 는 1마일의 누적 곱을 나타냅니다.
 μ 는 분산 일정, σ 는 샘플링된 노이즈, $\phi(\cdot)$
 확산 모델에 의해 예측된 소음입니다. p 는 다음을 의미한다
 노이즈가 추가된 카메라 포즈 p에서 렌더링된 이미지, en-
 확산 모델에 의해 코딩되었으며 $\sim p$ 는 잡음이 제거된 IM입니다.
 나. 우리는 렌더링 결과를 우리의 유무에 따라 비교합니다.
 모듈이 성공적으로 제거된 그림 4의 SDS 손실
 장면 구조를 벗어나는 동안 고주파 아티팩트
 손대지 않은.

3.3.2 깊이 뒤틀림 손실

3DGS는 훈련 뷰에 맞춰 작동합니다.

기본 기하학을 배울 것이라고 기대합니다.
 장면. 그러나 희소 입력 설정에서는 모델이 다음과 같은 경향이 있습니다.
 제한된 데이터에 과도하게 과대적합하여
 보기에 약간의 변화가 있어도 배경이 무너지지 않습니다.
 각도. 깊이 있는 사전 학습 뷰를 정규화
 극단적인 희소 보기 시나리오에서는 도움이 되지만 충분하지 않습니다.
 이 문제를 해결하기 위해 우리는 이미지 재투영(image re-projection)을 사용합니다.
 강화하기 위해 확립된 깊이 워핑 기술[22, 44]

주변 뷰에 이미지를 다시 투영하여 훈련 데이터를 생성합니다.
포인트.

깊이 맵에 의존하는 이전 방법 [3]과 달리
노이즈가 자주 발생하는 COLMAP에서 생성된
허위 서신, 시끄러운 카메라 매개변수로 인해-
ter 또는 열악한 COLMAP 최적화를 발견했습니다.

단안 추정 깊이의 상대적 범위를 확장하는 것
렌더링된 알파 블렌딩 깊이 범위와 일치하는 맵
지도는 깊이 뒤틀기에 충분합니다. 결과적으로,
뒤틀림의 품질은 품질에 크게 좌우됩니다.

미니 달파

나, 맥시 달파

나, 그리고 dpt. 그러나 실제로는

--- 페이지 6 ---

현재 단안 추정 모델 [11]에서 우리는 다음과 같은 결과를 얻었습니다.

뒤틀린 결과의 대부분의 영역은 안정적이고 프로 -

앞서 언급한 Pearson 깊이 손실이

합리적인 수준에 이르렀다.

수학적으로 이미지 재투영을 다음과 같이 정의합니다.

다음과 같습니다: imgelsrc 훈련의 픽셀 $\text{pi}(x_i, y_i)$ 에 대해 워프는-

보이지 않는 뷰에서 해당 $\text{pixelpj}(x_j, y_j)$ 로 이동합니다.

포인트 ltrg 는 다음과 같이 공식화될 수 있습니다.

$\text{pj} = \text{KtrgT}(\text{K}^{-1}$

$\text{src Zipi}), (11)$

여기서 Z_i 는 단안 추정 깊이 맵을 나타냅니다.

미니 달파 범위로 확장

나와 맥시 달파

나. Ktrg 및

Ksrc 는 소스와 타겟의 고유 행렬입니다.

카메라, T 는 카메라 간 변환을 나타냅니다.

관점 lsrc 에서 ltrg 까지 포즈를 취합니다. 워프 마스크 M 표시

어떤 픽셀이 유효하게 워프되었는지는 다음과 같이 생성됩니다.

프로세스. 마지막으로 Depth Warping lossLProj 가 공식화됩니다.

다음과 같이:

$\text{LProj} = M * \text{L1}(\text{I}, \text{ltrg}). (12)$

3.4. 고급 플로터 가지치기

소프트맥스 깊이 손실은 소프트 제약이기 때문에

dmode 와 dalpha 가 정렬되지 않는 영역이 존재할 수 있습니다. 로서

결과적으로 일부 플로터는 입력 광선을 따라 남아 있을 수 있습니다.

조희수. 따라서 우리는 새로운 가지치기 연산자를 제안합니다.

훈련이 끝나면 잘못된 모드에서 가우스를 제거합니다.

우리는 다음과 같이 각 훈련 뷰 i 에 대해 마스크 F_i 를 생성합니다.

픽셀당 상대 차이를 나타내는 $\hat{d}_i$ 를 계산합니다.

모드 선택에서 얻은 깊이와

알파 블렌딩의 깊이. 분포도를 조사한 결과,

$\hat{d}_i$ 의 경우, 우리는 숫자를 포함하는 이미지를 관찰했습니다.

플로터는 일반적으로 이중 모드 히스토그램을 나타냅니다. 이것은 플로터는 일반적으로 상당히 멀리 위치하기 때문에 진정한 깊이에서. 반대로 플로터가 없는 이미지는 더 많은 단봉형 히스토그램을 갖는 경향이 있습니다. 이 차이는 그림 5(c)에 설명되어 있습니다. 이 관찰을 바탕으로 우리는 분포를 더욱 단봉으로 만들기 위한 α 에 대한 임계값, 이로써 부유물의 존재를 최소화합니다. 예 플로터 마스크의 그림은 그림 5(d)에 나와 있습니다. 생성 후 마스크를 사용하여 모든 가우시안을 식별하고 정리합니다. 가우시안 모드를 포함합니다. 이번 가지치기의 효과는 다음과 같습니다. 그림 5(b)에 설명되어 있습니다. 완전한 가지치기 알고리즘 보충 자료에 자세히 설명되어 있습니다.

4. 실험

4.1. 실험 설정

데이터 세트. 우리는 세 가지 데이터 세트에 대해 실험을 수행합니다.

두 가지 설정으로 분류됩니다: 1) Mip-NeRF360 [2]

7개의 까다로운 360° 장면을 포함하는 데이터세트

2) 다음을 포함하는 LLFF [19] 및 DTU [10] 데이터 세트

앞으로 나아가는 장면. Mip-NeRF360 데이터 세트의 경우

그림 5. 제안된 플로터 가지치기 기술은

부정확한 깊이의 가우스. 예 (a)는 다음을 보여줍니다.

가지치기 방법: 가지치기 전, 안에 부유물(파란색)이 있습니다.

물체 표면(빨간색)에서 가우시안 앞쪽에 있으므로,

d_{mode} α 가 정렬되지 않았습니다. 가지치기 방법은 모든 Gauss-를 제거합니다.

모드 이전에 해당 픽셀에 α 가 있고 결과적으로 $d_{mode} = \alpha$ 가 됩니다.

정원 장면(b)에 적용한 가지치기 방법은 큰 가치를 제거합니다.

장면 중앙과 왼쪽에 플로터가 있습니다. 우리는 관계가 다음과 같다고 봅니다.

상대적 차이의 히스토그램의 이중 모드 사이

d_{mode} 와 d_{mode} 사이, 정리 작업 전후

(c) 적절한 가지치기 컷오프 지점은 다음과 같습니다.

빨간색 수직선. (d) 자두 마스크 F_i (하단)는 다음과 같이 구해진다.

모드 d_{mode} 의 상대 차분 임계값 지정(상단)

컷오프 지점에서.

매 8번째 이미지를 테스트 보기로 사용하고 균등하게 샘플을 채취합니다.

나머지 보기 중 12개 또는 24개의 보기가 훈련 세트로 사용됩니다.

LLFF 및 DTU 데이터 세트의 경우 교육을 따르고

RegNeRF[24]에 확립된 평가 프로토콜. 팔로우-

관례에 따라 모든 입력 이미지는 1/4로 축소됩니다.

원래 높이와 너비.

구현 세부정보. 카메라 교정을 얻습니다.

3DGS us의 입력 뷰 및 초기 포인트 클라우드-

--- 페이지 7 ---

12뷰 24뷰모델 PSNR↑ LPIPS↓ SSIM↑ PSNR↑ LPIPS↓ SSIM↑

Mip-NeRF 360 17.73 0.520 0.432 19.78 0.431 0.530RegNeRF 18.84 0.544 0.437 20.55 0.398

0.546SparseNeRF 17.44 0.609 0.395 21.13 0.389 0.600

3DGS 17.49 0.431 0.499 19.93 0.401 0.588DNGaussian 16.28 0.549 0.432 19.26 0.440 0.550
 FSGS(MVS 제외)18.15 0.485 0.504 21.76 0.396 0.626SparseGS(MVS 제외)18.46 0.476 0.513 22.03 0.381
 0.631FSGS 19.31 0.413 0.574 22.82 0.293 0.693SparseGS(당사)19.37 0.398 0.577 23.02 0.290 0.713

표 1. Mip-NeRF360 데이터세트의 정량적 비교

12/24 입력-보기 설정.

COLMAP [32, 33]을 참조하세요. 구체적으로 초기 포인트 클라우드는

MVS(Multi-View Stereo) 단계에서 출력됩니다. 우리는 훈련한다

12개 뷰 설정에서 10,000회 반복, 24개 뷰 설정에서 30,000회 반복

설정을 봅니다. 깊이 상관 손실은 다음과 같이 적용됩니다.

MipNeRF360 데이터세트의 패치 크기는 64×64 픽셀입니다.

다른 데이터 세트의 경우 32×32 픽셀입니다. 소프트에 대한

최대 깊이는 5로 설정됩니다. 플로터 가지치기는 이후에 한 번 적용됩니다.

훈련이 완료됩니다. 일반적으로 깊이 상관 손실은

3,000번의 반복 후에 수렴됩니다. 그 사이 알파 블렌딩

이미지 재투영을 위해 깊이 맵이 렌더링됩니다. 각각에 대해

트레이닝 뷰에서는 다음과 같은 방법으로 4개의 추가 워핑 뷰포인트를 생성합니다.

장면 중심을 중심으로 카메라를 회전합니다.

우리는 확산을 위해 Stable-Diffusion 버전 2.1을 사용합니다.

초의 모델 3.3.1. SDS 손실은 두 번 후에 활성화됩니다.

전체 반복의 3분의 1, 장면의 대부분이

구조가 안정되었습니다.

깊이 뒤틀림 손실 가중치를 SDS 0.05로 설정했습니다.

5×10^{-4} 로 손실 가중치, 로컬 및 글로벌 Pearson 손실

가중치는 모두 0.15입니다.

4.2. 비교

무제한 데이터 세트. 우리는 Mip-NeRF360 데이터 세트를 사용하여

무한한 360° 장면의 3D 재구성을 평가합니다. 는

데이터 세트는 고유한 구성 요소로 인해 심각한 문제를 제시합니다.

희박한 시야에서 장면의 다양성과 강한 폐색

설정. 또한 COLMAP의 초기 포인트 클라우드는

MVS 단계를 사용하더라도 매우 제한적일 수 있습니다. 순서대로

우리 방법의 견고성을 증명하기 위해 우리는 또한 다음을 평가합니다.

Struct에 의해 출력된 더 희박한 포인트 클라우드로 형태를 조정합니다.

모션에서(즉, MVS 단계 없이) 초기화를 수행합니다.

tion. 이제부터 정량평가에서는

픽크 신호 대 잡음비(PSNR), 학습된 지각 Im-

연령 패치 유사성(LPIPS) 및 구조적 유사성 지수

(SSIM) 측정항목을 측정합니다. 탭에 표시된대로. 1, SparseGS 시그니처-

이전 NeRF 기반 방법보다 훨씬 뛰어난 성능을 발휘합니다.

12개 뷰 모두에서 동시 작업, FSGS 및 DNGaussian

24뷰 설정.

전방을 향한 데이터 세트. 우리는 또한 평가를 제공합니다

앞으로 향하는 데이터세트(LLFF 및 DTU)에 대해

우리 파이프라인의 전략적 견고성. LLFF 데이터 세트는 다음과 같습니다.

8개의 복잡한 전방 실제 장면을 담고 있으며,

DTU 데이터 세트에는 전경이 있는 객체 중심 장면이 포함되어 있습니다.

마스크. 과소 재구성된 경우에 유의하는 것이 중요합니다.

LLFF DTU모델 PSNR↑ LPIPS↓ SSIM↑ PSNR↑ LPIPS↓ SSIM↑

Mip-NeRF 15.22 0.540 0.351 16.71 0.239 0.757 RegNeRF 18.06 0.411 0.535 18.89 0.190 0.745 SparseNeRF 19.07 0.401 0.564 19.55 0.201 0.769

3DGS 16.94 0.402 0.488 14.18 0.301 0.628 FSGS 19.88 0.340 0.612 18.36 0.232 0.707 DN가우스 19.12 0.294 0.591 18.91 0.176 0.790 SparseGS(당사) 19.86 0.322 0.668 18.89 0.178 0.834

표 2. 미래 지향적 데이터셋의 정량적 비교.

깊이 PCC PSNR↑ LPIPS↓ SSIM↑ 알파 블렌딩 소프트맥스 스케일링 UVR 가지치기
17.49 0.431 0.499

18.45 0.410 0.549 18.86 0.401 0.561

19.09 0.400 0.565 19.37 0.398 0.577

표 3. 절제 연구. 우리는 구성 요소를 제거합니다.

12뷰 설정의 Mip-NeRF360 데이터 세트.

입력 커버리지가 부족한 지역, NeRF 기반

방법을 사용하면 지나치게 매끄러운 모양이 나타나는 경우가 많습니다. 이

제한으로 인해 실제로 위치 지정이 도입되었습니다.

인코딩 [20, 37]. 대조적으로, 3DGS 기반 표현은

고립된 가우시안을 배치하는 쪽으로 끌리게 됩니다.

고주파 인공물. PSNR은 지나치게 관용하는 경향이 있습니다.

이미지를 매끄럽게 하고 날카로운 아티팩트를 크게 처벌합니다.

LPIPS와 같은 시각 지표는 그 반대를 강조합니다[41].

이로 인해 두 가지 기준 사이에 사소한 불일치가 발생할 수 있습니다.

Tab의 특정 테스트 사례에 대한 내용입니다. 2. 일반적으로 SparseGS는

이전 및 동시 SOTA 방법과의 경쟁

두 데이터 세트 모두에서.

4.3. 절제 연구

Mip-NeRF360 데이터 세트 12-view에서 방법을 제거합니다.

설정. 정량적 결과는 탭에 보고됩니다. 3. 퀄리티-

실제 수치는 그림 7에 나와 있습니다.

깊이 상관 손실. 깊이 피어슨 상관관계

손실은 3DGS 표현에 깊이 있는 지식을 도입합니다.

tation. 이 손실을 적용하여 개선 사항을 보여줍니다.

알파 블렌딩과 소프트맥스 스케일링 깊이 모두에 적용됩니다. 인디로서

탭으로 분류되었습니다. 3, 소프트맥스 스케일링 깊이 렌더링 방법

성능이 향상되어 PSNR이 1.37dB 향상되었습니다.

3DGS를 사용하여 렌더링 품질을 크게 향상시킵니다.

깊이 맵 그림 7.

보이지 않는 관점 정규화. UVR 모듈

훈련과는 다른 관점에서 정규화를 추가합니다.

관점에서 과도한 과적합 문제를 줄입니다.

최소 입력 설정. 고주파수를 효과적으로 감소시킵니다.

아티팩트를 사용하여 PSNR을 평균 0.33dB 개선합니다.

플로터 가지치기. 플로터 가지치기 휴리스틱 추가

잘못 배치된 불투명도가 낮은 항목을 삭제하여 장면을 정리합니다.

이미지와 깊이 맵을 모두 만드는 가우시안

더 날카롭게. 이 모듈은 PSNR을 0.28dB 더 향상시킵니다.

--- 페이지 8 ---

그림 6. Mip-NeRF 360 데이터 세트에 대한 정성적 평가. 우리 모델은 고주파 기하학을 효과적으로 재구성하여 보존합니다. 피사체와 배경 사이의 경계가 뚜렷합니다. 대조적으로, FSGS는 치밀화로 인해 미세한 세부 사항을 보존하는 데 탁월합니다. 기술을 사용했지만 배경 형상을 재구성하지 못했습니다. 반면, DNGaussian은 일관된 배경을 렌더링할 수 있지만 전경은 개체가 잘못 정리되었습니다.

그림 7. 절제 연구. 참조 깊이 맵은 단안 깊이 추정 모델에 의해 생성됩니다. 우리의 완전한 모델은 노이즈가 적고 더욱 깨끗하고 일관된 장면 구조를 제공합니다.

그림 8. 미래 지향적 기업에 대한 정성적 평가
데이터 세트. 우리의 방법은 고주파수 지역을 재구성할 수 있습니다.
최신 기술보다 더 정확하게 측정합니다 [49].

5. 결론

본 논문에서는 3차원 가우시안을 이용한 방법을 제안한다.

희소 뷰 3D를 처리하기 위한 스피래팅(3DGS) 표현

재건축 과제. 우리는 알파 블렌딩이

원본 3DGS의 깊이 렌더링으로 인해 위치가 잘못되는 경우가 많습니다.

가우스(“플로터”라고도 함). 그러므로 우리는 제안합니다

소프트맥스 스케일링으로 깊이 수렴을 제한하고

이러한 플로터를 크게 줄이는 모드 선택 편향.

입력 뷰의 적용 범위가 거의 없는 지역에서는 다음을 활용합니다.

점수 종류 샘플링(SDS) 및 깊이 워핑

사전에 형상의 붕괴와 텍스처의 노이즈를 줄입니다.

세부적인 내용을 제공합니다. 마지막으로 우리는 새로운 floater prun을 제안합니다.

불투명도가 낮은 부유물을 식별하고 제거하는 프로세스입니다. 에서
평가를 통해 우리의 방법이 상태보다 성능이 우수하다는 것을 보여줍니다.

훨씬 더 깨끗하고 더 많은 것을 출력함으로써 최첨단 방법을 사용합니다.

더욱 까다로운 12뷰 설정 아래 일관된 장면-

Mip-NeRF360 데이터 세트에 대한 정보입니다.

--- 페이지 9 ---

참고자료

[1] 조나단 T. 배런, 벤 밀덴홀, 매튜 탄식, 피터

Hedman, Ricardo Martin-Brualla 및 Pratul P. Srinivasan.

Mip-nerf: 엔티앨리어싱 중립을 위한 다중 스케일 표현

ral 래디언스 필드. ICCV, 2021. 2

[2] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P.

스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한

엔티앨리어싱된 신경 방사 필드. CVPR, 2022. 1, 2, 6

[3] Kangle Deng, Andrew Liu, Jun-Yan Zhu 및 Deva Ra-

마난. 심도 감독 NeRF: 부가 적고 속도가 빠릅니다.

무료로 훈련. IEEE/CVF 회의 진행 중-

컴퓨터 비전 및 패턴 인식(CVPR)에 대한 연구,

2022. 3, 5

[4] J. A. Hartigan 및 P. M. Hartigan. Uni-의 덩 테스트

양식. 통계연보, 13(1):70 - 84, 1985. 13

[5] 조나단 호, 아제이 자인, 피터 아벨. 노이즈 제거 차이

융합 확률 모델. 신경 정보의 발전

처리 시스템, 33:6840-6851, 2020. 5

- [6] Yicong Hong, Kai Zhang, Jiuxiang Gu, Sai Bi, Yang Zhou, Difan Liu, Feng Liu, Kalyan Sunkavalli, Trung Bui 및 Hao Tan. Lrm: 단일 이미지에 대한 대규모 재구성 모델 3d. arXiv 사전 인쇄 arXiv:2311.04400, 2023. 5
- [7] Muhammad Zubair Irshad, Sergey Zakharov, 캐서린 리우, 비토 귀질리니, 토마스 콜라, 아드리안 가이돈, 졸트 키라, 그리고 레레스 암브루스(Rares Ambrus). Neo 360: 희소성을 위한 신경장 야외 장면의 합성을 봅니다. 절차에서 IEEE/CVF 컴퓨터 비전 국제 컨퍼런스, 페이지 9187-9198, 2023. 3
- [8] Ajay Jain, Matthew Tancik, Pieter Abbeel. 너프 적용 다이어트 중: 의미상 일관된 퓨샷 뷰 합성. IEEE/CVF 국제 컨퍼런스 진행 중 컴퓨터 비전(ICCV), 페이지 5885-5894, 2021. 3
- [9] 아제이 제인, 벤 밀든홀, 조나단 T. 배런, 피터 아빌, 벤 풀. 제로샷 텍스트 안내 객체 생성 꿈의 발과 함께합니다. CVPR, 2022. 5
- [10] Rasmus Jensen, Anders Dahl, George Vogiatis, Engil Tola, 그리고 헨리크 아나이스(Henrik Aanæs). 대규모 다시점 입체시 평가 유에이션. 2014년 IEEE 컴퓨터 비전 컨퍼런스에서는 패턴 인식, 406~413페이지. IEEE, 2014. 6
- [11] Bingxin Ke, Anton Obukhov, Shengyu Huang, Nando Metzger, 로드리고 케이 다우드, 콘라드 쇠들러. 용도 변경-단안 깊이를 위한 확산 기반 이미지 생성기 추정. IEEE/CVF 회의 진행 중 컴퓨터비전 및 패턴인식(CVPR), 2024. 4, 6
- [12] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크ühler, 그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅 래디언스 필드 렌더링. 그래픽의 ACM 트랜잭션, 42(4), 2023. 1, 2, 11
- [13] Aviad Lev, Pratul P Srinivasan, Andrew A Chael, Ren Ng, 그리고 캐서린 L 보우만(Katherine L Bouman). 중력렌즈 블랙홀 방출 단층 촬영. IEEE/CVF 회의 진행 중 컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지 19841~19850, 2022. 2
- [14] Jiahe Li, Jiawei Zhang, Xiao Bai, Jin Zheng, Xin Ning, Jun 저우, 린 구. Dngaussian: 희소 뷰 3D 최적화 글로벌-로컬 깊이 정규화를 통한 가우스 래디언스 필드 tion. arXiv 사전 인쇄 arXiv:2403.06912, 2024. 1, 2, 3
- [15] Liu Minghua, Chao Xu, Haian Jin, Linghao Chen, Zexiang Xu, Hao Su, 그 외 여러분. One-2-3-45: 단일 이미지를 3D 메시로 변환 형태별 최적화 없이 45초 만에.arXiv 사전 인쇄 arXiv:2306.16928, 2023. 5
- [16] Ruoshi Liu, Rundi Wu, Basile Van Hoorick, Pavel Tok마코프, 세르게이 자카로프, 칼 V 온드릭. 0-1-3: 하나의 이미지를 3차원 물체로 제로샷, 2023. 2, 5

- [17] 조나톤 루이텐, 게오르기오스 코파나스, 바스티안 레이베, 데바 라마난. 동적 3D 가우스: 추적
지속적인 동적 뷰 합성을 통해. arXiv 사전 인쇄
arXiv:2308.09713, 2023. 2
- [18] S. Mahdi H. Miangoleh, Sebastian Dille, Long Mai, Sylvain 파리, Yağız Aksoy. 단안 깊이 추정 강화
콘텐츠 적응형 다중화를 통해 모델을 고해상도로
해상도 병합. Proc에서 CVPR, 2021. 4
- [19] 벤 Mildenhall, Pratul P. Srinivasan, Rodrigo Ortiz-Cayon, 니마 카데미 칼란타리(Nima Khademi Kalantari), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng) 아비셰크 카르. 국소광장융합: 실용시각동기화
규범적인 샘플링 지침을 갖춘 논문. ACM트랜잭-
그래픽 관련 정보(TOG), 2019. 6
- [20] 벤 Mildenhall, Pratul P. Srinivasan, Matthew Tancik, 조나단 T. 배런(Jonathan T. Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프:
뷰 동기화를 위해 장면을 신경 방사 필드로 표현
논문. ECCV에서는 2020. 2, 3, 7
- [21] 벤 밀든홀, 피터 헤드먼, 리카르도 마틴-브루알라, Pratul P. Srinivasan 및 Jonathan T. Barron. NeRF는
dark: 노이즈가 있는 원본에서 높은 동적 범위 뷰 합성
이미지. CVPR, 2022. 2
- [22] 모리 유지, 후쿠시마 노리시게, 후지이 토시아키, 다니모토 마사유키. 3D 워핑을 통한 뷰 생성-
ftv에 대한 깊이 정보를 전송 중입니다. 2008년 3DTV 컨퍼런스:
진정한 비전 - 3D 캡처, 전송 및 디스플레이
비디오, 페이지 229-232, 2008. 2, 5
- [23] Thomas Müller, Alex Evans, Christoph Schied 및 Alexander Keller. 다중 해상도를 갖춘 즉각적인 신경 그래픽 프리미티브
솔루션 해시 인코딩. ACM 트랜스. 그래프. , 41(4):102:1-
102:15, 2022. 2
- [24] 마이클 니마이어, 조나단 T. 배런, 벤 밀든홀, 메디 S. M. 사자디(Mehdi S. M. Sajjadi), 안드레아스 가이거(Andreas Geiger), 노하 라드완(Noha Radwan)
Regnerf: 뷰 동기화를 위한 신경 복사 필드 정규화
희박한 입력에서 나온 논문. Proc에서 IEEE 컨퍼런스. 컴퓨터에서
비전 및 패턴 인식(CVPR), 2022. 2, 3, 6
- [25] 라이언 포, 왕이판, 블라디슬라프 골야닉, 크피르 아베르만, 조나단 T 배런, 아미트 H 버마노, 에릭 라이언 찬, 탈리
Dekel, Aleksander Holynski, Angjoo Kanazawa 등 상태
비주얼 컴퓨팅을 위한 확산 모델 분야의 예술. arXiv
사전 인쇄 arXiv:2310.07204, 2023. 5
- [26] Ben Poole, Ajay Jain, Jonathan T Barron 및 Ben Mildenhall. Dreamfusion: 2D 확산을 사용하여 텍스트를 3D로 변환합니다. arXiv
사전 인쇄 arXiv:2209.14988, 2022. 2, 5
- [27] René Ranftl, Katrin Lasinger, David Hafner, Konrad
신들러, 블라들렌 콜튼. 견고한 단안을 향하여
깊이 추정: 제로 샷 교차 데이터 세트에 대한 데이터 세트 혼합

양도. 패턴 분석 및 MA에 관한 IEEE 거래
차인인텔리전스(TPAMI), 2020. 3, 4

--- 페이지 10 ---

[28] Ren 'e Ranftl, Alexey Bochkovskiy 및 Vladlen Koltun. Vi-
조밀한 예측을 위한 이온 변환기. ArXiv 사전 인쇄, 2021.

3, 4

[29] O. 로드리게스. Lois du mouvement des syst emes de points
재료. Journal de l'Ecole Royale Polytechnique, 19:319-
429, 1840. 12

[30] 로빈 롬바흐, 안드레아스 블라트만, 도미니크 로렌츠,
패트릭 에세르(Patrick Esser), 비온 오머(Bj orn Ommer). 고해상도 이미지 동기화
잠재 확산 모델을 이용한 논문, 2021. 5

[31] 로빈 롬바흐, 안드레아스 블라트만, 도미니크 로렌츠,
Patrick Esser, Bj orn Ommer. 고해상도 이미지

잠재 확산 모델을 사용한 합성. 의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
표창, 페이지 10684-10695, 2022. 5

[32] Johannes Lutz Sch onberger 및 Jan-Michael Frahm.
모션에서 구조를 재검토했습니다. Com 회의에서
퓨터 비전 및 패턴 인식(CVPR), 2016. 3, 7

[33] Johannes Lutz Sch onberger, Enliang Zheng, Marc Pollefeys,
그리고 Jan-Michael Frahm. un-에 대한 픽셀별 보기 선택
구조화된 멀티뷰 스테레오. 유럽회의에서
컴퓨터비전(ECCV), 2016. 7

[34] Pratul P. Srinivasan, Richard Tucker, Jonathan T. Barron,
라비 라마무르티, 렌 응, 노아 스네이블리. 밀고
다중 평면 이미지를 사용한 뷰 추정의 경계.
CVPR, 2019. 2

[35] 가브리엘라 벤 멜렉 스탠, 다이아나 워크, 스코티 폭스, 알렉스
레드든, 윌 색스턴, 진 유, 에스텔 아플라로, 샤오옌
Tseng, Fabio Nonato, Matthias Muller 등. Ldm3d: 잠재
3D 확산 모델. arXiv 사전 인쇄 arXiv:2305.10853 ,
2023. 4

[36] Xingyuan Sun, Jiajun Wu, Xiuming Zhang, Zhoutong
장, Chengkai Zhang, Tianfan Xue, 조슈아 B 테넨바움,
그리고 윌리엄 T 프리먼. Pix3d: 데이터 세트 및 방법
단일 이미지 3D 형상 모델링. IEEE 회의에서
컴퓨터 비전 및 패턴 인식(CVPR), 2018. 5

[37] 매튜 탄식(Matthew Tancik), 프라툴 스리니바산(Pratul Srinivasan), 벤 밀덴홀(Ben Mildenhall), 사라
Fridovich-Keil, Nithin Raghavan, Utkarsh Singhal, 라비 라-
마모르티, 조나단 배런, 렌 응. 푸리에 특징
네트워크가 저차원에서 고주파 기능을 학습하도록 하세요.

특정 도메인. 신경 정보 처리의 발전
시스템, 33:7537-7547, 2020. 7

[38] Jiaxiang Tang, Jiawei Ren, Hang Zhou, Ziwei Liu 및 Gang

- 정. Dreamgaussian: 효율성을 위한 생성 가우스 스피래팅
고대 3D 콘텐츠 제작. arXiv 사전 인쇄 arXiv:2309.16653,
2023. 2, 5
- [39] 리처드 터커와 노아 스네이블리. 싱글 뷰 합성 -
다중 평면 이미지가 있는 sis. IEEE/CVF 절차에서
컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스,
551~560페이지, 2020. 2
- [40] Guangcong Wang, Zhaoxi Chen, Chen Change Loy 및 Zi-
웨이 리우. Sparsenerf: 퓨샷을 위한 증류 깊이 순위
새로운 관점 합성. IEEE/CVF 국제 컨퍼런스
컴퓨터 비전(ICCV), 2023. 2, 3, 4, 14
- [41] Zhou Wang, A.C. Bovik, H.R. Sheikh 및 E.P. 시몬첼리.
이미지 품질 평가: 오류 가시성부터 구조적까지
유사성. 이미지 처리에 관한 IEEE 트랜잭션, 13(4):
600-612, 2004. 7
- [42] 청이 웬(Chung-Yi Weng), 브라이언 컬리스(Brian Curless), 프라툴 P. 스리니바산(Pratul P. Srinivasan),
Jonathan T. Barron, Ira Kemelmacher-Shlizerman. 후-
manNeRF: 움직이는 사람들의 자유 시점 렌더링
단안 비디오. IEEE/CVF 회의 진행 중-
컴퓨터 비전 및 패턴 인식(CVPR)에 대한 연구,
페이지 16210-16220, 2022. 2
- [43] 우 관준(Guanjun Wu), 이타오란(Taoran Yi), 팡 지에민(Jiemmin Fang), 링시 시에(Lingxi Xie), 샤오핑(Xiaopeng)
Zhang, Wei Wei, Wenyu Liu, Qi Tian 및 Xinggang Wang.
실시간 동적 장면 렌더링을 위한 4D 가우스 스피래팅.
arXiv 사전 인쇄 arXiv:2310.08528, 2023. 2
- [44] DeJia Xu, Yifan Jiang, Peihao Wang, Zhiwen Fan, Humphrey
시, 장양 왕. Sinnerf: 신경 방사 훈련
단일 이미지의 복잡한 장면에 대한 필드.arXiv 사전 인쇄
arXiv:2204.00928, 2022. 2, 5
- [45] DeJia Xu, Yifan Jiang, Peihao Wang, Zhiwen Fan, Yi Wang,
그리고 왕장양. Neurallift-360: 야생에서 들어올리기
2D 사진을 360° 보기로 3D 개체로 변환합니다. arXiv 사전 인쇄
arXiv:2211.16431, 2022. 5
- [46] 이타오란, 방지민, 우관준, 시에 링시, 샤오핑
Zhang, Wenyu Liu, Qi Tian 및 Xinggang Wang. 가우스-
dreamer: 텍스트에서 3D 가우스 스피래팅으로의 빠른 생성
포인트 클라우드 사전을 사용합니다. arXiv 사전 인쇄 arXiv:2310.08529 ,
2023. 2
- [47] Xiuming Zhang, Pratul P Srinivasan, Boyang Deng, Paul De-
베벡, 윌리엄 T 프리먼, 조나단 T 배런. 네르-
요인: 모양과 반사율의 신경 인수분해
알 수 없는 조명. 그래픽에 대한 ACM 트랜잭션
(ToG), 40(6):1-18, 2021. 2
- [48] 저우팅후이, 리처드 터커, 존 플린, 그레이엄 파이프,
그리고 노아 스네이블리. 입체 확대: 학습
다중 평면 이미지를 사용하여 합성을 봅니다. arXiv 사전 인쇄
arXiv:1805.09817, 2018. 2

[49] Zehao Zhu, Zhiwen Fan, Yifan Jiang 및 Zhangyang Wang.

Fsgs: 가우스를 이용한 실시간 퓨샷 뷰 합성

스플래팅, 2023. 1, 3, 8, 14

[50] 보이치예흐 지엘론카, 티무르 바가우트디노프, 사이토 슌스케,

Michael Zollhofer, Justus Thies 및 Javier Romero. 드라이브-

3D 가우스 아바타를 사용할 수 있습니다. arXiv 사전 인쇄 arXiv:2311.08581, 2023. 2

--- 페이지 11 ---

SparseGS: 3D 가우스 스플래팅을 사용한 스파스 뷰 합성

보충 자료

보충 내용

이 보충 자료는 다음과 같이 구성됩니다.

- 초. F는 소프트맥스 스케일링 깊이 공식에 대한 그래디언트 유도를 나타냅니다.
- 초. G는 UVR 모듈에서 사용되는 뷰 샘플링 방법을 자세히 설명합니다.
- 초. H는 Advance Floater Pruning 방법에 대한 알고리즘 세부 정보를 제공합니다.

F. 소프트맥스 깊이 기울기 도출

이 섹션에서는 래스터라이저에 구현된 소프트맥스 깊이에 사용되는 그래디언트를 도출합니다. 우리는 렌더링한다고 가정합니다.

단일 픽셀이고 카메라 광선을 따라 Gaussians G_i 가 카메라 평면에 가장 가까운 것부터 가장 먼 것까지 순서가 지정됩니다.

(즉, 1은 카메라에 가장 가까운 가우스에 해당하고, N 은 가장 먼 가우스에 해당합니다)

$w_k = T_k \cdot k$ 및 $T_k = Q_k \cdot 1$ 이라고 하면

$i=1 \dots (1 \dots i)[12]$, 그러면

d_{softmax}

$x, y = \log$

PN

$i=1 \dots w_i e \dots w_i d_i$

PN

$i=1 \dots w_i e \dots w_i$

!

(13)

가우시안의 카메라 깊이 값에 대한 미분은 다음과 같습니다.

$\partial d_{\text{softmax}}$

x, y

∂d_k

$= w_k e \dots w_k$

PN

$i=1 \dots w_i e \dots w_i d_i$

(14)

가우스 알파 값에 대한 미분은 다음과 같습니다.

$\partial d_{\text{softmax}}$

x, y

$\partial \alpha_k$

=

$(1 + w_k) T_k e \dots w_k d_k \cdot 1$

$1 \dots k$

PN

$$j=k+1(1 + w_j)w_{j_e} w_j DJ$$

PN

$$i=1 w_{i_e} w_i d_i$$

(3)

-

$$(1 + w_k)T_{k_e} w_k 1$$

$$1 k$$

PN

$$j=k+1(1 + w_j)w_{j_e} w_j$$

PN

$$i=1 w_{i_e} w_i$$

(4)

분모의 합은 정방향 패스 동안 유지되었다가 이후 역방향 패스로 전송됩니다. 받는 사람 $O(n^2)$ 폭발을 방지하려면 [12]와 같이 누산기 전략이 사용됩니다.

알하자

케이, 아르

k는 다음과 관련된 누산기입니다.

$\partial \text{softmax}$

x, y

∂k

각각 식 (3)과 (4)에 대해.

알

$$0 = A_r$$

$$0 = 0$$

알

$$k = k 1(1 + w_k 1)e w_k 1 d_k 1 + (1 k 1)A_l$$

$$k 1$$

아칸소

$$k = k 1(1 + w_k 1)e w_k 1 + (1 k 1)A_r$$

$$k 1$$

다음과 같이 표시될 수 있습니다.

$\partial \text{softmax}$

x, y

∂k

$$= T_k$$

$$(1 + w_k)e w_k d_k A_l$$

$$kPN$$

$$i=1 w_{i_e} w_i d_i$$

$$(1 + w_k)e w_k A_r$$

$$kPN$$

$$i=1 w_{i_e} w_i$$

!

--- 페이지 12 ---

G. UVR에 대한 샘플링 보기

주요 논문에서 설명한 것처럼 UVR은 전체적으로 샘플링된 뷰에서 3DGS 훈련을 정규화하도록 설계되었지만, 각 구성 요소에는 서로 다른 카메라 샘플링 전략이 있습니다.

타원 원통 샘플링된 뷰. SDS 손실을 계산하기 위해 장면 중앙을 향한 임의의 카메라 뷰를 생성합니다. 훈련 뷰의 위치에 가장 잘 맞는 타원형 실린더를 사용합니다. 이 과정은 카메라를 변형하는 것부터 시작됩니다. PCA를 사용하여 세계 좌표계(양의 Z축이 지면에 수직인 위치)와 정렬되는 위치입니다. 우리 그런 다음 절대 변위의 90번째 백분위수를 취하여 타원형 축에 대한 배율 계수를 결정합니다. 장면 중심에 배치하여 타원이 대부분의 입력 뷰를 포함하도록 합니다. z 좌표의 수직 경계는 입력 뷰 z 좌표의 10번째 및 90번째 백분위수로 설정됩니다. 우리 타원의 x-y 좌표와 타원 내의 z-좌표를 사용하여 카메라 이동 벡터를 균일하게 무작위로 선택합니다. 앞서 언급한 z 경계. 마지막으로, 카메라의 회전 행렬은 카메라의 시선 벡터를 장면 쪽으로 향하게 하여 계산됩니다. 중앙에 놓고 위쪽 벡터를 입력 뷰의 평균 위쪽 벡터와 정렬합니다. 그림 1. 타원 실린더 샘플링의 조감도. 점선은 입력 보기(빨간색)에 가장 잘 맞는 타원입니다. 푸른 전망 z 좌표에 임의의 변화가 있는 타원의 샘플링된 뷰입니다. 뒤틀린 견해. 큰 뷰를 제공하기에는 너무 멀기 때문에 SDS에서와 동일한 샘플링된 뷰포인트를 사용할 수 없습니다. 겹치는. 대신, 각 훈련 카메라에 대해 모든 카메라의 평균 상향 벡터 주위에 미리 정의된 각도 만큼 워프를 적용합니다. 훈련 카메라. 구체적으로 각 카메라의 상향 벡터는 다음과 같이 추출됩니다.

$$Y =$$

R11

R21

R31

(15)

R은 카메라 포즈의 회전 행렬을 나타냅니다. 다음으로, 모든 항목에 걸쳐 정규화된 평균 상향 벡터를 계산합니다. 장면 중심과 방향을 추정하는 역할을 하는 카메라입니다. 그런 다음 훈련을 순환시켜 새로운 관점이 생성됩니다. Rodrigues의 회전 공식[29]을 사용하여 다양한 각도로 이 추정 중심축을 중심으로 카메라를 배치합니다.

$$Y = 1$$

엔

X

나

이(16)

$$Y =$$

Y

|| Y || (17)

$$P' = P \cos + (P \times Y) \sin + Y (Y \cdot P) (1 - \cos) \quad (18)$$

여기서 P는 원래 카메라 포즈를 나타내고 Y는 장면 중심에서 추정된 위쪽 축입니다. 각도 를 선택합니다.

-3°, -1.5°, 1.5° 및 3°로 인해 각 훈련 카메라에 대해 4개의 뒤틀린 시점이 생성됩니다.

--- 페이지 13 ---

Pearson 깊이 손실 SDS 손실 깊이 뒤틀림 손실 플로터 가지치기에 적용

입력 조회수(12/24)

타원 원통 샘플링 뷰

뒤틀린 뷰

표 D. Pearson 깊이 손실 및 플로터 가지치기는 희소 입력 뷰에 적용되는 반면, SDS 및 깊이 워핑 손실은 다르게 샘플링된 뷰에 적용됩니다.

H. 고급 플로터 가지치기 알고리즘

3DGS에서 "플로터"는 카메라 중심에 가깝게 배치된 상대적으로 불투명도가 낮은 가우스를 나타냅니다. 이 플로터는 그렇지 않습니다.

장면의 알파 블렌딩 깊이를 렌더링할 때 "평균화"되기 때문에 눈에 띄게 나타나지만 눈에 띄지 않습니다.
모드 선택 깊이에서, Pearson 깊이 손실은 상대적으로 소프트 제약이므로 모드 간의 정렬이 잘못되었습니다.

알파 깊이는 여전히 발생할 수 있습니다. 이 정렬 불량은 주로 투과율 임계값에 도달하면 3DGS가 래스터화를 중단하기 때문에 발생합니다.

도달했습니다. 카메라 근처의 플로터 가우시안은 이 전송 예산을 조기에 고갈시켜 다른 가우시안이 올바른 깊이로 수렴합니다.

이 문제를 해결하기 위해 우리는 각 입력 희소 뷰에 대해 플로터 마스크를 생성하여 정렬 불량 영역을 임계값으로 지정하여 식별합니다.

카메라에 너무 가깝게 잘못 배치된 가우시안을 삭제합니다. 구체적으로, 먼저 상대적인 차이를 계산합니다.

각 트레이닝 뷰 i 에 대한 모드 선택 깊이와 알파 블렌딩 깊이 사이는 $i = (d_{\text{mode}} - d_{\text{alpha}})$ 입니다.

달파. 논의한대로

본 논문에서 i 의 분포를 시각화할 때 플로터가 많은 이미지는 플로터로서 바이모달 히스토그램을 갖습니다.

실제 깊이에서 크게 벗어나는 경향이 있습니다. 이러한 관찰을 바탕으로 우리는 단봉성의 척도인 딥 테스트[4]를 적용합니다.

배포에. 그런 다음 플로터가 있기 때문에 장면에 대한 모든 훈련 보기에서 단일 양식 점수의 평균을 냅니다.

장면 전체 측정항목이며 평균 점수를 사용하여 상대적 차이에 대한 백분위수 임계값을 선택합니다.

딥 통계에서 임계값으로의 변환은 매개변수 a 와 b 가 있는 지수 곡선을 사용하여 수행됩니다. 우리는 추정한다 다양한 데이터 세트와 실제 캡처의 다양한 장면에 대해 i 및 F_i 를 수동으로 검사하여 이러한 매개변수를 우리의 값은 $a = 0.97$, $b = 7.5$ 입니다. 이 프로세스는 플로터 가지치기 방법이 적응할 수 있도록 신중하게 설계되었습니다.

전체 가지치기 알고리즘은 다음과 같습니다.

플로터를 정리하는 알고리즘 1 알고리즘

1: 입력: 3DGS 표현 G , 훈련 카메라 I , 곡선 매개변수 a, b

2: $D \leftarrow 0.0$

3: 내가 $\in$ 내가 하는 모든 일에 대해서

4: $d_{\text{alpha}} \leftarrow$ 알파 블렌딩 깊이(G, i)

5: $d_{\text{mode}} \leftarrow$ 모드 선택(G, i)

6: $i \leftarrow d_{\text{mode}} - d_{\text{alpha}}$

달파

7: $D \leftarrow D + \text{딥 테스트}(i)$

8: 종료

9: $D \leftarrow D/||I||$

10: 내가 $\in$ 내가 하는 모든 일을 위해

11: $i \leftarrow$ 백분위수(i, a, b, D)

12: $F_i \leftarrow 1[i > i]$

13: $\{g_0, g_1, \dots, g_n\} \leftarrow$ 가우스 마스크(F_i)

14: 가우스 제거($\{g_0, g_1, \dots, g_n\}$)

15: 끝

--- 페이지 14 ---

I. Few-shot 방법을 사용한 보다 질적인 비교 [40, 49]

그림 J. MipNeRF360 데이터 세트에서 FSGS 및 SparseNeRF와의 정성적 비교. 위의 모든 실험은 다음과 같이 학습되었습니다.

12개의 입력 보기. SparseNeRF는 훈련 뷰에서 적용 범위가 부족한 영역을 과도하게 평활화하는 경우가 많습니다.

대조적으로, 우리의 방법은 보존합니다

세부적인 부분을 선명하게 표현하고 누락된 영역을 더 정확하게 채웁니다. FSGS는 전경 구조와 세부 사항을 유지하는 데 탁월하지만 부족할 수 있습니다.

배경 일관성을 유지하고 플로터를 생성합니다.

[논문 13] DropGaussian 본문 전체 번역

--- 페이지 1 ---

DropGaussian: 희소 뷰 가우스 스플래팅을 위한 구조적 정규화

박현우 류건 김원준 *

건국대학교

{pzls, fbrjs15, wonjkim}@konkuk.ac.kr

초록

최근에는 3D GS(3D Gaussian splatting)가 주목을 받고 있습니다.

새로운 관점 종합 분야에서 많은 관심을 받고 있다.

뛰어난 이미지를 생성하는 동시에 빠른 성능을 제공합니다.

품질. 그러나 스파스 뷰 설정의 3DGS(예: 3-view input)은 종종 과적합 문제에 직면합니다.

훈련 뷰는 시각적 품질을 크게 떨어뜨립니다.

참신한 뷰 이미지의 특성. 기존의 많은 접근 방식은

2D 생성과 같은 강력한 사전 변수를 사용하여 이 문제를 해결했습니다.

생성적인 상황 정보와 외부 깊이 신호.

대조적으로, 이 논문에서는 사전-무로 방법을 소개합니다.

DropGaussian이라고 하며 3D Gaussian을 간단히 변경합니다.

튀는. 구체적으로, 우리는 도중에 가우시안을 무작위로 제거합니다.

학습 과정을 중퇴와 유사한 방식으로 수행합니다.

제외되지 않은 가우스가 더 큰 그래디언트를 가질 수 있도록 허용합니다.

가시성을 향상시키는 동시에 이렇게 하면 남은

최적화 프로세스에 더 많은 기여를 하는 가우시안

희소 입력 뷰로 렌더링하기 위한 것입니다. 이런 간단한 조작-

ation은 과적합 문제를 효과적으로 완화하고

새로운 뷰 합성의 품질을 향상시킵니다. 간단하게 신청하면-

DropGaussian을 원래의 3DGS 프레임워크에 적용하면 다음과 같은 작업을 수행할 수 있습니다.

기존 선행기술로 경쟁력 있는 성과 달성

벤치마크의 희소 보기 설정에서 3DGS 방법 기반

추가적인 복잡성 없이 데이터 세트를 생성합니다. 코드와

모델은 <https://github.com/DCVL-3D/DropGaussian>에서 공개적으로 제공됩니다.

m/DCVL-3D/DropGaussian 릴리스.

1. 소개

사실적인 렌더링에 대한 요구와 그 적용에 따라

양이온이 급격히 증가함에 따라 NVS(Novel View Synthesis)가

필수적인 기술이 되었습니다. 최근에는 신경방사선

NeRF(ance field)[14]가 문헌에 소개되었습니다.

주어진 3D 장면을 인코딩하는 좋은 능력을 가지고 있습니다.

학습 가능한 매개변수를 통한 암시적 복사장

신경망. NeRF와 그 다양한 변종에도 불구하고

개미는 이전보다 놀라운 성능을 보여주었습니다.

여러 방법을 사용하려면 렌더링에 시간이 많이 걸리는 프로세스가 필요합니다.

훈련도 그렇고. 그러던 중, 새로운 기술이 등장했습니다.

*교신저자

(b)(a) (c)

: 3D 가우시안 : 가우시안이 무작위로 떨어짐

그림 1. (a) 3DGS의 기존 설정. (b) 스파스 뷰 세트
3DGS의 특징. (c) 희소 보기 설정에서 DropGaussian의 효과.
각 시점에서 렌더링된 출력은 (a), (b)에서 시각화됩니다.
및 (c) 각각.

3D GS(3D Gaussian splatting)[8]라는 기술이 등장했습니다.

2023년 NVS 분야의 주류로 자리잡고 있습니다.

3DGS는 명시적 래디언스 필드를 생성하는 방식으로,

3D 공간에 위치한 3D 가우시안 세트로 구성됩니다.

점 기반 명시적 표현의 속성을 기반으로

3DGS는 렌더링을 위한 실시간 작업을 보여줍니다.

새로운 시각을 위한 렌더링 품질을 유지하면서

입력. 그러나 입력 뷰가 희박한 경우 3DGS는 여전히

시각적인 적응을 위한 단서가 부족하여 과적합되기 쉽습니다.

주어진 3D를 이해하는데 있어서의 형상과 기하학적 레이아웃
장면.

3DGS 분야의 상당한 노력에도 불구하고,

여전히 희박한 입력 뷰를 사용하여 3D 가우스를 축소합니다.

여전히 도전적입니다. 이 문제를 해결하기 위해 몇 가지 응용 프로그램이 있습니다.

제안은 사전 정보를 활용하기 시작했습니다.

주어진 장면. 예를 들어, 다음과 같은 의미 있는 행사가 있었습니다.

단안 깊이 추정 결과를 다음과 같이 채택하려고 합니다.

가우시안을 부과하기 위한 외부 감시 신호

적절한 위치 [5, 11, 36]. 그러나, 아무런 조건 없이

세계 좌표를 고려하면 추정 깊이 스케일이 다양합니다.

다양한 관점에 걸쳐 일관된 정규화가 가능합니다.

어렵다. 2D 생성 상황별 정보가

1

arXiv:2504.00773v1 [cs.CV] 2025년 4월 1일

--- 페이지 2 ---

형성은 또한 다음을 안내하는 데 성공적으로 사용되었습니다.

보다 현실적인 결과를 얻기 위한 렌더링 프로세스[30],

높은 계산 비용이 필요하며 종종 불안정한 결과를 초래합니다.

확률론적 샘플링 프로세스로 인한 최적화. 예

반면에 광학 흐름은 정규화에 활용되었습니다.

3D 간 3D 가우시안의 픽셀별 대응

희소 보기 조건의 가우스 [18]. 비록 그런

완화하기 위해 사전 기반 접근 방식이 적극적으로 탐색되었습니다.

희박한 입력 뷰로 인한 과적합 문제를 해결하고,
대부분은 오류 프로퍼티와 같은 각각의 제한 사항을 가지고 있습니다.
agation과 높은 계산 부담.
본 논문에서는 이전의 방법과 달리 강한 힘에 의존했다.
사전에, 우리는 단지
추가 계산 없이 3DGS를 간단하게 수정
비용. 3DGS의 기존 설정에서는 Gaussians,
카메라에서 멀리 떨어져 있고 아마도 가려졌을 것입니다.
특정 시점은 다른 시점에서 볼 수 있습니다.
그림 1 (a)에 나와 있습니다. 대조적으로, 그러한 가우스는 종종
스파스 뷰 설정의 시야에서 제외되었습니다.
결과적으로 낮은 기울기 피드백을 덜 받게 됩니다.
다른 가우시안 간의 폐색으로 인한 가시성(참조
그림 1(b)). 이는 궁극적으로 작은 크기의 과적합으로 이어집니다.
훈련 조희수. 제안된 핵심 아이디어
방법은 소위 드롭(Drop)이라 불리는 가우시안(Gaussian)을 무작위로 제거하는 것입니다.
Gaussian, training시 이전 in을 채택하는 대신
희박한 입력 뷰를 위한 형성. DropGaus를 기반으로-
sian 방식, 나머지 Gaussian은 다음과 같이 제공됩니다.
그림 1과 같이 더 눈에 띄는 기회
(다). 이러한 간단한 조작으로 최적화 프로세스가 이루어집니다.
희박한 입력 뷰를 사용하면 다음과 같은 의미에서 더 균형을 이룰 수 있습니다.
눈에 잘 띄지 않는 가우시안은 동안 적절한 주의를 받습니다.
훈련 중입니다(그림 1(c) 참조). 결과적으로 모델은 다음과 같은 기능을 수행할 수 있습니다.
특정 3D 장면의 전체 레이아웃을 파악하기 위해
포괄적인 방식. 이는 렌더링을 효과적으로 일반화합니다.
성능을 새로운 관점으로 끌어올리고 위험을 완화합니다.
제한된 수의 훈련 보기에 과적합됩니다. 추가적으로
우리는 과적합이 주로 다음과 같은 현상을 나타내는 것을 관찰했습니다.
초기 단계가 아닌 훈련의 후반 단계에서
보기가 드문 조건에서. 이 관찰을 바탕으로,
우리는 DropGaus를 점진적으로 적용할 것을 제안했습니다.
3DGS의 훈련 과정에 대한 시안 계획. 주요 내용은
제안된 방법의 분포는 다음과 같이 요약될 수 있다.
최저:

- 우리는 간단하면서도 강력한 정규화 기술을 제안합니다.

 희소 렌더링을 위한 고유한 DropGaussian
입력 조희수. 가우스를 무작위로 제거함으로써
훈련 과정에서 DropGaussian은 다음과 같은 기회를 제공합니다.
나머지 가우시안이 더 잘 보이도록
더 큰 기울기를 통해 의미 있게 일치하게 됩니다.
3DGS의 최적화 과정에 대한 찬사입니다. 이는 상당히
과적합 문제를 완화하는 것이 바람직합니다.
희소 보기 조건.

- 벤치마크 데이터 세트에 대한 다양한 실험을 통해

 과적합이 주로 발생하는 것으로 확인되었습니다.
초기 단계가 아닌 훈련의 후반 단계

입력 뷰가 희박합니다. 이 관찰을 바탕으로, 드랍률을 점진적으로 높일 것을 제안합니다. 훈련 과정에서 가우시안을 핏합니다. 이 적응-
tive 전략은 과적합 문제를 효과적으로 완화합니다. 렌더링 성능에 예상치 못한 영향을 주지 않고 초기 단계에서.

2. 관련 저작물

이 섹션에서는 최근의 방법에 대해 간략하게 검토합니다. 새로운 관점 합성의 ods를 연구하고 다양한 접근법을 탐구합니다. 희소성과 관련된 문제를 해결하기 위해 특별히 설계되었습니다. 입력 조회수.

2.1. 소설관 종합

최근 NeRF(Neural Radiance Field)[14]가 특정 3D 인코딩에 있어 상당한 진전을 이루었습니다. 3D 좌표를 매핑하여 장면을 암시적 복사 필드로 변환 색상 및 밀도 값에 대한 보기 방향을 지정합니다. 간단한 신경망을 통해 전송됩니다. 다양한 변형 특히 개선에 중점을 두고 도입되었습니다. 렌더링 품질 [1, 2, 25], 훈련 가속화 속도 [6, 15], 그리고 더 많은 것을 처리하기 위해 모델 확장 동적 장면과 같은 복잡한 시나리오[19] 또는

긴장된 장면 [12] 환경을 위한 이러한 광범위한 노력에도 불구하고 NeRF의 기능을 향상시키면서 대부분의 이전 방법은 교육과 임대 모두에 시간이 많이 소요되는 프로세스가 필요합니다. 이는 실제 적용 가능성을 제한합니다. 광고에- 이러한 한계를 해결하기 위해 3D라고 알려진 새로운 접근 방식이 사용되었습니다. Gaussian splatting(3DGS)[8]이 등장했습니다. 3DGS 3D Gauss 세트를 활용하여 주어진 장면을 나타냅니다. sians 및 미분 래스터화를 통해 이미지를 렌더링합니다. 계획. 신경망을 포인트 기반으로 대체하여 3D Gaussians, 3DGS는 효율성을 획기적으로 향상시킵니다. 교육 및 렌더링을 통해 실시간 애플리케이션 구현 가능 3DGS의. 3DGS의 풍부한 가능성에서 영감을 받아 다양한 최근에 후속 연구가 소개되었습니다. 예를 들어 렌더링 품질 개선 [33], 주소- 메모리 비효율성[10, 16]을 고려하고 역동적인 장면에 대한 시간적 관계 [29].

2.2. 희소 뷰를 사용한 새로운 뷰 합성

NeRF와 3DGS가 놀라운 결과를 보여줬음에도 불구하고 렌더링 성능 때문에 많은 수의 입력 이미지가 고품질 결과를 보장하는 데 필요합니다. 그러나 실제 시나리오에서는 소수의 이미지만 사용할 수 있습니다(즉, 희박한 입력 보기). 과적합 문제로 인한 성능 저하. 이전 3DGS의 출현으로 NeRF 기반 방법은 다음과 같습니다. 다양한 방법으로 이 문제를 해결하려고 합니다. 에서

초기 단계, Yuet al. [32]는 사전 훈련된 CNN 엔진을 사용했습니다.

상황에 맞는 정보를 NeRF에 통합하는 코더

2

--- 페이지 3 ---

평가과정

3D 가우스 출력

래스터라이저

프로그레시브 드롭가우스

렌더링된 RGBTraining 보기

훈련 과정

래스터라이저

초기 단계

반복

이후 단계

: 3D 가우스

: 3D 가우스가 무작위로 떨어짐 L1 + SSIM 손실

초기 가우스

희박한 조회수

전처리

드롭

가우스 필드 가우스 필드

드롭

가우스 필드 가우스 필드

그림 2. 희소 보기 설정에서 3DGS에 대해 제안된 방법의 전체 프레임워크. 우리의 DropGaussian 체계는

훈련 과정에서 무작위로 가우스를 삭제하여 카메라에서 멀리 떨어진 곳에서도 가우스의 가시성을 확보함으로써 과적합을 완화합니다.

제한된 수의 훈련 보기로 제한됩니다. 대조적으로, 테스트 단계에서는 모든 가우스가 렌더링되어 고품질 RGB를 생성합니다.

이미지를 통해 완전한 장면 표현이 새로운 뷰 합성에 활용되도록 보장합니다.

전이학습을 통해 Jainet al. [7] 의미를 디자인했습니다.

CLIP 임베딩[22]을 활용하여 일관성 손실을 방지합니다.

보이지 않는 뷰를 효과적으로 처리합니다. 게다가 니에마이어는

외. [17]은 패치 기반 색상 및 깊이 규정을 도입했습니다.

larization 방법, 기하학과 외관을 가로질러 만들기

인접 지역은 일관성을 유지해야 합니다. 최근에는 Yang 등

알. [31]은 간단하면서도 강력한 계획을 제안했습니다.

일반화를 향상시키는 Quency 정규화

NeRF의 입력 주파수 범위를 조정하여 능력을 향상시킵니다.

왕 외. [26] 로컬 깊이 순위 제한을 도입했습니다.

희박한 입력 뷰의 경우 추정 깊이를 보장합니다.

지역 내 질서는 거칠고 일관되게 유지됩니다.

관찰을 통해 희박한 부분의 부정확성을 완화합니다.

나리오스.

한편, 3DGS에서는 여러 가지 방법이 시작되었습니다.
 희박한 입력 뷰에 대해 적극적으로 연구합니다. 구체적으로,
 정 외. [5]는 깊이 모호성을 명확히 하려고 시도했습니다.
 훈련 중에 학습 가능한 매개변수를 주입하는 것은 다음과 같습니다.
 10은 서로 다른 관점 사이에서 발생합니다. 비슷한 방식으로 Li et al.
 알. [11]은 전역-지역 깊이 정규화 기술을 제안했습니다.
 패치 기반 로컬에서 깊이 값을 정규화하는 nique
 이를 통해 작은 변화에도 정확하게 다시 초점을 맞춥니다.
 지역적 깊이. 깊이 기반 규제를 수행하는 대신
 설명, Zhu et al. [36] 가우스 풀링을 도입했습니다.
 새로운 가우시안을 생성하도록 설계된 방식입니다.
 가장 가까운 곳의 그래프 기반 근접성 점수를 활용합니다.
 K 이웃. Xionget al. [30] 점수 적용 제안
 증류 샘플링 손실 [21]을 훈련 과정에 적용

적용 범위가 제한된 지역에서 그럴듯한 세부 정보를 다듬습니다.
 훈련 보기(즉, 희소 입력 보기) 및 생성
 더욱 완벽한 3D 표현. 특히 팔리왈은
 외. [18] 사전 훈련된 광학 흐름 모델 [23]을 활용하여
 3D Gaus- 사이의 픽셀 단위 대응을 정규화합니다.
 sians는 다음과 같이 과적합 문제를 효율적으로 완화합니다.
 입력 뷰가 적습니다.

3. 제안 방법

제안하는 방법은 업데이트 성능을 향상시키는 것을 목표로 한다.
 희소 보기 설정에서 가우스 매개변수를 사용합니다. 이에
 섹션에서는 무작위로 다시 생성되는 DropGaussian을 소개합니다.
 훈련 중에 가우시안을 이동하여 증가시킵니다.
 희박한 나머지 사람들을 위한 데이트 기회-
 상태를 확인하여 재검토에 대한 가시성을 향상시킵니다.
 희박한 보기 조건에서 주요 가우시안. 참고입니다-
 점진적으로 가우시안을 삭제하는 비율이 적당합니다.
 증가하므로 과적합 문제가 더 잘 완화됩니다.

훈련의 후반 단계. 전체적인 틀은
 제안된 방법은 그림 2와 같다.

3.1. 예선

3D 가우스 스플래팅(3DGS)[8]은 명시적으로 나타냅니다.
 포인트 기반 3D 가우시안 세트를 사용하여 주어진 장면.
 각 가우스는 중심 $\mu \in \mathbb{R}^3$, 즉 스케일링으로 정의됩니다.
 인수 $s \in \mathbb{R}^3$ 및 회전 쿼터니언 $q \in \mathbb{R}^4$. 기초
 i 번째 가우스 함수, 즉 G_i 는 다음과 같이 제공됩니다.
 $G_i(x) = \text{특급}$

-1

$2(x - \mu)^T$ 1

나는 $(x - \mu)$

, (1)
3

--- 페이지 4 ---

여기서 공분산 행렬 Σ_i 는 다음과 같이 근사화됩니다.

스케일링 계수 s_i 와 회전 4차의 조합

Gaus-의 크기와 방향을 결정하는 n_i 와 q_i

3D 공간의 시안. 이러한 기하학적인 요소 외에도

공물, 각 가우스도 불투명도 값을 가지고 있습니다.

$o_i \in \mathbb{R}$ 이고 K 차원 색상의 특징은 $f_i \in \mathbb{R}^K$ 입니다. n_i 는

색상 특징은 일반적으로 구형 Harness를 사용하여 표현됩니다.

빛을 효율적으로 인코딩하는 모닉(SH) 계수

다른 방향에 따라 효과를 나타냅니다. 렌더링의 경우,

i 번째 가우스의 색상, 즉 RGB 값이 계산됩니다.

이 SH 계수로부터, 주어진에서의 최종 색상 $C(p)$

픽셀 p 는 가중치가 적용된 색상을 누적하여 계산됩니다.

모든 가우시안의 기여는 다음과 같이 공식화될 수 있습니다.

다음과 같습니다:

$C(p) =$

$N \times$

$n_i = 1$

$C_i = i T_i$, (2)

여기서 c_i 는 색상 특성에서 파생된 RGB 값입니다.

i 번째 가우스의 f_i . i 는 프로의 곱을 나타냅니다.

주입된 2D 가우스와 학습된 불투명도 값 o_i

i 번째 가우스. T_i 는 축적된 투명도를 나타냅니다.

i 번째 가우스의 뷰 방향을 따라. N 은

최종 색상에 기여하는 총 가우시안 수

픽셀 p 의 다음 [8]을 통해 T_i 와 i 를 계산할 수 있습니다.

다음과 같이:

$T_i =$

$i = 1 \dots Y$

$j = 1$

$(1 \dots j)$, $i = o_i \cdot g_{2D}$

나, (3)

여기서 g_{2D}

i 는 프로에서 얻은 2D 가우스입니다.

i 번째 3D 가우스를 이미지 평면에 주입합니다.

3.2. 드롭가우스

회박한 시야 조건에서 3D의 투과율 T_i

카메라에서 멀리 떨어져 있는 가우시안

다른 가우시안에 의해 가려질 확률이 높으며,

그림 1(b)에 도시된 바와 같이 상대적으로 낮아진다. 이후

그러한 가우시안의 가시 범위는 엄격하게 제한되어 있습니다.

소수의 입력 뷰, 가우스 속성, 예:

규모, 색상, 불투명도 등을 적극적으로 업데이트할 수 없습니다.

전체 수익에 대한 기여도가 감소합니다.

데리링 과정. 결과적으로, 기울기 피드백은
 3DGS의 최적화 프로세스가 충분히 제공되지 않음
 해당 가우시안으로 변환하고 결국 결과는 다음과 같습니다.
 소수의 훈련 뷰에 과적합(예: 회소
 입력 보기).
 이 문제를 해결하기 위해 DropGaussian을 제안합니다.
 무작위로 재조정하는 구조적 정규화 기술
 훈련 과정에서 가우시안 세트를 이동합니다.
 구체적으로, 낙하율 r 은 먼저 다음과 같이 정의됩니다.
 충분하면 전체 가우스를 10% 제거하기 위해 r 을 0.1로 설정합니다.
 색상 값에 기여하는 누적 불투명도
 아마도 이러한 감소로 인해 각 픽셀이 감소할 것입니다.
 ccess에 보상 계수를 적용할 것을 제안합니다.
 SSIM: 0.941
 PSNR: 31.83

SSIM: 0.897
 PSNR: 28.67
 SSIM: 0.610
 PSNR: 16.56
 SSIM: 0.657
 PSNR: 19.12

(비) (다)
 (디) (마)
 (아)

그림 3. (a) 더 큰 기울기를 갖는 가우스 분포
 카메라와의 거리를 줄로 묶습니다. y 축은 다음을 나타냅니다.
 그라디언트 값이 더 큰 가우스의 수
 3DGS의 치밀화 임계값보다 높습니다. (b) 렌더링
 3DGS의 훈련 보기 결과입니다. (c) 렌더링 결과
 DropGaussian 체계를 사용한 3DGS의 훈련 보기. (디)
 3DGS에 의한 새로운 뷰의 렌더링 결과입니다. (e) 렌더링 결과
 DropGaussian 체계를 사용하여 3DGS의 새로운 관점을 구현합니다.
 나머지 가우스의 불투명도 값은 다음과 같습니다.

$$\sim o_i = M(i) \cdot o_i, (4)$$

여기서 $M(i)$ 는 i 번째에 대한 보상 계수를 나타냅니다.

1을 할당하는 가우스

(1 r) 나머지 가우스

그렇지 않으면 0입니다. 총 기여액이 눈에 됩니다.
 각 픽셀의 색상 값에 가우시안을 성공적으로 적용했습니다.
 보상 계수의 스케일링 효과에 의해 유지됨
 떨어지는 과정에도 불구하고. 게다가 가우스는
 카메라에서 멀리 떨어져 있으면 Drop으로 인해 큰 그라데이션이 생길 수 있습니다.
 가시성이 효율적으로 향상되므로 가우시안
 그림 1 (c)에 나와 있습니다.

DropGaussian 체계의 효과를 보여주기 위해 다음과 같은 내용을 추가했습니다.
 그런 다음 그라데이션을 사용하여 가우스 분포를 분석합니다.

카메라로부터의 거리에 따른 값. 다음과 같이
그림 3(a)에 표시된 것처럼 가우시안은 다음과 같이 더 큰 기울기를 가질 수 있습니다.
DropGaussian은 다소 거리가 있지만
카메라. 그라디언트가 있는 가우스만 계산합니다.
4

--- 페이지 5 ---

그림 4. 학습 과정 중 PSNR 값의 변화
DropGaussian을 사용한 3DGS 및 3DGS용 LLFF 데이터세트. 참고
1,000회 및 10,000회 반복에서 새로운 관점에 대한 결과를 렌더링하는 것은
과적합의 강화를 강조하는 옵션도 제공됩니다.
이후 훈련 단계에서 DropGaussian의 효율성
이 문제를 완화합니다. 빨간색 상자는 초과된 지역을 나타냅니다.
피팅이 발생합니다.
그 값은 밀도화에 대한 임계값보다 큼니다.
3DGS의 양이온(예: 이 예에서는 0.0005)입니다. 이것은
3DGS는 렌더링 시 과적합 문제에 강력합니다.
희소 보기 조건에서 새로운 보기 이미지 생성(참조
그림 3(e)).
또한, 우리는 다음과 같은 경향이 있음을 관찰했습니다.
희소 뷰 조건에서는 과적합이 더 강해집니다.
그림 4와 같이 훈련 과정이 진행됨에 따라
이 문제를 해결하기 위해 드롭율을 조정할 것을 제안합니다.
현재 반복 인덱스 t 에 따르면 다음과 같습니다.

$rt = \cdot t$

총

, (5)

여기서 $\in \{0, 1\}$ 은 드롭에 대한 배율 인수를 나타냅니다.
핑 속도. t_{total} 은 학습 프로세스의 총 반복 횟수입니다.
이러한 점진적인 조정 전략은 규제를 강화합니다.
학습 과정이 진행됨에 따라 명확화 효과가 나타납니다.

3.3. 손실 함수

제안된 방법은 전통적인 학습 방식을 기반으로 훈련된다.
색상 재구성 손실. 3D 가우시안 스피래딩에 이어,
색상 재구성 손실은 L1 손실과
구조적 유사성을 측정하는 D-SSIM 손실은 다음과 같습니다.
렌더링된 이미지 I_r 와 실제 이미지 I 를 트위닝하고,
[8]로 주어진다:

$$L_{color} = L1(I_r, I) + LD-SSIM(I_r, I), \quad (6)$$

여기서 λ 는 균형을 이루는 가중치를 나타냅니다.
L1과 LD-SSIM의 기여도 사이에서 다음과 같이 설정됩니다.
0.2.

4. 실험 결과

4.1. 훈련

모든 실험은 PyTorch를 사용하여 진행되었습니다.
Intel E5-1650 v4@3.60GHz에서 실행되는 프레임워크 [20]
CPU 및 NVIDIA RTX 3090Ti GPU. 우리는

Adam 옵티마이저[9]는 모든 모델 매개변수를 학습합니다.
 멘텀 인자는 각각 0.9와 0.999로 설정되었습니다. 프로-
 제기된 방법은 밀도가 높은 10,000번의 반복을 위해 학습되었습니다.
 100번 반복마다 수행됩니다. 경사 임계값
 치밀화는 [36]에서 사용된 것처럼 5×10^{-4} 로 설정됩니다.

4.2. 데이터 세트 및 평가 지표

데이터세트. 제안된 성능 평가를 위해
 방법, 세 가지 대표적인 벤치마크, 즉 LLFF[13],
 Mip-NeRF360 [2] 및 Blender [14]가 사용되었습니다. 우리
 이전 작업에서 사용된 설정을 동일하게 따릅니다.

LLFF, Mip-NeRF360 및 블렌더 데이터 세트의 분할
 각각 3개, 12개, 8개의 훈련 뷰로 구성됩니다. 는
 다운샘플링 속도는 LLFF와 Mip 모두에 대해 8로 설정됩니다.
 NeRF360은 2가 블렌더에 사용됩니다.
 평가 지표. 정량적인 평가를 위해 우리는
 세 가지 측정항목, 즉 최대 신호 대 잡음비(PSNR)를 사용합니다.
 구조적 유사성 지수(SSIM) [28] 및 학습된 인식
 LPIPS(Tual Image Patch 유사성)[35]
 일반적으로 이 분야에서 채택됩니다. 구체적으로 PSNR 측정은
 렌더링된 이미지 사이의 평균 피크 오류를 확인합니다.
 그리고 사실. SSIM은 구조적 유사성을 계산합니다.
 휘도, 대비, 질감 정보를 기반으로 합니다.
 반면에 LPIPS는 지각 거리를 계산합니다.
 알아내는 데 유용한 학습된 특징을 활용하여
 전통적인 방식으로는 반영되지 않는 근본적인 차이점
 측정항목.

4.3. 성과평가

정량적 평가. 효과적인 방법을 보여주기 위해-
 과적합을 해결하기 위해 제안된 방법의 본질은 다음과 같습니다.
 Sparse로 렌더링하는 이전 방법과 비교
 입력 뷰, 즉 MipNeRF [1], DietNeRF [7], RegN-
 eRF [17], FreeNeRF [31], SparseNeRF [26], DNGaus-
 5

--- 페이지 6 ---

(a) (b) (c) (d) (e)

그림 5. LLFF [2] 데이터세트에 대한 새로운 뷰 렌더링 결과. (a) 3DGS에 의한 결과[8]. (b) FSGS의 결과[36]. (c) 결과
 CoR-GS [34]. (d) 제안된 방법에 따른 결과. (e) GT 이미지.

방법 3-뷰 6-뷰 9-뷰

PSNR(↑) SSIM(↑) LPIPS(↓) PSNR(↑) SSIM(↑) LPIPS(↓) PSNR(↑) SSIM(↑) LPIPS(↓)
 NeRF 기반

Mip-NeRF [1] 16.11 0.401 0.460 22.91 0.756 0.213 24.88 0.826 0.170

다이어트NeRF [7] 14.94 0.370 0.496 21.75 0.717 0.248 24.28 0.801 0.183

RegNeRF [17] 19.08 0.587 0.336 23.10 0.760 0.206 24.86 0.820 0.161

FreeNeRF [31] 19.63 0.612 0.308 23.73 0.779 0.195 25.13 0.827 0.160

SparseNeRF [26] 19.86 0.624 0.328 - - - - -

3DGS 기반

3DGS [8] 19.22 0.649 0.229 23.80 0.814 0.125 25.44 0.860 0.096
 DN가우시안 [11] 19.12 0.591 0.294 22.18 0.755 0.198 23.17 0.788 0.180
 FSGS [36] 20.43 0.682 0.248 24.09 0.823 0.145 25.31 0.860 0.122
 CoR-GS [34] 20.45 0.712 0.196 24.49 0.837 0.115 26.06 0.874 0.089
 당사 20.76 0.713 0.200 24.74 0.837 0.117 26.21 0.874 0.088

표 1. LLFF 데이터세트의 스파스 뷰 합성 성능 비교 [13] 최고, 2위, 3위 항목이 표시됩니다.
 각각 빨간색, 주황색, 노란색으로 표시됩니다.

sian [11], FSGS [36] 및 CoR-GS [34]. 우선,
 LLFF 데이터 세트의 성능 비교는 다음과 같습니다.

Table 1. 제안하는 방법은 다음과 같다.

렌더링 성능의 의미 있는 개선

아주 간단한 조작으로. 구체적으로 제안된

3-view에서 가장 높은 PSNR 20.76을 달성한 방법

NeRF 기반 및 3DGS 기반을 모두 능가하는 설정

방법. 6개 보기 및 9개 보기 설정 모두에 대해 우리의 접근 방식은
 에 비해 여전히 경쟁력 있는 성과를 달성하고 있습니다.

최첨단 방법(예: CoR-GS [34])

계산 복잡도가 증가합니다.

Mip-NeRF360의 성능 비교

데이터 세트는 표 2에도 나와 있습니다.

접근 방식은 23.92(PSNR), 0.755(SSIM) 및 0.242를 달성합니다.

(LPIPS), 현재 수준의 성능을 크게 능가합니다.

의미있는 차이로 예술 방법. 마지막으로 우리는 또한 평가합니다.

Blender 데이터세트의 렌더링 성능을 평가하고

해당 결과는 표 3에 나와 있습니다. 제안된

방법은 25.42의 가장 높은 PSNR을 달성하는 반면

다른 두 측정항목의 성능은 약간 떨어졌습니다.

최고 점수로 맞췄습니다. 제안된 방법에도 불구하고

항상 모든 지표에 대해 최고의 성능을 보여줍니다.

Sparse를 사용한 렌더링에는 여전히 효과적이고 경쟁력이 있습니다.

추가 모듈이나 AL 없이도 입력을 볼 수 있습니다.

고리듬.

게다가, 우리는 제안된 방법을 피드-

pixelSplat [3], MVS-와 같은 3DGS 방법을 전달합니다.

Replica 데이터세트의 plat [4] 및 FreeSplat [27](Ta-

블레 4). 이러한 사전 훈련된 피드포워드 모델은

더 빠른 추론을 제공하지만 우리의 방법은 여전히 높은 결과를 보여줍니다

스파스 뷰 입력의 시각적 품질.

정성적 평가. 게다가, 질적 COM-

제안된 방법과 FSGS [36], CoR-의 패리슨

LLFF 데이터 세트의 GS [34] 및 3DGS는 다음과 같습니다.

그림 5. 결과는 우리의 효율성을 보여줍니다.

특히 목표를 달성할 때 전방을 향한 장면에 접근합니다.

6

--- 페이지 7 ---

(a) (b) (c) (d) (e)

그림 6. Mip-NeRF360 [2] 데이터세트에 대한 새로운 뷰 렌더링 결과. (a) 3DGS에 의한 결과[8]. (b) FSGS의 결과[36]. (다)

CoR-GS의 결과 [34]. (d) 제안된 방법에 따른 결과. (e) GT 이미지.

방법

12뷰 24뷰

PSNR(↑) SSIM(↑) LPIPS(↓) PSNR(↑) SSIM(↑) LPIPS(↓)

3DGS [8] 18.52 0.523 0.415 22.80 0.708 0.276

FSGS [36] 18.80 0.531 0.418 23.70 0.745 0.230

CoR-GS [34] 19.52 0.558 0.418 23.39 0.727 0.271

당사 19.74 0.577 0.364 24.13 0.762 0.225

표 2. Mip-NeRF360 데이터세트의 스파스 뷰 합성 성능 비교 [2] 최고, 2위, 3위 출품작 각각 빨간색, 주황색, 노란색으로 표시되어 있습니다.

높은 정밀도와 아티팩트 없는 렌더링 비교

기본 방법에. 그림 5의 첫 번째 행에서 우리는

방법은 지속적으로 다른 접근 방식보다 성능이 뛰어납니다.

더욱 정밀하게 전방 장면을 촬영합니다. 동안

다른 방법은 미세하게 캡처하는 데 있어 눈에 띄는 부정확성을 나타냅니다.

세부 사항과 구조적 일관성 유지, 우리의 접근 방식

뛰어난 충실도를 달성하고 복잡한 장면 기능을 보존합니다.

좀 더 현실감 있는 결과물을 만들어냅니다. 두 번째에는

행, 완화에 있어서 제안된 방법의 견고성

과적합이 추가로 입증되었습니다. FSGS 및 CoR-GS 전-

품질을 손상시키는 눈에 띄는 유물을 금지하고

렌더링의 현실성. 대조적으로, 우리의 방법 효과는

이러한 인공물을 효과적으로 방지하여 깨끗하고 정확한 상태를 유지합니다.

까다로운 지역에서도 재구성 속도를 높일 수 있습니다. 렌더링-

제안된 방법에 의한 새로운 관점의 결과는 다음과 같다.

그림 7에도 나와 있습니다. 이러한 정성적 결과는

과적합을 해결하는 방법의 효율성과

다양한 데이터 세트에서 강력한 성능을 보장하고

다재다능함과 신뢰성을 보여주는 장면 유형

광범위한 렌더링 작업.

4.4. 한계 및 향후 작업

제안된 방법은 상당한 효과를 보여주지만

과적합 완화 및 렌더링 향상에 대한 입증

그림 7. 블렌더에서 새로운 뷰 렌더링 결과

제안된 방법으로 데이터세트 [14]를 수행한다.

희소 보기 3D 가우스 스피래팅(3DGS)의 품질,

추가 조사가 필요한 특정 제한 사항이 있습니다.

tion. 이러한 제한은 미래의 기회를 강조합니다.

연구 및 실질적인 개선. hy-에 대한 의존도

드롭에 대한 배율 계수 와 같은 매개변수

핑 속도 r은 데이터 세트별 튜닝에 대한 민감도를 도입합니다.

는 점진적으로 조정하는 데 중요한 역할을 하지만

과적합을 완화하기 위해 비율을 낮추면 최적의 값을 얻을 수 있습니다.

데이터세트와 작업에 따라 다릅니다. 미래의 작업은

시간을 동적으로 조정하는 적응 메커니즘을 탐색합니다.
교육을 실시하여 수동으로 미세 조정해야 할 필요성을 줄이고
다양한 데이터 세트에 대한 일반화를 개선합니다.

7

--- 페이지 8 ---

방법 PSNR(↑) SSIM(↑) LPIPS(↓)

NeRF 기반

밈-NeRF [1] 20.89 0.830 0.168

다이어트NeRF [7] 22.50 0.823 0.124

RegNeRF [17] 23.86 0.852 0.105

프리네르프 [31] 24.26 0.883 0.098

SparseNeRF [26] 24.04 0.876 0.113

3DGS 기반

3DGS [8] 21.56 0.847 0.130

DN가우시안 [11] 24.31 0.886 0.088

FSGS [36] 24.64 0.895 0.095

CoR-GS [34] 24.43 0.896 0.084

우리 25.42 0.888 0.089

표 3. 스파스 뷰 합성의 성능 비교

블렌더 데이터 세트 [14]. 최고, 2위, 3위 출품작
각각 빨간색, 주황색, 노란색으로 표시되어 있습니다.

방법 유형 PSNR(↑) SSIM(↑) LPIPS(↓)

pixelSplat [3] 피드포워드 26.24 0.829 0.229

MVSplat [4] 피드포워드 26.16 0.840 0.173

FreeSplat [27] 피드포워드 26.98 0.848 0.171

우리 최적화 27.76 0.866 0.179

표 4. 피드포워드 방법과의 성능 비교

복제본 데이터세트(2뷰)[24]. 최고, 두 번째 최고, 세 번째

최고의 항목은 각각 빨간색, 주황색, 노란색으로 표시됩니다.

4.5. 절제 연구

이 하위 섹션에서는 변경 사항의 효과를 확인합니다.

하락율과 점진적인 조정 전략. 는

이 하위 섹션의 모든 실험에 대한 성능은 다음과 같습니다.

3뷰 세트를 사용하여 LLFF [13] 데이터 세트에서 평가되었습니다.

팅. 낙하율의 스케일 팩터는 다음과 같습니다.

점진적인 조정을 할 때 하락율이 나옵니다.

전략은 사용되지 않습니다. 구체적으로 사용방법에 비해

고정 낙하율, 우리의 점진적인 조정 전략 효과

상관없이 렌더링 성능을 효율적으로 향상시킵니다.

표 5에 나타난 바와 같이 낙하율의 값.

고정 낙하율, 성능 저하가 관찰되었습니다.

가우시안 드롭 비율이 0.1에서 증가했습니다.

0.3으로 이는 과도한 공격의 역효과를 나타냅니다.

정밀한 가우스 제거. 한 가지 흥미로운 점은 이것이 다시

Versal은 점진적으로 증가하는 효과를 강조합니다.

과적합 문제를 완화하기 위해 하락률을 조정하고, 특히 훈련의 후반 단계에서는 더욱 그렇습니다. 최고의 당의 스케일 팩터로 0.2를 사용하면 형식이 달성됩니다. 낙하율이므로 = 0.2가 기본 설정입니다. 이것들 결과는 우리의 점진적인 조정의 유용성을 보여줍니다. 과적합을 줄이기 위한 감소율의 구현 렌더링 품질을 입증합니다. 게다가, 우리는 무작위로 가우스 프리미티브를 떨어뜨리는 것이 더 효과적입니다. 선택적으로 삭제하는 것보다. 선택적으로 접근하기 때문에 경사도 크기 및 거리와 같은 측정항목에 의존합니다. 가우시안을 반복적으로 폐기할 위험이 있습니다. 희소 뷰 환경에서 장면을 재구성하는 데 매우 중요합니다. 에디션. 해당 결과는 표 6에 나와 있습니다. 최적화 영역에서 L1 정규화는 일반적으로 낮은 상관 관계를 나타내는 요소를 잘라내는 데 사용됩니다. 스케일링 팩터() 프로그레시브 PSNR(↑) SSIM(↑) LPIPS(↓)

-- 19.22 0.649 0.229

0.1 20.28 0.701 0.209

0.2 20.16 0.700 0.216

0.3 20.15 0.691 0.223

0.1 20.29 0.702 0.206

0.2 20.56 0.708 0.207

0.3 20.48 0.707 0.212

표 5. LLFF 데이터세트에 대한 절제 연구(3뷰) 최고, 두 번째로 좋은 항목과 세 번째로 좋은 항목은 빨간색, 주황색으로 표시됩니다. 각각 노란색.

방법 지표 PSNR(↑) SSIM(↑) LPIPS(↓)

무작위 - 20.76 0.713 0.200

선택적 구매 19.62 0.682 0.214

선택적 거리 17.49 0.582 0.273

표 6. 낙하 계획에 따른 절제 연구. 최고, 두 번째로 좋은 항목과 세 번째로 좋은 항목은 빨간색, 주황색으로 표시됩니다. 각각 노란색.

방법 지표 PSNR(↑) SSIM(↑) LPIPS(↓)

감소 - 20.76 0.713 0.200

L1 등록. 기울기 19.97 0.690 0.211

L1 등록. 거리 19.73 0.681 0.213

표 7. 정규화 계획에 따른 절제 연구. 는 최고, 2위, 3위 항목은 빨간색, 주황색으로 표시됩니다. 그리고 각각 노란색.

목적 함수. 그러나 이 접근 방식은 영구적일 수 있습니다.

가우스를 완전히 제거하는 반면, 우리의 방법은 단지 임시적입니다.

일시적으로 가우시안을 비활성화합니다. 즉, 강한 상관관계가 있다

가우스는 이후 반복 중에 다시 참여할 수 있습니다. 이 소품은-

L1에 비해 효율적으로 성능을 향상시킵니다.

표 7과 같이 정규화합니다.

5. 결론

이 논문에서는 간단하면서도 강력한 기능을 소개합니다.
 스파스 뷰 3DGS 방법. 프로의 핵심 아이디어는
 DropGaussian이라고 불리는 제기된 방법은
 3D Gaus를 무작위로 제거하여 과적합 문제를 해결합니다.
 훈련 과정 중 시안들. 간단한 드랍으로
 카메라에서 멀리 떨어진 가우시안 연산
 희소 보기 조건은 더 큰 그래데이션을 가질 수 있지만
 가시성을 향상시킵니다. 이는 상당히 바람직하다.
 희소 렌더링 시 과적합 문제 완화
 입력 조희수. 또한, 우리는 점진적으로 제안합니다
 DropGaussian을 교육 과정에 적용해 보세요.
 그런 다음 렌더링 결과의 시각적 품질을 향상시킵니다.
 감사의 말씀. 본 작품은 나눔재단의 지원을 받아 제작되었습니다.
 한국연구재단(NRF) 보조금 지원

한국 정부(MSIT)(RS-2023-NR076462) 및
 정보통신기술연구원 계획-
 한국정부가 자금을 지원하는 IITP(Ning Evaluation) 보조금
 (과기부) (No. 2018-0-00207, RS-2018-II180207, Im-
 머시브미디어연구소).

8

--- 페이지 9 ---

참고자료

- [1] 조나단 T 배런, 벤 밀든홀, 매튜 탄식, 피터 Hedman, Ricardo Martin-Brualla 및 Pratul P Srinivasan. Mip-nerf: 엔티앨리어싱 중립을 위한 다중 스케일 표현 ral 래디언스 필드. Proc에서 IEEE 컨퍼런스. 계산. 비스. 패턴 Recog., 페이지 5855-5864, 2021. 2, 5, 6, 8
- [2] 조나단 T 배런, 벤 밀든홀, 도르 베르빈, 프라툴 P 스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한 엔티앨리어싱된 신경 방사 필드. InProc. IEEE 컨퍼런스. 컴- 넣어. 비스. 패턴 인식, 페이지 5470-5479, 2022. 2, 5, 6, 7
- [3] David Charatan, Sizhe Li, Andrea Tagliasacchi 및 Vincent Sitzman. pixelplat: im의 3d 가우스 스플랫- 확장 가능한 일반화 가능한 3D 재구성을 위한 연령 쌍. 에서 진행 IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 19457페이지 - 19467, 2024. 6, 8
- [4] Yuedong Chen, Haofei Xu, Chuanxia Zheng, Bohan Zhuang, Marc Pollefeys, Andreas Geiger, Tat-Jen Cham 및 Jianfei 카이. Mvsplat: 스파스에서 효율적인 3D 가우스 스플래팅 멀티뷰 이미지. Proc에서 유로. 회의 계산. Vis., 페이지 370-386, 2024. 6, 8
- [5] 정재영, 오정택, 이경무. 3D 가우스 스플래팅을 위한 깊이 정규화된 최적화 몇 장의 이미지. Proc에서 IEEE 컨퍼런스. 계산. 비스. 패턴 Recog., 페이지 811-820, 2024. 1, 3

- [6] Sara Fridovich-Keil, Alex Yu, Matthew Tancik, Qinhong Chen, Ben Mildenhall, Gopala Murthy, Anja Cozzolino, and Johannes Kopf. PlenopticNet: Radiance Fields without Neural Networks. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2022. 2
- [7] Ajay Jain, Matthew Tancik, Pieter Abbeel. Nerf++: Improved Neural Radiance Fields for Free. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2023. 3, 5, 6, 8
- [8] Ben Mildenhall, Pratul P Srinivasan, Rodrigo Ortiz-Cayon, Nima Khademi Kalantari, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. *Proc. of the European Conference on Computer Vision*, 2020. 1, 2, 3, 4, 5, 6, 7, 8
- [9] Diederik P. Kingma and Jimmy Ba. Adam: A Simple Method for Stochastic Optimization. *Proc. of the International Conference on Machine Learning*, 2017. 5
- [10] Jiahao Chen, Yipeng Wang, and Yizhen Wang. Nerf++: Improved Neural Radiance Fields for Free. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2023. 2
- [11] Jiahao Chen, Yipeng Wang, and Yizhen Wang. Nerf++: Improved Neural Radiance Fields for Free. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2023. 1, 3, 6, 8
- [12] Ricardo Martin-Brualla, Noha Radwan, Mehdi SM Sajjadi, Jonathan T Barron, Alexey Dosovitskiy, Daniel Duck, and Andreas Beyer. Neural Radiance Fields without Neural Networks. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2022. 2
- [13] Ben Mildenhall, Pratul P Srinivasan, Rodrigo Ortiz-Cayon, Nima Khademi Kalantari, Ravi Ramamoorthi, and Ren Ng. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis. *Proc. of the European Conference on Computer Vision*, 2020. 1, 2, 3, 4, 5, 6, 7, 8
- [14] Thomas Müller, Alex Evans, Christoph Schied, and Alexander Keller. Instant NGP: Neural Graphics Primitives. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2022. 2
- [15] Simon Niedermayr, Josef Stumpfegger, and Rüdiger Westermann. Instant NGP: Neural Graphics Primitives. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2022. 2
- [16] Simon Niedermayr, Josef Stumpfegger, and Rüdiger Westermann. Instant NGP: Neural Graphics Primitives. *Proc. of the IEEE Conference on Computer Vision and Pattern Recognition*, 2022. 2

tern Recog., 페이지 10349-10358, 2024. 2

- [17] 마이클 니마이어, 조나단 T 배런, 벤 밀든홀, Mehdi SM Sajjadi, Andreas Geiger 및 Noha Radwan. 등록-nerf: 뷰 합성을 위한 신경 복사 필드 정규화 희박한 입력에서. InProc. IEEE 컨퍼런스. 계산. 비스. 패턴 Recog., 페이지 5480-5490, 2022. 3, 5, 6, 8
- [18] Avinash Paliwal, Wei Ye, Jinhui Xiong, Dmytro Kotovenko, Rakesh Ranjan, Vikas Chandra, Nima Khademi Kalantari. Coherentgs: Coherent를 사용한 Sparse Novel 뷰 합성 3d 가우스. Proc에서 유로. 회의 계산. Vis., 페이지 19-37, 2024. 2, 3
- [19] 박근홍, Utkarsh Sinha, Peter Hedman, Jonathan T 배런, 소피엔 부아지즈, 댄 B 골드만, 리카르도 마틴-Brualla, 스티븐 M 세이츠(Steven M Seitz). 하이퍼너프: 더 높은-위상적으로 다양한 신경에 대한 차원 표현 래디언스 필드. ACM 트랜스. Graph., 40(6):1-12, 2021. 2
- [20] 아담 패스케, 샘 그로스, 수미스 친탈라, 그레고리 Chanan, Edward Yang, Zachary DeVito, Zeming Lin, 알-Desmaison, Luca Antiga 및 Adam Lerer를 금지합니다. 자동 pytorch의 차별화. 고급에서. 신경 정보. 프로세스. Syst., 페이지 1-4, 2017. 5
- [21] Ben Poole, Ajay Jain, Jonathan T Barron 및 Ben Mildenhall. Dreamfusion: 2D 확산을 사용하여 텍스트를 3D로 변환합니다. Proc에서 국제 회의 배우다. 대표., 2023. 3
- [22] 알렉 레드포드, 김종욱, 크리스 할러시, 아디트야 라메쉬, 가브리엘 고, 산디니 아가르왈, 기리쉬 사스트리, Amanda Aspell, Pamela Mishkin, Jack Clark 등 배워보세요-자연어 슈퍼에서 전송 가능한 시각적 모델을 비전. 페이지 8748-8763, 2021. 3
- [23] Xiaoyu Shi, Zhaoyang Huang, Dasong Li, Manyuan Zhang, Ka Chun Cheung, Simon See, Hongwei Qin, Jifeng Dai 및 리 홍성. Flowformer++: Masked Cost Volume Autoen-광학 흐름 추정을 사전 훈련하기 위한 코딩. InProc. IEEE 회의 계산. 비스. 패턴 인식, 페이지 1599-1610, 2023. 3
- [24] Julian Straub, Thomas Whelan, Lingni Ma, Yufan Chen, Erik 워즈먼스, 사이먼 그린, 야콥 J 옹겔, 라울 무르-아탈, 칼 Ren, Shobhit Verma 등. 복제 데이터세트: 디지털 실내 공간의 복제품. arXiv 사전 인쇄 arXiv:1906.05797, 2019. 8
- [25] 도르 베르빈, 피터 헤드만, 벤 밀든홀, 토드 지쿨러, 조나단 T 배런(Jonathan T Barron), 프라툴 P 스리니바산(Pratul P Srinivasan). 참조 너프: 구조-신경 방사 필드에 대한 뷰 의존적 모양을 조정했습니다.

--- 페이지 10 ---

Proc에서 IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 페이지 5481-5490, 2022. 2

[26] Guangcong Wang, Zhaoxi Chen, Chen Change Loy 및 Zi-웨이 리우. Sparsenerf: 퓨샷을 위한 증류 깊이 순위 새로운 관점 합성. Proc에서 국제 회의 계산. Vis., 페이지 9065-9076, 2023. 3, 5, 6, 8

[27] 왕윤송, 황천신, 천한린, 김희리. Freesplat: 일반화 가능한 3D 가우스 스플래팅 실내 장면의 무료 뷰 합성. 고급 신경 정보. 프로세스. Syst., 37:107326-107349, 2025. 6, 8

[28] Zhou Wang, Alan C Bovik, Hamid R Sheikh 및 Eero P 시몬첼리. 이미지 품질 평가: 오류 가시성부터 구조적 유사성에 대해 IEEE 트랜스. 이미지 프로세스., 13(4): 600-612, 2004. 5

[29] 우 관준(Guanjun Wu), 이타오란(Taoran Yi), 팡 지에민(Jiemin Fang), 링시 시에(Lingxi Xie), 샤오핑(Xiaopeng) Zhang, Wei Wei, Wenyu Liu, Qi Tian 및 Xinggang Wang. 실시간 동적 장면 렌더링을 위한 4D 가우스 스플래팅. Proc에서 IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 페이지 20310~20320, 2024. 2

[30] Haolin Xiong, Sairisheek Muttukuru, Rishi Upadhyay, Pradyumna Chari와 Achuta Kadambi. Sparsegs: 실제-시간 360 ° 가우스 스플래팅을 사용한 희소 뷰 합성. arXiv 사전 인쇄 arXiv:2312.00206, 2023. 2, 3

[31] Jiawei Yang, Marco Pavone, Yue Wang. Freenerf: 난-자유 주파수 조절을 통한 퓨샷 신경 렌더링 입증 라화. Proc에서 IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 페이지 8254-8263, 2023. 3, 5, 6, 8

[32] Alex Yu, Vickie Ye, Matthew Tancik 및 Angjoo Kanazawa. pixelnerf: 하나 또는 몇 개의 이미지에서 얻은 신경 복사장. 에서 진행 IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 4578페이지 - 4587, 2021. 2

[33] Zehao Yu, Anpei Chen, Binbin Huang, Torsten Sattler 및 안드레아스 가이거. Mip-splatting: Alias-free 3d gaussian splatting. Proc에서 IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 페이지 19447~19456, 2024. 2

[34] Jiawei Zhang, Jiahe Li, Xiaohan Yu, Lei Huang, Lin Gu, 진정, 샤오바이. Cor-gs: 희소 뷰 3D 가우스 공동 정규화를 통한 스플래팅. Proc에서 유로. 회의 계산. Vis., 페이지 335-352, 2024. 6, 7, 8

[35] 리처드 장, 필립 이슬라, 알렉세이 A 에프로스, 엘리 세흐트만, 그리고 올리버 왕. 딥의 불합리한 효율성 지각 지표로 기능합니다. InProc. IEEE 컨퍼런스. 계산. 비스. 패턴 인식, 586~595페이지, 2018. 5

[36] Zehao Zhu, Zhiwen Fan, Yifan Jiang 및 Zhangyang Wang. Fsgs: 가우스를 이용한 실시간 퓨샷 뷰 합성 튜닝. Proc에서 유로. 회의 계산. Vis., 페이지 145-163,

2024. 1, 3, 5, 6, 7, 8
10

[논문 14] CoR-GS 본문 전체 번역

--- 페이지 1 ---

CoR-GS: 희소 뷰 3D 가우스 스플래팅

공동 정규화

Jiawei Zhang¹, Jiahe Li¹, Xiaohan Yu³, Lei Huang², Lin Gu^{4,5}, Jin Zheng¹,
그리고 샤오바이¹

¹ 컴퓨터 과학 및 공학부 주립 핵심 연구소

복잡하고 중요한 소프트웨어 환경, Jiangxi Research Institute,
베이항대학교

² SKLCCSE, 베이항대학교 인공지능연구소

³ 맥쿼리대학교 컴퓨터공학부

⁴ 리켄 AIP

⁵ 도쿄대학교

추상. 3D GS(3D Gaussian Splatter)는 복사장 제어를 생성합니다.

장면을 표현하기 위해 3D Gaussian을 사용합니다. 희박한 훈련 보기를 통해
3DGS는 과적합으로 인해 쉽게 어려움을 겪으며 렌더링에 부정적인 영향을 미칩니다.

이 문서에서는 개선을 위한 새로운 공동 정규화 관점을 소개합니다.

스파스 뷰 3DGS를 사용 중입니다. 두 개의 3D Gaussian Radiance Field를 훈련할 때,
우리는 두 개의 복사 필드가 점 불일치를 나타내는 것을 관찰합니다.

감독 없이 재구성을 예측할 수 있는 불일치 렌더링

품질은 치밀화 구현의 무작위성에서 비롯됩니다.

우리는 두 가지 불일치를 더 정량화하고 부정적인 점을 보여줍니다.

그들 사이의 상관관계와 정확한 재구성을 통해 우리는

실제 정보에 접근하지 않고 부정확한 재구성을 식별하기 위해

형성. 이러한 연구를 바탕으로 우리는 이를 식별하고 분석하는 CoR-GS를 제안합니다.

두 가지 불일치를 기반으로 부정확한 재구성을 억제합니다. (i)

공동 가치치기에서는 높은 불일치를 보이는 가우스를 고려합니다.

부정확한 위치를 제거하고 제거합니다. (ii) 의사 뷰 공동 정규화

렌더링 불일치가 높은 픽셀은 부정확하다고 간주합니다.

의견 차이를 평가하고 억제합니다. LLFF, Mip-NeRF360에 대한 결과,

DTU와 Blender는 CoR-GS가 데이터를 효과적으로 정규화함을 보여줍니다.

장면 기하학, 간결한 표현 재구성 및 달성

희소 훈련 뷰에서 최첨단 신규 뷰 합성 품질을 제공합니다.

프로젝트 페이지: <https://jiaw-z.github.io/CoR-GS>

키워드: 3차원 가우스 스플래팅·스파스뷰 신규 뷰 합성

1 소개

2D 이미지에서 3D 표현을 얻는 것은 오랫동안 관심의 주제였습니다.

3D 가우스 스플래팅(3DGS)[16]은 구조화되지 않은 복사 필드를 생성합니다.

장면을 표현하기 위해 3D 가우시안 세트를 만들어 고품질을 달성했습니다.

교신저자 : Xiao Bai, Jin Zheng

arXiv:2405.12110v2 [cs.CV] 2024년 7월 11일

--- 페이지 2 ---

2 J. Zhang 외.

그림 1: 두 3D 가우스 광도 간의 서로 다른 동작을 보여주는 그림

건설 품질과 관련된 분야. 다양한 행동을 보이는 가우스는 그렇지 않은 경향이 있습니다.

실제 모양에 잘 맞습니다. 따라서 부정확한 재구성을 식별할 수 있습니다.

실측 정보에 접근하지 않고 차이점을 측정함으로써 말이죠.
 실시간으로 새로운 뷰 합성. 그러나 희박한 보기만 사용할 수 있는 경우에는
 훈련 제약이 줄어들면 3DGS가 훈련에 과적합되기 쉽습니다.
 뷰 [40,51]로 인해 비현실적인 새로운 뷰 합성이 발생했습니다.
 3DGS는 희박한 포인트 클라우드를 사용하여 3D 가우스를 초기화합니다. 그런 다음 인터리브된
 3D 가우시안의 최적화/밀도 제어는 정확도를 달성하기 위해 수행됩니다.
 장면의 비율 복사장 표현. 희박한 훈련 뷰에서 우리는
 두 개의 3D 가우스 복사 필드가 훈련되어 있음을 관찰하십시오.
 동일한 장면에서 가우시안 위치와 렌더링된 위치 모두에서 차이가 나타납니다.
 픽셀. 밀도 제어 중에 그 차이가 크게 증가합니다.
 새로운 가우스를 생성하고 샘플링하여 위치를 초기화하는 것입니다.
 정규 분포. 희박한 훈련 보기를 사용하면 최적화에 어려움을 겪을 수 있습니다.
 모호함으로 인해 장면을 정확하게 표현하기 위해 가우시안을 수정합니다.
 3D에서 2D로 투영하면 차이가 누적됩니다.
 이 논문에서는 두 3D의 서로 다른 동작 사이의 연관성을 밝힙니다.
 가우스 복사장 및 재구성 품질. 구체적으로, 우리는
 차이점을 나타내기 위해 의견 불일치를 제기하고 불일치를 렌더링합니다.

그리고 이를 정량적으로 측정합니다. 의견 불일치는 차이점을 나타냅니다.
 가우스 위치의 encs는 사이의 등록에 대해 평가됩니다.
 가우시안의 포인트 클라우드 표현. 렌더링 불일치는 다음을 나타냅니다.
 렌더링된 픽셀의 차이. 렌더링된 이미지를 다음과 비교합니다.
 3D 가우시안의 재구성 품질을 측정하기 위한 지상 진실 테스트 뷰
 래디언스 필드. 우리는 또한 조밀한 뷰로 훈련된 3D 가우스 필드를 다음과 같이 활용합니다.
 가우시안 위치와 렌더링된 깊이 맵을 평가하기 위한 지상 진실
 재건축 품질에 대한 보다 포괄적인 평가를 제공합니다. 자세한 내용
 Sec에서 제공됩니다. 3. 실험 결과는 음의 상관관계를 보여줍니다.
 두 불일치 사이의 관계와 정확한 재구성. 이를 통해
 두 개의 3D를 비교하여 감독 없이 부정확한 재구성을 식별합니다.
 그림 1에 표시된 가우스 복사장.
 우리의 연구를 바탕으로 우리는 두 개의 3D 가우스 복사를 훈련시키는 CoR-GS를 제안합니다.
 같은 견해를 가진 분야끼리 훈련을 진행하며 공동정규화를 진행합니다.
 부정확한 재구성을 식별하고 억제하여 희소 뷰 3DGS를 개선합니다.

--- 페이지 3 ---

CoR-GS 3

요점 불일치와 불일치 렌더링을 기반으로 구성됩니다. CoR-GS
 의견 불일치를 억제하기 위해 공동 가지치기를 의미합니다. 공동 가지치기는 두 개의 3D를 처리합니다.
 포인트별 매칭을 수행하는 두 개의 포인트 클라우드로 된 가우스 래디언스 필드
 그들 사이. 근처에 일치점이 없는 가우시안을 고려합니다.
 반대로 포인트 클라우드에 이상값을 지정하고 잘라냅니다. 렌더링을 억제하려면
 불일치, CoR-GS는 의사 뷰 공동 정규화를 의미합니다. 온라인으로 샘플링
 트레이닝 뷰를 보간하여 의사 뷰를 생성하고 다음을 나타내는 픽셀을 고려합니다.
 높은 렌더링 불일치가 부정확하게 렌더링됩니다. 부정확한 것을 억제하기 위해
 렌더링된 결과의 비율을 지정하고 렌더링된 픽셀의 차이를 규정에 따라 계산합니다.
 트레이닝 뷰 손실과 결합된 설명 용어입니다.
 공동 가지치기 및 의사 뷰 공동 정규화를 통합하여 CoR-GS 재구성

일관되고 컴팩트한 지오메트리를 구성하고 최첨단 희소 뷰를 구현합니다.

LLFF, Mip-NeRF360, DTU 및 Blender 데이터 세트의 렌더링 성능.

실험은 희소성을 정규화하는 방법의 보편성을 보여줍니다.

다양한 장면 상황에서 3DGS를 감상해보세요.

우리의 주요 기여는 다음과 같습니다:

- 우리는 포인트 불일치 및 불일치 렌더링을 제안하여 측정합니다.

동일한 장면에 대한 두 3D 가우스 복사 필드 간의 차이

두 종류의 불일치 사이의 부정적인 상관관계를 보여줍니다.

그리고 정확한 재구성. 두 가지 계약을 사용하여 액세스할 수 있습니다.

실측 정보가 없는 재구성 품질.

- 억제를 위한 공동 가지치기 및 의사 뷰 공동 정규화를 제안합니다.

의견 차이를 지적하고 불일치를 표현하는 것입니다. 우리 악마-

두 가지 불일치를 억제하면 보다 정확한 3D가 생성된다는 전략

장면을 표현하기 위한 가우스 래디언스 필드.

- 공동 가지치기 및 의사 뷰 공동 정규화 기능을 갖춘 CoR-GS re-
일관되고 컴팩트한 형상을 구성하고 경쟁력 있는 품질을 달성합니다.

여러 벤치마크에서 최신 방법과 비교했습니다.

이 논문의 관찰과 토론이 더욱 자극을 받을 수 있기를 바랍니다.

3D 가우스 복사장의 무작위성을 생각합니다.

2 관련 업무

2.1 래디언스 필드

Radiance Fields는 3D 장면을 재구성하고 합성하는 데 사용됩니다.

참신한 견해. NeRF(Neural Radiance Fields)[24]는 상당한 경험을 했습니다.

표현하기 위해 신경 체적 표현을 학습하는 발전

볼륨 렌더링을 통해 3D 장면 및 이미지를 렌더링합니다. 그 이후로 대단한

많은 연구는 렌더링 품질[2,3]과 효율성을 향상시키는 것을 목표로 합니다.

NeRF의 경우 [5,11,13,21,25,32,43]. 비정형 방사선 분야의 최근 발전

[7,16,41]과 같은 연구에서 입증된 것처럼 ance 필드는 다음의 컬렉션을 사용합니다.

3D 장면을 표현하는 가우스. 특히 3D 가우시안 스피래팅(3DGS) [16]

이방성 3D 가우스 세트를 사용하여 장면을 표현하고 이미지를 렌더링합니다.

--- 페이지 4 ---

4 J. 장 외.

미분 가능한 분할을 통해. 3DGS는 재개발 분야에서 놀라운 성공을 거두었습니다.

고품질의 복잡한 장면을 실시간으로 구축합니다. 엄청난데도 불구하고

많은 3D 작업에서 3DGS의 성공[22,33,38], 희박한 3DGS의 동작

견해가 덜 조사되어 현장에서 공개 문제를 제기합니다.

2.2 희소 뷰를 사용한 새로운 뷰 합성

새로운 관점 합성은 사물이나 장면에 대한 보이지 않는 관점을 생성하는 것을 목표로 합니다.

주어진 이미지 세트 [1,49]. 보기가 드물지만 많은 방법이 경향이 있습니다.

저하된 장면을 재구성하고 비현실적인 새로운 시각을 렌더링합니다. 많은 연구

희소 뷰를 사용하여 NeRF를 정규화하는 방법을 탐색했습니다 [10,17,26,42]. 일부 방법

생성모델설계및광범위한데이터세트사전학습에초점[6,

9,18,44,50]. 반대로, 다른 사람들[10,14,27,31,35,39]은 외부 지식을 활용합니다.

사전 훈련된 모델을 사용하여 훈련 프로세스를 정규화합니다.

3DGS의 발전으로 최근 연구[19,40,51]가 관찰되었습니다.

희소 뷰 시나리오에서 비현실적이고 새로운 뷰를 합성하는 3DGS 문제.

이러한 방법은 정규화로서 사전 훈련된 깊이 추정기의 예측에 의존합니다.

재구성된 기하학을 수정하기 위한 것입니다. 그러나 외부 감독은

추가 노이즈가 발생하여 재구성에 부정적인 영향을 미칩니다. 우리의 논문

지원하여 최소 뷰 3DGS에 대한 새로운 공동 정규화 관점을 도입합니다.

두 개의 3D 가우스 복사 필드 사이의 불일치를 압박합니다.

2.3 예측 합의

두 개의 신경망 예측의 일치는 많은 분야에서 탐구되었습니다.

작업[4,12,20,30,37,45,46], 특히 반 지도 학습[30] 및 학습-

시끄러운 라벨을 사용하고 있습니다 [12]. 일반적인 파이프라인에는 동시에 훈련이 포함됩니다.

두 개의 신경망. 그들은 서로 다른 네트워크의 사전 합의를 활용합니다.

레이블이 지정되지 않은 의사 레이블 데이터 [20]에 대한 사전 또는 레이블이 지정된 주석에서 노이즈 제거
tions [12]를 통해 향상된 일반화 기능으로 네트워크를 훈련할 수 있습니다.

이전 연구와의 차이점은 불일치에 대한 조사에 있습니다.

일반화된 신경망 대신 구조화되지 않은 3D 가우스 복사장,

여기서는 가우스 위치와 렌더링된 결과를 고려합니다.

3점 불일치 및 렌더링 불일치

3.1 예비 및 정의

3D Gaussian Splatting. 3D Gaussian splatting [16]은 다음과 같은 장면을 나타냅니다.

3D 가우스 세트. i 번째 가우스 프리미티브는 다음과 같이 설명할 수 있습니다.

$\{ \mathbf{i}, \mathbf{s}_i, \mathbf{q}_i, \mathbf{f}_i \}$, 여기서 $\mathbf{i} \in \mathbb{R}^3$ 은 중심이고 $\mathbf{s}_i \in \mathbb{R}^3$ 은 스케일링 계수입니다.

$\mathbf{q}_i \in \mathbb{R}^4$ 는 회전, $\mathbf{f}_i \in \mathbb{R}$ 은 렌더링의 불투명도, $\mathbf{f}_i \in \mathbb{R}^K$ 는

K차원 색상 특징. 3차원 공간에서는

x 위치의 i 번째 가우스 프리미티브는 다음과 같이 정의됩니다. $G_i(\mathbf{x})$:

$$G_i(\mathbf{x}) = e^{-\frac{1}{2}(\mathbf{x} - \mathbf{i})^T \Sigma^{-1}(\mathbf{x} - \mathbf{i})}$$

$$\Sigma = \mathbf{s}_i \mathbf{s}_i^T + \mathbf{I}$$

$$\mathbf{f}_i = (\mathbf{f}_i, 1)$$

--- 페이지 5 ---

CoR-GS 5

그림 2: 두 3D 가우스 복사장의 기록된 서로 다른 동작

훈련. 훈련 중에 포인트 불일치와 렌더링 불일치가 증가하고,

특히 치밀화 중에.

여기서 공분산 행렬 Σ 는 스케일과 회전 $\mathbf{q}$ 로부터 계산됩니다. $\mathbf{e}$ 에 대한

색상 렌더링, 3D Gaussian Splatting은 기여하는 모든 가우스를 주문합니다.

각 2D 평면 픽셀에 추가하고 알파 블렌딩을 통해 렌더링합니다. 최적화를 위해,

3DGS는 경사하강법을 통해 가우스에 대한 매개변수 θ 를 최적화하고

활성 가우스를 식별하고 복제하기 위해 치밀화를 수행합니다. 3DGS [16]

COLMAP [28,29] 또는 기타 SfM의 포인트 클라우드를 활용할 것을 제안합니다.

초기화. 그러나 Sparse View에서는 초기점 수가 제한되어 있으므로,

따라서 우리는 FSGS [51]에 따라 스테레오 융합 기반 초기화를 수행합니다.

차이점이 있는 점. 가우스의 3축 위치를 고려하면, 가우스-

두 개의 복사장에 있는 시안은 두 개의 점 구름으로 간주될 수 있습니다. 우리는 평가한다

Fitness와 RMSE(Root Mean Square Error)를 사용한 차이점은 다음과 같습니다.

포인트 클라우드 사이의 정합을 평가하는 데 사용됩니다[48]. 피트니스 계산

최대 거리 $d_{\max}$ = 5에 관한 가우스 사이의 중첩 영역

일치. RMSE는 해당 지점의 평균 거리를 계산합니다.
 렌더링 불일치. 우리는 두 가지를 모두 고려하여 차이점을 평가합니다.
 렌더링된 이미지와 깊이 맵. 우리는 PSNR을 사용하여 사이의 차이를 계산합니다.
 두 개의 렌더링된 이미지. 깊이 맵의 경우 상대 절대 오차(absErrorRel)은 깊이 값의 정확도를 평가하는 데 일반적으로 사용됩니다[34].
 재건 품질 평가. 가장 널리 사용되는 평가 방법은
 재구성은 렌더링된 이미지와 실제 이미지를 비교하는 것입니다.
 테스트 보기에서. 우리는 이 평가를 따르고 PSNR 측정항목을 사용합니다. 제공하려면
 보다 포괄적인 평가를 통해 실제 가우스 위치를 얻습니다.
 에 대한 조밀한 뷰를 갖춘 3D 가우스 복사 필드를 훈련하여 깊이 맵을 생성합니다.
 각 장면. 평가에는 Fitness, RMSE 및 absErrorRel을 사용합니다.

3.2 실증적 연구

동일한 희소 뷰로 훈련된 두 개의 3D 가우스 복사 필드
 서로 다른 행동을 보일 수 있습니다. 우리는 두 개의 3D 가우스를 동시에 훈련합니다.
 래디언스 필드를 분석하고 훈련 중 불일치를 기록합니다. 사실 이후부터
 감독은 훈련 뷰에 직접 부과되며, 렌더링 디스플레이를 평가합니다.
 보이지 않는 견해에 동의합니다. 그림 3과 같이 두 개의 3D 가우스안 휘도는

--- 페이지 6 ---

6 J. 장 외.

그림 3: 두 3D 가우스 복사장의 기록된 서로 다른 동작
 훈련. 훈련 중에 포인트 불일치와 렌더링 불일치가 증가하고,
 특히 치밀화 중에.
 그림 4: 두 불일치와 재구성 품질 간의 상관관계. 는
 x축 백분율은 가장 높은 영역의 백분율을 마스킹함을 나타냅니다.
 불일치 점수. 불일치 점수가 높은 지역이 줄어들면서,
 나머지 영역을 평균화하는 재구성 품질은 지속적으로 향상됩니다.
 필드는 서로 다른 동작을 나타냅니다. 특히 두 의견의 불일치는 점점 더 심각해지고 있다.
 새로운 가우스를 생성하지만 위치를 찾는 치밀화 중에 중요하게 발생합니다.
 장면 기하학에 맹목적으로. 따라서 치밀화 중 무작위성은
 희소 뷰 3DGS에서 오류 형상의 원인이 될 수 있습니다.
 포인트 불일치와 렌더링 불일치는 음의 상관관계가 있습니다.
 현장의 정확한 재구성과 관련이 있습니다.관찰을 바탕으로
 두 개의 3D 가우스 복사 필드 사이의 서로 다른 동작에 대해 추가로 조사합니다.
 그들의 불일치가 다음과 관련된 특정 상관관계를 암시하는지 여부를 조사합니다.
 재구성된 기하학 품질. 특정 비율로 영역을 마스킹합니다.
 두 개의 3D 가우스 복사 필드에서 가장 높은 불일치 점수를 가지며
 나머지 지역의 재구성 품질을 계산합니다. 도 4에 도시된 바와 같이,
 불일치 점수가 높은 지역이 줄어들면서 재구성은
 나머지 지역의 품질은 지속적으로 향상됩니다. 이것은 보여줍니다
 불일치와 정확한 재구성 사이에는 음의 상관관계가 있습니다.
 따라서 우리는 불일치에 기초하여 부정확한 재구성을 식별할 수 있습니다.
 사실에 근거한 정보 없이도 의견을 제시합니다. 테스트뷰 비주얼을 제공합니다.
 렌더링된 결과를 그림 5의 해당 오류 맵으로 분류합니다.

--- 페이지 7 ---

CoR-GS 7

Ground Truth 렌더링(필드 1) 렌더링(필드 2) GT 대 필드 1 필드 1 대 필드 2

그림 5: 렌더링된 이미지와 깊이 맵의 테스트 뷰 시각화 및 상관 관계
오류 지도. 두 3D 렌더링 결과 사이의 불일치 영역
가우스 래디언스 필드는 실제값에 비해 부정확한 경향이 있습니다.
두 3D 렌더링 결과 사이에 불일치하는 영역이 있음을 관찰할 수 있습니다.
가우스 래디언스 필드는 실제값에 비해 부정확한 경향이 있습니다.

4 방법

CoR-GS는 두 가지 모두를 기반으로 부정확한 재구성을 식별하고 억제합니다.
불일치를 지적하고 불일치를 렌더링합니다. 우리는 두 개의 3D를 동시에 훈련합니다.
가우스 래디언스 필드 $\mathbf{1} = \{ \mathbf{1}_i | i = 1, 2, \dots, N_1 \}$ 및 $\mathbf{2} = \{ \mathbf{2}_i | i = 1, 2, \dots, N_2 \}$,
나는 $\mathbf{1}$ 은 $\mathbf{1}_i = 1, 2, \dots, N_1$,
여기서 N_1 과 N_2 는 가우스 수입니다. 훈련 후에 우리는 하나를 유지합니다
추론을 위해 제출된 3D 가우스 휘도. 다음 내용에서는

두 번째 필드 $\mathbf{2}$ 에 대한 프로세스는 $\mathbf{1}$ 과 동일한 방식입니다.

4.1 공동 가지치기

치밀화의 샘플링 구현은 새로운 가우시안을 생성합니다.
형상이 희소한 뷰에서는 수정하기 어려울 수 있습니다. 점을 기준으로
불일치, 공동 가지치기는 다음에 위치한 가우시안을 식별하고 가지치기합니다.
부정확한 위치. 먼저 일치하는 대응을 찾습니다. $f: \mathbf{1} \rightarrow \mathbf{2}$
다른 세트에서 가장 가까운 가우스를 기반으로 합니다.

$f(\mathbf{1}_i) = \text{KNN}(\mathbf{1}_i, \mathbf{2})$. (2)
불일치를 계산하기 위해 허용 가능한 최대 거리 $\epsilon = 5$ 를 설정했습니다.

마스크 M :

$M_i =$

$(\mathbf{1}_i - \mathbf{2}_{f(\mathbf{1}_i)})^2 > \epsilon^2$,
 $\mathbf{1}_i = (x_i, y_i, z_i)$,
 $\mathbf{2}_{f(\mathbf{1}_i)} = (x_{f(\mathbf{1}_i)}, y_{f(\mathbf{1}_i)}, z_{f(\mathbf{1}_i)})$,
0, 그렇지 않으면

(3)

여기서 $\mathbf{1}_i$

x_i, y_i, z_i

이, $\mathbf{2}_{f(\mathbf{1}_i)}$

z_i 는 가우시안의 3축 위치를 나타냅니다. 계산이 끝난 후-

두 가우시안 세트 모두에 대해 일치하지 않는 마스크를 사용하면 모든 가우시안을 제거합니다.

--- 페이지 8 ---

8 J. 장 외.

가지치기
 공동가지치기
 의사 뷰 공동 정규화
 훈련 보기
 L1 + SSIM 손실
 의사 뷰 샘플링
 3D 가우스 방사형 필드 1
 3D 가우스 방사형 필드 2
 포인트 매칭
 엠
 엠

그림 6: CoR-GS 개요. 두 개의 3D 가우스 복사장을 동시에 훈련합니다.
 포인트 불일치를 억제하고 불일치를 렌더링하여 이를 정규화합니다.
 일치하지 않는 것으로 표시된 것은 부정확한 위치에 있는 것으로 간주됩니다.
 우리는 최적화된 특정 수(5로 설정)마다 공동 가지치기를 수행합니다.
 우리는 최적화를 위해 Gassuain을 잘라내는 것을 목표로 하고 있기 때문에 밀도 제어 인터리브를 사용합니다.
 처리할 수 없습니다.

4.2 의사 뷰 공동 정규화

의사 뷰 샘플링. 온라인 의사 뷰는 두 가지 뷰에서 샘플링됩니다.

이전 연구 [51]에 이어 유클리드 공간에서 가장 가까운 훈련 뷰.

$$P' = (t + \frac{1}{2}, q). \quad (4)$$

여기서 $t \in P$ 는 훈련 뷰의 카메라 위치를 나타내고, $\frac{1}{2}$ 는 무작위입니다.

정규 분포에서 샘플링된 노이즈, q 는 다음을 나타내는 쿼터니언입니다.

두 훈련 카메라의 회전 평균입니다.

색상 공동 정규화. 샘플링된 의사 뷰에서 두 개의 이미지를 렌더링합니다.

$I'1$ 과 $I'2$ 는 각각 두 개의 가우스 프리미티브 세트 1 및 2를 사용합니다.

색상 재구성 손실은 L1 재구성 손실과

균형 가중치 $\lambda = 0.2$ 인 D-SSIM 항:

$$R_{\text{pcolor}} = (1 - \lambda)L1(I'1, I'2) + \lambda D-SSIM(I'1, I'2). \quad (5)$$

트레이닝 뷰에서는 기본 세트 1에서 image1을 렌더링하고

실제 사실을 바탕으로 감독합니다. I^* :

$$L_{\text{color}} = (1 - \lambda)L1(I^1, I^*) + \lambda D-SSIM(I^1, I^*). \quad (6)$$

최종 훈련 손실은 지상 진실 감독 손실의 조합입니다.

훈련 뷰와 의사 뷰의 색상 공동 정규화 용어:

$$L = L_{\text{color}} + \lambda p R_{\text{pcolor}}, \quad (7)$$

여기서 λ 는 균형추이고 이를 1.0으로 설정합니다.

--- 페이지 9 ---

CoR-GS 9

표 1: 3, 6, 9 훈련 보기를 사용한 LLFF의 정량적 결과. 최고, 두 번째-

최고 및 세 번째 최고 항목은 각각 빨간색, 주황색 및 노란색으로 표시됩니다.

방법 PSNR↑ SSIM↑ LPIPS↓ AVGE↓

3뷰 6뷰 9뷰 3뷰 6뷰 9뷰 3뷰 6뷰 9뷰 3뷰 6뷰 9뷰

Mip-NeRF [2] 16.11 22.91 24.880.401 0.756 0.8260.460 0.213 0.1600.215 0.090 0.066

다이어트NeRF [14]14.94 21.75 24.280.370 0.717 0.8010.496 0.248 0.1830.240 0.105 0.073

RegNeRF [26]19.08 23.10 24.860.587 0.760 0.8200.336 0.206 0.1610.149 0.086 0.067

프리네르프 [42]19.63 23.73 25.130.612 0.779 0.8270.308 0.195 0.1600.134 0.075 0.064

SparseNeRF [35] 19.86 - - 0.624 - - 0.328 - - 0.127 - -
 3DGS [16] 19.22 23.80 25.44 0.649 0.814 0.860 0.229 0.125 0.096 0.120 0.066 0.051
 FSGS [51] 20.43 24.09 25.31 0.682 0.823 0.860 0.248 0.145 0.122 0.104 0.066 0.054
 CoR-GS(당사) 20.45 24.49 26.06 0.712 0.837 0.874 0.196 0.115 0.089 0.101 0.060 0.046

5가지 실험

5.1 설정

데이터 세트. 우리는 4개의 데이터 세트에 대한 실험을 수행했습니다: LLFF[23], Mip-NeRF360 [3], DTU [15] 및 블렌더 [24]. 우리의 실험 설정은 이전과 일치합니다
 연구 [26,35,42,51], 동일한 데이터 분할을 채택하고 다운 샘플링 속도는
 LLFF, Mip-NeRF360, DTU 및 Blender의 경우 각각 8, 4, 4 및 2입니다. 더 많은 de-
 꼬리는 Materia에 있습니다. 대상 물체에 초점을 맞추고 배경을 제거하려면

평가 중 노이즈가 발생하면 이전 작업 [26]과 유사한 객체 마스크를 적용합니다.
 DTU. 카메라 포즈는 보정 또는 기타 정보를 기반으로 알려진 것으로 가정됩니다.
 스파스 뷰 설정 규칙에 따라 확립된 방법입니다.

비교 기준선. 우리는 현재 SOTA 방법 Mip-NeRF [2], Diet-를 사용합니다.
 NeRF [14], RegNeRF [26], FreeNeRF [42], SparseNeRF [35] 및 FSGS [51]
 비교. 대부분의 방법에 대해 우리는 가장 잘 게시된 수량을 직접 보고합니다.

결과. 바닐라 3DGS의 경우 구현 결과를 보고합니다.

평가 지표. 재건축에 대한 정량적 평가를 제시합니다.

PSNR, SSIM [36] 및 LPIPS [47] 점수 보고를 통해 성능을 평가합니다. 추가
 기하학적으로 도출된 평균 오차(AVG E)[26]를 계산합니다.

MSE의 평균 = $10 \cdot \text{PSNR}/10$,

$\sqrt{\quad}$

1 -SSIM 및 LPIPS.

구현. 우리는 LLFF, DTU,

및 Blender 데이터 세트를 사용하고 3DGS[16]를 따라 30,000회 반복에 대한 모델 학습
 MipNeRF 데이터 세트에서. FSGS [51]에 따라 3DGS 및 CoR-GS를 초기화합니다.

희박한 보기에서 융합된 스테레오 포인트 클라우드를 사용합니다.

5.2 비교

LLFF. Tab에서 LLFF 데이터 세트에 대한 정량적 결과를 제공합니다. 1. 우리의
 방법은 PSNR, SSIM, LPIPS 전반에 걸쳐 지속적으로 최고의 성능을 달성합니다.

3, 6, 9개의 훈련 보기가 있는 AVGE 측정항목. 심층 감독되는 FSGS

[51]은 3개 및 6개의 보기가 있는 시나리오에서 3DGS의 성능을 향상시킵니다. 어떻게-
 9개의 트레이닝 뷰를 통해 3DGS는 이미 장면 구조를 재구성할 수 있습니다.

글쎄, 이는 외부 심층 감독의 효율성을 제한합니다. 우리의 방법

--- 페이지 10 ---

10 J. 장 외.

3DGSFSGSCoR-GS

렌더링된 이미지 렌더링된 깊이 지점(정면도) 지점(상면도)

3DGSFSGSCoR-GS

지상 진실

지상 진실

그림 7: LLFF의 정성적 비교. 우리는 Gaussian Primitive의 시각화를 제공합니다.

정면 및 평면도 모두에서 효과적인 위치. 3DGS [16]이 잘못 재구성되었습니다.

렌더링된 깊이 맵과 3D 가우시안 위치에 반영된 형상입니다.

FSGS [51]는 외부 깊이의 소음에 영향을 받고 재구성에도 어려움을 겪습니다. 소형 가우스. 서로 다른 기본 집합 간의 공동 정규화를 수행하면 CoR-GS는 컴팩트한 장면 형상을 재구성합니다. 잘못된 형상을 재구성하는 것을 방지하기 위해 공동 정규화를 수행하여 다양한 훈련 보기를 통해 모든 측정항목이 개선되었습니다. 우리는 수량을 제공합니다 새로운 뷰와 가우시안에서 렌더링된 이미지와 깊이의 직관적인 시각화 렌더링된 깊이 맵에서 우리는 바닐라 3DGS가 특정 장면 구조를 복구할 수 있지만 특히 기하학적 오류가 나타납니다. 렌더링된 이미지의 비현실적인 부분에서 분명하게 나타납니다. 점 표현의 경우, 많은 가우시안은 공간 전체에 분산되어 있으며 재구성된 것에서 멀리 떨어져 있습니다. 장면. 이러한 가우시안은 새로운 관점에서 관찰할 때 비현실적인 결과를 초래할 수 있습니다. istic 렌더링 이미지. 심도 감도를 통해 FSGS는 잘못된 정보를 수정할 수 있습니다. 3DGS의 기하학; 그러나 외부 깊이 맵의 노이즈도 부정적인 영향을 미칩니다. 기하학. 마찬가지로 심층 감도에 의존하는 것도 어려운 일입니다. 가우스를 직접적으로 제한합니다. 가우시안의 분산을 볼 수 있다. FSGS는 아직 컴팩트하지 않습니다. 우리의 방법은 가우스 분석을 효과적으로 지원합니다.

--- 페이지 11 ---

CoR-GS 11

표 2: Mip-NeRF360의 정량적 결과. 최고의 굵은 글씨로 표시되어 있습니다.

방법 12-보기 24-보기

PSNR↑ SSIM↑ LPIPS↓ AVGE↓ PSNR↑ SSIM↑ LPIPS↓ AVGE↓

3DGS [16] 18.52 0.523 0.415 0.167 22.80 0.708 0.276 0.096

FSGS [51] 18.80 0.531 0.418 0.163 23.28 0.715 0.274 0.093

CoR-GS(당사) 19.52 0.558 0.418 0.151 23.39 0.727 0.271 0.091

지상 진실

3DGS

CoR-GS

FSGS

12-보기 24-보기

그림 8: Mip-NeRF360의 정성적 비교. 세 가지 3DGS 기반 방법 모두

중심 개체를 재구성하는 데 잘 형성됩니다. 우리의 방법은 다음과 같은 이점을 보여줍니다.

충분한 공동 관찰이 없는 비중심 지역.

일관되고 컴팩트한 기하학을 구성하여 고품질의 새로운 뷰를 제공합니다.

렌더링.

미프-NeRF360. Mip-NeRF360 데이터 세트의 정량적 결과

희박한 훈련 뷰는 표 2에 보고되어 있습니다. 우리의 방법은 최고의 성능을 달성합니다.

12개 및 24개의 훈련 보기를 통해 PSNR, SSIM 및 AVGE 전반에 걸쳐 성능을 향상시킵니다. 바닐라 3DGS는 12개의 트레이닝 뷰를 통해 최고의 LPIPS 점수를 달성했습니다. 그 이유는 다음과 같습니다.

360도 파노라마 장면, 12개 뷰로 인해 많은 지역에서 공동 가시성이 부족함

제약. 이러한 영역에서 의사 뷰 공동 정규화는 다음을 생성하는 경향이 있습니다.

더 부드러운 효과. 공동 표시 영역이 늘어나는 24개의 트레이닝 뷰를 사용할 때,

우리의 방법은 최고의 LPIPS 점수를 달성했습니다. 우리는 질적 시각화를 제공합니다

그림 8. 렌더링된 이미지에서 우리는 모든 방법이 좋은 결과를 얻을 수 있음을 관찰합니다.

여러 훈련 보기에서 관찰된 중앙 개체에 대한 재구성. 광고-

--- 페이지 12 ---

12 J. 장 외.

표 3: 3, 6, 9 훈련 보기를 사용한 DTU의 정량적 결과. 최고, 두 번째-최고 및 세 번째 최고 항목은 각각 빨간색, 주황색 및 노란색으로 표시됩니다.

방법 PSNR↑ SSIM↑ LPIPS↓ AVGE↓

3뷰 6뷰 9뷰3뷰 6뷰 9뷰3뷰 6뷰 9뷰3뷰 6뷰 9뷰

다이어트NeRF [14]11.85 20.63 23.830.633 0.778 0.8230.314 0.201 0.1730.243 0.101 0.068

RegNeRF [26]18.89 22.20 24.930.745 0.841 0.8840.190 0.117 0.0890.112 0.071 0.047

Mip-NeRF [2] 9.10 16.84 23.560.578 0.754 0.8770.348 0.197 0.1000.311 0.144 0.057

FreeNeRF [42]19.92 23.25 25.38 0.787 0.844 0.888 0.182 0.137 0.096 0.098 0.068 0.046

SparseNeRF [35]19.55 - - 0.769 - - 0.201 - - 0.102 - -

3DGS [16] 17.65 24.00 26.85 0.816 0.907 0.942 0.146 0.076 0.049 0.108 0.050 0.032

CoR-GS(당사)19.21 24.51 27.18 0.853 0.917 0.947 0.119 0.068 0.045 0.087 0.046 0.029

3DGS 코어-GS

지상 진실

3DGS 코어-GS

지상 진실

그림 9: DTU의 정성적 결과. CoR-GS는 보다 완전한 개체를 재구성합니다.

우리 방법의 장점은 더 명확한 구조를 재구성하는 능력에서 분명합니다.

비중심 지역. 가우스 위치에서 우리는 훈련에도 불구하고

360도 뷰를 통해 3DGS 및 FSGS는 여전히 분산된 가우스를 재구성합니다.

거리. 분산된 가우시안은 관측 시 부정적인 영향을 미칩니다.

새로운 견해의 중심이 아닌 영역. 대조적으로, 우리의 방법은 더 많은 구성 요소를 재구성합니다.

협정 표현. 결과는 CoR-GS가 여전히 적합하다는 것을 보여줍니다.

희박한 훈련 보기를 사용하여 경계가 없는 완전한 360° 장면을 재구성합니다.

DTU. DTU 데이터세트의 정량적 결과는 표 3에 보고되어 있습니다.

방법은 3, 6, 9 훈련으로 SSIM, LPIPS 및 AVGE에서 최고를 달성합니다.

조화수. 그러나 단 3개의 뷰만 사용하면 3DGS 기반 방법이 다음을 얻는다는 것을 관찰할 수 있습니다.

NeRF 기반 방법에 비해 PSNR 점수가 낮습니다. 이로 인해 이런 일이 발생합니다.

3DGS는 훈련 이외의 보이지 않는 영역에 검정색 배경을 간단히 렌더링합니다.

보기와 DTU의 3가지 훈련 보기로 인해 보이지 않는 영역이 많이 발생합니다. NeRF

보이지 않는 영역에 대한 보간 특성으로 인해 더 나은 PSNR 점수를 얻을 수 있습니다.

훈련 보기가 증가함에 따라 3DGS 기반 방법이 더 좋아지는 것을 볼 수 있습니다.

NeRF와 비교한 PSNR 점수. 그림의 질적 시각화에서

9, 우리의 방법은 더 완전한 객체를 렌더링하고 더 컴팩트하게 재구성합니다.

3DGS와 가우스 비교.

블렌더. 주변 8개를 사용한 Blender 데이터 세트의 정량적 결과

훈련 보기는 탭에 보고됩니다. 4. 우리의 방법은 SSIM에서 가장 좋은 점수를 얻습니다.

및 LPIPS, PSNR에서 두 번째입니다. 결과는 CoR-GS가 또한

복잡한 객체를 재구성하는 데 적용 가능합니다.

--- 페이지 13 ---

CoR-GS 13

표 4: 8가지 훈련 보기를 사용한 Blender의 정량적 결과. 최고, 차선책,

세 번째로 좋은 항목은 각각 빨간색, 주황색, 노란색으로 표시됩니다.

방법 PSNR↑ SSIM↑ LPIPS↓

RegNeRF [26] 23.86 0.852 0.105

프리네르프 [42] 24.26 0.883 0.098

SparseNeRF [35] 24.04 0.876 0.113

3DGS [16] 23.20 0.870 0.104

FSGS [51] 24.64 0.895 0.095

CoR-GS(당사) 24.43 0.896 0.084

표 5: 효율성 비교. 우리의 방법은 최고의 새로운 관점 합성을 달성합니다
그리고 추론 비용이 가장 적습니다.

방법 추론 훈련

포인트 FPS PSNR ↑ SSIM↑ LPIPS↓ 시간 GPU 메모리

FreeNeRF [42] - 0.09 19.63 0.612 0.308 2.3h 4 ×48GB

SparseNeRF [35] - 0.09 19.86 0.624 0.328 1.5h 32GB

3DGS [16] 1.16×10⁵ 318 19.22 0.649 0.229 2.5분 2GB

CoR-GS(당사) 7.85×10⁴ 349 20.45 0.712 0.196 6분 3GB

효율성. 탭에서. 5. 우리는 훈련과 훈련의 효율성 비교를 실시합니다.

RTX 3090 Ti GPU를 사용한 LLFF 3뷰 설정 추론. 비교됨

NeRF에 따르면 3DGS는 효율성 측면에서 상당한 이점을 가지고 있습니다. 바닐라에 비해
3DGS, 우리의 방법은 훈련으로 인해 약간의 추가 훈련 비용을 발생시킵니다.

두 개의 3D 가우스 래디언스 필드와 의사 뷰 렌더링이 있지만 많이 남아 있습니다.

NeRF보다 효율적입니다. 우리의 방법은 추론 중에 가장 효율적입니다.

보다 컴팩트한 표현을 재구성하기 때문에 우리의 방법은
가우시안 수가 33% 증가하여 추론 속도가 향상됩니다.

5.3 절제 연구

포인트 불일치를 억제하고 렌더링하는 효과를 제거합니다.

불일치. 정량적 결과는 Tab에 보고됩니다. 6. 결과는 다음과 같습니다.

각각의 불일치를 억제하는 것이 희소 보기에 개별적으로 유익하다고 주장합니다.

3DGS와 이 둘의 조합이 최고의 성능을 발휘합니다. 우리는 더 나아가

그 효과를 더 잘 설명하기 위해 그림 10의 정성적 시각화를 제공합니다.

공동 가지치기. 공동 가지치기는 기하학적 구조를 개선하여 더 많은 부분에 반영됩니다.

합리적인 깊이 렌더링 및 보다 컴팩트한 가우시안. 그러나 그 단점은

렌더링된 깊이의 부드러움이 부족하며 특히 바닥 부분에서 두드러집니다.

뿔 장면의. 이는 공동 가지치기가 주로 불일치에 대해 작동하기 때문입니다.

충분한 구성이 부족하면서 재구성된 장면과는 거리가 먼 가우시안

합리적인 위치에 있는 일치하는 가우시안에 대한 제약이 있습니다.

의사 뷰 공동 정규화. 의사 뷰 공동 정규화만 가능합니다.

합리적인 깊이 맵을 얻기 위해 가우시안을 제한하는 데 효과적입니다.

정확하게 위치한 가우스는 불일치 렌더링을 통해 식별할 수 있습니다.

그러나 가우시안에 대한 직접적인 제약이 없기 때문에 표현은

충분히 컴팩트하지 않아 측정할 수 없는 일부 기하학적 오류가 발생합니다.

--- 페이지 14 ---

14 J. 장 외.

표 6: 3가지 훈련 보기를 사용한 CoR-GS의 절제 연구.

CoR-GS LLFF DTU

공동 가지치기 의사 보기 공동 등록.PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

19.22 0.649 0.229 17.65 0.816 0.146

19.62 0.673 0.217 18.59 0.836 0.127

20.26 0.706 0.198 18.56 0.849 0.128

20.45 0.712 0.196 19.21 0.853 0.119

의사부 공동등록

3DGS 공동 가지치기 전체

별

양치류

그림 10: 절제에 대한 시각화 결과. 공동 가지치기는 가우시안을 멀리서 가지치기합니다.

간결한 표현을 위해 장면을 재구성하고 의사 부 공동 정규화

근처의 가우스를 수정하고 우리 방법에서 서로를 보완하는 데 도움이 됩니다.

효과적으로 수정되었으며, 특히 양치류 장면에서 분명하게 드러났습니다. CoR-의 전체 세트

GS는 두 가지 불일치를 압축하여 보다 정확한 장면을 재구성합니다.

기하학과 간결한 표현.

6 결론

이 문서에서는 희소성 향상을 위한 새로운 공동 정규화 관점을 소개합니다.

3DGS를 보세요. 우리는 두 개의 3D 가우스 복사 필드가 서로 다른 것을 관찰합니다.

희박한 훈련 뷰를 사용하여 동일한 장면에 대한 동작을 제안하고 포인트 분배를 제안합니다.

차이점을 정량적으로 표시하기 위해 동의 및 불일치 렌더링.

우리는 두 불일치 사이의 부정적인 상관 관계를 추가로 보여줍니다.

정확한 재구성을 통해 부정확한 재구성을 식별할 수 있습니다.

감독 없이. 이러한 연구를 바탕으로 우리는 개선된 CoR-GS를 제안합니다.

두 종류의 불일치를 억제하여 sparse-view 3DGS를 구현합니다. 우리는

다양한 데이터 세트에 대한 CoR-GS의 효율성으로 최첨단 소설 달성

sparse-view 설정에서 합성을 봅니다.

--- 페이지 15 ---

CoR-GS 보충자료

개요

우리는 다음과 같이 자료를 정리합니다. 먼저 해당 포인트에 대한 추가 결과를 제공합니다.

Sec.의 불일치 및 불일치 렌더링. A. 그러면 하이퍼파라미터는

우리 방법의 설계는 Sec에서 논의됩니다. B. 우리는 더 많은 서비스를 제공합니다.

패리스 결과는 Sec. C. Sec.에서는 더 많은 시각화 결과를 제공합니다. D.

미래 작업에 대한 논의는 Sec. E. 마지막으로, 우리는

Sec의 실험 설정. F.

불일치의 추가적인 결과

A.1 불일치 행위

에 기록된 의견 불일치 및 렌더링 불일치를 제공합니다.

더 많은 장면. 우리는 또한 CoR-GS의 두 가지 불일치를 제공합니다. 결과

그림에 나와 있습니다. 나와 II. 우리는 두 개의 3D 가우스 광도가

분야는 다양한 장면에서 서로 다른 행동을 보이고 불일치가 증가합니다.

치밀화 중에 크게 발생합니다. 공동 가지치기 및 의사 보기 공동 통합

정규화를 통해 CoR-GS는 요점 불일치와

바닐라 3DGS의 불일치 렌더링.

그림 I: 3-채널에서 두 개의 3d 가우스 복사 필드에 대해 기록된 서로 다른 동작

훈련 중에 LLFF 데이터 세트를 봅니다.

--- 페이지 16 ---

16 J. 장 외.

그림 II: 두 개의 3d 가우스 복사장에 대해 기록된 서로 다른 동작

훈련 중 3뷰 LLFF 데이터세트.

--- 페이지 17 ---

CoR-GS 17

그림 III: 불일치와 재구성 품질 사이의 상관관계

3뷰 LLFF 데이터 세트. 불일치 점수가 높은 지역이 줄어들면서,
나머지 영역을 평균화하는 재구성 품질은 지속적으로 향상됩니다.

A.2 불일치와 정확한 재구성

그림 III 및 IV에서 우리는 부정적인 결과를 입증하기 위해 더 많은 장면에 대한 결과를 제공합니다.

불일치와 정확한 재구성 사이의 상관 관계. 억제하여-

두 가지 의견 차이로 인해 CoR-GS는 재구성이 전반적으로 개선되었습니다.

품질은 바닐라 3DGS로, 불일치가 다른 영역에 반영됩니다.

점수. 우리는 재구성된 가우스 포인트의 시각화를 추가로 제공합니다.

그림 V.

--- 페이지 18 ---

18 J. 장 외.

그림 IV: 불일치와 재구성 품질 사이의 상관관계

3뷰 LLFF 데이터 세트. 불일치 점수가 높은 지역이 줄어들면서,
나머지 영역을 평균화하는 재구성 품질은 지속적으로 향상됩니다.

--- 페이지 19 ---

CoR-GS 19

카메라 카메라 카메라

지상 진실 3DGS CoR-GS

카메라

카메라

카메라 카메라

카메라카메라

그림 V: 3D 가우스 복사장의 포인트 클라우드 가시화. 우리는

조밀한 뷰로 래디언스 필드를 훈련하여 지상 진실을 파악합니다. CoR-GS는 더 많은 것을 재구성합니다.

컴팩트한 표현이며 밀집된 뷰 표현과 더 유사합니다.

B 추가 절제 결과

공동 가지치기 시 거리 임계값에 대한 더 많은 절제 결과를 제공합니다.

Tab의 의사 뷰 공동 정규화의 정규화 용어. 나.

B.1 거리 임계값

거리 임계값 컨트롤에서는 공동 가지치기가 가우시안을 일치하지 않는 것으로 간주합니다.

임계값 = 5 및 = 10이 최상의 결과를 얻는 것을 볼 수 있습니다. 임계값 = 3

가우시안을 잘라내는 최종 구현 = 5보다 성능이 떨어집니다.

엄격하게. 임계값 = 30은 가우스에 대해 매우 느슨한 제약을 부과합니다.

의사 뷰 공동 정규화만으로 유사하게 수행됩니다.

B.2 색상 및 깊이 공동 정규화

또한 렌더링된 색상과 깊이를 사용하여 정규화 용어를 제거합니다. 팔로잉

깊이 정규화된 3DGS[40,51], Pearson을 사용하여 깊이 손실을 계산합니다.

상관관계. 우리는 깊이 있는 공동 정규화만으로도 도움이 되지만,

컬러 공동정렬화와 함께 사용하면 팩트가 매우 약해집니다.

이는 색상 공동 정규화가 깊이 정보에도 제약을 가하기 때문입니다.

렌더링에 포함된 정렬 프로세스로 인해 발생합니다. 그러므로 우리는하지 않습니다

이 경우 깊이 맵에서 공동 정규화를 수행합니다.

B.3 복사장 수

두 개의 3D 가우스 복사장 사이의 공동 정규화는 자연스럽게 더 많은 복사장을 활용하도록 확장되었습니다. 이 구현에서는 공동 가지치기 자두 가우시안은 다른 항목에 관해 높은 의견 불일치를 나타냅니다.

--- 페이지 20 ---

20 J. 장 외.

표 I: 3뷰 LLFF 설정에서 CoR-GS의 절제 연구.

거리 임계값 PSNR ↑ SSIM ↑ LPIPS ↓

3 20.36 0.709 0.198

5 20.45 0.712 0.196

10 20.46 0.711 0.196

30 20.30 0.707 0.198

컬러공동등록 데스 공동등록 PSNR ↑ SSIM ↑ LPIPS ↓

20.45 0.712 0.196

20.01 0.685 0.206

20.45 0.711 0.195

방사 필드 수 PSNR ↑ SSIM ↑ LPIPS ↓

2 20.45 0.712 0.196

3 20.58 0.721 0.190

4 20.61 0.723 0.190

3DGS 베이스라인 PSNR ↑ SSIM ↑ LPIPS ↓

FSGS [51] 20.43 0.682 0.248

CoR-GS 20.45 0.712 0.196

CoR-FSGS 20.93 0.730 0.194

래디언스 필드. 의사 뷰 공동 정규화는 렌더링 불일치를 억제합니다.

다른 각 복사장에 관한 내용입니다. 더 많은 방사 필드를 사용하면

불일치는 부정확한 재구성을 더 정확하게 반영하므로

두 개의 필드를 사용하는 것보다 더 많은 개선이 이루어졌습니다.

B.4 깊이 정규화된 3DGS와 통합

3DGS는 Co-Regularization 방식을 적용하여 고품질의 렌더링이 가능합니다.

희박한 훈련 보기가 포함된 새로운 보기. 깊이 정규화를 고려하면

sparse view 설정에서 효과적인 것으로 입증되었으므로 공동 정규화를 적용합니다.

깊이 정규화 방법 FSGS [51] 방법. 절제 결과 악마-

우리의 방법이 깊이 정규화와 잘 작동할 수 있음을 나타냅니다. 특히

이미지 구조적 SSIM 점수에서 이점을 나타냅니다.

C 추가 비교 결과

C.1 LLFF

우리는 우리의 방법을 Tab의 LLFF에 대한 일반화된 방법과 비교합니다. II. 는

일반화된 방법은 DTU 데이터 세트에 대해 학습됩니다. 우리는 또한 그들의 당을 제공합니다

장면을 미세 조정한 결과. 우리의 방법은 또한 일반화된 방법의 장점을 보여줍니다.

방법.

--- 페이지 21 ---

CoR-GS 21

표 II: 3, 6, 9를 사용한 LLFF에 대한 일반화된 방법과의 정량적 비교

훈련 보기. 최고는 빨간색으로 표시됩니다.

방법 PSNR↑ SSIM↑ LPIPS↓ AVGE↓

3뷰 6뷰 9뷰3뷰 6뷰 9뷰3뷰 6뷰 9뷰3뷰 6뷰 9뷰

SRF [8] 12.34 13.10 13.000.250 0.293 0.2970.591 0.594 0.6050.313 0.293 0.296

PixelNeRF [44]7.93 8.74 8.61 0.272 0.280 0.2740.682 0.676 0.6650.461 0.433 0.432

MVSNeRF [6] 17.25 19.79 20.470.557 0.656 0.6890.356 0.269 0.2420.171 0.125 0.111

SRF 피트 [8] 17.07 16.75 17.390.436 0.438 0.4650.529 0.521 0.5030.203 0.207 0.193

PixelNeRF ft [44]16.17 17.03 18.920.438 0.473 0.5350.512 0.477 0.4300.217 0.196 0.163

MVSNeRF 피트 [6]17.88 19.99 20.470.584 0.660 0.6950.327 0.264 0.2440.157 0.122 0.111

CoR-GS(당사)20.45 24.49 26.06 0.712 0.837 0.874 0.196 0.115 0.089 0.101 0.060 0.046

표 III: 3, 6, 9를 사용한 DTU에 대한 일반화된 방법과의 정량적 비교

훈련 보기. 최고는 빨간색으로 표시됩니다.

방법 PSNR↑ SSIM↑ LPIPS↓ AVGE↓

3뷰 6뷰 9뷰3뷰 6뷰 9뷰3뷰 6뷰 9뷰3뷰 6뷰 9뷰

SRF [8] 15.32 17.54 18.350.671 0.730 0.7520.304 0.250 0.2320.171 0.132 0.120

PixelNeRF [44]16.82 19.11 20.400.695 0.745 0.7680.270 0.232 0.2200.147 0.115 0.100

MVSNeRF [6] 18.63 20.70 22.400.769 0.823 0.8530.197 0.156 0.1350.113 0.088 0.068

SRF 피트 [8] 15.68 18.81 20.750.698 0.757 0.7850.281 0.225 0.2050.162 0.114 0.093

PixelNeRF ft [44]18.95 20.56 21.830.710 0.753 0.7810.269 0.223 0.2030.125 0.104 0.090

MVSNeRF 피트 [6]18.54 20.49 22.220.769 0.822 0.8530.197 0.155 0.1350.113 0.089 0.069

CoR-GS(당사)19.21 24.51 27.18 0.853 0.917 0.947 0.119 0.068 0.045 0.087 0.046 0.029

C.2 DTU

우리는 우리의 방법을 Tab에서 DTU의 일반화된 방법과 비교합니다. III. 는

일반화된 방법은 DTU 데이터 세트에 대해 학습됩니다. 우리는 또한 그들의 당을 제공합니다

장면을 미세 조정된 결과. 우리의 방법은 또한 일반화된 방법의 장점을 보여줍니다.

방법.

C.3 MipNeRF-360

Mip-NeRF360에 대한 추가 비교는 탭에 표시됩니다. IV. 우리의 방법도

NeRF 기반 방법의 장점을 보여줍니다.

표 IV: 24뷰 Mip-NeRF360의 NeRF와의 비교.

방법 PSNR ↑ SSIM ↑ LPIPS ↓

RegNeRF [26] 20.55 0.546 0.398

프리네르프 [42] 21.39 0.587 0.377

SparseNeRF [35] 21.43 0.604 0.389

CoR-GS(당사) 23.39 0.727 0.271

--- 페이지 22 ---

22 J. Zhang 외.

CoR-GS

Ground Truth FreeNeRF

그림 VI: 3뷰 LLFF, 3뷰의 FreeNeRF와 CoR-GS의 정성적 비교

DTU 및 8뷰 블렌더.

D 추가 시각화 결과

D.1 NeRF와의 비교

그림 VI에서는 최신 기술 간의 시각화 비교를 제공합니다.

NeRF 기반 방법 FreeNeRF [42] 및 CoR-GS. FreeNeRF와 비교하면,

우리의 방법은 현실적인 고주파수를 재구성하는 데 이점을 보여줍니다.

얇은 구조의 세부 사항과 더 나은 기하학적 구조.

D.2 CoR-GS 시각화

이 섹션에서는 CoR-GS의 더 많은 시각화 결과를 제공합니다. 무화과. VII ~ X 프로-DTU, LLFF, Mip-NeRF360 및 CoR-GS의 새로운 뷰 합성을 확인하세요.

블렌더 데이터세트.

--- 페이지 23 ---

CoR-GS 23

E 토론 및 향후 작업

본 논문에서는 공동 정규화에서 희소 뷰 3DGS를 정규화할 것을 제안합니다.

관점을 파악하고 다양한 시나리오에서 폭넓은 효율성을 검증합니다.

입력 뷰 수와 깊이 정규화 방법을 사용합니다. 이 논문

3D Gaussian의 불일치 동작 간의 음의 상관 관계를 보여줍니다.

스파스 뷰 설정의 라디언스 필드 및 재구성 품질. 우리는

다음과 같은 더 많은 3DGS 응용 프로그램에서 불일치 동작 활용을 조사합니다.

공간적, 시간적으로 희박한 입력으로 비디오 재구성.

F 세부사항

F.1 데이터세트 분할

LLFF. LLFF 데이터세트[23]에는 8개의 전방 장면이 포함되어 있습니다. [19, 26, 35, 42], 우리는 테스트를 위해 모든 8번째 이미지를 새로운 뷰로 사용합니다. 입력 보기는 나머지 보기 전체에서 균등하게 샘플링됩니다. 이미지가 다운샘플링되었습니다. 8×에서 378×504의 해상도.

DTU. DTU 데이터세트[15]는 124개의 객체 중심 장면으로 구성됩니다.

고정 카메라 세트. 우리는 [19, 26, 35, 42]에 따라 모델을 직접 평가합니다.

스캔 ID가 8, 21, 30, 31, 34, 38, 40, 41, 45, 55, 63, 82인 15개 장면

103, 110, 114. 각 스캔에서 ID가 25, 22, 28인 이미지는

3뷰 설정의 입력 뷰로 사용됩니다. 25, 22, 40, 44, 48의 ID

6뷰 설정; 9개 보기 설정의 경우 ID는 25, 22, 40, 44, 48, 0, 8, 13입니다. 테스트

세트는 ID가 1, 2, 9, 10, 11, 12, 14, 15, 23, 24, 26, 27, 29,

평가를 위해 30, 31, 32, 33, 34, 35, 41, 42, 43, 45, 46 및 47을 참고하세요. 이미지는

4배로 다운샘플링되었습니다. 우리는 COLMAP의 왜곡되지 않은 이미지를 사용하여

지워지지 않은 렌즈 왜곡의 부정적인 영향.

블렌더. Blender 데이터세트[10]에 대해 [14, 19, 42]에서 사용된 데이터 분할을 따릅니다.

8개의 입력 뷰는 ID가 26, 86, 2, 55인 훈련 이미지에서 선택됩니다.

75, 93, 16, 73, 8. 25개의 테스트 뷰는 테스트에서 균등하게 샘플링됩니다.

평가용 이미지. 모든 이미지는 재생 중에 2×에서 400×400으로 다운샘플링됩니다.

실험.

MipNeRF-360. 우리는 MipNeRF-360에 대해 [51]에서 사용된 데이터 분할을 따릅니다.

데이터 세트 [3]. 우리는 테스트를 위해 모든 8번째 이미지를 새로운 뷰로 사용합니다. 입력

보기는 나머지 보기 전체에서 균등하게 샘플링됩니다.

--- 페이지 24 ---

24 J. Zhang 외.

스캔 8

스캔 21

스캔 30

스캔 31

스캔 34

스캔 38

스캔 40

스캔 41

스캔 45

스캔 55

스캔 63

스캔 82

스캔 103

스캔 110

스캔 114

그림 VII: 3뷰 DTU 설정의 질적 시각화.

양치류

나뭇잎

난초룸트렉스

꽃의 요새

그림 VIII: 3뷰 LLFF 설정의 정성적 시각화.

--- 페이지 25 ---

CoR-GS 25

자전거분재카운터가든

부엌

방

그루터기

그림 IX: 24뷰 Mip-NeRF360 설정의 정성적 시각화.

의자 레고

재료드럼

무화과나무

햇도그

마이크

배

그림 X: 8뷰 블렌더 설정의 질적 시각화.

--- 페이지 26 ---

26 J. Zhang 외.

참고자료

1. Avidan, S., Shashua, A.: 텐서 공간의 새로운 뷰 합성. 에서: 절차 컴퓨터 비전 및 패턴 인식에 관한 IEEE 컴퓨터 학회 회의.

1034~1040페이지. IEEE (1997) 4

2. Barron, J.T., Mildenhall, B., Tancik, M., Hedman, P., Martin-Brualla, R., Srinivasan, P.P.: Mip-nerf: 엔티앨리어싱 신경 복사를 위한 다중 스케일 표현 필드. In: 컴퓨터에 관한 IEEE/CVF 국제 회의 진행

비전. pp. 5855-5864 (2021) 3, 9, 12

3. Barron, J.T., Mildenhall, B., Verbin, D., Srinivasan, P.P., Hedman, P.: Mip-nerf 360: 무제한 엔티앨리어싱 신경 방사 필드. 에서: 절차 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 회의. 5470페이지-

5479(2022) 3, 9, 23

4. Blum, A., Mitchell, T.: 레이블이 지정된 데이터와 레이블이 지정되지 않은 데이터를 공동 훈련과 결합합니다. 안에:

전산 학습 이론에 관한 제11차 연례 회의의 간행물.

pp. 92-100 (1998) 4

5. Chen, A., Xu, Z., Geiger, A., Yu, J., Su, H.: Tensorf: 장력 복사장.

In: 컴퓨터 비전 -ECCV 2022: 제17차 유럽 회의, 이스라엘 텔아비브, 2022년 10월 23~27일, 절차, XXXII부. 333~350쪽. 스프링거 (2022) 3

6. Chen, A., Xu, Z., Zhao, F., Zhang, X., Xiang, F., Yu, J., Su, H.: Mvsnerf: 빠른 다중 뷰 스테레오로부터 일반화 가능한 복사장 재구성. 에서: 절차 컴퓨터 비전에 관한 IEEE/CVF 국제 컨퍼런스의 내용입니다. 14124~14133페이지 (2021) 4, 21

7. Chen, Z., Li, Z., Song, L., Chen, L., Yu, J., Yuan, J., Xu, Y.: Neurbf: 신경 적응형 방사형 기초 함수를 사용한 필드 표현. 에서: 절차 컴퓨터 비전에 관한 IEEE/CVF 국제 컨퍼런스. 4182~4194페이지(2023) 3

8. Chibane, J., Bansal, A., Lazova, V., Pons-Moll, G.: 스테레오 복사장(srf): 새로운 장면의 희소 보기에 대한 보기 합성을 학습합니다. 에서: 절차 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 회의. 7911페이지-7920 (2021) 21

9. Cong, W., Liang, H., Wang, P., Fan, Z., Chen, T., Varma, M., Wang, Y., Wang, Z.: LLM 강화와 유사한 너프 강화: 일반화 가능한 너프 변환기 견해가 혼합된 전문가. In: IEEE/CVF 국제 컨퍼런스 진행 컴퓨터 비전에 관한 내용입니다. pp. 3193-3204 (2023) 4

10. Deng, K., Liu, A., Zhu, J. Y., Ramanan, D.: 심도 감독 너프: 더 적은 조회수 및 무료로 더 빠른 교육을 받을 수 있습니다. In: 컴퓨터에 관한 IEEE/CVF 컨퍼런스 진행 비전 및 패턴 인식. pp. 12882-12891 (2022) 4, 23

11. Fridovich-Keil, S., Yu, A., Tancik, M., Chen, Q., Recht, B., Kanazawa, A.: Plenoxels: 신경망이 없는 Radiance 필드. 에서: IEEE/CVF 절차 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스. pp. 5501-5510 (2022) 3

12. Han, B., Yao, Q., Yu, X., Niu, G., Xu, M., Hu, W., Tsang, I., Sugiyama, M.: 공동 교육: 매우 시끄러운 레이블이 있는 심층 신경망에 대한 강력한 교육입니다. 신경 정보 처리 시스템의 발전 31 (2018) 4

13. Hu, W., Wang, Y., Ma, L., Yang, B., Gao, L., Liu, X., Ma, Y.: Tri-miprf: Tri-mip 효율적인 앤티앨리어싱 신경 방사 필드를 표현합니다. 에서: 절차 컴퓨터 비전에 관한 IEEE/CVF 국제 회의. 19774~19783페이지 (2023) 3

14. Jain, A., Tancik, M., Abbeel, P.: 다이어트에 너프 적용: 의미상 일관성 퓨샷 뷰 합성. In: IEEE/CVF 국제 컨퍼런스 진행 컴퓨터 비전에 관한 내용입니다. pp. 5885-5894 (2021) 4, 9, 12, 23

--- 페이지 27 ---

CoR-GS 27

15. Jensen, R., Dahl, A., Vogiatzis, G., Tola, E., Aanaes, H.: 대규모 다중 뷰 입체시 평가. In: 컴퓨터 비전에 관한 IEEE 컨퍼런스 진행 그리고 패턴 인식. pp. 406-413 (2014) 9, 23

16. Kerbl, B., Kopanas, G., Leimkühler, T., Drettakis, G.: 3d 가우스 스피래팅 실시간 래디언스 필드 렌더링. 그래픽에 대한 ACM 트랜잭션(ToG) 42(4),

- 1~14(2023) 1, 3, 4, 5, 9, 10, 11, 12, 13
17. Kim, M., Seo, S., Han, B.: Infonerf: 소수 신경을 위한 광선 엔트로피 최소화 볼륨 렌더링. In: 컴퓨터에 관한 IEEE/CVF 컨퍼런스 진행 비전 및 패턴 인식. pp. 12912-12921 (2022) 4
18. Kulhane, J., Derner, E., Sattler, T., Babu, R.: Viewformer: Nerf-free 신경 변환기를 사용하여 몇 가지 이미지에서 렌더링합니다. 에서: Com-에 관한 유럽 회의 컴퓨터 비전(ECCV)(2022) 4
19. Li, J., Zhang, J., Bai, X., Zheng, J., Ning, X., Zhou, J., Gu, L.: Dngaussian: Op-글로벌-로컬 깊이 노멀을 사용하여 스파스 뷰 3D 가우스 라디언스 필드를 최적화합니다. 화. In: 컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스 진행 및 패턴 인식. pp. 20775-20785 (2024) 4, 23
20. Li, J., Socher, R., Hoi, S.C.: Dividemix: 시끄러운 레이블을 세미-로 학습 지도 학습. arXiv 사전 인쇄 arXiv:2002.07394 (2020) 4
21. Liu, L., Gu, J., Zaw Lin, K., Chua, T.S., Theobalt, C.: 신경 회소 복셀 필드. 신경 정보 처리 시스템의 발전33, 15651-15663(2020) 3
22. Luiten, J., Kopanas, G., Leibe, B., Ramanan, D.: 동적 3D 가우스: 추적 지속적인 동적 뷰 합성을 통해. arXiv 사전 인쇄 arXiv:2308.09713 (2023) 4
23. Mildenhall, B., Srinivasan, P.P., Ortiz-Cayon, R., Kalantari, N.K., Ramamoorthi, R., Ng, R., Kar, A.: 국소 광장 융합: 사전을 이용한 실용적인 뷰 합성 스크립트 샘플링 지침. 그래픽에 대한 ACM 트랜잭션(TOG)38(4), 1-14 (2019) 9, 23
24. Mildenhall, B., Srinivasan, P.P., Tancik, M., Barron, J.T., Ramamoorthi, R., Ng, R.: Nerf: 장면을 뷰 합성을 위한 신경 복사 필드로 표현합니다. 커뮤-ACM65(1), 99-106(2021) 3, 9의 규정
25. Müller, T., Evans, A., Schied, C., Keller, A.: 즉각적 신경 그래픽 프리미티브 다중 해상도 해시 인코딩. 그래픽에 대한 ACM 트랜잭션(ToG)41(4), 1-15 (2022) 3
26. Niemeyer, M., Barron, J.T., Mildenhall, B., Sajjadi, M.S., Geiger, A., Radwan, N.: Regnerf: 회소 입력의 뷰 합성을 위해 신경 복사 필드를 정규화합니다. In: 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 회의 진행 인식. pp. 5480-5490 (2022) 4, 9, 12, 13, 21, 23
27. Roessle, B., Barron, J.T., Mildenhall, B., Srinivasan, P.P., Nießner, M.: 조밀함 회소 입력 뷰의 신경 방사 필드에 대한 깊이 사전. 에서: 절차 컴퓨터 비전 및 패턴 인식에 관한 IEEE/CVF 회의. pp. 12892-12901 (2022) 4
28. Schönberger, J.L., Frahm, J.M.: 동작으로부터의 구조 재검토. 에서: 회의 컴퓨터 비전 및 패턴 인식(CVPR)(2016) 5
29. Schönberger, J.L., Zheng, E., Pollefeys, M., Frahm, J.M.: Pixelwise 보기 선택 구조화되지 않은 다중 뷰 스테레오용. In: 컴퓨터 비전에 관한 유럽 회의 (ECCV) (2016) 5
30. Sindhvani, V., Niyogi, P., Belkin, M.: 준표준화에 대한 공동 정규화 접근 방식 다양한 보기를 갖춘 지도 학습. 에서: ICML 워크숍 진행 다양한 관점으로 학습합니다. 권. 2005년, 74~79페이지. 시테시어(2005) 4
31. Song, J., Park, S., An, H., Cho, S., Kwak, M.S., Cho, S., Kim, S.: D-erf: Boosting 단안 깊이 적응을 통한 회소 입력의 복사장(2023) 4

--- 페이지 28 ---

28 J. Zhang 외.

32. Sun, C., Sun, M., Chen, H.T.: 직접 복셀 그리드 최적화: 초고속 변환 복사장 재구성을 위한 텐스. 에서: IEEE/CVF Con-Procings of the IEEE/CVF Con-컴퓨터 비전 및 패턴 인식에 대한 참조. pp. 5459-5469 (2022) 3
33. Tang, J., Ren, J., Zhou, H., Liu, Z., Zeng, G.: Dreamgaussian: 생성 가우시안 효율적인 3D 콘텐츠 제작을 위한 스피래팅. arXiv 사전 인쇄 arXiv:2309.16653 (2023) 4
34. Uhrig, J., Schneider, N., Schneider, L., Franke, U., Brox, T., Geiger, A.: 희소성 불변 CNN. In: 3D Vision(3DV) 국제 컨퍼런스(2017) 5
35. Wang, G., Chen, Z., Loy, C.C., Liu, Z.: Sparsenerf: 증류 깊이 순위 몇 장의 새로운 뷰 합성. In: IEEE/CVF International의 절차 컴퓨터 비전 컨퍼런스(ICCV). 9065-9076(2023년 10월) 4, 9, 12, 13, 21, 23
36. Wang, Z., Bovik, A.C., Sheikh, H.R., Simoncelli, E.P.: 이미지 품질 평가: 오류 가시성에서 구조적 유사성까지. 이미지 처리에 대한 IEEE 트랜잭션 13(4), 600-612 (2004) 9
37. Wei, H., Feng, L., Chen, X., An, B.: 합의를 통해 시끄러운 레이블과 싸우기: A 공동 정규화를 통한 공동 훈련 방법. 에서: IEEE/CVF 절차 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스입니다. pp. 13726-13735 (2020) 4
38. Wu, G., Yi, T., Fang, J., Xie, L., Zhang, X., Wei, W., Liu, W., Tian, Q., Wang, X.: 실시간 동적 장면 렌더링을 위한 4D 가우스 스피래팅. arXiv 사전 인쇄 arXiv:2310.08528 (2023) 4
39. Wynn, J., Turmukhambetov, D.: Diffusionerf: 신경 방사 필드 정규화 노이즈 제거 확산 모델을 사용합니다. In: IEEE/CVF 회의 진행 컴퓨터 비전 및 패턴 인식. pp. 4180-4189 (2023) 4
40. Xiong, H., Muttukuru, S.: Sparsegs: 다음을 사용한 실시간 360° 희소 뷰 합성 가우스 스피래팅(10 2023) 2, 4, 19
41. Xu, Q., Xu, Z., Philip, J., Bi, S., Shu, Z., Sunkavalli, K., Neumann, U.: 포인트 너프: 포인트 기반 신경 방사 필드. In: IEEE/CVF 컨퍼런스 진행 컴퓨터 비전 및 패턴 인식에 관한 것입니다. pp. 5438-5448 (2022) 3
42. Yang, J., Pavone, M., Wang, Y.: Freenerf: 소수 신경 렌더링 개선 자유 주파수 정규화를 사용합니다. In: IEEE/CVF 컨퍼런스 진행 컴퓨터 비전 및 패턴 인식에 관한 것입니다. 8254-8263 (2023) 4, 9, 12, 13, 21, 22, 23
43. Yu, A., Li, R., Tancik, M., Li, H., Ng, R., Kanazawa, A.: 실시간 Plenotrees 신경 방사 필드의 렌더링. In: IEEE/CVF International의 절차 컴퓨터 비전 컨퍼런스. pp. 5752-5761 (2021) 3
44. Yu, A., Ye, V., Tancik, M., Kanazawa, A.: pixelnerf: 신경 복사장 하나 또는 몇 개의 이미지. In: 컴퓨터에 관한 IEEE/CVF 컨퍼런스 진행 비전 및 패턴 인식. 4578-4587 (2021) 4, 21페이지
45. Yu, X., Han, B., Yao, J., Niu, G., Tsang, I., Sugiyama, M.: 어떻게 동의하지 않습니까? 라벨 손상에 대한 일반화에 도움이 되나요? In: 국제회의 기계 학습. 7164~7173페이지. PMLR(2019) 4
46. Zhang, J., Li, J., Huang, L., Yu, X., Gu, L., Zheng, J., Bai, X.: 견고한 합성 - 스테레오 매칭을 위한 실제 전송. In: IEEE/CVF 컨퍼런스 진행 컴퓨터 비전 및 패턴 인식에 관한 것입니다. pp. 20247-20257 (2024) 4

47. Zhang, R., Isola, P., Efros, A.A., Shechtman, E., Wang, O.: 불합리한
지각 지표로서의 심층 기능의 효율성. 에서: IEEE 절차
컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스입니다. pp. 586-595 (2018) 9
48. Zhou, Q.Y., Park, J., Koltun, V.: Open3d: 3D 데이터 처리를 위한 최신 라이브러리.
arXiv 사전 인쇄 arXiv:1801.09847 (2018) 5

--- 페이지 29 ---

CoR-GS 29

49. Zhou, T., Tulsiani, S., Sun, W., Malik, J., Efros, A.A.: 출현별 합성 보기-
엔스 흐름. In: Computer Vision-ECCV 2016: 제14회 유럽 컨퍼런스, Amster-
담, 네덜란드, 2016년 10월 11~14일, 절차, 파트 IV 14. 286~301페이지.
스프링거 (2016) 4
50. Zhou, Z., Tulsiani, S.: Sparsefusion: 3D를 위한 뷰 조건 확산 증류
재건축. 에서: CVPR (2023) 4
51. Zhu, Z., Fan, Z., Jiang, Y., Wang, Z.: Fsgs: 다음을 사용한 실시간 퓨샷 뷰 합성
가우스 스피래팅(2023) 2, 4, 5, 8, 9, 10, 11, 13, 19, 20, 23

5. Camera Pose Trajectory 포함 계열

[논문 15] 3R-GS 본문 전체 번역

--- 페이지 1 ---

3R-GS: 3DGS와 함께 카메라 포즈를 최적화하는 모범 사례

Zhisheng Huang¹ Peng Wang² Jingdong Zhang¹ Yuan Liu³ Xin Li¹

왕웬핑¹

¹텍사스 A&M 대학교, ²홍콩 대학교, ³홍콩 과학 기술 대학교

불완전한 포즈 + 3DGS

카메라 포즈소셜전망합성

불완전한 포즈 + 3R-GS

PSNR 20.193

평행이동 0.0267m 회전 0.83° 이동 0.0156m 회전 0.23°

PSNR 19.289

추정지면진실거리

추정지면진실거리

평행이동 0.0112m 회전 0.16°

PSNR 24.822

추정지면진실거리

PSNR 21.933

평행이동 0.0049m 회전 0.06°

추정지면진실거리

그림 1. 우리는 고품질 3D 가우시안과 MAST3R의 불완전한 포즈를 재구성하기 위한 강력한 방법인 3R-GS를 제안합니다.

출력 카메라. 우리의 방법은 3DGS와 함께 단순한 공동 카메라 포즈 최적화보다 큰 차이로 성능이 뛰어납니다.

초록

3D 가우스 스플래팅(3DGS)은 신경에 혁명을 일으켰습니다.

효율성과 품질이 뛰어나지만 많은 사람들이 그렇듯

새로운 뷰 합성 방법은 정확도에 크게 의존합니다.

SfM(Structure-from-Motion) 시스템에서 카메라 포즈를 평가합니다.

항목. 최근 SfM 파이프라인이 인상적인 성과를 거두었지만

진전이 있지만, 어떻게 더 나은 결과를 얻을 수 있을지에 대한 의문이 남아 있습니다.

까다로운 상황에서도 강력한 성능을 입증합니다.

버전(예: 질감이 없는 장면) 및 캠의 정밀도

시대 매개변수 추정을 동시에 수행합니다. 우리는 3R-을 제시합니다.

이를 연결하는 3D Gaussian Splatting 프레임워크인 GS

3D Gaussian과 카메라 PA를 공동으로 최적화하여 격차를 해소합니다.

MASt3R-SfM 이전의 대규모 재구성의 레이미터. 우리

순진하게 3D 가우스와 캠을 합동으로 수행한다는 점에 유의하세요.

시대 최적화는 두 가지 과제에 직면해 있습니다.

SfM 초기화 품질 및 제한된 용량

전역 최적화로 인해 차선책으로 재구성됨
 결과. 당사의 3R-GS는 다음을 통합하여 이러한 문제를 극복합니다.
 최적화된 사례를 적용하여 강력한 장면 재구성을 가능하게 합니다.
 카메라 등록이 불완전한 경우에도 가능합니다. 광범위한
 실험에 따르면 3R-GS는 고품질을 제공합니다.
 새로운 뷰 합성 및 정확한 카메라 포즈 추정
 계산 효율성을 유지하면서. 프로젝트 페이지:
<https://zsh523.github.io/3R-GS/>

1. 소개

2D 이미지에서 3D 표현을 구축하는 것이
 최근 수십 년 동안 지속된 연구 과제입니다.
 최근에는 Neural Radiance Fields와 같은 방법이
 (NeRF) [32] 및 3D Gaussian Splatting (3DGS) [22]
 3D 장면 표현을 위한 강력한 접근 방식으로 등장했습니다.
 특히 새로운 뷰 합성에 적합합니다. 이 NeRF-
 3DGS 기반 방법에는 정확한 카메라 매개변수가 필요합니다.
 3D-2D 투영 관계를 올바르게 설정하기 위해,
 일반적으로 SfM(구조-동작)에 의존하는 작업
 기술(예: COLMAP) [38]. 그러나 SfM 프로세스
 종종 시간이 많이 걸리고 때로는 견고하지 않습니다.
 실내와 같이 특징이 없는 영역이 있는 장면 또는 객체
 환경 — 신뢰성을 떨어뜨립니다.
 학습 기반, 피드포워드의 최근 발전
 조밀한 재구성 방법(예: DUST3R [45] 및
 MAST3R [12])은 상당한 잠재력을 입증했습니다.
 보정되지 않은 데이터로부터 3D 구조를 추론하기 위한 대형 모델
 브레이티드 이미지. [12, 13, 51]. 그들은보다 더 강력합니다

1

arXiv:2504.04294v1 [cs.CV] 2025년 4월 5일

--- 페이지 2 ---

특히 까다로운 상황에서 전통적인 SfM 파이프라인
 순수한 회전 운동, 텍스처 없는 조건
 지역 및 스파스 뷰 시나리오. 그럼에도 불구하고 나는-
 증명, 이러한 3R 기반의 예상 카메라 포즈
 방법은 여전히 제한 사항으로 인해 완벽한 정확성이 부족합니다.
 피드포워드 패러다임 또는 지나치게 단순화된 글로벌 방식
 최적화 전략. 결과적으로 이러한 불완전성은
 후속 3DGS 훈련의 성능이 저하될 수 있습니다.
 픽셀 수준의 정확도를 갖춘 카메라 포즈가 필요합니다.
 본 논문에서는 강력한 방법인 3R-GS를 소개합니다.
 고품질 3D 가우스 표현 재구성을 위한
 MAST3R 카메라의 불완전한 출력으로 인해 발생합니다. 우리의 방법
 카메라 포즈를 동시에 학습한다는 아이디어를 기반으로 합니다.

및 3D 가우스 표현. 그러나 직접 신청-
 불완전하게 등록된 3DGS에 대한 공동 학습 접근 방식

카메라 프레임이 여러 가지 문제를 야기합니다.
 첫 번째 과제는 초기화에 대한 민감성입니다. 기차-3DGS를 수행하려면 다음과 같은 고급 엔지니어링 휴리스틱이 필요합니다.
 분할/복제 및 불투명도 재설정 등 광범위한 작업이 필요함
 하이퍼파라미터 튜닝. 카메라 포즈가 불완전할 때,
 조인트 최적화는 로컬 최소값에 쉽게 갇힐 수 있습니다.
 이 문제는 최근 피드포워드로 인해 더욱 심각해졌습니다.
 DUS3R [45]과 같은 조밀한 재구성 방법. 이것들
 방법은 정확도가 낮은 포인트 클라우드를 생성하는 경우가 많습니다.
 높은 깊이의 모호함으로 인한 배경 영역
 훈련 데이터.
 두 번째 과제는 비효율적인 포즈 최적화입니다.
 Ray March를 사용하여 렌더링하는 NeRF와 같은 방법과 달리
 픽셀 수준의 정밀도를 제공하는 3DGS에는 내장된 메커니즘이 부족합니다.
 단일 카메라에서 여러 대의 카메라를 효율적으로 최적화하기 위한 Nisms
 훈련 단계. 대신 3DGS는 미분 가능한 래스터를 사용합니다.
 각 훈련 단계에서 모든 포인트를
 동일한 NDC(Normalized Device Coordinates) 공간
 이를 이미지 공간에 투영하고, 정렬하고, 렌더링합니다.
 전체 이미지 수준 렌더링을 생성합니다. 이 기계가
 애니메이션은 한 번에 많은 픽셀 배치를 렌더링합니다.
 단일 카메라에서 발생합니다. 즉, 최적화가
 이는 훈련 단계당 하나의 카메라에만 영향을 미칩니다. 대조적으로,
 NeRF와 유사한 방법을 통해 보다 효율적인 카메라 최적화가 가능합니다.
 각 훈련 단계에는 렌더링된 픽셀이 포함될 수 있으므로
 여러 카메라에서.
 첫 번째 문제를 해결하기 위해 우리는 3DGS를 채택할 것을 제안합니다.
 불완전한 초기에 대한 견고성을 향상시키는 MCMC [24]
 화. 우리는 3D 가우시안을 MCMC 샘플로 봅니다.
 장면을 정확하게 나타내는 분포에서.
 상태 전환을 통해 가우스 프리미티브는 다시
 위치를 파악하여 지역적 최소점을 벗어나도록 돕고 개선합니다.
 수렴. 이는 높은 수준에 대한 방법의 의존도를 줄입니다.
 품질 포인트 클라우드 및 카메라 포즈 초기화. 추가적으로
 3DGS-MCMC를 사용하면 휴리스틱이 필요하지 않습니다.
 3DGS의 텍 밀도화 및 가지치기 전략, 제거
 하이퍼파라미터 미세 조정의 부담.
 두 번째 문제를 해결하기 위해 다음에서 영감을 얻습니다.
 PoRF [2] 및 ACE0 [4]를 통해 카메라 포즈 최적화를 개선합니다.
 카메라 포즈 간의 상관관계를 모델링하여
 다층 퍼셉트론(MLP). 구체적으로 우리는 공동으로 훈련합니다.
 카메라별 임베딩과 함께 전 세계적으로 공유되는 MLP
 카메라 포즈를 다듬습니다. 또한, 캠을 더욱 향상시키기 위해
 시대 포즈 최적화, 에피플라 거리를 통합합니다.
 카메라 포즈를 다듬기 위한 기하학적 제약으로서의 손실.
 이 접근 방식은 쌍별 대응을 직접 활용합니다.
 카메라 포즈를 최적화하기 위한 이미지 매칭. 활용하여

사용 가능한 모든 쌍별 대응을 통해 더 나은 선택을 할 수 있습니다.
 보다 직접적인 기하학적 감독을 사용하여 카메라 포즈를 조정합니다.
 신호. 우리가 아는 한, 우리의 접근 방식은 다음과 같습니다.
 최초로 MLP 포즈 모델링 및 에피폴라 손실을 적용하여 해결
 공동 3DGS와 카메라 포즈 최적화의 독특한 과제
 마이징.

요약하면 우리의 기여는 다음과 같습니다.

1. 우리는 재구성을 위한 강력한 방법인 3R-GS를 제안합니다.
 고품질 3D 가우시안을 사용하고
 MAST3R의 불완전한 출력 카메라.
 2. 번들 조정의 두 가지 주요 과제 식별
 3DGS는 다음과 같은 효과적인 솔루션을 제안합니다.
 MLP 기반 포즈 리파이너인 3DGS-MCMC와
 이러한 문제를 해결하기 위해 에피폴라 거리 손실이 필요합니다.
 3. 우리의 실험은 우수한 성능을 보여줍니다
 새로운 뷰 합성과 카메라 포즈 모두에서 3R-GS의
 추정.

2. 관련 업무

2.1. 이미지로부터 카메라 포즈 추정

를 사용하여 견고하고 정확하게 카메라 포즈를 추정합니다.
 RGB 이미지는 오랫동안 지속되어 온 근본적인 과제입니다.
 이미지가 다른 방식으로 캡처되는지 여부에 따라
 순서가 지정되지 않은 순서, 구조와 같은 방법
 from-Motion(SfM) 또는 동시 현지화 및 지도-
 ping(SLAM)을 사용하여 정확한 포즈를 얻을 수 있습니다.
 타이밍.
 본 논문에서는 주로 순서가 지정되지 않은 설정에 중점을 두고 있습니다.

동작으로부터 구조를 얻는 방법의 예시로 볼 수 있습니다. Tra-
 COLMAP[38]과 같은 추가적인 SfM 방법은 길다.
 파이프라인은 기능 일치와 같은 여러 단계를 손상시킵니다.
 카메라 등록, 번들 조정 등이 복잡하고
 텍스처가 없는 재작업과 같은 일부 까다로운 경우에는 견고하지 않습니다.
 기온과 순수 회전. 최근 학습 기반 회소 기능
 ture 추출 및 매칭 방법 [28, 34, 37, 42]
 전통적인 특징 매칭을 개선하려고 노력했지만, 그들의 역할은
 가숨은 여전히 개선의 여지가 남아있습니다. 컴과는 달리
 플렉스 파이프라인, DUST3R [45]과 같은 최신 방법
 그 변형[12, 43, 44]은 di-의 힘을 보여주었습니다.
 대형 모델을 사용하여 3차원 구조를 정확하게 예측합니다. 어떻게-
 견고함에도 불구하고 이러한 접근 방식에는 픽셀이 부족합니다.
 수준 정확도로 인해 차선의 다운스트림 재조정이 발생합니다.
 공사결과.

2

--- 페이지 3 ---

2.2. 새로운 관점 합성(NVS)

소설적 관점 종합은 이름에서 알 수 있듯이 다음을 생성하는 것을 목표로 합니다.
 입력된 이미지를 활용하여 보이지 않는 시점에서 이미지를 먹었습니다.
 나이. 이 기능은 가상 머신과 같은 애플리케이션에서 중추적인 역할을 합니다.
 실제 현실, 텔레프레즌스 등. 최근에는 Neural
 Radiance Fields(NeRF) [32] 및 3D 가우스 스피래팅
 (3DGS) [21] 참신한 뷰의 품질을 크게 향상시켰습니다.
 합성하여 사실적인 결과를 얻습니다. 특히,
 3DGS와 유사한 방법은 NVS 재구성의 최전선에 있었습니다.
 명확하고 명시적인 표현으로 인해 최근 검색
 실시간 렌더링 기능. 여러 변형
 3DGS가 제안되었으며, 각각은 특정 측면을 목표로 합니다.
 문제의 해결 - 예를 들어 대규모 접근 방식
 재구성 [23, 29, 29, 35, 50, 62], 피드포워드 모드-
 els [30, 40, 49, 58], 표면 재구성 [17, 55-57] 및
 반사 물체를 처리하는 방법 [20, 52, 60]. 어떻게-
 항상 이러한 NVS 방법은 밀도가 높고 정확해야 하는 경우가 많습니다.
 SfM 파이프라인을 통해 얻은 카메라 포즈. 때
 입력 카메라 포즈가 부정확하고, 정렬이 잘못되었으며, 예술적인 부분이 있습니다.
 사실은 합성된 보기에서 발생할 수 있습니다.

2.3. 조인트 NVS 및 자세 추정

알려진 캠에 의존하는 문제를 해결하기 위해
 위에서 설명한 대로 시대가 포즈를 취하고 있지만 최근 방법에는
 강판 포즈 최적화, 엔드투엔드 프레임워크 설계
 공동 카메라 포즈 추정 및 NVS용. 예를 들어,
 Guo et al. [16]은 합성하는 2단계 네트워크를 제안했습니다.
 6-DoF 카메라 포즈에서 직접 새로운 뷰 크기를 조정하고
 기하학적 매핑과 텍스처 렌더링을 en-
 다양한 작동 조건에 대한 견고성을 강화합니다.
 NeRF try의 초기 작품 [3, 6, 8, 19, 27, 41, 47, 54]
 그러한 요구 사항을 없애기 위해. 그 중 NeRFmm
 [47]은 카메라 매개변수의 공동 최적화를 보여줍니다.
 경험적, 2단계를 통한 테르 및 NeRF 매개변수
 파이프라인. 반면 BARF[27]는 단일 코스를 도입한다.
 좌표 기반 장면 표현에 대한 대략적인 등록과 미세한 등록
 분노. GARF [8] 및 [48]은 특수 활성화를 사용합니다.
 기능, 고주파 위치 문제 완화
 NeRFmm 재구성의 인코딩 및 체계적 차선택
 관점에서. NoPe-NeRF [3]는 추가적인 싱글 뷰를 채택합니다.
 강력한 기하학 단서를 제공하는 깊이 추정. 스파프
 [41], SC-NeRF [19] 및 PoRF [2]는 이미지 보정을 통합합니다.
 공동 최적화의 응답. 인상적이긴 하지만
 결과가 달성되었으면 이러한 방법은 다음으로 제한됩니다.
 앞으로 향하는 장면이나 간단한 비디오 클립
 궤적. 게다가 NeRF 표현은 다음을 가능하게 합니다.
 수렴 속도가 느린 방법.
 최근 연구에서는 NeRF에서 3DGS로 초점이 옮겨졌습니다.
 실시간 렌더링이 가능하고 렌더링 품질이 향상됩니다.

훈련 속도도 빨라집니다. 공동 NVS의 범위에서
포즈 추정, CF-3DGS [15] 및 [39]는 다음과 같은 순서를 가정합니다.
비디오 프레임은 프레임을 순차적으로 입력하고 처리합니다.
방식으로 점진적으로 3DGS를 훈련합니다. 인스턴트스플랫
[14]는 카메라 포즈 초기화를 위해 DUS3R [45]를 활용합니다.
하지만 아주 적은 수의 이미지로 제한됩니다. ZeroGS[7]는 사전
훈련된 모델을 숫자 장면 표현으로 훈련할 수 있습니다.
포즈도 없고 순서도 없는 수백 개의 이미지에서 3DGS를

나이. 그러나 그들은 또한 점진적인 훈련과
융합을 위해서는 2단계 전략이 필요하다. BAD-가우시안
[61]과 [10]은 훈련 시 카메라 최적화도 고려합니다.
3DGS이지만 모션 블러 해결에 중점을 둡니다.
우리의 작업은 주로 다음과 같은 선구적인 작업에서 영감을 받았습니다.
NeRF. 예를 들어, MLP 포즈 구체화가 도입되었습니다.
PoRF와 ACE0[4]에 의해 유도된 에피플라 거리 손실
기능은 SC-NeRF 및 PoRF에서도 활용되었습니다.
그러나 그들과는 다르게 우리는 이러한 접근법을 사용합니다.
번들 조정 시 고유한 문제를 효과적으로 처리합니다.
3DGS. 그리고 3DGS의 진보적 방법을 비교해보면,
방법은 표준 3DGS 훈련만 수정하면 됩니다.
무시할 수 있는 오버헤드로 약간의 파이프라인을 적용할 수 있습니다.
짧은 비디오 클립과 전체 비디오 시퀀스 모두에 적용됩니다.

3. 방법

3.1. 개요

알려진 포즈 없이 캡처된 이미지 세트가 주어졌을 때
도전적인 장면을 재현하는 것이 우리의 목표입니다.
고품질의 3D 가우스 표현과 정확한 캠-
시대 포즈. 기존 3D 가우스 재구성 방법
ods는 정확한 카메라 포즈에 크게 의존합니다.
전통적인 구조-동작 기술을 바탕으로
(예: COLMAP [5])를 입력으로 사용하고 종종 시나리오에서 어려움을 겪습니다.
질감이 없는 실내 환경과 같은 iOS.
이를 위해 우리는 다음과 같은 최신 기술을 기반으로 합니다.
대규모 재구성 사전 조사 [12, 45], 특히,
우리는 카메라를 견고하게 추정하기 위해 MAST3R-SfM [12]을 사용합니다.
포즈.
MASt3R-SfM은 기존 SfM 방법보다 성능이 뛰어납니다.
견고성 측면에서 COLMAP [38]과 같은 ods
다양한 조건에서 추정된 카메라 포즈는 그대로 유지됩니다.
픽셀 수준의 정확도가 부족하여 완벽합니다.
다운스트림 3DGS 재구성을 위한 렌지입니다. 우리의 3R-
3DGS와 카메라가 결합된 학습 프레임워크인 GS
MASt3R-SfM에서 위의 문제를 해결하는 것을 목표로 합니다. 어떻게-
불완전한 카메라 포즈를 순진하게 최적화합니다.
3DGS 교육은 제한된 개선으로만 이어집니다.
초기화에 대한 민감성과 내부화라는 두 가지 과제를 해결합니다.

소개에서 설명한 대로 효율적인 포즈 최적화.
 이러한 과제를 해결하기 위해 다음을 소개합니다. (1) ro-
 Markov Chain을 활용한 흉상 자세 개선 전략
 Monte Carlo(섹션 3.2), (2) 전역 카메라 상관 관계
 MLP 기반 리파이너를 사용한 모델(섹션 3.3) 및 (3)
 에피폴라 손실을 기반으로 한 렌더링 없는 기하학적 제약 조건
 (섹션 3.4).

3

--- 페이지 4 ---

MASt3RSfM

RGB이미지

불완전한카메라포즈

가우스 프리미티브

!"#

세련된 포즈

픽셀별 대응...

...

...

... ..

포즈 리파이너

샘플링된 보기

3R-GS

그림 2. 3R-GS 파이프라인 개요. 파이프라인은 카메라 포즈와 3D 가우스 매개변수를 공동으로 개선합니다.

(a) 로컬 최소값에서 가우시안 탐색(b) 깊이 관련 기하학적 제약 조건

3D-3D

!!!3D-2D이미지 A이미지 B3D-2D

(c) 포즈 추정의 공유 드리프트 오류

렌더 탐색

이미지

투영 깊이

드리프트

추정 GroundTruth

그림 3. 3R-GS에 대한 동기; 섹션을 참조하세요. 3.2, 3.4, 3.3.

3.2. MCMC 기반 포즈 최적화

동기: 바닐라 3DGS 최적화는 매우 민감합니다.

가우시안 프리미티브에는 제한이 있기 때문에 초기화에 효과적입니다.

적응성이 뛰어나고 정확한 초기 포인트 클라우드에 의존합니다.

[24, 36]. 예를 들어, 그림 3(a)와 같이 Gaussian

기본 요소는 처음에 이상적인 위치에서 약간 떨어진 곳에 배치됩니다.

불완전한 초기화로 인해 수정하는 데 어려움을 겪을 수 있습니다.

그 자체. 이는 광도 렌더링 손실로 인해 발생합니다.

작은 로컬 영역 내에서만 그래디언트를 제공하므로

원시인이 국소 최적점을 벗어나서 최적점에 도달하는 것은 어렵습니다.

올바른 위치. 결과적으로 초기화가 잘못되면 다음과 같은 문제가 발생할 수 있습니다.

차선의 수렴 및 저하된 장면 재구성.

또한 3DGS의 적응형 밀도 제어는

기울기 크기 기반 임계값에 대해
치밀화 전략에 대한 수동 조정 또는 조정
[11] 새로운 훈련 목표를 도입할 때. 이번 재-
liance는 최적화를 복잡하게 할 뿐만 아니라
카메라 포즈를 공동으로 최적화할 때 추가적인 과제
3DGS와 함께.

해결책: 우리는 3DGS-MCMC[24]를 채택하여

3D 가우시안을 재구성하여 초기화에 대한 견고성
Markov Chain Monte Carlo(MCMC) 샘플로 스플래팅
플링. 이 접근법은 훈련을 다음으로부터의 샘플링으로 해석합니다.
컬렉션에 높은 확률을 할당하는 분포 $p(G)$
가우시안은 훈련 이미지를 충실하게 재구성합니다. 그것은 다시
표준 3DGS 최적화가 Stochas와 유사하다는 송아지-
SGLD(Gradient Langevin Dynamics) 업데이트:
 $G \leftarrow G + a \cdot \nabla G \log p(G) + b \cdot \text{eta}$
여기서 ∇ 는 탐사 잡음이고, 매개변수 a 와 b 는 bal-
융합과 탐구. 이 소음과 함께 전-
그림 3(a)의 탐색이 달성될 수 있다. 게다가 3DGS-
MCMC는 경험적 기반 밀도화의 필요성을 제거합니다.
그리고 이를 원칙에 입각한 국가 트랜스로 교체하여 가지치기합니다.
위치. 우리는 또한 정규화 프로그램을 통합하여
가우시안을 절약적으로 사용합니다.
3DGS-MCMC를 사용하여 강력한 조인트 최적화를 달성합니다.
카메라 포즈와 3DGS의 "감각"을 해결합니다.
초기화에 대한 민감성" 문제. 다음 섹션에서는
"비효율적인 자세"를 해결하기 위한 두 가지 기술을 소개합니다.
최적화'에 도전합니다.

3.3. MLP 기반 전역 포즈 개선

동기: 실제로 여러 대의 카메라가 종종 통신을 공유합니다.
mon 드리프트 오류 - 상대적인 포즈는 일치할 수 있습니다.
즉, 그들은 집합적으로 실제 사실에서 벗어납니다.
그림 3(c)와 같이 공유 회전 및 변환 오류.
그러나 개별 카메라 포즈를 직접 최적화하면
독립적인 것으로서 원래 올바른 위치를 왜곡할 수 있습니다.
Cal 상대적인 포즈를 취하고 최적화를 더 쉽게 만듭니다.
문제의 고유한 비볼록성으로 인한 로컬 최소값
렘 [33].

솔루션: MLP 기반 글로벌 포즈 리파이너를 소개합니다.
잠재에서 자세 교정 T_i 를 예측하는 방법을 학습합니다.
카메라 표현:

$$T_i = \text{RMLP}(z_i), (1)$$

여기서 z_i 는 공동으로 최적화된 학습 가능한 카메라입니다.
MLP 정제기를 사용하여 수정사항은 번역으로 구성됩니다.
($t_i \in \mathbb{R}^3$) 및 회전($r_i \in \mathbb{R}^6$) 구성요소. 는
MLP는 안정성을 보장하기 전에 평균 0으로 초기화됩니다.
개선. 이 공식은 전역 포즈 관계를 포착합니다.

모든 보기에서 공유 MLP를 사용하여 제공됩니다.
 보다 정확한 카메라 조정. 실제로는
 개인을 직접 최적화하는 것보다 훨씬 더 나은 결과를 얻을 수 있습니다.
 평소 카메라 포즈.
 3.4. 렌더링 없는 기하학적 제약
 동기: 앞서 언급한 요인에 더해
 비효율적인 카메라 최적화에 기여하는 또 다른
 문제는 렌더링 손실에만 의존하는 것에는 직접적인 결과가 부족하다는 것입니다.
 카메라 포즈에 대한 측정 감독. 간단하다
 직접적인 기하학적 감독을 부과하는 접근 방식은
 대응 기반 기하학적 손실을 사용합니다. 우리는
 MAST3R-SfM은 일치하는 대응을 제공합니다.
 기하학적 최적화에 잠재적으로 사용될 수 있습니다.
 4

--- 페이지 5 ---

특히 MAST3R-SfM은 회소 장면을 구성합니다.
 그래프 $G = (V, E)$, 여기서 각 꼭지점 $l \in V$ 는
 이미지, 각 에지 $e = (n, m) \in E$ 는 단일을 나타냅니다.
 중복될 가능성이 있는 두 이미지 사이의 연결을 수정했습니다.
 나 n 과 나 m . 그래프를 기반으로 MAST3R-SfM은 다음을 계산합니다.
 대응은 $M_{n,m}$ 과 일치합니다.
 대응을 활용하기 위해 일반적인 선택에는 다음이 포함됩니다.
 3D-2D 투영 손실 [12, 41] 및 3D-3D 손실 [5, 12]
 둘 다 그림 3(b)에 표시된 것처럼 깊이에 의존합니다. 3D-3D 손실
 im 에서 해당 지점 사이의 거리를 계산합니다.
 깊이를 사용하여 3D 공간으로 역투영하여 연령 쌍
 카메라 매개변수; 3D-2D 손실은 이를 재투영합니다.
 2D 거리를 계산하기 위해 이미지 평면 위의 3D 점
 그들의 서신에. 이러한 방법에는 일반적으로 다음이 필요합니다.
 글로벌 번들 조정을 시뮬레이션하기 위한 여러 이미지 쌍,
 보다 일관된 그라데이션을 보장합니다. 그러나 통합
 이러한 최적화 목표를 3DGS 교육에 추가하면
 주로 3DGS가 per-
 렌더링을 위한 뷰 깊이 정렬(RGB 및 깊이 모두)
 훈련을 위해서는 수만 번의 반복이 필요합니다.
 이 계산상의 제약으로 인해 숫자가 심각하게 제한됩니다.
 각 단계에서 처리할 수 있는 뷰 수입니다. 통합

뷰가 추가되면 훈련 시간이 크게 늘어나고
 엄청난 수준의 메모리 소비. 결과적으로,
 각 단계에서는 이미지 쌍의 하위 집합만 고려할 수 있습니다.
 앞서 언급한 기하학적 구속조건을 적용할 때,
 진정한 글로벌 목표의 실행을 방해하고
 궁극적으로 차선의 결과를 초래합니다.
 해결책: 렌더링이 필요 없는 전역 기하학을 제안합니다.
 에피플라 거리에 따른 제약. 주어진 이미지 일치 -

MASt3R-SfM의 응답 $M_{n,m}$ 을 사용하여 손실을 정의합니다.

다음과 같이:

$L_{GEO} = 1$

$|E|$

X

$(n,m) \in E$

1

$|M_{n,m}|$

X

(x_i, x')

$i) \in M_{n,m}$

$\text{conf}_i \cdot d(x_i, x')$

나)

(2)

여기서 conf_i 는 MASt3R이 제공한 신뢰도입니다.

응답 (x, x') , $d(x, x')$ 는 대칭 에피폴라입니다.

기본 행렬 F 로부터 계산된 거리는 다음과 같습니다.

카메라 포즈와 내장 함수에서 파생됩니다. PoRF와 달리

[2], 모든 이미지 쌍의 대응성을 고려합니다.

(n, m) 각 훈련 반복 동안 MASt3R-SfM의 $\in E$.

이를 통해 보다 전 세계적으로 정보를 바탕으로 공동 최적화를 수행할 수 있습니다.

카메라 포즈. MASt3R-SfM은 수천 개의 서비스를 제공할 수 있지만

각 이미지 쌍에 대한 대응 관계를 경험적으로 찾았습니다.

단지 몇백 개만 필요하므로 우리는

균일하게 대응합니다.

3.5. 최종 훈련 목표

우리의 완전한 교육 목표는 원래의 3D를 통합합니다.

추가 규제로 인한 Gaussian Splatting 렌더링 손실

3DGS-MCMC[24]의 용어 정의와 함께

Eq.의 기하학적 제약 조건 L_{geo} . 2.

$L_{total} = L_{orig} + \lambda_{geo} \cdot L_{geo} + L_{reg}$ (3)

원래 3DGS 훈련 손실 L_{orig} 는 [22]를 따릅니다.

$L_{orig} = (1 - \lambda_{D-SSIM}) \cdot L_1 + \lambda_{D-SSIM} \cdot L_{D-SSIM}$ (4)

여기서 L_1 은 L_1 색상 오류를 측정하고 L_{D-SSIM} 은 측정합니다.

$D-SSIM = 0.2$ 인 구조적 유사성. 정규화-

3DGS-MCMC의 L_{reg} 라는 용어는 효율적인 사용을 촉진합니다.

더 적은 수의 가우스를 장려하여 가우스:

$L_{reg} = \sum_i \alpha_i \cdot$

X

나

$\|o_i\|_1 + \sum_{j \neq i} \alpha_j \cdot$

X

i, j

|

큐

$\text{eig}_j(\Sigma_i) \cdot \alpha_i$ (5)

여기서 $\text{eig}_j(\cdot)$ 는 공분산의 j 번째 고유값을 나타냅니다.

매트릭스.

4. 실험

4.1. 실험 설정

데이터 세트. 우리는 세 가지 방법을 광범위하게 평가합니다.

실제 데이터 세트 사용: 탱크 및 사원[25], Mip-NeRF360[1], DTU[18] 등 대표 4인 선정

각각의 장면. Mip-NeRF360 데이터 세트에는 다음이 포함되어 있습니다.

배포된 카메라로 촬영한 문 및 실외 장면

360도 궤적을 따라 균등하게 각 장면을 구성합니다.

약 100~300개의 이미지를 평가합니다. 탱크 및 온도

Ples는 카메라 포즈와 관련하여 유사한 설정을 따릅니다.

장면 규모는 더 크지만 조명의 변화가 더 큼니다.

그리고 외모. 이와 대조적으로 DTU는 개체 수준에 중점을 둡니다.

조명이 조절된 실내 장면을 각각 촬영했습니다.

49개 또는 64개의 이미지와 정확한 지면을 포함하는 시퀀스

진실 포즈. 이러한 데이터 세트는 3D Gaus-

시안 스플래팅 문헌 [17, 22]. 사전 작업에 이어,

동일한 평가 프로토콜과 훈련 뷰 해상도를 채택합니다.

각 데이터 세트에 대한 솔루션입니다.

측정항목. BARF [27] 및 CF-3DGS [15]에 이어

NVS(Novel View Synthesis)와 카메라를 모두 평가합니다.

포즈등록. 카메라 자세 평가를 위해 보고합니다.

평균 회전 오류 및 Root Mean Square Er-

절대궤도오차(ATE)의 ror(RMSE) [31]

(미터 단위) 훈련 보기. 비슷한 것을 설명하기 위해 -

ity 변환을 통해 최적화된 훈련 자세를 정렬합니다.

카메라에서 프로크루스테스 분석을 사용하여 실제 사실을 확인합니다.

이전 작업 [27]에 이어 위치. NVS의 경우 보고합니다.

PSNR, SSIM [46] 및 LPIPS [59]. NVS가 필요하기 때문에

테스트 뷰 포즈, 테스트 시간 렌더링 최적화를 수행합니다.

이전과 일치하는 최적의 테스트 포즈를 얻기 위한

[3, 15, 27]에 접근합니다.

구현 세부정보 우리의 방법은 다음과 같이 구현됩니다.

3D Gaussian Splatting 프레임워크를 기반으로 구축된 PyTorch -

gsplat [53]을 사용하세요. 모든 실험에 대해 우리는 일관된

가중치 인자: $\text{D-SSIM} = 0.2$, $\text{o} = 0.01$, $\text{r} = 0.01$,

5

--- 페이지 6 ---

3DGS Spann3R ZeroGS CF-3DGS OursScenes PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

트럭 20.91 0.723 0.181 10.67 0.398 0.863 - - - - - 24.82 0.860 0.121이그나티우스 18.96 0.665 0.249 13.32

0.298 0.589 21.95 0.665 0.234 - - - 21.93 0.778 0.198캐터필러19.29 0.539 0.349 12.57 0.348 0.720 - - -

12.96 0.340 0.616 23.37 0.773 0.235회의실22.78 0.784 0.239 11.87 0.462 0.834 - - - - - 25.93 0.867 0.177

정원 24.85 0.729 0.126 18.13 0.281 0.485 25.47 0.839 0.107 - - - 26.44 0.82 0.131카운터 27.57 0.862 0.209

15.02 0.537 0.632 26.87 0.873 0.124 - - - 28.80 0.897 0.157자전거 17.52 0.303 0.567 16.09 0.256 0.634

23.10 0.707 0.201 - - - 24.89 0.727 0.252방 30.66 0.899 0.204 14.06 0.563 0.709 - - - - - 31.82 0.924 0.154
스캔69 26.37 0.865 0.134 15.76 0.447 0.565 - - - 18.09 0.554 0.521 26.62 0.868 0.112scan83 28.36 0.882
0.172 20.45 0.759 0.321 - - - 12.81 0.572 0.546 28.44 0.881 0.117scan106 32.74 0.923 0.109 20.30 0.664
0.379 - - - 18.00 0.550 0.530 34.35 0.936 0.066스캔110 31.46 0.905 0.142 21.58 0.752 0.323 - - - 18.87
0.644 0.482 32.63 0.931 0.074

표 1. 새로운 관점 합성의 정량적 비교. (-)는 ZeroGS에 대해 보고되지 않은 결과와 CF-3DGS에 대해 실패한 장면을 나타냅니다.

3DGS Spann3R ZeroGS CF-3DGS OursScenes 회전(°)↓ ATE(m)↓ 회전(°)↓ ATE(m)↓ 회전(°)↓ ATE(m)↓ 회전(°)↓ ATE(m)↓ 회전(°)↓ ATE(m)↓

트럭 0.83 0.027 51.69 3.156 - - - - 0.16 0.011
이그나티우스 0.23 0.016 5.87 0.391 0.03 0.002 - - 0.06 0.005
캐터필러 1.41 0.402 10.95 0.695 - - 82.50 3.743 0.32 0.020
회의실 0.75 0.052 26.14 2.021 - - - - 0.24 0.023
정원 0.19 0.003 2.08 0.147 0.03 0.002 - - 0.03 0.002
카운터 0.25 0.011 4.08 0.332 0.03 0.002 - - 0.05 0.003
자전거 1.07 0.034 11.11 1.516 0.04 0.005 - - 0.09 0.013
방 0.27 0.016 8.46 0.908 - - - - 0.13 0.012
스캔69 0.23 0.006 5.10 0.158 - - 47.95 0.955 0.1 0.003
스캔83 0.26 0.007 3.04 0.184 - - 155.34 1.286 0.19 0.005
스캔106 0.13 0.004 4.09 0.121 - - 46.40 0.902 0.11 0.003
스캔110 0.48 0.007 3.00 0.129 - - 66.78 0.983 0.13 0.004

표 2. 카메라 포즈 등록의 정량적 비교. (-)는 ZeroGS에 대해 보고되지 않은 결과와 CF-3DGS에 대해 실패한 장면을 나타냅니다.

geo = 2 입니다. 우리는 에피폴라 기하학적 구조가
긴장된 Lgeo는 초기 훈련 단계에서 중요한 역할을 합니다.
3DGS는 올바른 기하학을 확립하는 데 도움을 주며, 그 영향은 다음과 같습니다.
이후 단계에서는 중요성이 덜해집니다. 그리하여 우리는 부패한다
3,000회 반복 후 geo를 0으로 설정합니다. 이 전략은 꾸준히
모든 실험에 적용되었습니다. 우리의 훈련 절차
표준 3DGS 파이프라인[17, 22]을 따릅니다.
반복 샘플을 생성하고 단일 훈련 뷰를 렌더링합니다. 는
주요 차이점은 각 지점에서 Lgeo를 추가로 계산한다는 것입니다.
포즈를 통해 카메라 포즈 그라디언트를 단계적으로 전파합니다.
구체화 및 관련 카메라 잠재 코드. 모든 실험
단일 NVIDIA RTX 4090 GPU에서 수행됩니다.
24GB 메모리.

4.2. 이전 방법과의 비교

전체 비디오 시퀀스의 결과입니다. 우리는 우리의 방법을 평가합니다
4개의 최첨단 기준선에 대한 비교: 3DGS [22], Spann3R
[43], ZeroGS [7] 및 CF-3DGS [15]. 평가는
세 가지 표준 데이터 세트(탱크 및 사원)에서 수행되었습니다.
[25], Mip-NeRF360 [1] 및 DTU [18]. 3DGS의 경우, 우리는
gsplat 구현을 확인하세요 [53]. 공정한 거래를 보장하기 위해
parison, 동일한 카메라 포즈를 사용하도록 3DGS를 구성합니다.
MASt3R-SfM에서 획득하고 카메라 포즈 최적화를 활성화합니다.
gsplat [53]에서 지원하는 훈련 중 크기 조정. 이후
Spann3R은 다른 장면 표현을 사용합니다.
카메라를 사용한 3DGS 훈련을 위한 예상 카메라 포즈

최적화가 활성화되어 이전 제품과의 일관성을 유지했습니다.
주변 설정. 공개적으로 이용 가능하지 않은 ZeroGS의 경우
작성 시점에 코드를 작성할 수 있으면 결과를 직접 보고합니다.
그들의 종이에서. CF-3DGS 실험은 다음과 같이 수행됩니다.
세 가지 데이터 세트 모두에 걸쳐 공식 구현을 진행하고 있습니다.
표 1과 그림 4는 새로운 뷰 합성 재구성을 나타냅니다.
결과. 우리의 접근 방식은 탁월한 성능을 보여줍니다
세 가지 데이터 세트 모두에서 3DGS보다 훨씬 뛰어난 성능을 발휘했습니다.
동일한 MAsT3R-SfM 카메라 포즈를 사용합니다. 하는 동안

ZeroGS는 당사에 비해 약간 낮은 성능을 보여줍니다.
방법을 사용하면 CF-3DGS가 Mip-NeRF360에서 지속적으로 실패하고
탱크 및 사원 데이터세트. 이 실패의 원인은 다음과 같습니다.
점진적 훈련 중 초기 카메라 추적 손실
파이프라인, 대형 카메라가 있는 장면에서 특히 두드러짐
모션.
카메라 등록을 위해(표 2 및 그림 5), 우리의 방법은
카메라 포즈 최적화로 3DGS보다 훨씬 뛰어난 성능을 발휘합니다.
ZeroGS와 비슷한 결과를 보여줍니다. 는
한계차이(회전오차 0.02°, 회전오차 0.003m)
평균 ATE)는 특히 우리를 고려하면 무시할 수 있습니다.
우수한 신규 뷰 합성 결과. 게다가 Ze-
roGS는 다음과 같은 복잡한 2단계 교육 전략을 사용합니다.
고전적인 증분과 유사한 점진적인 이미지 정합
tal SfM, 우리의 접근 방식은 다음을 통해 경쟁력 있는 결과를 달성합니다.
표준 3DGS 교육을 향상시키는 더 간단한 프로세스입니다.
SfM 출력력을 수행하여 최소한의 계산 오버를 도입합니다.
머리.
짧은 비디오 클립에 대한 결과입니다. 우리는 또한 우리의 방법을 평가합니다
Tanks and Temples 데이터세트의 짧은 비디오 클립에서
CF-3DGS[15]의 실험 프로토콜을 따르고
전처리된 데이터를 사용합니다. 비교를 위해 선택합니다.
BARF[27], SC-NeRF를 포함한 최첨단 기준선
[19] 및 Nope-NeRF [3].
표 3과 표 4에 표시된 것처럼 우리의 접근 방식은 다음과 같습니다.
기존 방법에 비해 상당한 개선을 제시합니다.
새로운 뷰 합성과 카메라 포즈 추정이 모두 가능합니다. 에 대한

6

--- 페이지 7 ---

Ground Truth3DGSspann3R 당사CF-3DGS

Ground Truth3DGSspann3ROurs

그림 4. 새로운 뷰 합성 결과. CF-3DGS의 실패 장면과 ZeroGS의 보고되지 않은 결과는 생략합니다.

BARF SC-NeRF Nope-NeRF CF-3DGS OursScenes PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓
PSNR↑ SSIM↑ LPIPS↓ PSNR↑ SSIM↑ LPIPS↓

헛간 25.28 0.64 0.48 23.26 0.62 0.51 26.35 0.69 0.44 31.23 0.93 0.11 36.95 0.97 0.01

박물관23.58 0.61 0.55 24.94 0.69 0.45 26.77 0.76 0.35 29.91 0.91 0.11 35.78 0.97 0.01

이냐시오 21.78 0.47 0.60 23.00 0.55 0.53 23.96 0.61 0.47 28.43 0.90 0.09 31.16 0.93 0.03

표 3. 짧은 비디오 클립의 새로운 뷰 합성의 정량적 비교.

공정한 비교를 통해 우리는 다음의 평가 프로토콜을 따릅니다.

ATE(절대 궤적 오류)가 다음과 같은 이전 작업

100배로 크기가 조정되고 카메라 포즈가 정렬됩니다.

Ground Truth는 변환과 회전을 모두 사용하여 수행됩니다.

tion. 모든 정량적 결과는 공식을 사용하여 얻습니다.

[15]에서 제공하는 평가 코드입니다.

COLMAP과 비교. 두 탱크 모두

Temples 데이터세트와 MipNeRF360은 COLMAP을 사용합니다.

생성된 카메라는 일반 정보로 인해 Ground Truth로 포즈를 취합니다.

동맹국의 높은 정확도를 통해 우리는 특정 시나리오를 식별합니다.

COLMAP은 도전에 직면해 있습니다. 이를 입증하기 위해 우리는 다음을 평가합니다.

ScanNet [9] 데이터 세트에서 몇 가지 어려운 장면을 먹었습니다.

결과는 표 5에 제시되어 있습니다. 우리의 방법은

COLMAP에 비해 우수한 성능

전통적인 구조의 한계를 강조하는 장면-

까다로운 시나리오에서 모션 접근 방식을 사용합니다.

7

--- 페이지 8 ---

스판3R

스캔69

3DGS우리

이그나티우스 카운터룸가든

그림 5. 세 가지 최고 성능 방법에 대한 카메라 포즈 등록 시각화. ZeroGS 결과를 사용할 수 없습니다.

BARF SC-NeRF Nope-NeRF CF-3DGS Oursscenes RPEt ↓ RPEr ↓ ATE ↓ RPEt ↓ RPEr ↓ ATE ↓ RPEt ↓ RPEr ↓ ATE ↓ RPEt
↓ RPEr ↓ ATE ↓ RPEt ↓ RPEr ↓ ATE ↓

헛간 0.314 0.265 0.050 1.317 0.429 0.157 0.046 0.032 0.004 0.034 0.034 0.003 0.009 0.020 0.000

박물관 3.442 1.128 0.263 8.339 1.491 0.316 0.207 0.202 0.020 0.052 0.215 0.005 0.018 0.020 0.000

연회장 0.531 0.228 0.018 0.328 0.146 0.012 0.041 0.018 0.002 0.037 0.024 0.003 0.016 0.013 0.000

이그나티우스 0.736 0.324 0.029 0.533 0.240 0.085 0.026 0.005 0.002 0.033 0.032 0.005 0.010 0.012 0.001

표 4. 짧은 비디오 클립에 대한 카메라 포즈 등록의 정량적 비교.

콜맵 우리 것

포즈포즈썸

$R(^{\circ}) \downarrow$ ATE(m) $\downarrow$ PSNR $\uparrow$ $R(^{\circ}) \downarrow$ ATE(m) $\downarrow$ PSNR $\uparrow$

007900 3.55 0.014 30.78 2.45 0.014 32.58

030100 133.83 0.169 23.63 9.30 0.009 30.11

041800 5.03 0.012 29.03 4.34 0.012 31.62

표 5. ScanNet의 COLMAP과 비교.

configs	포즈	NVS3DGS	MCMCRMLP	Lgeo	R(°)↓	ATE(m)↓	PSNR↑	SSIM↑	LPIPS↓
					0.805	0.124	20.49	0.678	

0.255 0.783 0.032 21.94 0.724 0.222 0.353 0.025 23.61 0.803 0.193 0.195 0.015 24.02

0.820 0.183기하학적 구속만 있는 경우 0.430 0.038 21.94 0.731 0.239국소적인 기하학적 구속인 경우 0.458 0.034

21.97 0.736 0.228

표 6. 탱크 및 템플릿에 대한 절제 연구.

4.3. 절제 연구

구성요소별 분석. 우리의 방법은 세 가지로 구성됩니다

주요 구성 요소: 1) MCMC로서의 3DGS, 2) 렌더링이 필요 없음

전역 기하학적 제약, 3) 상관 모델링

글로벌 카메라 포즈 구체화. 각 구성 요소를 평가하려면

기여를 위해 우리는 Ta에 표시된 대로 절제 연구를 수행합니다.

6. 우리는 탱크와 템-의 장면을 평가합니다.

두 가지 모두에 대한 평균 측정항목을 보고하는 ples 데이터세트(표 1)

새로운 뷰 합성 및 카메라 포즈 추정. 다시

결과는 각 제품에서 상당한 개선을 보여줍니다.

구성요소. 기본 3DGS 방법에는 카메라가 포함되어 있지만

훈련 중 포즈 최적화(gsplat [53]에서 제공)

우리가 제안한 구성 요소가 없으면 그 효과가 제한됩니다.

넷. 표 1과 2에 대한 자세한 장면별 절제 결과

보충자료로 제공됩니다.

광도 및 기하학적 손실의 시너지 효과.

표 6은 기하학적 모델의 효율성을 검증합니다.

제약 조건 Lgeo, 우리는 사진의 역할을 더 조사합니다.

카메라 포즈 등록 및 NVS의 메트릭 렌더링. 우리

카메라 포즈 매개변수를 분리하여 실험을 수행합니다.

가우스 분할 중 에테르를 제거하여 기울기를 제거합니다.

카메라 매개변수에 대한 측광 렌더링. 추가 -

동맹국으로서 우리는 geo를 0으로 감소시키는 대신 상수를 유지합니다.

섹션 4.1에 설명된 대로 3000단계 이후. 결과는

표 6의 마지막에서 두 번째 행은 렌더링을 보여줍니다.

방정식의 손실. 3은 고품질 NVS와 정확도 모두에 중요합니다.

카메라 포즈 등록을 평가합니다. 최적의 성능은

렌더링의 시너지적 결합을 통해 달성

손실 및 기하학적 제약.

로컬 기하학적 구속조건에 비해 전역 구속조건인 장점

글로벌 기하학적 구성의 우수성을 입증하기 위해

로컬 대안에 대한 제약으로 인해 변형과 비교합니다.

대응을 위해 각 이미지 쌍을 무작위로 샘플링합니다.

모든 쌍 $(n, m) \in E$ 을 활용하는 대신 모든 단계에서. 는

표 6의 마지막 행에 표시된 결과는 로컬

기하학적 제약은 기존에 비해 최소한의 이점을 제공합니다.

글로벌 접근 방식을 통해 Lgeo의 효율성을 검증합니다.

5. 결론

우리는 캠 최적화를 위한 강력한 프레임워크인 3R-GS를 제시합니다.

불완전한 시대 포즈와 3D 가우스 표현

MASt3R-SfM 출력. 실험 결과는

우리의 3R-GS는 두 가지 새로운 분야에서 탁월한 성능을 달성했습니다.

뷰 합성 및 카메라 포즈 등록과 비교

사전 작업. 우리는 이것이 3R 기반 [26, 45]에 도움이 되기를 바랍니다.

--- 페이지 9 ---

3DGS를 사용한 방법 및 다운스트림 적용

커뮤니티. 가능한 미래의 작업은 확장을 탐구할 수 있습니다.

역동적인 장면을 처리하고 현실감을 지원하는 우리의 접근 방식
시간 응용 프로그램.

참고자료

[1] 조나단 T 배런, 벤 밀든홀, 도르 베르빈, 프라툴 P

스리니바산(Srinivasan), 피터 헤드먼(Peter Hedman). Mip-nerf 360: 무제한
앤티앨리어싱된 신경 방사 필드. 의 절차에서

컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스

인식, 페이지 5470-5479, 2022. 5, 6

[2] Jia-Wang Bian, Wenjing Bian, Victor Adrian Prisacariu 및

필립 토르. Porf: 정확한 신경 감시를 위한 포즈 잔류 필드

얼굴 재구성. arXiv 사전 인쇄 arXiv:2310.07449, 2023.

2, 3, 5

[3] Wenjing Bian, Zirui Wang, Kejie Li, Jia-Wang Bian 및

빅터 아드리안 프리사카리우. 너프 없음: 중립 최적화

사전 포즈가 없는 ral 라디언스 필드. 의 절차에서

컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스

인식, 페이지 4160-4169, 2023. 3, 5, 6

[4] Eric Brachmann, Jamie Wynn, Shuai Chen, Tommaso Cav-

allari, 'Aron Monszpart, Daniyar Turmukhambetov 및 Vic-

Adrian Prisacariu에게. 장면 좌표 재구성: Pos-

재배치의 증분 학습을 통한 이미지 수집

칼리라이저. 컴퓨터 비전에 관한 유럽 회의에서 페이지

421-440. 스프링어, 2024. 2, 3

[5] Shu Chen, Yang Zhang, Yaxin Xu 및 Beiji Zou. 구조-

에피플라 제약을 통해 포즈 카메라 없이 너프를 인식합니다.

arXiv 사전 인쇄 arXiv:2210.00183, 2022. 3, 5

[6] Yue Chen, Xingyu Chen, Xuan Wang, Qi Zhang, Yu Guo,

잉산(Ying Shan), 페이왕(Fei Wang). 로컬에서 글로벌로 등록

변들 조정 신경 복사 필드. 의 절차에서

컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스

인식, 페이지 8264-8273, 2023. 3

[7] 유 첸, 롤란도스 알렉산드로스 포타미아스, 에반젤로스

Ververas, Jifei Song, Jiankang Deng, 김희 이. 제-

rogs: 포즈가 지정되지 않은 이미지에서 3D 가우스 스플래팅을 훈련합니다.

arXiv 사전 인쇄 arXiv:2411.15779, 2024. 3, 6

[8] Shin-Fang Chng, Sameera Ramasinghe, Jamie Sherrah 및

사이먼 루시. 가우스 활성화 신경 방사 필드

고충실도 재구성 및 포즈 추정. 인유-

컴퓨터 비전에 관한 로페안 컨퍼런스, 264~280페이지.

스프링어, 2022. 3

[9] 안젤라 다이, 엔젤X장, 마놀리스 사바, 마시에 할-

베르, 토마스 핑크하우저, 마티아스 니스너. 스캔넷:

풍부한 주석이 달린 실내 장면의 3D 재구성. 에서

컴퓨터 비전 및 컴퓨터 비전에 관한 IEEE 회의 진행

- 패턴 인식, 5828~5839페이지, 2017. 7
- [10] 프랑크 오이 Darmon, Lorenzo Porzi, Samuel Rota-Bulo 및 피터 콘치더. 강력한 가우스 스피래팅. arXiv 사전 인쇄 arXiv:2404.04211, 2024. 3
- [11] Xiaobiao Du, Yida Wang, Xin Yu. Mvgs: 멀티뷰-새로운 뷰 합성을 위해 규제된 가우스 스피래팅. arXiv 사전 인쇄 arXiv:2410.02103, 2024. 4
- [12] Bardienus Duisterhof, Lojze Zust, Philippe Weinzaepfel, 뱅상 르로이, 요한 카봉, 제롬 레보. Mast3r-sfm: 제약 없는 구조를 위한 완전히 통합된 솔루션-모션에서. arXiv 사전 인쇄 arXiv:2409.19152, 2024. 1, 2, 3, 5
- [13] Sven Elflein, Qunjie Zhou, Sergio Agostinho 및 Laura Leal-Taix'e. Light3r-sfm: 피드포워드 구조를 향하여-모션에서. arXiv 사전 인쇄 arXiv:2501.14914, 2025. 1
- [14] Zhiwen Fan, Wenyan Cong, Kairun Wen, Kevin Wang, Jian Zhang, Xinghao Ding, Danfei Xu, 보리스 이바노비치, Marco Pavone, Georgios Pavlakos 등. Instantsplat: Under 40초 안에 제한된 희소 뷰 포즈 없는 가우스 스피래팅-onds. arXiv 사전 인쇄 arXiv:2403.20309, 2(3):4, 2024. 3
- [15] 양푸, Sifei Liu, Amey Kulkarni, Jan Kautz, Alexei A 에프로스과 왕샤오롱. Colmap이 없는 3D 가우스 표시팅. IEEE/CVF 통신 회의 진행 중
- 퓨터 비전 및 패턴 인식, 페이지 20796-20805, 2024. 3, 5, 6, 7
- [16] Xiang Guo, Bo Li, Yuchao Dai, Tongxin Zhang 및 Hui Deng. 6-dof 카메라 포즈만으로 새로운 뷰 합성 2단계 네트워크로. 2020년 제25차 국제대회에서는 패턴 인식(ICPR)에 대한 참조, 5028~5035페이지. IEEE, 2021. 3
- [17] Binbin Huang, Zehao Yu, Anpei Chen, Andreas Geiger 및 가오 성화. 기하학적 AC를 위한 2D 가우스 스피래팅 큐레이트 래디언스 필드. ACM SIGGRAPH 2024 컨퍼런스에서 논문, 2024년 1~11페이지. 3, 5, 6
- [18] Rasmus Jensen, Anders Dahl, George Vogiatis, Engin Tola, 그리고 헨리크 아나이스(Henrik Aanæs). 대규모 다시점 입체시 평가 유에이션. 컴퓨터에 관한 IEEE 회의 진행 중
- 시각 및 패턴 인식, 406~413페이지, 2014. 5, 6
- [19] 정윤우, 안석준, 크리스토퍼 초이, 애니마 Anandkumar, 조민수, 박재식. 자가 교정 신경 방사 필드. IEEE/CVF 절차에서 컴퓨터 비전에 관한 국제 회의, 5846페이지 - 5854, 2021. 3, 6
- [20] Yingwenqi Jiang, Jiadong Tu, Yuan Liu, Xifeng Gao, Xiaoxiao Long, Wenping Wang, Yuexin Ma. 가우스-셰이더: 재조정을 위한 셰이딩 기능을 갖춘 3D 가우스 스피래팅 반사 표면. IEEE/CVF 회의 진행 중-

컴퓨터 비전 및 패턴 인식에 대한 내용, 페이지

5322-5332, 2024. 3

[21] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler,
그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅

래디언스 필드 렌더링. ACM 트랜스. 그래프., 42(4):139-1,
2023. 3

[22] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler,
그리고 조지 드레타키스. 실시간 3D 가우스 스피래팅

래디언스 필드 렌더링. 그래픽의 ACM 트랜잭션, 42
(4), 2023. 1, 5, 6

[23] 베른하르트 케르블, 안드레아스 뮐레만, 게오르기오스 코파나스,
마이클 위머, 알렉상드르 랑방, 조지 드레타키스.

실시간 렌더링을 위한 계층적 3D 가우스 표현

매우 큰 데이터셋을 처리합니다. 그래픽의 ACM 트랜잭션
(TOG), 43(4):1-15, 2024. 3

[24] 샤키바 케라드만드, 다니엘 레베인, 고팔 샤르마, 웨이-
웨이 순, 양체 첵, 호삼 이삭, 아비섹 카르,

안드레아 탈리아사키, 이광무. 3d 가우스 표시

마르코프 체인 몬테카를로처럼요. 신경 내부의 발전

9

--- 페이지 10 ---

형성 처리 시스템, 37:80965-80986, 2025. 2, 4,
5

[25] 아르노 크나피치(Arno Knapitsch), 박재식, 저우첸이(Qian-Yi Zhou), 블라들렌(Vladlen)
콜툰. 탱크와 사원: 대규모 장면 벤치마킹

재건축. 그래픽에 대한 ACM 트랜잭션(ToG) , 36
(4):1~13, 2017. 5, 6

[26] Vincent Leroy, Yohann Cabon 및 J'erreome Revaud. 지상-
mast3r을 사용하여 3D 이미지 매칭을 수행합니다. 유럽 회의에서-

컴퓨터 비전에 대한 내용, 71~91페이지. 스프링어, 2024. 8

[27] Chen-Hsuan Lin, Wei-Chiu Ma, Antonio Torralba 및 Si-
먼 루시. Barf: 번들 조정 신경 복사 필드.

IEEE/CVF 국제 회의 진행 중

컴퓨터 비전, 페이지 5741-5751, 2021. 3, 5, 6

[28] Philipp Lindenberger, Paul-Edouard Sarlin, Marc Polle-
페이. Lightglue: 빛의 속도로 로컬 기능을 일치시킵니다. 에서

IEEE/CVF 국제 컨퍼런스 진행

컴퓨터 비전, 17627~17638페이지, 2023. 2

[29] Yang Liu, Chuanchen Luo, Lue Fan, Naiyan Wang, Jun-
Peng과 Zhaoxiang Zhang을 운영했습니다. 시티가우시안: 실시간

가우스를 사용한 고품질 대규모 장면 렌더링. 에서

컴퓨터 비전에 관한 유럽 회의, 265~282페이지.

스프링어, 2024. 3

[30] Yuanxun Lu, Jingyang Zhang, Tian Fang, Jean-Daniel Nah-
mias, Yanghai Tsin, Long Quan, Xun Cao, Yao Yao 및 Shi-

웨이 리. Matrix3d: 대형 사진 측량 모델 올인원.

arXiv 사전 인쇄 arXiv:2502.07685, 2025. 3

[31] 마츠키 히데노부, 무라이 리쿠, 폴 HJ 켈리, 안-
J 데이비슨을 그렸습니다. 가우스 스피래팅 슬램. 절차 중
컴퓨터 비전 및 특허에 관한 IEEE/CVF 회의-
tern Recognition, 페이지 18039-18048, 2024. 5

[32] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik,
조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프:
뷰 동기화를 위해 장면을 신경 방사 필드로 표현
논문. ACM 커뮤니케이션, 65(1):99-106, 2021. 1,
3

[33] Linfei Pan, D 'aniel Bar'ath, Marc Pollefeys, Johannes L
Sch onberger. 모션에서 글로벌 구조를 재검토했습니다. 에서
컴퓨터 비전에 관한 유럽 회의, 58~77페이지.
스프링어, 2024. 4

[34] Guilherme Potje, Felipe Cadar, Andr 'e Araujo, Renato Mar-
통 및 Erickson R Nascimento. Xfeat: 가속 기능
경량 이미지 매칭을 위한 기능입니다. 의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
인식, 페이지 2682-2691, 2024. 2

[35] Kerui Ren, Lihan Jiang, Tao Lu, Mulin Yu, Linning Xu,
장카이니(Zhangkai Ni), 보다이(Bo Dai). Octree-gs: 일관성을 향하여
로드 구조의 3D 가우스를 사용한 실시간 렌더링. arXiv
사전 인쇄 arXiv:2403.17898, 2024. 3

[36] Samuel Rota Bul o, Lorenzo Porzi, Peter Kotschieder.
가우스 스피래팅의 치밀화 수정. 유럽에서는
컴퓨터 비전 컨퍼런스, 347~362페이지. 스프링거,
2024. 4

[37] 폴 에두아르 살린(Paul-Edouard Sarlin), 다니엘 디톤(Daniel DeTone), 토마스 말리시비츠(Tomasz Malisiewicz),
앤드류 라비노비치. Superglue: 학습 기능
그래프 신경망과 일치합니다. 의 절차에서
컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
표창, 페이지 4938-4947, 2020. 2

[38] Johannes L Schonberger 및 Jan-Michael Frahm. 구조-
모션에서 재검토되었습니다. IEEE 회의 진행 중
컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지
4104-4113, 2016. 1, 2, 3

[39] Wei Sun, Xiaosong Zhang, Fang Wan, Yanzhao Zhou, Yuan
리(Li), 예치상(Qixiang Ye), 지안빈 자오(Jianbin Jiao). 대응 안내

nvs를 위한 sfm-free 3d 가우스 스피래팅. arXiv 사전 인쇄
arXiv:2408.08723, 2024. 3

[40] Jiaxiang Tang, Zhaoxi Chen, Xiaokang Chen, Tengfei Wang,
강 쟁(Gang Zeng), 류즈웨이(Ziwei Liu). Lgm: 대형 다중 뷰 가우스
고해상도 3D 콘텐츠 제작을 위한 모델입니다. 유럽에서는
컴퓨터 비전 컨퍼런스, 1~18페이지. 스프링거, 2024년.
3

- [41] 자두 Truong, Marie-Julie Rakotosaona, Fabian Manhardt, 그리고 페데리코 톰바리. Sparf: 신경 복사장 희박하고 시끄러운 포즈. IEEE/CVF 절차에서 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 4190-4200, 2023. 3, 5
- [42] Michał Tyszkiewicz, Pascal Fua 및 Eduard Trulls. 디스크: 정책 그래데이션을 사용하여 로컬 기능을 학습합니다. 진출 신경정보처리시스템, 33:14254-14265, 2020. 2
- [43] 왕형이(Hengyi Wang)와 루르드 아가피토(Lourdes Agapito). 3D 재구성 공간 기억. arXiv 사전 인쇄 arXiv:2408.16061, 2024. 2, 6
- [44] Qianqian Wang, Yifei Zhang, Aleksander Holynski, 알렉세이 A 에프로스, 가나자와 양주. 연속적인 3D 지속적인 상태를 갖는 인식 모델. arXiv 사전 인쇄 arXiv:2501.12387, 2025. 2
- [45] 왕 슈저, 빈센트 르로이, 요한 카본, 보리스 Chidlovskii, 제롬 레보(Jerome Revaud). Dust3r: 기하학적인 3D 영상 시운이 쉬워졌습니다. IEEE/CVF 컨퍼런스 진행 중 컴퓨터 비전 및 패턴 인식, 20697페이지 - 20709, 2024. 1, 2, 3, 8
- [46] Zhou Wang, Alan C Bovik, Hamid R Sheikh 및 Eero P Simoncelli. 이미지 품질 평가: 오류 가시성부터 구조적 유사성. 이미지 처리에 대한 IEEE 트랜잭션, 13(4):600-612, 2004. 5
- [47] Zirui Wang, Shangzhe Wu, Weidi Xie, Min Chen 및 Vic-Adrian Prisacariu에게. Nerf: 다음을 포함한 신경 복사장 알려진 카메라 매개변수. arXiv 전자 인쇄물, 페이지 arXiv-2102, 2021. 3
- [48] Yitong Xia, Hao Tang, Radu Timofte 및 Luc Van Gool. Sinerf: 관절 포즈를 위한 정현파 신경 방사 필드 추정 및 장면 재구성. arXiv 사전 인쇄 arXiv:2210.04553, 2022. 3
- [49] Yinghao Xu, Zifan Shi, Wang Yifan, Hansheng Chen, Ceyuan Yang, Sida Peng, Yujun Shen, Gordon Wetstein. Grm: ef-에 대한 대형 가우스 재구성 모델 가상의 3D 재구성 및 생성. 유럽연합에서는 컴퓨터 비전에 대한 참조, 1~20페이지. 스프링거, 2024. 3
- [50] Yan Yunzhi, Haotong Lin, Chenxu Zhou, Weijie Wang, Haiyang Sun, Kun Zhan, Xianpeng Lang, Xiaowei Zhou, 그리고 평 시다. 거리 가우스: 역동적인 도시 모델링 가우스 스피래팅이 포함된 장면. 유럽회의에서 컴퓨터 비전, 156~173페이지. 스프링거, 2024. 3
- [51] 양 지아닝, 알렉산더 색스, 케빈 J 리앙, 미카엘 헤나프, Hao Tang, Ang Cao, Joyce Chai, Franziska Meier 및 Matt

--- 페이지 11 ---

Feiszli. Fast3r: 1000개 이상의 이미지를 3D로 재구성하기 위해 한 번의 전달로. arXiv 사전 인쇄 arXiv:2501.13928, 2025.

1

[52] 예예양(Keyang Ye), 허우치밍(Qiming Hou), 쿤저우(Kun Zhou). 3d 가우스 표시 지연된 반성을 가지고 있습니다. InACM SIGGRAPH 2024 콘-참고 논문, 2024년 1~10페이지. 3

[53] Vickie Ye, Ruilong Li, 저스틴 커, Matias Turkulainen, 브렌트 이, Zhuoyang Pan, Otto Seiskari, Jianbo Ye, Jeffrey Hu, Matthew Tancik, Angjoo Kanazawa. gsplat: 안 Gaussian splatting을 위한 오픈 소스 라이브러리입니다. arXiv 사전 인쇄 arXiv:2409.06765, 2024. 5, 6, 8

[54] 린 엔첸, 피트 플로렌스, 조나단 T 배런, 알베르토 로드리게스, 필립 이슬라, 그리고 Tsung-Yi Lin. inerf: 반전 자세 추정을 위한 신경 방사 필드. 2021년 IEEE/RSJ 지능형 로봇 및 시스템에 관한 국제 컨퍼런스 (IROS), 1323~1330페이지. IEEE, 2021. 3

[55] Mulin Yu, Tao Lu, Linning Xu, Lihan Jiang, Yuanbo Xiangli, 그리고 보다이. Gsdf: 3dgs와 sdf의 만남으로 신경 재생 개선 데링과 재건축. 신경 정보의 발전 처리 시스템, 37:129507-129530, 2025. 3

[56] Zehao Yu, Torsten Sattler 및 Andreas Geiger. 가우스 불투명 필드: 효율적인 적응형 표면 재구성 무한한 장면. TOG(그래픽 기반 ACM 트랜잭션), 43(6):1-13, 2024.

[57] Baowen Zhang, Chuan Fang, Rakesh Shrestha, Yixun Liang, 샤오샤오 룡, 핑 탄. Rade-gs: 깊이 래스터화

가우스 스피래팅. arXiv 사전 인쇄 arXiv:2406.01467, 2024.

3

[58] Kai Zhang, Sai Bi, Hao Tan, Yuanbo Xiangli, Nanxuan Zhao, Kalyan Sunkavalli 및 Zexiang Xu. Gs-Irm: 대규모 정찰 3D 가우스 스피래팅을 위한 구조 모델. 유럽연합에서는 컴퓨터 비전에 대한 참조, 1~19페이지. 스프링거, 2024. 3

[59] 리처드 장, 필립 이슬라, 알렉세이 A 에프로스, 엘리 세흐트-남자, 그리고 올리버 왕. 불합리한 효율성 지각 지표로서의 심층 기능. 절차에서 컴퓨터 비전 및 패턴 인식에 관한 IEEE 컨퍼런스 섹션, 586~595페이지, 2018. 5

[60] Youjia Zhang, Anpei Chen, Yumin Wan, Zikai Song, Jun-칭 유, 아웨이 루오, 웨이 양. Ref-gs: 직접-2D 가우스 스피래팅을 위한 인수분해. arXiv 사전 인쇄 arXiv:2412.00905, 2024. 3

[61] Lingzhe Zhao, Peng Wang 및 Peidong Liu. 불량 가우스: 조정된 디블러 가우스 스피래팅을 번들로 묶습니다. 인유럽콘-컴퓨터 비전에 대한 참조, 233~250페이지. 스프링거, 2024년.

3

[62] 주샤오유, 린지웨이, 산샤오준, 왕용타오,

Deqing Sun, Ming-Hsuan Yang. 드라이빙가우시안:
주변 동적 오디오를 위한 복합 가우스 스플래팅
음란한 운전 장면. IEEE/CVF 절차에서
컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스,
페이지 21634-21643, 2024. 3
11

[논문 16] UGS-Loc 본문 전체 번역

--- 페이지 1 ---

포즈 이전 및 아래의 3D 가우스 스플래팅에서 포즈 개선에 대한 재고

기하학적 불확실성

공만규¹ 이재원¹ 이성원²

김은태^{1,3*}

¹연세대 ²국민대학교 ³한국과학기술원

초록

최근 3DGS(3D Gaussian Splatting)가 등장했습니다.

강력한 장면 표현이며 점점 더 많이 사용되고 있습니다.

시각적 현지화 및 포즈 개선을 위해. 그러나, 드-

고품질의 차별화 가능한 렌더링에도 불구하고 견고함

3DGS 기반 포즈 개선의 기술은 여전히 매우 민감합니다.

초기 카메라 포즈와 재구성된 포즈 모두에 효과적입니다.

기하학. 이번 연구에서는 이러한 한계에 대해 자세히 살펴보겠습니다.

불확실성의 두 가지 주요 원인을 식별하고 다음을 수행합니다. (i) 포즈

회귀나 회귀로 인해 종종 발생하는 사전 불확실성

단일 결정론적 추정치를 출력하는 삼중 모델

(ii) 불완전성으로 인한 기하학적 불확실성

PnP에 오류를 전파하는 3DGS 재구성

해결사. 이러한 불확실성은 재투영 기하구조를 왜곡할 수 있습니다.

렌더링된 앱이 있더라도 최적화를 시도하고 불안정하게 만드세요.

피어런스는 여전히 그럴듯해 보인다. 이러한 불확실한 문제를 해결하기 위해

우리는 다음을 결합한 재지역화 프레임워크를 소개합니다.

Fisher Information 기반의 Monte Carlo 포즈 샘플링

PnP 최적화. 우리의 방법은 두 가지 모두를 명시적으로 설명합니다.

포즈와 기하학적 불확실성이 있으며 재교육이 필요하지 않습니다.

또는 추가적인 감독이 필요합니다. 다양한 실내와

야외 벤치마크를 통해 우리의 접근 방식은 지속적으로 개선되었습니다.

위치 파악 정확도가 향상되고 안정성이 크게 향상됩니다.

포즈와 깊이 노이즈가 있는 경우. 우리의 코드는 다음에서 사용할 수 있습니다.

프로젝트 웹사이트.

1. 소개

시각적 위치 파악은 6-DoF 카메라 자세를 추정하는 것을 목표로 합니다.

알려진 장면 내에서 쿼리 이미지를 추출하고 키를 재생합니다.

AR/VR, 자율주행, 로봇공학 분야의 역할. 메인

현지화 방법의 성능을 좌우하는 요소

장면이 표현되는 방식입니다. 전통적인 구조 기반

파이프라인은 다음을 통해 재구성된 희박한 3D 포인트 클라우드에 의존합니다.

동작으로부터의 구조 [44, 46]. 추출된 지역 특징

쿼리 이미지의 참조 이미지와 일치하거나

3D 점 [11, 41, 45] 및 결과 대응

*교신저자.

: 카메라 샘플링 : 불확실성 PnP

: 초기 포즈

: 가설 포즈 : 세련된 포즈

그림 1.UGS-Loc. 제안된 프레임워크는 카메라 포즈를 개선합니다.
 몬테카를로 샘플링을 통해 포즈 사전 불확실성을 통합함으로써
 불확실성 필드를 통한 기하학적 불확실성, 견고한 달성
 재교육 없이 현지화.
 PnP 알고리즘을 통해 카메라 포즈를 추정하는 데 사용됩니다.
 리듬 [12, 13, 25]. 장면 좌표 회귀(SCR)
 접근 방식 [3-5]은 밀집된 예측을 통해 이 패러다임을 확장합니다.
 장면 좌표 및 APR(절대 포즈 회귀)
 방법 [6, 8, 19, 28, 48] 이미지를 직접 매핑하는 방법을 배웁니다.
 포즈를 취하다. 이러한 접근 방식은 지도의 발전이 어떻게 이루어지는지 보여줍니다.
 희소 기하학적 지도에서 암시적 표현까지
 학습된 좌표 또는 포즈 모델을 계속해서 형성합니다.
 현지화 시스템 설계.
 최근에는 다음과 같은 신경 장면 표현이
 NeRF[38]와 3DGS[20]는 새로운 유형의
 장면 표현, 그리고 그것이 개발을 촉발시켰습니다.
 새로운 포즈 개선 방법. 이러한 방법은 다음과 같습니다.
 렌더링 및 비교로 요약됩니다. 그들은 먼저 렌더링
 다시 얻은 초기 포즈의 합성 뷰
 retrieval [1, 24], APR 또는 SCR을 선택한 다음 이 뷰를
 광도 손실 [30, 53, 64] 또는 기능을 사용하여 이미지 쿼리
 거리 [7, 33, 56]. 보다 최근의 방법 [17, 28, 32]
 이 아이디어를 확장하면 밀도가 높은 2D-2D 대응을 찾습니다.
 쿼리와 렌더링된 뷰 사이의 밀도 [26, 52]
 arXiv:2603.16538v1 [cs.CV] 2026년 3월 17일

--- 페이지 2 ---

잘못된 대응
 잘못된 기하학
 혼란
 피쳐 정보
 서신 발견!
 중요도 샘플링
 포즈 추정기
 포즈 추정기(a) 기존 3DGS 기반 포즈 개선 방법
 집중할 곳!
 높음
 낮음

(a) 3DGS 기반 포즈 개선이미지 쿼리잘못된 포즈 이전 렌더링된 이미지렌더링된 깊이이미지 쿼리잘못된 포즈 이전렌더링된
 이미지렌더링된 깊이3D 가우스 스피래팅불확실성 필드기하학적 불확실성3D 가우스 스피래팅
 그림 2. 이전 3DGS 기반 포즈 개선과 제안된 UGS-Loc의 비교.(a) 기존 파이프라인은
 렌더링된 깊이를 사용하기 전에 단일 결정론적 포즈를 취하므로 부정확한 사전 및 기하학적 오류에 취약해집니다.
 잘못된 대응과 불안정한 세련미. (b) 우리의 방법은 대신 Monte Carlo 포즈 샘플링과 기하학적 불확실성을 적용합니다.
 Fisher Information은 서신을 안내하고 신뢰할 수 있는 지역에 초점을 맞춰 개선하여 열악한 상황에서도 강력한 자세 추정을
 달성합니다.
 사전과 불확실한 기하학을 제시합니다.

렌더링된 깊이를 사용하여 이러한 일치 항목을 3D로 끌어 올리고 해결합니다.
 PnP-RANSAC을 사용한 포즈. 이 서신 중심의
 이제 렌더링 및 비교 버전이 포즈 개선을 주도합니다.
 최첨단 재위치 정확도를 달성합니다.
 렌더링 기반 포즈 개선. 하지만 포즈를 취할 때
 3DGS에 정제 방법을 적용하면
 기존 포즈 개선 방법은 몇 가지 사항을 간과하고 있습니다.
 일부 성능이 저하될 수 있습니다.
 3D Gaussian Splatting은 명시적 요소를 사용하여 형상을 모델화합니다.
 립티컬 프리미티브이지만 프리미티브는 근사치일 뿐입니다.
 그리고 그들이 렌더링하는 깊이는 균일하게 신뢰할 수 없습니다. 지역
 희박한 훈련 뷰[61]로부터 재구성되거나 오염된
 동적 개체에 의해 명명된 [21]은 종종 눈에 띄는 배열을 나타냅니다.
 기하학적 정확도의 공간적 변화로 이어지는 사실.
 이러한 공간적 변화에도 불구하고 현재의 개선 방법은
 ods는 다음과 같은 경우 렌더링된 모든 깊이를 동등하게 신뢰할 수 있는 것으로 간주합니다.
 2D-2D 대응을 3D로 끌어올리는 것입니다. 그 결과 그들은
 재구성 충실도가 크게 달라질 수 있다는 사실을 무시하십시오.
 장면의 여러 부분을 간신히 가로지릅니다.
 이러한 과제는 다음과 같은 경우 더욱 두드러집니다.
 사전에 정확한 자세에 대한 의존성을 고려합니다. 이후
 3DGS 기반 개선 [17, 28, 32]은 렌더링을 통해 작동합니다.
 단일 초기 추정으로 얻은 종합적인 견해, 품질
 대응의 정도는 이 포즈가 얼마나 잘 정렬되어 있는지에 달려 있습니다.
 실제 장면 콘텐츠로. 이전 포즈가 편향되거나
 인공물에 의해 가려지면 렌더링된 시점이 나타날 수 있습니다.
 가시성이 제한되어 기능 일치자 [11, 26, 52]가
 신뢰할 수 있는 서신을 구축하기 위해 노력합니다.
 이러한 문제를 해결하기 위해 우리는 UGS-Loc을 제안합니다.
 불확실성 인식 자세 개선 프레임워크
 3D 가우스 스플래팅. UGS-Loc은 이전의 포즈를 나타냅니다.
 배포판으로 몬테카를로 샘플을 통해 탐색합니다.
 Pling을 통해 개선 파이프라인이
 초기 자세가 신뢰할 수 있는 영역에서 멀리 떨어져 있는 경우
 장면. 동시에, 우리는 기하학적 불확실성을 정량화합니다.
 Fisher Informa를 통해 가우스 매개변수에서 직접
 tion [18]을 수행하고 이 신호를 PnP-RANSAC에 통합합니다.
 프로세스를 통해 서신 샘플링을 지리적으로 안내합니다.
 측정적으로 신뢰할 수 있는 지역. 공동모델 포즈로
 3DGS, UGS-Loc에 내재된 기하학적 불확실성
 안정적인 교육이 필요 없는 강력한 현지화를 달성합니다.
 까다로운 현장 조건에서도 일관되고 일관됩니다.

2. 관련 저작물

시각적 현지화. 시각적 현지화 작업은 다음과 같습니다.
 재와 관련된 쿼리 이미지의 포즈를 결정합니다.
 3D 장면을 구축했습니다. 일반적으로 사용되는 사전 구축된 표현은
 장면의 표현은 다음을 통해 재구성된 3D 포인트 클라우드입니다.

동작으로부터의 구조(SfM) [67]. 이 안의 각 3D 포인트 클라우드는 다음의 시각적 설명자 세트와 연관되어 있습니다. 데이터베이스 이미지를 통해 시스템의 신뢰성을 확보할 수 있습니다. 현지화 중 2D-3D 대응. 이미지 쿼리 쿼리 이미지와 3D 간의 키포인트가 일치합니다. 2D-3D 대응을 확립하기 위한 모델 [11, 44, 45, 54]. 장면 좌표 회귀(SCR) 방법 [4, 5, 58] 열차 2D-3D 통신을 직접 획득하는 네트워크입니다. 두 방법 모두에서 얻은 대응 관계는 다음과 같습니다. 카메라 포즈를 추정하기 위해 PnP 솔버에 입력됩니다. 대체-

실제로 절대 자세 회귀(APR)[19, 48]는 다음을 예측합니다. 쿼리 이미지에서 직접 6-DoF 카메라 포즈를 통해 신경망. 그러나 이러한 접근 방식은 종종 어려움을 겪습니다. 제한된 포즈 정확도로 인해. 우리의 방법은 포즈를 개선합니다 3D Gaussian을 이용한 SCR, APR 방법으로 추정 추가 교육이 필요 없이 스플래팅(3DGS)이 가능합니다. Radiance 필드 기반 시각적 위치 파악. 전통의 희박함과 제한된 표현력 3D 포인트 클라우드 표현, 최근 연구 연구 vi-radiance field와 같은 조밀한 장면 표현 동시 현지화. 강력한 신규 뷰 싱크를 활용하여

--- 페이지 3 ---

NeRF(Neural Radiance Fields)의 논문 기능 [38] 및 Gaussian Splatting(3DGS)[20]과 같은 방법을 사용합니다. 포즈 개선과 데이터 모드를 위한 사실적인 렌더링 증강. 예를 들어, 라디언스 필드 기반 증강은 tation은 다음을 생성하여 APR 프레임워크[6, 28, 39]를 강화합니다. 다양한 관점과 조명에 걸친 종합적인 트레이닝 뷰 조건을 적용하여 견고성과 일반화를 개선합니다. 보이지 않는 도메인. 지배적인 연구 계열은 렌더링 및 초기 카메라 포즈가 반복되는 비교 전략 불일치를 최소화하여 효과적으로 개선되었습니다. 예상 결과에서 렌더링된 쿼리 이미지 및 새로운 보기 포즈. iNeRF [64]는 최적화를 통해 이 패러다임을 개척했습니다. NeRF의 역 렌더링을 통해 직접 카메라 포즈를 취합니다. 다음 작품에 영감을 불어넣었습니다 [30, 53]. 이러한 접근법 측광 [2] 또는 기능을 사용하여 직접 포즈를 최적화합니다. 공간 정렬 [7]은 위치 파악 정확도를 향상시킵니다. 에서 병렬, 대응 기반 파이프라인이 등장했습니다. 강력한 대안. CROSSFIRE [40]는 특수 기능을 통합합니다. 신경 장면 표현에 맞춰진 특징 설명자 정확한 2D-3D 대응 구축이 가능합니다. 자세 추정을 위해 PnP-RANSAC이 뒤따릅니다. 이 디자인 [34, 51, 66, 68]은 위치 파악 능력을 크게 향상시킵니다.

밀접하게 일치하는 기능을 활용하여 정확성을 높입니다.
 기본 복사 필드.
 장면별 설명어 학습을 넘어 GS-
 CPR[32]은 더 간단하고 효율적인 전략을 채택합니다.
 APR 또는 SCR 이전 포즈를 사용하여 고품질 렌더링
 합성 뷰는 직접 2D-2D 매칭을 수행합니다.
 쿼리, 렌더링된 깊이를 통해 서신을 3D로 끌어올리고,
 PnP 최적화를 통해 포즈를 다듬습니다. 유사한
 2D-2D 대응 중심의 개선 파이프라인도
 최근 여러 3DGS 기반 위치 파악 방법에 사용되었습니다.
 ods [17, 28], 여기서 각 방법으로 예측된 대략적인 포즈
 초기 포즈 역할을 합니다. 그 단순성과 효율성은
 이 서신 기반 개선 파이프라인은 널리
 3DGS 기반 포즈 개선을 위해 기준선을 사용했습니다. 그러나,
 이러한 개선 기반 접근 방식은 여전히
 정확한 포즈 사전 또는 잘 재구성된 장면 기하학,
 불확실성과 기하학에 취약하게 만듭니다.
 실제 시나리오의 불일치. 이번 작품에서 우리는
 현지화를 도입하여 이러한 제한 사항을 해결합니다.
 이전과 미래의 불확실성을 처리하는 프레임워크
 장면 기하학.
 Radiance Fields.Re-의 불확실성 정량화
 센트 연구[16, 18, 62, 63, 65]에서는 다양한 제안을 했습니다.
 Radiance Fields 내의 불확실성을 정량화하는 전략.
 NeRF 기반 방법 [23, 62, 65]은 신뢰성을 추정합니다.
 불확실성을 모델링하여 장면 재구성의 정확성
 일반적으로 광선별 밀도 분포를 통해 캐스팅된 광선
 tions. 소수점 불확실성 추정 방법 [49, 63]
 변이 추론을 사용하여 인식론적 불확실성을 모델화합니다.
 Bayes' Rays [16]는 다음을 적용하여 공간적 불확실성을 추정합니다.
 공간 그리드에 대한 섭동 필드 및 보간
 쿼리 포인트의 확실성. 마찬가지로 FisherRF [18]는 다음을 계산합니다.
 시야 측정을 위한 NeRF 및 3DGS를 통한 Fisher 정보
 의존적 불확실성.
 그러나 이러한 불확실성 정량화 접근법은
 주로 장면 재구성을 개선하기 위해 설계되었습니다.
 이상치[16, 21, 37]와 산만한 요인을 필터링하여
 또는 활성 매핑 [23, 65] 및 다음 뷰 설정을 안내하여
 보다는 자율적인 재건을 위한 선택 [18, 43]
 카메라 위치 파악의 불확실성을 해결합니다. 더욱이,
 대부분의 공식은 쿼리 포인트 표현에 의존하기 때문입니다.
 NeRF [38]에 내재된 문장은 직접적으로 언급되지 않습니다.
 3D Gaussian과 같은 최근 명시적 모델과 호환 가능
 스플래팅 [20]. 대조적으로, 우리의 작업은 지리학적인 방법을 조사합니다.
 미터법 및 포즈 불확실성이 함께 현지화 신뢰도에 영향을 미칩니다.
 능력을 갖추고 확률적 개선 프레임워크를 도입합니다.

이는 이러한 불확실성을 lo -에 명시적으로 통합합니다.
칼리화 과정.

3. 방법

3.1. 개요

3DGS의 포즈 개선. 이 작업에서 우리는 다음을 고려합니다.

3DGS 및 프로에서 카메라 포즈 개선의 불확실성

그림과 같이 확률론적 포즈 개선 프레임워크를 제시합니다.

Gaussian Splat을 활용한 자세 개선

ting [17, 28, 32]은 일반적으로 결정론적 파이프라인에 의존합니다.

포즈 추정 모듈이 사전에 포즈를 예측하는 경우

$T_{prior} = [R_i, t_i] \in SE(3)$, 이는 다음을 통해 정제됩니다.

가우스 스플래팅G. 이러한 파이프라인에서는 렌더링된 이미지가

이전 추정 포즈 T 의 age_i r 과 쿼리 $image_i$ q 는 다음과 같습니다.

그런 다음 레버를 사용하여 2D-2D 대응 $C_{q,r}$ 을 추출하는 데 사용됩니다.

MASt3r [26]과 같은 노화된 2D 매칭 모듈 및

LoFTR [52]. 이러한 2D-2D 픽셀 대응 $C_{q,r} =$

$\{(q_i, r_i)\}$ 는 이후 2D-3D 대응으로 확장됩니다.

$dencesC = \{(q_i, X_i)\}$ 렌더링된 깊이 맵 사용 D_r

카메라 내장 기능K:

$z_i = D_r(r_i), X_i = T$ 이전

$z_i^{K-1} \sim r_i$

, (1)

여기서 $\sim r_i = [u_i, v_i, 1]^T, r_i = (u_i, v_i)$ 는 픽셀을 나타냅니다.

렌더링된 이미지에서 마지막으로 이전 포즈는 다시

PnP-RANSAC 솔버[12, 13, 25]를 사용하여 벌금을 부과하여 예측

카메라 포즈가 세련됐어요.

Pose Prior Uncertainty. 3DGS 기반 포즈 개선

파이프라인에는 추가 교육이 필요하지 않으며 둘 다

간단하고 효율적이어서 많은 분야에서 채택되고 있습니다.

센트가 작동합니다. 그러나 이 파이프라인은 두 가지 주요 가정을 합니다.

tions: 사전의 정확한 포즈와 정확한 기하학

장면. 첫째, 이전 포즈에 중대한 오류가 있거나

장면 내에서 폐쇄이 심한 지역에 위치하며,

쿼리 이미지와의 매칭이 실패했거나 매칭 품질이 좋지 않았습니다.

--- 페이지 4 ---

(a) (b) (c) (d)

그림 3. 오류-신뢰도 및 오류-불확실성의 분포. 번역 오류와 오류 사이의 관계를 시각화합니다.

Kings(파란색) 및 Hospital(주황색) 장면의 프레임에 대한 집계된 일치 신뢰도(a,c) 또는 집계된 깊이 불확실성(b,d)

캠브리지 데이터셋의 각 프레임에 대해 x축 값은 모든 2D-2D 대응에 대한 신뢰도 또는 불확실성의 합을 나타냅니다.

밀도. 녹색 추세선은 더 높은 신뢰도와 더 낮은 불확실성이 더 작은 위치 오류와 지속적으로 연관되어 있음을 보여줍니다.

저하될 수 있습니다. 그림 2와 같이 세련된 포즈가 생성되었습니다.

그러한 결정론적 개선으로 인해

포즈 추정기보다 먼저 초기 포즈를 취합니다 [5, 6, 8]. 이것은-

고소는 단일 결정론적 포즈에 의존하여 발생합니다.

견적. 이를 해결하기 위해 우리는 수정된 Monte Carlo를 활용합니다.
 이러한 모호함을 해결하는 데 도움이 되는 현지화 [22, 55]
 다양한 포즈 가설을 샘플링하여 불확실성을
 확률적으로 정제합니다.
 기하학적 불확실성. 3DGS 기반 포즈 개선-
 파이프라인도 기하학적 품질에 따라 달라집니다.
 3DGS 표현. 기존 파이프라인에서 포즈
 사전은 PnP-RANSAC을 통해 다음과 같이 정제됩니다.
 Eq.의 3D 좌표 $\mathbf{map}_X \mathbf{r}$ 사이. (1). 경우에도
 이미지 합성은 정확하지만 잘못된 기하학으로 인해
 잘못된 3D 포인트 정보 [16, 18, 63]
 최종 포즈 추정에 적극적으로 영향을 미칩니다. 이러한 내용을 바탕으로
 광경, 우리는 앵커 기반 가우스의 깊이 불확실성을 탐구합니다.
 시안 스플래팅 [35]. 깊이 불확실성 추정을 통해
 우리는 현장 전반에 걸쳐 불확실성을 기반으로 한 전략을 제안합니다.
 포즈 개선을 위한 포인트 샘플링 전략. 이번 샘플링
 체계는 기하학적 신뢰성을 명시적으로 활용하여 완화합니다.
 PnP 동작 중 잘못된 3D 포인트로 인한 장애 사례
 Sec.에 자세히 설명된 대로 타이밍 프로세스. 3.2.

3.2. 몬테카를로 개선

사전 불확실성을 설명하기 위해 MCL을 채택합니다.
 다양한 포즈 가설을 생성하는 영감받은 전략
 초기 포즈부터 최적화를 통해 각각을 개선합니다.
 tion 절차를 수행하고 중요도 샘플링을 통해 평가합니다.
 플링. MCL은 카메라 포즈를 가중치 집합으로 나타냅니다.

$$\text{입자} P = \{(T(m), w(m))\}_{m=1}^M$$

$$m=1, \text{여기서 각각의 } T(m) \in SE(3)$$
 SE(3)은 샘플링된 입자를 나타내고 $w(m)$ 은 그 중요성을 나타냅니다.
 무게. 그러나 표준 MCL 프레임워크는 컴퓨팅입니다.
 이 고차원에서 6DoF 포즈에 대해서는 이론적으로 비효율적입니다.
 상태 공간. 전형적인 예측 단계는 다음과 같습니다.
 단순히 무작위 섭동이나 샘플링을 포함합니다.
 넓은 사전은 지시되지 않으며 엄청나게 필요합니다.
 SE를 적절하게 덮을 만큼 많은 수의 입자(3)
 다양하고 수렴한다. 이 문제를 해결하기 위해 예측을 대체합니다.
 섹션에서와 같이 로컬 최적화를 사용하는 단계. 3.3. 이 단계
 가능성이 있는 가까운 모드로 각 입자를 안내합니다.
 유통. 결정적으로, 이 최적화는 지시된 역할을 합니다.
 사전 수정 메커니즘을 통해
 광범위한 사전에 의해 도입된 확실성.
 사전 수정 단계 이후 중요도 가중치
 샘플을 채취하려면 각 입자의 $w(m)$ 를 식별해야 합니다.
 가장 가능성이 높은 입자. 광도계를 적용하는 것보다
 추가 렌더링이 필요한 오류 [30, 53, 64]
 도메인 이동 및 장면 표시에 매우 취약합니다.
 다양한 변형에 대해 효율적인 평가를 위해 두 가지 주요 측정항목을 활용합니다.

유에이션. 특히, 우리는 일치 신뢰도를 활용합니다.
ScoreS m은 본질적으로 생성된 부산물입니다.
2D 매칭 모듈M 및 기하학적 불확실성
mapU m, Sec.에 설명되어 있습니다. 3.3. 그림 3에 도시된 바와 같이,
높은 일치 신뢰도 점수 S m 및 낮은 기하학적 un-
확실성Um은 포즈 오류 감소와 강한 상관관계가 있습니다.
신뢰할 수 있는 가중치 요소로 사용되는지 검증합니다. 이들은 만났다-
그런 다음 rics를 결합하여 세련된 운동의 적합성을 정량화합니다.
포즈를 취하고 입자가 상위에 속하는지 여부를 결정합니다.
실제 카메라 포즈 근처의 우도 영역.
결과적으로, 각 항목에 대한 중요도 가중치w(m)는
미세한 입자는 두 화합물의 곱으로 정의됩니다.
입자 집합에 대해 정규화된 보완 요소P:

$$w(m) = \prod_{i=1}^m S_m(r_i) \cdot (1 - U_m(r_i))$$

$$\prod_{j=1}^n P_n(r_j) \cdot (1 - U_j(r_j))$$
, (2)
여기서 i는 2D-2D 대응 픽셀을 나타냅니다.
렌더링된 이미지. 가중치 할당 후 최종
포즈 추정치는 입자 기반을 리샘플링하여 파생됩니다.
운유(m). 최종 추정된 카메라 포즈 Tfinal은 다음과 같습니다.
일반적으로 다음 중 하나에 의해 설정된 결과 입자에서 추출됩니다.
가장 높은 가중치를 갖는 입자를 선택하거나 계산을 통해
입자의 가중 평균을 계산하는 것은 SE(3)에서
최종 반복.

--- 페이지 5 ---

오류(cm,°) : 13.62, 0.09 오류(cm,°) : 16.78, 0.22 쿼리 이미지 w. 불확실성 기반 PnP(w/o) 불확실성 기반 PnP
높음
낮음
그림 4. 불확실성 기반 PnP의 효과. 우리는
2D-2D 대응과 함께 렌더링된 불확실성 맵
합성된 뷰에 투영됩니다. 녹색과 빨간색 점
각각 내부점과 이상점을 나타냅니다. 신청시
우리의 불확실성에 기반한 PnP, 높은 위치에 있는 대응
불확실성 영역은 자연스럽게 억제되어 더 많은 신뢰도를 제공합니다.
가능한 inliers 및 향상된 포즈 추정 결과.
3.3. Fisher 정보 안내 자세 개선
Fisher 정보 근사. 지리를 식별하려면
3DGS의 미터법 불확실성을 자세 개선으로 변환하여
Fisher 정보 기반 깊이 불확실성을 다음으로 확장합니다.
앵커 기반 가우스 스플래팅 표현 [35]
FisherRF [18]에서 영감을 얻었습니다. 전체 3DGS 모델을 PA-

평가자는 다음과 같이 표현됩니다.

$$= (\mu, \sigma), \sigma = D(\mu), (3)$$

여기서 μ 는 앵커 매개변수와 σ 가우시안을 나타냅니다.

decoderD에서 생성된 속성. [18]에 이어

Fisher 정보는 표준 규정에 따라 대략적으로 계산할 수 있습니다.

ularity 조건 [47]은 다음의 예상되는 음의 헤세 행렬입니다.

로그 가능성:

$$l(x, \mu) = -E$$

∇^2

$$\log p(y|x, \mu)$$

$$= H''[y|x, \mu], (4)$$

여기서 x 는 렌더링 포즈를 나타냅니다. 헤세 행렬 H''

렌더링된 출력의 야코비안(Jacobian)에서 계산됩니다.

에 관해서는 $\sin$ -를 통해 효율적으로 얻을 수 있습니다.

주어진 뷰에 대해 역방향 전달을 수행합니다. 실제로 우리는

전체 Hes를 대체하는 라플라스 근사 [10, 36]

대각선 요소와 작은 정규화가 있는 sian

용어:

$$H''[y|x, \mu] \approx \text{diag}$$

$$(\nabla f)^\top (\nabla f)$$

$$+ \dots (5)$$

깊이 불확실성을 집계합니다. 지리를 정량화하려면-

측정 불확실성, Fisher 정보를 집계합니다.

$l(x_i, \mu)$ 주어진 훈련 뷰에서 $x_i \in X$ 전역에서

$G = \text{PNviews}$ 로 정의된 행렬 G

$i=1 \dots H''[y|x_i, \mu]$. 그런 다음,

추정된 뷰 x_q 의 불확실성 U 는 다음을 사용하여 계산됩니다.

3DGS 렌더링 공식은 각 가우시안의

기하학적 불확실성은 깊이 기여에 따라 가중치가 부여됩니다.

광선을 따라 이동합니다. 총 개수에 대해 정규화하여

GaussiansN의 이 작업은 효과적으로 AC를 투영합니다.

누적된 3D 불확실성을 픽셀당 2D 불확실성으로 변환

지도:

$$U = 1$$

엔

$N \times$

$$U = 1$$

$$\text{tr}(G_i) d_i$$

$$Y_i = 1$$

$$j=1$$

$$(1 \dots j). (6)$$

여기서 d_i 와 G_n 은 가우시안 깊이를 나타낸다.

i번째 가우스 포인트에 대응하는 G의 부분행렬
렌더링 뷰에서 본 모습입니다.
기하학적 불확실성을 통한 자세 추정.
Fisher 기반 기하학적 불확실성을
포즈 최적화 절차, 2D-3D 대응
 $C=\{(q_i, X_i)\}$ 식에서. (1) 특정 분야와 연관되어 있습니다.
특정 기하학적 불확실성 $U(r_i)$. This $U(r_i)$ 는
재구성된 점 X 의 국부적인 기하학적 신뢰성 i .
단일 기반에 의존하는 단순한 RANSAC-Sampler와는 달리
양식 샘플링을 통해 우리 프레임워크는 확률적 방법을 도입했습니다.
불확실성 장의 편향. 샘플링 가중치를 구성합니다.
이 기하학적 의존성에 기초하여 각 대응에 대한 s_i
능력:
$$s_i = e^{-U(r_i) + \dots}, (7)$$

여기서 $U \in [0, 1]$ 은 정규화된 불확실성을 나타냅니다.
일치하는 픽셀의 모든 불확실성 값. 이것은-
물레이션은 샘플링 단계를 기하학적으로 편향시킵니다.
더 높은 가중치를 할당하여 신뢰할 수 있는 대응 i .
각 개선 반복에서 최소 2D-3D 하위 집합
확률적 가중치에 따라 샘플링된 $S_k \subset C$ is
시. 추정된 포즈 T_k 는 다음을 사용하여 계산됩니다.
EPnP 알고리즘[25]을 반복적으로 수행합니다. 이 반복적인 프로세스는
새로 생성된 각각의 가설이 본질적으로
그림과 같이 안정적인 기하학적 앵커를 향해 안내됩니다.
그림 4. 또한 우리는 이 편향을 합의로 확장합니다.
평가. 정제된 최종 포즈 T 는 최대화에 의해 선택됩니다.
가중치가 부여된 합의를 수행합니다. $P s_i$.

4. 실험

이번 섹션에서는 현지화 성능과
우리가 제안한 포즈 개선 파이프라인 분석. 비서. 4.1
실내와 실외 모두에서 위치 파악 정확도를 보고합니다.
도어 벤치마크. 비서. 4.2는 상세한 절제를 제공합니다
우리 프레임워크의 주요 구성 요소를 연구하고 검토합니다.
단순 반복 정제와의 비교를 포함하여,
입자 수의 영향과 다른 영향
일치하는 모듈.
데이터 세트. 우리는 세 가지 방법을 광범위하게 평가합니다.
시각적 현지화 벤치마크 사용: 7Scenes [50],
12Scenes [57] 및 Cambridge Landmarks [19]. 는
7Scenes 데이터세트[50]는 7개의 실내 환경으로 구성됩니다.
사무실부터 거실까지 다양한 공간 볼륨

--- 페이지 6 ---

오차(cm,°) : 4.91, 1.51 오차(cm,°) : 0.88, 0.29 오차(cm,°) : 10.48, 7.09
오차(cm,°) : 2.41, 0.77 오차(cm,°) : 0.55, 0.08 오차(cm,°) : 33.02, 8.67
오차(cm,°) : 26.41, 3.82 오차(cm,°) : 2.77, 0.45 오차(cm,°) : 132.15, 20.07
오차(cm,°) : 7.99, 3.01 오차(cm,°) : 1.43, 0.49 오차(cm,°) : 55.01, 13.91 DFNet DFNet + GS-CPRDFNet +

OursDFNet DFNet + GS-CPR DFNet + Ours

GT

추정

GT

추정

GT

추정

GT

추정

그림 5. 7장면 데이터셋의 현지화 품질 시각화. 각 이미지 3개는 실측 뷰를 비교합니다(왼쪽 위).

(i) 사전 입력 포즈, (ii) 기본 GS-CPR 개선, (iii) UGS-Loc 개선(오른쪽 아래)에서 렌더링된 뷰를 사용합니다. 대각선 경계를 따라 정렬이 가까울수록 자세 정확도가 향상됩니다.

표 1. 7Scenes 데이터셋의 현지화 결과. 중앙값 변환 오류(cm)와 회전 오류(°)를 보고합니다. 최고와 두 번째로 좋은 결과는 굵은 글씨와 밑줄이 그어져 있습니다.

방법 체크 마이어 헤드 오피스 호박 레드키친 계단 평균↓[cm/o]

4월

포즈넷 [19] 10/4.02 27/10.0 18/13.0 17/5.97 19/4.67 22/5.91 35/10.5 21/7.74

DFNet [6] 3/1.12 6/2.30 4/2.29 6/1.54 7/1.92 7/1.74 12/2.63 6/1.93

마레포 [8] 1.9/0.83 2.3/0.92 2.1/1.24 2.9/0.93 2.5/0.88 2.9/0.98 5.9/1.48 2.9/1.04

RAP [28] 1/0.84 6/3.44 4/5.48 5/1.92 4/1.71 7/2.11 9/2.10 5/2.51

SCR

DSAC* [4] 0.5/0.17 0.8/0.28 0.5/0.34 1.2/0.34 1.2/0.28 0.7/0.21 2.7/0.78 1.1/0.34

ACE [5] 0.5/0.18 0.8/0.33 0.5/0.33 1.0/0.29 1.0/0.22 0.8/0.2 2.9/0.81 1.1/0.34

글레이스 [58] 0.6/0.18 0.9/0.34 0.6/0.34 1.1/0.29 0.9/0.23 0.8/0.20 3.2/0.93 1.2/0.36

NRP

FQN-MN [14] 4.1/1.31 10.5/2.97 9.2/2.45 3.6/2.36 4.6/1.76 16.1/4.42 139.5/34.67 28/7.3

크로스파이어 [40] 1/0.4 5/1.9 3/2.3 5/1.6 3/0.8 2/0.8 12/1.9 4.4/1.38

pNeRFloc [66] 2/0.8 2/0.88 1/0.83 3/1.05 6/1.51 5/1.54 32/5.73 7.3/1.76

DFNet + NeFeS50 [7] 2/0.57 2/0.74 2/1.28 2/0.56 2/0.55 2/0.57 5/1.28 2.4/0.79

NeRFMatch [68] 0.9/0.3 1.1/0.4 1.5/1.0 3.0/0.8 2.2/0.6 1.0/0.3 10.1/1.7 2.8/0.7

MCLoc [56] 2/0.8 3/1.4 3/1.3 4/1.3 5/1.6 6/1.6 6/2.0 4.1/1.43

DFNet + GS-CPR [32] 0.7/0.20 0.9/0.32 0.6/0.36 1.2/0.32 1.3/0.31 0.9/0.25 2.2/0.61 1.1/0.34

마레포 + GS-CPR [32] 0.6/0.18 0.7/0.28 0.5/0.32 1.1/0.29 1.0/0.26 0.8/0.21 1.5/0.44 0.9/0.28

ACE + GS-CPR [32] 0.5/0.15 0.6/0.25 0.4 /0.28 0.9/0.26 1.0/ 0.23 0.7/0.17 1.4/0.42 0.8/0.25

STDLoc [17] 0.46/0.150.57/0.240.45/0.260.86/0.24 0.93/0.21 0.63/0.19 1.42/0.41 0.76/0.24

DFNet +우리 0.36/0.16 0.48/0.20 0.37/0.25 0.77/0.210.81/0.180.59 /0.151.21/0.35 0.66/0.21

마레포+우리 0.37/0.120.48/0.20 0.36/0.26 0.78/0.22 0.81/0.180.59 /0.151.13 /0.34 0.65//0.21

에이스+우리 0.37/0.12 0.47/0.20 0.36/0.25 0.77/0.220.79/0.18 0.58/0.15 1.11/0.33 0.64/0.21

약 1m³에서 18m³까지. 12장면 [57]

데이터 세트는 이 설정을 더 큰 실내 환경으로 확장합니다.

(14m³ - 79m³), 더욱 복잡한 장면 레이아웃 제공

그리고 관점의 다양성. 캠브리지 랜드마크 [19]

데이터 세트에는 공간적 특성을 갖춘 4개의 대규모 야외 장면이 포함되어 있습니다.

875m²에서 5600m²까지 다양한 도시를 포착

중요한 조명과 관점 아래 있는 랜드마크

변화.

구현 세부 사항.In Monte Carlo Refinement, al-

경량 매칭 [11, 31, 45] 모듈은 em- 배치되어 반복 횟수가 늘어나고 입자도 없습니다. 추론 시간이 상당히 늘어나게 됩니다. 반복된 일치 및 포즈 최적화 단계. 그러므로, 우리는 전체 포즈 개선 프로세스를 $N=2$ 로 유지합니다. 모든 실험에서 $m=8$ 개의 입자를 사용합니다. 모피로-효율성, 포즈 개선 및 무게를 향상시킵니다. 각 입자의 처리는 다중 처리를 사용하여 병렬로 처리됩니다. [56]으로 처리됩니다. 벤치마크 실험을 위해 우리는 미세 조정 없이 MAST3r [26]을 매칭 모듈로 사용 ing, 대체 매칭 모드에 대한 추가 연구는 ule은 Sec에 제시되어 있습니다. 4.2 및 보충 자료. Monte Carlo Refinement의 섭동 노이즈에 대해, 첫 번째 반복 샘플 변환 및 회전 섭동 10cm와 0.01° 범위의 균일한 분포에서, 각각. 후속 반복에서는 1cm 트랜스를 사용합니다.

--- 페이지 7 ---

표 2. 7개 장면의 평균 리콜. 리콜율을 보고합니다. 전체에 걸쳐 [2cm, 2] 및 [5cm, 5] 오류 임계값 이내 7장면.

데이터 세트 7장면

방법 평균 Acc $\uparrow$ [5cm, 5] 평균. Acc $\uparrow$ [2cm, 2]

DF넷 43.1 8.4

DFNet + GS-CPR 94.2 76.5

DFNet + GS-CPR2 98.4 86.1

DFNet +UGS-Loc 99.7 95.1

에이스 97.1 83.3

ACE + GS-CPR10093.1

ACE + GS-CPR2 10093.1

ACE +UGS-Loc 100 95.6

관계 및 0.01° 회전 소음. Fisher In을 도출하려면

Scaffold-GS 매개변수에 대한 형성() [35],

앵커 기능과 로컬 가우스 오프셋을 탐색합니다.

매개변수 로. 모든 실험은

엔비디아 RTX A5000 GPU. GS-CPR[32]에 따라 우리는

30,000회 반복을 위해 Scaffold-GS [35] 모델을 훈련하고

노출 적응 전략을 채택하십시오. 우리의 기준으로는

위치 파악 구성($m=8$), 모든 입자 렌더링

뷰에는 190ms가 필요하며 일괄화된 MAST3r 추론에는

492ms가 걸립니다. 불확실성에 기반한 PnP 최적화

다중 처리 설정에서 실행되는 MAST3r matcher,

377ms를 추가합니다. 전체적으로 엔드 투 엔드 추론 시간은 1.1초입니다.

반복 당. 총 런타임은 다양한 방식으로 조정될 수 있습니다.

입자의 수. 특히 MCLoc은

유사한 Monte Carlo 기반 개선 파이프라인인 80 it-

생성 절차에는 쿼리당 약 2.4초가 소요됩니다.
 우리의 방법은 실제 런타임 범위 내에서 유지됩니다.
 비슷한 설정.
 기준선. 현지화 성능을 비교합니다.
 세 가지 벤치마크에 걸쳐 최첨단 접근 방식을 사용합니다.
 데이터 세트 [19, 29, 50]. 비교에는 다음이 포함됩니다.
 다음을 포함하는 용질 자세 회귀(APR) 방법[48]
 PoseNet [19], DFNet [6], LENS [39] 및 RAP [28]; 장면
 DSAC*[4]와 같은 좌표 회귀(SCR) 방법,
 ACE [5] 및 GLACE [58]; 신경 렌더링 기반
 사후 정제(NRP) 방법 [7, 14, 17, 32, 40, 56, 66,
 68], 이는 다음에서 파생된 2D-3D 대응을 활용합니다.
 신경 장면 표현 또는 동기화를 통해 초기 포즈 개선
 새로운 관점을 제시합니다.

4.1. 벤치마크 결과

7 장면 [15, 50]. 탭에 표시된 대로. 1, 우리는 나를 제시합니다 -
 각 장면의 디안 변환 및 회전 오류. 우리 프로-
 제기된 방법인 UGS-Loc은 약 40%의 효과를 달성합니다.

ACE [5]에서 추정된 사전 포즈로부터의 증명,
 DFNet [6] 및 merapo [8]는 중앙값 전송 측면에서
 관계 및 회전 오류. 게다가 비교해보면

표 3. 12Scenes 데이터세트의 현지화 결과.
 추정된 포즈가 다음을 만족하는 프레임의 평균 비율
 $[2\text{cm}, 2^\circ]$ 및 $[5\text{cm}, 5^\circ]$ 임계값과 중앙값 이동
 12개 장면에 걸쳐 회전 및 회전 오류(cm/o)가 발생합니다.

방법 평균 Err↓[cm/°] 평균↑[5cm, 5°] 평균↑[2cm, 2°]

마레포 2.1/1.04 95 50.4

DSAC* 0.5/0.25 99.8 96.7

에이스 0.7/0.26 100 97.2

글레이스 0.7/0.25 100 97.5

마레포 + GS-CPR 0.7/0.28 98.9 90.9

마레포 + UGS-Loc 0.5/0.21 99.4 95.3

ACE + GS-CPR 0.5/0.21 100 98.7

ACE + UGS-Loc 0.4/0.18 100 99.1

표 4. 캠브리지 랜드마크 현지화 결과

데이터 세트입니다. 중앙값 번역 오류(cm)와 회전을 보고합니다.

오류(○). 가장 좋은 결과는 대담하고 두 번째로 좋은 결과입니다.

밑줄로 표시되어 있습니다.

Methods 킹스병원삽교회Avg.↓[cm/○]

4월

PoseNet [19] 93/2.73 224/7.88 147/6.62 237/5.94 175/5.79 MS-트랜스포머 [48] 85/1.45 175/2.43 88/3.20

166/4.12 129/2.80 LENS [39] 33/0.5 44/0.9 27/1.6 53/1.6 39/1.15 DFNet [6] 73/2.37 200/2.98 67/2.21

137/4.02 119/2.90 RAP [28] 58/0.87 81/1.20 33/1.64 60/1.83 58/1.39

SCR ACE [5] 29/0.38 31/0.61 5/0.3 19/0.6 21/0.47 GLACE [58] 20/0.32 20/0.41 5/0.22 9/0.3 14/0.32

NRP

FQN-MN [14] 28/0.4 54/0.8 13/0.6 58/2 38/1 CrossFire [40] 47/0.7 43/0.7 20/1.2 39/1.4 37/1 DFNet +

NeFeS30 [7] 37/0.64 98/1.61 17/0.60 42/1.38 49/1.06 DFNet + NeFeS50 [7] 37/0.54 52/0.88 15/0.53

37/1.1435/0.77HR-APR [33]36/0.58 53/0.89 13/0.51 38/1.1635/0.78MCLoc [56] 31/0.42 39/0.73 12/0.45
 26/0.827/0.6RAPref[28] 18/0.38 22/0.42 8/0.39 16/0.4716/0.42DFNet + GS-CPR [32]23/0.32 42/0.74
 10/0.36 27/0.6226/0.51ACE + GS-CPR [32]20/0.29 21/0.40 5/0.24 13/0.4015/0.33DFNet
 +Ours18.7/0.1914.5/0.29 3.9/0.155.5/0.1710.7/0.20ACE +우리17.8/0.18 13.8/0.304.2/0.166.3/0.20
 10.5/0.21

순수 결정론적 복사장 기반 GS-CPR [32]

포즈 개선 프레임워크에서 우리의 방법은 추가 기능을 보여줍니다.

세 가지 초기 포즈 추정에 대해 약 20% 개선

유사한 개선 프로세스를 사용함에도 불구하고 [5, 6, 8]

그렇죠. 또한 a2cm,2 °의 평균 정확도를 보여줍니다.

및5cm,5 ° Tab의 psae 오류 임계값. 2. 탭에서. 2, 우리

추가적으로 GS-CPR2의 결과를 포함합니다.

반복적인 방식으로 GS-CPR의 개선 구조

공정한 비교를 위해. GS-CPR2는 재위치화를 수행합니다.

근본적으로 세련된 포즈를 새로운 초기 포즈로 사용합니다.

우리가 제안한 UGS-Loc은 UGS-Loc보다 더 높은 정확도를 보여줍니다.

원래의 비반복적 개선 구조와

2cm 아래에서 10% 반복 GS-CPR2를 수행합니다.2 °

문지방. 이러한 개선은 반복적인 재작업에서 비롯된 것이 아닙니다.

별금을 부과하지만 효과적으로 한계를 해결하는 것은 불가능합니다.

우리가 제안한 Proba를 통해 결정론적 프레임워크를

빌리스틱 공식.

12장면 [57]. 탭에 표시된 대로. 3, 우리는 수량을 보고합니다.

Merapo[8]와 ACE[5]를 이용한 효과적인 위치 파악 성능

이전에 포즈를 취한 것처럼. SCR-의 강력한 기본 정확도를 고려하면

[5cm,5 °] 임계값에 대한 방법 [3, 58]을 기반으로 우리는

우리의 접근 방식은 엄격한 기준점[2cm,2 °]에 있습니다.

--- 페이지 8 ---

표 5. 미세화를 위한 입자 수 평가

우리는 중앙값 변환 및 회전 오류(cm/ °)를 보고합니다.

다양한 입자 수에 대한 Cambridge Landmarks 데이터세트

Monte Carlo Refinement에 사용됩니다. PP 및 NP는 사전 포즈를 나타냅니다.

그리고 입자의 수

PP NP 킹스병원 매장교회 평균↓[cm/o]

DFNet

2 18.7/0.20 16.24/0.36 5.5/0.20 6.6/0.2011.8/0.24

4 19.1/0.19 15.1/0.29 4.6/0.19 6.0/0.1811.2/0.21

8 18.7/0.1914.50.293.9/0.155.5/0.17 10.7/0.20

16 18.2/0.2013.8/0.274.2/0.165.1/0.16 10.3/0.20

에이스

2 17.8/0.21 14.8/0.30 4.0/0.18 6.9/0.2310.9/0.51

4 18.8/0.19 14.3/0.28 3.7/0.16 6.8/0.2110.7/0.21

8 17.8/0.1813.8/0.30 4.2/0.16 6.3/0.2010.5/0.21

16 17.0/0.18 11.9/0.28 3.4/0.15 6.1/0.199.6/0.20

99.1%의 가장 높은 정확도를 달성합니다. 게다가 우리의

방법은 가장 낮은 중간 이동 및 회전을 달성합니다.

모든 장면에서 오류가 발생하여 기존 재작업보다 성능이 뛰어납니다.
 보다 정확하고
 안정적인 현지화 결과.
 Cambridge Landmark [19]. 탭에 표시됨. 4, 우리는 평가-
 DFNet [6] 및 ACE [5]를 이용한 위치 파악 성능
 이전에 포즈를 취한 것처럼. UGS-Loc은 중간 번역 오류를 줄입니다.
 기준 GS-CPR[32]의 약 30%,
 강력한 정제 능력을 보여줍니다. 특히, 우리의
 프레임워크는 단 두 번의 반복 내에서 안정적으로 수렴됩니다.
 품질에 관계없이 지속적으로 높은 정확도를 달성합니다.
 이전의 초기 포즈의 특성. DFNet의 현지화에도 불구하고
 성능은 ACE보다 상당히 약하며 종종 다릅니다.
 5배 증가하면 개선 모듈도 비슷한 결과를 제공합니다.
 두 사전에 대한 정확한 결과. 이는 능력을 보여줍니다.
 하위로 인해 발생하는 불확실성을 완화하기 위해 UGS-Loc을 사용합니다.
 최적의 포즈 사전. 놀랍게도 어려운 상황에서도
 Shop 장면과 같은 UGS-Loc은 DFNet 사전 보증을 통해
 ACE를 사용하여 얻은 개선 결과를 통과합니다.
 이전 소음에 대한 접근 방식의 견고성을 검증합니다.

4.2. 절제 연구

Simple Iterative Refinement와의 비교. 우리는-
 UGS-Loc의 성능 향상 여부를 조사합니다.
 단순히 여러 번의 개선 반복에서 비롯됩니다. 이에
 마지막으로, 우리는 캠브리지 랜드에서 실험을 수행합니다.
 결정론적 기반을 반복적으로 적용하여 데이터셋을 표시합니다.
 라인 파이프라인 [32]을 여러 번 시도하고 이를 우리의 것과 비교합니다.
 확률적 개선을 제안했습니다. 그림 6과 같이 심지어
 GS-CPR을 통한 반복적 개선은 점차 감소하지만
 변환 및 회전 오류가 발생하면 빠르게 포화됩니다.
 첫 번째 반복. 대조적으로, 우리의 방법은 두 가지 모두를 달성합니다.
 텐트 수렴과 더 낮은 최종 오류를 보여줍니다.
 개선은 우리의 프레임워크에서 비롯됩니다.
 반복되는 결정론적 최적화로부터.
 포즈 미세 조정에 대한 입자 수의 영향.우리는 분석합니다.
 몬테에 사용된 입자 수의 영향을 분해합니다.
 표 6. 다양한 2D 매칭 모듈을 사용한 평가
 희소 기능을 사용하여 확률적 개선 프레임워크를 비교합니다.
 실제 일치자(SuperPoint(SP) [11] + LightGlue(LG) [31]) 및
 조밀한 대응 모델(MASt3r [26]).
 사전 매칭자 Kings Hospital Shop Church 평균↓[cm/o]
 기준선 23/0.32 42/0.74 10/0.36 27/0.62 26/0.51
 DFNet SP + LG 20/0.22 17/0.31 5.5/0.26 7.7/0.25 13/0.26
 DFNet MASt3r 19/0.19 15/0.32 4.3/0.17 5.8/0.18 11/0.22
 ACE SP + LG 19/0.23 15/0.27 4.0/0.19 7.8/0.26 11/0.26
 에이스 MASt3r 18/0.20 14/0.30 4.5/0.16 6.5/0.21 11/0.22
 그림 6. Iteration-wise Pose Refinement와 비교.

반복에 대한 중앙값 변환 및 회전 오류 시각화
 UGS를 비교한 캠브리지 랜드마크의 교회 현장
 GS-CPR[32]에서 채택된 반복 개선 전략을 사용하여 Loc.
 카를로 리파인먼트. 탭에 표시된대로. 5, 개수를 다양하게 한다
 정제수를 유지하면서 2~16개의 입자를
 반복을 2로 설정합니다. 숫자가 증가하는 것을 관찰합니다.
 입자의 변환과 회전이 지속적으로 향상됩니다.
 모든 장면에서 정확도를 유지합니다. 특히, 수행
 참여도를 높일 때 이득이 가장 두드러집니다.
 클 카운트. 이는 다중 포즈 가설을 사용함을 시사합니다.
 ses는 이전 포즈의 불확실성을 더 잘 포착하는 데 도움이 됩니다.
 최적이 아닌 로컬 최소값으로의 수렴을 방지합니다.
 다양한 매칭 모듈. 탭에 표시된 대로. 6, 우리
 방법은 현지화 결과를 다음과 비교하여 보여줍니다.
 경량 희소 특성 일치자(SuperPoint [11] +
 LightGlue[31]). MAST3r은 약간 양보하는 경향이 있지만
 강력한 맥락 추론으로 인해 더 높은 정확도와
 조밀한 기능 집계, 불확실성을 인식한 개선
 ment는 다음과 같은 경우에도 비슷한 위치 정확도를 달성합니다.
 경량의 희소 일치자. GS-CPR을 다음과 같이 보고합니다.
 MAST3r을 기준으로 삼습니다.

5. 결론

본 논문에서는 간과된 영향을 조사했습니다.
 3D 가우시안의 사전 자세 및 기하학적 불확실성
 스플래팅 기반 포즈 개선. 이러한 문제를 완화하기 위해,
 우리는 확률적 재배치 프레임워크를 제안했습니다.

--- 페이지 9 ---

Monte Carlo 샘플링과 Fisher Informa-를 결합합니다.
 지침에 따른 PnP 최적화. 이 디자인은 불확실성을 처리합니다.
 재교육이나 장면별 광고 없이도 오염됩니다.
 정의. 실내외를 넘나드는 광범위한 실험
 벤치마크는 우리의 방법이 지속적으로
 현지화 정확도를 입증하고 관계없이 견고함을 유지합니다.
 포즈 이전 또는 일치 모듈을 선택합니다. 전반적으로,
 우리의 연구 결과는 불확실성을
 3DGS 파이프라인은 보다 안정적이고 신뢰할 수 있는 자세 개선을 제공합니다.
 프로세스.
 감사의 말
 본 연구는 한국평가원의 지원을 받아 수행되었습니다
 산업기술지원부(KEIT) 지원
 정부(산업부)(제20023455호, 개발)
 협력 매핑, 환경 인식 및 Au-
 다중 이동 로봇을 위한 대용량 구동 기술
 대규모 실내 작업 공간에서 운영), KIST In-
 기관 프로그램 (No.2E33801-25-015) 및 연구소
 정보통신기술기획학부
 한국 정부가 지원하는 IITP(평가 및 평가) 보조금-

먼트(과기부) (No.RS-2025-02219317, AI Star Fellowship, 국민대학교).

참고자료

- [1] Relja Arandjelovic, Petr Gronat, Akihiko Torii, Tomas Padla, 그리고 Josef Sivic. Netvlad: 약한 사용자를 위한 Cnn 아키텍처 감독된 장소 인식. IEEE 회보 중 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 5297-5307, 2016. 1, 12, 13, 14, 16, 17
- [2] Kazii Botashev, Vladislav Pyatov, Gonzalo Ferrer 및 Stamatios Lefkimmiatis. Gsloc: 3D를 이용한 시각적 현지화 가우스 스플래팅. 2024년 IEEE/RSJ 국제 컨퍼런스-지능형 로봇 및 시스템(IROS)에 대한 내용, 5664페이지 - 5671. IEEE, 2024. 3
- [3] Eric Brachmann과 Carsten Rother. 실화상 카메라 재 dsac.IEEE를 사용하여 rgb 및 rgb-d 이미지에서 지역화 패턴 분석 및 기계 지능에 대한 거래, 44(9):5847-5865, 2021. 1, 7
- [4] Eric Brachmann, Alexander Krull, Sebastian Nowozin, 제이미 쇼튼, 프랭크 미셸, 스테판 겐홀드, 카스텐 로터. 카메라 위치 파악을 위한 Dsac 구별 가능 랜삭입니다. 컴퓨터 비전에 관한 IEEE 회의 진행 중 및 패턴 인식, 페이지 6684-6692, 2017. 2, 6, 7
- [5] 에릭 브라흐만, 토마소 카발라리, 빅터 아드리안 프리사카리우. 가속 좌표 인코딩: 재학습 RGB와 포즈를 사용하여 몇 분 안에 위치를 파악하세요. 다음의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 5044-5053, 2023. 1, 2, 4, 6, 7, 8, 13, 15
- [6] Shuai Chen, Xinghui Li, Zirui Wang 및 Victor A 프리사카리우. Dfnet: 절대 포즈 회귀를 강화합니다. 직접적인 특징 매칭. InComputer Vision-ECCV 2022: 제17차 유럽회의, 이스라엘 텔아비브, 10월 23~27일, 2022년, 절차, X부, 1~17페이지. 스프링어, 2022. 1, 3, 4, 6, 7, 8, 13, 15
- [7] Shuai Chen, Yash Bhalgat, Xinghui Li, Jia-Wang Bian, Kejie Li, Zirui Wang, Victor Adrian Prisacariu. 신경정화-특징 합성을 통한 절대 포즈 회귀 분석. 에서 컴퓨터 비디오에 관한 IEEE/CVF 컨퍼런스 진행 이온 및 패턴 인식, 페이지 20987-20996, 2024. 1, 3, 6, 7
- [8] 슈아이 첸, 토마소 카발라리, 빅터 아드리안 프리사카리우, 그리고 에릭 브래크만. 시각적인 맵 관련 포즈 회귀 재현지화. IEEE/CVF 컨퍼런스 진행 중 컴퓨터 비전 및 패턴 인식, 20665페이지 - 20674, 2024. 1, 4, 6, 7
- [9] 보웬 첸, 이산 미스라, 알렉산더 G 슈윙, 알렉산-der Kirillov 및 Rohit Girdhar. 가면을 쓴 주의 마스크

범용 이미지 분할을 위한 변환기. 진행중-

컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스의 내용과

패턴 인식, 1290~1299페이지, 2022. 16

[10] Erik Daxberger, Agustinus Kristiadi, Alexander Immer,

Runa Eschenhagen, Matthias Bauer, Philipp Hennig.

Laplace redux-쉽지 않은 베이지안 딥 러닝. 발전

신경 정보 처리 시스템, 34:20089-20103,

2021. 5

[11] Daniel DeTone, Tomasz Malisiewicz 및 Andrew Rabi-

노비치. 슈퍼포인트: 자체 감독 관심 지점 감지

그리고 설명. IEEE 컨퍼런스 진행 중

컴퓨터 비전 및 패턴 인식 워크숍, 페이지

224-236, 2018. 1, 2, 6, 8, 15

[12] 마틴 A 피슬러(Martin A Fischler)와 로버트 C 볼레스(Robert C Bolles). 무작위 표본

합의: 애플리케이션에 적합한 모델을 위한 패러다임

이미지 분석 및 자동화된 지도 제작.커뮤니케이션

ACM, 24(6):381-395, 1981. 1, 3

[13] Xiao-Shan Gao, Xiao-Rong Hou, Jianliang Tang 및 Hang-

페이 첵. 완벽한 솔루션 분류

관점-3점 문제.IEEE 트랜잭션

패턴 분석 및 기계 지능, 25(8):930-943,

2003. 1, 3

[14] 휴고 제르맹, 다니엘 디톤, 제프리 파스코, 탄-

너 슈미트, 데이비드 노보트니, 리처드 뉴컴, 크리스

스위니, 리차드 스젤리스키, 바실레이오스 발르타스. 특징

쿼리 네트워크: 카메라 포즈에 대한 신경 표면 설명

개선. IEEE/CVF 컨퍼런스 진행 중

컴퓨터 비전 및 패턴 인식, 5071페이지 -

5081, 2022. 6, 7

[15] 벤 글로커(Ben Glocker), 샤람 이자디(Shahram Izadi), 제이미 쇼튼(Jamie Shotton), 안토니오

범죄. 실시간 rgb-d 카메라 재위치화. 2013년

혼합 및 증강에 관한 IEEE 국제 심포지엄

현실(ISMAR), 173~179페이지. IEEE, 2013. 7

[16] Lily Goli, Cody Reading, Silvia Sell 'an, Alec Jacobson 및

안드레아 탈리아사키. 베이지 광선: 불확실성 정량화

신경 방사 필드용. IEEE/CVF 회의록

컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스,

페이지 20061-20070, 2024. 3, 4

[17] Zhiwei Huang, Hailin Yu, Yichun Shentu, Jin Yuan 및

장궈펑. 회소에서 밀도로: 카메라 재위치화-

특징 가우스 스플래트(feature gaussian splat)의 장면별 검출기를 사용한

팅. 컴퓨터 비전 및 패턴 논문집

표창 컨퍼런스, 페이지 27059-27069, 2025. 1, 2, 3,

6, 7, 16

--- 페이지 10 ---

[18] 원 지양(Wen Jiang), 보슈 레이(Boshu Lei), 코스타스 다닐리디스(Kostas Daniilidis). Fisherrf: AC-

tive view 선택 및 radiance field 매핑

어부정보. 유럽 내 컴퓨터 회의

비전, 422~440쪽. 스프링어, 2024. 2, 3, 4, 5

[19] 알렉스 켄달, 매튜 그라임스, 로베르토 치폴라.

Posenet: 실시간 6자유도 캠을 위한 컨벌루션 네트워크

시대 재배치. IEEE 국제회의의 진행 중

컴퓨터 비전에 관한 컨퍼런스, 페이지 2938-2946, 2015. 1,

2, 5, 6, 7, 8, 15

[20] 베른하르트 케르블, 게오르기오스 코파나스, 토마스 라임크 uhler,

그리고 조지 드레타키스. 실시간 3D 가우스 스플래팅

래디언스 필드 렌더링.ACM Trans. 그래프., 42(4):139-1,

2023. 1, 3

[21] 요나스 쿨하네크(Jonas Kulhanek), 팡 송유(Songyou Peng), 주자나 쿠켈로바(Zuzana Kukelova), 마크

Pollefeys, Torsten Sattler 등이 있습니다. 와일드가우스: 3D 가우스

splatting in the wild.arXiv 사전 인쇄 arXiv:2407.08447, 2024.

2, 3

[22] 권정현, 최민석, 박종우,

그리고 전창목. 유클리드의 입자 필터링

그룹: 프레임워크 및 애플리케이션.Robotica, 25(6):725-

737, 2007. 4

[23] 이수민, 르첸, 왕지아오, 알렉산더 리니거,

수리얀시 쿠마르(Suryansh Kumar), 피셔 유(Fisher Yu). 불확실성에 따른 폴-

신경 복사를 이용한 능동형 로봇 3D 재구성을 위한 icy

fields.IEEE 로봇공학 및 자동화 서신, 7(4):12070-

12077, 2022. 3

[24] 이성원, 성홍제, 이수현, 은태

김. 이미지 검색을 위한 상관관계 검증. 인프로-

컴퓨터 비전에 관한 IEEE/CVF 컨퍼런스의 결과

및 패턴 인식, 페이지 5374-5384, 2022. 1

[25] 빈센트 르페티(Vincent Lepetit), 프란세스크 모레노-노게르(Francesc Moreno-Noguer), 파스칼 푸아(Pascal Fua).

Ep n p: p n p 문제에 대한 정확한 o(n) 해입니다.Inter-

전국 컴퓨터 비전 저널, 81(2):155-166, 2009. 1,

3, 5

[26] Vincent Leroy, Yohann Cabon 및 J'erre ome Revaud. 지상-

mast3r을 사용하여 3D 이미지 매칭을 수행합니다. InEuropean 회의-

컴퓨터 비전에 대한 내용, 71~91페이지. 스프링어, 2024. 1, 2,

3, 6, 8, 15, 16

[27] Siyuan Li, Lei Ke, Martin Danelljan, Luigi Piccinelli, Mattia

세구(Segu), 룩 반 굴(Luc Van Gool), 피셔 유(Fisher Yu). 무엇이든 일치시키는 방법

무엇이든 세분화합니다. IEEE/CVF 회의의 진행 중

컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지

18963~18973, 2024. 13, 15

[28] Sihang Li, Siqi Tan, Bowen Chang, Jing Zhang, Chen Feng,

그리고 리이밍. 데이터 합성의 힘을 활용하세요

시각적 현지화.arXiv 사전 인쇄 arXiv:2412.00138, 2024.

1, 2, 3, 6, 7, 16

- [29] Jingyu Lin, Jiaqi Gu, Bojian Wu, Lubin Fan, Renjie Chen, Ligang Liu, Jieping Ye. 신경 체적 자세 학습 카메라 현지화 기능. 유럽 회의 컴퓨터 비전, 198~214페이지. 스프링거, 2024. 7
- [30] 윤지 린, 토마스 뮐러, 조나단 트렘블레이, 보웬 Wen, Stephen Tyree, Alex Evans, Patricio A Vela 및 Stan 버치필드. 에 대한 신경 방사 필드의 병렬 반전 강력한 포즈 추정. In 2023 IEEE 국제 컨퍼런스-로봇공학 및 자동화(ICRA), 페이지 9377-9384. IEEE, 2023. 1, 3, 4
- [31] Philipp Lindenberger, Paul-Edouard Sarlin, Marc Polle-페이. Lightglue: 빛의 속도로 로컬 기능을 일치시킵니다. 에서 IEEE/CVF 국제 컨퍼런스 진행 컴퓨터 비전, 페이지 17627-17638, 2023. 6, 8, 15
- [32] Changkun Liu, Shuai Chen, Yash Bhalgat, Siyan Hu, Ming Cheng, Zirui Wang, Victor Adrian Prisacariu, 트리스탄 브라우드. Gs-cpr: 3D 가우스를 통한 효율적인 카메라 포즈 개선 sian splatting.arXiv 사전 인쇄 arXiv:2408.11085, 2024. 1, 2, 3, 6, 7, 8, 14, 16, 17
- [33] Liu Changkun, Chen Shuai, Yukun Zhao, Huajian Huang, 빅터 프리사카리우, 트리스탄 브라우드. Hr-apr: 4월 불가지론 불확실성 추정 및 계층적 재구성을 갖춘 프레임워크 카메라 재배치에 대한 개선. 2024년 IEEE 인터-ICRA(로봇공학 및 자동화에 관한 전국 회의), 8544~8550페이지. IEEE, 2024. 1, 7
- [34] Jianlin Liu, Qiang Nie, Yong Liu 및 Chengjie Wang. 너프-loc: 조건부 신경 방사능을 사용한 시각적 위치 파악 필드. In 2023 IEEE 로봇공학 국제 컨퍼런스 및 자동화(ICRA), 페이지 9385-9392. IEEE, 2023. 3
- [35] Tao Lu, Mulin Yu, Linning Xu, Yuanbo Xiangli, Limin 왕(Wang), 다화린(Dahua Lin), 보다이(Bo Dai). Scaffold-gs: 구조화된 3D 뷰 적응형 렌더링을 위한 가우스. 다음의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 20654-20664, 2024. 4, 5, 7, 16
- [36] 데이비드 JC 맥케이. 베이지안 보간. 신경 계산 tation, 4(3):415-447, 1992. 5
- [37] Ricardo Martin-Brualla, Noha Radwan, Mehdi SM Sajjadi, 조나단 T 배런(Jonathan T Barron), 알렉세이 도소비츠키(Alexey Dosovitskiy), 다니엘 덕(Daniel Duck) 가치가 있습니다. 야생의 너프: 불감증을 위한 신경 복사장 긴장된 사진 컬렉션. IEEE/CVF 회의록 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 7210-7219, 2021. 3
- [38] 벤 Mildenhall, Pratul P Srinivasan, Matthew Tancik, 조나단 T 배런(Jonathan T Barron), 라비 라마무르티(Ravi Ramamoorthi), 렌 응(Ren Ng). 너프: 뷰 동기화를 위해 장면을 신경 방사 필드로 표현 논문.ACM 커뮤니케이션, 65(1):99-106, 2021. 1, 3

[39] Arthur Moreau, Nathan Piasco, Dzmitry Tsishkou, Bogdan Stanciulescu 및 Arnaud de La Fortelle. 렌즈: 현지화 너프 합성으로 강화되었습니다. InConference on Robot Learning, 1347~1356페이지. PMLR, 2022. 3, 7

[40] 아서 모로, 네이션 피아스코, 무사브 베네하르, Dzmitry Tsishkou, Bogdan Stanciulescu 및 Arnaud de La Fortelle. Crossfire: 자체 감독 기능에 대한 카메라 재지역화 암시적 표현에서. 의 절차에서 IEEE/CVF 컴퓨터 비전 국제 컨퍼런스, 페이지 252-262, 2023. 3, 6, 7

[41] Raul Mur-Artal, Jose Maria Martinez Montiel, Juan D 타르도스. 오브 슬램: 다재다능하고 정확한 단안 슬램 system.IEEE 로봇 공학 트랜잭션, 31(5):1147-1163, 2015. 1

[42] Guilherme Potje, Felipe Cadar, Andr 'e Araujo, Renato Mar- 통 및 Erickson R Nascimento. Xfeat: 가속 기능 경량 이미지 매칭을 위한 기능입니다. 다음의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 인식, 페이지 2682-2691, 2024. 13, 15

[43] Yunlong Ran, Jing Zeng, Shibo He, Jiming Chen, Lincheng Li, Yingfeng Chen, 김희, Qi Ye. 신경: 신경

--- 페이지 11 ---

암시적 자율 3D 재구성에 대한 불확실성 신경 표현.IEEE 로봇 공학 및 자동화 Let- 테르, 8(2):1125-1132, 2023. 3

[44] Paul-Edouard Sarlin, Cesar Cadena, Roland Siegwart 및 마르신 딘치크(Marcin Dymczyk). 거친 것부터 미세한 것까지: 강력한 계층적 대규모 현지화. IEEE/CVF 회의록 컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스, 페이지 12716-12725, 2019. 1, 2

[45] 폴 에두아르 살린(Paul-Edouard Sarlin), 다니엘 디톤(Daniel DeTone), 토마스 말리시비츠(Tomasz Malisiewicz), 앤드류 라비노비치. Superglue: 학습 기능 그래프 신경망과 일치합니다. 다음의 절차에서 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스 표창, 페이지 4938-4947, 2020. 1, 2, 6, 15

[46] 토르스텐 새틀러, 윌 매든, 칼 토프트, 토리 아키히코, 라스 함마르스트란드, 에릭 스텐보그, 다니엘 사파리, 마사토시 Okutomi, Marc Pollefeys, Josef Sivic 등 벤치마킹 변화하는 조건에서 6dof 실외 시각적 위치 파악. 에서 컴퓨터 비전 및 컴퓨터 비전에 관한 IEEE 회의 진행 패턴 인식, 8601~8610페이지, 2018. 1

[47] Mark J Schervish. 통계 이론. 스프링거 과학 & 경제미디어, 2012. 5

[48] 율리 샤빗(Yoli Shavit), 론 페렌스(Ron Ferens), 요시 켈러(Yosi Keller). 멀티 학습 트랜스포머를 사용한 장면 절대 포즈 회귀. 인프로- IEEE/CVF 국제 컨퍼런스 관련 자료 컴퓨터 비전, 2733~2742페이지, 2021. 1, 2, 7

- [49] Jianxiong Shen, Adria Ruiz, Antonio Agudo 및 Francesc 모레노노게르. 확률론적 신경 방사 필드: Quanti-
암시적 3D 표현의 불확실성을 해소합니다. 2021년에는
3D Vision(3DV)에 관한 국제 컨퍼런스, 972~981페이지.
IEEE, 2021. 3
- [50] 제이미 쇼튼, 벤 글로커, 크리스토퍼 잭, 샤람
이자디, 안토니오 크리미니시, 앤드류 피츠기번. 장면 공동
rgb-d의 카메라 재위치를 위한 세로 회귀 포레스트
이미지. 컴퓨터에 관한 IEEE 컨퍼런스 진행 중
시각 및 패턴 인식, 페이지 2930-2937, 2013. 5,
7, 15
- [51] 겐나디 시도로프(Gennady Sidorov), 말리크 모흐라트(Malik Mohrat), 데니스 그리두소프(Denis Gridusov),
루슬란(Ruslan)
라키모프(Rakhimov), 세르게이 콜류빈(Sergey Kolyubin). Gsplatloc: 접지 카-
향상된 가시성을 위해 포인트 설명자를 3D 가우스 스피클레팅으로 변환
sual localization.arXiv 사전 인쇄 arXiv:2409.16502, 2024. 3
- [52] Jiaming Sun, Zehong Shen, Yuang Wang, Hujun Bao 및
저우 샤오웨이. Loftr: 감지기가 필요 없는 로컬 특징 매칭
변압기와 함께. IEEE/CVF 회의 진행 중
컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지
8922-8931, 2021. 1, 2, 3
- [53] Yuan Sun, Xuan Wang, Yunfan Zhang, Jie Zhang, Caigui
장(Jiang), 위궈(Yu Guo), 페이 왕(Fei Wang). icomma: 3D 가우스 반전-
비교를 통해 카메라 포즈 추정을 위한 시안 스피클레팅
매칭.arXiv 사전 인쇄 arXiv:2312.09031, 2023. 1, 3, 4
- [54] 타이라 하지메, 오쿠토미 마사토시, 토르스텐 사틀러, 미르체아
Cimpoi, Marc Pollefeys, Josef Sivic, Tomas Pajdla 및 Ak-
토리이 이히코. Inloc: 밀도가 높은 실내 시각적 위치 파악
매칭 및 뷰 합성. IEEE 회보 중
컴퓨터 비전 및 패턴 인식에 관한 컨퍼런스,
페이지 7199-7209, 2018. 2
- [55] Sebastian Thrun, Wolfram Burgard, Dieter Fox.Proba-
빌리스틱 로봇공학. MIT 출판사, 2005. 4
- [56] 가브리엘레 트리비뇨, 카를로 메이소네, 바바라 카푸토,
토르스텐 사틀러. 사전의 불합리한 효율성
카메라 포즈 개선을 위해 훈련된 기능. 진행 중
컴퓨터 비전 및 특허에 관한 IEEE/CVF 회의-
tern Recognition, 페이지 12786-12798, 2024. 1, 6, 7
- [57] 줄리앙 발렌틴, 안젤라 다이, 마티아스 니스너, 푸시미트
콜리(Kohli), 필립 토르(Philip Torr), 샤람 이자디(Shahram Izadi), 썸 케스킨(Cem Keskin). 배워보세요-
에너지 환경을 탐색하고 있습니다. 2016년 4번째-
3D Vision(3DV)에 관한 국제 컨퍼런스, 323~332페이지.
IEEE, 2016. 5, 6, 7
- [58] 왕팡진화(Fangjinhua Wang), 장쑤동(Xudong Jiang), 실바노 갈리아니(Silvano Galliani),
크리스토프 보겔(Christoph Vogel), 마크 폴레페이즈(Marc Pollefeys). Glace: 글로벌 로컬
가속 좌표 인코딩. 의 절차에서

- 컴퓨터 비전 및 패턴에 관한 IEEE/CVF 컨퍼런스
인식, 페이지 21562-21571, 2024. 2, 6, 7
- [59] Yifan Wang, Xingyi He, Sida Peng, Dongli Tan 및 Xiaowei
저우. 효율적인 loftr: 다음과 일치하는 반밀도 로컬 특성
희박한 속도. IEEE/CVF 회의 진행 중
컴퓨터 비전 및 패턴 인식에 대한 참조, 페이지
21666~21675, 2024. 13, 15
- [60] Zhou Wang, Alan C Bovik, Hamid R Sheikh 및 Eero P Si-
몬첼리. 이미지 품질 평가: 오류 가시성부터
구조적 유사성. 이미지 처리에 대한 IEEE 트랜잭션,
13(4):600-612, 2004. 16
- [61] Haolin Xiong, Sairisheek Muttukuru, Rishi Upadhyay,
Pradyumna Chari와 Achuta Kadambi. Sparsegs: 실제-
가우스 스피클릿을 사용한 시간 360° 희소 뷰 합성
ting.arXiv 사전 인쇄 arXiv:2312.00206, 2023. 2
- [62] Yan Dongyu, Jianheng Liu, Fengyu Quan, Haoyao Chen,
그리고 Mengmeng Fu. 활성 암시적 객체 재구성 사용
불확실성에 기반한 차선책 최적화를 진행 중입니다.IEEE
로봇 공학 및 자동화 편지, 8(10):6395-6402, 2023. 3
- [63] Yan Qingsong, Qiang Wang, Kaiyong Zhao, Jie Chen, Bo
리, 샤오웬 추, 페이 덩. Cf-nerf: 카메라 매개변수
증분 학습을 통해 무료 신경 방사 필드를 제공합니다. 인프로-
AAAI 인공 지능 회의의 회의록,
페이지 6440-6448, 2024. 3, 4
- [64] 린 엔첸, 피트 플로렌스, 조나단 T 배런, 알베르토
로드리게스, 필립 이슬라, 그리고 Tsung-Yi Lin. inerf: 반전
자세 추정을 위한 신경 방사 필드. 2021년 IEEE/RSJ
지능형 로봇 및 시스템에 관한 국제 컨퍼런스
(IROS), 1323~1330페이지. IEEE, 2021. 1, 3, 4
- [65] 황잉 잔(Huangying Zhan), 지양 정(Jiyang Zheng), 이쑤(Yi Xu), 이안 리드(Ian Reid), 하미드(Hamid)
Rezatofighi. Activermap: 활성 매핑을 위한 Radiance 필드
및 Planning.arXiv 사전 인쇄 arXiv:2211.12656, 2022. 3
- [66] 자오보밍(Boming Zhao), 양루웨이(Luwei Yang), 마오마오(Mao Mao), 후준바오(Hujun Bao),
자오펑 추이. Pnerfloc: 포인트를 이용한 시각적 위치 파악
기반 신경 방사 필드. AAAI 절차 중
인공 지능 회의, 7450-7459페이지,
2024. 3, 6, 7
- [67] 정 엔량(Enliang Zheng)과 우 창창(Changchang Wu). 모션의 구조
구조가 없는 절제술을 사용합니다. IEEE 회보 중
컴퓨터 비전에 관한 국제 컨퍼런스, 2075페이지 -
2083년 2015년 2월
- [68] Qunjie Zhou, Maxim Maximov, Or Litany 및 Laura Leal-
Taixe. 완벽한 일치: 시각적인 너프 기능 탐색
현지화. 컴퓨터 비전에 관한 유럽 회의,
108~127페이지. 스프링어, 2024. 3, 6, 7

--- 페이지 12 ---

포즈 이전 및 아래의 3D 가우스 스플래팅에서 포즈 개선에 대한 재고
기하학적 불확실성

보충자료

보충

보충 자료에서 보여드리겠습니다.

- 검색 기반 포즈 초기화를

방법;

- 다양한 매칭 방법을 이용한 비교;
- 파이프라인의 각 모듈을 분석하는 절제 연구;
- 런타임 토론;
- 추가 구현 세부 사항.

A. 사전 이미지 검색 활용

3D Gaussian Splatting의 포즈 개선은 다음 사항에 크게 의존합니다.

초기 포즈의 품질은 이전에 개선되었으므로

모듈은 이 추정치를 중심으로 로컬에서만 포즈를 조정합니다.

결과적으로, 다음을 제공하는 포즈 추정기를 선택합니다.

이전에는 일반적으로 이미지 검색 시스템인 APR 또는 SCR,
전반적인 현지화를 결정하는 데 중요한 역할을 합니다.

성능. 이러한 옵션 중에서 이미지 검색은 다음을 제공합니다.

독특한 장점: APR이나 SCR과 달리

모든 장면별 훈련. 3DGS 장면과 결합하는 경우

표현을 통해 이는 순전히 기하학적 기반의 로컬 기반 표현을 가능하게 합니다.

추가 없이 relocation을 수행하는 ization 파이프라인

학습.

그림 A에 도시된 바와 같이, 기존의 3DGS 기반 재구성은

Finement 파이프라인은 검색된 Top-1의 포즈를 사용합니다.

데이터베이스(DB) 이미지를 이전 포즈로 사용합니다. 이 접근 방식을 사용하는 동안
간단하고 효율적이므로 본질적으로 다음과 같이 가정합니다.

검색된 Top-1 이미지는 쿼리와 공간적으로 가깝습니다. 실제로는

그러나 이 가정은 종종 무너집니다. 다시 하더라도

검색된 DB 이미지는 시각적으로 쿼리와 유사하지만 여전히
예를 들어 상대방과 같은 다른 관점에서 포착할 수 있습니다.

같은 건물의 옆면. 그림 B는 이러한 것을 보여줍니다.

Cambridge LandmarksChurchscene의 실패 사례.

Top-1 검색된 이미지는 높은 시각적 유사성을 나타내며,

하지만 그 자세는 교회 반대편에 놓여 있습니다.

공간적 차이가 크다. 이렇게 잘못된 사전을 정제하는 중

렌더링 품질이나 품질에 관계없이 여전히 어려운 과제입니다.

3DGS 모델에서 장면 세부정보를 사용할 수 있습니다.

우리가 제안한 UGS-Loc은 다음과 같은 방법으로 이러한 제한을 해결합니다.

검색 결과를 몬테카를로 개선으로 통합

프레임워크. 하나의 결정론에만 의존하는 대신

이전에 우리는 Top-Kretrieved DB im의 포즈를 사용했습니다.

초기 가설(입자)로서의 나이. 각 가설은 다음과 같습니다.

일치 조건에서 파생된 중요도 가중치에 서명했습니다.

신뢰도와 기하학적 불확실성을 통해 시스템이 다음을 수행할 수 있게 해줍니다.

오해의 소지가 있는 후보자에 대한 가중치를 낮추고 오직 리샘플링을 통해 신뢰할 수 있는 제품입니다. 그림 B에 도시된 바와 같이, 알-이미지 쿼리

DB 이미지

이미지 검색

가설포즈

상위 1개 이미지

단일 결정적 포즈이전 3DGS-PoseRefinementRefinedPose

imageDB 이미지 쿼리

이미지 검색

Top-K 이미지UGS-Loc

세련된 포즈

(아)

(비)

그림 A. UGS-Loc에 이미지 검색 활용.그림-

결정론적 3DGS 기반 포즈 개선과 비교

이전에 이미지 검색을 포즈로 사용할 때 UGS-Loc. (가) 이전

방법은 최악을 얻기 위해 검색된 Top-1 이미지에만 의존합니다.

gle 결정론적 포즈 가설은 다음을 통해 정제됩니다.

3DGS 기반 파이프라인으로 인해 부정확하거나

모호한 검색 결과. (b) 대신 UGS-Loc은 다음을 활용합니다.

Top-K는 여러 포즈 가설을 생성하기 위해 이미지를 검색했습니다.

중요도 가중치 및 개선을 통해 낮아졌습니다. 이를 통해

오해의 소지가 있는 가설을 억제하고 신뢰를 수렴하기 위한 현지화

실제 카메라 포즈에 가까워졌습니다.

대부분의 초기 입자는 잘못된 쪽에 놓여 있지만

UGS-Loc은 올바른 위치에서 포즈를 샘플링합니다.

중요도 가중치를 활용하여

매칭 모듈의 신뢰도와 불확실성

매칭 포인트. 이는 우리 회사의 견고함을 보여줍니다.

검색 통합 샘플링 방식과 그 광고를 강조합니다.

전통적인 결정론적 포즈 개선에 비해 유리합니다.

우리는 이미지 재통합의 효율성을 평가합니다.

다음과 같이 UGS-Loc 프레임워크에 사전 검색을 수행합니다.

탭. A와 C. 이미지 검색으로 NetVlad [1]을 활용합니다.

모델. 공정한 비교를 위해 반복도 포함합니다.

표준 3DGS 기반 포즈 개선의 적극적인 확장

세련된 포즈를 반복적으로 피드백하는 파이프라인

새로운 초기화로. 이를 통해 직접 비교할 수 있습니다.

기존의 단일 단계 개선에 대한 UGS-Loc-

멘션과 그 반복 변형.

꼬리표. C는 대규모로 현지화 결과를 보고합니다.

--- 페이지 13 ---

표 A. 이미지 검색을 사용한 7개 장면의 위치 파악 결과. 중앙값 변환 오류(cm)와 회전 오류(°)를 보고합니다. 포즈 Prior는 NetVlad [1]에서 검색한 데이터베이스 이미지의 포즈로 초기화됩니다.

반복 방법 Top-K Chess Fire Heads Office Pumpkin Redkitchen Stairs Avg.↓[cm/ °]

1 GS-CPR 1 1.66/0.43 2.38/0.61 1.34/0.67 3.33/0.65 2.16/0.45 2.56/0.54 4.51/1.10 2.56/0.64
 2 1 0.56/0.16 0.80/0.28 0.48/0.32 1.18/0.31 1.13/0.25 0.77/0.19 2.24/0.66 1.03/0.31
 2UGS-Loc(당사)50.40/0.13 0.54/0.21 0.40/0.27 0.88/0.23 0.85/0.19 0.64/0.16 1.80/0.50 0.79/0.24

표 B. 이미지 검색이 포함된 7개 장면의 평균 리콜.

우리는 [2cm,2 o] 및 [5cm,5 o] 이내의 재현율을 보고합니다.

7Scene 전체에 걸쳐 임계값을 설정합니다.

반복 방법 Top-K Acc↑[2cm,2 o] Acc↑[5cm,5 o]

1 GS-심폐소생술 1 43.0 76.6

2 1 79.9 94.4

2UGS-Loc588.9 97.2

에이스 83.3 97.1

캠브리지 랜드마크 데이터세트. 놀랍게도,

이미지 검색과 결합된 UGS-Loc은

ACE [5]의 성능에 필적하는 성능

에 의존하는 장면 좌표 회귀(Scene Coordinate Regression) 방법

현장 훈련. 또한, 단독으로 사용하는 것에 비해

Top-1 검색된 이미지는 이전의 결정론적 포즈, UGS-

Loc은 그럼에도 불구하고 중간 번역 오류를 17% 줄였습니다.

동일한 검색 가정 하에서 운영되며

추가 학습.

검색 기반 실험에는 다음 중 하나가 포함되지만

표준에 비해 추가적인 개선 반복

설정을 통해 개선 사항은 여전히 주목할 만합니다. 이 악마-

UGS-Loc이 불확실성을 효과적으로 완화한다고 설명합니다.

불완전한 검색 사전에 의해 도입되었으며 지속적으로

정확한 포즈를 향해 수렴합니다. 에 대한 평가는

7Scenes 데이터 세트는 Tab에 표시됩니다. A, 이를 추가로 확인합니다.

추세. UGS-Loc은 다음에서 얻은 포즈 사전을 강력하게 처리합니다.

원래의 3DGS 기반 재구성보다 성능이 뛰어납니다.

모든 장면에 걸쳐 정교함과 반복적인 변형이 가능합니다.

B. 다양한 매칭 모듈

우리의 UGS-Loc 프레임워크는 2D-3D 상관관계를 사용하여 포즈를 개선합니다.

2D-2D 매치를 통해 얻은 응답

렌더링된 깊이. 대응 품질이 직접적으로 떨어지기 때문에

기본 2D 일치자에 따라 추가로 평가합니다.

더 광범위한 매칭 모듈 세트로 UGS-Loc을 사용하세요.

주요 논문 외에 ELoFTR [59], XFeat [42] 및 Match-

무엇이든 [27], 중앙값 번역 및 회전을 보고합니다.

Tab의 Cambridge Landmarks 데이터세트에 오류가 있습니다. 디.

모든 일치자에서 UGS-Loc은 지속적으로

강력한 포즈 정제 성능을 보여줍니다.

방법은 일치하는 특정 백본에 의존하지 않습니다.

Transformer 기반의 Dense Matcher는 일반적으로 다음과 같은 이점을 제공합니다.

(b)(a)

그림 B. 이미지 검색을 통한 UGS-Loc 시각화.

이미지 검색을 파이프라인과 통합하면 어떻게 가능해지는지 보여줍니다.

탄탄한 포즈 정제. CambridgeChurchscene에서는 드-

Terministic Top-1 기준선(a)은 다음과 같은 실패 사례를 겪습니다.

검색된 이미지(빨간색 상자)는 반대쪽에서 교회를 봅니다.
 현장의 측면에서 이전에 잘못된 포즈가 발생했습니다. 대조적으로,
 Top-K 검색 포즈(b)를 사용하여 UGS-Loc은 효과적으로 억제합니다.
 그러한 잘못된 가설은 올바른 포즈로 수렴되며,
 파란색 상자로 조명됩니다.
 가볍거나 가볍더라도 더 높은 통신 범위를 제공합니다.
 클래식 매처는 비슷한 위치 정확도를 제공합니다.
 UGS-Loc과 결합 시. 이러한 견고함이 강조됩니다.
 우리 프레임워크의 이점은 주로 다음에서 비롯됩니다.
 불확실성에 기반한 샘플링과 다중 가설이 다시 제기됩니다.
 일치하는 용량 자체가 아니라 정교함입니다.

C. 모듈 제거

탭. E와 F는 파이프라인의 각 구성요소가
 MCR(Monte Carlo Refinement) 및 불확실성 기반
 PnP(UPnP)는 최종 위치 파악 정확도에 기여합니다.
 우리는 DFNet [6]과 ACE [5]를 이전 포즈로 평가합니다.
 다양한 초기에 걸쳐 각 모듈의 일반성을 분석합니다.
 결합 특성. 두 이전 모듈에 대해 UPnP만 활성화
 신뢰할 수 없는 상관 관계를 억제하여 약간의 개선을 가져옵니다.
 깊이 불확실성 안내를 통한 대응. 법인체-

--- 페이지 14 ---

표 C. 이미지 검색을 사용한 7개 장면의 위치 파악 결과. 중앙값 변환 오류(cm)와 회전 오류(°)를 보고합니다. 포즈
 Prior는 NetVlad [1]에서 검색한 데이터베이스 이미지의 포즈로 초기화됩니다.

반복방법 Top-K 킹스병원 Shop Church Avg.↓[cm/

°

]

1

GS-심폐소생술

1 26/0.33 35/0.57 13/0.43 23/0.61 24/0.49

2 1 24/0.26 27/0.46 6.2/0.25 8.8/0.27 17/0.31

3 1 19/0.23 20/0.41 5.9/0.21 6.6/0.22 13/0.27

3 UGS-Loc(당사) 518/0.2015/0.324.3/0.175.4/0.1811/0.22

3 1018/0.19 15/0.314.5/0.17 5.1/0.17 11/0.21

ACE + UGS-Loc 18/0.20 14/0.30 4.5/0.16 6.5/0.21 11/0.22

오차(m,°) : 8.78, 11.04

오류(m,°) : 0.89, 1.11 오류(m,°) : 7.04, 14.26 오류(m,°) : 0.66, 1.26 오류(m,°) : 0.97, 4.49 오류(m,°) : 0.47, 2.15

오류(m,°) : 4.66, 23.02 오류(m,°) : 0.08, 0.44 오류(m,°) : 65.77, 179.17 오류(m,°) : 0.52, 1.11 오류(m,°) : 1.66,

5.34 오류(m,°) : 0.33, 1.27 오류(m,°) : 10.11, 13.03 오류(m,°) : 3.16, 4.07GS-CPR³ + IR UGS-Loc + IR GS-CPR³

+ IR UGS-Loc + IR

GT

추정

GT

추정

GT

추정

GT

추정

오차(m, °) : 1.66, 1.34 오차(m, °) : 0.75, 0.31

그림 C. Cambridge 랜드마크 데이터 세트의 현지화 품질 시각화. 각 열 쌍은 실측을 비교합니다.

(i) 3회 반복으로 반복적으로 수정된 GS-CPR 개선(GS-CPR3으로 표시됨)에서 렌더링된 뷰(오른쪽 상단) [32]

(ii) UGS-Loc 개선(왼쪽 하단). IR은 IR(Image Retrieval)[1]을 통해 사전 포즈가 초기화됨을 나타냅니다. 더욱 타이트해진 비주얼

대각선 경계를 따라 정렬하면 자세 추정이 더 정확해집니다. 빨간색 경계 상자는 정렬이 잘못된 영역을 강조 표시합니다.

UGS-Loc이 결정론적 3DGS 기반 개선으로 해결되지 않은 오류를 수정하는 방법을 강조하는 것이 가장 분명합니다.

MCR 등급만 평가하면 이점을 반영하여 더 큰 이득을 얻을 수 있습니다.

의존하기보다는 다양한 포즈 가설을 탐구하는 것이 적합합니다.

단일 결정론적 사전에 대해.

탭에 표시된대로. E, 불확실성 기반 적용

PnP만으로도 이미 중앙값 변환 오류가 다음과 같이 개선됩니다.

표준 3DGS 기반 포즈에 비해 약 11%

개선. 개량 몬테카를로와 결합 시

개선을 통해 두 번의 반복을 통해 성능이 더욱 향상됩니다.

MCL 구조는 상당한 감소를 달성합니다.

변환 및 회전 오류가 모두 발생합니다. 두 개의 모드가 있을 때

ule이 결합되면 우리는 전체에서 최고의 성능을 관찰합니다.

모든 장면. DFNet 포즈 사전 하에서 결합 시스템

평균 오차를 11cm와 0.22°로 줄여줍니다.

더 나은 포즈 사전(ACE)을 활용하여 동일한 성능을 발휘합니다. 이

--- 페이지 15 ---

표 D. 다양한 2D 매칭 모듈을 사용한 평가. 중앙값 변환 오류(cm)와 회전 오류(°)를 보고합니다.

캠브리지 랜드마크 데이터 세트[19]. 다양한 매칭 모듈을 활용하여 2D-3D 대응을 구축합니다.

사전 매칭자 킹스 병원 상점 교회 평균↓[cm/

°

]

DFNet

SP [45] + LG [31] 20/0.22 17/0.31 5.5/0.26 7.7/0.25 13/0.26

Xfeat [42] 19/0.18 15/0.28 5.5/0.26 6.6/0.20 12/0.23

ELoFTR [59] 20/0.21 13/0.25 4.1/0.19 6.5/0.20 11/0.20

매치애니 [27] 20/0.20 14/0.25 4.0/0.16 6.3/0.20 11/0.20

MASt3r [26] 19/0.19 15/0.30 4.3/0.17 5.8/0.18 11/0.22

에이스

SP [11] + LG [31] 19/0.23 15/0.27 4.0/0.19 7.8/0.26 11/0.26

Xfeat [42] 19/0.19 12/0.25 3.9/0.17 7.2/0.24 11/0.21

ELoFTR [59] 19/0.20 13/0.25 3.7/0.15 7.0/0.23 11/0.21

매치애니 [27] 19/0.20 13/0.26 3.6/0.17 6.6/0.20 11/0.21

MASt3r [26] 18/0.19 14/0.30 4.5/0.16 6.5/0.21 11/0.22

표 E. 캠브리지 랜드마크의 모듈 제거. 캠브리지의 중간 변환 오류(cm) 및 회전 오류(°)를 보고합니다.

랜드마크 데이터 세트 [19]. 우리는 모듈 절제를 위한 포즈로 DFNet [6] 및 ACE [5]를 활용합니다. MCR 및 UPnP는 몬테카를로를 나타냅니다.

개선 및 불확실성 샘플링 기반 PnP 최적화.

이전 MCR UPnP 킹스병원 매장 교회 평균↓[cm/

○

]

DFNet

21/0.25 29/0.54 9.4/0.35 14/0.38 19/0.38
 20/0.25 25/0.58 9.2/0.34 14/0.39 17/0.39
 19/0.20 17/0.30 4.4/0.18 5.8/0.18 12/0.22
 19/0.19 15/0.30 4.3/0.17 5.7/0.18 11/0.22

에이스

21/0.25 19 /0.36 4.7/0.20 9.5/0.29 14/0.28
 19/0.21 18 /0.33 4.6/0.20 8.3/0.26 12/0.25
 18/0.20 15 /0.31 4.3/0.18 6.8/0.21 11/0.23
 18/0.19 14/0.29 4.3/0.17 6.3/0.21 11/0.22

표 F. 7장면에 대한 모듈 제거 [50]. 7장면 데이터셋의 중앙값 변환 오류(cm)와 회전 오류(o)를 보고합니다. 우리

모듈 절제를 위한 포즈로 DFNet [6]을 활용합니다. MCR 및 UPnP는 몬테카를로 개선 및 불확실성 샘플링 기반을 나타냅니다.

PnP 최적화.

이전 MCR UPnP 체스 파이어 헤드 사무실 호박 Redkitchen 계단 평균↓[cm/

○

]

DFNet

0.63/0.18 0.93/0.33 0.56/0.36 1.27/0.33 1.18/0.28 0.93/0.24 2.18/0.59 1.10/0.33
 0.53/0.16 0.81/0.31 0.58/0.38 1.10/0.29 0.99/0.23 0.85/0.23 2.40/0.63 1.04/0.32
 0.40/0.13 0.55/0.21 0.38/0.25 0.83/0.23 0.89/0.21 0.63/0.15 1.18/0.35 0.69/0.22
 0.36/0.12 0.49/0.20 0.36/0.25 0.78/0.22 0.81/0.18 0.59/0.15 1.19/0.35 0.65/0.21

서로 다른 사전에 걸쳐 일관된 수렴이 입증됩니다.

각 모듈은 뚜렷한 불확실성의 원인을 다루고 있습니다.

MCR은 포즈 사전 편향을 완화하는 반면 UPnP는 위치-

2D-3D 리프팅 중 측정 불안정성.

전반적으로 절제를 통해 두 구성 요소가 모두 확인되었습니다.

상호 보완적인 강점과 그 결합에 기여

강력하고 안정적인 포즈 개선 파이프라인을 독립적으로 형성합니다.

포즈 추정기 선택에 따라 달라집니다.

D. 추론 비용

우리는 UGS-Loc이 UGS-Loc보다 더 빠른 추론을 제공한다고 주장하지 않습니다.

결정론적 3DGS 기반 포즈 개선. 왜냐하면 우리의

프레임워크는 기존의 3DGS 개선을 통합합니다.

MCL에서 영감을 받은 다중 가설 전략을 갖춘 파이프라인,

추가 계산이 자연스럽게 도입됩니다. 그러나,

기존 방식처럼 반복적인 개선을 순차적으로 실행하는 대신

선택적 3DGS 파이프라인, UGS-Loc은 멀티프로세싱을 활용합니다.

여러 포즈 가설을 동시에 평가합니다. 이 드-

부호는 많은 계산 오버헤드를 완화하는 데 도움이 되며

다중 입자 설정에서 실질적인 효율성을 제공합니다. 또 다른

추론 속도에 영향을 미치는 중요한 요소는 선택입니다

2D 매칭 모듈의 모습입니다. Sec에서 논의한 바와 같이. 비, UGS-

Loc은 다음과 같은 경우에도 강력한 현지화 성능을 유지합니다.

XFeat 또는 SP+LG와 같은 경량 매처와 짝을 이루며,

--- 페이지 16 ---

오차(cm,°) : 51.38, 11.51

오차(cm,°) : 40.43, 76.19

오차(cm,°) : 2.37, 0.06

오차(cm,°) : 1.33, 0.52

오차(cm,°) : 51.24, 16.34

오차(cm,°) : 27.62, 6.93

오차(cm,°) : 1.45, 0.19

오차(cm,°) : 1.55, 0.27

GS-CPR² + IR UGS-Loc + IR GS-CPR² + IR UGS-Loc + IR

GT

추정

GT

추정

그림 D. 7장면 데이터 세트의 현지화 품질 시각화. 각 열 쌍은 실측 뷰를 비교합니다(상단-

오른쪽) (i) 2회 반복으로 반복적으로 수정된 GS-CPR 개선(GS-CPR2로 표시됨) [32] 및 (ii)에서 렌더링된 관점에 대해 UGS-Loc 개선(왼쪽 하단). IR은 IR(Image Retrieval)[1]을 통해 사전 포즈가 초기화됨을 나타냅니다.

속도와 정확성의 균형을 맞추는 유연성을 제공합니다.

MASt3r 기반 구성 외에는 없습니다.

GS-CPR과의 비교. 하드의 차이로 인해

GS-CPR과의 직접적인 추론 시간 비교 [32]

정규화가 필요합니다. 원래 GS-CPR에 따르면

논문에서 각 구성 요소의 런타임은 다음과 같습니다: 3.7ms

단일 렌더링의 경우 MASt3r [26] 전달의 경우 71ms

통과, MASt3r를 사용한 PnP 최적화의 경우 94ms

매칭. 그러나 우리 환경에서는 동일한 것을 사용하여

코드베이스, 렌더링, MASt3r 추론 및 PnP 최적화

tion에는 각각 12.4ms, 189ms, 182ms가 소요됩니다.

모든 프로세스에서 일관된 속도 저하가 발생합니다. 이 불일치-

알고리즘보다는 하드웨어 차이로 인해 발생합니다.

마이크 오버헤드.

E. 추가 구현 세부 사항

이 섹션에서는 하이퍼파라미터와 구현에 대해 설명합니다.

포즈 개선 파이프라인에 사용된 세부 정보입니다. UGS-

Loc은 두 번의 반복을 통해 PnP 기반 개선을 수행합니다.

반복당 8개의 입자를 유지합니다. 효율성을 위해 우리는

첫 번째 반복에서는 256 해상도를 사용하고 512 해상도를 사용합니다.

두 번째로 해결책을 제시합니다. PnP 최적화를 위해 재현은

7Scenes의 경우 사출 오류 임계값이 1.0px로 설정되어 있으며

2.5px 또는 캠브리지. 최대 반복 횟수

PnP-RANSAC의 경우 GS와 일치하여 1000으로 고정됩니다.

심폐소생술[32]. 불확실성 기반 샘플링 기반 PnP 용어

신뢰 임계값이 0.99에 도달하면 일찍 종료됩니다.

대응 불확실성의 극단값을 방지하기 위해

값을 사용하여 5%~95%를 사용하여 백분위수 클리핑을 적용합니다.
범위. Monte Carlo 개선의 마지막 반복 동안,
우리는 세련된 포즈와 구성을 통해 모든 파티클을 다시 렌더링합니다.
입자 무게를 얻기 위해 SSIM 점수[60]를 입력합니다. 에 대한
7Scenes에서 가중평균을 통해 최종 포즈를 구하고,
Cambridge의 경우 가장 좋은 단일 입자를 선택합니다.
시끄러운 샘플로 인한 성능 저하를 방지합니다.
장면 표현을 위해 Scaffold-GS [35]를 채택하고
기성품에서 얻은 객체 및 하늘 마스크 적용
지나치게 시끄러운 가우스 재구성을 방지하기 위한 모델 [9]
tions. 이전의 여러 현지화 작업과 달리 [17, 28]
7Scenes 실험으로 Gaussian Splatter 모델 학습
심도 감독 없이 RGB 이미지만 사용
GS 이상의 심층적인 기능을 갖춘 장면별 미세 조정
훈련.

--- 페이지 17 ---

오차(cm,°) : 6.34, 1.80

오차(cm,°) : 29.9, 1.80

오차(cm,°) : 0.74, 0.23

오차(cm,°) : 1.33, 0.52

오차(cm,°) : 10.86, 3.03

오차(cm,°) : 11.06, 2.58

오차(cm,°) : 0.78, 0.07

오차(cm,°) : 0.89, 0.25

오차(cm,°) : 10.17, 3.41

오차(cm,°) : 22.21, 17.67

오차(cm,°) : 0.37, 0.40

오차(cm,°) : 0.68, 0.37

오차(cm,°) : 214.78, 49.65

오차(cm,°) : 214.78, 49.65

오차(cm,°) : 111.85, 11.85

오차(cm,°) : 1.09, 0.15

오차(cm,°) : 551.39, 130.70

오차(cm,°) : 0.81, 0.26

오차(cm,°) : 285.10, 17.88

오차(cm,°) : 1.03, 0.53

GS-CPR² + IR UGS-Loc + IR GS-CPR² + IR UGS-Loc + IR

GT

추정

GT

추정

GT

추정

GT

추정

GT

추정

그림 E. 7장면 데이터 세트의 현지화 품질 시각화. 각 열 쌍은 실측 뷰를 비교합니다(상단-오른쪽) (i) 2회 반복으로 반복적으로 수정된 GS-CPR 개선(GS-CPR2로 표시됨) [32] 및 (ii)에서 렌더링된 관점에 대해 UGS-Loc 개선(왼쪽 하단). IR은 IR(Image Retrieval)[1]을 통해 사전 포즈가 초기화됨을 나타냅니다.